

基于改进 YOLOv11n 的固定栓目标检测算法

薛志凯,陶卫军

(南京理工大学 机械工程学院,南京 210000)

摘要: 针对移动机器人视角下固定栓目标检测中存在的计算开销大及复杂场景干扰导致检测精度不足的问题,提出了一种改进的轻量化目标检测算法SPAD-YOLOv11。首先,引入了Pinwheel-shaped Convolution(PCConv)替代原有卷积模块,在减少参数数量的同时扩大感受野,从而提升目标特征提取能力;其次,使用Starnet模型作为骨干网络,显著降低模型的计算复杂度;最后,为提升通道间的特征表达能力,引入Adaptive Fine-Grained Channel Attention(AFCA)机制,通过融合多粒度的全局与局部信息实现细粒度的通道建模。同时,嵌入无归一化的可学习激活函数DynamicTanh(DyT),作为注意力模块前后的激活结构,提升训练稳定性并减少计算负担。在复杂环境下的自建数据集上的实验结果表明,与YOLOv11n相比,改进后的算法准确率提升1.7%,召回率提升2.3%,mAP@50提高0.1%,mAP@50-95提高1.2%,模型的参数量降低30.8%,计算量降低11.1%。这表明该算法在实现了轻量化设计的同时,又保证了较高的检测精度,能够满足移动机器人固定栓目标检测的实际需求。

关键词: 移动机器人;固定栓检测;目标检测;轻量化;YOLOv11n

中图分类号: TP273

文献标识码: A

文章编号: 1001-9944(2025)11-0050-08

Fixed Bolt Target Detection Algorithm Based on Improved YOLOv11n

XUE Zhikai,TAO Weijun

(School of Mechanical Engineering,Nanjing University of Science and Technology,Nanjing 210000,China)

Abstract: To address the issues of high computational cost and reduced detection accuracy caused by complex scene interference in fixed bolt detection from a mobile robot perspective, this paper proposes an improved lightweight object detection algorithm, SPAD-YOLOv11. First, a pinwheel-shaped convolution (PCConv) is introduced to replace the original convolution module, significantly reducing the number of parameters while expanding the receptive field, thereby enhancing the feature extraction capability. Second, the Starnet model is employed as the backbone network to notably reduce the model's computational complexity. Finally, to improve feature representation across channels, an adaptive fine-grained channel attention (AFCA) mechanism is integrated, which fuses multi-scale global and local information for fine-grained channel modeling. Additionally, a non-normalized, learnable activation function, DynamicTanh (DyT), is embedded before and after the attention module to enhance training stability and reduce computational burden. Experiments conducted on a self-built dataset with complex backgrounds show that, compared with the original YOLOv11n, the improved algorithm achieves a 1.7% increase in precision, a 2.3% increase in recall, a 0.1% improvement in mAP@50, and a 1.2% improvement in mAP@50-95. Moreover, the model's parameter count is reduced by 30.8%, and its computational cost is decreased by 11.1%. These results demonstrate that the proposed algorithm achieves a balance between lightweight design and high detection accuracy, making it well-suited for fixed bolt detection tasks in mobile robotic applications.

Key words: mobile robot; fixed bolt detection; object detection; lightweight; YOLOv11n

固定栓是船舶上的重要核心设施,其大量且不均匀分布在船舶的甲板上。而目前的巡检和维护方

式主要依赖于人工进行,存在效率低、准确性差和安全性不足等问题。随着船舶工业的发展,传统人

收稿日期:2025-05-29;修订日期:2025-09-12

作者简介:薛志凯(1998—),男,硕士,研究方向为移动机器人、计算机视觉;陶卫军(1975—),男,博士,副教授,研究方向为特种机器人、医疗服务机器人、智能移动机器人。

工巡检方式已难以满足高效精准的需求。搭载目标检测算法的移动机器人为此提供了有效的解决方案,但其有限的计算资源对算法的轻量化与精度提出了更高的要求。此外,船舶甲板的光照变化、相机模糊、栓体弱纹理等复杂因素,也会在一定程度上影响检测算法的性能。

现有的目标检测算法主要可分为两阶段方法 Faster R-CNN^[1]、Mask R-CNN 和一阶段方法如 SSD^[2] (single shot multibox detector) 和 YOLO^[3] (you only look once) 系列。前者检测精度高但检测速度慢,不适用于实时场景;后者检测速度快,更适合移动端部署。YOLOv11 作为 YOLO 系列的最新轻量化模型,在速度和精度上取得了良好平衡。然而,在特定应用场景下,YOLOv11 仍存在检测精度不足的问题。为此,本文基于 YOLOv11n 提出一种改进的固定栓目标检测算法 SPAD-YOLOv11。

1 基于 YOLOv11n 的改进算法

1.1 YOLOv11 模型

YOLOv11^[4] 是基于 YOLOv8 改进的新一代 SOTA (state of the art) 一阶段目标检测算法,其网络

结构由主干网络 (Backbone)、特征增强网络 (Neck) 和检测头 (Head) 组成。

YOLOv11 的主干网络采用了 C3k2 块,替代了之前版本中的 C2f 块。C3K2 模块是 YOLOv11 中对 CSP (cross stage partial networks) 结构的优化实现^[5],旨在提升特征提取的效率和速度。C3K2 的设计允许在每个卷积层中处理不同的特征通道,使得模型能够更好地捕捉多样化的信息^[6]。在 YOLOv11 中,特征增强网络部分也进行了优化,在 SPPF 模块后面添加了一个 C2PSA 模块。C2PSA 模块继承了 CSP 的分段特征处理思想,特征经过一次 1×1 卷积后被分成两部分,一部分直接传递,另一部分经过 PSA 注意力模块^[7]处理,然后将两部分特征拼接,并经过另一个 1×1 卷积来恢复原始通道数 YOLOv11 相比于 YOLOv8 模型,在保持高效检测能力的同时,也能减少计算资源的使用。

1.2 改进模型 SPAD-YOLOv11

针对 YOLOv11 在移动机器人固定栓检测场景下存在的不足之处,提出一种改进算法,其整体结构如图 1 所示。SPAD-YOLOv11 模型结构如图 2 所示。主要改进如下:




图 1 YOLOv11 网络结构

Fig.1 YOLOv11 model structure




图2 SPAD-YOLOv11 模型结构

Fig.2 SPAD-YOLOv11 model structure

(1) 引入 PConv (pinwheel-shaped convolution) 来替换原有的卷积模块,以更小的参数量来获得更大更高效的感受野以增强对目标的特征提取能力。

(2) 为降低模型的参数量以及计算量,采用改进的 Starnet 模型来替换原有的骨干网络。并采用 PConv 对 Starnet 模型进行改进,以降低参数下降带来的精度损失。

(3) 通过添加 DynamicTanh^[8](DyT) 激活函数并结合 AFCA^[9](adaptive fine-grained channel attention) 注意力机制来改进 C2PSA 模块,以此来提升模型对通道特征的表达能力和训练稳定性。

1.2.1 PConv 模型

PConv^[10]模型的架构如图3所示。相比于标准卷积,PConv 采用非对称填充策略,以创建具有方向性的水平和垂直卷积核,从而实现卷积核向外扩散的特性。设输入张量为 $X^{(h_1, w_1, c_1)}$,其中 h_1, w_1, c_1 分别表示输入的高度、宽度与通道数。为了提升训练过程的稳定性与收敛速度,在每次卷积操作后均引入批归一化 (batch normalization, BN) 以及激活函数 SiLU (sigmoid

linear unit)。PConv 的第一层的并行卷积公式如下:

$$\begin{aligned} X_1^{(h', w', c')} &= \text{SiLU} \left(\text{BN} \left(X_{P(1,0,0,3)}^{(h_1, w_1, c_1)} \otimes W_1^{(1,3, c')} \right) \right) \\ X_2^{(h', w', c')} &= \text{SiLU} \left(\text{BN} \left(X_{P(0,3,0,1)}^{(h_1, w_1, c_1)} \otimes W_2^{(3,1, c')} \right) \right) \\ X_3^{(h', w', c')} &= \text{SiLU} \left(\text{BN} \left(X_{P(0,1,3,0)}^{(h_1, w_1, c_1)} \otimes W_3^{(1,3, c')} \right) \right) \\ X_4^{(h', w', c')} &= \text{SiLU} \left(\text{BN} \left(X_{P(3,0,1,0)}^{(h_1, w_1, c_1)} \otimes W_4^{(3,1, c')} \right) \right) \end{aligned} \quad (1)$$

式中: $\otimes$ 是卷积运算符; $W_1^{(1,3, c')}$ 是一个 1×3 的卷积核; c' 为输出通道。填充参数 $P(1,0,0,3)$ 分别表示在左、右、上、下方向的填充像素数。

第一层交错卷积后输出特征图的高度 (h')、宽度 (w') 和通道数 (c') 与输入特征图的关系为

$$h' = \frac{h_1}{s} + 1, w' = \frac{w_1}{s} + 1, c' = \frac{c_2}{4} \quad (2)$$

式中: c_2 是 PConv 模块最终输出特征图的通道数; s 是卷积步长。




图3 PConv 结构

Fig.3 PConv structure

第一层交错卷积的结果进行拼接,输出计算为

$$X'^{(h',w',4c')} = \text{Cat}(X_1^{(h',w',c')}, \dots, X_4^{(h',w',c')}) \quad (3)$$

最后,拼接后的张量通过卷积核 $W^{(2,2,c_2)}$ 进行归一化,不进行填充。输出特征图的高度和宽度调整为预设值 h_2 和 w_2 ,使 PConv 可与 Conv 层互换,并作为一种通道注意力机制分析不同卷积方向的贡献。最终输出 $Y^{(h_2,w_2,c_2)}$ 计算如下:

$$h_2 = h' - 1 = \frac{h_1}{s}, w_2 = w' - 1 = \frac{w_1}{s}$$

$$Y^{(h_2,w_2,c_2)} = \text{SiLU}(\text{BN}(X'^{(h',w',4c')} \otimes W^{(2,2,c_2)})) \quad (4)$$

PConv 的感受野的有效性向外逐渐减弱,类似于高斯分布,且目标越小,其特征越集中,突出了中心特征的重要性。PConv 利用分组卷积,在显著增加感受野的同时最小化参数数量。标准卷积(Conv)的参数数量计算公式为

$$\text{Conv}_{\text{params}} = c_2 \times c_1 \times k, (\text{bias} = \text{False}) \quad (5)$$

若输出通道数(c_2)等于输入通道数(c_1), 3×3 的 Conv 参数为 $9c_1^2$ 。而 PConv 的参数计算如下:

$$\begin{aligned} \text{PConv}_{\text{params}} &= 4 \times ((c_2/4) \times c_1 \times 3 \times 1) + 4c_2c_1 \\ &= 7c_2c_1 = 7c_1^2 \end{aligned} \quad (6)$$

从这两个公式的输出相比较的结果中,可以看到如果卷积核大小同样为 3 的时候,PConv 的参数数量减少 22%,而感受野增加了 177%。同样,如果使用 PConv 替换 YOLOv11 中的前两个卷积模块,相比于普通卷积,PConv 的在参数量增加 111% 的情况下,感受野增大 178%。这充分表明了,使用 PConv 对普通卷积模块进行替换,能够以最小的参数量的

增加实现更加有效的感受野的增加。从而以更少的参数实现更高效的特征提取。

通过集成 PConv 模块,模型的感知能力可以得到大幅提高,从而在移动机器人的检测任务中保持较高的检测精度。

1.2.2 Starnet 骨干网络

YOLOv11 采用 CSPDarknet^[11] 作为其骨干网络,相比于 YOLOv8,增加了一个 C2PSA 模块,并且将 C2f 替换为了 C3k2。尽管二者的引入使得 YOLOv11 在计算效率以及特征提取能力上得到提高,但 CSPDarknet 原有的多层卷积以及池化操作仍然存在,从而导致训练周期的延长以及训练完毕后的模型的参数量以及计算量的增加。因此,本文引入了轻量化网络模型 Starnet^[12] 作为 YOLOv11 新的骨干结构,其整体结构如图 4 所示。

Starnet 作为一种结构简洁且高效的网络架构,通过引入独特的星形操作(即元素级乘法),一定程度上提升了全局特征提取能力,同时避免了网络宽度的扩张。使用 Starnet 作为骨干网络显著增强了模型在移动机器人这一计算资源受限情况下的部署适应能力。

StarNet 采用四阶段的分层架构,每个阶段通过卷积下采样,并结合 Star Block 模块提取特征。整体流程如下:在起始阶段,输入特征图通过 7×7 的深度可分离卷积(DW-Conv),高效提取局部特征的同时显著减少参数量。随后,批量归一化(Batch Normalization)增强训练稳定性、加快收敛,并提升模型对抗扰动的鲁棒性。归一化后的特征被分为 2 组,其中一组通过 1×1 点卷积进行通道混合,以实现非线性特征变换。另一组则通过 ReLU6^[13] 激活函数引入非线性,有助于增强模型表达能力并优化梯度传播。




图4 Starnet 结构图

Fig.4 Starnet structure

Starnet 原始各阶段使用的卷积模块由卷积核大小为 3 的 Conv2d、Batch Normalization 和 ReLU 激活函数顺序堆叠而成。相比之下,原模块在细粒度特征建模和特征表达方面能力有限,难以满足固定栓目标检测的高特征敏感度需求,因此引入了 PConv。替换过程中,考虑到星模块(Star Block)中仍需进行 ReLU 激活,而 PConv 默认采用 SiLU 激活,为避免重复激活引发的梯度爆炸和计算冗余,将 SiLU 设置为可选,仅在星模块外部保留 SiLU,内部仍使用 ReLU。通过上述设计,可以实现在保持 Starnet 原有的轻量化的优势的同时,用能够充分利用 PConv 模块的特征提取能力。

1.2.3 C2AFCA_DyT

为提升模型对通道间信息的建模能力并优化训练过程,本文对 Neck 网络中的 C2PSA 模块进行了改进。引入了自适应细粒度通道注意(AFCA)机制和动态激活函数 DyT。DyT 函数是由文献[8]于 2025 年最新提出的一种用于实现替代归一化层的操作。归一化层可以提升注意力模块的鲁棒性和稳定性,归一化的过程可以表达为

$$\text{normalization}(x) = \gamma \cdot \left(\frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}} \right) + \beta \quad (7)$$

式中: ε 是一个常数; γ 和 β 是可学习向量参数。它们是缩放和移动仿射参数,允许输出在任何范围内。

μ 和 σ^2 表示输入的均值和方差。原始 PSA 结构中缺少这一过程对注意力机制的输入/输出进行控制,从而导致注意力响应可能存在数值偏移、不稳定或过饱和等问题。而传统归一化往往依赖于均值、方差等全局统计量,可能导致被检测目标的特征被压缩或失真等问题。除此之外,归一化也会导致模型的计算复杂度增加。因此引入 DyT 结构,它的非线性特征类似于归一化的特征。它的定义如下:

$$\text{DyT}(x) = \gamma \cdot \tanh(\alpha x) + \beta \quad (8)$$

式中: α 是一个可学习的标量参数,用于根据输入的范围动态调整缩放比例。DyT 通过 $\tanh$ 函数对输入进行非线性变换,同时保留了归一化层对极端值的压缩以及保持训练稳定性等效果。但又避免了归一化层带来的特征压缩以及计算量增加等问题。

自适应细粒度通道注意 AFCA 机制是由文献[9]于 2024 年提出的一种新型注意力机制,其整体结构如图 5 所示。

AFCA 通过对通道依赖性的精细建模实现特征增强。AFCA 首先将输入张量 $F \in \mathbb{R}^{C \times H \times W}$ 通过全局平均池化(GAP)压缩为通道描述符 $U \in \mathbb{R}^C$,随后分别提取其全局信息 U_{gc} 和局部信息 U_{lc} 表示。通过将对象矩阵获得的全局信息与通过带状矩阵获得的局部信息相结合,从而实现信息的充分融合。此机制不仅能够同时捕获通道间的全局和局部依赖关系,还能




图5 AFCA 结构

Fig.5 AFCA structure

根据输入数据动态调整两种依赖的相对重要性,显著提升模型的特征表达能力而仅带来微小的计算开销。

二者融合改进原有的 C2PSA 模块,仅增加了少量的计算复杂度,就实现了模型训练稳定性的提升和特征融合能力的增强,在一定程度上提升了模型的检测精度。

2 实验与分析

2.1 实验数据集

本文的检测算法使用了自建的船舶固定栓的单一类别数据集,包含从不同角度、距离以及不同表面状态的固定栓图像。最终获得图像数据 1000 张,按照 8:1:1 的比例随机划分为训练集、验证集和测试集。同时为了增加数据多样性,避免模型过度依赖训练集中的局部特征或噪声对训练集进行了一定程度的图像增强。

2.2 实验环境及训练参数

实验所使用的相关硬件、软件及实验环境详细信息如表 1 所示,训练参数设置如表 2 所示。其他训练策略及超参数为默认设置。

表 1 实验环境配置

Tab.1 Experimental environment configuration

类别	配置	类别	配置
系统环境	Windows11	解释器	Python 3.12
CPU	Intel Core i7-13650HX	框架	PyTorch 2.5.0
GPU	NVIDIA GeForce RTX 4060 Laptop	CUDA	12.4

表 2 训练参数

Tab.2 Training parameters

参数	配置	参数	配置
迭代周期(epoch)	250	学习率衰减(lrf)	0.001
批处理大小(batch size)	16	优化器(optimizer)	AdamW
初始学习率(lr0)	0.0005	动量因子(momentum)	0.9

2.3 评价指标

本文使用参数量(parameters)和浮点计算量(GFLOPs)作为衡量模型轻量化的指标,参数量和 GFLOPs 越小,表明模型的轻量化程度越高,也代表着模型对所运行的硬件平台的计算资源需求越低。

为了评估目标检测算法的性能,本文取了准确率(Precision)、召回率(Recall)以及平均精度均值(mean Average Precision, mAP)作为主要评价指标。

2.4 模型对比实验

为验证改进算法的有效性,在自建数据集上评估所提出算法的性能,并在相同的实验环境下与 YOLOv5n、YOLOv8n、YOLOv10n 以及 YOLOv11n 等主流目标检测检测算法进行了对比实验。实验结果如表 3 所示。

由表 3 可知,尽管 YOLOv8n 和 YOLOv10n 在精度上表现不错,但其参数量和计算量过大。而 SPAD-YOLOv11 在参数量与 YOLOv5n 相当的情况下,各项精度指标均明显占优,相较于基准模型 YOLOv11n,在精度和轻量化方面取得了更优的综合表现。

2.5 模型消融实验

为验证 SPAD-YOLOv11 各个改进的有效性以

及对改进算法整体在检测精度以及轻量化等方面的影响,以 YOLOv11n 为基础进行消融实验。实验

结果如表 4 所示,其中“√”标记代表采用了该算法或改进点。

表 3 主流目标检测算法检测结果对比

Tab.3 Comparison of experimental results of mainstream target detection algorithms

模型	准确率/%	召回率/%	GFLOPs	参数量/ 10^6	mAP50/%	mAP50-95/%
YOLOv5n	94.5	93.4	4.1	1.8	95.6	78.5
YOLOv8n	96.8	94.7	8.1	3.0	98.8	79.1
YOLOv10n	96.7	95.7	8.2	2.7	97.0	79.3
YOLOv11n	95.2	96.1	6.3	2.6	98.5	81.1
SPAD-YOLOv11	96.9	98.4	5.6	1.8	98.6	82.3

表 4 消融实验结果对比

Tab.4 Comparison of results of ablation experiments

YOLOv11n	Starnet	PConv	C2AFCA_DyT	准确率/%	召回率/%	GFLOPs	参数量/ 10^6	mAP50/%	mAP50-95/%
√	×	×	×	95.2	96.1	6.3	2.6	98.5	81.1
√	√	×	×	94.6	93.9	5.0	1.9	98.1	78.5
√	×	√	×	95.4	97.9	6.3	2.5	97.6	80.5
√	×	×	√	95.3	98.6	6.3	2.5	97.7	80.8
√	√	√	×	96.6	95.7	5.6	1.9	98.6	81.4
√	√	√	√	96.9	98.4	5.6	1.8	98.6	82.3

由表 4 可知,单独引入 Starnet 骨干网能显著降低模型参数量和计算量(分别下降26.9%和20.6%),但精度略有牺牲。在 Starnet 基础上,进一步引入 PConv 和 C2AFCA_DyT 模块后,模型的准确率、召回率和 mAP 指标均得到提升,有效弥补了轻量化带来的性能损失,并超越了原始基准。

最终的 SPAD-YOLOv11 模型相比 YOLOv11n,参数量降低 30.8%,计算量降低 11.1%,而 mAP50-95 提升了 1.2%,验证了所提改进之间协同作用的有效性。

2.6 可视化结果与分析

本研究采用 Grad-CAM++^[14]方法对基准模型 YOLOv11n 以及本文提出的改进模型进行可视化分析,生成的热力图中像素值反映了对应区域在目标检测中的重要性。

固定栓模型的目标检测热力图如图 6 所示,其中第 1 行为 YOLOv11n 所得热力图,第 2 行为改进后模型的热力图。从图 6 中可以看出,面对不同尺度的检测目标时,改进后的模型能够更加关注目标区域。以及在目标有一定的遮挡时,改进后模型能



(a)YOLOv11n 模型热力图



(b)SPAD-YOLOv11 模型热力图

图 6 实验热力图

Fig.6 Heat map of experiment

够更加清晰且集中的感知到待检测目标。

3 结语

针对现有模型在计算资源受限的设备上表现不佳,以及复杂背景下模型特征识别能力差等问题,本文提出一种以 Starnet 模型作为骨干网络并融合 PConv 和 C2AFCA_DyT 模块的轻量化固定栓检测算法 SPAD-YOLOv11。在模型性能指标方面,与 YOLOv11n 相比,改进后的算法准确率提升 1.7%,召回率提升 2.3%,mAP50 提高 0.1%,mAP50-95 提高 1.2%,使得改进后的算法能更准确地识别出固定栓。同时,模型的参数量降低 30.8%,计算量降低 11.1%,在实际应用中能够更高效地在边缘设备上运行。

未来的工作将围绕模型剪枝和知识蒸馏等方向进一步优化算法,以期在不显著降低检测精度的前提下,进一步提升模型的泛化能力和推理速度,使其更适用于嵌入式轻量化设备的部署。

参考文献:

- [1] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6): 1137-1149.
- [2] Liu W, Anguelov D, Erhan D, et al. SSD: Single shot MultiBox detector[C]//European Conference on Computer Vision, 2016.
- [3] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Computer Vision & Pattern Recognition, 2016.
- [4] Khanam R, Hussain M. YOLOv11: An overview of the key architectural enhancements[J]. arXiv, 2024, 24: 1-9.
- [5] He L, Zhou Y, Liu L, et al. Research and application of YOLOv11-based object segmentation in intelligent recognition at construction sites[J]. Buildings, 2024, 14(12): 3777.
- [6] 陈佳, 章坚武, 张浙亮. 基于上下文信息与注意力特征的欺骗语音检测[J]. 电信科学, 2023, 39(2): 92-102.
- [7] Zhang H, Zu K, Lu J, et al. EPSANet: An efficient pyramid squeeze attention block on convolutional neural network[C]//Asian Conference on Computer Vision, 2023.
- [8] Zhu J, Chen X, He K, et al. Transformers without normalization[C]//IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2025.
- [9] Sun H, Wen Y, Feng H, et al. Unsupervised bidirectional contrastive reconstruction and adaptive fine-grained channel attention networks for image dehazing[J]. Neural Networks, 2024, 176: 1-6.
- [10] Yang J, Liu S, Wu J, et al. Pinwheel-shaped convolution and scale-based dynamic loss for infrared small target detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(9): 9202-9210.
- [11] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A new backbone that can enhance learning capability of CNN[C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2020.
- [12] Ma X, Dai X, Bai Y, et al. Rewrite the stars[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2024.
- [13] Lin G, Shen W. Research on convolutional neural network based on improved relu piecewise activation function[J]. Procedia Computer Science, 2018, 131: 977-984.
- [14] Chattopadhyay A, Sarkar A, Howlader P, et al. Grad-CAM++: Generalized gradient-based visual explanations for deep convolutional networks[C]//2018 IEEE Winter Conference on Applications of Computer Vision (WACV), 2018.
- [1] 赵国强, 黄永华, 韩其飞. 面向发动机部件定制加工的矩阵式智能产线设计[J]. 机床与液压, 2023, 12(10): 162-167.
- [2] 王世勇, 万加富, 张春华, 等. 面向智能产线的柔性输送系统结构与智能控制[J]. 华南理工大学学报(自然科学版), 2016(3): 30-35.
- [3] 曹锦江, 陈桂, 黄家才. 智能制造背景下自动化类专业综合实践平台的设计与实践[J]. 实验技术与管理, 2021, 38(3): 278-282.
- [4] 刘肖燕, 左锋, 张珏, 等. 新工科背景下面向复杂工程问题的自动化实验教学改革创新实践[J]. 实验室研究与探索, 2020, 39(9): 188-191.
- [5] 庆鹏展, 刘建群, 李强. 面向伺服运动控制的实时 EtherCAT 主站开发[J]. 机电工程, 2019, 36(11): 1216-1220.
- [6] 刘新洋, 栗琳, 张佳明. 工业机器人自动视觉检测综合实训平台的设计与实践[J]. 实验室研究与探索, 2024, 43(2): 222-225.
- [7] 刘志恒, 郝雷, 李敏, 等. 基于伺服电动机目标位置控制实验平台[J]. 实验室研究与探索, 2023, 42(8): 111-116.
- [8] 于赫洋, 刘丽萍, 王超. 新工科智能制造实践教学平台建设[J]. 实验技术与管理, 2023, 40(9): 275-279.
- [9] 张翰明, 徐宏海, 魏领会. 虚实结合的智能制造实训教学模式探索[J]. 实验技术与管理, 2024, 41(5): 203-209.
- [10] 钱志源, 李念涓, 李俊烨, 等. 基于视觉检测技术和仿形设计的导电滑环轴向接触位置测试方法研究[J]. 中国机械工程, 2025, 50(5): 121-128.
- [11] 王金栋, 谢成胜, 张行健, 等. 机器人搭载双目视觉系统下的工件尺寸检测方法研究[J]. 仪器仪表科学, 2025, 41(3): 201-208.
- [12] 朱彦, 王坚. 基于知识图谱推荐的钢铁产线智能故障诊断[J]. 控制理论与应用, 2023(12): 1548-1558.
- [13] 洪金华, 程宝, 程鹏. 柔性压力传感器教学实验平台设计与实现[J]. 实验室研究与探索, 2024, 43(5): 29-33.
- [14] 田莉, 郝雯娟, 王志凌. 四旋翼飞行器创新实验平台的渐进式教学实践[J]. 实验室研究与探索, 2024, 42(10): 166-169.

(责任编辑: 马丽亚) ■

(责任编辑: 马丽亚) ■