

面向路网交通流态势预测的图神经网络模型

姜 山^{1,2}, 丁治明^{1,3+}, 徐馨润^{1,2}, 严 瑾^{1,2}

1. 中国科学院 软件研究所, 北京 100190

2. 中国科学院大学, 北京 100190

3. 大规模流数据集成与分析技术北京市重点实验室, 北京 100190

+ 通信作者 E-mail: zhiming@iscas.ac.cn

摘 要: 融合了路网结构的交通流态势预测是一个高度非线性化且复杂的时空动态相关性的时序数据预测问题。然而, 传统交通流态势预测方法无法建模交通网络中长时间序列数据间的时空相关性。针对交通路网交通流态势预测问题, 提出了一种基于图结构的交通流预测深度学习模型。首先, 基于图小波变换定义图小波卷积算子, 设计了面向路网交通流态势预测的图小波卷积神经网络模块; 其次, 结合时空注意机制构建了用于道路网络交通流态势预测的时空动态相关性模型, 以捕获交通网络的动态时空相关性; 最后, 采用叠加多层图小波神经网络模块的策略, 构建了一种面向路网交通流态势预测的图小波卷积神经网络模型。实验结果表明, 该网络模型在数据集上的性能优于现有的基线模型。通过图小波变换矩阵与傅里叶变换矩阵非零元素统计对比实验, 发现基于图小波变换定义的卷积运算更具稀疏性。因此, 基于图小波变换定义的卷积运算更有助于提升交通流态势预测模型的计算效率。

关键词: 交通流态势预测; 图卷积; 图小波神经网络; 交通流

文献标志码: A **中图分类号:** TP391.4

Graph Neural Network for Traffic Flow Situation Prediction

JIANG Shan^{1,2}, DING Zhiming^{1,3+}, XU Xinrun^{1,2}, YAN Jin^{1,2}

1. Institute of Software, Chinese Academy of Sciences, Beijing 100190, China

2. University of Chinese Academy of Sciences, Beijing 100190, China

3. Beijing Key Laboratory on Integration and Analysis of Large-Scale Stream Data, Beijing 100190, China

Abstract: Road network structure integrated traffic flow situation prediction is a highly nonlinear and complexly spatial-temporal dynamic correlation time-series data prediction problem. However, traditional traffic flow situation forecasting methods cannot model the temporal and spatial correlation in long-term series data in the traffic network. To address the issue mentioned above, a deep learning model of traffic flow prediction based on graph structure is proposed. Firstly, the graph wavelet convolution operator is defined based on the graph wavelet transform. Furthermore, the graph wavelet convolution neural network module is designed based on the operator for the traffic flow situation prediction. Secondly, a spatial-temporal dynamic correlation model is constructed based on the spatial-temporal attention mechanism to capture the dynamic temporal and spatial correlation of the traffic network. Finally, the strategy

基金项目: 国家自然科学基金 (61703013, 91646201) 北京市自然科学基金 (4192004)。

This work was supported by the National Natural Science Foundation of China (61703013, 91646201) and the Natural Science Foundation of Beijing (4192004).

收稿日期: 2020-11-03 修回日期: 2021-01-22

of stacking multi-layer graph wavelet neural network modules is adopted to establish a novel graph wavelet neural network for road network traffic flow situation prediction. Experimental results show that the developed model's performance on the experimental datasets is better than the existing baseline models. In the comparative experiment on the non-zero element statistics of the graph wavelet transform matrix and the Fourier transform matrix, it's found that the convolution operation based on the graph wavelet transform is more sparse. Therefore, the convolution operation defined based on the graph wavelet transform is more helpful to improve the calculation efficiency of the traffic flow situation prediction model.

Key words: traffic flow situation prediction; graph convolution; graph wavelet neural network; traffic flow

城市道路网中的交通流态势预测问题是应急管理科学和城市管理科学等众多领域的核心问题之一。路网交通流态势预测是一个典型的时空时序数据预测问题,交通流数据被分布在城市道路网络各个固定卡口的数据采集设备以固定时间间隔连续采集。相邻设备采集的数据记录以及不同时间戳下的数据记录具有某种时空相关性。因此,有效地捕捉道路网络中观测数据间的时空相关性是解决交通流态势预测问题的关键。

近年来,卷积神经网络(convolutional neural network, CNN)^[1-2]模型与算法已经广泛地被用于计算机视觉任务和模式识别任务等领域,神经网络以其独特的数据经验优势和其卷积核的领域相关性优势,在交通流预测问题中得到了学界的普遍关注,有大量学者研究并提出了用于交通流预测的循环神经网络及其多种改进版本^[3-5]。然而, CNN 的计算通常被限定在欧式空间。对于欧式空间以外的非欧式空间数据的处理,传统的 CNN 就显得乏力。由于非欧式空间下的图结构数据具有很强的数据建模与表达能力,越来越受到关注,比如,文献[6-8]就提出了基于图数据结构的图卷积神经网络(graph convolutional neural network, GCNN)模型与算法, GCNN 模型一经提出就受到了学界和工业界的广泛重视。此外,文献[9]提出了一种能预测结构化数据序列的深度学习模型,即图卷积循环网络(graph convolutional recurrent network, GCRN)。该模型结合 CNN 对图形进行空间结构特征提取,并采用循环神经网络^[10](recurrent neural network, RNN)对时序数据的动态特征进行提取,但是不能很好地拓展到更大尺度的时间预测窗口。进一步地,文献[11]针对交通领域的时间序列预测问题,提出了一种新的时空图卷积网络学习框架,基于图形结构建立了具有完整卷积结构的图神经网络模

型,其在较少参数的情况下,能够有效保证训练速度,但是该方法对图的卷积核邻域尺寸的支持不够灵活。文献[12]提出了一种用于时空图建模的新型图神经网络模型,该模型能够准确地捕获数据中隐藏的空间依赖关系。此外,文献[13]将图小波代替图拉普拉斯的特征向量作为基底,通过小波变换和卷积定理定义卷积算子,提出的模型能够实现节点的分类预测,但无法对交通数据的时空特征和动态相关性进行同时建模。

一个时序预测模型与算法不仅要考虑某感兴趣路段的历史观测数据,还需要考虑相邻路网观测对其的累积影响效应。因此,本文提出了基于图小波卷积网络的路网交通流态势预测模型与方法。首先,基于图小波卷积算子,设计了面向路网交通流态势预测的图小波神经网络模块,对交通数据的时空相关性和动态相关性进行建模;其次,通过引入注意力机制构建时空注意力模型,以捕获交通网络上的动态时空相关性;最后,通过叠加多层图小波神经网络模块从交通网络图节点邻域中捕获空间相关性。

1 路网交通流态势预测与图小波卷积

1.1 路网交通流态势预测

1.1.1 交通路网图模型

以城市路网交通流探测传感器 i 安装位置为节点,以 v_i 表示,并且以相邻路段上的传感器 j 为邻居节点 v_j ,构建交通路网图模型 G ,定义如下:

$$G=(V,E,A) \quad (1)$$

其中, V 表示节点集合,在路网中表示交通流探测传感器集合,且 $|V|=N$ 。 E 表示图 G 中边的集合,元素 $e_i=<v_i,v_j>\in E$ 表示节点 v_i 和节点 v_j 有联结关系。在路网图构建过程中,通常以节点 v_i 邻域范围内邻居

节点构建边或联结。 $A \in \mathbb{R}^{N \times N}$ 为图 G 的邻接矩阵。本文构建的交通路网图 G 是无向图模型。在图 G 中,每个传感节点 v_i 以相同频率 p 采集 m 个测量属性值(如车流量和行驶平均速度等),即在每个时间片 t 下每个节点 v_i 共收集 m 维度的特征向量 $\mathbf{x}^i \in \mathbb{R}^m$ 。

1.1.2 路网交通流预测

交通路网图 G 中每个节点以相同的频率进行数据采集,每个节点包含 m 维测量属性值,即在时间步 t 下图 G 中每个节点 v_i 观测属性值属于 m 维特征向量 $\mathbf{x}_t^i \in \mathbb{R}^m$ 。对于道路网络图 G ,在给定历史观测序列值 $(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-H+1})^T \in \mathbb{R}^{N \times m \times H}$ 和预测时间窗口 F 大小的情况下,交通流态势预测问题定义如下:

$$\hat{\mathbf{x}}_{t+F}, \dots, \hat{\mathbf{x}}_{t+2}, \hat{\mathbf{x}}_{t+1} = f(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-H+1}) \quad (2)$$

其中, $\mathbf{x}_t \in \mathbb{R}^{N \times m}$ 是图 G 中全部节点在时间 t 下的特征观测矩阵, $\mathbf{x}_t$ 每一行代表某节点的特征观测向量 $\mathbf{x}_t^i \in \mathbb{R}^m$, f 为映射函数, F 为预测窗口长度。

1.2 图小波卷积

(1) 图谱卷积

利用多个卷积核对输入数据进行特征提取,各卷积层中每个神经元都与前一层位置临近区域的多个神经元相连接,以捕获空间相关性,卷积操作区域的大小取决于卷积核的尺寸。面向图结构的图谱卷积定义如下:

$$\zeta_\theta *_{\mathcal{G}} \mathbf{x} = \zeta_\theta(L)\mathbf{x} = \zeta_\theta(U\Lambda U^T)\mathbf{x} = U\zeta_\theta(\Lambda)U^T\mathbf{x} = U\zeta_\theta U^T\mathbf{x} \quad (3)$$

其中, $\mathbf{x}$ 表示图 G 的节点信号,即 $\mathbf{x}_t$ 。 ζ_θ 表示卷积滤波核。 $*_{\mathcal{G}}$ 为卷积操作算符。矩阵 $L = D - A$ 是图 G 的拉普拉斯矩阵, $D \in \mathbb{R}^{N \times N}$ 是图 G 的度矩阵,并且 $D_{ii} = \sum_j A_{ij}$ 。规范化之后的拉普拉斯矩阵 $L = I_N - D^{-1/2}AD^{-1/2}$, $I_N \in \mathbb{R}^{N \times N}$ 为单位矩阵。 U 是拉普拉斯矩阵 L 进行特征值分解后相应的特征向量矩阵,即 $L = U\Lambda U^T$ 。 $\Lambda \in \mathbb{R}^{N \times N}$ 是由 L 特征分解后的特征值对角矩阵。 $\tilde{\mathbf{x}} = U^T\mathbf{x}$ 表示图傅里叶变换,矩阵 U 为傅里叶变换基。

(2) 图小波卷积

图小波卷积用图小波基替代 L 特征值分解后的特征向量基^[13](傅里叶变换基 U^T),并通过图小波变换和卷积定理定义图小波卷积算子。基于图小波变换的图小波卷积定义如下:

$$\zeta_\theta *_{\mathcal{G}} \mathbf{x} = \Psi_s \zeta_\theta \Psi_s^{-1} \mathbf{x} \quad (4)$$

其中, $\Psi_s = UG_s U^T = (\Psi_{s1}, \Psi_{s2}, \dots, \Psi_{sN})$, s 为扩散尺度因

子, Ψ_{si} 表示以节点 i 为中心并以 s 为尺度向邻居节点扩散, $G_s = \text{diag}(g(s\lambda_i))_{i=1:N} \in \mathbb{R}^{N \times N}$, $g(s\lambda_i)_{i=1:N} = e^{-s\lambda_i}$ 为热扩散核函数^[14], λ_i 为 L 特征分解后特征值。为了计算方便,本文采用 $\Psi_s^{-1} = UG_s^{-1}U^T$, $G_s^{-1} = \text{diag}(g(-s\lambda_i))_{i=1:N} \in \mathbb{R}^{N \times N}$ 。为了不对图 G 的拉普拉斯矩阵 L 进行特征分解,本文采用 Hammond 等人^[15]提出的基于切比雪夫多项式近似算法有效近似 Ψ_s 和 Ψ_s^{-1} ,从而有效避免了对矩阵 L 的特征分解计算,近似求解算法复杂度为 $O(K \times |E|)$, K 为多项式阶数, $|E|$ 为图 G 的边数。近似算法如下:

$$\Psi_s^{-1}\tau = \frac{1}{2}c_0\tau + \sum_{k=1}^K c_k T_k^*(L)\tau \quad (5)$$

$$c_k = \frac{\pi}{2} \int_0^\pi \cos(k\beta) g(s(\frac{1}{2}\lambda_{\max}(\cos\beta + 1))) d\beta \quad (6)$$

$$T_k^*(L)\tau = 2(2/\lambda_{\max} L - I_N)T_{k-1}^*(L)\tau - T_{k-2}^*(L)\tau \quad (7)$$

其中, τ 为图信号,即 $\mathbf{x}_t$, $T_k^*(L)$ 表示矩阵 L 的 K 阶切比雪夫多项式, $T_0^* = I_N$, $T_1^* = 2/\lambda_{\max} L - I_N$ 。 $\lambda_{\max}$ 为矩阵 L 的最大特征值。多项式阶数 K 值越大计算越精确,但会带来较高的计算复杂度,通常情况下 K 的取值范围为 3~10 之间。与图谱卷积相比,图小波卷积计算复杂度更低; Ψ_s 和 Ψ_s^{-1} 多为稀疏矩阵,运算效率较高;图小波卷积具有局部特性^[16],扩散尺度因子 s 控制着节点的邻域范围。

2 图小波神经网络模型

2.1 图小波神经网络模型总体结构

时空图小波卷积网络的总体架构如图 1 所示。时空图小波卷积网络由时空动态相关性捕获模型和时空相关性捕获模型串联组成时空块,再串联堆叠多个时空块,最后接入到一个多层感知机^[17](multilayer perceptron, MLP)模型输出层。在时空图小波卷积网络的总体架构中,时空动态相关性捕获模型由空间注意力模型和时间注意力模型组成,空间注意力模型通过引入空间注意力机制捕获空间动态相关依赖特征,空间注意力模型基于注意力机制构造时间注意力矩阵捕获交通流数据的时间动态相关依赖特征;时空相关性捕获模型由图小波卷积和 1 维扩张因果卷积组成,图小波卷积用以提取图节点间的空间特征,1 维扩张因果卷积用以提取时间维度上各观测值的时间相关性特征。从本质上讲,图小波神经网络是一种多层图谱卷积神经网络,其核心是利用小




Fig.1 Architecture of spatial-temporal graph wavelets convolutional networks

图1 时空图小波卷积网络的总体架构图

波变换代替傅里叶变换来定义图卷积运算符。

2.2 时空动态相关性捕获模型

图小波卷积运算能够捕获节点间的空间相关性特征,并以此建模图节点间的信息流向和汇集的影响力,但是只能建模有限尺度邻域内节点间的静态依赖特征。在交通网络中,节点间相互影响具有长时空的动态相关性,比如相邻节点在不同时间发生了不同程度的堵车以及不同节点同一时段交通流量状况都有着时空关联性。为了建模节点间的动态相关性,引入注意力机制模型^[18]分别对时间和空间的动态相关性进行建模,并构建了时空动态相关性模型,对时空动态相关性进行建模。

(1) 空间注意力模型

为了建模交通网络图节点间的空间动态相关性,在空间维度上定义空间注意力模型,如下:

$$\mathbf{Z}_s = \mathbf{W}_s \cdot h((\mathbf{X}_{T_m}^l \mathbf{W}_1) \cdot \mathbf{W}_2 \cdot ((\mathbf{X}_{T_m}^l)^T \mathbf{W}_3) + \mathbf{b}_s) = f_{Z_s}(\mathbf{X}_{T_m}^l) \quad (8)$$

$$\tilde{\mathbf{Z}}_s(i, j)_{i=1:N} = \frac{\exp(\mathbf{Z}_s(i, j))}{\sum_{j=1}^N \exp(\mathbf{Z}_s(i, j))} \quad (9)$$

其中, $\mathbf{Z}_s \in \mathbf{R}^{N \times N}$ 为空间注意力矩阵, $\tilde{\mathbf{Z}}_s$ 为规范化后的空间注意力矩阵, h 为激活函数(如 ReLU(rectified

linear unit)), $\tilde{\mathbf{Z}}_s(i, j)$ 表示图节点 i, j 间的连接强度,通过设定合理的阈值大小可以动态调整空间注意力矩阵。 $\mathbf{X}_{T_m}^l = \{\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-T_m+1}\}_{\text{layer}} \in \mathbf{R}^{N \times F^l \times T_m^l}$ 是网络的第 l 层输入特征信号, T_m^l 为第 l 层时间序列长度, F^l 为第 l 层特征维度;若 l 为 0,则表示第一层,其对应的输入为 $\mathbf{X}_{T_m}^0 = (\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-H+1})^T$ 。 $\mathbf{W}_1 \in \mathbf{R}^{T_m^l}$, $\mathbf{W}_2 \in \mathbf{R}^{F^l \times T_m^l}$, $\mathbf{W}_3 \in \mathbf{R}^{F^l}$, $\mathbf{W}_s \in \mathbf{R}^{N \times N}$ 以及偏置 $\mathbf{b}_s \in \mathbf{R}^{N \times N}$ 待训练学习的参数。

(2) 时间注意力模型

为了建模交通网络图节点间的时间动态相关性,在时间维度上定义时间注意力模型,如下:

$$\mathbf{Z}_t = \mathbf{W}_t \cdot h(((\mathbf{X}_{T_m}^l)^T \mathbf{H}_1) \cdot \mathbf{H}_2 \cdot (\mathbf{X}_{T_m}^l \mathbf{H}_3) + \mathbf{b}_t) = f_{Z_t}(\mathbf{X}_{T_m}^l) \quad (10)$$

$$\tilde{\mathbf{Z}}_t(i, j)_{j=1:T_m^l} = \frac{\exp(\mathbf{Z}_t(i, j))}{\sum_{j=1}^{T_m^l} \exp(\mathbf{Z}_t(i, j))} \quad (11)$$

其中, $\mathbf{Z}_t \in \mathbf{R}^{T_m^l \times T_m^l}$ 为时间注意力矩阵, $\tilde{\mathbf{Z}}_t$ 为规范化后的时间注意力矩阵,同理 $\tilde{\mathbf{Z}}_t(i, j)$ 表示图节点 i 和节点 j 在时间 t 时的连接强度。 $\mathbf{X}_{T_m}^l \cdot \tilde{\mathbf{Z}}_t = \{(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_{t-T_m+1})_{\text{layer}} \cdot \tilde{\mathbf{Z}}_t\} \in \mathbf{R}^{N \times F^l \times T_m^l}$ 可以动态调节和融合不同时间

步下的信息。 $H_1 \in \mathbf{R}^N$, $H_2 \in \mathbf{R}^{F \times N}$, $H_3 \in \mathbf{R}^{F^2}$, $W_t \in \mathbf{R}^{T_n^1 \times T_n^1}$ 和 $b_t \in \mathbf{R}^{T_n^1 \times T_n^1}$ 待训练学习的参数。

2.3 时序相关性捕获模型

为了能够捕获时序数据间的时间相关性,采用一维扩张因果卷积(dilated causal convolution, DCC)提取节点的时间相关特征。在扩张因果卷积网络中,随着层数的增加,接受域(或称感受野)变大,在当前时间步上所做的推论只包含历史信息。假设给定一个输入序列 $\mathbf{x}^* \in \mathbf{R}^H$, 则一维扩张因果卷积定义如下:

$$\mathbf{x}^* *_d k(t) = \sum_{i=0}^K k(i) \mathbf{x}^*(t-id) \quad (12)$$

其中, $*_d$ 表示扩张因果卷积操作算符, $k \in \mathbf{R}^K$ 为滤波核, K 表示扩张因果卷积滤波核大小, d 为扩张率(或扩张因子)。通过将扩张因果卷积层与扩张因子按递增顺序叠加,模型的感受野会指数级增长。这使得扩张因果卷积网络能够以较少的层捕获较长的序列,从而有效节省了计算资源。

2.4 图小波网络交通流预测算法训练步骤

基于图小波神经网络的交通流预测前向训练步骤如下:

步骤1 给定道路网络图 G 和各节点的历史观测数据集,并设定历史时间窗口长度 H 和预测时间窗口长度 F ,将历史时间窗口 H 对应的时序数据作为训练样本 $\{\mathbf{x}_i\} = (\mathbf{x}_i, \mathbf{x}_{i-1}, \dots, \mathbf{x}_{i-H+1})^T \in \mathbf{R}^{N \times m \times H}$, 将预测时间窗口长度 F 对应的时序数据作为训练样本的学习目标 $\{\mathbf{y}_i\}$ 。

步骤2 将数据集以 6:2:2 的比例随机分割为训练集、验证集和测试集(其中,训练集用于模型拟合的数据样本,验证集用于“调优”模型的超参数设置,训练集和验证集数据均参与训练过程,测试集数据仅对训练调优后的模型进行测试验证),并对数据进行零均值归一化处理,以减小尺度因素对样本均衡性的影响,使模型更容易收敛到最优解。此外,在训练过程中对数据集进行了随机 Shuffle 操作,以提升模型的泛化性能。

步骤3 利用公式 $\Psi_s^{-1} \tau = \frac{1}{2} c_0 \tau + \sum_{k=1}^K c_k T_k^*(L) \tau$ 计算 Ψ_s 和 Ψ_s^{-1} 。

步骤4 串联堆叠两个时空块(每个时空块由时空动态相关性捕获模型和时空相关性捕获模型串联

组成)构造时空图小波卷积网络模型。输入数据 $\{\mathbf{x}_i\} \in \mathbf{R}^{N \times m \times H}$, 计算 $Z_t = f_{Z_t}(\{\mathbf{x}_i\})$ 时间注意力矩阵,并规范化为 $\tilde{Z}_t$, 计算 $\{\mathbf{x}_{i,t}\} = \tilde{Z}_t \cdot \{\mathbf{x}_i\} \in \mathbf{R}^{N \times m \times H}$; 计算 $Z_s = f_{Z_s}(\{\mathbf{x}_i\})$ 空间注意力矩阵,并规范化为 $\tilde{Z}_s$, 计算 $\{\mathbf{x}_{i,st}\} = \tilde{Z}_s \cdot \{\mathbf{x}_{i,t}\} + \{\mathbf{x}_i\} \in \mathbf{R}^{N \times m \times H}$ 。

步骤5 利用公式 $\zeta_{\theta^*} \mathbf{x} = \Psi_s \zeta_{\theta} \Psi_s^{-1} \mathbf{x}$ 对 $\{\mathbf{x}_{i,st}\}$ 进行空间特征提取运算,利用公式 $\mathbf{x}^* *_d k(t) = \sum_{i=0}^K k(i) \mathbf{x}^*(t-id)$ 对输入数据进行时间特征提取运算。

步骤6 将由多个串联堆叠的时空块进行特征提取后的数据接入到多层感知机 MLP^[17] 中,MLP 将特征进行融合输出,输出结果作为时空图小波卷积网络模型的前向传播输出。

步骤7 以均方误差为优化损失函数,采用 Adam 一阶优化算法进行梯度反向传播优化,迭代学习得到模型的参数数值。

步骤8 基于已经训练得到的最优模型参数,进行路网交通流态势预测,得到预测时间窗口 F 内的各节点交通流状态。

3 结果与分析

3.1 实验环境及数据预处理

(1) 实验数据集

选用公开数据集 PeMSD-4 和 PeMSD-8 作为时空图小波卷积神经网络模型的验证数据^[19]。实验中,将 PeMSD-4 和 PeMSD-8 数据聚合为 5 min 间隔的数据记录。PeMSD-4 中记录了某高速公路 307 个传感器两个月的交通参数,具体包括交通流量、平均速度和平均车道占有量。PeMSD-8 中记录了某高速公路 170 个传感器两个月的交通参数。

(2) 实验环境

实验基础硬件平台为: Intel® Xeon® Gold 5218 CPU@2.30 GHz, NVIDIA GeForce GTX 2080 GPU, 显存 32 GB。采用 Adam 优化器进行优化,学习率为 0.000 1。为了提升计算效率,将 Ψ_s 和 Ψ_s^{-1} 中小于阈值 0.000 1 的元素设置为 0。训练过程中如果存在连续 200 个迭代步骤中验证集的损失无明显变化的情况,则表示完成模型训练。

(3) 模型评估度量与对照基线

在实验过程中,选用平均绝对误差(mean absolute errors, MAE)、平均绝对百分比误差(mean absolute

percentage errors, MAPE)和均方根误差(root mean squared errors, RMSE)三种度量指标来评估模型,指标越小表示模型越精确,并选用 STGCN-Cheb(spatio-temporal graph convolutional networks with Chebyshev polynomials approximation)、STGCN-1st(spatio-temporal graph convolutional networks with 1st order approximation)、ASTGCN(attention based spatial-temporal graph convolutional network)和 MSTGCN(multi-component spatial-temporal graph convolution networks)模型^[11,20]作为本文模型实验对比基线。同时,为了和传统非深度学习模型进行比较,本文选取了历史平均(historical average, HA)预测方法和 VAR(vector auto-regressive)^[21]预测方法作为传统基线模型。在 HA 中,根据前 12 个时间片的平均值来预测下一个值。

3.2 实验结果与分析

基于 PeMSD-4 和 PeMSD-8 数据集,验证本文提出的面向路网交通流态势预测的时空图小波卷积网络模型的性能,并与多个基线进行比较。

图 2 和图 3 分别展示了不同模型在数据集 PeMSD-4 和 PeMSD-8 上的平均性能对比结果。从图 2 中可以明显看出,在 PeMSD-4 数据集上,提出的时空图小波卷积网络模型均方根误差 RMSE、平均绝对误差 MAE 和平均绝对百分比误差 MAPE 均比其他 4 个基线模型的平均性能低。其中时空图小波卷积网络模型的 RMSE 比 STGCN-1st、STGCN-Cheb、MSTGCN 和 ASTGCN 分别低 15.92%、11.47%、6.31%和 2.93%,时空图小波卷积网络模型的 MAE 比 STGCN-1st、STGCN-Cheb、MSTGCN 和 ASTGCN 分别低 17.35%、




Fig.2 Average performance comparison of different models on PeMSD-4

图2 不同模型在数据集 PeMSD-4 上平均性能比较




Fig.3 Average performance comparison of different models on PeMSD-8

图3 不同模型在数据集 PeMSD-8 上平均性能比较

16.40%、9.10%和 2.81%, MAPE 数值比 STGCN-1st、STGCN-Cheb、MSTGCN 和 ASTGCN 分别低 24.08%、18.45%、18.04%和 3.50%。

从图 3 中可以明显看出,在 PeMSD-8 数据集上,时空图小波卷积网络模型平均性能均比其他 4 个基线模型的平均性能低。时空图小波卷积网络模型的 RMSE、MAE 和 MAPE 均比最佳基线模型 ASTGCN 分别低 2.08%、0.68%和 6.26%。与基线模型 STGCN-1st 的平均性能相比,时空图小波卷积网络模型的 RMSE、MAE 和 MAPE 分别低 15.42%、18.71%和 41.05%。与传统模型相比,从图 2 和图 3 中可以明显看出,时空图小波卷积网络模型具有明显的性能优势。

从图 2 和图 3 的平均性能结果可以看出,以图小波变换为基础的图小波卷积运算、扩张因果卷积运算和基于注意力机制的时空注意力模型构建的时空图卷积网络模型,不仅能够很好地提取时空相关性特征,还能够建模时空动态相关性特征。因此,本文提出的时空图卷积网络模型更适合用作交通路网的交通流态势的预测与分析任务。

基于图小波卷积的神经网络模型,除了能够提高预测精度外,图小波卷积中的小波变换矩阵更具稀疏性。统计了在 PeMSD-4 和 PeMSD-8 数据集上的图小波变换矩阵与傅里叶变换矩阵非零元素个数和密度,分别如表 1 和表 2 所示。

在 PeMSD-4 数据集中,共有 307 个节点,因此图小波变换矩阵 $\Psi_s^{-1} \in \mathbb{R}^{307 \times 307}$ 和傅里叶变换矩阵 $U^T \in \mathbb{R}^{307 \times 307}$ 。表 1 中第一行统计了变换矩阵间的非 0 元素占比(密度),可以明显看出图小波变换矩阵 Ψ_s^{-1} 以及图小波

Table 1 Count of non-zero elements of different transformation matrices on PeMSD-4

表1 不同变换矩阵在PeMSD-4上的非零元素计数

项目	图小波变换矩阵		图傅里叶变换矩阵	
	Ψ_s	Ψ_s^{-1}	U	U^T
密度/%	5.77	10.44	99.73	99.73
非0元素个数	5 439	9 835	93 997	93 997

Table 2 Count of non-zero elements of different transformation matrices on PeMSD-8

表2 不同变换矩阵在PeMSD-8上的非零元素计数

项目	图小波变换矩阵		图傅里叶变换矩阵	
	Ψ_s	Ψ_s^{-1}	U	U^T
密度/%	21.85	53.09	100.00	100.00
非0元素个数	6 314	15 344	28 900	28 900

逆变换矩阵 Ψ_s 均比傅里叶变换矩阵 U^T 和傅里叶逆变换矩阵 U 稀疏。因此,基于图小波变换定义的卷积运算更有效率。表2中,分别统计了在PeMSD-8数据集(共有170个节点)上的图小波变换矩阵 $\Psi_s^{-1} \in \mathbb{R}^{170 \times 170}$ 的非零元素个数与傅里叶变换矩阵 $U^T \in \mathbb{R}^{170 \times 170}$ 的非零元素个数,可以看出,图小波变换矩阵 Ψ_s^{-1} 比傅里叶变换矩阵 U^T 稀疏,其中 Ψ_s^{-1} 的密度占比比 U^T 的密度占比低约88.36%。通过统计PeMSD-4和PeMSD-8数据集上的图小波变换矩阵与傅里叶变换矩阵的稀疏性,发现基于图小波变换定义的卷积运算更具稀疏性,这将有助于提高模型训练时的计算效率。

4 结束语

针对交通路网中交通流态势预测问题,提出了一种基于图的交通流预测深度学习模型。实验发现,该模型不仅能够很好地捕捉时空相关性特征,还能够建模时空动态相关性特征;同时,该模型的预测精度优于所选的基准模型;此外,本文模型中的卷积运算更具稀疏性,相较于传统图卷积运算更具有计算效率。因此,提出的模型极易推广至更一般的时空图结构序列预测场景中。

交通路网中的交通流态势预测,实际上会受到许多外部因素的影响,如气象条件、突发事件等。因此,在未来工作中,一方面,考虑将外部因素引入模型,进一步提高预测精度;另一方面,将提出的交通

流预测深度学习模型应用到新的城市路网交通流数据上,进一步验证和测试模型的性能。

参考文献:

- [1] QIN W J, JIA W, HAN F, et al. Superpixel-based and boundary-sensitive convolutional neural network for automated liver segmentation[J]. Physics in Medicine & Biology, 2018, 63(9): 095017.
- [2] ROCCO I, ARANDJELOVIC R, SIVIC J. Convolutional neural network architecture for geometric matching[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(11): 2553-2567.
- [3] LV Y S, DUAN Y J, KANG W W, et al. Traffic flow prediction with big data: a deep learning approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(2): 865-873.
- [4] FOULADGAR M, PARCHAMI M, ELMASRI R, et al. Scalable deep traffic flow neural networks for urban traffic congestion prediction[C]//Proceedings of the 2017 International Joint Conference on Neural Networks, Anchorage, May 14-19, 2017. Piscataway: IEEE, 2017: 2251-2258.
- [5] PENG S F, SHEN Y Y, ZHU Y M, et al. A frequency-aware spatio-temporal network for traffic flow prediction[C]//LNCS 11447: Proceedings of the 24th International Conference on Database Systems for Advanced Applications, Chiang Mai, Apr 22-25, 2019. Berlin, Heidelberg: Springer, 2019: 697-712.
- [6] SONG T F, ZHENG W M, SONG P, et al. EEG emotion recognition using dynamical graph convolutional neural networks[J]. IEEE Transactions on Affective Computing, 2020, 11(3): 532-541.
- [7] XU Y, KONG Q Q, HUANG Q, et al. Convolutional gated recurrent neural network incorporating spatial features for audio tagging[C]//Proceedings of the 2017 International Joint Conference on Neural Networks, Anchorage, May 14-19, 2017. Piscataway: IEEE, 2017: 3461-3466.
- [8] SOUMYASUNDAR P, FLORENCE R, MARK C. Bayesian graph convolutional neural networks using node copying[C]//Proceedings of the International Conference on Machine Learning, Learning and Reasoning with Graph-Structured Representations Workshop, Long Beach, Jun 6, 2019: 1-6.
- [9] YOUNGJOO S, MICHAEL D, PIERRE V, et al. Structured sequence modeling with graph convolutional recurrent networks[J]. arXiv:1612.07659, 2016.
- [10] GREGOR K, DANIHELKA I, GRAVES A, et al. DRAW: a recurrent neural network for image generation[C]//Proceed-

- ings of the 32nd International Conference on Machine Learning, Lille, Jul 6-11, 2015: 1462-1471.
- [11] YU B, YIN H T, ZHU Z X. Spatio-temporal graph convolutional networks: a deep learning framework for traffic forecasting[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence, Stockholm, Jul 13-19, 2018: 3634-3640.
- [12] WU Z H, PAN S R, LONG G D, et al. Graph WaveNet for deep spatial-temporal graph modeling[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence, Macao, China, Aug 10-16, 2019: 1907-1913.
- [13] XU B B, SHEN H W, CAO Q, et al. Graph wavelet neural network[C]//Proceedings of the 7th International Conference on Learning Representations, New Orleans, May 6-9, 2019: 1-14.
- [14] DONNAT C, ZITNIK M, HALLAC D, et al. Learning structural node embeddings via diffusion wavelets[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, London, Aug 19-23, 2018. New York: ACM, 2018: 1320-1329.
- [15] HAMMOND D K, VANDERGHEYNST P, GRIBONVAL R. Wavelets on graphs via spectral graph theory[J]. Applied and Computational Harmonic Analysis, 2011, 30: 129-150.
- [16] TREMBLAY N, BORGNAT P. Graph wavelets or multiscale community mining[J]. IEEE Transactions on Signal Processing, 2014, 62(20): 5227-5239.
- [17] SUN X Q, FENG Y J. Sensitivity analysis of multilayer perceptron[J]. Chinese Journal of Computers, 2001, 24(9): 951-958.
- 孙学全, 冯英俊. 多层感知器的灵敏度分析[J]. 计算机学报, 2001, 24(9): 951-958.
- [18] LIANG Y X, KE S, ZHANG J B, et al. GeoMAN: multi-level attention networks for geo-sensory time series prediction[C]//Proceedings of the 27th International Joint Conference on Artificial Intelligence, Stockholm, Jul 13-19, 2018: 3428-3434.
- [19] CHEN C, PETTY K F, SKABARDONIS A, et al. Freeway performance measurement system: mining loop detector data[J]. Transportation Research Record: Journal of the Transportation Research Board, 2001(1): 96-102.
- [20] GUO S N, LI Y F, FENG N, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//Proceedings of the 33rd AAAI Conference on Artificial Intelligence, the 31st Innovative Applications of Artificial Intelligence Conference, the 9th AAAI Symposium on Educational Advances in Artificial Intelligence, Honolulu, Jan 27-Feb 1, 2019. Menlo Park: AAAI, 2019: 922-929.
- [21] ZIVOT E, WANG J H. Vector autoregressive models for multivariate time series[M]//ZIVOT E, WANG J H. Modeling Financial Time Series with S-Plus®. Berlin, Heidelberg: Springer, 2003.



姜山(1989—),男,陕西安康人,博士研究生,主要研究方向为时空感知大数据分析、深度学习算法。

JIANG Shan, born in 1989, Ph.D. candidate. His research interests include spatial-temporal perceptual big data analysis and deep learning algorithms.



丁治明(1966—),男,博士,研究员,博士生导师,主要研究方向为数据库与知识库系统、时空空间数据库、物联网、信息检索、大数据与云计算。

DING Zhiming, born in 1966, Ph.D., research professor, Ph.D. supervisor. His research interests include database and knowledge base systems, spatial-temporal databases, Internet of things, information retrieval, big data and cloud computing.



徐馨润(1999—),女,山西运城人,博士研究生,主要研究方向为时空感知大数据分析、深度学习算法。

XU Xinrun, born in 1999, Ph.D. candidate. Her research interests include spatial-temporal perceptual big data analysis and deep learning algorithms.



严瑾(1993—),女,加拿大华人,硕士研究生,主要研究方向为数据分析、数据挖掘、应急系统数据管理。

YAN Jin, born in 1993, M.S. candidate. Her research interests include data analysis, data mining and emergency system data management.