

基于低成本三维扫描仪的人脸深度图识别方法

张楠楠¹, 桑高丽²

(1.浙江理工大学 计算机科学与技术学院, 浙江 杭州 310018;

2.嘉兴大学 人工智能学院, 浙江 嘉兴 314000)

摘要: 提出一种基于低成本三维扫描仪的人脸深度图识别方法(FDMR),目的是提高低质量人脸深度图的鲁棒性特征表达能力以提高识别准确率,提高算法的实时性能以更好地满足实际应用需求。首先,针对单张深度数据提取特征有限的问题,将低质量人脸深度图像构建为对比图像对并输入到FDMR网络中。其次,在特征提取过程中,为减少低质量人脸深度数据中噪声的影响,引入连续归一化流模块进行特征去噪。最后,提出了一种面向图像对的对比损失函数,通过最小化图像对相似度分数分布与真实标签匹配分布之间的KL散度以简化计算过程,进一步提高了模型训练的效率。所提方法展现出较其他当前最优方法更高的实时性能,处理图像时的帧速率达到183帧/s,而当前最优方法仅为125帧/s。在Lock3DFace和Extended-Multi-Dim两个数据集上的实验结果显示,与当前最优方法相比,提出方法在平均识别率上分别提高了0.23%和0.67%。

关键词: 低成本三维扫描仪; 低质量人脸深度图像; 对比图像对; 特征去噪; 对比损失函数; 高实时性

中图分类号: TB96

文献标识码: A

文章编号: 1000-1158(2025)11-1612-10

Face Depth Map Recognition Method Based on Low-cost 3D Scanners

ZHANG Nannan¹, SANG Gaoli²

(1.School of Computer Science and Technology, Zhejiang Sci-Tech University, Hangzhou, Zhejiang 310018, China;

2.School of Artificial Intelligence, Jiaxing University, Jiaxing, Zhejiang 314000, China)

Abstract: A face depth map recognition (FDMR) method based on low-cost 3D scanners is proposed, aiming to enhance the robust feature expression ability of low-quality face depth maps to improve recognition accuracy, and to enhance the real-time performance of the algorithm to better meet practical application needs. Firstly, addressing the limitation of extracting features from single-depth data, low-quality deep face images are constructed as contrastive image pairs and fed into the FDMR network. During feature extraction, a continuous normalizing flow module is introduced to reduce the noise impact from low-quality deep face data. Lastly, a contrastive loss function tailored for image pairs is proposed. By minimizing the KL divergence between the similarity score distribution of image pairs and the matching distribution of real labels, the computation is simplified, thereby further enhancing training efficiency of the model. The proposed method demonstrates higher real-time performance compared to other current state-of-the-art methods, achieving a frame rate of 183 frames per second for image processing, whereas the current best method achieves 125 frames per second. Experiments conducted on the Lock3DFace and Extended-Multi-Dim datasets show that the proposed method improves the average recognition rate by 0.23% and 0.67%, respectively, compared to the current best method.

Key words: low-cost 3D scanner; low-quality face depth map; contrasting image pair; feature denoising; contrastive loss function; high real-time performance

1 引言

早期人脸深度图像识别(face depth map recognition, FDMR)研究中,研究人员主要依赖高质

量的人脸深度数据。高质量人脸深度数据的获取相对困难,为解决数据不足的问题,一些研究人员^[1,2]开始利用现有的小规模高质量人脸深度数据库进行数据合成以增加数据量。这一举措推动了数据增强技术的发展,并促进了深度学习模型^[3]的

收稿日期: 2024-09-12; 修回日期: 2025-07-03

基金项目: 浙江省教育厅科研项目(Y202249424);嘉兴市公益性研究计划项目(2024AD10046)

出现。尽管高质量人脸深度数据识别技术^[4,5]已取得一定进展,但数据采集设备成本高、采集时间长且体积庞大,导致相关识别技术仍然难以满足实际应用需求。

直到 Kinect v2 和 RealSense 等低成本三维扫描仪^[6]的出现,获取的低质量人脸深度数据质量相较于低成本三维扫描仪 Kinect v1 有了相对提升,从而推动了相关研究^[7,8]的进展。Lock3DFace 数据集^[9]的公开发布使得研究人员开始专注于利用这些低质量人脸数据来提高识别准确率。

近年来,许多研究采用深度学习方法来提高低质量人脸深度图像识别的准确性,取得了较好的成果。例如,Mu 等^[10]提出1种轻量高效的深度方法,所提模型中引入的多尺度特征融合模块有助于全面整合不同尺度的图像特征,以增强模型的表达能力。此外,多尺度特征融合模块在其他研究中也得到了较多应用^[11,12]。此外,Mu 等还设计了1套数据处理流程,有效提高识别准确率。然而,他们的卷积神经网络设计未考虑低质量人脸深度数据中噪声的影响。

另外,Hu 等^[13]建立一个包含高质量和低质量人脸深度数据的 RGB-D 数据库,并利用高质量数据指导低质量数据的方法进行模型训练,在该数据集上取得较好成果。由于缺乏同时涵盖高质量和低质量数据的数据集,无法验证所提方法的泛化能力。

Sang 等^[14]提出了1种联合软阈值去噪(soft threshold denoising, STD)和视频数据融合的方法,用于低质量人脸深度图像识别。该方法因处理多帧视频数据较为耗时而导致实时性能下降。此外,他们提出了1种联合渐变损失函数,验证了方法对提升低质量人脸深度识别准确率的有效性。然而,该方法在处理非平稳噪声方面的效果尚待进一步优化。

Wang 等^[15]提出了一种 Point CNN(convolutional neural network),在低质量三维人脸识别方面取得较高识别准确率。然而,该方法时间成本高,实时性能较差。

目前用于提高低质量人脸深度图像识别准确率的方法主要采用单一数据训练卷积神经网络(CNN),存在过拟合风险高和对抗性攻击敏感等问题。为提高模型的鲁棒性,需要多样化的数据集来进行训练。

针对上述存在问题,本文主要贡献如下:1)提出一种新的对比图像对构建及图像对比学习方法以增强对单张深度数据的鲁棒特征学习能力,旨在

解决利用低质量人脸深度图像进行人脸识别所面临的数据可靠性低,且特征提取易受表情、姿态、遮挡等因素影响的问题。2)本文所提对比损失函数计算复杂度较低,使得模型训练效率有效提高。3)针对低质量人脸深度图像中存在的噪声,在模型架构中引入连续归一化流(continuous normalizing flow, CNF)的特征去噪模块以实现噪声的自动去除。

本文算法代码公布在: <https://github.com/lacbdhr-haha/experiment/tree/master/recognition>。

本文研究思路架构如图1所示。




图1 研究思路架构图

Fig. 1 Research idea architecture diagram

2 方法

2.1 对比图像对构建

2.1.1 对比图像对定义

对比图像对由中性基准图像和多样性变化图像组成。中性基准图像是能够稳定提取人脸特征,且准确反映面部特征与身份信息的图像;而多样性变化图像是因姿态、表情、遮挡和光照等因素,导致可能缺乏关键部分或信息表现不准确的图像。

2.1.2 构建对比图像对

本文采用 Lock3DFace 数据集^[9]和 Extended-Multi-Dim 数据集^[13]构建对比图像对。构建过程如下:

1) 针对 Lock3DFace 数据集。

首先,从每个身份的首个中性表情视频中提取第1帧,以作为中性基准图像。随后,按照相同的时间间隔提取6帧,并对其进行数据增强。增强方法与 Mu 等^[10]所提的方法相同,包括平面外旋转、姿态生成、形状抖动和形状缩放。接着,将其余视频中的所有帧(如姿态、表情、遮挡等)以及经过增强处理的中性表情帧全部作为多样性变化图像。最终,

将中性基准图像与多样性变化图像进行配对,以形成对比图像对,具体的配对方式如图2所示。




图2 图像对的配对方式

Fig. 2 Pairing method for image pairs

2) 针对 Extended-Multi-Dim 数据集
从其中674个身份中选取低质量深度图像作为数据集,具体的深度图像类型如图3所示。




图3 不同形态的低质量人脸深度图像

Fig. 3 Low- quality deep face images of different forms

从每个身份的中性表情深度图像集合中提取

第1张图像,作为中性基准图像,并将该身份的所有图像用作多样性变化图像。对比图像对的构建方式与Lock3DFace数据集一致。

2.2 图像-图像对的对比学习与预训练方法

2.2.1 图像-图像对对比学习

构建对比图像对的核心目的是弥补单数据在卷积神经网络训练中的特征提取不足。通过采用多样性数据进行网络模型训练,可以有效消除与身份识别无关的干扰因素的影响,例如姿态、表情、遮挡和光照等。这一过程受到对比学习思想的启发。采用中性人脸作为监督信号进行对比学习,能够使所有人脸在语义上与中性人脸对齐,从而获得更加稳定和鲁棒的人脸特征。

目前已存在多种先进的对比学习方法,如(contrastive language-image pre-training, CLIP^[16])、SimCLR^[17]、SwAV^[18]等,用于很多主流的机器视觉领域。然而,用于本文提出的对比图像-图像对学习的模型仍具有一定的探索空间。以CLIP为例,其主要针对文本和图像的对比学习,并不符合我们的需求。因此,需要探索适用于本文构建的图像-图像对的对比学习模型。

2.2.2 对比预训练

对比图像-图像对的预训练是本文的核心内容,其重要性体现在2个方面。首先,该预训练方法能够验证所提出的对比图像对构建及对比学习策略在低质量人脸深度图像识别任务中的有效性;其次,它有助于证明对比学习思想在此类人脸图像识别任务中的可迁移性。

针对构建的对比图像对数据进行对比预训练的具体过程如图4所示。




图4 对比图像-图像预训练

Fig. 4 Pre-training of compare images- images

在预训练过程中,采用中性基准图像编码器与多样性变化图像编码器,分别用于提取中性基准图

像和多样性变化图像的特征。按顺序处理每个身份的所有图像对,仅在当前身份的所有图像对训练

完成后,才开始处理下一个身份的图像对。2个图像编码器使用与Led3D^[10]网络相同的模型架构,并共享参数。在此过程中,提取到的多样性变化图像特征用 L_{FE}^i (表情特征), L_{NU}^j (中性表情特征), L_{OC}^k (遮挡特征), L_{PS}^m (姿态特征), L_{TM}^n (时间特征)表示,而中性基准图像特征用 H_{NU}^t 表示,上标 i, j, k, m, n, t 的取值均从0开始。

在本研究中,针对同一身份,将1个中性基准图像特征与 N 个多样性变化图像特征进行两两组合。随后,对2个特征进行线性投射处理,以获得相同维度的特征并进行 $L2$ 归一化。模型根据生成的图像-图像特征组合预测出 N 个可能的图像-图像对之间的相似度,该相似度通过计算中性基准图像特征与多样性变化图像特征的余弦相似性来实现。图像-

图像特征组合用 $H_{NU}^t \cdot L_{FE}^i, H_{NU}^t \cdot L_{NU}^j, H_{NU}^t \cdot L_{OC}^k, H_{NU}^t \cdot L_{PS}^m, H_{NU}^t \cdot L_{TM}^n$ 表示。针对同一身份的图像,训练目标是最大化这 N 个样本的相似度;而对于不同身份的图像,训练目标则是最小化各样本之间的相似度,以提高识别准确率。

2.3 模型架构

本文所采用的模型架构如图5所示,主要分为2个部分。第一部分是特征提取模块,用于从输入数据中提取特征。第二部分是基于连续归一化流CNF的特征去噪模块,旨在进一步消除低质量人脸图像特征中的噪声。为了获取更加鲁棒的特征表示,引入了对比图像对损失函数(contrasting image pairs loss function, CIPL)。




图5 整体模型架构

Fig. 5 Overall model architecture

特征提取网络包括作为模型输入的对比图像对及图像编码器。图像编码器由中性基准、多样性变化图像编码器构成。提取图像特征后,利用具有可学习参数均值 μ_i 和方差 σ_i^2 的高斯分布 $N(z; \mu_i; \sigma_i^2 I)$ 来近似真实后验 $q(z|x_i)$ 。这样获得的后验分布称为高斯后验分布,记作 $p(z|x_i), z \sim p(z|x_i)$ 。这里, z 表示带噪声的潜在特征,而 x_i 代表观察到的三维人脸。

为使训练过程可微并从 $p(z|x_i)$ 获得最大可能样本,采用重新参数化技巧^[19]:

$$z = \mu_i + \varepsilon \sigma_i^2, \quad \varepsilon \in N(0, I) \quad (1)$$

特征去噪模块的核心部分是CNF,通过参数化CNF将高斯分布转换为灵活的分布表示形式,例如 $p(z'|x_i)$ 。获得灵活后验分布后,从中选择最大可能样本 z' 用于低质量人脸深度图像识别任务。该过程的核心目标是提取干净特征,以降低带噪声特征对人脸识别效果的负面影响。最后,通过采用对比损

失函数(CIPL)计算对比图像的灵活后验分布之间的对比损失。

总体而言,该模型架构较为简单,参数量相对较少,并充分考虑了噪声特征的影响。

2.4 图像对的对比损失函数

本文提出了1种适用于特征表示学习或度量学习的对比损失函数,命名为对比图像对损失函数(CIPL)。对比图像对损失的计算过程如图6所示。




图6 对比图像对损失计算过程

Fig. 6 The computing process of contrastive image pairs loss

该损失函数将 N 个图像-图像对的相似度分布嵌入到^[19]KL 散度 (Kullback-Leibler divergence, D_{KL}) 中,以关联对比图像对的特征表示。对于给定的 N 个图像-图像对,我们在每个中性基准图像的全局表示 f_i^v 的基础上,构造一组图像-图像表示对 $\{(f_i^v, f_j^v), y_{i,j}\}_{j=1}^N$, 其中 f_j^v 表示多样性变化图像的全局表示, $y_{i,j}$ 是数据预处理阶段为每个身份分配的真实匹配标签。

定义 $\text{sim}(\mathbf{x}, \mathbf{y}) = \mathbf{x}^T \mathbf{y} / \|\mathbf{x}\| \|\mathbf{y}\|$ 表示对 $\mathbf{x}$ 和 $\mathbf{y}$ 进行 $L2$ 归一化后的余弦相似度。然后,使用以下 Softmax 函数计算图像-图像匹配对的概率:

$$q_{ij} = \frac{\exp(\text{sim}(f_i^v, f_j^v) / \tau)}{\sum_{k=1}^N \exp(\text{sim}(f_i^v, f_k^v) / \tau)} \quad (2)$$

式中: k 表示多样性变化图像的全局表示的数量; τ 为温度系数,通过调整该系数,可以改变损失函数中概率分布的尺度,从而影响损失函数的训练效果和收敛性。经过多次实验确定固定的 τ 值,在一定程度上简化模型调优过程,减少需要调整的超参数数量,简化模型的训练和调试流程,并且有助于维持模型的稳定性。匹配概率 $q_{i,j}$ 可以理解为在一个小批次图像对中, f_i^v 和 f_j^v 之间的余弦相似度得分与 f_i^v 和 $\{f_j^v\}_{j=1}^N$ 之间的余弦相似度得分之和的比例。接着,针对小批次图像对,从中性基准图像 (NU) 到多样性变化图像 (Diversity) 的对比损失 L_{n2d} 通过以下公式计算得到:

$$L_{n2d} = D_{KL}(p_{i,j} \| q_{i,j}) = \frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N q_{i,j} \log\left(\frac{q_{i,j}}{p_{i,j} + \delta}\right) \quad (3)$$

式中: δ 代表一个小的数值,用于避免分母为零,而 $p_{i,j} = y_{i,j} / \sum_{k=1}^N y_{i,k}$ 则表示真实匹配概率。相应地,从多样性变化图像到中性基准图像的对比损失 L_{d2n} 可以通过交换式 (2) 和式 (3) 中的 f_i^v 和 f_j^v 得到。双向对比损失的计算公式为:

$$L_{CIPL} = L_{n2d} + L_{d2n} \quad (4)$$

该对比损失函数结合中性基准图像特征表示和多样性变化图像特征表示,通过调整共享嵌入空间中图像对的距离,使得匹配图像对更接近,而对不匹配的图像对施加惩罚。这一设计旨在帮助网络学习更准确的图像对匹配关系,从而提升特征表示的判别性。模型训练时,利用该损失函数的梯度信息持续更新模型参数,以更好拟合训练数据。调用该对比损失函数时,仅需传入 3 个参数,其表示形式为:

$$\text{Compare}_{\text{loss}} = \text{CIPL}(w_{\text{diversity}}, w_{\text{nu}}, \text{target}) \quad (5)$$

式中: $w_{\text{diversity}}$ 和 w_{nu} 分别代表多样性变化图像数据和中性基准图像数据的特征表示,它们经过连续归一化流 (CNF)^[20] 处理得到;而 target 则表示真实标签。

3 实验设置

3.1 数据集

为验证所提出的对比图像对构建以及对比损失函数的有效性,本文采用低质量人脸深度图像识别任务中主流的 Lock3DFace 数据集以及另外一种 Extended-Multi-Dim 数据集分别对提出的方法进行训练和测试。与 Mu 等^[10]的研究一致,所有的基准模型和本文的模型都在高质量三维人脸数据集 FRGC v2^[21] 和 Bosphorus^[22] 上进行了预训练。

Lock3DFace 数据集包含 509 人的 5671 段视频,每个身份都包括中性表情 (NU)、表情 (FE)、姿态 (PS)、遮挡 (OC)、时间 (TM) 等多种形态的一段或多段视频。对于低质量人脸深度图像识别任务而言, Lock3DFace 数据集是最为合适的数据集。

Extended-Multi-Dim 数据集是包含高质量和低质量人脸深度数据的数据集。该数据集包含 902 个样本的以多种形式存在的高质量和低质量人脸深度数据,因包含 902 个不同样本而被视为目前最大的低质量人脸深度数据集。该数据集由两部分构成,部分一由 228 人构成,部分二由 705 人构成,部分一和部分二之间有 31 个身份重叠。部分二中每个人的深度数据在三种不同光照条件下采集得到,相较于部分一中的图像来讲,每个人的图像具有更多的状态变化,其中涵盖表情 (FE)、中性表情 (NU)、姿态 1 (PS1)、姿态 2 (PS2) 等不同的形态。PS1 是通过将头部进行左右 90° 的水平旋转而构建的水平姿态变化下的人脸数据集;而 PS2 图像集则是通过仅对部分二中的 705 个人进行顺时针旋转头部而构建的,旨在创建更多、更复杂的姿态变化下的人脸数据。

FRGC v2 数据集涵盖 466 人的 4 007 个数据子集,其中每个身份的人脸数据包含多种表情变化,是一个高质量的三维人脸数据集。

Bosphorus 数据集涵盖 105 人的 4 666 张高质量三维人脸数据,其中包含表情、遮挡和姿态等多种变化。

3.2 实验细节

为确保与 Zhang 等^[23]、桑高丽等^[14]以及 Wang 等^[15]的研究结果进行公平比较,在 Lock3DFace 数据

集上采取以下训练设置:将输入图像大小设置为 128×128 像素。使用Adam优化器优化深度模型,在训练过程中,将训练集批次大小设置为300,并进行50个epochs的训练。初始学习率为 1×10^{-4} ,每迭代3 000次就将学习率减小为原来的1/10。

针对Extended-Multi-Dim数据集,同样将输入图像大小设置为 128×128 像素。进行30个epochs的训练,初始学习率为 1×10^{-5} ,使用Adam优化器优化深度模型。对多次实验结果比较之后确定针对Extended-Multi-Dim数据集的参数设置,将训练集批次大小设置为256,并且每迭代3 000次就将学习率减小为原来的1/10。

在实现过程中,FDMR网络使用了Pytorch框架。测试实验中使用了整体模型架构中的特征提取和特征去噪模块,并在测试阶段加载训练阶段保存的模型参数。输入为第3.3节中定义的图库样本(gallery)和测试样本(probe)。实现过程是从probe中提取图像,并在gallery中寻找与其相似度匹配分数最高的图像,将其判定为同一样本并得到其身份。验证所提方法有效性的所有实验均在Nvidia GeForce RTX 2080 Ti GPU上进行。

3.3 协议

协议针对Lock3DFace和Extended-Multi-Dim两个低质量人脸深度数据集进行设置。考虑到这2个数据集呈现不同的特征,并为满足与其他研究进行比较的需要,设计具有针对性的评估协议。协议的相关描述如下:

1) Lock3DFace协议1:协议设置与Zhang等^[23]的协议2类似。从经过对比图像对构建得到的509人的图像集中选取前400个身份的数据作为训练集。剩余的109个身份的所有帧构成测试集。在测试阶段,设定图库样本(gallery)和测试样本(probe)。每个身份的第一个中性表情视频的第一帧被选为gallery,而该身份的剩余FE、OC、PS、TM形态的所有帧构成probe。

2) Lock3DFace协议2:该协议的设置与Wang等^[15]的协议类似。从经过对比图像对构建得到的509个身份的图像集中随机选取340个身份的对比图像对数据作为训练集。其余169个身份的每一段视频都被采样6帧以进行测试。在测试阶段,设定图库样本(gallery)和测试样本(probe)。每个身份的第一个中性表情视频的第一帧被选为gallery,每个身份每段视频采样6帧后得到的FE、OC、PS、TM形态的帧的集合被用作probe。

3) Lock3DFace开集协议:该协议的设置与桑高

丽等^[14]的Lock3DFace开集协议类似,即随机从经过对比图像对构建得到的509个身份的图像集中选取300个身份的对比图像对数据作为训练集。其余209个身份的每一段视频都被采样6帧以进行测试。在测试阶段,设定图库样本(gallery)和测试样本(probe)。每个身份的第一个中性表情视频的第一帧被选为gallery,每个身份每段视频采样6帧后得到的NU、FE、OC、PS、TM形态的帧的集合被用作probe。

4) Extended-Multi-Dim协议:该协议从经过对比图像对构建得到的674个身份的图像集中选取前474个身份的数据作为训练集,剩余200个身份的所有图像构成测试集。在测试阶段,与Lock3DFace协议一致,设定图库样本(gallery)和测试样本(probe)。每个身份的的第一张中性表情图像被用作gallery,而剩余的FE、OC、PS1、PS2形态的所有帧被用作probe。

5) 与Extended-Multi-Dim协议对应的基准协议:为了与Extended-Multi-Dim协议进行比较,需要设置一个与其相比的基准实验,且模型架构与Led3D相同。该协议训练集由Extended-Multi-Dim数据集中前474个身份的所有低质量深度图像组成,测试集由后200个身份的所有图像组成。在测试阶段,同样设置gallery和probe,划分方式与Extended-Multi-Dim协议相同。

3.4 综合性能比较

为验证本文提出方法的有效性和鲁棒性,对第3.3节中不同的协议进行实验。将本文方法(FDMR)与当前已有的先进方法进行比较,具体实验结果参见表1、表2、表3和表4(注:各表中加粗字体表示各列最优结果)。

在表1中,对比方法依次为Inception-V2^[24]、Led3D^[10]、GP^[23](Gaussian posterior)和LFDR^[23](learning flexibly distributional representation)。

从表1中可以看出,本文提出的方法在4个测试子集上明显优于当前最先进方法。与Zhang等^[23]的方法相比,本文的方法表现出更高的识别准确率。具体而言,在平均识别准确率上,本文的方法比Zhang等^[23]的最优方法高出0.72%。此外,在测试子集中,本文方法在表情子集的识别准确率上高出1.09%,在姿态子集的识别准确率上高出1.08%。在其他子集上的识别准确率也显示出不同程度的提升。综合各项对比实验结果,本文提出的方法在性能上表现最优。

Lock3DFace协议2的实验结果如表2所示,比

表 1 在 Lock3DFace 协议 1 上各方法的识别准确率

Tab. 1 The recognition accuracy of each method on the Lock3DFace protocol 1 (%)					
方法	表情	遮挡	姿态	时间	平均
Inception-V2 ^[24]	88.51	52.84	42.43	39.14	63.49
Led3D ^[10]	93.22	63.44	39.03	53.91	68.65
GP ^[23]	95.30	67.64	39.44	50.74	70.26
LFDR ^[23]	95.52	69.08	43.64	54.36	71.89
FDMR	96.61	69.40	44.72	54.73	72.61

较了包括 RIA^[25]、Mobilenetv2^[26]、Led3d^[10]、PF^[27] (PointFace)、PCNN^[15] (Point CNN) 在内的多种方法。

从表 2 中可以看出,本文提出方法在部分测试子集上的识别准确率略低于当前最优方法^[15]。进一步分析表明,我们的模型训练采用了对比图像对策略,即每个身份仅使用一张中性表情图像,而其他方法则使用经过数据增强的 78 张中性表情图像。

此外,Lock3DFace 协议 1 与 Extended-Multi-Dim 协议的测试集包含了每个身份的所有图像,使得我们的测试数据量明显超过了其他低质量人脸深度图像识别方法所用的协议的数据量。这解释了部分子集识别准确率低于当前最优方法的现象。总体而言,本文的协议设置能够更为严谨地验证我们所提出的方法是否能有效提升低质量人脸深度图像识别的准确率。

表 2 在 Lock3DFace 协议 2 上各方法的识别准确率

Tab. 2 The recognition accuracy of each method on the Lock3DFace protocol 2 (%)					
方法	表情	中性	遮挡	姿态	平均
RIA ^[25]	93.6	99.0	57.0	54.1	74.4
Mobilenetv2 ^[26]	95.7	98.9	61.4	69.9	79.5
Led3D ^[10]	98.1	99.6	78.1	70.4	84.2
PF ^[27]	98.5	99.5	80.1	73.7	87.2
PCNN ^[15]	98.5	99.3	82.6	74.9	88.0
FDMR	98.3	99.1	83.6	73.9	87.9

Lock3DFace 开集协议的实验结果见表 3,对比方法依次为 NAN^[28] (neural aggregation network)、MAA^[29] (meta attention-based aggregation) 和 STD^[14] (Soft threshold denoising and video data fusion)。

从表 3 中可以观察到,在表情和时间测试子集上,相较于当前最优方法^[14],本文方法的识别准确率分别降低了 0.35% 和 0.16%。分析显示,桑高丽等^[14]在浅层特征获取之前引入了软阈值去噪模块,

表 3 在 Lock3DFace 开集协议上各方法的识别准确率

Tab. 3 The recognition accuracy of each method on the Lock3DFace open-set protocol (%)						
方法	中性	表情	遮挡	姿态	时间	平均
NAN ^[28]	98.05	96.73	60.20	60.67	62.50	75.46
MAA ^[29]	99.02	98.46	74.94	69.78	72.27	82.88
STD ^[14]	99.02	98.65	75.68	69.54	73.05	83.16
FDMR	99.02	98.30	76.16	70.68	72.89	83.39

有效提升了表情和时间变化子集的性能。相反,本文方法在获取高层特征后引入去噪模块,在浅层特征详细信息获取方面表现较差。在遮挡和姿态子集上,本文方法相对于文献[14]识别准确率提升了 0.48% 和 1.14% 的,这归因于采用的 CNF 去噪模块有效减少了高层特征噪声对识别效果的负面影响。

表 4 呈现了在 Extended-Multi-Dim 协议下,提出的模型的实验效果。与基准效果 Led3D^[10]相比,通过本文提出的方法获得的中性表情识别准确率提高 1.08%,姿态 1 识别准确率提高 0.7%,表情识别准确率提高 0.62%,姿态 2 的识别准确率也有所提高,平均准确率提高 0.67%。

表 4 在 Extended-Multi-Dim 数据集上的识别准确率

Tab. 4 The recognition accuracy on the Extended-Multi-Dim (%)					
方法	中性	表情	姿态 1	姿态 2	平均
Led3D ^[10]	96.41	93.14	71.43	49.72	82.53
FDMR	97.49	93.76	72.13	50.03	83.20

除识别准确率之外,时间成本也是衡量网络效率的一个重要指标。表 5 列出了不同方法对时间成本的比较结果。在表 5 中,本文方法处理图像时的帧速率为 183 帧/s。由此可见,所提方法的实时性能明显优于当前最优方法。

表 5 时间成本比较

Tab. 5 Comparison of time costs 帧/s	
方法	帧速率
STD ^[14]	117
Led3D ^[10]	136
PF ^[27]	118
PCNN ^[15]	125
FDMR	183

与使用单数据训练卷积神经网络模型不同,本文采用构建的对比图像对来训练模型,以增加

训练数据的多样性。此外,在训练过程中,引入 CNF 去噪模块对低质量人脸深度图像进行去噪。以上结果表明,本文提出的方法在低质量人脸深度图像识别准确率提高方面具有较高的实时性、有效性和鲁棒性。

3.5 消融研究

为评估所提出的对比图像对构建和对比损失函数的贡献,本文按照第3.3节设置的部分评估协议,在不同的数据集上分别训练3个网络。随后,将其应用于测试数据集以评估其性能,并根据测试结果得出它们的贡献。

对于 Lock3DFace 协议 1 采用以下 3 种方法: 1) 使用未经过本文提出的对比图像对构建的数据作为模型输入,并采用与 Zhang 等^[23]相同的模型;2) 使用本文提出的对比图像对和相应的模型架构,但不采用对比损失函数;3) 同时采用本文提出的对比图像对、模型架构和对比损失函数。表 6 显示 Lock3DFace 协议 1 的结果。

表 6 针对 Lock3DFace 协议 1 不同网络设置的识别准确率比较

Tab. 6 Comparison of recognition accuracy for different network settings of Lock3DFace protocol 1 (%)

方法	对比图像对	对比损失函数	表情	遮挡	姿态	时间	平均
1			95.52	69.08	43.64	54.36	71.89
2	√		96.29	69.12	44.06	54.52	72.36
3	√	√	96.61	69.40	44.72	54.73	72.61

对于 Extended-Multi-Dim 协议,采用以下设置:使用未经过本文提出的对比图像对构建的数据,作为模型输入,采用 Led3D^[10]网络模型;后两种方法的设置与对 Lock3DFace 协议的方法相同。表 7 展示了这 3 种方法的结果。

表 7 针对 Extend-Multi-Dim 协议不同网络设置的识别准确率比较

Tab. 7 Comparison of recognition accuracy for different network settings of the Extend-Multi-Dim (%)

方法	对比图像对	对比损失函数	中性	表情	姿态 1	姿态 2	平均
1			96.41	93.14	71.43	54.36	82.53
2	√		95.87	92.41	71.35	54.52	82.05
3	√	√	97.49	93.76	72.13	54.73	83.20

以上实验结果表明,同时采用提出的对比图像对和对比损失函数时,识别准确率可达最高水平。

然而,当仅采用提出的对比图像对和模型架构而不使用对比损失函数时,其效果不及基准模型。这说明所提出的对比图像对和对比损失函数需要结合使用,才能更好地展现其鲁棒性。

为了直观展示 CNF 去噪模块在特征提取过程中降低噪声强度的有效性,选取了来自 4 个不同身份的低质量人脸深度中性表情数据,我们对这些数据经过 FDMR 网络的第 1 层 CNN 模块和 CNF 模块后的特征进行了可视化处理,以观察去噪效果。

如图 7 所示,每 1 行表示同一幅图像的特征可视化,基准为模型输入。第 1 列展示了经过 FDMR 网络第 1 层 CNN 模块后的特征可视化结果,第 2 列至第 6 列按顺序展示了经过 CNF 去噪模块不同迭代次数后的可视化结果。显而易见,经过 CNF 去噪模块处理后,从中性表情数据中提取的特征噪声逐渐减少,人脸的有效特征变得更加清晰。




图 7 低质量三维人脸中性表情数据的特征可视化

Fig. 7 Feature visualization of low-quality 3D face neutral expression data

为验证 CNF 去噪模块对 Lock3DFace 数据集所有子集上的去噪效果,我们从同一身份的低质量人脸深度数据的各个子集中随机选择了一张图像,并进行了与前述相同的可视化处理。图 8 展示了相应的可视化结果。根据图示,CNF 去噪模块对 Lock3DFace 的任意子集都表现出明显的去噪效果。



图 8 Lock3DFace 数据集不同子集的特征可视化

Fig. 8 Feature visualization of different subsets of Lock3DFace

为验证 CNF 去噪模块在提高人脸识别准确率方面仍有效果,采用与 Zhang 等^[23]相同的 C 协议开展验证实验。网络模型设置如下:1)Led3D^[10]网络模型;2)Led3D 网络模型+CNF 去噪模块。表 8 展示了这 2 种实验的结果。

表 8 针对 C 协议不同网络设置的识别准确率比较

Tab. 8 Comparison of recognition accuracy for different net work settings of C protocol (%)						
方法	CNF 去噪模块	表情	遮挡	姿态	时间	平均
1		93.52	56.77	36.34	37.94	61.10
2	√	95.70	67.56	40.56	51.76	68.13

从表 8 中可以看出,添加了 CNF 去噪模块的网络模型在各个子集上的识别准确率均有提升。相对于 Led3D 网络模型,表情识别准确率提高了 2.18%,姿态识别准确率提高了 4.22%,平均准确率提高了 7.03%。结合特征可视化结果与实验数据,CNF 去噪模块不仅在直观上有效地降低了特征噪声,而且在提高识别准确率方面也表现出有效性。

综上所述,本文提出的对比图像对构建方法、对比损失函数设计以及去噪模块在提升低质量人脸深度图像识别准确率方面均表现出一定的有效性。

4 结 论

本文提出基于低成本三维扫描仪的人脸深度图识别方法。为缓解特征噪声、损失函数计算复杂度高问题对低质量人脸深度图像识别性能的负面影响,我们引入 CNF 去噪模块,减轻噪声数据对识别结果的影响。方法通过构建低质量人脸深度图像的对比图像对、设计相应的对比损失函数,提升模型的鲁棒性和实时性能。在 Lock3DFace 和 Extended-Multi-Dim 数据集上的实验结果表明,所提方法在面对不同表情、姿态、遮挡的人脸时均表现出良好有效性。

[参 考 文 献]

[1] GILANI S Z, MIAN A. Learning from millions of 3d scans for large-scale 3d face recognition [C]// IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Salt Lake City, Utah, US, 2018: 1896–1905.

[2] KIM D, HERNANDEZ M, CHOI J, et al. Deep 3D face identification [C]//IEEE. IAPR. IEEE

International Joint Conference on Biometrics. Washington DC, US, 2017: 133–142.

[3] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. Imagenet classification with deep convolutional neural networks [J]. *Advances in neural information processing systems*, 2012, 25: 1097–1105.

[4] CAI Y, LEI Y, YANG M, et al. A fast and robust 3d face recognition approach based on deeply learned face representation [J]. *Neurocomputing*, 2019, 363: 375–397.

[5] OLIVETTI E C, FERRETTI J, CIRRINCIONE G, et al. Deep cnn for 3d face recognition [C]//Springer. International Conference of the Italian Association of Design Methods and Tools for Industrial Engineering. Bologna, Italy, 2019: 665–674.

[6] 胡振国. 低质量深度图像人脸识别技术研究[D]. 成都: 四川大学, 2019: 1–64.

[7] GOSWAMI G, BHARADWAJ S, VATSA M, et al. On rgb-d face recognition using Kinect [C]//IEEE. IEEE Sixth International Conference on Biometrics: Theory, Applications and Systems. Washington DC, US, 2013: 1–6.

[8] MIN R, KOSE N, DUGELAY J L. Kinectfacedb: A kinect database for face recognition [J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2014, 44(11):1534–1548.

[9] ZHANG J J, HUANG D, WANG Y H, et al. Lock3dface: A large-scale database of low-cost kinect 3d faces [C]//IEEE. International Conference on Biometrics. Washington DC, US, 2016: 1–8.

[10] MU G, HUANG D, HU G, et al. Led3d: A lightweight and efficient deep approach to recognizing low-quality 3d faces [C]//IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Angeles, CA, US, 2019: 5773–5782.

[11] 金梅, 李媛媛, 郝兴军, 等. 基于非对称增强注意力与特征交叉融合的行人重识别方法[J]. *计量学报*, 2022, 43(12): 1573–1580.

JIN M, LI Y Y, HAO X J, et al. Pedestrian Re-identification Method Based on Asymmetric Enhanced Attention and Feature Cross Fusion[J]. *Acta Metrologica Sinica*, 2022, 43(12): 1573–1580.

[12] 张立峰, 常恩健. 基于多尺度密集连接网络的电容层析成像图像重建[J]. *计量学报*, 2024, 45(5): 678–684.

ZHANG L F, CHANG E J. Image Reconstruction of Electrical Capacitance Tomography Based on Multi-scale Densely Connected Network [J]. *Acta Metrologica Sinica*, 2024, 45(5): 678–684.

[13] HU Z G, GUI P H, FENG Z Q, et al. Boosting depth-

- based face recognition from a quality perspective [J]. *Sensors*, 2019, 19(19):1-19.
- [14] 桑高丽,肖述笛,赵启军.联合软阈值去噪和视频数据融合的低质量3维人脸识别[J].中国图象图形学报,2023, 28(5): 1434-1444.
- SANG G L, XIAO S D, ZHAO Q J. Soft threshold denoising and video data fusion-relevant low-quality 3D face recognition [J]. *Journal of Image and Graphics*, 2023, 28(5): 1434-1444.
- [15] WANG Q, LEI H AND QIAN W Z. Point CNN: 3D Face Recognition with Local Feature Descriptor and Feature Enhancement Mechanism [J]. *Sensors*, 2023, 23(18): 7715-7731.
- [16] RADFORD A, KIM J W, HALLACY C, *et al.* Learning transferable visual models from natural language supervision [C]//ICML. The 38th International Conference on Machine Learning. 2021: 8748-8763.
- [17] CHEN, T, KORNBLITH S, NOROUZI M, *et al.* A simple framework for contrastive learning of visual representations [C]//IMLS. International Conference on Machine Learning. Vienna, Austria, 2020: 1597-1607.
- [18] CARON M, MISRA I, MAIRAL J, *et al.* Unsupervised learning of visual features by contrasting cluster assignments [C]//NeurIPS Foundation. Proceedings of the 34th Annual Conference on Neural Information Processing Systems. Vancouver, Canada, 2020: 9912-9924.
- [19] KINGMA D P, WELING M. Auto-Encoding Variational Bayes [C]//ICLR. In 2nd International Conference on Learning Representations. Arizona, US, 2014: 501-508.
- [20] CHEN T Q, RUBANOVA Y, BETTENCOURT J, *et al.* Neural Ordinary Differential Equations [C]//NeurIPS Foundation. In Annual Conference on Neural Information Processing Systems. Vancouver, Canada, 2018: 6571-6583.
- [21] PHILLIPS P J, FLYNN P J, SCRUGGS T, *et al.* Overview of the face recognition grand challenge [C]//IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. San Francisco, US, 2005: 947-954.
- [22] SAVRAN A, ALYÜZ N, DİBEKLİOĞLU H, *et al.* Bosphorus database for 3d face analysis [C]//IEEE. European Workshop on Biometrics and Identity Management. Bologna, Italy, 2008: 47-56.
- [23] ZHANG Z, YU C, XU S, *et al.* Learning flexibly distributional representation for low - quality 3d face recognition [C]//AAAI. Proceedings of the AAAI Conference on Artificial Intelligence. Los Angeles, CA, US, 2021: 3465-3473.
- [24] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift [C]//IMLS. In Proceedings of the 32nd International Conference on Machine Learning. Lyon, France, 2015: 747-756.
- [25] SZEGEDY C, VANHOUCKE V, IOFFE S, *et al.* Rethinking the inception architecture for computer vision [C]//IEEE. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, Nevada, USA, 2016: 2818-2826.
- [26] SANDLER M, HOWARD A, ZHU M L, *et al.* Mobilenetv2: Inverted residuals and linear bottlenecks [C]//IEEE/CVF. Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA, 2018: 4510-4520.
- [27] JIANG C, LIN S, CHEN W, *et al.* PointFace: Point cloud encoder-based feature embedding for 3-D face recognition //IEEE. *IEEE Transactions on Biometrics, Behavior, and Identity Science*. 2022:486-497.
- [28] YANG J L, REN P R, ZHANG D Q, *et al.* Neural aggregation network for video face recognition [C]//IEEE. Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA, 2017: 5216-5225.
- [29] LIU Z X, HU H, BAI J Q, *et al.* Feature aggregation network for video face recognition [C]//IEEE/CVF. Proceedings of 2019 IEEE/CVF International Conference on Computer Vision Workshop. Seoul, South Korea, 2019: 990-998.



第一作者: 张楠楠(1999 -),男,河南洛阳人,浙江理工大学硕士研究生,主要研究方向为低质量三维人脸识别。

Email: zhangn202203@163.com



通讯作者: 桑高丽(1986 -),女,河南鹿邑人,嘉兴大学副教授,硕士生导师,博士,从事复杂环境下模式识别、身份认证等方面的研究工作。

Email: glsang@zjxu.edu.cn