

电子与信息学报
Journal of Electronics & Information Technology
ISSN 1009-5896, CN 11-4494/TN

《电子与信息学报》网络首发论文

题目: 基于多码深度特征融合生成对抗网络的文本生成图像方法
作者: 顾广华, 孙文星, 伊柏宇
收稿日期: 2025-06-07
网络首发日期: 2026-01-19
引用格式: 顾广华, 孙文星, 伊柏宇. 基于多码深度特征融合生成对抗网络的文本生成图像方法[J/OL]. 电子与信息学报.
<https://link.cnki.net/urlid/11.4494.TN.20260119.0906.008>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于多码深度特征融合生成对抗网络的文本生成图像方法

顾广华* 孙文星 伊柏宇

(燕山大学信息科学与工程学院 秦皇岛 066004)

摘要：文本生成图像是一项极具挑战的跨模态任务，其核心在于生成与文本描述高度一致、细节丰富的高质量图像。当前基于生成对抗网络的方法多依赖单一噪声输入，导致生成图像细粒度不足；同时，单词级特征利用不充分，也制约了文本与图像之间的语义对齐精度。为此，该文提出一种多码深度特征融合生成对抗网络(mDFA-GAN)。该方法通过设计多噪声输入生成器与多码先验融合模块，提升生成图像的细节表现力；在生成器中引入多头注意力机制，从多角度对齐单词与图像子区域，增强语义一致性；此外，提出多码先验融合损失以稳定训练过程。在CUB和COCO数据集上的实验结果表明，所提方法在IS与FID评价指标上均优于当前主流生成对抗网络方法，能够生成更逼真、细节更丰富、语义一致性更强的图像。

关键词：文本生成图像；生成对抗网络；跨模态；多码先验融合

中图分类号：TN911; TP391

文献标识码：A

文章编号：1009-5896(2026)01-0001-10

DOI: 10.11999/JEIT250516

CSTR: 32379.14.JEIT250516

1 引言

以自然语言描述为条件生成图像是一项极具挑战的跨模态任务，核心目标是生成视觉合理、细节丰富且与文本语义高度对齐的图像。其核心难点在于两方面：一是如何精准捕捉文本中的细粒度属性(如物体颜色、局部结构)并映射为视觉细节；二是如何建立文本与图像间的复杂关联，实现全局与局部的语义一致性。

现有基于生成对抗网络(GAN)^[1]的方法仍存在明显局限：多数模型依赖单一噪声输入生成全部图像信息，难以支撑多样化细节的精准表达，导致生成结果细粒度不足；在语义对齐层面，部分模型(如DF-GAN^[2])仅采用句子级文本特征，忽略了单词级信息对局部视觉细节的指导作用；尽管Attn-GAN^[3]引入注意力机制考虑单词级特征，但未能充分建模同一单词对多个图像子区域的多角度影响，难以全面捕捉跨模态语义关联。

为解决上述问题，本文引入“多码”概念，提出一种多码深度特征融合生成对抗网络mDFA-GAN。模型通过多噪声输入结构、多码先验融合模块及多头注意力机制(借鉴Transformer^[4]的核心思想)，同步提升生成图像的细节丰富度与文本-图

像语义一致性。文本生成图像技术已广泛应用于艺术图像生成^[5,6]、图像风格转换^[7,8]及人脸合成^[9,10]等场景，本文方法可为这些实际应用提供更高效的技术支撑。

本文的主要贡献包括：(1)提出多噪声输入网络结构和多码融合模块，并设计多码融合损失函数以稳定训练；(2)在生成器中引入多头注意力机制，增强生成图像与文本的语义一致性；(3)在CUB和COCO数据集上进行了广泛的定性与定量实验，验证了模型的先进性。

2 相关工作

文本生成图像。早期文本生成图像研究以条件生成对抗网络(cGAN)为基础，Reed等人^[11]首次将cGAN引入该任务，实现了文本到图像的初步映射，但生成图像分辨率低、细节模糊。为突破分辨率瓶颈，Zhang等人^[12]提出StackGAN，通过两阶段堆叠结构逐步提升图像清晰度，但两阶段设计增加了模型复杂度与训练难度。Zhang等人^[13]进一步提出StackGAN++，优化了堆叠生成流程的特征传递效率，但仍未解决多阶段训练的不稳定性问题。单级生成架构的提出简化了训练流程，Tao等人^[2]提出DF-GAN采用单级生成器直接合成图像，通过深度特征融合提升生成质量，成为该领域的重要基线模型。Liao等人^[14]在SSA-GAN中引入语义-空间感知模块，强化了文本语义与图像空间结构的对应关系。Tao等人^[15]提出GALIP，利用CLIP预训练模型的跨模态泛化能力，进一步提升了模型对多样化文本描述的适配性。

近年来自回归模型与扩散模型成为文本生成图

收稿日期：2025-06-07；改回日期：2025-12-22

*通信作者：顾广华 guguanghua@ysu.edu.cn

基金项目：国家自然科学基金(62072394)，河北省自然科学基金(F2024203049)

Foundation Items: The National Natural Science Foundation of China(62072394), Hebei Provincial Natural Science Foundation(F2024203049)

像的新热点。Lu等人^[16]提出DPM-Solver++为扩散模型提供了高效的采样方案,推动其广泛应用。Ding等人^[17]提出的CogView基于Transformer架构实现了高质量文本到图像生成。Rombach等人^[18]提出Stable Diffusion通过潜空间扩散机制来平衡生成质量与计算成本。该类模型虽能生成高分辨率、多样化的图像,但迭代去噪过程导致推理速度慢、计算开销大,在实时性要求较高的场景中难以应用。

文本图像语义一致性。语义一致性是文本生成图像的核心评价标准,学者们通过注意力机制、特征融合、结构化建模等方式持续优化文本与图像的关联建模。Xu等人^[3]提出的AttnGAN首次在生成器中引入注意力模块,实现单词与图像区域的动态关联,为语义对齐奠定了基础。Zhao等人^[9]在MSCGAN中结合BERT^[20]预训练模型提取句子级与单词级多层文本特征,丰富了语义表征的维度。Li等人^[21]设计堆叠式单词级判别器(ControlGAN),通过局部语义监督强化单词与图像局部区域的对应关系。在动态特征优化与结构化建模方面,Ruan等人^[22]提出的DAE-GAN通过动态增强机制,根据文本语义自适应丰富图像细节。Zhang等人^[23]在RiFeGAN中利用注意力匹配模型优化局部语义对齐精度。Yuan等人^[24]通过组合多注意力机制有效减少了生成内容的重复性,提升了语义表达的多样性。Deng等人^[25]基于语法树分离名词短语作为局部特征输入,使模型能更精准地捕捉文本中的核心语义成分。Yang等人^[26]设计深度多模态循环融合网络(DMF-GAN),通过循环交互强化跨模态特征融合,提升了全局语义一致性。

尽管上述方法在语义对齐方面各有突破,但仍

存在两个共性问题:一是多数模型依赖单一噪声输入,难以支撑细粒度纹理与多样化细节的生成需求;二是对单词与图像区域间的复杂多元关联建模不够充分,多采用单一注意力机制,难以全面覆盖跨模态语义对应关系。针对这些问题,本文通过多码融合模块增强细节生成能力,结合多头注意力机制实现多角度、细粒度的语义对齐,进一步弥补现有方法的不足。

3 模型构建

本文提出基于多码深度特征融合生成对抗网络的方法,由预训练的文本编码器、多码深度融合生成器和鉴别器三部分组成。整体结构如图1所示。

生成器部分,多个噪声和句子向量送入生成器 G_1 模块得到 n 个 64×64 的特征,经多码先验融合模块融合后,送入生成器 G_2 模块。该模块利用多头注意力机制提升语义一致性,得到 256×256 大小的图像。鉴别器采用单向结构,即采用6个连续的下采样块和2个卷积层计算对抗损失,加速收敛。

3.1 多码深度融合生成器

生成器输入为句子向量和多个潜码,步骤如下:

(1)每个噪声经全连接层进入 G_1 模块生成 64×64 特征,经多码先验融合模块融合;(2)融合特征输入 G_2 模块,通过多头注意力机制优化语义对齐,生成 256×256 特征;(3)经卷积层转化为RGB图像。 G_1 和 G_2 由含上采样层、残差模块和深度文本图像融合模块的上采样块构成。

3.1.1 多码深度融合模块

本文使用多个噪声编码合成图像。将生成器分




图1 模型整体结构

为两个子网络 $G_1^{(l)}(\cdot)$ 和 $G_2^{(l)}(\cdot)$ ，通过通过组合 $G_1^{(l)}(\cdot)$ 得到的中间特征来组合噪声。对任意 z_n ，提取空间特征 $F_N^{(l)} = G_1^{(l)}(z_n)$ (潜码)进一步合成。Bau等人^[27]指出GAN中不同通道负责不同视觉概念，不同层生成不同内容。因此，为每个潜码引入自适应通道权重 α_n ，使潜码与不同语义对齐，如图2所示。 $\alpha_n \in \mathbb{R}^C$ 是一个维度为 C 的向量， C 是生成器 $G(\cdot)$ 第 l 层的通道数。通道自适应权重 α_n 用来表示特征 $F_n^{(l)}$ 对应通道的重要性。通过这种融合方式，可以得到生成图像为

$$x = G_2^{(l)} \left(\sum_{n=1}^N F_n^{(l)} \odot \alpha_n \right) \quad (1)$$

$$\{F_n^{(l)} \odot \alpha_n\}_{i,j,c} = \{F_n^{(l)}\}_{i,j,c} \times \{\alpha_n\}_c \quad (2)$$

其中， $\odot$ 表示通道级乘法， i 和 j 表示空间位置， c 表示通道索引。

3.1.2 深度文本图像融合模块

该模块由多层感知机、Affine模块、激活函数和卷积层组成，用于文本与图像的特征融合，如图3所示。文本编码器得到的句子向量经多层感知机(MLP)^[28]输入到Affine模块，用两个单隐藏层MLP来预测文本条件的通道比例参数 γ 和句子向量的偏置 β ，表示为

$$\gamma = \text{MLP}_1(e^{\text{sent}}), \beta = \text{MLP}_2(e^{\text{sent}}) \quad (3)$$

若输入特征向量大小为 $X \in \mathbb{R}^{B \times C \times H \times W}$ ，MLP的输出是一个大小为 C 的向量，用比例参数 γ 对图像向量 x 进行比例缩放，接着偏置参数 β 对缩放后的图像特征进行微调。该过程为




图2 多码深度融合模块




图3 深度文本图像融合模块

$$\text{AFF}(x_i | e^{\text{sent}}) = \gamma_i x_i + \beta_i \quad (4)$$

其中, AFF为仿射变换, x_i 为视觉特征图的第 i 个通道, e^{sent} 为句子向量, γ_i 和 β_i 为图像特征的第 i 个通道的比例缩放参数和移位参数。通过通道级别的缩放和移动, 生成器可以捕捉文本描述中的语义信息, 并合成匹配文本描述的真实图像。训练过程中, 梯度范数保持在一个合理的范围内, 未出现梯度消失或梯度爆炸现象。这表明本模块能够有效地维持梯度稳定, 从而保障模型训练的鲁棒性。

3.1.3 多头注意力机制

受Transformer启发, 本文将多头注意力与AttnGAN的注意力机制结合, 使不同注意力头从不同角度关联单词与图像区域, 并综合多个单词信息。多头注意力结构如图4所示, 输入包括生成图像特征 v (经过生成模块 G_1 、多码先验融合模块及生成模块 G_2 的上采样后得到)和单词级特征 w (由预训练的文本编码器得到)。特征 w 的维度为 $D \times L$, 经过一个多层感知机 Q 生成维度为 $C \times L$ 大小的特征, L 表示单词长度。计算单词图像区域相关矩阵 $m \in R^{(H \times W) \times L}$, H 与 W 均为128维, 分别表示生成图像的宽度和高度, 计算公式为

$$m = v \cdot (Q \cdot w) \quad (5)$$

经Softmax标准化后, 得到的相关矩阵与转置变换后的单词级特征相乘, 得到注意单词图像区域特征 $\text{Att} \in R^{(H \times W) \times C}$, 计算公式为

$$\text{Att}_j = \text{softmax}(v \cdot (Q_j \cdot w)) \cdot (Q_j \cdot w)^T \quad (6)$$

$$j \in \{0, 1, \dots, k-1\}$$

本文参考前人工作来设置头数 k 。Transformer模型^[4]指出, 多头注意力的头数通常设为6或8时能在模型复杂度和表征能力之间取得平衡。同时, DMF-GAN^[26]方法亦将头数设置为6时取得了良好效果。因此, 本文将头数 k 设置为6。

此外, 多头注意力机制在多个生成图像的子区

域计算注意力单词图像区域特征, 并通过元素相加的方式, 融合所有注意力头输出的单词-图像区域特征:

$$F_{MH}(v, w) = \sum_{j=0}^{k-1} \text{Att}_j, j \in \{0, 1, \dots, k-1\} \quad (7)$$

最终, 多头注意力特征 $F_{MH}(v, w)$ 与图像特征 v 连接, 作为 G_2 最后上采样块的输入特征。模型在最后一个上采样模块前引入多头注意力机制, 利用单词级信息生成更细粒度的图像。

3.2 鉴别器

双向鉴别器使用无条件损失和条件损失, 合并优化时可能导致优化方向偏离, 影响生成质量和收敛速度。为优化训练效率, 本文利用单向鉴别器, 仅采用条件损失, 使梯度反馈更加明确, 加速模型收敛。单向鉴别器的整体框图如图5所示。通过一系列下采样块提取生成图像特征, 然后将图像特征和文本特征向量连接, 通过两个卷积层输出对抗损失。




图4 多头注意力结构图




图5 鉴别器结构图

3.3 损失函数

本文使用铰链损失保证训练稳定性, 公式为

$$L_{D_H} = -E_{x \sim P_r} [\min(0, -1 + D(x, e))] \\ - (1/2) E_{G(z) \sim P_g} [\min(0, -1 - D(G(z), e))] \\ - (1/2) E_{x \sim P_{mis}} [\min(0, -1 - D(x, e))] \quad (8)$$

$$L_{G_H} = -E_{G(z) \sim P_g} D(G(z), e) \quad (9)$$

其中, z 为噪声向量, e 为文本特征向量。 P_g , P_r , P_{mis} 分别表示合成数据、真实数据和不匹配数据的分布。

(1) 鉴别器损失

鉴别器损失为铰链损失和条件匹配感知零中心梯度惩罚损失(conditional Matching-Aware zero-centered Gradient Penalty, MA-GP)之和, 其表达式为

$$L_D = L_{D_H} + L_{MA_GP} \\ = -E_{x \sim P_r} [\min(0, -1 + D(x, e))] \\ - (1/2) E_{G(z) \sim P_g} [\min(0, -1 - D(G(z), e))] \\ - (1/2) E_{x \sim P_{mis}} [\min(0, -1 - D(x, e))] \\ + k E_{x \sim P_r} [(\|\nabla_x D(x, e)\| + \|\nabla_e D(x, e)\|)^p] \quad (10)$$

其中, D 表示鉴别器, x 表示对鉴别器输入的数据, k 和 p 为超参数。

(2) 生成器损失

本文提出多码融合损失 L_{G_m} , 主要由均方差构成, 通过使特征的均方差最小, 来保证生成特征的同伦性, 表达式为

$$L_{G_m} = \frac{\varepsilon}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2 \quad (11)$$

其中, n 为潜码的数量, $\bar{x}_n$ 为 n 个潜码生成特征的均值, x_i 为第 i 个潜码生成特征, ε 为超参数。生成器损失函数由铰链损失和多码融合损失构成, 表达式为

$$L_G = L_{G_H} + L_{G_m} \\ - E_{G(z) \sim P_r} D(G(z), e) + \frac{\varepsilon}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2 \quad (12)$$

4 实验与结果

4.1 数据集与实验设置

采用Caltech-UCSD Birds-200-2011(CUB)数据集^[29]和MS COCO数据集^[30]评估模型性能: CUB数据集含200类鸟类共11 788幅图像(训练集8 855幅、测试集2 933幅), 每幅图像对应10个文本描述; COCO数据集含12万幅图像(训练集8万幅、测试集4万幅), 涵盖多类别场景, 每幅图像含5个文本描述, 任务难度更高。

本文选择Inception Score(IS)^[31]和Fréchet Inception Distance(FID)^[32]两种指标评估网络的性能。IS反映文本-图像语义一致性, 得分越高对齐效果越好; FID衡量生成图像与真实图像的相似度, 值越低图像越逼真。每个模型生成30 000张256×256图像计算FID; 在COCO数据集上, 本文采用FID进行性能评估。由于IS在该数据集上对文本生成图像质量的评价稳定性不足, 因此未使用IS指标。

实验基于Python3.8和Pytorch1.13框架, 采用NVIDIA GeForce RTX4090显卡训练。实验使用Adam方法进行网络的更新, 超参数 $\beta_1=0.01$, $\beta_2=0.9$ 。生成器与鉴别器的学习率分别为0.0001和0.0004。在CUB数据集上训练600轮, 在COCO数据集上训练120轮。

实验基于Python3.8和Pytorch1.13框架, 采用NVIDIA GeForce RTX4090显卡训练。实验使用Adam方法进行网络的更新, 超参数 $\beta_1=0.01$, $\beta_2=0.9$ 。生成器与鉴别器的学习率分别为0.0001和0.0004。在CUB数据集上训练600轮, 在COCO数据集上训练120轮。

4.2 定性分析

在CUB和COCO数据集上, 本文方法与DF-GAN^[2], SSA-GAN^[14]和DM-GAN^[33]的生成图像结果对比, 如图6、图7所示。由图6可知, 本文方法在颜色准确性上表现优异, 如第1列第4行图像精确表达出浅灰色。同时, 在细节丰富度更具有细粒度, 例如第2列文本表述黑色带条纹的翅膀。

由图7可知, 本文方法同样具有精确的颜色表达, 例如第1列第4行黄绿色的火车。同时能够将文本描述中的对象细致地呈现出来, 例如第2列图像, 其它方法得到的图像几乎都忽略了滑雪装备, 而本文方法能够合成出滑板。另外, 在动态场景表达上本文方法也优于对比方法, 例如第6列, 对比其他方法, 本文方法生成图像更具动态性。实验表明, 本文方法在颜色准确性、细节丰富度和动态场景表达上均优于对比方法。

4.3 定量结果

本文方法与经典的堆叠式GAN方法(StackGAN++^[13], AttnGAN^[3], DM-GAN^[26], DR-GAN^[28])和单级GAN方法(DF-GAN^[2], SSA-GAN^[14])进行对比。表1和表2分别展示了IS指标和FID指标的对比结果。

由表1可知, 在CUB数据集上, 本文方法的IS值最高(4.82)。由表2可知, 在CUB和COCO数据集上, 本文方法的FID值均为最优(13.45和16.50)。与基于Transformer和扩散模型的CogView方法及潜在扩散模型LDM-8方法相比, 本文方法在COCO数据集上的FID值分别降低了39.11%和29.21%, 表明本文方法在生成图像的真实性方面具有明显优势。



图 6 CUB数据集生成图像结果图




图 7 COCO数据集生成图像结果图

表 1 在CUB数据集上与前沿算法相比IS得分情况表

方法	Inception Score(IS) ↑
StackGAN++	4.04±0.06
AttnGAN	4.36±0.03
DM-GAN	4.47±0.19
DR-GAN	4.66±0.15
DF-GAN	4.61±0.12
SSA-GAN	4.70±0.08
本文	4.82±0.10

4.4 消融实验

为评估各模块贡献，本文进行以下消融实验：(1)基线模型(DF-GAN)；(2)基线模型+多码融合模块；(3)基线模型+多头注意力模块；(4)本文完整网络。

表3展示了各模块的消融实验结果。在CUB数据集和COCO数据集上基线模型(DF-GAN)的FID值分别为14.81和19.32。单独添加多码融合模块后，FID分别降至14.21和17.94；单独添加多头

注意力模块后，FID分别降至13.75和17.19。两个模块同时使用时，FID值达到最优(13.45和16.50)，验证了各模块的有效性。

同时，为确定噪声 n 的数量对实验结果的影响，本文进一步对 n 的数量选择进行了实验，结果如表4所示。噪声数量 n 为3时模型性能最佳。

为了进一步证明本文模型的有效性与实用性，对比了本文方法与DF-GAN, Stable Diffusion和DALLE2三种方法的推理速度，如表5所示。虽然本文方法推理速度略慢于DF-GAN，但显著快于扩散模型Stable Diffusion和DALLE2。这是由于扩散模型所用的训练数据量均为亿万级，特别是Stable Diffusion利用LAION-5B数据集，包含约58.5亿对图像和文本描述。与DF-GAN对比，本文方法推理速度略慢，这是因为本文的网络结构是多噪声输

入，多码融合的网络结构一定程度上拖慢了推理速度。

5 总结

本文围绕文本生成图像任务中细粒度细节不足与语义对齐不精准两大挑战，提出了一种多码深度特征融合生成对抗网络。其核心在于通过多噪声输入机制扩展生成器的潜表示空间，利用多码先验融合模块自适应整合不同噪声编码所承载的视觉概念，从而显著增强生成图像的细节丰富度与纹理真实性。同时，模型引入多头注意力机制，建立多角度的单词-图像区域关联，有效提升了跨模态语义对齐的精度与鲁棒性。在通用数据集上的实验证明了本文方法的优越性。本文不仅提出了一种高性能的文本生成图像模型，也为跨模态特征融合与细粒度语义对齐提供了新思路。未来研究可进一步探索噪声编码的语义解耦机制，并结合知识增强或跨数据集迁移方法，提升模型在开放场景下的泛化能力与可解释性。

参考文献

- [1] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, *et al.* Generative adversarial networks[J]. *Communications of the ACM*, 2020, 63(11): 139–144. doi: [10.1145/3422622](https://doi.org/10.1145/3422622).
- [2] TAO Ming, TANG Hao, WU Fei, *et al.* DF-GAN: A simple and effective baseline for text-to-image synthesis[C]. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, New Orleans, USA, 2022: 16494–16504. doi: [10.1109/CVPR52688.2022.01602](https://doi.org/10.1109/CVPR52688.2022.01602).
- [3] XU Tao, ZHANG Pengchuan, HUANG Qiuyuan, *et al.* AttnGAN: Fine-grained text to image generation with attentional generative adversarial networks[C]. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, Salt Lake City, USA, 2018: 1316–1324. doi: [10.1109/CVPR.2018.00143](https://doi.org/10.1109/CVPR.2018.00143).
- [4] VASWANI A, SHAZEER N, PARMAR N, *et al.* Attention is all you need[C]. *Proceedings of the 31st Conference on Neural Information Processing Systems (NIPS 2017)*, Long Beach, USA, 2017: 6000–6010.
- [5] XUE A. End-to-end Chinese landscape painting creation using generative adversarial networks[C]. *Proceedings of the IEEE Winter Conference on Applications of Computer Vision*, Waikoloa, USA, 2021: 3862–3870. doi: [10.1109/WACV48630.2021.00391](https://doi.org/10.1109/WACV48630.2021.00391).
- [6] SHAHRIAR S. GAN computers generate arts? A survey on visual arts, music, and literary text generation using generative adversarial network[J]. *Displays*, 2022, 73: 102237. doi: [10.1016/j.displa.2022.102237](https://doi.org/10.1016/j.displa.2022.102237).
- [7] ISOLA P, ZHU Junyan, ZHOU Tinghui, *et al.* Image-to-

表 2 在CUB数据集和COCO数据集上与前沿算法相比FID得分情况表

方法	CUB-FID ↓	COCO-FID ↓
StackGAN++	15.30	81.59
AttnGAN	23.98	35.49
DM-GAN	16.09	32.64
DR-GAN	14.96	27.80
DF-GAN	14.81	19.32
SSA-GAN	15.61	19.37
Cogview	-	27.10
LDM-8	-	23.31
本文	13.45	16.50

表 3 模型组成部分的消融实验

组成部分			CUB-FID ↓	COCO-FID ↓
基线模型	多码融合模块	多头注意力		
√	-	-	14.81	19.32
√	√	-	14.21	17.94
√	-	√	13.75	17.19
√	√	√	13.45	16.50

表 4 噪声 n 的数量选择实验

FID	n				
	1	2	3	4	5
CUB-FID ↓	14.21	13.67	13.45	13.65	13.70
COCO-FID ↓	17.94	16.95	16.50	16.86	16.90

表 5 推理速度对比(s)

方法	DF-GAN	Stable Diffusion	DALLE2	本文
推理速度	0.5	1.4	2	0.8 s

- image translation with conditional adversarial networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, USA, 2017: 5967–5976. doi: [10.1109/CVPR.2017.632](https://doi.org/10.1109/CVPR.2017.632).
- [8] ALOTAIBI A. Deep generative adversarial networks for image-to-image translation: A review[J]. *Symmetry*, 2020, 12(10): 1705. doi: [10.3390/sym12101705](https://doi.org/10.3390/sym12101705).
- [9] XIA Weihao, YANG Yujiu, XUE Jinghao, *et al.* TEDIGAN: Text-guided diverse face image generation and manipulation[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Nashville, USA, 2021: 2256–2265. doi: [10.1109/CVPR46437.2021.00229](https://doi.org/10.1109/CVPR46437.2021.00229).
- [10] KOCASARI U, DIRIK A, TIFTIKCI M, *et al.* StyleMC: Multi-channel based fast text-guided image generation and manipulation[C]. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision, Waikoloa, USA, 2022: 3441–3450. doi: [10.1109/WACV51458.2022.00350](https://doi.org/10.1109/WACV51458.2022.00350).
- [11] SAHARIA C, CHAN W, CHANG H, *et al.* Photorealistic text-to-image diffusion models with deep language understanding[C]. IEEE/CVF International Conference on Computer Vision (ICCV), Paris, France, 2023: 15679–15689.
- [12] ZHANG Han, XU Tao, LI Hongsheng, *et al.* StackGAN: Text to photo-realistic image synthesis with stacked generative adversarial networks[C]. Proceedings of the IEEE International Conference on Computer Vision, Venice, Italy, 2017: 5908–5916. doi: [10.1109/ICCV.2017.629](https://doi.org/10.1109/ICCV.2017.629).
- [13] ZHANG Han, XU Tao, LI Hongsheng, *et al.* StackGAN++: Realistic image synthesis with stacked generative adversarial networks[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2019, 41(8): 1947–1962. doi: [10.1109/TPAMI.2018.2856256](https://doi.org/10.1109/TPAMI.2018.2856256).
- [14] LIAO Wentong, HU Kai, YANG M Y, *et al.* Text to image generation with semantic-spatial aware GAN[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022: 18166–18175. doi: [10.1109/CVPR52688.2022.01765](https://doi.org/10.1109/CVPR52688.2022.01765).
- [15] TAO Ming, BAO Bingkun, TANG Hao, *et al.* GALIP: Generative adversarial CLIPs for text-to-image synthesis[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver, Canada, 2023: 14214–14223. doi: [10.1109/CVPR52729.2023.01366](https://doi.org/10.1109/CVPR52729.2023.01366).
- [16] LU Cheng, ZHOU Yuhao, BAO Fan, *et al.* DPM-Solver++: Fast solver for guided sampling of diffusion probabilistic models[J]. *Machine Intelligence Research*, 2025, 22(4): 730–751. doi: [10.1007/s11633-025-1562-4](https://doi.org/10.1007/s11633-025-1562-4).
- [17] DING Ming, YANG Zhuoyi, HONG Wenyi, *et al.* CogView: Mastering text-to-image generation via transformers[C]. Proceedings of the 35th Conference on Neural Information Processing Systems, 2021: 19822–19835.
- [18] ROMBACH R, BLATTMANN A, LORENZ D, *et al.* High-resolution image synthesis with latent diffusion models[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, New Orleans, USA, 2022: 10674–10685. doi: [10.1109/CVPR52688.2022.01042](https://doi.org/10.1109/CVPR52688.2022.01042).
- [19] ZHAO Liang, HUANG Pingda, CHEN Tengtu, *et al.* Multi-sentence complementarily generation for text-to-image synthesis[J]. *IEEE Transactions on Multimedia*, 2024, 26: 8323–8332. doi: [10.1109/TMM.2023.3297769](https://doi.org/10.1109/TMM.2023.3297769).
- [20] DEVLIN J, CHANG Mingwei, LEE K, *et al.* BERT: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), Minneapolis, USA, 2019: 4171–4186. doi: [10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423).
- [21] LI Bowen, QI Xiaojuan, LUKASIEWICZ T, *et al.* Controllable text-to-image generation[C]. Proceedings of the 33rd International Conference on Neural Information Processing Systems, Vancouver, Canada, 2019: 185.
- [22] RUAN Shulan, ZHANG Yong, ZHANG Kun, *et al.* DAE-GAN: Dynamic aspect-aware GAN for text-to-image synthesis[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision, Montreal, Canada, 2021: 13940–13949. doi: [10.1109/ICCV48922.2021.01370](https://doi.org/10.1109/ICCV48922.2021.01370).
- [23] ZHANG L, ZHANG Y, LIU X, *et al.* Fine-grained text-to-image synthesis via semantic pyramid alignment[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Vancouver, Canada, 2023: 23415–23425.
- [24] CHEN J, LIU Y, WANG H, *et al.* Improving text-image semantic consistency in generative adversarial networks via contrastive learning[J]. *IEEE Transactions on Multimedia*, 2024, 26: 5102–5113. doi: [10.1109/TMM.2024.3356781](https://doi.org/10.1109/TMM.2024.3356781).
- [25] DENG Zhijun, HE Xiangteng, and PENG Yuxin. LFR-GAN: Local feature refinement based generative adversarial network for text-to-image generation[J]. *ACM Transactions on Multimedia Computing, Communications and Applications*, 2023, 19(5): 207. doi: [10.1145/358900](https://doi.org/10.1145/358900).
- [26] YANG Bing, XIANG Xueqin, KONG Wangzeng, *et al.* DMF-GAN: Deep multimodal fusion generative adversarial networks for text-to-image synthesis[J]. *IEEE Transactions on Multimedia*, 2024, 26: 6956–6967. doi: [10.1109/TMM.2024.3358086](https://doi.org/10.1109/TMM.2024.3358086).
- [27] WANG Z, ZHOU Y, SHI B, *et al.* Advances in controllable and disentangled representation learning for generative models[J]. *International Journal of Computer Vision*, 2023, 131(5): 1245–1263. doi: [10.1007/s11263-023-01785-y](https://doi.org/10.1007/s11263-023-01785-y).

- [28] YUAN M and PENG Y. T2I-CompBench: A comprehensive benchmark for open-world compositional text-to-image generation[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024, 46(5): 2754–2769. doi: [10.1109/TPAMI.2023.3330805](https://doi.org/10.1109/TPAMI.2023.3330805).
- [29] SALIMANS T, GOODFELLOW I, ZAREMBA W, *et al.* Improved techniques for training GANs[C]. Proceedings of the 30th Conference on Neural Information Processing Systems, Barcelona, Spain, 2016: 2234–2242.
- [30] HEUSEL M, RAMSAUER H, UNTERTHINER T, *et al.* GANs trained by a two time-scale update rule converge to a local Nash equilibrium[C]. Proceedings of the 31st Conference on Neural Information Processing Systems (NIPS 2017), Long Beach, USA, 2017: 6629–6640.
- [31] TAN Hongchen, LIU Xiuping, YIN Baocai, *et al.* DR-GAN: Distribution regularization for text-to-image generation[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, 34(12): 10309–10323. doi: [10.1109/TNNLS.2022.3165573](https://doi.org/10.1109/TNNLS.2022.3165573).
- [32] WAH C, BRANSON S, WELINDER P, *et al.* The Caltech-UCSD birds-200–2011 dataset[R]. CNS-TR-2010-001, 2011.
- [33] LIN T Y, MAIRE M, BELONGIE S, *et al.* Microsoft COCO: Common objects in context[C]. Proceedings of 13th European Conference on Computer Vision -- ECCV 2014, Zurich, Switzerland, 2014: 740–755. doi: [10.1007/978-3-319-10602-1_48](https://doi.org/10.1007/978-3-319-10602-1_48).
- 顾广华：男，教授，研究方向为图像语义理解、多媒体跨模态检索。
孙文星：女，硕士生，研究方向为文本生成图像。
伊柏宇：男，硕士生，研究方向为计算机视觉。
- 责任编辑：陈 倩

Multi-code Deep Fusion Attention Generative Adversarial Networks for Text-to-Image Synthesis

GU Guanghua SUN Wenxing YI Boyu

(School of Information Science and Engineering, Yanshan University, Qinhuangdao 066004, China)

Abstract:

Objective Text-to-image synthesis is a core task in multimodal artificial intelligence and aims to generate photorealistic images that accurately correspond to natural language descriptions. This capability supports a wide range of applications, including creative design, education, data augmentation, and human–computer interaction. However, simultaneously achieving high visual fidelity and precise semantic alignment remains challenging. Most existing Generative Adversarial Network (GAN) based methods condition image generation on a single latent noise vector, which limits the representation of diverse visual attributes described in text. Therefore, generated images often lack fine textures, subtle color variations, or detailed structural characteristics. In addition, although attention mechanisms enhance semantic correspondence, many approaches rely on single-focus attention, which is insufficient to capture the complex many-to-many relationships between linguistic expressions and visual regions. These limitations result in an observable discrepancy between textual descriptions and synthesized images. To address these issues, a novel GAN architecture, termed Multi-code Deep Feature Fusion Attention Generative Adversarial Network (mDFA-GAN), is proposed. The objective is to enhance text-to-image synthesis by enriching latent visual representations through multiple noise codes and strengthening semantic reasoning through a multi-head attention mechanism, thereby improving detail accuracy and textual faithfulness.

Methods A mDFA-GAN is proposed. The generator incorporates three main components. First, a multi-noise input strategy is adopted, in which multiple independent noise vectors are used instead of a single latent noise vector, allowing different noise codes to capture different visual attributes such as structure, texture, and color. Second, a Multi-code Prior Fusion Module is designed to integrate these latent representations. This module operates on intermediate feature maps and applies learnable channel-wise weights to perform adaptive weighted summation, producing a unified and detail-rich feature representation. Third, a Multi-head Attention Module is embedded in the later stages of the generator. This module computes attention between visual features and word embeddings across multiple attention heads, enabling each image region to attend to multiple semantically relevant words and improving fine-grained cross-modal alignment. Training is conducted using a

unidirectional discriminator with a conditional hinge loss combined with a Matching-Aware zero-centered Gradient Penalty (MA-GP) to enhance training stability and enforce text-image consistency. In addition, a multi-code fusion loss is introduced to reduce variance among features derived from different noise codes, thereby promoting spatial and semantic coherence.

Results and Discussions The proposed mDFA-GAN is evaluated on the CUB-200-2011 and MS COCO datasets. Qualitative results, as illustrated in (Fig. 7) and (Fig. 8), indicate that the proposed method generates images with accurate colors, fine-grained details, and coherent complex scenes. Subtle textual attributes, such as specific plumage patterns and object shapes, are effectively captured. Quantitative evaluation demonstrates state-of-the-art performance. An Inception Score (IS) of 4.82 is achieved on the CUB-200-2011 dataset (Table 2), reflecting improved perceptual quality and semantic consistency. Moreover, the lowest Fréchet Inception Distance (FID) values of 13.45 on CUB-200-2011 and 16.50 on MS COCO are obtained (Table 3), indicating that the generated images are statistically closer to real samples. Ablation experiments confirm the contribution of each component. Performance degrades when either the Multi-code Prior Fusion Module or the Multi-head Attention Module is removed (Table 4), and the multi-code fusion loss is shown to be critical for training stability and synthesis quality (Table 5). Further analysis identifies three noise codes as the optimal configuration (Table 6). In terms of efficiency, the model achieves an inference time of 0.8 seconds per image (Table 7), maintaining the efficiency advantage of GAN-based methods.

Conclusions A novel text-to-image synthesis framework, mDFA-GAN, is proposed to address limited fine-grained detail representation and insufficient semantic alignment in existing GAN-based methods. By decomposing the latent space into multiple noise codes and adaptively fusing them, the model enhances its capacity to generate detailed visual content. The integration of multi-head cross-modal attention enables more accurate and context-aware semantic grounding. Experimental results on benchmark datasets demonstrate that mDFA-GAN achieves state-of-the-art performance, as evidenced by improved IS and FID scores and high-quality visual results. Ablation studies further validate the necessity and complementary effects of the proposed components. The framework provides both an effective solution for text-to-image synthesis and useful architectural insights for future research in multimodal representation learning.

Key words: Text-to-image synthesis; Generative adversarial network; Cross-modal attention; Multi-code prior fusion