

计算机辅助设计与图形学学报

Journal of Computer-Aided Design & Computer Graphics

ISSN 1003-9775, CN 11-2925/TP

《计算机辅助设计与图形学学报》网络首发论文

题目：增强人体关键点特征的姿态估计算法
作者：刘赏，代娆，周煜炜，董林芳
收稿日期：2023-10-31
网络首发日期：2024-08-21
引用格式：刘赏，代娆，周煜炜，董林芳. 增强人体关键点特征的姿态估计算法[J/OL]. 计算机辅助设计与图形学学报.
<https://link.cnki.net/urlid/11.2925.TP.20240821.1035.014>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

增强人体关键点特征的姿态估计算法

刘赏, 代娆, 周煜炜, 董林芳

(天津财经大学理工学院 天津 300222)

(liushangw@tjufe.edu.cn)

摘要：二维多人姿态估计是计算机视觉领域中一项具有挑战性的任务，其中基于回归的单阶段方法大多缺乏对多人姿态特征学习的针对性，对人体关节结构特征提取能力不足和关键点位置特征融合能力不足。针对上述人体关键点特征约束能力不足的问题进行改进，提出一种增强人体关键点特征的算法。首先基于 MixFormer 思想给出多头自注意力机制和深度卷积并行的策略，以增强人体姿态的局部和全局特征，在获取高质量视觉表征的同时学习更多的人体关节结构信息；然后给出坐标注意力机制和空洞空间卷积池化金字塔串行融合策略，先将人体姿态特征进行拆分来捕获跨通道信息，再采用空洞卷积扩大感受野，减少小目标信息的丢失，提高多尺度特征融合能力；最后结合 YOLO-Pose 算法进行姿态估计。在 2 个数据集上进行实验的结果表明，COCO2017 数据集上，所提算法的 AP 值提高 0.9 个百分点，AR 值提高 1.2 个百分点；OC_Human 遮挡数据集上，AP 值提高 2.3 个百分点；该算法可以在保证运行速度的同时增强人体关键点特征，提高整体性能。

关键词：多人姿态估计；多头自注意力机制；坐标注意力机制；空洞空间卷积池化金字塔

中图法分类号：TP391.41 DOI: 10.3724/SP.J.1089.2023-00706

Pose Estimation Algorithm with Enhanced Human Keypoint Features

Liu Shang, Dai Rao, Zhou Yuwei, and Dong Linfang

(School of Science and Technology, Tianjin University of Finance and Economics, Tianjin 300222)

Abstract: 2D multi-person pose estimation is a challenging task in computer vision. Some regression-based single-stage methods lack pertinence for learning multi-person pose representation, which leads to insufficient feature extraction capability for the human joint structure and feature fusion capability for the keypoint location. This paper improves the problem of insufficient constraint for the keypoint features and proposes an algorithm with enhanced human keypoint features. Firstly, based on the idea of MixFormer, the strategy of the multi-head self-attention mechanism and depthwise convolution parallelism is proposed, which enhances the local and global features of the human pose simultaneously. High-quality visual representations can be obtained while learning more human joint structure information. Second, the strategy of serial fusion of the coordinate attention mechanism and atrous spatial pyramid pooling is proposed. The human pose features are split to capture cross-channel information, and then the atrous convolution is used to expand the receptive field, thus reducing the loss of small object information and enhancing the multi-scale feature fusion ability. Finally, the YOLO-Pose is combined for multi-person pose estimation. Experiments on the two data sets show that the algorithm in this paper improves the AP by 0.9 percentage point and the AR by 1.2 percentage point

收稿日期：2023-10-31；修回日期：2024-07-02。基金项目：天津市科技计划项目(22ZLZKZF00480)；天津市自然科学基金(22JCYBJC01550)。刘赏(1977—)，女，博士，教授，硕士生导师，主要研究方向为计算机视觉；代娆(1998—)，女，硕士研究生，主要研究方向为计算机视觉、图像处理；周煜炜(1998—)，女，硕士研究生，主要研究方向为图像处理、目标检测；董林芳(1972—)，女，博士，副教授，硕士生导师，主要研究方向为图形图像处理、自然语言分析。

on the COCO2017 data sets. The AP on the OC_Human crowded data sets is improved by 2.3 percentage point. With the guarantee of the running speed unchanged, the human keypoint features are enhanced and the overall performance is improved.

Key words: multi-person pose estimation; multi-head self-attention mechanism; coordinate attention mechanism; atrous spatial pyramid pooling

二维多人姿态估计是人体姿态估计中一个重要的分支,任务是在图像中识别出人体关键点,将关键点按顺序连接形成人体骨骼图^[1],在人机交互、视频监控、运动分析等领域均有应用。

通常,二维多人姿态估计包括自顶向下、自底向上和单阶段3种方法。自顶向下方法先识别出图像中的所有人体,然后分别对每个人体做单人姿态估计。高分辨率网络(high-resolution net, HRNet)^[2]通过多分辨率并行的方式保持高分辨率特征并进行多尺度融合,提高关键点位置预测的准确性;基于回归方法的残差对数似然估计^[3]利用极大似然估计和基于流的生成模型学习误差分布,效果优于热图法;视觉Transformer姿态估计^[4]以Transformer^[5]为基准,通过在视觉Transformer^[6]网络之后附加反卷积层来回归关键点热图,进行姿态估计。自底向上方法则是先预测出图像中所有关键点的位置坐标,再为这些关键点分配对应的人体。文献[7]借鉴单阶段目标检测的思路,通过从图像中回归出人体和关键点的位置分析预测人体姿态;在HRNet的基础上,Cheng等^[8]提出一种尺度感知高分辨率网络,通过反卷积得到高分辨率特征以提高算法准确率。单阶段方法直接对输入图像中的所有人体进行关键点预测,能发挥端到端网络将输入图像映射到人体姿态的优势,比多阶段方法具有更快的运算速度^[9],算法精度也具有竞争力。FCPose(fully convolutional pose)^[10]是一种基于动态实例感知卷积的全卷积多人姿态估计算法,其充分利用动态卷积的特点提高推理速度。McNally等^[11]提出一种基于回归的KaPao(key-points and poses as objects)算法,以YOLOv5(you only look once v5)框架为基准,在不使用热图的情况下同时检测人体姿态对象和关键点对象,通过融合检测结果得到预测的关键点;由于该算法的预测结果不包含单个关键点的置信度,并且其训练通常需要大量时间和内存,因此存在一定的局限性。YOLO-Pose(you only look once pose)^[12]同样是一种基于YOLOv5的回归算法,与KaPao不同,

YOLO-Pose联合预测人体边界框和17个人体关键点坐标及其置信度,在目标检测框架上实现了姿态估计且几乎不增加额外的运算,精度也与两阶段方法不分伯仲。

基于回归的单阶段二维多人姿态估计算法缺乏对人体关键点特征的约束。无论是KaPao还是YOLO-Pose,均以目标检测模型为基础,以C3^[13]组成的骨干网络进行特征提取,并以金字塔结构进行多尺度特征融合。本文通过分析发现:YOLO-Pose算法利用C3提取图像特征时,卷积操作虽然可以提取丰富的局部姿态特征,但不能有效地提取人体相连关节结构整体特征,从而出现关键点偏移现象;在特征金字塔多尺度融合过程中,也忽略了多尺度变化对关键点位置特征造成的损失。因此,这类算法的结构更偏向对目标检测和姿态估计联合学习的通用性,没有体现其在二维多人姿态估计领域的优势。

根据以上分析,本文提出YOLO-Pose针对(pertinence yolo pose, PY-Pose)算法,在实现姿势估计时获取更充分的人体局部和全局结构特征,以及多尺度特征融合时的关键点位置特征。该算法给出基于CMixF3(C3 with mixformer)结构的特征提取网络和基于空洞金字塔坐标注意力(atrous pyramid coordinate attention, APCA)结构的特征融合网络,并将2者结合到YOLO-Pose算法中进行二维多人姿态估计。CMixF3结构采用多头自注意力机制(multi-head self-attention mechanism, MHSAM)和深度卷积(depthwise convolution, DWConv)^[14]并行的策略,增强了人体关节结构的局部和全局特征;APCA结构采用坐标注意力机制(coordinate attention mechanism, CAM)^[15]和空洞空间卷积池化金字塔(atrous spatial pyramid pooling, ASPP)^[16]串行融合的策略,能够扩大感受野以丰富多尺度特征融合时的关键点位置特征。PY-Pose算法可以解决现有单阶段回归方法对关键点特征约束不足的问题,对于人体姿态特征的学习更具有针对性,能够提高预测的准确率。

1 PY-Pose 算法

1.1 PY-Pose 总体架构

PY-Pose 算法分为特征提取网络、特征融合网络、检测头和后处理 4 部分, 整体上使用 4 个不同尺度的特征层, 如图 1 所示. 其中, 特征提取网络面向人体局部和全局特征, 由 C3 模块和本文提出的 CMixF3 结构组成, 得到 P_3 , P_4 , P_5 和 P_6 这 4 个中间特征层; 特征融合网络由特征金字塔网络 (feature pyramid networks, FPN)^[17] 和路径聚合网络 (path aggregation network, PAN)^[18] 构成, 执行上采样和下采样操作, 融合多尺度的人体姿态特征, PAN 中采用本文提出的 APCA 结构, 以减少 P_6 最深特征层的关键点位置特征损失; 检测头由普通卷积和 DWConv 构成, 通过对网络输出结果进行解码调整得到预测结果, 解码时, 人体边界框和关

键点坐标都相对于锚框中心进行转换, 得到多个重叠的预测边界框; 后处理则利用非极大值抑制 (non-maximum suppression, NMS) 算法^[19] 剔除重叠框, 得到预测结果. 假设输入为 1 幅 3 通道的 RGB 图像, 最终的预测结果包含 1 个人体类别, 每个人体包括 1 个边界框和 17 个关键点坐标及其对应的置信度. 因此对于每个锚框, 其预测输出的向量 P_v 定义为

$$P_v = \{x, y, W, H, C_{\text{conf}}, C_{\text{class}}, K_x^1, K_y^1, K_{\text{conf}}^1, \dots, K_x^{17}, K_y^{17}, K_{\text{conf}}^{17}\}.$$

其中, x, y 表示预测中心点的坐标; W, H 表示边界框的宽和高; C_{conf} 表示预测边界框的置信度; C_{class} 表示预测的类别; $K^1 \sim K^{17}$ 表示人体的 17 个关键点; K_x, K_y 和 K_{conf} 分别表示关键点的二维坐标 (x, y) 和置信度.





图 1 PY-Pose 算法整体结构

1.2 MHSAM 和 DWConv 并行策略

本文基于 MixFormer^[20] 的思想将 MHSAM 和卷积操作相结合, 提出 MHSAM 和 DWConv 并行的双分支结构. 为了使算法学习到更多的人体关节结构信息, 将双分支结构与 C3 模块进行全新结合, 提出 CMixF3 结构以增强算法对姿态特征提取的针对性.

人体姿态估计任务本质上是定位出图像中的人体和预测人体关键点的位置, 并将相连关节进行符合实际的连接. 利用 C3 卷积构成的骨干网络对图像进行特征提取, 其特征包含视觉特征和人体关节结构特征 2 个方面. C3 中的卷积操作利用过滤器, 通过滑动的方式对区域内的像素进行计算, 其对图像纹理信息的特征提取能力很强, 能学习到高质量的视觉表征. 但是, 卷积操作提取到的人体姿态特征基本属于局部特征, 对全局关键点位置特征的学习能力较弱, 导致对人体关节结构

特征提取不足. 例如, 若图像中左手肘和右手肘关键点位置碰巧相邻, 使用 C3 提取局部特征时可能会错误地让这 2 个点联动, 如图 2a 所示, 但实际上, 左手肘和右手肘并不相连, 而是与手臂或手腕相连. 对人体关节结构特征提取不足也会导致预测出的关键点发生严重偏移, 如图 2b 所示, 算法对面部密集相连关节的结构特征学习不足, 导致关键点位置偏移出边界框.



a. 特征学习错误

b. 关键点偏移

图 2 人体关节结构特征提取不足问题

本文基于 MHSAM 的特点, 给出 MHSAM 与 DWConv 并行的策略, 以提高算法对人体关节结

构局部和全局特征的提取能力. MixFormer 是一个将局部窗口自注意力机制(local windows self-attention mechanism, LWSAM)^[21]和卷积操作相结合的算法. 本文通过实验发现, 局部窗口的方式对学习关键点位置特征并不友好, 过度学习窗口内部分关键点之间的关系会导致算法忽略全局关键点的相关性, 适得其反. 而 MHSAM 采用多个头来增强算法对不同维度特征的关注度, 同时在图像的每个块之间两两使用注意力机制, 因此可以更好地学习到全局关键点之间的位置关系和相关性. 卷积操作通过建模邻域像素之间的关系, 与 MHSAM 互补, 同时增强人体姿态的局部和全局特征, 使得预测的人体姿态更贴近实际的人体物理学结构.

CMixF3 的结构如图 3 所示, 核心部分是将 MHSAM 和 DWConv 这 2 个分支并行执行, 其中, MHSAM 头数设置为 4, DWConv 使用 3×3 大小的卷积核以减少参数量. MHSAM 在空间维度进行计算, 提取人体姿态的空间特征, 但是在通道维度建模能力较弱; DWConv 在通道维度建模, 提取人体姿态的通道特征, 但是其空间维度的建模能力较弱; 因此将 2 者进行双向交互, 可以同时增强 2 个分支的通道-空间维度的建模能力, 获取更全面的人体姿态特征. 对于 DWConv 到 MHSAM 的交互

实现, 首先进行全局平均池化(global average pooling, GAP)处理; 然后利用 1 个 Conv 卷积层进行通道间的信息交互; 最后使用 1×1 的 Conv2d 卷积函数调整维度后, 利用 Sigmoid 函数将特征值转化为概率分布传给 MHSAM. CMixF3 结构利用 DWConv 分支生成通道维度的注意力应用于 MHSAM 分支, 增强其对通道维度的姿态特征提取能力. MHSAM 到 DWConv 的交互实现与前者类似, 不同的是不经过 GAP 处理. 同理, CMixF3 利用 MHSAM 分支生成空间维度的注意力传给 DWConv 分支, 增强其对空间维度的姿态特征提取能力. 最后连接残差并通过多层感知器(multilayer perceptron, MLP)层输出, 公式为

$$\begin{cases} X^{l+1'} = M_f \left(\text{LN}(X^l), \text{MHSAM}, \text{DWConv} \right) + X^l \\ X^{l+1} = \text{MLP} \left(\text{LN}(X^{l+1'}) \right) + X^{l+1'} \end{cases}$$

其中, X^l 表示第 l 层特征; 层归一化(layer normalization, LN)表示对当前层进行归一化; M_f 表示对 MHSAM 分支和 DWConv 分支之间的特征 f 进行混合, 即上述分支并行过程; $X^{l+1'}$ 表示混合后的中间层, MLP 则由 2 个线性层组成, 中间使用 GELU 激活函数. 将 $X^{l+1'}$ 进行归一化后传入 MLP, 然后拼接残差得到第 $l+1$ 层.




图 3 CMixF3 的结构

针对 C3 模块对人体关节结构特征提取能力不足的问题, 本文采用并行分支结构替代瓶颈结构,

作为 C3 的主要组成部分, 构建 CMixF3. CMixF3 整体上分成左、右 2 部分: 主干部分将并行分支进

行堆叠; 另 1 部分则利用 1 个卷积操作直接连接到最后. 将 CMixF3 结构应用到骨干网络, PY-Pose 算法中的特征提取网络如图 4 所示. 该网络由 Conv, C3 和 CMixF3 构成. Focus 模块对输入图像进行切片操作; 空间金字塔池化(spatial pyramid pooling, SPP)^[22]模块将特征图转换为固定大小的特征向量. Conv 卷积层包括 1×1 或 3×3 的 Conv2d 卷积函数、批归一化(batch normalization, BN)和 SiLU 激活

函数 3 部分. 瓶颈结构先利用 1×1 卷积将通道数减小一半, 再通过 3×3 卷积将通道数加倍并获取特征. P3, P4, P5 和 P6 这 4 个不同尺度特征层分别连接特征融合网络. P6 作为最深特征层具有较强的语义信息, 但是关键点位置信息最薄弱, 因此 PY-Pose 使用 CMixF3 结构对最深特征层进行特征提取, 以学习更丰富的局部和全局特征, 提高对关键点特征的约束能力和针对性.




图 4 PY-Pose 算法中的特征提取网络结构

1.3 CAM 和 ASPP 串行融合策略

本文将 CAM 和 ASPP 进行串行融合, 整体上采用 CAM 的结构, 将 ASPP 引入 CAM 中, 串行融合到一维特征拼接后构建 APCA, 提高对多人姿态特征提取的针对性.

多尺度特征融合金字塔使用 FPN, 将深层的语义特征经过上采样传到浅层进行融合, 然后使用 PAN 将浅层的位置特征经过逐步下采样传到深层进行融合. 在此过程中, PAN 逐步对深层的关键点位置信息进行补充, 但是在下采样过程中损失过多, 最后传递到深层的位置特征几乎不存在, 大

大降低了深特征层对人体姿态特征的融合能力. 考虑到不同尺度的位置特征对算法的作用不同, 如果直接融合这些特征可能会给算法带来噪声, 存在语义冲突.

针对上述问题, 本文以 CAM 为主体框架, 将人体姿态特征拆分成 2 个并行的一维编码过程, 捕获跨通道的姿态信息. 通过增强深特征层的位置特征, 算法能够更加精准地定位人体关键点. 但是, 2 个并行的一维特征拼接融合后可能会存在语义冲突, 小目标人体的关键点位置信息容易混淆在冲突信息中, 导致位置信息的丢失. ASPP 是一种

可提高感受野的技术, 由空洞卷积构成. 空洞卷积与一般卷积的差别在于膨胀率, 通过不同的填充以及膨胀可以获取不同尺度的感受野, 提取更丰富的人体姿态位置信息. 因此, 本文将 ASPP 引入

CAM 中, 串行融合到一维特征拼接后捕获多尺度上下文的人体姿态特征, 减少关键点位置信息的丢失. APCA 的结构如图 5 所示.




图 5 APCA 的结构

本文的 APCA 结构中, CAM 首先将特征图经 GAP 分解为 $(c \times h \times 1)$ 和 $(c \times 1 \times w)$ 这 2 个一维特征编码过程, 分别沿垂直和水平 2 个空间方向聚合特征; 然后连接 ASPP 结构, ASPP 对拼接融合后的特征以 1, 2 和 5 这 3 种采样率的空洞卷积并行采样, 采样率遵循混合空洞卷积^[23]原则, 避免网格效应. 为了保持 APCA 灵活且轻量, 本文以深度可分离的空洞卷积替代普通空洞卷积, 在保证卷积效果的同时大大减小算法模型的参数量并降低计算复杂度; 然后通过 1×1 卷积改变通道数进行降维, 继续执行 CAM 生成中间特征图 f , 将其沿垂直和水平 2 个空间维度拆分为 f^h 和 f^w . 针对 f^h 和 f^w 分别使用 1×1 卷积和 Sigmoid 激活函数进行加权, 将这 2 个嵌入特定方向信息的特征图编码为 2 个注意力图, 每个注意力图都能够捕获对应方向的远程依赖关系, 获取更准确的关键点位置信息. 公式为

$$\begin{cases} W^h = \sigma(C^h(f^h)) \\ W^w = \sigma(C^w(f^w)) \end{cases}$$

其中, f^h , f^w 分别表示沿垂直和水平方向的中间特征图; C^h 和 C^w 表示 2 个方向的 1×1 卷积; σ 表示 Sigmoid 激活函数; W^h 和 W^w 表示 2 个方向计算得出的权重. 将 2 个注意力图作用到输入特征图上, 以增强其对关键点位置特征的约束, 将 APCA 结构应用到 PAN 中, PY-Pose 算法中的特征融合网络如图 6 所示. 该网络由特征金字塔构成, FPN 由 Conv, 上采样和 C3 构成, Conv 使用 1×1 卷积核, 上采样使用插值, C3 不使用残差连接. PAN 由 C3, 下采样和 APCA 构成, 下采样使用 3×3 卷积核. PAN 中浅层的位置信息传到最深特征层 P6 时损失过多, 关键点位置特征约束能力最差, 故 APCA 被用于 P6 特征拼接融合之后, 以提高对关键点位置特征的融合能力.




图6 PY-Pose 特征融合网络结构图

2 实验结果与分析

2.1 数据集与实验设置

2.1.1 数据集

为了验证 PY-Pose 算法的效果, 本文采用 COCO2017 多人姿态估计数据集(简称 COCO2017 数据集)^[24]和 OC_Human 多人遮挡的数据集(简称 OC_Human 数据集)^[25]进行实验. COCO2017 数据集包含 118k 训练集、5k 验证集和 41k 测试集, 其中, 多人姿态估计训练集为 64k, 经过图像去噪处理之后为 57k; 该数据集的类别只有 1 个“人体”, 每个人体包含边界框、17 个关键点位置坐标及其可见性; 本文使用 57k 训练集和 5k 验证集来验证 PY-Pose 算法的性能. OC_Human 是一个存在严重遮挡的多人姿态估计数据集, 共有 4 731 幅图像, 包含 8 110 个人体实例. 本文在 OC_Human 数据集的 2 500 幅验证集和 2 231 幅测试集上进行实验.

2.1.2 实验环境

本文使用 24 GB 显存的 RTX 3090 GPU 进行实验, 使用的 Python 版本为 3.9.7, Pytorch 框架版本为 1.8.0, Torchvision 版本为 0.9.0, 并安装 CUDA 11.1 和 CUDNN 8.0.5 进行加速. PY-Pose 算法的模型分为 s, m 和 l 这 3 个版本, 网络深度和宽度逐渐增大, 模型复杂度逐渐上升, 本文默认以 s 基础版

本进行实验, 不展示在 m 以及 l 版本上的结果. PY-Pose 算法采用与 YOLO-Pose 相同的数据增强策略, 包括随机缩放([0.5,1.5])、随机平移([-10,10])、左右翻转(0.5)、马赛克增强(1.0)以及各种色彩增强等. 模型在训练时使用随机梯度下降优化算法, 初始学习率设为 0.01, 训练批次设置为 300, 其中, 前 100 次采用冻结训练, 冻结骨干网络部分层, 保留 YOLO-Pose 预训练模型的泛化能力; 批大小为 32, 训练输入图像大小为 960×960 , 置信度阈值为 0.001, 交并比阈值设为 0.7.

2.1.3 评估指标

本文使用标准的基于关键点相似度(object keypoint similarity, OKS)的 COCO 姿态估计评估指标, 计算所有预测的人体关键点和其真实值之间的相似度. 使用平均精度(average precision, AP), AP^{50} , AP^{75} , AP^M , AP^L 和平均召回率(average recall, AR)来综合评估 PY-Pose 算法的性能. 其中, AP^{50} 表示 OKS 大于 0.5 时的 AP 值; AP^{75} 表示 OKS 大于 0.75 时的 AP 值; AP^M 和 AP^L 分别表示中、大 2 种不同尺度目标的 AP 值, M 指面积在 $[32 \times 32, 96 \times 96]$ 之间的目标人体, L 指面积大于 96×96 的目标人体.

2.2 实验分析

2.2.1 COCO2017 数据集上的实验

在 COCO val2017 数据集上, 将 PY-Pose 与 7 种经典的二维多人姿态估计算法进行实验, 包含自顶向下、自底向上和单阶段 3 类, 结果如表 1 所示. 其中, 粗体表示最优值; 对比方法中, YOLO-Pose 为本文复现的结果, 其余对比方法的结果均为引用得到; 为了保持实验设置的一致性, 所有对比模型同样选取其基础版本, 均不附加加强版骨干网络、测试时数据增强等条件. 可以看出, PY-Pose 算法的 AP, AP^{50} , AP^{75} 和 AR 指标均取得了最优值, 高于次优值 0.4, 0.2, 0.1 和 0.1 个百分点; 在输入图像相对较小的情况下, DirectPose^[26]和 FCPose^[10]分别在 AP^L 和 AP^M 上取得了最优, 说明 2 者具有对大、中目标人体的预测优势; Integral Pose^[27], OpenPose^[28], InsPose^[29]和 KAPAO^[11]的效果略逊一筹. 在骨干网络和图像大小设置相同的情况下, 与基准模型 YOLO-Pose 相比, PY-Pose 算法的 5 项指标均有提升, AP 值提高 0.9 个百分点, AP^{50} 提高 0.2 个百分点, AP^{75} 提高 1.5 个百分点, AP^M 提高 2.9 个百分点, AR 值提高 1.2 个百分点,

证明了该算法整体的有效性,同时说明其在中等目标人体的预测上具有明显效果;在 AP^M 值提高的同时 PY-Pose 的 AP^L 值降低,对大目标人体的预测效果有所欠缺.因此,同时提高对中、大目标人

体的预测能力也是本文未来的工作.总体来说, PY-Pose 算法在大部分指标上都取得了最优值,具有一定的优势和发展潜力.

表 1 在 COCO val2017 数据集上的实验结果对比

模型	类型	图像大小	AP	AP^{50}	AP^{75}	AP^M	AP^L	AR
Integral Pose ^[27]	自顶向下	256	63.0	85.6	70.0			
OpenPose ^[28]	自底向上		58.4	81.5	62.6	54.4	65.1	
DirectPose ^[26]	单阶段	800	63.1	85.6	68.8	57.7	71.3	
FCPose ^[10]	单阶段	800	63.0	85.9	68.9	59.1	70.3	
InsPose ^[29]	单阶段	800	63.1	86.2	68.5	58.5	70.1	
KAPAO ^[11]	单阶段	1 280	63.0					70.2
YOLO-Pose ^[12]	单阶段	960	62.6	87.0	68.6	49.8	71.2	69.1
PY-Pose	单阶段	960	63.5	87.2	70.1	52.7	69.4	70.3

注. 粗体表示最优值.

图 7 所示为 PY-Pose 算法在 COCO val2017 数据集上的部分可视化结果,包括大、中、小不同尺寸,不同位置,不同姿态和不同数量的各类人体.可以看出,不同图像中的每个人体都被检测出 1 个边界框和置信度以及人体关键点,相连关节使用

不同颜色的线条进行连接; PY-Pose 算法均可以较为准确地预测;通过对比图 2,关键点偏移的问题也得到了解决,但是还存在其他小目标人体检测不到的现象.因此,未来会进一步提高算法对小目标人体的检测能力.




图 7 PY-Pose 算法效果图

为了验证 CMixF3 和 APCA 结构的有效性,在

COCO2017 数据集上进行消融实验,分为 4 个实验,

结果如表 2 所示. 实验 1 为 YOLO-Pose 的 s 基准模型均不添加 CMixF3 和 APCA 的结果, 其中, 模型参数量为 15.1M; GFLOPs 是一个衡量模型计算复杂度的指标, 表示 10 亿次浮点运算的次数, 值为 20.5. 参数量和模型复杂度在一定程度上可以反映模型的运行速度. 实验 2 为在基准模型上施加 CMixF3 的结果. 可以看出, 在保持参数量和模型复杂度几乎不增加的情况下, 4 项指标均有提升: 其中, AP 提高 0.6 个百分点, AP^{75} 提高 1.0 个百分点, AR 提高 0.8 个百分点, AR^{75} 提高 1.3 个百分点, AP^{50} 和 AR^{50} 有轻微下降, 可以证明 MHSAM 和 DWConv 并行策略的有效性. 实验 3 为在基准模型上施加 APCA 的结果, 可以看出, 参数量和 GFLOPs 值分别有 4.2M 和 1.6 的轻微上升, 模型运行速度基本不受影响; 5 项指标均有提升: AP 提高 0.7 个百分点, AP^{75} 提高 1.3 个百分点, AR 提高 1.2 个百分点, AR^{50} 提高 0.2 个百分点, AR^{75} 提高

1.8 个百分点, AP^{50} 有 0.1 个百分点的轻微下降, 几乎无影响, 验证了 CAM 和 ASPP 串行融合策略的有效性. 实验 4 为 PY-Pose 算法, 即同时施加 CMixF3 和 APCA 的结果. 可以看出, 与基准模型相比, 参数量和 GFLOPs 均有一定程度的增加, 但总体来说增长较小, 模型依然可以保持与基准模型相当的运行速度; PY-Pose 算法的各项指标全部有提升: AP 提高 0.9 个百分点, AP^{50} 提高 0.2 个百分点, AP^{75} 提高 1.5 个百分点, AR 提高 1.2 个百分点, AR^{50} 提高 0.3 个百分点, AR^{75} 提高 1.6 个百分点, 说明该算法的整体预测结果有着全面性的提高. 将实验 4 与实验 2 和实验 3 分别进行比较可以看出, 2 种策略同时施加时, 各项指标值均高于只施加其中 1 种策略的情况, 充分表明本文提出的 2 种 MHSAM 和 DWConv 并行策略、CAM 和 ASPP 串行融合策略之间具有相辅相成的促进作用.

表 2 在 COCO val2017 数据集上的消融实验结果对比

%

实验	CMixF3	APCA	参数量	GFLOPs	AP	AP^{50}	AP^{75}	AR	AR^{50}	AR^{75}
1			15.1M	20.5	62.6	87.0	68.6	69.1	91.1	74.9
2	▲		15.2M	20.5	63.2	86.9	69.6	69.9	90.9	76.2
3		▲	19.3M	22.1	63.3	86.9	69.9	70.3	91.3	76.7
4	▲	▲	19.4M	22.1	63.5	87.2	70.1	70.3	91.4	76.5

注. “▲”表示施加对应的策略.

图 8 所示为 YOLO-Pose 和 PY-Pose 的注意力图可视化结果对比. 图 8a, 图 8c 所示为基准模型上的结果, 其中, YOLO-Pose-C3 对应特征提取网络最后 1 层的 C3 模块进行注意力可视化的结果图; YOLO-Pose-P6 为不施加 APCA 时, 特征融合网络 P6 最深特征层的 C3 模块的注意力图. 图 8b, 图 8d 所示为 PY-Pose 算法上的结果, 其中, CMixF3 表示特征提取网络最后一层 CMixF3 结构的注意力结果图; APCA 是特征融合网络 P6 最深特征层在施加 APCA 结构之后, C3 模块的注意力图. 可以看出, 与 YOLO-Pose-C3 相比, CMixF3 的第 2 行和第 3 行中算法对目标人体关键点的关注程度明显

增加, 第 1 行中对关键点位置的定位也更加精准, 说明 CMixF3 结构起到了增强人体关键点局部和全局特征的作用; 与 YOLO-Pose-P6 相比, APCA 的第 1 行和第 3 行图像中, 算法在施加 APCA 结构之后, C3 模块对人体以及关键点位置的关注意明显增强; 对比第 2 行也表明, 算法关注点向目标人体和关键点位置所在之处聚拢, 验证了 APCA 结构可以提高算法对人体关键点位置特征的约束能力. 实验结果表明, 不管是 CMixF3 还是 APCA 结构, 对人体关键点特征的学习能力均强于基准模型, 证明了本文所提 2 种策略的有效性.




图8 注意力图可视化结果对比

2.2.2 OC_Human 数据集上的实验

在 OC_Human 数据集上进行消融实验, 检验 CMixF3 和 APCA 结构在人体遮挡情况下的有效性, 表 3 所示为 CMixF3, APCA, 以及将 CMixF3 和 APCA 共同添加的结果对比. 实验 1 为 YOLO-Pose 基准模型均不添加 2 个结构的结果; 实验 2 和实验 3 为分别施加 CMixF3 和 APCA 的结果. 可以看出, 与实验 1 相比, 实验 2 和实验 3 的 3 项指标全部有所提升, 验证了在遮挡的情况下, CMixF3 和 APCA 结构均具有更强的鲁棒性, 能够保持一个更好的预测效果. 实验 4 为 CMixF3 和 APCA 同时施加的效果, 即 PY-Pose 算法. 可以看出, 与 YOLO-Pose 算法相比, 各项指标全部有所提升: AP 提高 2.3 个百分点, AP^{50} 提高 1.3 个百分点, AP^{75} 提高 2.2 个百分点, 说明 CMixF3 和 APCA 结构整体施加的有效性, 证明了 2 种策略在增强人体关键点特征上起到了明显的作用. 将实验 4 与实验 2 和实验 3 分别进

行实验, 可以看出, 全部指标均有一定程度的提升, 表明 CMixF3 和 APCA 结构具有共同促进的作用.

表 3 在 OC_Human 数据集上的消融实验结果 %

实验	CMixF3	APCA	AP	AP^{50}	AP^{75}
1			44.7	70.2	47.9
2	▲		45.6	71.4	49.1
3		▲	45.9	71.0	49.5
4	▲	▲	47.0	71.5	50.1

注: “▲”表示施加对应的策略.

为了更加直观地体现 PY-Pose 算法在遮挡情况下的效果, 将 YOLO-Pose 和 PY-Pose 算法在 OC_Human 数据集上进行实时检测, 图 9 所示为 2 者的效果对比. 可以看出, 针对多人身体遮挡的情况, PY-Pose 算法检测出了更多的被遮挡的人体和关键点, 比 YOLO-Pose 具有更强的检测能力, 虽然该算法目前还不能完全检测出所有遮挡的人体, 但是具有明显的优势和效果.



图9 遮挡情况下的检测效果对比

3 结 语

针对一类基于回归的单阶段二维多人姿态估计算法, 其结构更偏向对目标检测和姿态估计任务联合学习的通用性, 缺乏对人体关键点特征的约束. 本文针对人体关节结构特征提取能力不足、关键点位置特征融合能力不足的问题进行改进, 结合 YOLO-Pose 算法, 提出了基于 CMixF3 和 APCA 的 PY-Pose 算法, 以增强人体关键点特征.

本文在 COCO2017 数据集和 OC_Human 数据集上设计了对比实验和消融实验, 验证 PY-Pose 算法的性能. 实验结果表明, 与 YOLO-Pose 算法相比, PY-Pose 算法在保证运行速度基本不变的前提下各项指标均有提升, 与其他算法相比也具有一定的优势. 通过消融实验验证了 CMixF3 和 APCA 的有效性, CMixF3 可以提高算法对人体关节结构

的特征提取能力, 改善关键点偏移的情况; APCA 可以增强对关键点位置特征的融合能力.

未来, 将改进 NMS 算法来调整 PY-Pose 的后处理, 进一步提升该算法对大目标人体的预测能力, 减少小目标人体的漏检情况. 另外, 基于 PY-Pose 算法实现对人体不同姿态的多分类也是未来的一个研究目标.

参考文献(References):

- [1] Ma Shuangshuang, Wang Jia, Cao Shaozhong, *et al.* Overview on two-dimensional human pose estimation methods based on deep learning[J]. Computer Systems & Applications, 2022, 31(10): 36-43(in Chinese)
(马双双, 王佳, 曹少中, 等. 基于深度学习的二维人体姿态估计算法综述[J]. 计算机系统应用, 2022, 31(10): 36-43)
- [2] Sun K, Xiao B, Liu D, *et al.* Deep high-resolution representation learning for human pose estimation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 5686-5696

- [3] Li J F, Bian S Y, Zeng A L, *et al.* Human pose regression with residual log-likelihood estimation[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 11005-11014
- [4] Xu Y F, Zhang J, Zhang Q M, *et al.* ViTPose: simple vision transformer baselines for human pose estimation[C] //Proceedings of the 36th International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2022: Article No.2795
- [5] Vaswani A, Shazeer N, Parmar N, *et al.* Attention is all you need[C] //Proceedings of the 31st International Conference on Neural Information Processing Systems. Red Hook: Curran Associates Inc., 2017: 6000-6010
- [6] Dosovitskiy A, Beyer L, Kolesnikov A, *et al.* An image is worth 16x16 words: transformers for image recognition at scale[C] //Proceedings of the 9th International Conference on Learning Representations. Washington DC: ICLR, 2021
- [7] Sekii T. Pose proposal networks[C] //Proceedings of the 15th European Conference on Computer Vision. Heidelberg: Springer, 2018: 350-366
- [8] Cheng B W, Xiao B, Wang J D, *et al.* HigherHRNet: scale-aware representation learning for bottom-up human pose estimation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2020: 5385-5394
- [9] Kong Yinghui, Qin Yinfeng, Zhang Ke. Deep learning based two-dimension human pose estimation: a critical analysis[J]. Journal of Image and Graphics, 2023, 28(7): 1965-1989(in Chinese)
(孔英会, 秦胤峰, 张珂. 深度学习二维人体姿态估计方法综述[J]. 中国图象图形学报, 2023, 28(7): 1965-1989)
- [10] Mao W A, Tian Z, Wang X L, *et al.* FCPose: fully convolutional multi-person pose estimation with dynamic instance-aware convolutions[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2021: 9030-9039
- [11] McNally W, Vats K, Wong A, *et al.* Rethinking keypoint representations: modeling keypoints and poses as objects for multi-person human pose estimation[C] //Proceedings of the 17th European Conference on Computer Vision. Heidelberg: Springer, 2022: 37-54
- [12] Maji D, Nagori S, Mathew M, *et al.* YOLO-pose: enhancing YOLO for multi person pose estimation using object keypoint similarity loss[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Los Alamitos: IEEE Computer Society Press, 2022: 2636-2645
- [13] Bochkovskiy A, Wang C Y, Liao H Y M. Yolov4: optimal speed and accuracy of object detection[OL]. [2023-10-31]. <https://arxiv.org/abs/2004.10934>
- [14] Chollet F. Xception: deep learning with depthwise separable convolutions[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 1800-1807
- [15] Hou Q B, Zhou D Q, Feng J S. Coordinate attention for efficient mobile network design[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2021: 13708-13717
- [16] Chen L C, Papandreou G, Kokkinos I, *et al.* DeepLab: semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected CRFs[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 40(4): 834-848
- [17] Lin T Y, Dollár P, Girshick R, *et al.* Feature pyramid networks for object detection[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2016: 936-944
- [18] Liu S, Qi L, Qin H F, *et al.* Path aggregation network for instance segmentation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 8759-8768
- [19] Neubeck A, Van Gool L. Efficient non-maximum suppression[C] //Proceedings of the 18th International Conference on Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2006: 850-855
- [20] Chen Q, Wu Q M, Wang J, *et al.* MixFormer: mixing features across windows and dimensions[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2022: 5239-5249
- [21] Liu Z, Lin Y T, Cao Y, *et al.* Swin transformer: hierarchical vision transformer using shifted windows[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2021: 9992-10002
- [22] He K M, Zhang X Y, Ren S Q, *et al.* Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37(9): 1904-1916
- [23] Wang P Q, Chen P F, Yuan Y, *et al.* Understanding convolution for semantic segmentation[C] //Proceedings of the IEEE Winter Conference on Applications of Computer Vision. Los Alamitos: IEEE Computer Society Press, 2018: 1451-1460
- [24] Lin T Y, Maire M, Belongie S, *et al.* Microsoft COCO: common objects in context[C] //Proceedings of the 13th European Conference on Computer Vision. Heidelberg: Springer, 2014: 740-755
- [25] Zhang S H, Li R L, Dong X, *et al.* Pose2Seg: detection free human instance segmentation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 889-898
- [26] Tian Z, Chen H, Shen C H. DirectPose: direct end-to-end multi-person pose estimation[OL]. [2023-10-31]. <https://arxiv.org/abs/1911.07451>
- [27] Sun X, Xiao B, Wei F Y, *et al.* Integral human pose regression[C] //Proceedings of the 15th European Conference on Computer Vision. Heidelberg: Springer, 2018: 536-553
- [28] Cao Z, Simon T, Wei S E, *et al.* Realtime multi-person 2D pose estimation using part affinity fields[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 1302-1310
- [29] Shi D H, Wei X, Yu X D, *et al.* InsPose: instance-aware networks for single-stage multi-person pose estimation[C] //Proceedings of the 29th ACM International Conference on Multimedia. New York: ACM Press, 2021: 3079-3087