

文章

人工智能驱动的古文物识别与可持续保护
壁画:DKR-YOLO框架Zixuan Guo ¹ , Sameer Kumar ^{1,*}, Houbin Wang ²  and Jingyi Li ³ ¹ 马来西亚吉隆坡马来亚大学亚欧研究院,邮编:50603;s2138710@siswa.um.edu.my;中国烟台鲁东大学资源与环境工程² 学院,邮编:264025;houbin.wang.0816@gmail.com;中国重庆工程职业学院金融与旅游学院,邮编:402260;

lijingyi.ghkl@gmail.com; *通讯

作者:sameer@um.edu.my;电话:+60-379676929

抽象的

本文介绍了 DKR-YOLO,这是一个先进的深度学习框架,旨在增强古代壁画遗产的数字化保存和可持续管理。

DKR-YOLO 基于 YOLOv8,集成了创新组件,包括用于精细特征提取的 DySnake 卷积层和用于优化表征的自适应卷积核仓库,从而应对复杂细节、多元艺术风格和壁画退化带来的挑战。该网络架构还整合了残差特征增强 (RFA) 增强的 FPN (RE-FPN),优先处理最关键的视觉特征并提高可解释性。在壁画数据集上的大量实验表明,与基线模型相比,DKR-YOLO 的浮点运算次数 (FLOPs) 减少了 43.6%,准确率提高了 3.7%,平均绝对精度 (mAP) 提高了 5.1%。这种性能,加上对鲁棒性和可解释性的重视,支持人工智能在文化机构中更具包容性和可及性的应用,从而促进更广泛的参与和数字遗产保护的公平性。



学术编辑:Paolo Rosati,

马尔科·拉乌尔·马里尼和奥古斯托

帕隆比尼

收到日期:2025年8月3日

修订日期:2025年9月5日

已接受:2025年9月17日

发布日期:2025年9月25日

引用:郭志强、库马尔·S、王浩、李建,《人工智能驱动的古文物识别与可持续保护》。

壁画:DKR-YOLO 框架。

Heritage 2025, 8, 402. <https://doi.org/10.3390/heritage8100402>

版权所有: © 2025 作者所有。

被许可方 MDPI,瑞士巴塞尔。

本文为开放获取文章

根据条款和条件分发

知识共享协议的条款

署名 (CC BY) 许可

(https://creativecommons.org/

licenses/by/4.0/)。

关键词:文化遗产保护;古代壁画识别;深度学习;

YOLOv8;鲁棒性;可解释性;包容性人工智能;可持续数字化;DySnake

卷积;自适应卷积核

1. 引言

在全球范围内,壁画的保护和研究已在既定的国际框架内发展,该框架将壁画视为人类共同遗产的一部分[1]。联合国教科文组织《世界遗产公约》制定了保护“具有突出普遍价值”的文化财产的原则,促进了跨境协调,并制定了文献记录、状况评估和干预标准。在此政策基础之上,主要的保护项目推广了结合材料科学、艺术史和预防性保护的跨学科方法[2]。与此同时,研究基础设施降低了先进仪器、共享数据集和专家服务的门槛,加速了跨机构和跨国比较研究和可复制工作流程的开展[3]。

多传感器采集流程如今能够实现原位无损成像和多层建模,为下游分析提供丰富的输入数据[4]。与此同时,计算机视觉技术已从概念验证阶段发展成为美术馆、图书馆、档案馆和博物馆等场所的实用工具,支持藏品的分类、检索和监测。

规模[5]。近期调查和政策简报强调了深度学习的进步如何改善视觉档案的获取、实现编目自动化并辅助文物保护决策,同时也指出了特定领域的挑战,例如风格差异、老化导致的劣化以及数据不平衡[6]。在这样的国际背景下,中国壁画遗产——尤其是敦煌壁画——提供了一个独特的、极具挑战性的试验场:跨越数千年的风格、庞大的图像词汇以及广泛的数字化工作汇聚在一起,既创造了前所未有的机遇,也带来了严峻的信息检索瓶颈[7]。正是在此背景下,我们将目光转向敦煌,因为提高壁画元素的识别、检索和组织对于学术研究、文物保护规划和公众参与至关重要[8]。

敦煌石窟始发于前秦建元二年,凝聚了千余年各民族历史文化的融合,最终形成了独特的中国佛教艺术体系[9]。敦煌壁画对于全面了解中国艺术史至关重要,并在推动现代艺术创新方面发挥着关键作用[10]。

随着信息技术的飞速发展和文化遗产数字化进程的加快,敦煌壁画的修复技术和数字化馆藏方法取得了显著进步[11]。图书馆、档案馆和博物馆目前都收藏了大量的敦煌壁画图像。然而,这些图像抽象的视觉形式和晦涩的语义内容常常给用户构建精确的搜索查询带来挑战,导致相关图像检索困难,资源利用率低[12]。这些挑战阻碍了研究人员对敦煌壁画的有效研究,也抑制了公众探索敦煌文化的热情。将计算机图像识别技术应用于敦煌壁画的检索领域,为提高资源获取效率提供了一种有前景的解决方案[13]。通过改进修复和保护流程,并优化数字化馆藏和存储系统,这项技术可以为敦煌文化遗产的保护和传承做出重要贡献。具体而言,它通过提高资源利用率和推进信息传播来支持这些壁画的保护,最终确保这一宝贵文化遗产的长久保存和可及性。

1.1 视觉分类与检测研究近年来,目标检测和场景识别

的研究主要从三个方面展开:多尺度特征建模、轻量级设计和部署可行性。一个代表性方向是将自适应或加权机制引入特征融合结构,以增强多尺度交互。例如,自适应特征融合 (ASFF)已被广泛应用于顶级会议,证明了其在缓解复杂背景 (尺度分布不均)下语义信息与细节信息不匹配方面的有效性[14]。第二类研究强调动态卷积和注意力机制的结合,以在不显著增加计算量的情况下提高通道和空间选择性[15]。代表性趋势是将可变形/动态卷积核和轻量级注意力机制嵌入自顶向下/自底向上的金字塔结构中[16]。第三类研究关注端到端部署的轻量级检测器,并在参数数量和延迟方面提供了可复现的经验基线[17]。

假设一幅 640×640 的壁画中心包含一个直径约为 300 像素的大型语义目标。目标周围环绕着 4–8 像素的点阵图案和 2–4 像素宽的精细小目标。此外,颜料老化会进一步降低这些细节与背景颜色之间的对比度[18]。在 YOLOv8 的多尺度特征中,P5/stride32 捕捉到了主图像的强语义模式,并且

P3/stride8 保留了高频边缘信号[19]。当采用固定权重 PAN/FPN对 P3 进行自顶向下上采样和逐元素相加时, P5 的强语义响应往往会掩盖 P3 的弱边缘激活。此外,双线性或最近邻上采样会引入相位失调和高频混叠。

这些因素共同作用,进一步削弱了小目标信号。同时,壁画细节呈现出密集且重复的纹理分布,P3层中模糊的老化噪声会被无差别地传递到上层,导致点状图案被当作背景处理或合并成粗糙的块状响应[20]。主图像和大目标(例如光晕)的定位较为稳定,但斑点图案和细微裂纹则明显缺失,或者融合后置信度降低[21]。性能方面的主要共同点是:小目标的平均精度(AP)远低于大目标,相似图案之间的混淆增加,热图的注意力从细节泄露到大片背景色[22]。该场景示例表明,壁画图像的检测会放大固定跨阶段融合中细节与语义之间的冲突,从而使特征融合成为检测性能的瓶颈。

跨领域证据也支持上述方向:Dahri等人使用定制的CNN在遮挡和相似纹理环境下实现了室内场景识别的高精度,表明在“纹理相似且尺度变化较大”的任务中需要更强的多尺度判别能力[23]。Sun等人提出的MFE-YOLOv8用DCSlideLoss和ByteTrack实现了实时检测,并替换了C2f的多特征模块、EMA注意力机制和Focal-Modulation噪声抑制[24]。这体现了“融合+注意力+训练损失”协同优化的有效路径。

Ullah 等人通过多尺度特征协作和注意力引导,显著提高了小麦病害识别中对细粒度纹理的感知,满足了增强壁画裂缝和磨损等细节特征的要求[25]。

Iqbal 等人从物联网中的多传感器融合和“终端云”协作的角度为部署架构提供了参考[26]。

YOLO 系列提出了一种开创性和有影响力的目标检测方法,从根本上改变了视觉信息的感知和处理方式[27]。

YOLOv8 突破了目标检测和分类的界限[28]。近年来,许多顶尖研究工作都集中于基于 YOLO 的特征融合和结构演化。

Yolo-world 将视觉语言预训练集成到 YOLO 中,并提出了可重参数化的 RepVL-PAN 和基于区域的文本对比度损失[29]。它在 LVIS 数据集上取得了 35.4 AP/52 FPS (V100) 的成绩,表明在开放词汇检测条件下,效率和准确率仍然可以得到平衡。这使其成为跨模态特征聚合范式的宝贵参考。RTMO 将坐标分类以双一维热图的形式无缝集成到 YOLO 架构中,并在 COCO val2017 数据集上取得了 74.8 AP/141 FPS (V100) 的成绩,表明在单阶段框架中,通过更适合任务的特征表示和聚合路径,也可以打破速度-准确率的权衡[30]。在早期的辅助激励方法中,从训练策略出发,定位先验在早期阶段被显式地注入到检测头中,并逐步退火,使得YOLO在MS-COCO数据集上分别取得了+3.8/+2.2的mAP,这表明学习过程中的引导激活也能增强融合效果[31]。红外对抗车贴通过3D建模生成红外对抗车贴,在真实车辆上实现了91.49%的物理攻击成功率,并且对包括YOLOv3在内的多种检测器具有很强的迁移性[32]。我们注意到,在讨论弱对比度、多尺度场景(例如……)中的融合结构时,同时评估鲁棒性是必要的。

壁画。与固定权重的PAN/FPN相比,这些研究采用了可学习加权、多方向融合、任务自适应表示和训练时间指导机制等策略。这些方法共同改进了多尺度特征对齐和信息迁移,而没有显著增加开销。这为本文补充相关研究提供了直接基础,并以壁画的多尺度特性为例,阐明了改进融合的必要性的。

1.2 壁画检测应用研究

壁画作为最基本的绘画形式之一,已成为人类文化历史不可或缺的一部分[33]。传统艺术作品的研究日益受益于数字技术的应用。机器学习技术已被应用于传统绘画的分类。例如,输入向量已被用于山水画的分类,而基于注意力机制的长短期记忆 (LSTM)网络则被用于中国画的分类[34]。目前,大多数壁画自动分类技术都依赖于计算机视觉。常用方法包括基于轮廓的相似性度量、多示例分组和语义检索模型,这些方法旨在建立古代壁画内容与其潜在含义之间的联系。传统的壁画分类方法取得了一定的成功;然而,它们仅限于提取图像的基本属性[35]。壁画固有的主观性和多样性给充分捕捉纹理、色彩特性和其他复杂细节等高级特征带来了巨大挑战[36]。

现有的方法往往无法捕捉古代壁画的层次结构,而这对于理解不同元素之间的空间关系至关重要[37]。这种局限性导致定位和分类性能较差,特别是对于较小或部分遮挡的元素[38]。此外,许多现有技术中缺乏鲁棒的特征金字塔网络 (FPN),阻碍了多尺度特征的提取,导致图像不同层次的关键信息丢失[39]。

另一个主要挑战是现有算法无法有效解决古代壁画特有的问题,例如图像分辨率低、光照不均以及存在人为痕迹等。这些因素会显著降低目标检测和分类模型的性能,导致误报率和漏报率上升。此外,传统方法依赖手工提取的特征,限制了其对不同类型壁画的适应性和泛化能力。如果没有动态特征提取机制,这些模型难以有效地学习和表示古代壁画中固有的复杂图案和纹理[40]。

敦煌壁画是数字人文领域的一个重点,数字人文是一门将计算机科学与人文和社会科学相结合的学科,旨在促进数字技术融入文化遗产的保护和传播[41]。

这种跨学科方法重塑了传统的研究范式,并显著推进了文化史的研究。王等人对敦煌壁画构建了语义框架,创建了特定领域的词汇表,以弥合图像检索中的语义鸿沟[42]。曾等人采用词袋模型提取壁画图像特征,并使用支持向量机 (SVM)进行分类,探索了壁画的主题分布和王朝演变[43]。任等人则专注于利用生成对抗网络 (GAN)进行壁画修复,通过学习退化 and 修复后的壁画纹理之间的关系来实现修复过程的自动化[44]。

另一项研究提出了一种基于线条图稀疏编码的修复算法。Fei等人进一步改进了曲率扩散算法,采用了自适应策略以提高复原效果[45]。Mu等人设计了“Restore VR”系统,使用户能够

通过基于虚拟现实 (VR) 技术的洞窟数字导览,体验敦煌壁画的修复过程[46]。近年来,医学图像分析领域的研究也为壁画识别提供了宝贵的方法。类似地,Nazir等人采用了一种嵌入式聚类切片U-Net网络,并结合融合策略进行椎间盘分割和分类,在医学图像分割方面取得了很高的精度[47]。

这些模型突显了自适应卷积技术在处理复杂图像结构方面的有效性。

像YOLOv8这样的通用目标检测器在自然图像上取得了优异的性能。然而,当应用于古代壁画这一特殊领域时,它们仍然面临诸多瓶颈。古代壁画通常具有纤细的笔触、连续的曲线和高频图案。标准卷积对各向异性和非线性边界的敏感度不足,这会导致漏检和边界粘连[48]。不同的时期和技法会导致颜色、笔触和纹理统计特征的显著漂移,使得通用模型的固定卷积核和静态特征空间过拟合主流风格,从而导致对罕见或异质风格的错误分类[49]。古代壁画通常具有密集的元素和大的尺度变化,传统的特征金字塔不足以描绘极小的目标和长距离依赖关系,导致召回率有限[50]。局部和集合场景受限于低功耗/低内存设备,现有的高精度模型在参数、浮点运算次数和内存使用方面难以满足实时处理和成本效益的要求。现有的目标检测研究通过重建颈部和引入注意力机制,力求在参数量和平均精度均值 (mAP) 之间取得更好的平衡。基于YOLOv8,Brg-YOLO采用BiFPN+Ghost+RSE颈部和RSE骨干网络来抑制混叠特征,并在壁画检测中取得了mAP@0.5=84.6%和mAP@0.5:0.95=47.8%的成绩[51]。YOLOv10改进的“YOLO Mural”结合了高效RepGFPN和SimAM,仅使用265万个参数就实现了289帧/秒的帧率和mAP@0.5=63.7%的精度,并声称其参数规模低于YOLOv8/7等通用模型[52]。PLDS-YOLO 针对“脱落/断裂”分割,采用 PA-FPN+残差、CSPDarkNet+ShuffleNetV2 双骨干网络以及 SPD-Conv 增强的多尺度表示,在自建数据集上取得了 86.2% 的分割精度[53]。原生 YOLOv8 的固定 PAN/FPN 在对比度弱、目标小、纹理精细的壁画图像上存在信息传递不足和尺度对齐不良的问题。即使在相同或更低的计算预算下,这种局限性也会导致 mAP 性能下降和参数冗余。可以看出,传统的 YOLOv8在壁画检测特征融合方面计算开销较高,且跨阶段特征融合效率较低。这些问题使得通用检测器难以平衡类内召回率、类间可分性和推理效率。这种局限性在壁画元素的识别、元素级检索和知识组织方面尤为明显。

1.3 本文的研究

基于上述痛点,本文提出的DKR-YOLOv8旨在实现准确性、鲁棒性和效率之间的可部署平衡,并专门针对壁画场景设计。YOLOv8是YOLO系列的最新版本,代表了一种基于深度学习原理构建的端到端、紧凑型神经网络[54]。

本研究提出的 DKR-YOLOv8 是 YOLOv8 的改进版本,增强了YOLOv8 的特征提取网络。本研究提出了一种壁画图像目标识别算法 DKR-YOLOv8,旨在应对古代壁画所面临的独特挑战。我们构建了一个专门针对敦煌石窟壁画的数据集,涵盖了30 种常见的壁画艺术特征。严格的评估程序确保了该算法的有效性。

我们仅纳入高质量图像,并对其进行人工标注,以识别壁画中的关键元素。在原有YOLOv8架构的基础上,我们引入了DySnake Conv模块,该模块以其对细长拓扑结构的敏感性而闻名。这一改进显著提高了检测精度,尤其对于形状不规则和细长结构的壁画特征。我们的方法整合了三个关键组件:主动目标检测模块、三通道空间注意力机制以及来自Kernel Warehouse的动态卷积技术。这些创新减少了模型参数,缓解了过拟合,并降低了计算和内存需求。因此,该模型能够更准确、更可靠地检测壁画元素。我们将FPN结构替换为RE-FPN,这是一种更高效、更轻量级的残差特征融合金字塔结构。此外,我们还添加了SOD层,以提高模型检测各种尺寸物体(尤其是小型物体)的能力。

从学术价值和应用价值的角度来看,这项研究十分必要。DKR-YOLOv8 为非刚性、曲线主导、风格多样且存在劣化现象的艺术图像提供了一个可验证的结构化建模模型。它可以为壁画等文化遗产图像的检测和检索建立可复用的系统化设计。在多模态资源平台中,稳健高效的元素级检测是内容检索、语义编目、修复参考匹配以及检查和监控的基础能力,直接决定了资源调用效率和公共可访问性。因此,DKR-YOLOv8 不仅解决了通用检测器在壁画场景中的关键缺陷,而且为在低计算能力条件下实现可持续的数字保护提供了一条可行的技术路径。

同时,它也支持智能公共服务的发展。

2. 材料和步骤

2.1. YOLOv8 模型的架构

YOLOv8 是 Ultralytics 公开的单阶段目标检测算法的迭代版本,提供了五个变体:n、s、m、l 和 x,每个版本都增加了模型参数的数量[55]。与 YOLOv5 类似,YOLOv8 移除了特征提取、特征融合和预测模块。此外,YOLOv5 中的跨阶段部分网络(C3)被梯度更丰富的 C2f 模块所取代,从而增强了信息获取能力。采样阶段的体素结构从 PAN-FPN 中移除,提高了计算速度。此外,YOLOv8 中的无滑移检测器在精度方面优于传统的基于帧的方法,从而实现了更快的目标检测和识别。YOLOv8 的损失函数由分类损失和回归损失组成,其中分类损失使用二元交叉熵(BCE)损失计算,而回归损失使用分布式焦点损失和并集损失计算。两类损失均按预定义的系数加权,总损失通过加权组合计算得出,如图1所示。

尽管取得了这些进展,但仍然迫切需要一种能够有效整合这些技术的综合算法,以应对古代壁画图像所面临的独特挑战。核函数库(Kernel Warehouse)是一个可定制核函数的存储库,为开发此类算法提供了一条很有前景的途径。本文提出的方法旨在通过结合核函数库、YOLOv8、特征金字塔网络和蛇形卷积的优势,提高古代壁画图像元素识别和分类的准确性和鲁棒性。




图 1. YOLOv8 模型架构图。

2.2. 动态蛇形卷积

DySnake Conv于2023年提出,主要应用于图像分割和识别领域[56]。与传统卷积核相比,其优势在于增强的特征提取能力和处理非刚性物体形状的灵活性。在构建图像驱动知识图谱时,研究人员将DySnake卷积嵌入ResNet骨干网络,以提高对曲线图案和精细边界的检测能力,并通过对比和消融实验在自建数据集上验证了其有效性,结果表明曲线自适应感受野有助于复杂图案的结构提取[57]。在电力绝缘体缺陷的复杂纹理和细长形状的工业视觉场景中,ORAL-YOLOv8将DySnakeConv与C2f相结合。借助轻量级检测头和优化的融合颈,参数量和计算量分别减少了约27%和38%,平均精度均值(mAP)提高了1.7% [58]。这表明,这种卷积可以增强对细窄边界和复杂纹理的表示,同时保持实时性能。

在此基础上,我们专门针对识别和预测古代壁画图像中复杂线条和图案这一复杂任务,定制了 DySnake Conv 层。DySnake Conv 核的灵活性使其能够有效地学习目标的复杂几何特征。通过使用一组受限的偏移量作为学习参数,该模型可以动态地识别特征提取的最佳位置。这确保了即使在存在显著形变的情况下,检测区域也能保持稳定。如图2 所示,拓扑结构经过微调,能够捕捉壁画图像中固有的细微线条和艺术细节。这种改进使得对古代壁画的分析更加准确和全面,从而使深度学习网络能够以更高的精度提取局部信息。蓝色箭头表示各阶段/分支之间的数据流。蓝色方块标记参考元素(核心 E),其采样位置在学习到的偏移量前后均会被跟踪。




图 2. DSConv 的结构。

在二维图像平面中,我们使用连续坐标 (α, β) 来表示水平和垂直位置,其中整数值对应于像素中心;卷积核或采样路径上的第 t 个采样位置记为 $K_t = (\alpha_t, \beta_t)$ 。沿水平和垂直方向的离散步长索引分别记为 i 和 j , 步长 $c \in \mathbb{Z}^+$ 。在 DySnake Conv 中,每一步的形变偏移量为 $\Delta \alpha_t, \Delta \beta_t \in \mathbb{R}$,这些是训练过程中按时间顺序累积的可学习参数。当采样位置不在整数网格点上时,我们使用双线性插值:设输入特征图在整数网格点 (α) 处的值在连续位置 $K = (\alpha, \beta)$ 处为 $X(\alpha, \beta) = \sum_{(\alpha', \beta') \in N(\alpha, \beta)} B(\alpha, \beta) X(\alpha', \beta')$, 其中 $N(\alpha, \beta)$ 是用于插值的整数邻域集合。标准情况下为四个邻域。在实现中可选择将其约束为以 K 为中心的 $(2r+1) \times (2r+1)$ 窗口。插值核 B 分解为两个一维核, $B = b(\alpha, \alpha') b(\beta, \beta')$ 。在控制法线带宽的情况下,我们将二维可变形覆盖半径设置为 $r = 4$, 对应于 9×9 的局部窗口。在描述传统的刚性卷积 $'b'$ 为 $X[\alpha', \beta']$ 然后是插值核时,我们假设一个 3×3 的网格,其相对偏移集为 $\{(-1, -1), \dots, (+1, +1)\}$ 。 $'b'$ 为 $(a, b) \times [a', b']$ 。

$'b(\beta, \beta')$, 其中 $b(u, u') = \max(0, 1 - |u - u'|)$ 。为了获得足够的切向

传统的 3×3 和 2D 卷积核 K 的表达式如下:

$$K = \{(\alpha - 1, \beta - 1), (\alpha - 1, \beta), \dots, (\alpha + 1, \beta + 1)\} \quad (1)$$

受可变形卷积的启发,我们引入形变偏移量 Δ 来增强卷积核的灵活性,使其能够聚焦于目标的复杂几何特征。然而,如果允许模型自由学习形变偏移量,感受野可能会偏离目标,尤其是在处理细长结构时。为了解决这个问题并保持注意力机制的连续性,我们采用迭代方法来确定每个待处理目标的后续位置。这种迭代过程确保感知场始终聚焦于目标,防止因较大的形变偏移而导致的过度扩展。

$$K_{i+c} = (\alpha_{i+c}, \beta_{i+c}) = \alpha_i + c, \beta_i + \sum \Delta \beta_i + c \quad (2)$$

当水平方向推进 c 个步长时, α 以整数步长更新为 $\alpha_i + c$,从而确保沿 x 轴方向的“前进速度”稳定且可控; β 通过累积 $\Delta \beta_t$ 在亚像素级别进行细化,使路径能够沿着真实曲线逐渐弯曲。求和范围 $t = i + 1$ 到 $i + c$ 表明这不是一次跳跃,而是 c 个小法线偏移量的逐步累积,这既保持了连续性,又便于在每个子步长施加幅度约束。

DSConv沿x轴的变形规则如下:

$$K_{i \pm c} = \begin{matrix} (a_{i+c}, \beta_{i+c}) = a_i + c, \beta_i + \sum_{j=c}^i \Delta \beta \\ (a_{i-c}, \beta_{i-c}) = a_i - c, \beta_i - \sum_{j=c}^i \Delta \beta \end{matrix} \quad (3)$$

沿y轴方向的变形规律如下:

$$K_{i \pm c} = \begin{matrix} j+c \ a_{j+c}, \beta_{j+c} = a_j + c, \beta_j + \sum \Delta \alpha, \beta_j + c \ j \\ j \ a_{j-c}, \beta_{j-c} = a_j - c, \beta_j - \sum \Delta \alpha, \beta_j - c \ j-c \end{matrix} \quad (4)$$

沿y轴推进时, β 以整数步长更新,而 α 仅通过累积的微调进行调整;这确保了无论目标的主方向是水平、垂直还是局部倾斜,核函数都采用切向整数步长结合常规微调的策略进行对齐。如果局部曲线更接近垂直轨迹,则 $\sum \Delta \alpha$ 承担主要的几何对齐任务;随着曲线方向的逐渐变化, $\Delta \alpha$ 和 $\Delta \beta$ 的相对大小在相邻步长之间平滑过渡,避免出现锯齿状(阶梯状)路径。

使用双线性插值时,偏移量 Δ 通常以分数形式表示。过程如下:

$$K = \sum_K B_{K'}', K \cdot K' \quad (5)$$

双线性插值核用 B 表示,所有列出的积分。两个一维核构成双线性插值核。空间坐标用 K 插值核表示:

$$B_{K,K'}' = b_{K\alpha}, K'_{\alpha} \cdot b_{K\beta}, K'_{\beta} \quad (6)$$

DSConv是一种基于形变的二维变换过程,覆盖 9×9 的区域,能够增强对关键特征的感知。这对于壁画检测尤为有利,因为壁画检测涉及远距离、小型且细长的目标。通过在形变过程中覆盖 9×9 的范围,DSConv扩展了模型的感受野,提高了关键特征的检测能力,并为精确识别奠定了基础。动态蛇形卷积的引入允许自适应地调整卷积核的形状,从而能够精确地捕捉图像中的局部特征和结构信息。这种方法使复杂图像的处理更加人性化,从而提高了特征提取能力和鲁棒性。

通过这种方法,每个待处理目标的下一个位置按顺序选择,从而确保聚焦的连续性。随后,应用常规卷积。动态蛇形卷积通过累积偏移值来确保卷积核修改的连续性。这种设计允许灵活选择感受野,而不会过度分散,从而对细长目标保持更精确、更稳定的聚焦。此外,双线性插值保证了卷积过程的平滑性和精度,进一步提高了卷积运算的效率。在DSConv模块中,常规卷积与动态蛇形卷积的结合,既保留了传统卷积的稳定性和效率,又引入了动态蛇形卷积的灵活性和适应性。

壁画中的线性图案大多细长,具有连续的曲率和平滑的局部方向,但整体变形显著。它们还叠加了……

长期存放会导致诸如开裂、粉末脱落、污渍和光照不均等劣化因素。DySnake Conv 利用受限且迭代的位移参数生成“蛇形”采样路径。本质上,它将卷积核从刚性网格转换为适应曲线的采样带,通过不断累积位移,确保相邻位置的卷积核元素具有大致相同的切向方向和有限的法向振荡,从而将感受野沿图案方向拉伸成一个狭窄的条状区域。

这显著降低了传统可变形卷积在处理细长目标时出现的感受野漂移和能量泄漏,避免了目标结构中受损裂纹、随机粒子或笔触噪声的吸收。DySnake Conv 每一步的偏移量取决于前一步的位置和当前的局部几何形状,确保采样点在长距离变形下仍沿真实的结构主方向移动。振幅限制和连续性惩罚抑制了对背景中强纹理的过度依赖,从根本上降低了细长结构被背景“拖走”的风险。结合 9×9 的二维变形覆盖区域,该网络能够在保证窄法向带的同时获得足够的切向上下文信息,并利用这些信息填充粉末损失和断裂造成的小间隙,从而实现对“缺失笔触和断线”的稳健连接;这对于壁画中常见的长距离、断续线条尤为重要。在网络层次结构中,DySnake Conv 和传统卷积以多层串行/并行方式组合,形成“纹理几何”双通道互补性:传统卷积保留纹理线索,如颜料颗粒、笔触纹理和颜色渐变,而 DySnake Conv 则专注于提取曲线骨架和局部方向。

2.3. 核仓库动态卷积

动态轧制研究了一种由n个静态轧制核线性混合物构成的混合轧制核,通过对其样本相关关注度进行加权,与普通轧制相比,展现出优异的性能[59]。然而,以往的设计存在参数效率问题:它们将轧制参数的数量增加了n倍。

这个问题,加上优化的复杂性,导致动态体积领域的研究进展不足,因此无法使用更大的 n 值 (例如, $n > 100$,而不是传统的 $n < 10$)来突破性能极限。

内核仓库是动态包络的扩展版本,能够在参数效率和表示能力之间取得良好的平衡。其核心思想是重新诠释与动态卷积相关的基本术语“组装卷积核”和“卷积核”,重点在于大幅增加核的数量,同时降低其维度。内核仓库通过先进的内核划分和仓库共享,提高了同一层内以及连续层之间体积参数的依赖性。

具体来说,在任何卷积神经网络 (ConvNet)的体积层上,核仓库 (Kernel Warehouse)将静态核分割成 m 个维度相同的互不兼容的核。然后,它基于一个预定义的“仓库”(其中包含 n 个核,例如 $n = 108$),计算每个核的线性混合。该“仓库”也被几个相邻的体积层共享。最后,它按顺序组装这 m 个混合,在满足必要参数预算的同时,提供了更高的自由度。作者还开发了一种新的注意力函数,以辅助学习过程中将注意力集中到聚类核上。ConvBERT 使用基于跨度的核仓库动态卷积替换了部分全局注意力头,这降低了训练成本和参数规模,同时在 GLUE 数据集上优于同级模型,证明了根据输入自适应核的机制的有效性。

能够有效地捕获局部依赖性[60]。MAGIC通过多维聚合和核重新计算重建了核仓库动态卷积,在多个基准测试中系统性地优于传统的卷积和现有的动态卷积,证明了其对形变和多尺度结构的更强适应性[61]。

动态卷积是一种利用输入相关的注意力机制来学习 n 个静态卷积核的线性组合的方法。该方法在性能上优于标准卷积。然而,它会导致卷积参数数量增加 n 倍,因此在参数方面效率较低。

由于研究进展不足,研究人员难以探索 $n > 100$ 的情况,而 $n > 100$ 远大于常见的 $n < 10$ 的情况。这种探索对于在保持参数效率的同时提升动态卷积的性能边界至关重要。本文提出了一种名为 Kernel Warehouse 的解决方案来弥补这一空白。Kernel Warehouse 是动态卷积的更完善版本,它重新定义了“卷积核”、“卷积核组装”和“注意力函数”等基本概念。其原理是利用卷积神经网络 (ConvNet) 同一层内以及相邻层之间的卷积参数依赖关系。我们通过使用不同的 ConvNet 拓扑结构,在 ImageNet 和 MS-COCO 数据集上验证了 Kernel Warehouse 的有效性。Kernel Warehouse 可以应用于 Vision Transformer,在减小模型核心尺寸的同时,还能提高模型的精度。例如, Kernel Warehouse ($n = 4$) 在 ResNet18|MobileNetV2|DeiT-Tiny 骨干网上实现了 5.61%|3.90%|4.38% 的绝对 top-1 准确率提升,而 Kernel Warehouse ($n = 1/4$) 在 ResNet18 骨干网上实现了 2.29% 的提升,同时将模型大小减少了 65.10%。

内核仓库提供了一个用户友好的界面,使用户能够根据自身需求和限制轻松搜索、筛选和比较不同的内核。这涵盖了内核大小、步长、填充和空洞等因素,使用户能够快速找到最适合其应用的内核。内核仓库的示意图如图 3 所示。

核仓库的另一个关键特性是其高效管理大规模图像数据集的能力[62]。它集成了一个先进的数据管理系统,确保核函数的有效存储和检索,从而显著降低了特征提取的计算成本[63]。这一能力使我们的系统能够高效处理海量的古代壁画图像,同时又不影响识别和分类的准确性。核仓库与我们方法的其他组件 (例如特征金字塔网络和蛇形卷积)无缝集成。这些组件之间的协同作用提升了我们系统的整体性能,从而提高了古代壁画元素识别和分类的准确性和效率。

自适应核仓库 (KW)的设计逻辑与壁画目标检测的实际难点高度契合,从而解释了其“更适用”的机制:壁画图像通常呈现出复杂且连续的线性图案、极其庞大的装饰单元、严重的退化噪声 (粉末脱落、裂缝、污渍、反射和光照不均匀),以及特定区域在颜色、材质和纹理上的差异。这就要求特征提取能够平衡空间各向异性、跨尺度鲁棒性和参数可控性。KW本质上提供了一个“低维参数和高维形状的组装库”:无需对参数数量进行非线性扩展,该模型即可从大量形态各异的基核族 (包括具有不同方向、频带、孔隙率和长宽比的子核)中,自适应地为每个空间位置和尺度级别选择并组装最合适的激励模板。对于精细且长条状的壁画,KW尤其适用。

KW 的线和卷图案、方向选择性和可控孔率使得感受野在切向积分和法向抑制方面更加敏感,从而减少了常见动态卷积容易发生的漂移和能量泄漏。

对于对比度较弱、断裂和褪色的区域,跨层共享的核仓库使得相邻层能够在相似结构中复用相同的基础核组合,从而沿着曲线形成稳定的“跟踪”,在噪声背景下保持一致的响应,并实现断裂笔触的跨尺度桥接。与传统的“n折参数”动态卷积不同,KW通过核分解和共享仓库显著提高了参数效率,使得在预算范围内可以显著扩展n值,从统计学习的角度提高了模型的覆盖率和先验多样性,并降低了因数据量有限而导致的过拟合风险。如果结合结构张量或方向一致性正则化,自定义注意力函数可以抑制对高频噪声和斑驳纹理的错误关注,增强对具有平滑曲率和连续方向的真实模式的偏好。




图 3.内核仓库动态卷积方法的示意图。

在所有实验中,我们采用预定义的核仓库 (Kernel Warehouse,KW)作为动态卷积后端。默认大小为 $N = 64$,包含 $3 \times 3/5 \times 5$ 的卷积核和可分离的 $1 \times k/k \times 1$ 的卷积核 ($k = 3, 5$),空洞率分别为 $[1, 2, 3]$;采用深度可分离设计和低秩分解来控制参数和浮点运算次数 (FLOPs)。三个相邻的卷积层共享同一个核仓库,每个卷积层将通道划分为 $m = 4$ 个组,以便进行组内选择。KW 注意力分支使用轻量级上下文编码器,并结合 softmax/Top-k 归一化,从共享的核仓库中为每个通道组线性选择并组合若干子卷积核。

然后,前向传播通过“先混合后卷积”或“先卷积后加权”的方式进行。这样,它既保留了动态卷积的内容自适应性,又通过共享和分解显著提高了参数效率和可部署性。

2.4. 轻量级残差特征金字塔网络

基于YOLOv8的古代壁画图像元素识别与分类方法很大程度上依赖于特征金字塔网络 (FPN)架构。

针对传统目标检测模型的局限性, FPN架构提出了一种改进的模型,这些模型通常难以准确检测图像中不同尺度的目标[64]。FPN采用自顶向下的方法,并结合横向连接,能够从输入图像中提取多尺度特征。这种结构对于提升YOLOv8模型分析古代壁画的有效性至关重要。FPN通过构建不同分辨率的特征图金字塔,使模型能够同时捕捉壁画图像中的高层语义信息和细粒度细节。这种多尺度特征表示对于准确检测和分类古代壁画复杂图案中的元素至关重要。

FPN架构由多个阶段组成,每个阶段负责提取不同尺度的特征。初始阶段侧重于捕捉低级特征,例如边缘和纹理,而后续阶段则捕捉高级特征,包括物体形状和图案。这些阶段之间的横向连接促进了不同尺度信息的融合,从而形成一个全面的特征表示,非常适合用于壁画图像元素的识别和分类。此外, FPN架构具有高度可定制性,可以与YOLOv8模型的其他组件(例如Snake卷积模块)无缝集成。这种集成确保了从壁画图像中高效提取特征,显著提升了识别和分类算法的整体性能。通过利用FPN架构的优势,基于YOLOv8的方法能够可靠地识别和分类古代壁画图像中的各种元素,从而有助于更深入地理解这些珍贵的文化遗产。

$$L_{\text{输出}} = \sum_{u=1}^{\text{在}} \sum_p \left(\frac{C}{u(p)} \right)^2 - C \frac{u(p)}{2} \quad (7)$$

$$L_{\text{输出}} = \sum_{b=1}^B \sum_p \left(\frac{C}{b(p)} \right)^2 - C \frac{b(p)}{2} \quad (8)$$

深度神经网络中的浅层特征包含丰富的空间信息和精细的细节,但通常伴有噪声。随着网络深度的增加,特征中的语义内容增加,而空间信息和细微细节信息逐渐减少,噪声也随之降低。本研究利用特征金字塔网络(FPN)来增强YOLOv8模型中颈部架构的效率,从而促进特征的融合。目标是实现不同深度特征之间的流动和交互。此外,我们提出了一种新方法来解决FPN框架内高层特征因通道变换而导致的空间信息丢失这一核心问题。该方法通过在模型设计中引入残差特征增强(RFA)单元来实现。RFA模块利用残差分支注入来自不同空间位置的上下文信息,从而改善高层特征的特征表示。此外,我们还在FPN的每个分支中集成了一个轻量级的注意力机制——高效通道注意力(ECA)模块,以进一步减少空间信息的损失。如图4所示,通过对每个特征图应用 3×3 深度卷积(DW Conv)操作,开发了一种轻量级残差特征融合金字塔结构,称为RE-FPN。




图 4.轻量级残差特征融合的金字塔结构。

该方法的主要目标是增强特征交互、减少空间信息损失,并保持YOLOv8算法特征网络(FPN)的轻量级特性。通过鼓励不同网络层级的特征移动和通信, RE-FPN结构利用残差分支引入上下文信息,强化了高层特征表示,从而解决了高层特征通道中空间信息损失的问题。此外,在每个FPN分支中集成简单的注意力机制可以进一步减少空间信息损失。对每个特征图应用 3×3 深度可分离卷积构建RE-FPN结构,在保持网络轻量级特性的同时,兼顾了特征交互和空间信息保留的优势。因此,RE-FPN在最大限度减少空间信息损失的情况下增强了特征交互和表示,从而提升了YOLOv8算法在目标检测任务中的整体性能。

为了解决算法各阶段特征融合效率低下的问题,本文在颈部位置引入了FPN结构,以增强各阶段的特征循环和信息交互。选取MobileNet V2网络的第2、4、6和7层的输出作为FPN结构的输入特征,分别记为C2、C3、C4和C5,其输入特征图大小分别设置为 $38 \times 38 \times 32$ 、 $19 \times 19 \times 96$ 、 $10 \times 10 \times 320$ 和 $10 \times 10 \times 1280$ 。为了进一步提升模型的轻量级特性,利用 1×1 卷积将FPN结构各阶段的通道数从256减少到160,从而最小化模型参数和计算量。此外,FPN结构中的 3×3 标准卷积被替换为 3×3 深度可分离卷积,进一步减小了模型的体积。在特征层面,FPN结构将强语义特征从高层向下传递,通过特征融合提升目标检测性能。然而,在特征融合过程中,低层特征受益于高层特征的强语义信息,而金字塔顶端的特征则因通道减少而损失信息。为了解决这个问题,本文采用自适应池化来提取不同的上下文信息,从而减少特征金字塔中最高层特征的信息损失。通过引入残差特征增强(RFA)模块,残差分支从不同的空间位置注入上下文信息,以更简洁的方式增强高层特征的表达,并降低计算需求。

古代壁画一方面呈现出“极小尺度、纤细连续的线条以及低对比度”的图案和笔触,另一方面又伴随着“高分辨率成像、不均匀光照以及材料老化造成的斑驳噪声和裂纹”。这要求检测网络不仅要在跨尺度语义聚合中保留微小的空间细节,还要在可控的计算预算下支持更高的输入分辨率和更密集的滑动窗口推理。RE-FPN基于FPN的自顶向下和横向融合,并用 1×1 通道压缩和 3×3 深度可分离卷积代替了标准卷积,从而显著减少了参数和浮点运算次数,使得在不增加内存使用量和延迟的情况下提高输入分辨率成为可能。这对于区分壁画中亚像素级的线条和微小图案至关重要。针对FPN通道变换后高层特征空间信息丢失的问题,RE-FPN引入了残差特征增强(RFA)单元,通过残差分支注入多尺度上下文信息:自适应池化聚合来自不同感受野的结构背景和组成语义,然后将其重新注入到压缩后的高层特征中,在保持强语义的同时恢复空间线索,从而提高低对比度、褪色和断裂等线性目标的连续性和可追溯性,并减少因高层语义“过度平滑”而导致的细节覆盖和间隙遗漏。RE-FPN的轻量级设计释放了计算能力和内存资源,使其能够与现有的几何对齐和组装内核机制(例如DySnake Conv和Kernel Warehouse)协同工作:前者在各向异性感受野内执行沿线细化采样,后者在多尺度分支上提供内容自适应的方向/孔洞/宽高比基内核。RE-FPN确保这些几何形状和模板先验以低损耗的方式跨层和尺度传播和融合,最终在高分辨率、远距离上下文和壁画中各种材料噪声的真实条件下,实现检测召回率、定位精度和推理效率的平衡。

3. 实验及结果3.1. 硬件和软件配置

本研究的实验平台如表1所示。同时,该模型在训练阶段使用统一的超参数,其中优化器为随机梯度下降(SGD),初始学习率为0.01,权重下降为0.0005,训练轮数为200 epoch。

表1.实验平台。

物品	设置随机梯
优化器	度下降 (SGD) (Nesterov = True) ,动量 0.937,权重衰减 5×10^{-4} 0.01 (SGD),余弦衰减至 LR 的 1%;
初始LR	预热 3 个 epoch (线性) ;200 32 张图像/GPU (RTX 3090 Ti,24 GB);640 × 640 (训练集和验证集) ,
纪元	信箱
批量大小	模式缩放,保持宽高比;像素范围 [0, 1];无通道均值/标准差偏
输入大小	移;水平翻转 0.5 ;缩放 [0.5, 1.5];平移 0.1 ;剪切 0.0 ;角度 0 ;HSV(h = 0.015, s = 0.7, v = 0.4);
正常化	基线行 (Model1) 无马赛克/混合。
增强 (训练)	
模型精度	FP16 混合精度 (AMP)
损失	Box:CIoU + DFL (Ultralytics 默认值) ;Cls/Obj:BCE (标签平滑度 0.0)
锚固设置	无锚点 (YOLOv8 头部)

表1.续

物品	设置与类
NMS 评估指标 数据集拆分 课程 硬件/环境	别无关的 NMS,IoU 0.60;置信阈值 0.25 主要 :mAP@0.5 (IoU = 0.5)表2-4中报 告的值分层 50/50 训练/验证集（保持每个类别的比例） 20（见表2） Windows 11（64 位）;Python 3.8;PyTorch 1.10;i9-14900K;RTX 3090 Ti

表 2.壁画识别类型。

类别	姓名	介绍	套
人文景观	粉丝	这些扇子不仅具有实用价值,而且还蕴含着丰富的文化意义,体现了古代工匠的艺术成就。	85
	金银花	在敦煌石窟的边缘,如楼台、平瓦、墙层、拱门、壁龛和华盖等处,都以金银花图案作为边缘装饰。	40
	火焰	敦煌壁画中的火焰图案常以背光、光晕等装饰纹样出现,象征着光明、神圣和力量。在佛像、菩萨等宗教人物周围,火焰纹样的使用更能凸显其神圣庄严之感。	35
	鸟	鸟类是敦煌壁画中常见的自然元素,它们为壁画增添了生动的生命力和自然之美。	28
	管道	琵琶作为一种重要的古代弹拨乐器,经常出现在敦煌壁画中,尤其是在音乐和舞蹈场景中。	62
	Konghou	孔侯也是一种古代弹拨乐器,是敦煌壁画中音乐和舞蹈场景的重要组成部分。	34
	树	敦煌壁画中的树木,如松树和柏树,常常作为背景或装饰元素出现。它们不仅为壁画增添自然美感,也象征着长寿、坚韧和其他美德。	38
	亭	亭台楼阁是敦煌壁画中常见的建筑意象。 这些建筑图像不仅展现了古代建筑的艺术风格和技术水平,也反映了当时的文化生活和审美追求。	76
	马匹	敦煌壁画中的马匹常以交通工具或象征物的形式出现,例如战马和马车。这些马的形象充满活力和力量,反映了古代社会的军事实力和生活方式。	72
	车辆	敦煌壁画中常见的交通工具形象还包括马车和牛车。这些交通工具不仅展现了古代社会的交通状况和技术水平,也反映了人们的生活方式和文化习俗。	49
生产性劳动	船	虽然敦煌壁画中船只不如陆路交通工具常见,但它们确实出现在反映水上生活的场景中。这些船只反映了古代社会的水路运输状况和水文化特征。	22
	牛	敦煌壁画中的牛经常以耕作或交通工具的形象出现,例如耕作的牛和牛拉车。这些牛的形象朴实无华,与古代社会的农耕生活紧密相连。	32

表2.续			
类别	姓名	介绍	套
宗教 活动	鹿	敦煌壁画中的鹿通常象征着善良和美丽。一些故事画或装饰图案中,鹿的形象增添了一种意境。为壁画增添了活力与和谐。	52
	云	敦煌壁画中的云朵常常作为背景元素出现。它们或许轻盈优雅,或许厚重稳固,从而创造出不同的效果。壁画的气氛和情感基调。云的运用也象征着美好的祝愿,例如好运和圆满。	72
	阿拉格井	藻井是重要的建筑装饰。位于天花板中央,它们装饰着精美的图案,颜色。它们不仅具有装饰作用,而且还象征着……驱除邪灵,保护建筑物。	126
	树冠	敦煌壁画中的华盖或光环可能看起来像车头灯或背光,覆盖着佛像等宗教人物和菩萨,象征着神圣和高贵。	43
	莲花	莲花是敦煌壁画中常见的图案。象征着纯洁、优雅和好运。下方或周围宗教人物,例如佛陀和菩萨。	24
	壁龛门楣	敦煌的壁龛过梁是壁龛上方的装饰性构件。壁画,通常绘有精美的图案和色彩。这些小众艺术作品门楣上的图案不仅具有装饰作用,而且还反映了……古代工匠的艺术成就和审美追求。	10
	宝塔	敦煌的宝塔是重要的宗教建筑象征。壁画。这些宝塔图像不仅展现了艺术风格,而且古代建筑的技术水平,同时也反映了其传播和佛教文化的影响。	66
	僧侣杖	僧侣杖是佛教僧侣常用的工具。并且可能作为敦煌壁画中僧侣人物的配饰出现。作为佛教文化的重要象征,无疑增添了……壁画充满了浓厚的宗教氛围。	29

表 3.从识别准确率和性能方面对网络模型进行了比较。

模拟	百分比	利率/%	mAP@0.5	F1/%	第一人识别准确率
YOLOv3-tiny	79.2	79.6	81.4	78.8	557
YOLOv4-tiny	81.4	74.8	82.6	78.1	229
YOLOv5n	80.1	75.2	82.3	77.2	326
YOLOv7-tiny	81.3	73.8	81.2	76.9	354
YOLOv8	78.3	75.4	80.6	77.2	526
DKR-YOLOv8	82.0	80.9	85.7	80.5	592

表 4.网络模型消融实验。

基于模型的模型		DSC KW RE-FPN P/%		R/% mAP@0.5 F1/%				第一人识别准确率	FLOPs (G)
模型1	YOLOv8			78.3	75.4	80.6	77.2	526	28.41
模型2	YOLOv8		✓	81.6	73.9	80.8	78.8	868	27.74
型号3	YOLOv8		✓	77.3	74.8	81.3	78.7	640	26.93
型号4	YOLOv8	✓		84.0	83.2	82.1	84.5	474	14.17
5型	YOLOv8		✓	80.9	74.8	82.0	75.9	669	27.84
6型	YOLOv8	✓	✓	80.6	79.8	86.2	76.5	539	13.43
7 型	YOLOv8	✓		80.6	81.4	78.9	84.3	524	15.08
8型	YOLOv8	✓	✓	82.0	80.9	85.7	80.5	592	16.01

为了确保结果的准确性和可靠性,我们精心设计了基于YOLOv8的核仓库、特征金字塔网络 (FPN) 和蛇形卷积YOLO (DKR-YOLO)古代壁画图像元素检测与分类方法的实验装置。图像预处理用于去除可能影响算法性能的噪声、伪影和失真。

内核仓库模块结合了预定义和自定义设计的内核函数构建而成,旨在捕捉古代壁画元素的独特特征。特征金字塔网络利用一系列空洞卷积层,能够提取多尺度特征。蛇形卷积模块集成到YOLOv8架构中,以增强对不规则形状物体 (例如历史壁画中复杂的图案和主题)的检测和分类能力。

基于数据集中图像的分布情况,我们采用了数据增强技术。该技术有助于网络学习更广泛的特征,从而提升其在未见过的数据上的性能,增强泛化能力,同时降低过拟合的风险。此外,数据增强还起到正则化的作用,促进训练过程中更稳定的收敛,尤其适用于复杂的模型结构或不均匀的数据分布。

为了增强数据集的多样性和鲁棒性,我们生成了10种不同的随机组合来扩充图像集,并相应地调整了图像的边界框。每张图像都通过随机选择10种内容类型中的一种进行扩充。图5展示了每个扩充过程生成的图像示例。




图 5. 10 种增强方法对示例照片的处理结果。

为了提升图像质量,可以使用特定的参数和方法应用各种图像处理操作。直方图均衡化 (HE) 通过均衡亮度直方图来提高图像对比度。自适应直方图均衡化 (AHE) 进一步增强局部对比度,而对比度受限自适应直方图均衡化 (CLAHE) 则在提高对比度的同时限制对比度,以防止噪声放大。腐蚀和膨胀操作使用半径为 5 的圆盘状结构元素来消除微小噪声或填充细小缝隙。类似地,开运算和闭运算也使用圆盘状结构元素来去除小物体和封闭小孔。均值滤波用于平滑处理,应用 5×5 滤波器来降低噪声。中值滤波使用 5×5 中值滤波器,可以有效地去除脉冲噪声。高斯平滑使用 5×5 高斯滤波器来降低高频噪声。梯度滤波用于边缘检测和细节增强。平移滤波操作将图像向左平移一个像素,以模拟图像平移。锐化可以增强图像边缘和细节。高斯金字塔方法用于下采样,而拉普拉斯算子则用于其他方法。

金字塔算法通过从下采样图像中减去上采样图像来实现下采样。傅里叶变换用于将图像转换到频域,采用对数函数和归一化频谱。傅里叶低通滤波和高通滤波分别使用高斯滤波器,用于保留图像的低频和低频分量。

3.2. 鉴定结果敦煌壁画作

为中国古代石窟艺术的代表作,起源于十六国时期,已有1500多年的历史。

这些壁画展现了不同历史时期的多元风格,使其成为世界最重要的艺术瑰宝之一。敦煌壁画的图案和纹饰丰富多样,常见于人字纹、平梁、沉箱等建筑元素,以及壁龛门楣、华盖、莲花座、光环等佛教器物的装饰特征中。此外,条形纹饰也常用于划分和装饰建筑及壁画空间。其设计涵盖了花卉、植物、云朵、飞鸟、野兽、火焰、几何图形、金灯等众多题材,这些元素充满艺术气息,蕴含着深刻的象征意义。它们不仅体现了高雅的审美趣味,也创造了独特的空间感知,具有重要的艺术、美学和学术价值。

本研究使用了《敦煌壁画全集》[10]中的图像。这些壁画包含多种图像和风格。图像数据集的DOI为10.57967/hf/4516(网址为<https://huggingface.co/datasets/jinmuxige/>)。敦煌(访问日期:2025年2月16日)。数据集被平均划分,50%用于验证集,50%用于训练集。我们选取了其中一部分图案进行实验,结果见表2。为了确保数据集的代表性和可复现性,我们从敦煌莫高窟(位于中国甘肃)选取图像。该壁画集涵盖了十六国时期至元代,并使用了公开的《敦煌壁画全集》。该语料库涵盖了主要的风格阶段和图像类型(建筑装饰、佛教法器、动植物图案和劳动场景),共包含20个对象类别和995个标注实例(呈长尾分布:每个类别10-126个实例,如表2所示;例如,壁龛门楣:10个实例,船:22个实例,水井:126个实例)。我们采用分层50/50的训练集/验证集划分,以保持每个类别的比例,并维持表2中三个主题组之间的平衡。所有标注均经过双重审核,并在壁画保护专家的指导下达成共识,以统一类别边界并确保与时期无关的一致性。该协议明确规定了我们的来源(地点、时期范围)、规模(20个类别;995个实例)和标签标准(复杂细节和劣化的定义),从而支持了关于敦煌风格多样性的概括性主张。

本研究的语料库具有显著的长尾分布。如果采用常见的70/30或80/20划分,验证集中最小类别的正例数量将分别减少到约10个,这将导致难以形成稳定且可解释的类别PR曲线和AP评估,也无法可靠地估计检测阈值和不确定性校准。50/50的分配至少可以确保少数类别在验证集中仍然有多个正例,从而更真实地测试模型,并减少因验证样本过少而导致的评估方差和结论的偶然性。

本文采用改进的DKR-YOLO模型识别敦煌莫高窟壁画照片中的20类符号。图6展示了一些示例。

壁画识别的内容。如图7 所示,升级后的 DKR-YOLO模型能够有效识别包含多个目标的壁画。它还可以检测出部分被遮盖或使用高斯模糊修改过的壁画。




图 6.部分壁画内容识别的目标对象显示。




图 7.展示了使用该模型识别部分壁画的结果。

从图6和图7所示的识别结果可以看出,改进后的DKR-YOLO模型不仅能够在复杂场景下实现多目标检测,而且即使图像失真或模糊,也能保持较高的鲁棒性。在处理大规模壁画遗产数字化时,自动化识别可以显著减少人工标注和分类的工作量,提高数据管理和学术研究的效率。该模型仍能有效检测部分遮挡或损坏的图像,为文物劣化监测和残缺图像修复提供可行的技术支持。通过系统地识别壁画中的建筑图案、佛教纹饰、动植物和几何符号等元素,该模型有助于揭示不同历史时期的风格演变和审美取向,从而为考古、艺术史和文物保护研究提供可量化的数据支持。

3.3. Mural 数据集的测试结果

为了有效地突出改进的 DKR-YOLOv8 模型的准确性和性能,表3给出了DKR-YOLOv8 模型与其他模型的识别准确性和性能的比较实验。

表3显示,DKR-YOLOv8在精确率、召回率、平均绝对平均概率 (mAP)、F1值和推理速度 (FPS)五个指标上均取得了最佳结果,实现了准确率、召回率和速度的“三赢”。与相同数据条件下的基线YOLOv8相比,DKR-YOLOv8的精确率从78.3%提高到82.0%,召回率从75.4%提高到80.9%,mAP从80.6%提高到85.7%,F1值从77.2%提高到80.5%,帧率从526提高到592。

与各指标的最佳“轻量级基线”相比,DKR-YOLOv8 依然领先:其精确率比 YOLOv4-tiny 高 0.6 个百分点,召回率比 YOLOv3-tiny 高 1.3 个百分点,mAP 比 YOLOv4-tiny 高 3.1 个百分点, F1 比 YOLOv3-tiny 高 1.7 个百分点,速度比 YOLOv3-tiny 快 35 帧。从检测显著性的角度来看,更高的召回率和 F1 值表明漏检“小而长、对比度弱、易碎”目标的概率更低,阈值也更稳定;mAP 的显著提升反映了在不同置信度阈值下分类和定位质量的整体增强;精确率的提高有效抑制了非结构化噪声引起的误报。

更重要的是,DKR-YOLOv8 在保持甚至提高帧率的同时,实现了全面的准确率提升,这表明 RE-FPN 的信息回填和轻量级设计、DySnake 的各向异性精细采样以及Kernel Warehouse 的内容自适应内核组装实现了互补:高层语义得到稳健传输而不会过度平滑,底层细节得到保留而不会过度噪声化,最终 DKR-YOLOv8 在相同的计算预算下处于各种方法的帕累托前沿,平衡了高吞吐量扫描和高质量识别,更好地满足了壁画场景的实时性能和准确率的双重要求。

3.4 消融实验为了评估升级

后的 DKR-YOLOv8 模型的效率,我们进行了一系列对比消融实验。共进行了八次消融实验,以确保模型性能评估的一致性,每次实验均采用相同的数据集、训练配置和方法。验证分析指标包括精确率、召回率、综合评价指标和平均精度均值 (mAP)。

表4的第一行展示了原始 YOLOv8 模型 (未采用任何数据增强技术)的训练结果。动态蛇形卷积的引入进一步提升了模型的性能。

将动态卷积 (DSC)、核仓库动态卷积或轻量级残差特征金字塔网络 (RE-FPN) 融入基线 YOLOv8 模型, 均能提升更新模型的检测率、准确率和计算效率。值得注意的是, DSC (而非核仓库) 使浮点运算次数 (FLOPs) 减少了约 50%。此外, 核仓库使平均平均精度 (mAP) 提高了 0.7%, DSC 提高了 1.5%, 而 RE-FPN 方法则使召回率降低了 1.5%。经过这些独立的算法改进后, 最终模型被命名为 DKR-YOLOv8。与原始 YOLOv8 相比, 该模型表现出显著的改进, 精确率提高了 3.7%, 召回率提高了 5.5%, F1 分数提高了 3.3%, mAP 提高了 5.1%。它还实现了 16.01 G FLOPs 的计算量 (比基线模型降低了 43.6%) 和 592 FPS 的帧率。总而言之, 增强型 DKR-YOLOv8 模型达到了 80.9% 的召回率和 85.7% 的 mAP。帧率的提升, 以及模型参数和计算量的减少, 显著提高了检测速度, 使其能够部署在移动和固定观测平台上。

浮点运算次数降低了 43.6%, 推理速度达到了 592 FPS, 这意味着在相同的预算和电源条件下, 超像素壁画镶嵌图可以以更高的输入分辨率进行处理, 并在边缘采用更密集的滑动窗口策略。这使得检测频率从“项目级”提升到“每日级”, 并支持在施工现场进行实时质量反馈和重新合成校正。同时, 更低的计算能力门槛使得资源有限的小型博物馆和地方文化遗产机构能够在 CPU 或入门级 GPU 设备上离线运行, 避免依赖外部网络和云平台, 满足文物图像的安全和隐私法规要求, 并降低长期运营成本。另一方面, mAP 提高 5.1%、准确率提高 3.7%、召回率提高 5.5% 以及 F1 分数提高 3.3% 的综合效应体现在修复和数字化编目链中: 漏检减少使得细微特征的空间分布图更加完整, 区域量化更加稳定, 有助于制定最小干预措施和流程; 误检减少减轻了人工审核的负担, 提高了批量处理的一致性, 使图像到语义标签再到目录信息的映射更具可追溯性和可验证性, 并能与 CIDOC 等标准化记录表格无缝衔接。此外, RE-FPN 和 ECA 保留的空间线索和显著性响应可作为可视化审核证据, 帮助非技术人员理解模型确定的来源, 增强跨团队协作和决策透明度。

3.5. Grad-CAM 模块分析

为了直观地呈现壁画上各组成部分的精细纹理增强效果, 我们采用 Grad-CAM 系列方法可视化检测网络的关键层, 并将热图叠加到典型的敦煌壁画样本上。图中颜色由蓝到绿到黄到红逐渐增强, 代表各组成部分贡献度的递增。

图8对比了原始 YOLOv8 和本文提出的 DKR-YOLOv8; 图8为基于模块的可视化图, 展示了引入 DySnake 卷积、核仓库和 RE-FPN 后激活分布的变化。所有样本均保持相同的输入大小和颜色映射, 以确保可比性。颜色从蓝色变为红色, 表示注意力水平从低到高逐渐增加。可以看出, 模型在目标对象及其判别结构处表现出显著更高的响应, 而在背景区域的响应较弱, 这与预测框的位置基本一致, 表明模型主要基于语义相关区域进行决策。热图是通过计算得到的。

对目标类别得分在最后一层卷积特征上的梯度进行加权求和,然后上采样到输入分辨率。这用于解释模型判别能力的依据和定位的合理性。




图 8.原始 YOLOv8 和本文中的 DKR-YOLOv8 热图。

原始YOLOv8的热图呈现出“大块高光”的趋势,尤其偏向于高对比度的大型结构,例如灯光背景、屋檐轮廓等;在复杂的烛台、交错图案和细如发丝的线条中,响应较为离散,边界模糊,容易被高层语义下采样产生的强响应所“淹没”。相比之下,图9中DKR-YOLOv8的热图则明显“更纤细、更精确”:高光区域沿细长曲线(例如卷轴、服装图案、屋檐角度等)呈带状连续分布,法线方向的带宽变窄,背景斑驳和风化噪声得到抑制;在低对比度的精细细节(例如马匹、人物的手部等)中,激活不再扩散到大片区域,而是集中在结构的主轴上,展现出对小型目标和精细边界的稳定捕捉能力。从“表面高光”到“线条高光/照明”的这种变化与我们对小目标召回率的定量结果以及mAP 的总体改进是一致的。

DySnake Conv的热图沿曲线切线方向形成细而连续的高光,能够平滑地穿过细微缺陷和断笔。法线能量集中,避免被壁裂纹或随机噪声牵拉。这表明用于曲线对齐的采样带有效地减少了接收域中的漂移和能量泄漏。Kernel Warehouse展现出明显的方向选择性:在同一图像块内,不同方向和孔隙率的内核被稀疏地激活,形成与图案主方向一致的分段响应,增强了跨尺度一致性,同时减少了背景随机纹理,展现了自适应模板组装能力。RE-FPN(带有残差特征增强)在融合后保留了P3的边缘和点状装饰,并通过多尺度上下文为P4/P5提供周围结构语义。高层语义不再“平滑”边界,上采样时的相位失配和高频混叠得到缓解,使跨尺度对齐更加鲁棒。总而言之,这组可视化结果不仅揭示了各个模块的划分和互补性:DySnake Conv 负责线条对齐和连续跟踪,Kernel Warehouse 负责根据方向和比例选择合适的表单模板,而 RE-FPN 则在轻量级预算下保持细节和稳定的融合;而且,它还与我们的定量改进形成了相互验证。

在 FLOPs 运算次数、延迟和像素吞吐量方面,支持了 DKR-YOLOv8 的结论。
在壁画场景中实现了“准确、稳定、高效”的可部署平衡。




图 9.不同算法模块的热图可视化。

3.6 模型方法对比实验

为了进一步论证 DKR-YOLOv8 不仅优于 YOLOv8 基线,而且也优于 YOLOv8 基线。但为了在以文化遗产为导向的环境中保持竞争力,我们设计了一种补充方案
评估涵盖了常用的轻量级检测器和像素级模型。
在保护流程中。在检测轨道上,我们添加了 NanoDet-Plus (1.5×)、 PP-PicoDet- LCNet (1.5×)、 EfficientDet-D0 和 MobileNetV3-SSD 作为参数高效的基线模型。
输入尺寸 (640 × 640) 和训练方案 (SGD,200 个 epoch,余弦函数)均匹配。
LR,批次 32)。这在相似的 FLOPs/延迟下建立了同类比较。在
分割跟踪 (通常用于条件映射)方面,我们引入了 U-Net (ResNet- 34 编码器)、DeepLabV3+
(MobileNetV3)和 SegFormer-B0 用于语义掩码,此外
针对示例掩码,我们提出了掩码 R-CNN (R50-FPN)。对比实验结果如下。
如下表5所示。

表 5.不同流行模型的对比实验结果。

模型	追踪	FLOPs (G)	百分比	R (%)	F1 (%)	mAP@0.5 (%)
DKR-YOLOv8	检测 检测 检	16.01	82.0	80.9	80.5	85.7
YOLOv8 (基线)	测 检测 检测	28.41	78.3	75.4	77.2	80.6
NanoDet-Plus (1.5倍)	检测 分割 分	3.9	79.0	73.8	76.3	78.7
PP-PicoDet-LCNet (1.5×)	割 分割 实例	2.7	78.5	72.6	75.4	77.9
EfficientDet-D0	分割	8.5	80.0	74.5	77.1	79.3
MobileNetV3-SSD U-Net		2.2	76.4	69.7	72.9	75.1
(R34编码器)		16.8	73.8	80.2	无 无	76.2
DeepLabV3+ (MV3)		5.4	74.9	79.0	无 78.6	76.5
SegFormer-B0 掩		8.9	77.3	80.5		78.3
模 R-CNN (R50-FPN)		44.7	81.0	76.4		80.1

从表格对比可以看出,DKR-YOLOv8在检测任务中取得了 P/R/F1/mAP@0.5 分别为 82.0/80.9/80.5/85.7 的成绩,这四项核心准确率指标在所有检测模型中均位列第一。同时,在计算成本方面,它比基线 YOLOv8 (28.41 G) 降低了 43.6%,体现了“高精度-中等计算成本”权衡的优势。与 NanoDet-Plus (3.9 G,mAP 78.7)、PP-PicoDet-LCNet (2.7 G,77.9)和 MobileNetV3-SSD (2.2 G,75.1)相比,DKR-YOLOv8 的 mAP 比它们高出 7.0-10.6 分,并且在召回率和 F1 值方面也显著领先。这表明, DySnake、RE-FPN 和 Kernel Warehouse 引入的几何对齐和多尺度增强技术,在捕获细长、低对比度的小目标时,相比“计算能力极低”的解决方案,带来了显著的识别优势。与 EfficientDet-D0 (8.5 G,mAP 79.3)相比,DKR-YOLOv8 仅需增加约 7.5 G 的计算能力,即可在 mAP 上提升 6.4 分,并获得更高的 P/R/F1 值,更接近实际应用所需的精度-稳定性平衡。表中的分割基线 (U-Net/DeepLabV3+/SegFormer-B0)基于掩模外部边界框的间接测量,提供了 P、R 和 mAP@0.5 值,因此 F1 值无法直接比较。即便如此,其最高mAP也仅为78.3 (SegFormer-B0),仍低于DKR-YOLOv8的85.7,这表明在以目标检测为中心的工作流程中,该方法在相同的输入和训练协议下具有更强的可用性。实例分割Mask R-CNN (44.7 G)在显著更高的计算开销下仅实现了80.1的mAP和78.6的F1,同样不及DKR-YOLOv8。

这进一步表明,在绝对准确性和计算效率的帕累托前沿位置上,在保持中低计算能力预算的情况下,该方法提供了最高的检测精度和更好的召回率/阈值稳定性,因此更适合资源受限但可靠性高的场景,例如数字保护和壁画编目。

在相同的输入 (640×640 ,批处理大小 = 1)下,DKR-YOLOv8 将 FLOPs 从 28.41 G 降低到 16.01 G (降低 43.6%),并将 FPS 从 526 提升到 592 (提升 12.55%),同时将端到端延迟从 1.90 ms 降低到 1.69 ms (降低 11.15%)。在像素吞吐量方面,基线算法的处理速度约为 2.154×10^6 px/s ($526 \times 640 \times 640$),而 DKR-YOLOv8 的处理速度为 2.425×10^6 px/s,净提升 12.55%。这意味着,在相同的时间预算下,滑动窗口的总数可以增加 12.55%。在常见的固定功耗边缘计算环境中,单幅图像的能耗与延迟大致成正比,因此单幅图像的能耗降低了约 11.15%;在固定帧率目标下,DKR-YOLOv8 提供了 12.55% 的计算余量,可以用于降低频率/电压,从而延长电池续航时间或改善散热。简而言之,该模型的轻量级设计不仅降低了 43.6% 的浮点运算次数,而且在边缘设备上还能转化为-11.15% 的延迟降低、+12.55% 的像素吞吐量提升、+33% 的可行输入分辨率 (在相同吞吐量下)以及-11.15% 的单幅图像能耗降低 这些都是清晰可验证的部署优势。

3.7 改进前后的对比实验

在经过 200 个 epoch 后,我们提取了 DKR-YOLOv8 和 YOLOv8 模型的位置损失值,以便更详细地分析模型升级前后的性能。通过分析这些位置损失值,我们可以深入了解升级后的 DKR-YOLOv8 模型在效率和精度方面的提升。数据表明,DKR-YOLOv8 模型的改进如何促进了模型性能的提升。

更精确的目标定位,最终带来更好的整体检测性能。

如图 10 所示,改进的 DKR-YOLOv8 模型与原始 YOLOv8 模型相比,收敛速度更快,收敛率也明显更高。

这一改进可归因于内核仓库和动态蛇形卷积技术的整合。召回率曲线显示召回率稳步上升。

随着训练迭代次数的增加,效果也随之提高。值得注意的是,在第200个epoch之后,改进后的DKR-YOLOv8模型与原始YOLOv8模型之间出现了显著差异。




图 10.位置丢失率和召回率曲线。

在聚类性能方面,DKR-YOLOv8 模型优于 YOLOv8 模型,展现出更优异的聚类能力。其聚类密度显著更高, 82.6% 的变量被聚类在 -0.4 到 0.3 的范围内。图11进一步展示了更稳健的聚类函数,增强了模型有效分组变量的能力。这种更紧密的聚类有助于提高目标检测的准确性,因为模型能够更好地区分图像中的不同目标。

DKR-YOLO v8 的数据提取频率二维直方图呈现出更加均匀一致的分布。频率计数主要集中在20 到 60 的范围内,表明提取过程均衡且一致。这种均匀性表明模型在不同帧上的数据提取更加均衡,从而降低了对特定数据段出现偏差或过拟合的可能性。DKR-YOLO v8 在不同角度方向上表现出更紧密的关联性,这体现在二维直方图中近乎圆形的分布上。这种近乎圆形的模式表明数据点的聚类更加各向同性,这意味着模型的性能和准确性对帧内物体方向的依赖性较低。这种各向同性有利于确保模型在检测物体时具有鲁棒性和一致性,而与物体的方向无关。

混淆矩阵是一个二维矩阵,其中行代表模型预测的类别,列代表实际类别。每一行的数据表示被预测为特定类别的实例数,每行中的总数表示被预测为属于该类别的实例数。类似地,每一列的数据表示实际类别,每列中的总数表示属于该类别的实例数。

为了诊断类别识别行为并分离出我们设计选择的影响,图12和图13并列展示了归一化形式的 YOLOv8 和 DKR-YOLOv8 的混淆矩阵。作为对该分析的补充,图14可视化了图像级别的误检共现结构。图中不同的颜色代表不同的聚类类别。颜色本身没有特定的含义;它们仅仅用于区分不同的类别。




图 11. DKR-YOLOv8 与 YOLOv8 的学术扩展与分析。(a) YOLOv8宽度和高度分布的重叠线图。(b) DKR-YOLOv8 宽度和高度分布的重叠线图。(c) YOLOv8 宽度和高度的二维直方图。(d) DKR-YOLOv8宽度和高度的二维直方图。




图 12. YOLOv8 的混淆矩阵比率信息。




图 13. DKR-YOLOv8 的混淆矩阵比率信息。




图 14.图像识别中误检共现图。

与YOLOv8相比,DKR-YOLOv8混淆矩阵的聚类程度显著更高,其准确率约为94%,而YOLOv8仅为85%。改进后的模型有效降低了漏检概率。

通过置信度图的分析,可以明显看出注意力机制显著提高了模型的检测精度,从而降低了不确定性和误检率。置信度图的分析结果表明,引入注意力机制显著提升了模型识别不同壁画类别的能力,减少了误检和漏检的发生,从而提高了整体检测精度。这些改进表明,注意力机制在优化DKR-YOLOv8模型的性能方面发挥着至关重要的作用,使其在复杂背景下的壁画检测任务中展现出更高的可靠性和准确性。

在图像识别中,物体类别之间以及同一类别内部的物体之间常常容易混淆。以下分析了导致每个类别误分类的因素:类别 1:孔侯、牛、云、鸟、火焰、藻井。云、火焰和鸟等自然元素形状变化多端,使得图像识别系统难以捕捉清晰的边界和形状。这种变化性可能导致系统将其与具有相似形态特征的物体(例如流水或烟雾)混淆。

装饰性或艺术性物体,包括藻井和孔侯,通常具有复杂的纹理或曲线,这些纹理或曲线与某些自然形态(例如植物或涟漪)相似,从而增加了误分类的可能性。同样,由于表面细节区分不足,牛皮或鸟羽的纹理也可能被误认为是其他带毛或带羽动物的纹理。

第二类:鹿、马、亭、琵琶。鹿和马在形态上具有相似性,尤其是在特定角度或低质量图像中观察时,更容易造成误判。亭台楼阁等建筑结构也可能与其他类似结构(例如寺庙或廊桥)混淆,尤其是在算法对细节不够敏感的情况下。同样,琵琶也可能被错误地归类为其他弦乐器,例如古琴或月琴,因为在识别过程中未能充分捕捉到它们的独特特征。

第三类:华盖、宝塔、船。华盖和宝塔通常包含多层结构或装饰华丽的尖顶,这可能导致它们被误认为是其他宗教建筑(例如佛塔或寺庙屋顶)。它们重复的装饰元素往往与其他皇家或宗教建筑设计在视觉上高度相似,这使得人们难以识别它们的具体功能或象征意义。同样,船的多种形状也可能导致人们将其与其他形状相似的物体混淆,例如桥梁构件或建筑物的下部结构。

第四类:僧杖、金银花、壁龛门楣、扇子、树。树木通常难以与其他植物或自然物体(例如灌木或藤蔓)区分开来,尤其是在细节模糊的图像中。僧杖可能与竹子等植物形态相似,尤其是在材质不显眼的情况下。装饰性和功能性的重叠进一步加剧了混淆;例如,当扇子与其他形状相似的物体(例如折扇或屏风)具有相似的图案或结构时,它们可能会被误认为是其他类似形状的物品。同样,由于形状和设计相似,壁龛门楣也可能被误认为是其他建筑元素(例如门楣或窗框)。

在图像识别中,物体混淆的主要原因包括形态相似性、表面纹理复杂性、功能性和装饰性元素的相互作用,以及自然物体和人造物体之间的视觉相似性。如果算法未能充分捕捉物体的关键特征,这些因素就可能导致识别错误或分类错误。

如图 15 所示,模型训练过程中的损失函数和准确度指标分别表现出各自的收敛趋势和振荡行为。损失函数衡量模型预测结果与实际标签之间的差异。所有三个损失函数(框损失、目标损失和分类损失)都呈现出明显的收敛趋势,最终趋于稳定。这表明模型在训练过程中逐步学习特征,并有效地降低了预测误差。




图 15.数据集上的结果。结果图中包含了损失函数、精确率、召回率和地图评估指标。

框损失函数用于衡量预测边界框与真实边界框之间的差异。目标存在性损失函数评估模型预测目标是否存在的准确率。分类损失函数评估模型预测目标类别的准确率。模型的准确率在训练过程中表现出明显的波动。这种波动可能是由于模型不断调整参数以在复杂数据集上获得更好的性能所致。然而,随着训练的进行,准确率逐渐趋于稳定,在大约160个epoch后稳定在0.8左右。这表明模型在分类任务中已达到较高的准确率。所有三个损失函数均收敛到稳定状态,表明模型在各项任务中均达到了预期的性能。

尽管训练过程中准确率出现波动,但最终会趋于稳定并保持在较高水平。注意力机制的引入显著提高了模型的检测准确率,降低了不确定性和误检率,有效提升了模型的整体性能。

浮点运算次数 (FLOPs) 降低 43.6% 可直接降低推理延迟和功耗,从而使小型博物馆和本地文物修复工作室能够在通常可用的配置较低的边缘硬件上进行现场部署 (例如,不具备数据中心连接的紧凑型 GPU 或仅 CPU 工作站)。这反过来又支持更高的输入分辨率、更密集的千兆像素壁画拼接,以及在脚手架旁采集数据和快速状况调查期间的实时反馈,所有这些都在相同的能耗和预算范围内完成。更低的计算成本还减少了归档处理时间和对云的依赖,从而促进了保护隐私的离线工作流程,使敏感文化资产无法离开机构。在日常监测中,同一设备可以对每个墙面区域进行更频繁的扫描,在不增加人员配备或电力成本的情况下提高时间覆盖范围。通过使资源有限的保管人员能够进行定期、标准化的评估,切实推进了“可持续管理”。

准确率提升 3.7%,平均绝对精度 (mAP) 提升 5.1%,意味着对小型、细长和低对比度元素的漏检率更低,噪声源的误报率也更低。在数字化和编目过程中,更高的 mAP 值能够提高不同壁画风格和老化程度下图像和图案层面的识别一致性,从而减轻策展人的人工核查负担,并大规模地生成更清晰、更完整的元数据。由于 RE-FPN 和 ECA 在保留空间线索的同时强调语义关键通道,因此生成的注意力和显著性叠加图对非技术专家来说更易于理解:文物修复人员可以审核某个区域被标记的原因,追溯决策依据的可见图像证据,并将这些叠加图整合到状况报告和符合 CIDOC 标准的记录中。

如图16所示,该软件的核心功能是自动识别壁画中的元素。通过高精度图像识别技术,该软件能够准确捕捉和分析壁画中的关键信息,为壁画研究领域的学者提供强有力的技术支持。学者可以利用该软件快速获取壁画的关键数据,从而更深入地研究壁画的历史、文化、艺术风格等各个方面。该软件拥有用户友好的界面设计,包含启动、导入图片、数据分析和查看历史记录等功能模块,使用户能够轻松上手,快速完成壁画元素的识别和分析任务。该软件的开发和应用涉及计算机科学、图像处理、文化艺术等多个学科,其成功应用将促进这些学科之间的交叉融合与深度合作,推动相关领域的共同发展。该软件的应用有助于提升壁画保护和研究水平。通过准确识别壁画中的元素和特征,可以更准确地评估壁画的保存状况,这为制定科学的保护计划和研究方案提供了强有力的支持。

Mural image recognition

log in

sign in

Intelligent DKR–YOLOv8 algorithm to identify mural scene elements

Use advanced artificial intelligence technology to provide a full range of detection and solutions for your mural recognition academic research and promote research development



Start to experience

import picture

reanalysis

data storage

Data history

Caisling is a unique form of interior ceiling decoration in ancient Chinese architecture, which has profound historical and cultural connotations and exquisite technology.

Origin and development

The origin of caislings can be traced back to the Northern Wei Dynasty (386-534 BC), and it was first seen in the stone lotus on the top of Yungang Grottoes and Longmen Grottoes. In the ancient cave era, the top hole was opened to absorb light, ventilation and access, and this structure gradually evolved into the later caislings. The name of the caisson comes from its concave shape of the well, and decorated with algae (that is, the pattern) and named.

Structure and form

The caissette is generally made into a well shape with a square, polygon or circular concave surface, and is decorated with various flower caissette patterns, carvings and colors around it. Its structure is usually supported by fine dougongs, which are recesses inward, forming a rich sense of layering and three-dimensional. The structure of caisings is complex and fine, showing the superb wood craftsmanship of ancient craftsmen.

Function and significance

Decorative effect: The caissette is used as a high-level smallpox decoration, mainly used for palaces, temples and other important buildings above the throne, Buddha altar, increase the sense of grandeur of the interior. Its exquisite carving, painting and complex structure reflect the exquisite level of ancient architectural art.

+

See more

Identification result:

Identification confidence:

Alage wells

0.962

See other possibilities

图 16.壁画识别软件页面。

4. 讨论

以壁画内容分类为中心的计算机视觉技术正从昂贵、脆弱、门槛高的实验室技术转向可部署、可重用且易于管理的数字基础设施,从而直接重塑博物馆、档案馆以及预算和人员有限的小型文化遗产机构的工作流程。DKR-YOLO 在保持与 YOLOv8 工业生态系统兼容的同时,通过 DySnake Conv 和自适应卷积核仓库增强了对复杂笔触和边缘的表征;它通过将 RFA 增强的 FPN (RE-FPN) 与高效通道注意力 (ECA) 相结合,进一步提高了图像的区分性和可解释性,从而实现了更好的计算成本与精度之间的平衡。这些改进并非仅仅是数值上的提升;它们切实地扩展了文化机构的选择空间和可承受范围。在数字存档方面,更强大的细节捕捉能力和对风格变化的适应性使得壁画语义单元的自动分割和标注成为可能。与依赖人工描述和关键词检索的工作流程相比,该模型能够识别图案变体、区域图像差异以及褪色或遮挡下的潜在元素,从而促进跨博物馆和跨区域的本体和词汇对齐,显著降低目录整合和去重等后续工作的成本。RE-FPN 中的残差增强和 ECA 的通道优先级排序能够稳定建议的标签和置信区间,减少策展人的验证时间,使小型机构中人手有限的人员能够将精力从重复的数据录入转移到语义审查和知识组织上,从而提高描述的一致性和可审计性。

内容级分类从两个方面助力文物保护决策:一方面,有助于早期发现和监测微病变;另一方面,有助于风险评估和修复项目的证据保存。DySnake Conv对曲折边界和细微裂缝的敏感性有助于稳定分割多时相图像中的形态特征;自适应卷积核仓库 (Adaptive Convolutional Kernel Warehouse) 可在材料和光照变化的情况下保持特征的通用性,从而减轻因设备或光照条件变化而需要重新训练的维护负担。结合模型固有的注意力热图和类激活 (CAM) 可视化,文物保护团队可以将解释模型为何分配特定分类的证据直接整合到记录中,形成可审计的解释链。在项目管理层面,43.6% 的浮点运算次数 (FLOPs) 减少使得在便携式终端或现场边缘设备上推理成为可能,从而减少了对温控服务器机房和云带宽的依赖,并降低了能源消耗和碳排放。

在访问和公众参与方面,稳定的内容分类为分层展示、可定制指南和教育应用提供了语义基础。

当系统能够可靠地区分主题类型、叙事片段和图像角色,并将它们与时间地点、材料和技法等知识图谱节点关联起来时,机构就能更轻松地构建多语言、分层式界面:为研究人员提供高精度图案比较和跨馆藏检索;为普通参观者提供主题式、故事驱动的导览;并为儿童或视障人士提供定制化的旁白和触觉/音频替代方案。由于 DKR-YOLO 降低了推理成本,小型机构可以将模型服务嵌入到展厅自助服务终端、移动小程序,甚至临时展览的离线设备中,从而在不显著增加运营成本的情况下丰富互动体验。壁画内容分类并非孤立运行;它与采集方式 (多光谱、宏观、结构光)、3D 重建、文本比较和信息提取相互促进。DKR-YOLO 通过在较低的推理负载下实现更高的 mAP,降低了从像素到语义的门槛,为中小机构提供了一条切实可行的路径:首先确保可用性。

首先构建结构化语义,然后进行跨模态链接和知识计算。这条路径能够提升当今的存档质量和保护效率,并为跨机构整合和开放科学奠定可扩展的基础。

5. 结论

我们提出了一种基于 YOLOv8 架构的古代壁画模型。经过广泛的测试和细致的分析,我们提出的技术已被证明能够在各种环境条件下正确、高效地检测壁画。

5.1 研究结果

本文提出的DKR-YOLOv8模型旨在用于古代壁画元素的识别与分类。它在泛化能力、效率和可解释性三个核心维度上进行了系统性的改进。通过核仓库动态卷积和动态蛇形卷积,该模型增强了对细粒度边界和装饰细节的表征。通过优化自顶向下的特征融合,并结合轻量级R-FPN (以及通道注意力机制),该模型在保持YOLOv8生态系统兼容性的同时,实现了计算能力和精度的双重提升 (浮点运算次数降低43.6%,精度提高3.7%,平均精度均值提高5.1%)。配套的多样化壁画数据集涵盖了不同的主题、风格、劣化形式和复杂的背景,显著增强了模型在实际场景中的鲁棒性,并验证了其在不同环境监测场景和移动/边缘设备上的部署可行性和时效性。

这些技术和数据相关的贡献直接服务于文化遗产保护实践。元素的自动化和精细化识别与定位,确保了高质量数字存档和结构化元数据生成的可复制性,从而降低了编目成本,并提高了跨机构比对和学术检索的效率。对于疾病的早期检测和过程监测,该模型对裂缝、粉化和白垩化等微观形态的敏感性,以及其跨设备/光照的鲁棒性,为现场检查 and 长期时间序列评估提供了可量化的证据,有助于按区域和等级确定优先干预级别。轻量级的推理能力和可解释的可视化 (热图、激活区域)增强了资源受限机构的可用性、可验证性和可信度,减少了对高能耗计算能力和外部云传输的依赖,同时也符合可持续数字化和数据主权的要求。

DKR-YOLOv8 将尖端检测框架转化为遗产保护的实用工具链,为壁画的长期保护、科学研究和公共服务提供了一条高效、可靠且可扩展的技术途径。

5.2 研究展望尽管

DKR-YOLOv8在壁画元素识别和分类方面取得了显著的效率和准确率提升,但仍存在一些局限性。首先,数据和标注的代表性和一致性尚不足以保证其结果能够推广到不同的遗址、材料和历史时期。虽然我们的数据集涵盖了敦煌等典型样本以及多种劣化形式,但不同收藏机构之间存在的显著差异 (例如光谱响应、照明设置、相机和镜头特性、分辨率以及压缩策略)可能会导致结果出现偏差。

与此同时,修复痕迹、重绘铭文、二次着色和灰尘阴影通常与真正的装饰边界具有相似的局部统计特征,导致

首先,该方法容易混淆“裂纹/线条”和“粉末/纹理”。长尾类别的严重匮乏加剧了类别不平衡,而类别不平衡对学习的主要影响尚未得到充分缓解。其次,该方法主要针对目标检测:虽然核仓库动态卷积和动态蛇形卷积能够改善曲折边缘和精细纹饰的表示,但对于需要像素级解释的文物保护任务而言,仅依靠框级监督是不够的。目前的可解释性主要依赖于通道注意力机制和类别激活图。这些事后可视化方法无法直接映射到文物保护术语中的因果解释或证据链。第三,评估方案仍然侧重于通用检测指标,缺乏对文物保护工作流程实际效益的过程性和纵向量化。

最后,部署和治理方面仍需加强:尽管轻量化降低了计算门槛,但对于超高分辨率全景镶嵌图、低照度/高反射率场景以及离线画廊设备而言,推理延迟和能耗仍然可能成为瓶颈。数据主权、敏感图像的分级访问、跨机构本体对齐以及版本溯源等问题同样需要更强大的机构和工具支持。

展望未来,我们提出将可见光与紫外荧光/红外反射光谱(UVF/IRR)、多光谱/高光谱成像、实时红外光谱(RTI)和浅层三维成像相结合,并利用耦合的光谱-材料-几何约束来增强对壁画类型和叠加结构的解读;几何感知型固定模式网络(FPN)或Transformer架构可以提高模型对曲面和倾斜镶嵌图案失真的鲁棒性。基于分层本体的弱监督学习,结合度量学习和原型网络,可以更好地支持长尾、少样本类别。主动学习和不确定性驱动的采样应将有限的标注资源集中在模型混淆和分歧最大的区域,而跨机构的持续学习和领域自适应可以缓解因设备、照明和工艺技术差异而导致的性能漂移。在任务构建方面,我们提倡从“检测”转向以保护为导向的语义建模。将实例/全景分割、裂纹骨架提取、图像关系推断和时间变化检测整合到一个端到端的多任务框架中,该框架输出可直接用于保护决策的结构化证据。为了提高可解释性和管理不确定性,我们建议采用积极主动、可审计的设计。概念瓶颈分析、原型/部件级归因以及因果干预,以生成与保护术语一致的解释单元。以及置信度校准和风险分层,以明确“何时不该进行保护”的界限。

在工作流程中明确“信任模型”。同时,我们也建议建立端到端的谱系记录和模型卡。从数据采集和标注到训练和发布,以支持跨机构审查和可复现性。

作者贡献:概念构思,SK和JL;方法论,ZG和HW;资源提供,ZG和SK;数据整理,ZG、HW和JL;初稿撰写,HW和ZG;审阅和编辑,SK;可视化,ZG、SK和HW;监督指导,SK;项目管理,SK;资金筹集,ZG和SK。所有作者均已阅读并同意发表稿件的最终版本。

资助:本研究由国家创新创业项目基金创新训练计划(202410451009)资助。

数据可用性声明:数据包含在文章中。

致谢:我们衷心感谢马来亚大学亚欧研究院和瑞禄维军(烟台)信息技术有限公司为本研究提供的宝贵支持和帮助。本节中提及的所有人员均已同意致谢。

利益冲突声明:作者声明不存在利益冲突。

缩写

本文中使用以下缩写:

射频消融术	残差特征增强
LSTM	长短期记忆
固定卷积网络	特征金字塔网络
支持向量机	支持向量机
生成对抗网络 (GAN)	
公元前	二元交叉熵
柯威	内核仓库
DWConv	深度卷积
新加坡元	随机梯度减小
他	直方图均衡化
差分扫描量热法	动态蛇卷积

参考

1. Brumann, C.; Gfeller, A.É. 文化景观与联合国教科文组织世界遗产名录 :延续欧洲的主导地位。国际期刊 继承。螺柱。 2022, 28, 147–162。 [交叉参考]
2. Mazzetto, S. 将新兴技术与数字孪生技术相结合用于遗产建筑保护 :一项跨学科研究 结合专家见解和文献计量分析的方法。Heritage 2024, 7, 6432–6479. [CrossRef]
3. Poger, D.; Yen, L.; Braet, F. 当代电子显微镜中的大数据 :数据传输、计算方面的挑战与机遇 以及管理。组织化学与细胞生物学, 2023,160,169–192 。 [CrossRef] [PubMed]
4. Vassilev, H.; Laska, M.; Blankenbach, J. 基于贝叶斯方法的面向基础设施项目的不确定性感知点云分割 深度学习. 自动化建设. 2024, 164, 105419. [CrossRef]
5. Agrawal, K.; Aggarwal, M.; Tanwar, S.; Sharma, G.; Bokoro, PN; Sharma, R. 基于区块链的应用调查 : 工具、框架、机遇、挑战与解决方案。IEEE Access 2022, 10, 116858–116906. [CrossRef]
6. Jaillant, L.; Mitchell, O.; Ewoh-Opu, E.; Hidalgo Urbaneja, M. 我们如何利用人工智能提高档案收藏的多样性? 机遇、风险与解决方案。人工智能与社会。2025 , 40, 4447–4459。 [CrossRef]
7. Yu, T.; Lin, C.; Zhang, S.; Wang, C.; Ding, X.; An, H.; Liu, X.; Qu, T.; Wan, L.; You, S. 敦煌文化人工智能 遗产保护 :项目与数据集。《国际计算机视觉杂志》 2022,130,2646–2673 。 [CrossRef]
8. Gao, Y.; Zhang, Q.; Wang, X.; Huang, Y.; Meng, F.; Tao, W. 文化遗迹资源的多维知识发现 唐代墓葬壁画类别。电子图书馆, 2024,42,1-22 。 [CrossRef]
- 9.张晓东,《敦煌石窟 :展现中国佛教艺术发展与社会互动》 4世纪和14世纪。《教育、人文与社会科学杂志》 2023年,第21卷,第266-279页。 [CrossRef]
- 10.陈思、Vermol, W.Ahmad, H. 敦煌文化价值中数字媒体的演变与挑战探究 壁画。生态人文主义杂志2024, 3, 1369–1376。 [CrossRef]
- 11.曾志强;邱松;张鹏;唐晓;李松;刘晓;胡斌. 基于高光谱的古代墓葬壁画虚拟修复 成像. 遗传学. 2024, 12, 410. [CrossRef]
12. Tekli, J. 基于聚类的图像搜索结果组织概述 :背景、技术和当前挑战。知识。 信息系统, 2022,64,589–642 。 [CrossRef]
13. Zeng, Z.; Sun, S.; Li, T.; Yin, J.; Shen, Y. 智能图书馆中敦煌壁画的移动视觉搜索模型. Libr. Hi Tech 2022, 40, 1796–1818. [CrossRef]
14. Gupta, N.; Jalal, AS 传统到迁移学习在场景文本检测和识别中的应用 :一项调查。人工智能。 Rev. 2022, 55, 3457–3502. [CrossRef]
15. Shin, J.; Miah, ASM; Konnai, S.; Hoshitaka, S.; Kim, P. 基于肌电图的手势识别与可解释人工智能 (XAI): 用于增强时空动态特性的分层特征提取. IEEE Access 2025, 13, 88930–88951. [CrossRef]
16. Zhang, P.; Liu, J.; Zhang, J.; Liu, Y.; Shi, J. HAF-YOLO :用于遥感图像目标检测的动态特征聚合网络. 遥感. 2025, 17, 2708. [CrossRef]
17. Neves, FS; Claro, RM; Pinto, AM 基于多模态早期检测的近海无人机着陆平台端到端检测 融合方法。Sensors 2023, 23, 2434. [CrossRef]
- 18.赵志强;张鹏;刘晓东;雷晓东;罗勇. 中国传统颜料和染料光老化特性的分析 基于色差原理的不同环境. 色彩研究与应用. 2021, 46, 1276–1287. [CrossRef]

19. Li, K.; Zhang, Y.; Li, K.; Li, Y.; Fu, Y. 基于视觉和文本语义推理的图像-文本嵌入学习. IEEE模式分析与机器学习汇刊. 2022, 45, 641–656. [\[CrossRef\]](#) [\[PubMed\]](#)
20. Gao, Y.; Li, W.; Liang, S.; Hao, A.; Tan, X. 面向虚拟现实渲染的显著性感知注视点路径追踪. IEEE Trans. Vis. Comput. Graph. 2025, 31, 2725–2735. [\[CrossRef\]](#)
21. Feng, C.-Q.; Li, B.-L.; Liu, Y.-F.; Zhang, F.; Yue, Y.; Fan, J.-S. 基于多传感器融合同步定位的裂缝评估以及用于桥梁检测的实时定位与地图构建 (SLAM)和图像超分辨率技术. 自动化建筑, 2023, 155, 105047. [\[CrossRef\]](#)
22. Ma, W.; Guan, Z.; Wang, X.; Yang, C.; Cao, J. YOLO-FL:一种用于反光服装穿着检测的目标检测算法。显示2023, 80, 102561. [\[CrossRef\]](#)
23. Dahri, FH; Abro, GEM; Dahri, NA; Laghari, AA; Ali, ZA 利用自定义顺序深度推进机器人自动化基于卷积神经网络的室内场景识别. ICCK Trans. Intell. Syst. 2024, 2, 14–26. [\[CrossRef\]](#)
24. Sun, H.; Wang, Y.; Du, J.; Wang, R. MFE-YOLO:一种用于机场鸟类检测的多特征融合算法. ICCK Trans. Intell. Syst. 2025, 2, 85–94.
25. Iqbal, M.; Yousaf, J.; Khan, A.; Muhammad, T. 基于物联网的多传感器数据融合和移动传感接口的食品新鲜度检测. ICCK Trans. Sens. Commun. Control 2025, 2, 122–131. [\[CrossRef\]](#)
26. Ullah, N.; Ahmad, B.; Khan, A.; Khan, I.; Khan, IM; Khan, S. 基于多尺度特征优化的注意力引导小麦病害识别网络. ICCK Trans. Sens. Commun. Control 2025, 2, 11–24. [\[CrossRef\]](#)
27. Ali, ML; Zhang, Z. YOLO 框架:对象设计中的演化、应用和基准测试的综合综述检测。计算机2024, 13, 336. [\[CrossRef\]](#)
28. Zhang, X.; Wang, H.; Dong, H.深度学习驱动的3D目标检测综述:传感器模式、技术架构, 以及应用。Sensors 2025, 25, 3668. [\[CrossRef\]](#)
29. Cheng, T.; Song, L.; Ge, Y.; Liu, W.; Wang, X.; Shan, Y. Yolo-world:实时开放词汇目标检测。在IEEE/CVF 计算机视觉与模式识别会议论文集, 美国华盛顿州西雅图, 2024年6月17-18日;第16901-16911页。
30. Lu, P.; Jiang, T.; Li, Y.; Li, X.; Chen, K.; Yang, W. Rtmo:面向高性能单阶段实时多人姿态估计。IEEE/CVF计算机视觉与模式识别会议论文集, 美国华盛顿州西雅图, 2024年6月17-18日;第1491-1500页。
31. Derakhshani, MM; Masoudnia, S.; Shaker, AH; Mersa, O.; Sadeghi, MA; Rastegari, M.; Araabi, BN.激活辅助激励:一种改进目标检测器的学习技术。载于 IEEE/CVF 计算机视觉与模式识别会议论文集, 美国加利福尼亚州长滩, 2019年6月15-20日;第9201-9210页。
32. Lengyel, H.; 雷梅利, V.; Szalay, Z.易于部署的对抗性交通标志贴纸的集合。at-自动化技术2021, 69, 511–523. [\[交叉参考\]](#)
33. Cetinic, E.; She, J. 利用人工智能理解和创作艺术:回顾与展望。ACM Trans. Multimed. Comput. Commun. Appl. (TOMM) 2022, 18, 1–22. [\[CrossRef\]](#)
34. Mei, S.; Li, X.; Liu, X.; Cai, H.; Du, Q. 基于注意力机制的双向长短期记忆高光谱图像分类存储网络. IEEE地球科学与遥感学报. 2021, 60, 1–12. [\[CrossRef\]](#)
35. Liu, S.; Yang, J.; Agaian, SS; Yuan, C. 肖像画艺术运动分类的新特征. 图像与视觉计算. 2021, 108, 104121. [\[CrossRef\]](#)
36. Martinez Pandiani, DS; Lazzari, N.; Erp, Mv; Presutti, V. Hypericons for interpretability: Decoding abstract concepts in visual data. Int. J. Digit. Humanit. 2023, 5, 451–490. [\[CrossRef\]](#)
37. 王艳, 吴晓. 壁画研究进展:分布、保护与利用. 遗产科学. 2023, 11, 61. [\[CrossRef\]](#) [\[PubMed\]](#)
38. Zhang, J.; Zhang, X.; Huang, Z.; Cheng, X.; Feng, J.; Jiao, L. 基于轨迹准则的双向多目标跟踪卫星视频。IEEE地球科学与遥感学报, 2023, 61, 1–14. [\[CrossRef\]](#)
39. Koo, B.; Choi, H.-S.; Kang, M. 基于多尺度的弱监督目标定位的简单特征金字塔网络信息. 多维系统与信号处理. 2021, 32, 1185–1197. [\[CrossRef\]](#)
40. Hu, J.; Yu, Y.; Zhou, Q. GuidePaint:一种用于古代壁画图像修复的无损图像引导扩散模型. npj 遗产科学. 2025, 13, 118. [\[CrossRef\]](#)
41. Mantzou, P.; Bitsikas, X.; Floros, A. 通过艺术与数字技术的融合丰富文化遗产。社会科学. 2023, 12, 594. [\[CrossRef\]](#)
42. Saunders, D. 神经机器翻译的领域自适应和多领域自适应:综述。人工智能研究杂志, 2022年. 75, 351–424. [\[CrossRef\]](#)
43. 曾志强; 孙松; 李涛; 尹建; 沈勇; 黄强. 通过图像分类探索敦煌壁画的主题演变。J. Inf. Sci. 2024, 50, 35–52. [\[CrossRef\]](#)
44. Ren, H.; Sun, K.; Zhao, F.; Zhu, X. 基于生成对抗网络的敦煌壁画图像复原方法. 遗产. Sci. 2024, 12, 39. [\[CrossRef\]](#)

45. Fei, B.; Lyu, Z.; Pan, L.; Zhang, J.; Yang, W.; Luo, T.; Zhang, B.; Dai, B. 用于统一图像恢复和增强的生成式扩散先验. IEEE/CVF 计算机视觉与模式识别会议论文集, 加拿大温哥华, 2023 年 6 月 17-24 日; 第 9935-9946 页。
46. Mu, R.; Nie, Y.; Cao, K.; You, R.; Wei, Y.; Tong, X. 净土朝圣: 艺术感知与五台壁画VR重建。 Int. J. Hum.-Comput. Interact. 2024, 40, 2002–2018. [\[CrossRef\]](#)
47. Nazir, A.; Cheema, MN; Sheng, B.; Li, P.; Li, H.; Xue, G.; Qin, J.; Kim, J.; Feng, DD. Ecsu-net: 一种嵌入式聚类切片U-Net结合融合策略, 用于高效的椎间盘分割和分类。IEEE图像处理汇刊, 2021, 31, 880–893。 [\[CrossRef\]](#)
48. Smagulova, D.; Samaitis, V.; Jasiuniene, E. 用于粘接界面缺陷检测的卷积神经网络不同的结构。应用科学, 2024, 14, 10351。 [\[CrossRef\]](#)
49. 张超. 基于Transformer智能渲染方法的镜面绘画数字交互设计. 科学报告. 2025, 15, 25518. [\[CrossRef\]](#)
50. Zhou, G.; Zhi, H.; Gao, E.; Lu, Y.; Chen, J.; Bai, Y.; Zhou, X. DeepU-Net: 一种用于从高分辨率遥感图像中提取道路的并行双分支模型, 该模型采用深度融合多尺度特征。IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens. 2025, 18, 9448–9463. [\[CrossRef\]](#)
51. Wang, P.; Fan, X.; Yang, Q.; Tian, S.; Yu, L. 基于改进YOLOv8的壁画图像目标检测. Multimed. Syst. 2025, 31, 93. [\[CrossRef\]](#)
52. Chen, L.; Wu, L.; Wan, J. 基于YOLOv10的石窟壁画损伤检测与数字重建方法. npj 遗产科学. 2025, 13, 91. [\[CrossRef\]](#)
53. Chen, Y.; Zhang, A.; Shi, J.; Gao, F.; Guo, J.; Wang, R. 基于YOLO的古代壁画和彩绘颜料脱落检测与分割: 一种改进的模型. Heritage 2025, 8, 136. [\[CrossRef\]](#)
54. 萨普科塔, R.; 弗洛雷斯-卡莱罗, M.; 库雷希, R.; 巴德古贾尔, C.; 尼泊尔, 美国; 普洛斯, A.; 芝诺, P.; 瓦德沃卢, UBP; 汗, S.; 索曼, M. YOLO 追溯其起源: 对《你只看一次》(YOLO)系列的十年全面回顾。人工智能评论. 2025, 58, 274. [\[CrossRef\]](#)
55. Hussain, M. YOLOv1 至 v8: 揭示每个变体 YOLO 的全面综述。IEEE Access 2024, 12, 42816–42833. [\[CrossRef\]](#)
56. Zheng, J.; Fu, Y.; Zhao, R.; Lu, J.; Liu, S. 基于DD-IYOLOv8的死鱼检测模型. Fishes 2024, 9, 356. [\[CrossRef\]](#)
57. Wu, X.; Yuan, Q.; Qu, P.; Su, M. 基于图像的蜡染产品知识图谱构建. npj Heritage Science. 2025, 13, 20. [\[CrossRef\]](#)
58. Ru, H.; Zhang, W.; Wang, G.; Ding, L. OMAL-YOLOv8: 基于优化的绝缘体缺陷实时检测算法特征融合. 实时图像处理杂志. 2025, 22, 52. [\[CrossRef\]](#)
59. Dunkerley, D. 叶片水分流失: 摆脱基于静态接触角的评估方法, 以及一种新的测量装置观察液滴动态滚动行为。生态学与进化方法, 2023, 14, 3047–3054. [\[CrossRef\]](#)
60. Lee, U.; Park, Y.; Kim, Y.; Choi, S.; Kim, H. Monacobert: 基于单调注意力的 convbert 用于知识追踪。在2024 年 6 月 10 日至 13 日于希腊塞萨洛尼基举行的国际智能辅导系统会议论文集上; 第 107-123 页。
61. Li, S.; Tu, Y.; Xiang, Q.; Li, Z. MAGIC: 重新思考用于医学图像分割的动态卷积设计。第 32 届 ACM 国际多媒体会议论文集, 澳大利亚墨尔本, 2024 年 10 月 28 日至 11 月 1 日; 第 9106-9115 页。
62. Zhao, M.; Agarwal, N.; Basant, A.; Gedik, B.; Pan, S.; Ozdal, M.; Komuravelli, R.; Pan, J.; Bao, T.; Lu, H. 理解大规模深度推荐模型训练的数据存储和摄取: 工业产品。载于第49届计算机体系结构国际研讨会论文集, 美国纽约, 2022年6月18-22日; 第1042-1057页。
63. Ahsan, F.; Dana, NH; Sarker, SK; Li, L.; Mueen, S.; Ali, MF; Tasneem, Z.; Hasan, MM; Abhi, SH; Islam, MR. 数据驱动的下一代智能电网迈向可持续能源演进: 技术与技术综述。Prot. Control Mod. Power Syst. 2023, 8, 1–42. [\[CrossRef\]](#)
64. Bhalla, S.; Kumar, A.; Kushwaha, R. 具有多尺度上下文集成的特征自适应 FPN 用于水下目标检测。地球科学信息学报, 2024, 17, 5923–5939. [\[CrossRef\]](#)

免责声明/出版商声明: 所有出版物中所包含的陈述、观点和数据仅代表作者或撰稿人个人意见, 并不代表MDPI和/或编辑的立场。MDPI和/或编辑对因内容中提及的任何观点、方法、说明或产品而造成的人身或财产损害不承担任何责任。