



文章

EMOLIPS:迈向可靠的情感语音唇语识别

德米特里·留明* , 埃琳娜·留米娜和丹尼斯·伊万科

俄罗斯科学院圣彼得堡联邦研究中心 (SPC RAS), 199178 圣彼得堡, 俄罗斯; ryumina_ev@mail.ru (ER);
ivanko.d@iiias.spb.su (DI)

*通讯作者: ryumin.d@iiias.spb.su

摘要: 本文提出了一种新的情感语音唇读方法 (EMOLIPS)。

这种基于视觉数据处理的两级情感语音转文本识别方法,其灵感来源于人类感知以及多模态深度学习的最新进展。该方法首先利用视觉语音数据来判断语音的情感类型,然后使用从头训练的情感唇读模型对语音数据进行处理。这从根本上解决了大多数现实场景中常见的多情感唇读难题。

我们结合了 EMO-3DCNN-GRU 架构 (用于情感识别) 和 3DCNN-BiLSTM 架构 (用于自动唇读) 来实现这些模型。我们在 CREMA-D 和 RAVDESS 情感语音语料库上评估了这些模型。此外,本文还详细回顾了过去五年 (2018-2023 年) 在自动唇读和情感识别领域取得的最新进展。与现有研究相比,我们主要关注深度学习引入该领域带来的宝贵进展,而省略了对传统方法的描述。由于考虑了发音视听语音的情感特征,EMOLIPS 方法显著提高了短语识别的准确率,在 RAVDESS 和 CREMA-D 语料库上的准确率分别达到了 91.9% 和 90.9%。

此外,我们进行了广泛的实验研究,证明了不同的情绪 (快乐、愤怒、厌恶、恐惧、悲伤和中性)、效价 (积极、中性和消极) 和二元性 (情绪化和中性) 如何影响自动唇读。

关键词: 唇读; 视觉语音识别; 情感语音; 语音转文本; 情感计算; 深度学习; 机器学习; 人机交互

MSC: 68T10



引文: Ryumin,D.;留米娜,E.;
伊万科,D. EMOLIPS:迈向
可靠的情感语音唇读.数学2023,
11, 4787.https://doi.org/10.3390/

math11234787

学术编辑:弗洛林·莱昂

收到日期:2023年10月25日

修订日期:2023年11月22日

接收日期:2023年11月24日

发布日期:2023年11月27日



版权所有: © 2023 作者所有。

被许可方 MDPI,瑞士巴塞尔。

本文为开放获取文章

根据条款和条件分发

知识共享协议的条款

署名 (CC BY) 许可(https://

creativecommons.org/licenses/by/

4.0/)。

1. 引言

说话时,人类发音器官会同时产生听觉和视觉两种语音线索[1-5]。因此,唇部运动与听觉信号之间存在很强的相关性,使我们能够从视觉和听觉两个方面提取语言信息。这种现象在人际交流中也十分明显。当存在噪声时,人们常常会将注意力转移到对方的唇部运动上,以增强对语音的理解。人们开始“观察”语音,而不仅仅是“聆听”。

这一事实促成了视觉语音识别 (VSR) 领域的发展,也称为唇读[6-9]。其主要思想是仅基于唇部动作来理解人类语音。然而,直到最近神经网络 (NN) 和深度学习 (DL) 的发展,自动系统才能够以足够的准确率 (Acc) 对人类语音感知的这一特征进行建模。尽管如此,目前自动VSR已取得了巨大的成功,尤其是在词汇量有限的任务中,其准确率远远超过了人类的唇读能力。当声学信号受到背景噪声干扰或说话者距离过远而无法清晰听清时, VSR就显得尤为重要[10]。

尽管当前最先进的唇读方法[8,11-15]在情感中性的语音识别(SR)任务中性能已显著提升,但在实际应用场景中,尤其是在语音受到人类情感影响时,其性能仍会大幅下降。然而,在实际应用中,对于用户而言,自动系统能否理解其在特定情绪状态下的请求往往至关重要。情感在声学和视觉模式下的表达方式不同,目前尚无“开箱即用”的情感鲁棒性视觉语音识别(VSR)解决方案。语音识别会随着说话者的情绪状态而变化:音色、音调和响度;声音的持续时间、停顿和发音。因此,识别带有情感的视觉语音转文本(S2T)任务极具挑战性。

现代语音情感识别 (SER)致力于利用深度神经网络 (DNN)模型使设备能够进行情感检测[16-19]。目前,语音情感识别在医疗保健、教育、媒体等领域有着广泛的应用。然而,由于缺乏有效的方法论以及缺乏适用于模型训练的标注语料库,语音情感识别的性能受到限制。

受人类感知和多模态深度学习最新进展的启发,我们提出了一种基于视觉数据处理的两级情感S2T识别方法 (EMOLIPS)。该方法建立在先前情感识别[20]和自动唇读[8]的研究成果之上,并充分利用了深度学习在这两个领域的最新进展。该方法的主要优势在于,它首先真正地处理情感识别,然后再进行特定情感的VSR,从而提高了自动唇读的准确率。我们免费提供源代码和模型供研究使用,旨在为未来情感S2T识别的研究建立一个基准。源代码和训练好的模型可在我们的GitHub仓库 (<https://github.com/SMIL-SPCRAS/EMOLIPS>)上获取。(访问日期:2023年10月25日)。

本文余下部分结构如下:第二节深入分析了视觉情感识别 (VER)和唇读领域的最新研究进展。第三节描述了用于训练、开发和测试我们提出的方法和模型的语料库。第四节提出了一种名为EMOLIPS的两级情感语音唇读方法。第五节展示了我们方法的实验结果。最后,第六节给出了一些结论性评述。

2. 相关工作

本节我们将仔细分析近期与SOTA相关的文献。

VER 方法以及唇读方法。

2.1. 视觉情感识别的最新方法

过去五年,由于现代机器学习 (ML)技术和算法的快速发展以及大规模语料库的发布,最先进的情感识别方法得到了极大的改进。情感识别已引起各个科学领域研究人员的广泛关注。人类情感可以从视觉数据 (面部表情[21-23]、行为[24]、手势[25-27]、姿态[28])、声学数据 (语音) [29]、生理信号[30-33]甚至文本[34]中识别和分析。本节将重点介绍基于面部表情分析的视觉情感识别 (VER)的最新方法。

面部表情的视觉信息是判断说话者情绪的重要指标。

根据目前最先进的 VER 流程,第一步是定位感兴趣区域(ROI)。一些开源计算机视觉 (CV) 库可以用于检测面部变化和面部形态 (例如, Dlib (<http://dlib.net/>), (访问日期:2023 年 10 月 25 日)或 MediaPipe (<https://google.github.io/mediapipe/>), (访问日期:2023 年 10 月 25 日)库)。此步骤评估面部特征点的位置,这些特征点包含有关人脸表情的有意义的信息,有助于进行自动情绪识别[35]。

对于任何话语,其潜在情感都通过语义情感分类 (SER)进行分类。语义情感分类可以通过两种方式进行:(a)

传统分类器;(b)深度学习分类器。

后者在情绪识别准确率方面比传统方法高出一个数量级。因此,下文仅讨论基于深度学习的方法。

深度神经网络 (DNN)是一种用于复杂数据处理的多层神经网络。许多研究人员已经研究了不同的深度模型,包括深度信念网络 (DBN) [36]、卷积神经网络 (CNN) [37]和长短期记忆 (LSTM)网络[38],以提高情感识别 (SER)系统的性能。然而,目前最有前景的情感识别方法通常以CNN和循环神经网络 (RNN)为核心,并结合注意力机制和一些其他改进[18]。

卷积神经网络 (CNN)是一种由多个层依次构成的神经网络。通常,该模型包含多个卷积层、池化层和全连接层,最后连接一个 SoftMax 单元。这种顺序网络构成了一个特征提取流程,将输入建模为抽象形式。CNN 的基础是卷积层,它们构成滤波器。这些层执行卷积运算,并将输出传递给池化层。池化层的主要目的是降低卷积层输出的分辨率,从而降低计算量。池化后的结果被送入全连接层,数据在全连接层中被展平,最终由SoftMax 单元进行分类。

循环神经网络 (RNN)及其变体通常用于从序列/时间序列数据中提取信息。RNN 基于以下递归方程工作:

$$S_t = FW(S_{t-1}, X_t), \quad (1)$$

其中 X_t 表示 t 时刻的输入; S_t (新状态)和 S_{t-1} (前一状态)分别表示 t 时刻和 $t-1$ 时刻的状态; FW 为递归函数。该递归函数为 $\tanh$ 函数。该方程可简化为:

$$\begin{aligned} S_t &= \tanh(W_s S_{t-1} + W_x X_t), \\ Y_t &= W_y S_t, \end{aligned} \quad (2)$$

其中 W_s 和 W_x 分别是前一状态和输入的权重, Y_t 是输出。文献[39]提出了一种基于循环神经网络 (RNN) 的高效情感识别方法。文献[40]表明,RNN 可以长时间学习时间聚合和帧级特征。

随着神经网络模型的最新发展,特别是诸如视觉几何组 (VGG) [41]和类ResNet [42]等深度神经网络架构的引入,这些架构无需特征提取阶段即可处理原始数据,现代情感超分辨率 (SR)方法开始崭露头角。过去五年中,已有大量研究成果发表,例如[43]。在现有的用于识别时空输入的深度学习 (DL)情感识别模型中,存在三种常见的拓扑结构:卷积神经网络-循环神经网络 (CNN-RNN) [44]、三维 (3D)卷积神经网络 (CNN) [45]和双流网络 (TSN) [46]。

这使得它们能够捕捉宏观和微观运动。然而,它无法像 CNN-RNN 那样方便地整合迁移知识。TSN 包含两个并行的 CNN:一个处理图像的网络和一个处理运动的时间网络[47]。

此外,还有大量研究致力于多模态视听 (AV)情感识别[48-55]。而且,诸如神经网络之类的视觉信息模型会考虑不同的信息通道。信息融合通常使用深度信念网络 (DBN) [56]或注意力机制[57]来实现。

一系列值得注意的方法将每个音频样本转换为二维 (2D) 视觉表示,以便能够使用基于 2D/3D CNN 的 SOTA CNN [58,59]。

为此,研究人员通常计算离散短时傅里叶变换 (STFT),如下所示:

$$\text{STFT}\{x[n]\}(m, k) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - mR] \cdot e^{-j \frac{2\pi}{N} kn}, \quad (3)$$

其中 $x[n]$ 为离散输入信号, $w[n]$ 为窗函数, N 为短时傅里叶变换 (STFT) 的长度, R 为步长。将频谱图计算为 STFT 幅值的平方后,所得值转换为对数尺度 (分贝),并归一化到区间 $[-1, 1]$,从而生成适用于后续图像处理的单通道图像。

此外,参考文献[60]的作者提出了一种基于著名的 Transformer [61] 的音频频谱图 Transformer 方法,Transformer 是一个无卷积、纯粹基于注意力的情感分类模型。

由于主要目标是评估视频而非图像 (帧) 中的情感,参考文献[62]的研究人员专注于视频分析,并评估了两种策略以提供最终的视频预测。第一种策略将每个时间戳中生成的动作单元序列折叠成一个向量,该向量是所有时间步长的平均值。这些特征被输入到三个静态模型中:支持向量机 (SVM)、k近邻 (k-NN) 和多层感知器 (MLP)。第二种策略采用带有注意力机制的序列双向 (Bi)LSTM,从视频每一帧提取的特征序列中提取视频预测结果。

作为静态模型的替代方案,作者采用了一种序列模型,该模型假设相关信息不仅存在于帧本身,也存在于帧的顺序中。作者使用双向长短期记忆网络 (BiLSTM) 作为序列模型。

BiLSTM 层以双向方式运行,使其能够收集 LSTM 隐藏状态 $h_1, h_2, \dots, h_N$ 两个方向上的序列信息。为了从 BiLSTM 层获得情感预测结果,需要根据以下公式将每个特定方向的输出嵌入连接起来:

$$h_i = \rightarrow h_i \leftarrow h_i, \text{ 其中 } h_i \in \mathbb{R}^{2L}, \quad (4)$$

其中 $\rightarrow$ 表示连接运算符, L 表示每个 LSTM 的大小。

以下注意力机制的总体目标是在检测整个视频中的情绪的同时,区分与特定帧关联的最相关的活跃单元。研究人员使用了通过多层感知器 (MLP) 评估的每个嵌入的实际贡献,并采用非线性激活函数,类似于 [63]。

注意力函数是一种应用于隐藏状态的概率分布,它使我们能够获得视频每一帧所接收的注意力权重。模型估计 LSTM 输出 h_i 与权重 a_i 的线性组合。最后,将得到的特征向量输入到用于情感识别的最终任务特定层。作者使用了一个包含八个神经元的全连接 (FC) 层,后接一个 SoftMax 激活函数,该函数返回情感类别的概率分布。

VER 中的一系列显著方法依赖于自注意力机制的实现 [61]。

自注意力机制是通过估计潜在空间中的点积相似度来实现的,其中查询 q 、键 k 和值 v 通过可训练的投影矩阵 W_q 、 W_k 、 W_v 从输入特征表示中学习,并基于它们计算结果表示:

$$\text{一个} = \text{softmax} \left(\frac{qk^T}{\sqrt{d}} \right) \text{ 在,} \quad (5)$$

其中 d 是潜在空间的维度。

这一思想已被广泛应用于解决各种情绪/情感识别任务 [57,64,65]。参考文献 [64] 提出了一种基于 Transformer 的方法。

对于未对齐的序列,并执行音频、视频和文本三种模态的融合。

首先,将每种模态的数据通过一维卷积层投影到所需的维度,然后经过一组Transformer模块。具体来说,每种模态都添加了两个Transformer模块。这些表示随后被连接起来,并在每个模态分支上对联合表示应用另一个Transformer模块。最后,将三个分支得到的表示连接起来,用于最终的情感分类。

参考文献[66]的作者近期提出使用Emoformer模块进行VER任务。Emoformer的编码器结构与Transformer类似,但缺少解码器部分。前文所述的自注意力层用于有效提取包含情感信息的特征,残差结构则保证了原始信息的完整性。最后,映射网络解耦特征并降低特征维度。

对于给定的输入特征 U ,根据 U 计算出三个矩阵:查询矩阵 $Q \in \mathbb{R}^{T_Q \times d_Q}$ 、键矩阵 $K \in \mathbb{R}^{T_K \times d_K}$ 和值矩阵 $V \in \mathbb{R}^{T_V \times d_V}$:

$$[Q, K, V] = U W_Q, W_K, W_V, \quad (6)$$

其中, T_Q 、 T_K 、 T_V 分别表示序列 Q 、 K 、 V 的长度; d_Q 、 d_K 、 d_V 分别表示序列 Q 、 K 、 V 的维度;且 $W_Q \in \mathbb{R}^{d_U \times d_Q}$, $W_K \in \mathbb{R}^{d_U \times d_K}$, $W_V \in \mathbb{R}^{d_U \times d_V}$ 。

将多个自注意力层连接起来,得到一个多头注意力层:

$$\text{MultiHead}(A) = \text{Concat}(A_1, \dots, A_h)W, \quad (7)$$

其中 $A_1, \dots, A_h$ 是自注意力层的输出, h 是层数, W 是权重参数。

通过与归一化层的残差连接来归一化多头注意力层的输出,并采用前馈层来获得自注意力部分的输出:

$$\begin{aligned} N &= \text{Norm}(A + \text{MultiHead}(A)), \\ F &= \max(0, N W_1 + b_1) W_2 + b_2, \\ G &= \text{Norm}(F + \text{MultiHead}(F)), \end{aligned} \quad (8)$$

其中 W_1 、 W_2 为权重参数, b_1 、 b_2 为偏置参数。

最后,将原始特征 U 和自注意力部分的输出 G 通过残差结构连接起来,并采用映射网络来获得最终输出 E :

$$H = U \oplus G, E = \text{Map}(H), \text{其中Map} \quad (9)$$

代表映射网络,它由五个全连接层组成。结合以上方程,我们可以使用Emo生成器从不同的输入通道获得不同模态的情感向量:

$$[E_a, E_v, E_t] = \text{情绪形式}(U_a, U_v, U_t), \quad (10)$$

其中 U_a 、 U_v 、 U_t 分别代表音频、视觉和文本特征的原始输入, E_a 、 E_v 、 E_t 代表相应模态的情感向量。

参考文献[67]的作者提出了一种解决对话视频中情感识别问题的方法。研究人员提出了基于递归的单模态编码器(RUME),其灵感来源于著名的Transformer架构[61]。作者添加了全连接网络和残差运算,以提高情感识别系统的表现力和稳定性。所提出的结构可以形式化为:

$$\begin{aligned} X_{rr} &= \text{LN}(X + \text{RNN}(X)), \\ X_{fr} &= \text{LN}(X + X_{rr} + \text{FF}(X_{rr})), \end{aligned} \quad (11)$$

其中 X 表示语音的特征矩阵; $\text{RNN}(\cdot)$ 、 $\text{LN}(\cdot)$ 和 $\text{FF}(\cdot)$ 分别表示循环神经网络层、归一化层和前馈网络层。在本研究中, $\text{RNN}(\cdot)$ 和 $\text{LN}(\cdot)$ 默认使用双向门控循环单元 (GRU) 和层归一化,而前馈层由两个全连接网络组成,其表达式如下:

$$\text{FF}(X_{rr}) = \text{DP}(\text{FC}(\text{DP}(\alpha(\text{FC}(X_{rr}))))), \quad (12)$$

其中 $\text{FC}(\cdot)$ 和 $\text{DP}(\cdot)$ 分别表示全连接网络和 dropout 操作, $\alpha(\cdot)$ 表示激活函数。

在本小节中,我们分析了基于视觉数据处理的最新情感识别系统 (SOTA SER)。深度学习 (DL)分类器通常用于识别情感。为了达到最佳性能,通常会采用深度神经网络 (DNN)、卷积神经网络 (CNN)和循环神经网络 (RNN)的框架,并结合注意力机制进行改进。

2.2 唇读技术的最新进展

在本小节中,我们将评估 VSR 方法论的最新进展。有关这些问题的更详细研究可以在相关研究[68,69]中找到。

传统的视频识别 (VSR)系统包含两个处理阶段:首先从视频数据中提取特征,然后进行唇语识别。传统方法通常在嘴部感兴趣区域 (ROI)周围提取特征。然而,近年来,随着深度学习 (DL)技术的发展,特征提取步骤已被深度瓶颈架构所取代。

第一个用于区分视觉音素的 CNN 图像分类器由文献[70]中的研究人员训练而成。文献[71]中,研究人员利用深度瓶颈特征进行单词识别,以充分利用深度卷积层并探索高度抽象的特征。类似地,文献[72]中也将其应用于视频的每一帧。

参考文献[73]中的研究人员提出使用3D卷积滤波器来处理嘴唇的时空信息。一个基本的二维卷积层,从 C 通道到 C 通道 (无偏置,步长为1),计算结果为[74]:

$$[\text{conv}(x, w)]_{tcij} = \sum_{c=1}^C \sum_{i=1}^{k_h} \sum_{j=1}^{k_h} w_{c, i+j, j} x_{c, i+j, j} \quad (13)$$

对于输入 x 和权重 $w \in \mathbb{R}^{C \times C \times k_w \times k_h}$,我们定义 $x_{cij} = 0$,当 i, j 超出界限时。

时空卷积神经网络 (STCNN)可以通过在时间和空间两个维度上应用卷积来处理视频数据[75],具体如下:

$$[\text{stconv}(x, w)]_{tcij} = \sum_{c=1}^C \sum_{t=1}^{k_t} \sum_{i=1}^{k_h} \sum_{j=1}^{k_h} w_{c, t+i, i+j} x_{c, t+i, i+j} \quad (14)$$

随后,文献[76]的研究人员将注意力机制应用于嘴部感兴趣区域 (ROI)。他们提出了观察 (Watch)、聆听 (Listen)、注意 (Attend)和拼写 (Spell)网络,该网络能够学习从一段无音频的说话人脸视频中预测正在发音的句子中的字符。作者将输出字符序列 $y = (y_1, y_2, \dots, y_l)$ 中的每个字符 y_i 建模为输入图像序列 x 中先前字符的条件分布,用于唇读。因此,我们将输出概率分布建模为:

在 $w \times h = x \times y, 1, 2, \dots, n$

$$P(y_i | x^{(i-1)}, y^{(i-1)}) = \prod_{i=1}^l P(y_i | x^{(i-1)}, y^{(i-1)}), \quad (15)$$

该模型由三个关键组件构成:图像编码器Watch、音频编码器Listen和字符解码器Spell。每个编码器将相应的输入序列转换为固定维度的状态向量 s 和编码器输出序列。

$o = o_1, \dots, o_p, p \in (n, m)$ 。解码器接收来自两个编码器的状态向量和注意力向量,并生成输出字符序列的概率分布。

$$\begin{aligned} \text{对, 在} &= \text{Watch}(x_{\text{在}}), \\ \text{为, 到} &= \text{聆听}(x_{\text{到}}), \\ P(y | x_{\text{在}}, x_{\text{到}}) &= \text{法特}(s_{\text{在}}, s_{\text{到}}). \end{aligned} \quad (16)$$

模型中的三个模块是联合训练的。

最近有人提出了几种唇读训练策略和深度神经网络[77]。

由于有大量公开可用的语料库,例如野外唇读数据集 (LRW) [78]和野外唇读句子数据集(LRS) [76],它受到了广泛关注。

参考文献[76]的作者提出了一种图像编码器,该编码器由一个卷积模块和一个循环模块组成:卷积模块为每个输入时间步 x 生成图像特征 f ,循环模块生成固定维度的状态向量 s 和一组输出向量 o :

$$\begin{aligned} f_{\text{在}} &= \text{CNN}(x_{\text{在}}), \\ \text{在 } h_{i,i} &= \text{LSTM } f = h_{i,i+1}, \\ \text{比} &= 1. \end{aligned} \quad (17)$$

大多数最先进的唇读方法都遵循类似的策略,包括视觉编码器、时间模型和分类层。参考文献[11]的作者提出了一种改进的自蒸馏方法。该方法基于使用蒸馏训练一系列具有相同架构的模型的思想,并且最近已应用于唇读领域。教师网络提供额外的监督信号,包括类间相似性信息。待优化的总体损失 L 是硬目标交叉熵损失 LCE 和软目标Kullback-Leibler (KL)散度损失 LKD 的加权组合:

$$L = LCE(y, \delta(zs; \theta s)) + \alpha LKD(\delta(zs; \theta s), \delta(zt; \theta t)), \quad (18)$$

其中 zs 和 zt 分别表示学生网络和教师网络的嵌入表示; θs 和 θt 分别表示学生模型和教师模型的可学习参数; y 是目标标签; $\delta(\cdot)$ 表示 SoftMax 函数; α 是两项之间的平衡权重。

视觉编码器最初在文献[79]中提出,此后在后续研究中得到广泛应用和改进[80]。同时,最新的进展包括时间模型和训练策略。双向GRU、LSTM以及多尺度时间卷积网络 (MSTCN)是最常用的时间模型[14]。

最近,作为 RNN 分类的替代方案,使用注意力机制和时间卷积网络的 Transformer 模型开始被使用[81,82]。

Vision Transformer (ViT) [83]首先将图像按一定大小分割,然后将每个图像块线性投影到标记上,从而将图像转换为一系列图像块标记。

Transformer编码器由一系列模块组成,每个模块包含一个带有前馈网络的多头自注意力 (MSA)网络。它包含一个隐藏层扩展比为 r 的两层多层感知器,并在第一个线性层之后应用一个高斯误差线性单元 (GELU)非线性层。每个模块之前应用层归一化 (LN),每个模块之后应用残差捷径。ViT的输入 x_0 以及第 k 个模块的处理可以表示为:

$$\begin{aligned} x_0 &= x_{\text{cls}} x_{\text{patch}} + x_{\text{pos}}, y_k \\ &= x_k - 1 + \text{MSA}(\text{LN}(x_k - 1)), x_k = \\ &= y_k + \text{FFN}(\text{LN}(y_k)), \end{aligned} \quad (19)$$

其中 $x_{cls} \in R^{1 \times C}$ 和 $x_{patch} \in R^{N \times C}$ 分别是CLS标记和补丁标记， $x_{pos} \in R^{(1+N) \times C}$ 是位置嵌入。 N 和 C 分别是补丁标记的数量。

分别是嵌入的维度。

然而,训练这类模型需要强大的计算能力以及大量的训练数据,因此,迁移学习是此类情况下常用的方法之一。

学习[84] 一种利用预训练模型来改进预测的方法

任务虽有不同但类似,因此可以减少训练时间和数据需求。

以及提高神经网络的性能。

为了开发适用于实际应用的唇读系统,高质量的训练和测试至关重要。

语料库至关重要。近年来兴起的一种现代趋势是基于网络的语料库:从 YouTube 或电视节目等开放资源收集的语料库[85]。最著名的

其中包括LRW [78]、LRS2-BBC和LRS3-TED语料库[86]等。最先进的深度学习方法与大规模视觉语料库的结合取得了巨大的成功。

获得了显著的认可度,甚至超越了人类的表现。

3. 研究语料库

选择合适的视听语音语料库最终是构建语音识别系统的关键任务。

系统之所以如此,是因为最先进的解决方案通常基于数据驱动的机器学习方法。

为了评估情绪对VSR的Acc的影响,有必要进行以下操作:

用于训练模型的充足语料库。该语料库必须在以下方面满足深度学习的要求。

说话人数、词汇量、重复次数等。符合

收集所有必要的参数具有挑战性;因此,有必要进行单独的研究。

对现有的公开可用的视听语料库和情感语音进行分析

选择最适合完成任务的方案。

我们审查了现有的28个用于视频语音识别 (VSR)和音视频的基准测试语料库。

语音识别 (AVSR)适用于我们相关研究[68]中训练深度学习模型。然而,所有这些现有的公开语料库(均在实验室条件下录制)

(并从互联网上收集)仅包含中性情绪的语音录音,或

包含极少量未标记情绪类别的情绪/数据。因此,它

可以说,现有的为语音识别设计的语料库并不适合用于评估语音识别能力。

情绪对SR的Acc的影响。

因此,我们需要考虑包含情感语音的语料库。然而,大多数

现有的情感语音语料库是为识别不同类型的情绪而创建的。

而不是为了语义识别。因此,我们需要分析现有的情感语料库。

它们可用于SR任务,以及情绪类别的识别。如表1所示,

最常用的情感语音基准语料库及其结果列于下方。

主要特点。

表1.情感语音AV语料库比较。#表示数据数量。

无人	语言	年	健康)状况	演讲嘉宾	# 话语	# 情绪
1 FABO [87] 2	-	2006	实验室	23	246	9
eINTERFACE 05 [88]	英语	2008	实验室	42	1166	6
3 IEMOCAP [89]	英语	2008	实验室	10	3060	9
4 SAVEE [90]	英语	2009	实验室	4	480 (3个短语)720	7
5 RML	多	2010	实验室	-	-	6
6 周[91]	英语	2012	实验室	150	959	27
7 AFEW [92]	英语	2012	荒野	330	1809	7
8 RECOLA [93]	法语	2013	实验室	46	-	-
9 CREMA-D [94]	英语	2014	实验室	91	7442 (12 个短语)	6
10 NNIME [95]	中国人	2017	实验室	44	-	6
11 RAVDESS [96]	英语	2018	实验室	24	4904 (2 个短语)581	8
剩余 12 [97]	俄语	2018	实验室	10	-	9
13 PolishDB [98]	抛光	2018	实验室	16	560	7
14 MELD [99]	英语	2018	荒野	-	1433	7
15 CHEAVD v1./v2 [100]	中国人	2018	荒野	527	7030	6-8

表1.续

无人	语言	年	健康)状况	演讲嘉宾	# 言语 # 情绪	
16 HEU 情绪[101]	多	2020	荒野	8984	16,569	10
17 AVSP-ESD [102]	多	2021	荒野	—	13,285	12
18 CelebV-HQ [103]	英语	2022	荒野	15,653	35,666	8
19 MimicME [104]	多	2022	荒野	4700	280,000	20
20 EmoSet [105]	多	2023	荒野	—	118,102	6

FABO [87]是一个用于自动分析的双模态面部和身体姿势语料库。人类非语言情感行为。该语料库包含约1900个视频。两台摄像机同时记录面部表情。其中一台是面部第一个是摄像机,第二个是随身摄像机。该语料库是第一个结合面部图像的语料库。并以有组织的方式记录身体活动。该视听语料库包含以下录音:共有23位发言者,其中男性11位,女性12位。年龄介于18岁至50岁之间。作者总共记录了九种情绪:愤怒、恐惧、惊讶、快乐、厌恶、无聊、担忧、悲伤、不安。

eINTERFACE 05 [88]是一个可作为基准的 AV 情感语料库。用于测试和评估视频、音频或联合音视频情感识别方法的语料库。它收录了 14 个不同国家的 42 位说话者说英语短语的录音。发言者中,34人为男性,8人为女性。录音内容包括仅拍摄头部区域,且背景为深色。

IEMOCAP [89]语料库包含 151 个录制对话的视频。它有每场会议两位发言者,因此语料库中共有 302 个视频。每个视频都进行了标注。它包含九种情绪以及效价、唤醒度和支配度。约 12 小时的音视频数据,包括视频、语音、面部动作和文本转录。

SAVEE [90]是一个语料库,由四位说话者发表讲话的录音组成。三个短语分别表达七种不同的情绪,十二个短语表达中性情绪。句子选自标准TIMIT语料库[106],并经过语音平衡处理。针对每种情绪。当说话者观看视频片段时,这些情绪被记录下来。阅读显示屏上的文字。

RML (<http://www.rml.ryerson.ca/rml-emotion-database.html>,访问日期(2023年10月25日)是迄今为止为数不多的可用多语言情感语料库之一。包含六种不同情绪的720个样本。每位参与的演讲者都会表达几种不同的情绪。语言。我们收集了八位说话者的视频录像,他们说了六种语言。(英语、普通话、乌尔都语、旁遮普语、波斯语和意大利语)。样本记录方式如下:AV格式在简单的前置摄像头,每个样本的平均持续时间为大约 5 秒。

SEMAINE [91]语料库是一个带有情感色彩的多模态标注记录。人与有限代理之间的对话。它包括大约共有150位发言者,共进行了959次对话,平均每次对话时长为5分钟。总计它包含27种不同的情感类别。高质量的录音使用了五种不同的音频设备。摄像头和四个麦克风。

AFEW [92]是一个从电影中提取的情感语料库,代表了真实世界的情境。该语料库包含展示自然头部姿势和动作的录音,真实世界的光照条件、同一画面中的多个扬声器、各种各样的遮挡情况等等。它收集自54部好莱坞电影,包括1809个视频。然而,由于由于版权原因,只有一小部分语料库是公开的。

RECOLA [93]是一个法语自发协作和情感互动的视听语料库。说话者在视频会议中完成一项任务时被录制下来。需要合作。共有 46 位发言者参与了录音,其中包括:27名女性和19名男性。所有受访者都讲法语,但母亲各不相同。语言:33 种法语、8 种意大利语、4 种德语和 1 种葡萄牙语。

CREMA-D [94]是一个包含 7442 个视频片段的语料库,这些片段来自 91 位演员(48 位男性和 43 位女性),他们来自不同的种族和民族。演员们朗读了 12 个选定的句子。这些句子分别用六种不同的情绪(愤怒、厌恶、恐惧、快乐、中性、悲伤)和四种不同的情绪水平(低、中、高、未指定)来表达。

NNIME [95]是一个中文交互式多模态情感语料库。它包含44位说话者自发互动的录音,其中女性24位,男性20位。每对说话者被要求自发地表演一段3分钟的短场景。总体目标是展现六种情绪之一(愤怒、沮丧、快乐、中性、悲伤和惊讶)。它是首个系统收集、整理并公开发布的大规模中文交互语料库。

RAVDESS [96]语料库包含 4904 段音视频录音,录音中的演员用中性的北美口音朗读两句词汇匹配的陈述句。共有 24 位专业演员(12 位男性和 12 位女性)参与了录音,他们试图展现八种不同的情绪(恐惧、悲伤、惊讶、快乐、愤怒、厌恶、平静和中性)。每种情绪表达都以两种强度(正常、强烈)呈现,并配有一个中性表情。

RAMAS [97]是首个俄罗斯视听情感语料库。十位年龄在 18 至 28 岁之间的年轻演员(五男五女)参与了录制。他们分别表达了六种基本情绪之一(愤怒、悲伤、厌恶、快乐、恐惧和惊讶)。该语料库包含约 7 小时的高质量视频录像,记录了说话者的面部表情、语音、动作捕捉数据和生理信号。这些录像由 21 位标注员进行了标注。

PolishDB [98]可能是目前唯一可用的波兰语语料库。该语料库的录音由十六位专业演员(八男八女)完成。语料库涵盖以下几个模态:面部表情、肢体动作和手势以及语音。数据根据埃克曼的情感分类法标注了六个基本情感类别。为了检验表演质量,所有录音均由专家和志愿者进行评估。

MELD [99]是一个多模态多方对话语料库,用于识别电视剧对话中的情感。它包含来自电视剧《老友记》的 1433 场对话中的约 13,000 条语音。每条语音都标注了情感和情绪标签,涵盖音频、视频和文本三种模态。参与者人数有限,其中 84% 的对话由六位主演完成。

CHEAVD [100]是一个中文自然情感视听语料库。它包含约 140 分钟的情感语音,这些语音提取自电影、电视剧和访谈节目。共有 238 位说话者参与了语料库的收集,年龄涵盖儿童到老年人。该语料库是首个大规模的中文自然情感语料库,涵盖多模态和自然情感。

HEU Emotion [101]是目前最大的基于视频的音视频情感识别语料库,包含 19,004 个视频片段。视频中的说话者包括亚洲人、非洲人和白种人。HEU 语料库的录制是在不可控的自然条件下进行的,涵盖了面部和身体姿态的多角度变化、局部遮挡、光照和表情强度等多种因素。

AVSP-ESD [102]语料库包含 13,285 个音视频文件,这些文件收集自电影、电视剧和 YouTube,包含语音和非语音内容。它涵盖了十二种不同的自然情绪(无聊、中性、快乐、悲伤、愤怒、恐惧、惊讶、厌恶、兴奋、愉悦、痛苦、失望),每种情绪又分为两个强度等级。此外,它还是一个多语言语料库,包含中文、英文、法文、俄文和其他语言的录音。

CelebV-HQ [103]是一个大规模的视频面部属性语料库。它包含 35,666 个视频片段,分辨率至少为 512×512 ,涉及 15,653 位说话者。所有视频均经过人工标注,标注了 83 个面部属性,涵盖外貌、动作和八种不同的情绪。该语料库在年龄、种族、亮度稳定性、运动平滑度、头部姿态多样性和数据质量参数方面均具有多样性。

MimicME [104]语料库包含 4700 位说话者的录音。这些录音以四维 (4D) 视频的形式呈现,记录了受试者展现的多种面部表情,共计超过 28 万个视频文件。该语料库涵盖了年龄、性别和种族的多样性。并非所有文件都已标注了相应的情绪。

EmoSet [105]语料库旨在预测人们对视觉刺激的情绪反应。EmoSet 总共包含 330 万个文件,但其中只有 118,102 个文件经过人工标注。尽管如此,它仍然是迄今为止最大的情绪语料库。

EmoSet 在不同的情感类别之间取得了良好的平衡。

根据分析结果,我们可以得出结论:现有的大多数语料库并不适用于情感语音唇读任务。许多语料库是为情感识别而非语音识别而建立的。因此,它们缺乏所需的词汇量以及目标情感短语的重复次数。

我们从列表中选择了两个公开可用的情感语料库,适用于语音识别 (SER)和语音识别 (VSR)评估。在科学文献中已有的语料库中,只有这两个语料库拥有足够的数据量来训练基于神经网络的唇读系统,并且满足所需的参数数量,例如说话人数量、词汇量、重复次数、情感平衡数据等。所选语料库的详细信息如下。

3.1. RAVDESS语料库瑞

尔森情感语音和歌曲视听数据库 (RAVDESS)语料库[62]包含24位演员的4904份视听录音,男女比例均衡 (12名女性和12名男性)。该语料库在实验室条件下录制。这些演员以标准的北美口音清晰地表达两个词汇匹配的短语 (见表2) 。每个短语由演员通过两个声道 (语音、歌曲)和两种情感强度 (正常、强烈)进行演绎。语音声道代表八种情感 (中性 (NE)、快乐 (HA)、愤怒 (AN)、悲伤 (SA)、厌恶 (DI)、恐惧 (FE)、平静 (CA)、惊讶 (SU)),而歌曲声道则包含六种情感 (不包括DI和SU) 。

表 2. RAVDESS 语料库中的短语及其标签。

标签	短语
凯特	孩子们在门口聊天。
这	几只狗坐在门口。

我们根据说话人独立性将录音分为三个样本:训练集 (前18位说话人,占75%)、开发集 (接下来的两位说话人,占8%)和测试集 (剩余的四位说话人,占17%)。图1展示了三个子集中每种情绪的录音分布情况,图2则展示了每个短语的录音分布情况。




图 1. RAVDESS 语料库的训练/开发/测试子集中每种情绪的录音分布。

3.2. CREMA-D 身体乳

众包情感多模态演员数据集 (CREMA-D) [94]包括 7442份AV录像,涉及91名演员,男女比例均衡 (43名女性和48名男性)。语料库是在实验室条件下录制的。这些演员说了十二个短语 (见)。表3)。这些短语由演员以三种不同的情感强度 (低、中、高)说出。高)和六种情绪 (NE、HA、AN、SA、DI、FE)。中性短语录音不包含在内。以不同强度呈现。




图 2.训练/开发/测试子集中每个短语的录音分布
RAVDSS语料库。

表 3. CREMA-D 语料库中的短语及其标签。

标签	短语	标签	短语
DFA	别忘了带外套。	IWW	我想知道这是怎么回事。
IEO	现在是十一点。	MTI	也许明天会冷。
国际移民组织	我正在去开会的路上。	TAI	飞机几乎满了。
ITH	我觉得我有个医生预约。TIE ITS		事情就是这样。
	我觉得我以前见过这个。	TSI	表面很滑。
IWL	我想要一个新的闹钟。	WSI	我们几分钟后就停下来。

考虑到数据的均匀分布,我们将数据分为三个子集。按说话者的年龄、性别以及说话者独立性划分:训练组 (70%)、开发组 (10%) 和测试组 (20%)。三种情况下,每种情绪的录音分布情况如下。图 3 展示了子集,而图4则展示了录音的分布情况。每句。




图 3.训练/开发/测试子集中每种情绪的录音分布
CREAM-D 身体乳。




图 4. CREMA-D 语料库的训练/开发/测试子集中每个短语的录音分布。

4. 方法我们考虑三种

不同的情感语音唇读策略,并将它们与经典的唇读模型 (在情感中性录音上训练的唇读模型)进行比较。

我们的方法包括视觉语音数据预处理,然后分为两个主要层级 (见图5)。第一层级解决情感识别任务;第二层级根据情感类型使用特定的视觉语音识别模型。情感策略分为: (1)6 种情感, (2)3 种效价,以及 (3)二元 (情感/中性数据)类别。在本节中,我们将介绍基于 EMO-3DCNN-GRU 网络的视觉语音情感识别部分。然后,我们将描述基于3DCNN-BiLSTM 架构的唇读模型。这两个模型分别针对六种、三种和两种情感类别进行了专门训练。




图 5. EMOLIPS 一般处理流程,根据三种情绪策略: (a) 6 种情绪, (b) 3 级效价, (c)二元。

图5所示的 EMOLIPS 方法的三种策略均基于相同的F (K-1)原理。该方法的输入数据为由K帧组成的视觉信号 $V = \{F\}$ 。使用人脸关法[15]检测人脸和唇部区域图像。人脸和唇部图像经过归一化、缩放至正确的(M-1)步长,并写入相应的列表 $I^0, F^2, \dots$, 键点检测算 $= \{I\}$ (用于人脸图像)。

分析每秒帧数 $\frac{0.2}{L}, \frac{0.2}{L}, \dots, \frac{0.2}{L}$ (用于唇部图像)。对于情绪识别,仅需五帧L (FPS) 的IL = {I 帧。步长值范围取决于视频的 FPS; M是缩减后剩余的帧数。根据情感策略,面部图像被输入到三个模型之一:(1)用于六种情感识别的情感模型EMO6classes ,(2)用于三种情感效价识别的情感模型EMO3classes ,以及 (3) 用于二元分类的情感模型 EMO2classes 。情感模型预测情感类别为Pemo。根据获得的标签,唇部图像被输入到特定的唇读模型LIPPemo中,该模型使用带有预测情感的短语进行训练。

最后,唇读模型预测视觉信号上呈现的短语类别Pphrase。
所提出的 EMOLIPS 方法的算法如算法1 所示。

算法 1 EMOLIPS 方法

```

1:过程PHRASEPREDICTION(V,S)
2:  $V \leftarrow \{F^0, F^1, \dots, F^{(K-1)}\}$  输入视觉信号
3:形成所需帧编号列表F 红色的 =  $\{0, \text{step}, \dots, \text{step} \cdot (i-1)\}$ ,其中
   step是帧抽取步长; i 的取值范围为 0 到M,M 表示抽取后剩余的帧数。
   减少。
4: 对于j  $\leftarrow 0$  到 K执行 处理视频帧
5: 人脸检测  $F$  和嘴唇我  $\{$  使用[15]在  $F_j$ 中生成图像
6: 重塑唇部图像  $I$   $\{ = \text{Reshape}(I \{$  (尺寸L) sizeL是唇部的正确尺寸
7: 唇部图像归一化  $I$   $\{ = \text{Normlips}(我 \{$ 
8: 添加嘴唇图片  $\{$  致伊利亚州
9: 如果j 在 F 中 然后是红色
10: 重塑唇部图像  $I$   $\{ = \text{Reshape}(I \{$  sizeF) sizeF是脸部的正确大小
11: 唇部图像归一化  $I$   $\{ = \text{Normfaces}(我 \{$ 
12: 添加嘴唇图片  $\{$  致IF
13: 如果结束
14:结束
15: 如果S 是 6 情绪策略,那么 S 指的是策略
16: 预测情绪类别Pemo = argmax(EMO6classes (IF))
17: 否则,如果S 是 3 级价策略,则
18: 预测情绪类别Pemo = argmax(EMO3classes (IF))
19: 别的 二元策略
20: 预测情绪类别Pemo = argmax(EMO2classes (IF))
21:结束 if
22: 预测短语类别Pphrase = argmax(LIPPemo (IL))
23: 返回短语
24:程序结束

```

4.1 数据预处理

VER模型和唇读模型都需要对原始视频进行一定的预处理。

语音数据。识别每个视频序列中的人脸ROI是第一步。我们使用 MediaPipe 开源库检测每一帧中的人脸 ROI [15]。对于两者在分类任务中,我们将视频分割成 2 秒的片段;最终预测结果是:所有线段概率向量之和的最大值。然后我们进一步考虑。

每个模型的预处理方法都不同。

我们应用了类似于[107]的情感识别预处理流程,其中包括:

(1)将视频下采样至 5 FPS (每 2 秒 10 帧),以确保相同效果

(2)循环神经网络的时间性处理条件;(3)通道归一化

(3)将人脸图像调整为 224×224 像素。唇读预处理

包括使用相同的方法 (MediaPipe)在每一帧上检测嘴部 ROI,

裁剪后,我们将嘴部图像调整为 $88 \times 88 \times 3$ 。为了保持嘴部清晰可见。

为了保持比例,我们用沿方向的平均像素值将图像填充到所需大小。

图像本身的垂直方向。然后我们使用线性归一化技术。我们不应用

现阶段不会进行任何帧率降采样,而是使用全部 60 帧来制作 2 秒的片段。

数据预处理在我们相关的研究中表现出最高的性能结果[20];

我们在目前的研究中保持不变。

4.2 视觉情绪识别

为了高效地进行情感识别,我们使用了参考文献[107]中提出的开源静态2DCNN模型。该模型已证实其在情感识别方面的性能。

与其他开源模型相比,我们的任务[108]。与文献[109]类似,我们通过添加循环层将基于ResNet50架构的2DCNN模型转换为3DCNN模型,以捕捉面部表情随时间的变化。然而,与之前的最佳方法[107,109]不同,我们从CNN的不同残差块中提取特征。我们将权重冻结到第二个残差块,并在新的研究语料库中微调第三个和第四个残差块的权重。这种方法允许我们结合不同尺度的特征,从而捕捉更大和更小的面部特征变化,这在目标检测中得到了广泛应用[110]。我们使用GRU作为RNN,因为它计算量更小,且性能不逊于LSTM [111]。每个GRU 层提取一个大小为 128 的特征向量。为了将每个特征向量的贡献融合到情感分类中,我们使用门控融合机制[109,112],其计算如下:

$$g_a = \tanh(W_a a), \quad (20)$$

$$g_b = \tanh(W_b b) \quad (21)$$

$$z = \sigma(W_z [a, b]), \quad (22)$$

$$g = z g_a + (1 - z) g_b, \text{ 其中} \quad (23)$$

$\tanh(\cdot)$ 为 $\tanh$ 激活函数, W_a 、 W_b 和 W_z 分别为特征向量 a 、 b 和 z 的权重矩阵。权重矩阵的大小为 $N \times U$, 其中 N 表示特征向量中的特征数量, U 表示输出神经元的数量, 等于 64。 g_a 和 g_b 分别是特征向量 a 和 b 的门控表示。 $\sigma(\cdot)$ 为 sigmoid 激活函数, 表示元素级乘积, g 为用于后续分类的最终特征向量。

4.3. 唇读我们使

用 3DCNN [42] 和 BiLSTM 来解决情感语音唇读问题 (参见图6 的右侧部分)。




图 6. EMO-3DCNN-GRU 模型 (左) 和 LIP-3DCNN-BiLSTM 模型 (右)。

与其他情感模型不同,该模型基于 ResNet18 [42]架构。

我们采用更简单的模型架构,因为唇部识别需要分析视频的每一帧,这会增加计算量。此外,与整张脸相比,每帧中覆盖嘴唇的区域要小,因此无需更复杂、更深层的模型。然而,由于唇读模型中分析的帧序列是情感模型的六倍,我们使用了双向长短期记忆网络 (BiLSTM)。该BiLSTM网络由两个BiLSTM层组成,每个层包含512个连续的神经元。

我们的模型之前经过训练,在 LRW语料库上实现了唇读的 SOTA 结果[8]。

三维卷积神经网络 (3D CNN) 输入一幅图像,该图像依次经过第一个 3D 卷积层和池化层,然后是四个残差块,每个残差块包含 3D 卷积层,每个卷积层重复两次。接下来是 3D 平均池化层和重塑层。对于长度为T (等于 60 帧)的序列中的每一幅图像,3D CNN 返回一个特征向量 $r_i = [f_1, \dots, f]$ 。

其中N是特征的数量, $i \in \{1, \dots, T\}$ 。

接下来是序列到序列类型的第一个双向长短期记忆网络 (BiLSTM)层,它由以下部分组成:

LSTM (矩阵h由两个 LSTM 的输出连接而成)。最后一个 LSTM1和前向及后向 分别对应LSTM1)。它返回一个新特征。

BiLSTM 层为序列到一类型;它以特征矩阵h作为输入,并返回序列最后一个时间步的最终特征向量s,以执行下一次分类。一般来说,该模型的运行可以用以下公式表示:

$$\rightarrow h_i = \text{LSTM1} (r_i), \quad (24)$$

$$\leftarrow h_i = \text{LSTM1} (r_i), \quad (25)$$

$$h = \left[\begin{matrix} \rightarrow h_1 & \leftarrow h_1 \\ \rightarrow h_2 & \leftarrow h_2 \\ \vdots & \vdots \end{matrix} \right], \quad (26)$$

$$\rightarrow s_i = \text{LSTM2} (h), \quad (27)$$

$$\leftarrow s_i = \text{LSTM2} (h), \quad (28)$$

$$s = \left[\begin{matrix} \rightarrow s_1 & \leftarrow s_1 \\ \rightarrow s_2 & \leftarrow s_2 \\ \vdots & \vdots \end{matrix} \right]. \quad (29)$$

5. 实验结果

为了开发和研究 EMOLIPS 方法,我们进行了一系列实验。

首先,我们训练了三个情感识别模型。然后,我们训练了几个唇语识别模型。最后,我们应用训练好的模型来评估所提出的 EMOLIPS方法的性能。

我们使用三个指标评估实验结果:平均准确率 (mAcc)表示在情绪/效价类别背景下对短语识别的评估;准确率表示不考虑情绪/效价的短语识别性能;非加权平均召回率 (UAR)、准确率和 F1 值 (F1) 用于评估 EMO-3DCNN-GRU 模型的情绪识别能力。


我们使用随机梯度下降 (SGD)优化器和余弦退火热重启[113]调度器训练情感模型,训练周期为100个epoch,重启次数为5次。学习率从0.001到0.0001不等。唇部模型则使用Adam优化器进行训练,学习率为0.0001。模型参数和训练参数均通过网格搜索实验确定。

5.1 视觉情绪识别

情绪识别模型旨在用于特定任务:(1)六种情绪识别,(2)三级效价识别,以及 (3)二元情绪识别。我们排除了

按照参考文献[109]的作者所进行的研究建议,采用类别加权。

战略	拉夫德斯				CREMA-D				多体						
	UAR F1 加速度平均值		UAR F1 加速度平均值		UAR F1 加速度平均值										
6种情绪	84.2	83.9	83.4	三级价态	83.8	69.2	68.8	68.8	85.9	68.9	70.6	70.0	70.3	81.7	70.3
93.8	91.2	95.0	二元	92.7	91.6	96.9				93.3	84.4	88.8	84.9	80.1	89.3
										86.4	78.8	84.7	82.4	79.5	90.1
										84.8					84.0



使用十折交叉验证方案对相同的语料库进行了验证,如上文所述。

表5. 对比结果表明,我们的方法至少具有1%的优势。
两个语料库均达到了最先进的水平。

表 5.情绪识别准确率与 SOTA 在 10 折交叉验证中的比较。

拉夫德斯				CREMA-D			
接近最大均值标准差				接近最大均值标准差			
人类[96]	-	75.0	-	人类[94]	-	58.2	-
材料[114]	-	52.0	-	MATER [114]	-	60.0	-
VO-LSTM [115]	-	60.5	-	VO-LSTM [115]	-	66.8	-
我们的	66.8	61.7	的3.9	我们	76.6	67.9	5.1

每个语料库的最佳结果以粗体突出显示。

5.2. 唇读术

我们使用唇部识别模型进行了四项实验。在第一个实验中，我们基于包含六种不同情绪的短语训练了六个模型。我们提供每种情绪下所有模型短语识别准确率的结果。我们还分别对每种情绪的表达方式进行了分类。此外，我们还基于表达每种情绪的短语训练了模型。但由于本例中 Train 子集增加了六倍，我们将其分成六份。按性别、年龄、短语标签和说话人均匀分布折叠。第一个实验结果见表6。

表6. 6种情绪策略的短语识别准确率比较。TM为训练模型。

TM	拉夫德斯												CREMA-D												多体													
	NE HA AN SA DI FE mAcc												NE HA AN SA DI FE mAcc												NE HA AN SA DI FE mAcc													
NE	93.8	79.7	85.2	89.1	92.2	70.3	和	82.8	93.0	87.5	85.9	91.4	93.8	85.1	92.1	75.0	95.3	82.2	72.2	88.2	78.9	95.5	90.5	82.9	83.0	84.2	72.3	55.5	73.1	69.1	62.5	68.8	65.9	74.1	69.0	62.4	63.4	66.9
AN	84.4	75.8	89.1	82.8	79.7	68.8	SA	89.1	82.8	79.7	68.8	SA	85.9	89.1	89.9	85.1	76.5	93.1	70.2	67.5	82.7	82.0	86.7	89.8	86.5	86.8	64.2	67.3	65.6	72.1	60.7	61.4	65.4	71.0	61.5	70.9	70.9	66.5
85.9	DI	73.4	69.5	68.0	70.3	73.4	70.3	FE	71.9	68.0	63.3	87.5	79.7	80.1	85.7	91.4	81.1	85.8	88.2	84.5	84.4	89.0	85.1	86.0	92.3	79.2	65.2	71.2	62.7	64.9	70.7	62.1	66.3	66.2	67.9	70.2	71.1	65.4
78.1	mAcc	82.6	79.7	76.9	84.2	83.7	79.19	18.	74.2	92.2	93.0	85.2	85.1	82.6	92.3	84.1	84.3	91.5	81.9	79.2	88.9	93.0	89.8	87.0	66.6	63.5	72.1	67.9	65.3	71.2	65.3	63.7	68.0	66.5	70.1	68.5	65.5	
75.0														70.8	92.5	86.5	83.5	86.8							85.5	71.8	64.0	66.2	69.3							68.5	65.5	
														74.8											87.2												68.5	68.5
														86.2											90.7												71.3	71.3
全部														84.5											88.7												68.0	68.0

每个语料库的 6 情感策略的性能指标值以粗体突出显示。

表6展示了六种情绪策略以及经典策略的结果。
(仅使用无情绪的NE短语进行训练)和有情绪的(使用所有有情绪的短语进行训练)(包含六种情绪)方法。在 VSR 方法仅针对以下情况进行训练时：
对于NE短语 (NE Train模型) ,RAVDESS的mAcc分别为85.1%、84.2%和66.9%。
分别使用 CREMA-D 和多语料库数据。在 VSR 方法的情况下
使用包含六种情绪的所有情绪短语进行训练 (All Train 模型) ,mAcc 等于 RAVDESS、CREMA-D 和多语料库数据的准确率分别为 84.5%、88.7% 和 68.0%。
对于我们采用的六种情绪策略,我们为每种情绪训练了六个不同的模型。
情绪 (见对角线上的数值)和 mAcc 分别为 86.2%、90.7% 和 71.3%。
分别针对 RAVDESS、CREMA-D 和多语料库数据集。使用我们的方法,我们与
传统方法相比,平均提高了 4%;与传统方法相比,平均提高了 2%。
在所有语料库中都采用了情感方法。
值得注意的是,根据情绪训练模型的不同,价值观
mAcc (水平方向)存在差异。对于 RAVDESS 语料库,mAcc 的变化范围为 70.8% 至 89.1%。
DI 和 HA 训练模型之间的对比度为 18.3%。相反,对于
CREMA-D语料库的mAcc值范围为79.2%至87.2%,偏差为8%。
AN 和 FE 训练模型。对于多语料库数据,mAcc 从
根据采用 AN/DI 还是 SA/FE 训练模型,比例在 65.4% 到 68.5% 之间,相差 3%。
被使用。情感短语识别的 mAcc (垂直方向)也因各种因素而异。
所使用的情绪训练模型。对于 RAVDESS 中的 AN 和 SA 口语短语。
语料库中,mAcc 的范围为 76.9% 至 84.2%。同时,CREMA-D 语料库显示出
带有 DI 和 AN 情绪的短语的 mAcc 从 79.2% 提高到 91.5%。

在多语料库数据中也观察到了类似的趋势,其中 mAcc 从 63.7% 变化。高达 71.2%。这种现象的出现是因为所有情绪都会引发特定的唇部动作,能够区分不同的情绪。这种发音上的变化会影响短语。识别性能。

在第二个实验中,我们根据以下标准将所有类别的情绪分组: 根据其效价:负面效价(NG)(包括AN、DI、FE和SA情绪),NE 效价,正效价(PO)(包括HA情绪)。由于我们获得了模型, 在第一个实验中,我们只针对NE和PO价态类别训练了模型。 NG价类。由于NE价的训练子集的大小超过了大小

我们将训练子集分成四份,分别针对其他价态进行四次重复训练。与第一个实验研究中的实验类似。我们报告了该实验结果。结果见表7。

表 7.三级效价策略的短语识别准确率比较。TM为训练集模型。

TM	拉夫德斯				CREMA-D				多体							
	没钱	没钱	没钱													
NE	93.8	79.7	86.2	PO	82.8	86.6	92.1	75.0	84.5	78.9	83.9	72.3	55.5	68.4	65.4	
	93.0	89.1	NG	95.3	88.3	90.6	88.3	95.3	86.5	89.9	89.0	86.9	65.9	74.1	64.7	68.2
mAcc	90.6	87.0	88.6		91.4	90.5	87.0	86.4	87.2	89.8	67.3	69.1	68.9	68.4		
					92.5					92.6	68.5	66.2	67.3	71.8		

每个语料库的 3 级效价策略的性能指标值以粗体突出显示。

表7所示的结果表明,当情绪按以下方式分组时:
它们的效价,十二个短语识别的mAcc值分别为92.5%、92.6%和
RAVDESS、CREMA-D 和多语料库数据集的准确率分别为 71.8%。这些值超过了
使用我们的六种情绪策略,mAcc 分别提高了 6.3%、1.9% 和 0.5%。
语料库 (其中mAcc 分别为 86.2%、 90.7% 和 71.3%;见表6)。该结果
结果表明,所有NG价态的情绪都具有相似的面部特征,这些特征与其他情绪不同。
价态类别。

此外,在表8中,我们考察了短语识别准确率(Acc)如何随语音通道(针对RAVDESS语料库)和情绪强度(针对RAVDESS语料库)而变化。

以及CREMA-D语料库)。在RAVDESS语料库中,NE效价缺乏强烈的情感强度。同样,在CREMA-D语料库中,NE效价也表现为低、中等强度。

高强度信号缺失。表8显示短语识别准确率较高。

语音声学通道比歌曲通道表现更好。此外,对于RAVDESS语料库,正常情绪强度下的SR准确率高于强烈情绪强度下的准确率。

差异不超过5.7%。另一方面,对于CREMA-D而言,情绪强度在短语识别中起着至关重要的作用,因为不同强度之间的差异会影响短语识别。

情绪效价和强度为62.9%。因此可以得出结论,变化

发音方式的改变会显著扭曲不同声带的短语识别准确率。

渠道和情感强度。

表 8.基于语音的 3 级效价策略的短语识别准确率比较
通道和情感强度。TM是训练模型。SP和SO分别指语音和歌曲。
分别指语音通道。NR和ST分别指正常和强烈的情感强度。
LQ、MD和H分别指低、中、高的情绪强度。

[illegible]

在第三个实验中,我们将情绪分为两类:NE 和情绪性。(EM) (除NE外的所有情绪),即,我们采用二元分类。该模型对于NE类保持不变。对于EM类,我们将训练集子集划分为五倍。与之前的实验研究类似,我们展示了最大结果。

仅在表 9 的一个折叠中获得。

表7和表9显示,对于RAVDESS语料库和多语料库数据,准确率 (Acc)

对于三级价态和二元词组,短语识别的性能大致相同。

策略。对于 CREMA-D 语料库,二元策略使 mAcc 降低了 1.4%。

(92.6% 对 91.2%)。由于 NG 和 PO 两种情绪的面部特征完全不同,

这两种相反价态的结合会导致 mAcc 值下降。

表10中,我们考察了短语识别准确率 (Acc)如何随语音变化。

通道和情感强度,与表 8 类似。人声通道短语的 Acc

对于带有情感的短语,语音识别率高于口语识别率。然而,

正常强度短语的识别率高于强强度短语。

例如,在 RAVDESS 语料库的三级效价策略中也是如此。此外,对于 CREMA-D 语料库,不同级别的短语识别准确率大致相同。

强度较高,但中等强度更高。

表9.二元策略的短语识别准确率比较。TM为训练模型。

TM	拉夫德斯			CREMA-D			多体		
	NE	EM	mAcc	NE	EM	mAcc	NE	EM	mAcc
NE 93.8	EM	84.7	89.3	92.1	82.6	87.4	72.3	65.8	69.1
93.8	mAcc	91.8	92.8	89.0	90.2	89.6	72.2	71.7	72.0
93.8		88.3	92.8	90.6	86.4	91.2	72.3	68.8	72.0

每个语料库的二元策略的性能指标值以粗体突出显示。

表 10.基于语音通道的二元策略短语识别准确率比较

以及情感强度。TM是训练模型。SP和SO分别指语音和歌曲的声乐表现。

分别指通道。NR和ST分别指正常和强烈的情绪强度。LO ,

MD、 HI分别指低、中、高的情绪强度。

TM	拉夫德斯						拉夫德斯						CREMA-D		
	是			在			是			在			在		
	SP	SO	SP	SO	SP	SO	NR	ST	NR	ST	NR	ST	LO	MD	HI
东北	93.8	93.8	81.6	88.7	89.5	93.8	85.1	84.4	87.8	11.3	20.3	9.3			
新兴市场	93.8	93.8	93.8	89.5	92.7	93.8	95.8	87.8	92.5	18.5	18.3	18.7			
mAcc	93.8	93.8	87.7	89.1			93.8	90.5	86.1	14.9	19.3	14.0			

5.3. EMOLIPS

mAcc 的值分别为 86.2%、90.7% 和 71.3% (六种情绪策略);92.5%、92.6%,

71.8% (三级效价策略);93.8%、91.2%和72.0% (二元策略)

这些成果的取得基于这样的假设:情感模型能够做出预测。

准确率很高。然而,目前还没有模型能够做出这样的预测。

在不同语料库上均取得了较高的准确率。因此,我们应用了这三种情感模型。

本文 (见第5.1节)提出的EMOLIPS 方法的第一层。

考虑到以下因素,对十二个短语进行识别的结果 (见表11):

使用 EMO-3DCNN-GRU 模型和两级识别进行情绪分布分析

与两个基线模型 (仅用中性短语训练的模型和所有短语训练的模型)相比,取得了显著的改进。

(情感短语)。实验结果表明,EMOLIPS 方法

采用六种情绪策略并不能比基线策略带来任何改进。

RAVDESS 和 CREMA-D 语料库。对于 CREMA-D 语料库,最高准确率为 90.9%。

采用三级效价策略实现了这一目标,该策略比NE基线高出6.7%。

比所有基线高出 2.2%。对于 RAVDESS 和多语料库数据,二元

该策略比三级效价策略平均高出 1%,结果是最大短语识别率分别为 91.9% 和 71.7%。

表 11.本文提出的两级方法与基线模型（仅在 NE 数据集上训练的模型）的 mAcc 比较短语和所有带有情感的短语。

语料库基线 (NE)基线 (全部)6种情绪3级效价二元					
拉夫德斯	85.1	84.5	83.8	90.6	91.9
CREMA-D	84.2	88.7	86.4	90.9	90.4
多	66.9	68.0	68.8	69.9	71.7

每个语料库的最佳结果以粗体突出显示。

值得注意的是,我们基于 CREMA-D 语料库的 EMOLIPS 方法,比我们之前的结果提高了 23.1% [20]。与我们之前的方法相比,我们不仅引入了基于唇语的两阶段短语识别方法,而且改进了短语识别模型本身。

6. 结论

本文提出了一种用于自动情感语音的EMOLIPS方法。唇读。这种基于视觉数据处理的两级方法是受以下因素驱动的:人类感知和多模态深度学习的最新进展。所提出的方法利用视觉语音数据来确定语音情感类型。然后对语音数据进行处理。使用从零开始训练的情感唇语识别模型进行处理。这从根本上解决了大多数现实生活场景中涉及的多情感唇语识别问题。我们将这些模型实现为 EMO-3DCNN-GRU 架构的组合。

用于自动唇读的情感识别和 3DCNN-BiLSTM 架构。

此外,本文还详细回顾了近年来在自动唇读和情绪识别领域取得的最新进展。

五年 (2018-2023)。与现有研究相比,我们主要关注深度学习引入该领域带来的宝贵进展,而省略了对以下内容的描述:传统方法。此外,我们还进行了广泛的实验研究。这表明不同的情绪 (快乐、愤怒、厌恶、恐惧、悲伤和)是如何相互影响的。中性)、效价 (积极、中性和消极)和二元 (情绪和中性)情感自动唇语识别。

在 RAVDESS 和 CREMA-D 语料库上的评估表明,所提出的方法达到了目前最先进的性能,情感短语识别率分别高达 91.9% 和 90.9%。

识别准确率分别为:我们还训练了三个用于特定任务的情感模型:

(1)六种情绪识别, (2)三级效价识别,以及 (3)二元情绪

识别方面,我们提出的情感模型优于目前最先进的情感识别结果。

使用十折交叉验证设置,识别率提高了 1% 以上。

未来研究有多种潜在领域。其中包括改进……

通过使用更复杂的模型架构来提高情感唇语识别模型的性能并将它们应用于情感计算和人机交互的实时应用中

人机交互 (HCI)。此外,探索整合多模态方法至关重要。

将唇读与其他方式 (例如音频和文本)结合使用。这项研究的结果是:

对于突破情绪识别和自动唇读的界限至关重要。

所有源代码和训练好的模型都可以在我们的 GitHub 存储库中找到,网址为[https://](https://github.com/SMIL-SPCRAS/EMOLIPS)

github.com/SMIL-SPCRAS/EMOLIPS (2023年10月25日访问)。

作者贡献:概念化,ER 和 DI;方法论,ER;验证,ER;形式分析,DR;调查,ER;资源,DI;写作 初稿准备,ER 和 DI;撰写审阅和编辑,DR 和 DI;可视化,DR,ER 和 DI;监督,DR;项目行政管理,DR;资金筹集,DI。所有作者均已阅读并同意已发表的内容。手稿版本。

资金来源:第1、3、4、5.2、5.3和6节由俄罗斯科学基金会提供资金支持。
(编号 23-71-01056, <https://rscf.ru/en/project/23-71-01056/>, (2023年10月25日访问),第5.1节
本研究由一项拨款(编号:MK-42.2022.4)资助,第二部分由……资助。
国家研究(主题编号:FFZF-2022-0005)。

机构审查委员会声明:不适用。

知情同意声明:不适用。

数据可用性声明:在本研究中,我们使用了两个大规模的公开语料库:
RAVDESS<https://zenodo.org/records/1188976> (2023年10月25日访问)和CREMA-D
<https://github.com/CheyneyComputerScience/CREMA-D> (2023年10月25日访问)。

利益冲突声明:作者声明不存在利益冲突。

缩写

本文中使用的以下缩写:

1D	一维
二维	二维
3D	三维
4D	四维
账户	准确性
一个	生气的
ASR	音频语音识别
的	视听
AVSR	音视频语音识别
与一个	双向
那	冷静的
CNN	卷积神经网络
CREMA-D	众包情感多模态演员数据集
简历	计算机视觉
DBN	深度信念网络
从	厌恶
DL	深度学习
深度神经网络	深度中立网络
在	情绪
F1	F1测量
反馈循环	完全互联
FE	可怕
第一人称特征提取	每秒帧数
刮胡子	高斯误差线性单元
格鲁	门控循环单元
哈	快乐的
氢氯噻嗪	人机交互
CL	库尔巴克-莱布勒
线性纳米	层归一化
地方	留一语料库排除法
唇读反应堆	唇读自然语境下的句子数据集
LRW	野外唇语识别数据集
LSTM	长短期记忆
mAcc	平均准确率
机器学习	机器学习
MLP	多层感知器
MSA	多头自我关注
MSTCN	多尺度时间卷积网络
是	中性的
的	消极的
NN	中立网络
后	积极的

瑞尔森大学情感语音和歌曲视听数据库 (RAVDESS)	
循环神经网络	循环神经网络
投资回报率	感兴趣区域
朗姆酒	基于递归的单模态编码器
S2T	语音转文字
在	伤心
成为	语音情感识别
新加坡元	随机梯度下降
在下面	最先进的
SR	语音识别
STCNN 时空卷积神经网络	
短时傅里叶变换	短时傅里叶变换
是	惊讶
支持向量机	支持向量机
TSN	双流网络
常见的	未加权平均召回率
看	视觉情绪识别
VGG	视觉几何组
年	视觉变形金刚
学校资源中心	视觉语音识别

参考

1. Benoit, C.; Martin, JC; Pelachaud, C.; Schomaker, L.; Suhm, B. 视听和多模态语音系统。标准手册。资源口语语言系统-增刊2000, 500, 1–95。

2. Chen, T. 视听语音处理. IEEE信号处理杂志. 2001, 18, 9–21. [\[CrossRef\]](#)

3. Hardison, DM. 第二语言语音习得:视觉线索、语境和说话者变异性的影响。应用心理学-guist. 2003, 24, 495–522. [\[CrossRef\]](#)

4. Campbell, R. 视听语音的处理:经验和神经基础。Philos. Trans. R. Soc. B Biol. Sci. 2008, 363, 1001–1010. [\[CrossRef\]](#)

5. Michon, M.; López, V.; Aboitiz, F. 人类语言的起源与演化:从听觉、视觉和感觉三模态的出现 Vocal Network. Prog. Brain Res. 2019, 250, 345–371. [\[CrossRef\]](#)

6. Dupont, S.; Luettin, J. 音频-视频语音建模用于连续语音识别。IEEE Trans. Multimed. 2000, 2, 141–151。 [\[交叉引用\]](#)

7. Shillingford, B.; Assael, Y.; Hoffman, M.W.; Pine, T.; Hughes, C.; Lord, U.; Liao, H.; White, H.; Rao, K.; Bennett, L.; 等。大规模视觉语音识别。在 2019 年 9 月 15 日至 19 日奥地利格拉茨举行的 Interspeech 会议论文集上;第 4135-4139 页。 [\[交叉引用\]](#)

8.伊万科,D.;留民,D.;卡舍夫尼克,A.;阿克约诺夫,A.; Karnov, A. 驾驶员辅助系统中的视觉语音识别。在 2022 年第 30 届欧洲信号处理会议 (EUSIPCO) 论文集,塞尔维亚贝尔格莱德,2022 年 8 月 29 日至 9 月 2 日;第1131-1135页。 [\[CrossRef\]](#)

9. Ma, P.; Petridis, S.; Pantic, M. Visual Speech Recognition for Multiple Languages in the Wild. Nat. Mach. Intell. 2022, 4, 930–939. [\[交叉引用\]](#)

10. Choi, J.; Kim, M.; Ro, YM. 基于语音单元的可理解唇语到语音合成。arXiv 2023, arXiv:2305.19603。

11. Ma, P.; Wang, Y.; Petridis, S.; Shen, J.; Pantic, M. 提高唇读能力的训练策略。载于 ICASSP 会议论文集 2022年IEEE国际声学、语音与信号处理会议 (ICASSP),新加坡,新加坡,2022年11月23日至27日 2022年5月;第8472-8476页。 [\[CrossRef\]](#)

12. Koumparoulis, A.; Potamianos, G. 使用 EfficientNetV2 和 Transformers 实现准确且资源高效的唇读。 2022 年 IEEE 国际声学、语音和信号处理会议 (ICASSP) 会议论文集 新加坡,2022年5月23-27日;IEEE:美国新泽西州皮斯卡塔韦,2022年;第8467-8471页。 [\[CrossRef\]](#)

13. Kim, M.; Yeo, JH; Ro, YM 利用多头视觉-听觉记忆进行唇读区分同形异义词。AAAI 会议。人工智能, 2022,36,1174–1182。 [\[CrossRef\]](#)

14. Ma, P.; Martínez, B.; Petridis, S.; Pantic, M. 基于精简高效模型的实用唇读方法。会议论文集 2021 年 IEEE 国际声学、语音和信号处理会议 (ICASSP),多伦多,安大略省, 加拿大,2021年6月6日至11日;第7608-7612页。 [\[CrossRef\]](#)

15. Feng, D.; Yang, S.; Shan, S.; Chen, X. Learn an Effective Lip Reading Model without Pains. arXiv 2020, arXiv:2011.07557.

16. El Ayadi, M.; Kamel, MS; Karray, F. 语音情感识别综述:特征、分类方案和数据库。模式识别. 2011, 44, 572–587. [\[CrossRef\]](#)

17. Swain, M.; Routray, A.; Kabisatpathy, P. 语音情感识别的数据库、特征和分类器:综述。国际期刊 Speech Technol. 2018, 21, 93–120. [\[CrossRef\]](#)

18. Wani, TM; Gunawan, TS; Qadri, SAA; Kartiwi, M.; Ambikairajah, E. 语音情感识别系统综述. IEEE Access 2021, 9, 47795–47814. [\[CrossRef\]](#)
19. Malik, MI; Latif, S.; Jurdak, R.; Schuller, BW. 基于扩散模型增强语音情感识别的初步研究。载于2023年8月20日至24日在爱尔兰都柏林举行的Interspeech会议论文集,第646-650页。 [\[CrossRef\]](#)
20. Ryumina, E.; Ivanko, D. 基于唇读的情感语音识别。载于国际语音与计算机会议 (SPECOM)论文集,印度达尔瓦德,2022年11月29日至12月2日;Springer出版社:瑞士查姆,2022年;第616-625页。 [\[CrossRef\]](#)
21. 塔尔诺夫斯基, P.; 科沃杰, M.; 马科夫斯基, A.; 拉克, R.J. 使用面部表情进行情绪识别。普罗塞迪亚计算。科学。 2017, 108, 1175–1184。 [\[交叉参考\]](#)
22. Mellouk, W.; Handouzi, W. 基于深度学习的面部表情识别:回顾与见解。Procedia Comput. Sci. 2020, 175, 689–694. [\[CrossRef\]](#)
23. Ouzar, Y.; Bousefsaf, F.; Djeldji, D.; Maaoui, C. 基于视频的多模态面部表情和生理信号的自发情绪识别。IEEE/CVF计算机视觉与模式识别会议 (CVPR)论文集,美国路易斯安那州奥尔良,2022年6月19-20日;第2460-2469页。 [\[CrossRef\]](#)
24. Kansizoglou, I.; Misirlis, E.; Tsintotas, K.; Gasteratos, A. 用于长期行为建模的连续情绪识别通过循环神经网络。技术2022, 10, 59。 [\[CrossRef\]](#)
25. Ryumin, D.; Karpov, AA. 基于 Kinect 2.0 的自动识别手语手势。载于2017 年 7 月 9 日至 14 日在加拿大温哥华举行的“人机交互通用访问国际会议 (UAHCI)”论文集; Springer 出版社:德国柏林/海德堡,2017 年;第 89-101 页。 [\[CrossRef\]](#)
26. Wu, J.; Zhang, Y.; Sun, S.; Li, Q.; Zhao, X. 基于身体姿态的广义零样本情绪识别. 应用智能. 2022, 52, 8616–8634. [\[CrossRef\]](#)
27. Ryumin, D.; Ivanko, D.; Axyonov, A. 利用视觉信息进行跨语言迁移学习以实现自动手语手势识别. 国际摄影测量与遥感空间信息科学档案. 2023, 48, 209–216. [\[CrossRef\]](#)
28. Shi, H.; Peng, W.; Chen, H.; Liu, X.; Zhao, G. 多尺度 3D 移位图卷积网络用于情感识别人类行为。IEEE智能系统, 2022, 37, 103–110。 [\[CrossRef\]](#)
29. Atmaja, BT; Sasou, A.; Akagi, M. 基于声学 and 语言信息融合的双模态语音情感识别综述. Speech Commun. 2022, 140, 11–28. [\[CrossRef\]](#)
30. Zhang, T.; El Ali, A.; Hanjalic, A.; Cesar, P. 利用生理信号进行细粒度情感识别的小样本学习。IEEE Trans. Multimed. 2022, 25, 3773–3787. [\[CrossRef\]](#)
31. Zhang, T.; El Ali, A.; Wang, C.; Hanjalic, A.; Cesar, P. 基于生理信号的弱监督学习细粒度情感识别. IEEE Trans. Affect. Comput. 2022, 14, 2304–2322. [\[CrossRef\]](#)
32. Saganowski, S.; Perz, B.; Polak, A.; Kazienko, P. 利用可穿戴设备的生理信号进行日常生活中的情绪识别:系统性文献综述. IEEE Trans. Affect. Comput. 2022, 14, 1876–1897. [\[CrossRef\]](#)
33. Lin, W.; Li, C. 基于生理信号的情绪识别与判断研究综述. 应用科学. 2023, 13, 2573. [\[交叉引用\]](#)
34. Kumar, P.; Raman, B. 基于 BERT 的双通道可解释文本情感识别系统. 神经网络. 2022, 150, 392–407. [\[交叉引用\]](#)
35. Poulouse, A.; Kim, JH; Han, DS 基于面部标志点的面部表情识别特征向量提取技术。载于2021年10月20日至22日在韩国济州岛举行的国际信息与通信技术融合会议 (ICTC)论文集;IEEE:美国新泽西州皮斯卡塔韦,2021年;第1072-1076页。 [\[CrossRef\]](#)
36. Latif, S.; Rana, R.; Younis, S.; Qadir, J.; Epps, J. 迁移学习提高语音情感分类准确率。载于Interspeech 会议论文集,印度海得拉巴,2018 年 9 月 2-6 日;第 257-261 页。 [\[CrossRef\]](#)
37. Yenigalla, P.; Kumar, A.; Tripathi, S.; Singh, C.; Kar, S.; Vepa, J. 基于频谱图和音素嵌入的语音情感识别。载于2018年9月2日至6日在印度海得拉巴举行的Interspeech会议论文集,第3688-3692页。 [\[CrossRef\]](#)
38. Wöllmer, M.; Metallinou, A.; Katsamanis, N.; Schuller, B.; Narayanan, S. 分析双向长短期记忆神经网络的记忆特性以增强双语语音交互中的情感分类。载于 IEEE 国际声学、语音与信号处理会议 (ICASSP) 会议录,日本京都,2012 年 3 月 25-30 日;IEEE:美国新泽西州皮斯卡塔韦,2012 年;第 4157-4160 页。 [\[CrossRef\]](#)
39. Lee, J.; Tashev, I. 基于循环神经网络的高级特征表示在语音情感识别中的应用。国际语音通信大会论文集,德国德累斯顿,2015年9月6日至10日;第1537-1540页。 [\[CrossRef\]](#)
40. Mirsamadi, S.; Barsoum, E.; Zhang, C. 基于局部注意力机制的循环神经网络的自动语音情感识别. IEEE国际声学、语音与信号处理会议 (ICASSP)论文集,美国路易斯安那州新奥尔良,2017年3月5-9日;IEEE:美国新泽西州皮斯卡塔韦,2017;第2227-2231页。 [\[CrossRef\]](#)
41. Simonyan, K.; Zisserman, A. 用于大规模图像识别的超深卷积网络。arXiv 2014, arXiv:1409.1556。
42. He, K.; Zhang, X.; Ren, S.; Sun, J. 基于深度残差学习的图像识别. IEEE/CVF计算机视觉与模式识别会议 (CVPR)论文集,美国内华达州拉斯维加斯,2016年6月 27-30日;第770-778页。 [\[CrossRef\]](#)
43. Schoneveld, L.; Othmani, A.; Abdelkawy, H. 利用深度学习的最新进展进行视听情感识别。Pattern Recognit. Lett. 2021, 146, 1–7. [\[CrossRef\]](#)
44. Kim, B.; Lee, J. 基于深度学习的视频片段情感评价模型. Int. J. Fuzzy Log. Intell. Syst. 2018, 18, 245–253. [\[交叉引用\]](#)

45. Yang, J.; Wang, K.; Peng, X.; Qiao, Y. 基于时空特征的深度循环多示例学习用于参与度预测。载于国际多模态交互会议（ICMI）论文集,美国科罗拉多州博尔德, 2018年10月16-20日;第594-598页。 [\[CrossRef\]](#)
46. Deng, D.; Chen, Z.; Zhou, Y.; Shi, B. Mimamo Net: Integrating Micro-and-Macro-Motion for Video Emotion Recognition. AAAI Conf. 人工智能, 2020,34,2621–2628。 [\[CrossRef\]](#)
47. Pan, X.; Ying, G.; Chen, G.; Li, H.; Li, W. 基于视频的人脸表情识别的深度时空聚合框架. IEEE Access 2019, 7, 48807–48815. [\[CrossRef\]](#)
48. Ma, F.; Li, Y.; Ni, S.; Huang, SL; Zhang, L. 基于高效多模态的视听情感识别数据增强条件生成对抗网络。应用科学, 2022,12,527。 [\[CrossRef\]](#)
49. Middya, AI; Nag, B.; Roy, S. 基于深度学习的多模态情感识别:基于模型级音视频融合. Knowl.-Based Syst. 2022, 244, 108580. [\[CrossRef\]](#)
50. Tran, M.; Soleymani, M. 用于情感识别的预训练音视频Transformer模型。IEEE国际声学、语音与信号处理会议（ICASSP）论文集,新加坡,2022年5月23-27日;第4698-4702页。 [\[CrossRef\]](#)
51. John, V.; Kawanishi, Y. 基于多模态Transformer的音频和视频情感识别.国际模式识别会议（ICPR）论文集,加拿大魁北克省蒙特利尔,2022年8月21-25日;第2582-2588页。 [\[CrossRef\]](#)
52. Praveen, RG; de Melo, WC; Ullah, N.; Aslam, H.; Zeeshan, O.; Denorme, T.; Pedersoli, M.; Koerich, AL; Bacon, S.; Cardinal, P.; 等. 用于维度情感识别中音视频联合的交叉注意力模型. IEEE/CVF计算机视觉与模式识别研讨会（CVPRW）论文集,美国路易斯安那州新奥尔良,2022年6月19-20日;第2485-2494页。 [\[CrossRef\]](#)
53. Lei, Y.; Cao, H. 基于意图和多模态感知标签的偏好学习的视听情感识别。IEEE Trans. Affect. Comput. 2023, 1–16. [\[CrossRef\]](#)
54. Zhang, S.; Yang, Y.; Chen, C.; Zhang, X.; Leng, Q.; Zhao, X. 基于深度学习的多模态情感识别:近期进展与未来展望的系统综述。Expert Syst. Appl. 2023, 237, 121692。 [\[交叉引用\]](#)
55. Mocanu, B.; Tapu, R.; Zaharia, T. 基于注意力机制和深度算法的跨模态音视频融合多模态情感识别度量学习. 图像与视觉计算. 2023, 133, 104676. [\[CrossRef\]](#)
56. Nguyen, D.; Nguyen, K.; Sridharan, S.; Ghasemi, A.; Dean, D.; Fookes, C. 用于多模态情感识别的深度时空特征。IEEE计算机视觉应用冬季会议（WACV）论文集,美国加利福尼亚州圣罗莎, 2017年3月24-31日;IEEE:美国新泽西州皮斯卡塔韦,2017;第1215-1223页。 [\[CrossRef\]](#)
57. Huang, J.; Tao, J.; Liu, B.; Lian, Z.; Niu, M. 基于多模态Transformer融合连续情感识别. IEEE国际声学、语音与信号处理会议（ICASSP）论文集,西班牙巴塞罗那, 2020年5月4-8日;IEEE:美国新泽西州皮斯卡塔韦,2020;第3507-3511页。 [\[CrossRef\]](#)
58. Ristea, NC; Ionescu, RT. 用于语音和音频分类的自步集成学习。arXiv 2021, arXiv:2103.11988。
59. 乔治斯库,密歇根州;约内斯库,RT;北卡罗来纳州里斯泰亚; Sebe, N. 具有类人顶端树突激活的非线性神经元。应用。英特尔。2023, 53, 25984–26007. [\[CrossRef\]](#)
60. Gong, Y.; Chung, YA; Glass, J. Ast: Audio Spectrogram Transformer. arXiv 2021, arXiv:2104.01778。
61. 瓦斯瓦尼, A.;沙泽尔, N.;帕尔玛, N.;乌什科雷特, J.;琼斯, L.;戈麦斯, AN;凯撒, 。 Polosukhin, I. 《注意力就是你所需要的》。副词。神经信息处理系统2017, 30, 6000–6010。
62. Luna-Jiménez, C.; Kleinlein, R.; Griol, D.; Callejas, Z.; Montero, JM; Fernández-Martínez, F. 基于 RAVDESS 数据集的听觉变换器和动作单元的多模态情感识别方案. Appl. Sci. 2021, 12, 327. [\[CrossRef\]](#)
63. Pavlopoulos, J.; Malakasiotis, P.; Androutsopoulos, I. 深度学习用于用户评论审核。arXiv 2017, arXiv:1705.09993。
64. Tsai, YHH; Bai, S.; Liang, PP; Kolter, JZ; Morency, LP; Salakhutdinov, R. 用于非对齐多模态语言序列的多模态Transformer。载于第57届计算语言学协会年会（ACL）论文集,意大利佛罗伦萨,2019年7月28日至8月2日;美国国立卫生研究院公共访问:美国马萨诸塞州贝塞斯达,2019年;第6558-6569页。 [\[CrossRef\]](#)
65. Krishna, D.; Patil, A. 基于跨模态注意力机制和一维卷积神经网络的多模态情感识别. 国际语音通信协会（Interspeech）会议论文集,中国上海,2020年10月25-29日;第4243-4247页。 [\[CrossRef\]](#)
66. Li, Z.; Tang, F.; Zhao, M.; Zhu, Y. EmoCaps:基于情感胶囊的会话情感识别模型。载于计算语言学协会年会论文集:ACL 2022;计算语言学协会:爱尔兰都柏林,2022。 [\[CrossRef\]](#)
67. Li, J.; Liu, Y.; Wang, X.; Zeng, Z. CFN-ESA:一种具有情绪转换感知能力的跨模态融合网络,用于对话情绪识别。arXiv 2023, arXiv:2307.15432。
68. Ivanko, D.; Ryumin, D.; Karpov, A. 音频-视频语音识别深度学习方法的最新进展综述。Mathematics 2023, 11, 2665. [\[CrossRef\]](#)
69. Ryumin, D.; Ivanko, D.; Ryumina, E. 基于移动设备传感器的视听语音和手势识别。Sensors 2023, 23, 2284. [\[CrossRef\]](#)
70. Noda, K.; Yamaguchi, Y.; Nakadai, K.; Here, HG; Ogata, T. 基于卷积神经网络的唇读。载于会议论文集国际演讲会,新加坡,2014年9月14-18日;第1149-1153页。 [\[CrossRef\]](#)
71. Tamura, S.; Ninomiya, H.; Kitaoka, N.; Osuga, S.; Iribe, Y.; Takeda, K.; Hayamizu, S. 基于深度瓶颈特征和高性能唇读的视听语音识别. 亚太信号与信息处理协会年会暨会议（APSIPA）论文集,中国香港,2015年12月16-19日;第575-582页。 [\[CrossRef\]](#)

72. Petridis, S.; Pantic, M. 用于视觉语音识别的深度互补瓶颈特征。IEEE国际声学、语音与信号处理会议 (ICASSP)论文集,中国上海,2016年3月20-25日;IEEE:美国新泽西州皮斯卡塔韦,2016年;第2304-2308页。 [[CrossRef](#)]
73. Tran, D.; Bourdev, L.; Fergus, R.; Torresani, L.; Paluri, M. 使用 3D 卷积网络学习时空特征。
在 2015 年 12 月 7 日至 13 日智利圣地亚哥举行的国际计算机视觉会议 (ICCV) 论文集上;第 4489-4497 页。
[[交叉引用](#)]
74. Assael, Y.; Shillingford, B.; Whiteson, S.; de Freitas, N. LipNet:句子级唇读。arXiv 2016, arXiv:1611.01599。
75. Karpathy, A.; Toderici, G.; Shetty, S.; Leung, T.; Sukthankar, R.; Fei-Fei, L. 基于卷积神经网络的大规模视频分类。IEEE/CVF计算机视觉与模式识别会议 (CVPR)论文集,美国俄亥俄州哥伦布市, 2014年6月23-28日;第1725-1732页。 [[CrossRef](#)]
76. Chung, JS; Senior, AW; Vinyals, O.; Zisserman, A. Lip Reading Sentences in the Wild. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Honolulu, HI, USA, 2017年7月21-26日; pp. 3444–3453. [[CrossRef](#)]
77. Shi, B.; Hsu, WN; Mohamed, A. 鲁棒的自监督视听语音识别。在仁川国际语音通信协会 (Interspeech)会议论文集中。
韩国,2022年9月18日至22日;第2118-2122页。 [[CrossRef](#)]
78. Chung, JS; Zisserman, A. Lip Reading in the Wild. In Asian Conference on Computer Vision; Springer: Cham, Switzerland, 2016.
[[交叉引用](#)]
79. Stafylakis, T.; Tzimiropoulos, G. 将残差网络与 LSTM 相结合用于唇读。载于 Interspeech 会议论文集,
瑞典斯德哥尔摩,2017年8月20日至24日;第3652-3656页。 [[CrossRef](#)]
80. Martínez, B.; Ma, P.; Petridis, S.; Pantic, M. 使用时间卷积网络进行唇读。在 IEEE 国际声学、语音和信号处理会议 (ICASSP) 论文集,西班牙巴塞罗那,2020 年 5 月 4 日至 8 日;第 6319-6323 页。
[[交叉引用](#)]
81. Serdyuk, D.; Braga, O.; Siohan, O. 基于Transformer的单人及多人视频音频语音识别视频前端。载于2022年9月18-22日韩国仁川国际语音通信大会 (Interspeech) 论文集,第2833-2837页。 [[CrossRef](#)]
82. Chen, CF; Fan, Q.; Panda, R. CrossViT:用于图像分类的跨注意力多尺度视觉Transformer。国际计算机视觉会议 (ICCV)论文集,加拿大魁北克省蒙特利尔,2021年10月10-17日;第347-356页。 [[CrossRef](#)]
83. Dosovitskiy, A.; Beyer, L.; Kolesnikov, A.; Weissenborn, D.; Zhai, X.; Unterthiner, T.; Dehghani, M.; Minderer, M.; Heigold, G.; Gelly, S.; 等. 一图胜千言:用于大规模图像识别的 Transformers。arXiv 2020, arXiv:2010.11929。
84. Pan, SJ; Yang, Q. 迁移学习综述。IEEE 知识与数据工程汇刊. 2010, 22, 1345–1359. [[CrossRef](#)]
85. Fernandez-Lopez, A.; Sukno, FM.深度学习时代自动唇读综述。图像与视觉计算. 2018, 78, 53–72.
[[交叉引用](#)]
86. Afouras, T.; Chung, JS; Zisserman, A. LRS3-TED:用于视觉语音识别的大规模数据集。arXiv 2018, arXiv:1809.00496。
87. Gunes, H.; Piccardi, M. 用于自动分析人类非语言情感行为的双模态面部和身体姿态数据库。
国际模式识别会议 (ICPR)论文集,中国香港,2006 年 8 月 20 日至 24 日;第 1 卷,第 159 页。
1148–1153. [[CrossRef](#)]
88. Martin, O.; Kotsia, I.; Macq, B.; Pitas, I. eINTERFACE 05 音视频情感数据库。国际数据工程研讨会 (ICDEW) 会议论文集,美国佐治亚州亚特兰大,2006 年 4 月 3-7 日;
IEEE:美国新泽西州皮斯卡塔韦,2006 年;第 8 页。
[[交叉引用](#)]
89. 布索, C.; 布卢特, M.; 李, CC; 卡齐姆扎德, EA; 教务长, EM; 金, S.; 张, JN; 李, S. Narayanan, SS IEMOCAP:互动情感二元动作捕捉数据库。语言资源评估. 2008, 42, 335–359. [[CrossRef](#)]
90. Haq, S.; Jackson, PJ; Edge, J. 说话人相关的视听情感识别。听觉-视觉语音处理. 2009, 2009, 53–58。
91. McKeown, G.; Valstar, M.; Cowie, R.; Pantic, M.; Schroder, M. SEMAINE 数据库:人与有限代理之间情感色彩对话的标注多模态记录。IEEE Trans. Affect. Comput. 2012, 3, 5–17. [[CrossRef](#)]
92. Dhall, A.; Goecke, R.; Lucey, S.; Gedeon, T. 从电影中收集大型、富含注释的面部表情数据库。IEEE Multimed. 2012, 19, 34–41. [[CrossRef](#)]
93. Ringeval, F.; Sonderegger, A.; Sauer, J.; Lalanne, D. 介绍远程协作和情感互动多模态语料库RECOLA。载于2013年4月22日至26日在中国上海举行的自动人脸和手势识别国际会议及研讨会 (FG)论文集,第1-8页。 [[CrossRef](#)]
94. Cao, H.; Cooper, DG; Keutmann, MK; Gur, RC; Nenkova, A.; Verma, R. CREMA-D:众包情感多模态演员数据集。IEEE情感计算汇刊, 2014, 5, 377–390. [[CrossRef](#)]
[[PubMed](#)]
95. Chou, HC; Lin, WC; Chang, LC; Li, CC; Ma, HP; Lee, CC. NNIME:清华大学-雅典国立科技大学中文交互式多模态情感语料库。载于2017年10月23-26日美国德克萨斯州圣安东尼奥市国际情感计算与智能交互会议 (ACII)论文集,第292-298页。 [[CrossRef](#)]
96. Livingstone, SR; Russo, FA. 瑞尔森情感语音和歌曲视听数据库 (RAVDESS):一个动态的多模态数据库
北美英语面部和语音表情集。PLoS ONE 2018, 13, e0196391. [[CrossRef](#)]
97. Perepelkina, OS; Kazimirova, E.; Konstantinova, M. RAMAS: 用于研究情绪识别的俄罗斯多模态二元互动语料库。PeerJ Prepr. 2018, 6, e26688v1. [[CrossRef](#)]
98. 萨宾斯基, T.; 卡米恩斯卡, D.; 鹈鹕, A.; 奥兹西纳尔, J.; 阿沃茨, E.; Anbarjafari, G. 情感语音、视频和情感多模态数据库
手势。见《模式识别与信息取证》;Springer出版社:瑞士查姆,2018年。 [[CrossRef](#)]

99. Poria, S.; Hazarika, D.; Majumder, N.; Naik, G.; Cambria, E.; Mihalcea, R. MELD:用于对话中情感识别的多模态多方数据集。计算语言学协会年会论文集; 计算语言学协会 (ACL):意大利佛罗伦萨,2019;第 527–536 页。 [\[CrossRef\]](#)
100. Li, Y.; Tao, J.; Schuller, B.; Shan, S.; Jiang, D.; Jia, J. MEC 2017:多模态情感识别挑战赛。载于亚洲情感计算与智能交互会议 (ACII Asia)论文集,中国北京,2018年5月20–22日;第1–5页。 [\[CrossRef\]](#)
101. Chen, J.; Wang, C.; Jun Wang, K.; Yin, C.; Zhao, C.; Xu, T.; Zhang, X.; Huang, Z.; Liu, M.; Yang, T. HEU Emotion: A Large-Scale Database for Multimodal Emotion Recognition in the Wild. *Neural Comput. Appl.* 2020, 33, 8669–8685. [\[CrossRef\]](#)
102. Landry, D.; He, Q.; Yan, H.; Li, Y. ASVP-ESD:一个使用语音和非语音话语进行情感识别的数据集及其基准。Glob. Sci. J. 2020, 8, 1793–1798.
103. Zhu, H.; Wu, W.; Zhu, W.; Jiang, L.; Tang, S.; Zhang, L.; Liu, Z.; Loy, CC CelebV-HQ: 大规模视频面部属性数据集。IEEE/CVF欧洲计算机视觉会议 (ECCV)论文集,英国格拉斯哥,2022年10月23–27日;Springer出版社:瑞士查姆,2022年;第650–667页。 [\[CrossRef\]](#)
104. 帕帕约安努, A.; 格策, B.; 程, S.; 克里索斯, G.; 邓, J.; 福蒂亚杜, E.; 坎普里斯, C.; 科利亚斯, D.; 莫斯霍格鲁, S.; Songsri-In, K.; 等人。MimicME:用于面部表情分析的大规模多样化 4D 数据库。IEEE/CVF 欧洲计算机视觉会议 (ECCV) 会议记录,英国格拉斯哥,2022 年 10 月 23–27 日;施普林格:瑞士查姆,2022 年;第 467–484 页。
[\[交叉引用\]](#)
105. Yang, J.; Huang, Q.; Ding, T.; Lischinski, D.; Cohen-Or, D.; Huang, H. EmoSet:具有丰富属性的大规模视觉情感数据集。在 IEEE/CVF 国际计算机视觉会议 (ICCV) 会议录中,法国巴黎, 2023 年 9 月 30 日至 10 月 6 日;第 20383–20394 页。
106. Garofolo, JS Timit 声学语音连续语音语料库;语言数据联盟:美国宾夕法尼亚州费城,1993 年。
107. Ryumina, E.; Dresvyanskiy, D.; Karpov, A. 寻找一种鲁棒的面部表情识别模型:大规模视觉跨语料库研究。Neurocomputing 2022, 514, 435–450. [\[CrossRef\]](#)
108. Fromberg, L.; Nielsen, T.; Frumosu, FD; Clemmensen, LH.超越准确率:面部表情识别中的公平性、可扩展性和不确定性考虑因素。载于2024年1月9日至11日挪威特罗姆瑟举行的北极光深度学习会议论文集;第1–9页。
109. Ryumina, E.; Markitantov, M.; Karpov, A. 用于视听情感和情绪识别的多语料库学习。数学 2023, 11, 3519. [\[CrossRef\]](#)
110. Wang, CY; Bochkovskiy, A.; Liao, HYM YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors. arXiv 2022, arXiv:2207.02696.
111. Yu, M.; Zheng, H.; Peng, Z.; Dong, J.; Du, H. 基于多任务全局-局部网络的面部表情识别。Pattern Recognit. Lett. 2020, 131, 166–171. [\[CrossRef\]](#)
112. Liu, P.; Li, K.; Meng, H. 基于注意力双向对齐的多模态情感识别的组门控融合。2020年10月25日至29日,中国上海,国际演讲与传播大会论文集,第379–383页。 [\[CrossRef\]](#)
113. Loshchilov, I.; Hutter, F. Sgdr: 具有暖重启的随机梯度下降。arXiv 2016, arXiv:1608.03983.
114. Ghaleb, E.; Niehues, J.; Asteriadis, S. 使用注意力机制对视听线索进行联合建模以进行情绪识别。Multimed. Tools Appl. 2023, 82, 11239–11264. [\[CrossRef\]](#)
115. Ghaleb, E.; Popa, M.; Asteriadis, S. 基于多模态和时间感知的视听线索在情绪识别中的应用。载于2019年9月3日至6日在英国剑桥举行的国际情感计算与智能交互会议 (ACII)论文集;IEEE:美国新泽西州皮斯卡塔韦,2019;第552–558页。 [\[CrossRef\]](#)

免责声明/出版商声明:所有出版物中所包含的陈述、观点和数据仅代表作者或撰稿人个人意见,并不代表MDPI和/或编辑的立场。MDPI和/或编辑对因内容中提及的任何观点、方法、说明或产品而造成的人身或财产损失不承担任何责任。