

电子与信息学报  
*Journal of Electronics & Information Technology*  
ISSN 1009-5896, CN 11-4494/TN

## 《电子与信息学报》网络首发论文

题目: T3FRNet: 一种融合三重感知细粒度重构的换衣行人重识别方法  
作者: 庄建军, 王楠  
收稿日期: 2025-05-27  
网络首发日期: 2026-01-19  
引用格式: 庄建军, 王楠. T3FRNet: 一种融合三重感知细粒度重构的换衣行人重识别方法[J/OL]. 电子与信息学报.  
<https://link.cnki.net/urlid/11.4494.tn.20260119.0906.010>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

# T<sup>3</sup>FRNet：一种融合三重感知细粒度重构的换衣行人重识别方法

庄建军\* 王 楠

(南京信息工程大学电子与信息工程学院 南京 210044)

**摘 要：**针对换衣行人重识别(CC Re-ID)任务中存在的有效特征提取困难和训练样本不足的问题，该文提出一种融合三重感知细粒度重构的换衣行人重识别方法，利用细粒度纹理感知模块处理后的纹理特征与深度特征进行拼接，提高服装变化下的识别能力，引入Transformer注意力机制的ResFormer50网络增强模型对图像特征提取的感知能力，通过自适应混合池化模块(AHP)进行通道级自主感知聚合，对特征进行深层次细粒度挖掘，从而达到整体表征一致性与服装变化泛化性并重的效果。新的自适应细粒度重构策略(AFR)通过细粒度级别的对抗性扰动与选择性重构，在不依赖显式监督的前提下，显著提升模型对服装变换、局部细节扰动的鲁棒性和泛化能力，从而提高模型在实际场景中的识别准确率。大量实验结果表明了所提方法的有效性，在LTCC和PRCC数据集换衣场景下，Rank-1/mAP分别达到了45.6%/19.8%和70.6%/69.1%，优于同类前沿方法。

**关键词：**行人重识别；换衣；纹理感知；Transformer；细粒度重构

**中图分类号：**TN911.73; TP391.41

**文献标识码：**A

**文章编号：**1009-5896(2026)01-0001-12

**DOI:** 10.11999/JEIT250476

**CSTR:** 32379.14.JEIT250476

## 1 引言

行人重识别是智能视频监控系统中一项重要的自动化行人检索技术，能够实现跨时间、跨地点和跨设备的行人跟踪。在过去的几十年里，为了克服光照差异、视角变化和物体遮挡等挑战，人们做了大量的努力，并取得了优异的成绩<sup>[1-2]</sup>。然而，他们主要关注短期场景，极度依赖行人外观特征的稳定不变性，导致在实际应用场景中模型性能大幅度降低。因此，衍生了一个新的任务，即换衣行人重识别(Cloth-Changing person Re-Identification, CC Re-ID)，它需要在长期场景中追求更具鲁棒的模型以完成行人重识别<sup>[3]</sup>。与传统行人重识别相比，CC Re-ID在更具有实际应用价值的基础上也面临着更加严峻的挑战。在长期场景下，目标行人大多更换衣物，使得衣物作为视觉特征主体所提供的显著特征发生巨大变化，模型难以泛化。同时，由于不同季节衣物厚度差异大，行人的躯干特征会出现不同程度的遮挡，导致特征对齐困难。

为应对CC Re-ID任务中的挑战，众多学者基于行人步态、姿态、轮廓、关键点和3D形状等行人软生物特征提出了一些方法<sup>[4-6]</sup>。例如，Jin等人<sup>[4]</sup>引入步态识别作为辅助任务来驱动基于图像的行人

重识别模型，辅助学习与衣物无关的特征。借助辅助模态虽然能够提升模型性能，但需要以极大的额外计算资源和系统复杂度的大幅度提升为代价，其不稳定性也会对模型性能产生不利影响，并且在训练过程中难以建立局部生物特征信息与全局身份语义之间的联系，导致推理阶段缺乏局部感知能力。Gu等人<sup>[7]</sup>和Yang等人<sup>[8]</sup>曾尝试在服装标签的辅助下，强制模型的主干网络学习与服装无关的特征。但服装标签需要大量额外工作进行标注，且不适用于现实场景。鉴于人类并不需要冗余的辅助信息就可以辨认出此前见过的目标，研究员尝试基于深层特征表征建模的方法完成CC Re-ID任务<sup>[9-13]</sup>。Zhang等人<sup>[9]</sup>通过提取人的头部、颈部和肩部的多种具有区分性的细粒度生物特征抵抗服装变化；Zhang等人<sup>[13]</sup>提出了一种基于Transformer的自适应注意力与金字塔融合网络，提高模型在换衣场景下的信息利用效率。他们依赖于显著性区域或属性信息的准确获取构建更具鲁棒性和判别性的特征表示，抵抗服装变换带来的干扰，这些依赖点虽然在一定程度上提升了模型性能，但在场景变化下极易成为性能瓶颈。

为了最大限度地挖掘行人图像中的细粒度信息，增强模型特征学习的鲁棒性，降低换衣对模型性能的影响，突破场景变化下的性能瓶颈，本文提出了一种基于三重感知细粒度重构网络(Texture-aware Transformer Tuning Fine-grained Reconstruction Network, T<sup>3</sup>FRNet)的换衣行人重识别方法，引入的Transformer注意力机制增强模型对图像特征提取的感知能力，细粒度纹理感知模块

收稿日期：2025-05-27；改回日期：2025-11-03

\*通信作者：庄建军 jjzhuang@nuist.edu.cn

基金项目：国家自然科学基金(62272234)，江苏省研究生科研与实践创新计划项目(SJCX25\_0503)

Foundation Items: The National Natural Science Foundation of China (62272234), Postgraduate Research & Practice Innovation Program of Jiangsu Province (SJCX25\_0503)

(Texture Awareness, TA)和自适应混合池化模块(Adaptive Hybrid Pooling, AHP)分别对纹理特征和全局特征进行深层次细粒度挖掘,同时采用新的自适应细粒度重构策略(Adaptive Fine-grained Reconstruction, AFR)增强模型的特征泛化能力和细粒度对比能力,从而提高模型在实际场景中的识别准确率。

## 2 本文方法

本文所提出的T<sup>3</sup>FRNet结构如图1所示,采用融合了Transformer注意力机制的ResFormer50网络作为特征提取主干网络,并由TA模块、AHP模块、AFR策略及联合损失函数等部分构成。

### 2.1 ResFormer50网络

由于ResNet50<sup>[14]</sup>网络作为CC Re-ID主干网络时能够很好地提取局部特征,推理速度快,但无法捕捉长距离像素依赖关系,对于粗粒度特征的依赖导致其在换衣场景下性能下降。而Transformer注意力机制可以很好地进行全局建模,挖掘细粒度特征,并且与Vision Transformer网络相比训练数据依赖和计算开销相对较小。因此,本文在ResNet50网络中引入Transformer注意力机制,构建了ResFormer50网络作为主干网络,在局部特征的基础上进行空间关系建模,保留局部感知和全局关系,兼顾效率与表现。

Transformer 注意力机制的结构如图2所示。首先将输入特征图 $F_A \in R^{C \times H \times W}$ 在高度 $H$ 和宽度

$W$ 维度上展平,并对通道 $C$ 维度进行归一化处理,得到归一化特征图 $F_N \in R^{C \times (H \times W)}$ 。之后通过多头自注意力对特征图进行计算,使得特征之间进行全局交互。将其结果与归一化特征图进行残差连接,得到特征图 $F_T \in R^{C \times (H \times W)}$ ,在进行归一化及MLP前馈网络处理后,与 $F_N$ 进行残差连接,并在 $H$ 和 $W$ 维度上进行投影,得到网络特征图 $F_R \in R^{C \times H \times W}$ 。MLP前馈网络由两个尺寸不同的线性层及ReLU激活函数组成,第1层线性层为将通道数变为 $C \times \kappa$ ,扩展特征维度,提取更丰富的特征,ReLU激活函数增加网络的非线性表达,第2层则将其投影回原始通道数 $C$ ,便于后续的残差连接。前馈比率 $\kappa$ 控制MLP层中的隐藏层维度的膨胀比例,其值越大,隐藏层越宽,网络学习能力越强,但计算成本也随之上升。将原始ResNet50浅层卷积池化层和之后的4个残差块组定义为stage0~4,本文选择将注意力机制插入stage2之后,此时ResFormer50网络能够以少量计算量的增加换取最佳的局部结构感知能力和全局身份建模能力,从而优化模型性能。

### 2.2 细粒度纹理感知模块

尽管CC Re-ID任务中,行人的服装不再能够提供身份辨别性强相关的外观特征,但细粒度纹理信息(如衣服褶皱、局部配饰等)仍然具有区分力,甚至对于一些服装相似度较高(如制服、工装)的场景下,纹理细节可能是唯一差异点。因此,为了有效利用图像中隐藏的信息,本文设计了细粒度纹理




图1 三重感知细粒度重构网络结构框图



感知模块TA, 通过融合Gabor滤波器与局部二值模式(Local Binary Pattern, LBP), 提取局部纹理信息, 并映射到高维特征空间, 增强细粒度特征表达。TA模块的结构示意图如图3所示。

输入原始特征图为  $X_B \in R^{C \times H \times W}$  在通道维度上计算均值进行灰度化处理, 得到灰度特征图  $F_B \in R^{1 \times H \times W}$ , 之后使用定义好的Gabor滤波器提取不同方向和尺度的纹理特征。Gabor核的计算公式如下所示:

$$G(x, y) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \cos\left(2\pi \frac{x'}{\lambda} + \psi\right) \quad (1)$$

其中,  $x' = x \cos \theta + y \sin \theta$ ,  $y' = -x \sin \theta + y \cos \theta$ , 标准差  $\sigma$  控制高斯窗口的扩展程度, 波长  $\lambda$  控制正弦波的频率, 纵横比  $\gamma$  控制椭圆形滤波器的纵横比例, 而角度  $\theta$  则负责控制滤波器的方向。随着  $\theta$  值的增加, Gabor滤波器能够捕获更多方向的纹理特征, 减少因角度偏差造成的特征遗漏, 进而提升模型对局部细粒度的辨别能力, 但每新增一个  $\theta$ , 就增加了一个通道的Gabor特征, 计算成本和冗余风险大幅度增加, 因此, 本文选择在  $0^\circ, 45^\circ, 90^\circ$  及

$135^\circ$  4个方向上应用滤波器, 得到4个方向上的滤波纹理特征图  $F_G \in R^{4 \times H \times W}$ 。

同时, 对  $F_B$  执行LBP提取, 选择一个像素  $I_c$  作为中心像素, 并选取  $n$  个邻域像素, 形成一个环形结构, 计算每个邻域像素  $I_n$  和  $I_c$  的关系  $S(I_n - I_c)$ , 并将二进制序列转换为十进制数, 作为LBP值:

$$LBP = \sum_{n=0}^{n-1} S(I_n - I_c) \cdot 2^n \quad (2)$$

基于LBP值生成LBP特征图, 从而更好地关注局部模式变化。考虑到LBP需要与Gabor结合使用进行纹理感知, 本文将环形邻域内的像素数  $p$  设置为8, 获得编码后的LBP纹理特征图  $F_L \in R^{1 \times H \times W}$ , 并将其与滤波纹理特征图  $F_G$  沿着通道维度进行拼接, 得到组合特征图  $F_F \in R^{5 \times H \times W}$ 。最后, 将组合特征图线性投影到高维特征空间, 从而得到纹理感知特征图  $X_{TAM} \in R^{C \times H \times W}$ , 使其能够与全局特征进行加权融合。

### 2.3 自适应混合池化模块

为了平衡模型对细粒度纹理与全局稳定性的需求, 兼顾特征表达能力与鲁棒性, 设计了自适应混




图2 Transformer注意力机制结构示意图




图3 细粒度纹理感知模块示意图

合池化模块AHP，通过结合自适应幂均值池化和最大池化方法，动态调整不同通道的池化方式。

自适应幂均值池化定义为

$$f_{\text{mean}}(X) = \left( \frac{1}{|X|} \sum_i x_i^t \right)^{\frac{1}{t}} \quad (3)$$

其中， $X$ 是输入特征图， $t$ 是控制平均池化与最大池化之间程度的超参数，当 $t=1$ 时，等价于平均池化，当 $t \rightarrow \infty$ 时趋近于最大池化， $t$ 越大，模型越倾向于关注局部高响应区域。

最大池化 $f_{\text{max}}$ 是从输入特征图的一个窗口区域中选取最大值，以此代表该区域的响应强度。它对于边缘、纹理及强响应特征区域敏感性高，但鲁棒性较差，而自适应幂均值池化具有高泛化能力、低敏感性的特点，基于此AHP模块将两者进行加权融合，提高特征表达能力，其计算公式为

$$f_{\text{AHP}}(X) = \alpha \cdot f_{\text{mean}}(X) + (1 - \alpha) \cdot f_{\text{max}}(X) \quad (4)$$

其中， $\alpha$ 是加权超参数。在训练过程中， $\alpha$ 与幂指数 $t$ 一并设定为可训练参数，模型通过联合感知损失函数对其的偏导数自动计算梯度，并借助优化器在迭代更新中不断调整其取值，使其能够自适应地收敛至当前任务的最优值。该机制不仅有效避免了传统手动调参的局限性，还进一步增强了模型对通道内特征分布的建模能力，从而提升了在复杂任务中的泛化性能。AHP模块融合了自适应幂均值池化的柔性及最大池化的敏感性，通过通道级自主学

习聚合策略，达到整体表征一致性与服装变化泛化性并重的效果。

## 2.4 自适应细粒度重构策略

为了降低服装变换对特征表示的干扰，增强对结构性细粒度信息的建模能力，本文提出了一种自适应细粒度重构策略AFR，通过细粒度级别的对抗性扰动与选择性重构，在不依赖显式监督的前提下，显著提升模型对服装变换、局部细节扰动的鲁棒性和泛化能力。

如图1所示，AFR策略首先将原始特征图 $X_B$ 与融合特征图 $X_F$ 进行逐元素相加得到细粒度特征图 $X_A \in R^{C \times H \times W}$ ，之后通过均值池化得到初步特征 $F \in R^{C \times 1 \times 1}$ ，并进入细粒度重构模块。图4展示了细粒度重构模块的结构示意图，初步特征图 $F$ 沿垂直方向平均划分为 $P$ 个局部区域，则对每个样本 $F_i$ ，分块如下：

$$F_i = [f_i^{(1)}, f_i^{(2)}, \dots, f_i^{(P)}], f_i^{(p)} \in R^{C \times h \times 1} \quad (5)$$

对每个局部块 $f_i^{(p)}$ 计算其均值和标准差，并将其记作 $N_i^{(p)} = N(\mu_i^{(p)}, (\sigma_i^{(p)})^2)$ ，其中均值 $\mu_i^{(p)} = \frac{1}{h} \sum_h f_i^{(p)}[:, h]$ ，标准差 $\sigma_i^{(p)} = \sqrt{\frac{1}{h} \sum_h (f_i^{(p)}[:, h] - \mu_i^{(p)})^2}$ 。从同一批处理中选择标签不同的样本 $j \neq i$ ，构造对抗扰动参考分布 $N_j^{(p)}$ 。对于每个局部区域 $p$ ，计算原始分布 $N_i^{(p)}$ 与对抗扰动参考分布 $N_j^{(p)}$ 的KL散度：




图4 自适应细粒度重构策略示意图

$$D\left(N_i^{(p)} \parallel N_j^{(p)}\right) = \log \left( \frac{\sigma_j^{(p)}}{\sigma_i^{(p)}} \right) + \frac{\left(\sigma_i^{(p)}\right)^2 + \left(\mu_i^{(p)} - \mu_j^{(p)}\right)^2}{2\left(\sigma_j^{(p)}\right)^2} - \frac{1}{2} \quad (6)$$

其中, 均值和标准差为 $C$ 维向量, 结果取所有通道平均。根据散度值生成扰动掩码 $m_i^{(p)}$ , 如式(7)所示:

$$m_i^{(p)} = \begin{cases} 1, & D\left(N_i^{(p)} \parallel N_j^{(p)}\right) > \tau \\ 0, & \text{其它} \end{cases} \quad (7)$$

对于被选中的区域, 用候选样本的统计信息扰动原始特征, 并使用扰动掩码 $m_i^{(p)}$ 做选择性替换:

$$\begin{aligned} f_i^{(p)'} &= (1 - m_i^{(p)}) \cdot f_i^{(p)} + m_i^{(p)} \cdot \tilde{f}_i^{(p)} \\ &= (1 - m_i^{(p)}) \cdot f_i^{(p)} + m_i^{(p)} \cdot \left[ \left( f_i^{(p)} - \mu_i^{(p)} \right) \cdot \frac{\sigma_j^{(p)}}{\sigma_i^{(p)}} + \mu_j^{(p)} \right] \end{aligned} \quad (8)$$

将所有重构后的局部块在高度维拼接, 最终返回重构后的特征图 $F_{afr} \in R^{C \times 1 \times 1}$ 。

为了训练它, 本文设计了一种细粒度身份鲁棒性损失, 公式表示为

$$L_{afr} = -\frac{1}{B} \sum_{i=1}^B \log p_i^{(y_i)} + \frac{1}{B \cdot P} \cdot \sum_{i=1}^B \sum_{p=1}^P D\left(N_i^{(p)} \parallel N_i'^{(p)}\right) \quad (9)$$

其中,  $p_i^{(y_i)}$ 表示样本 $i$ 经AFR策略处理后的重构特征图被分类器预测为其真实身份类别 $y_i$ 的概率值,  $D\left(N_i^{(p)} \parallel N_i'^{(p)}\right)$ 表示对抗扰动前后 $p$ 区域的KL散度。该损失函数能够保证模型在局部细粒度扰动后的特征图上仍保持全局身份一致, 同时抑制受扰动区域的语义偏移, 从而帮助AFR策略实现细粒度自适应调控, 增强模型泛化能力。

## 2.5 损失函数

为了对TA模块进行约束, 纹理特征损失 $L_{tf}$ 应用了三元组损失, 计算公式为

$$L_{tf-tri} = \frac{1}{B} \sum_{i=1}^B \max(d(f_i^T, f_i^P) - d(f_i^T, f_i^N) + l, 0) \quad (10)$$

其中,  $f_i^T, f_i^P, f_i^N$ 分别表示样本 $i$ 的目标行人、相同身份与不同身份的纹理特征,  $d(f_1, f_2) = \|f_1 - f_2\|_2^2$ 表示欧几里德距离,  $l$ 为间隔参数, 确保负样本比

正样本远, 让同一行人的纹理特征彼此接近。

不同行人的衣服纹理相似会导致模型误判, 因此,  $L_{tf}$ 中增加了对比损失来区分不同身份的纹理特征。对于两个样本 $i, j$ , 若他们是同一行人, 则 $y_{i,j} = 1$ , 反之 $y_{i,j} = -1$ , 计算对比损失如下:

$$L_{\text{contrast}} = \frac{1}{B} \sum_{i,j} [(1 - y_{i,j}) \max(0, d(f_i^T, f_j^T) - m) + y_{i,j} d(f_i^T, f_j^T)] \quad (11)$$

其中, 第1项用于拉远不同身份的纹理特征, 第2项用于拉近相同身份的纹理特征。最终,  $L_{tf}$ 如下所示:

$$L_{tf} = L_{tf-tri} + \beta L_{\text{contrast}} \quad (12)$$

其中,  $\beta$ 是权重超参数, 用于控制对比损失在纹理特征损失中的贡献。

为了推动模型学习到判别性强、具备跨外观一致性的行人特征表示, 本文提出了联合感知损失(Joint Perception Loss, JP-Loss), 将广泛使用的身份分类损失 $L_{id}$ <sup>[15]</sup>、三元组损失 $L_{tri}$ <sup>[16]</sup>以及本文提出的 $L_{afr}$ 和 $L_{tf}$ 进行组合, 共同对模型进行监督, 帮助模型学习鲁棒的细粒度身份特征。JP-Loss表示为

$$L_{JP} = L_{id} + L_{tri} + L_{afr} + L_{tf} \quad (13)$$

## 3 实验及结果分析

### 3.1 数据集和评价指标

为了证明该模型的有效性, 本文在个广泛使用的换衣行人重识别数据集LTCC<sup>[17]</sup>、PRCC<sup>[18]</sup>、Celeb-reID<sup>[19]</sup>及一个大规模的换衣数据集Deep-Change<sup>[20]</sup>上进行了评估。此外, 本文基于短期场景下的行人重识别数据集Market-1501<sup>[21]</sup>, 进一步研究该模型在无需换衣情况下的可行性。表1中详细介绍了各数据集的情况。

实验所用的评估指标包含了累计匹配特性曲线(cumulative matching characteristic)上的首位命中率Rank-1, 平均精度均值(mean Average Precision, mAP)。

### 3.2 实验设置

本文算法在PyTorch框架上实现, 训练评估均在NVIDIA 4090 GPU上进行, 采用由ImageNet<sup>[22]</sup>初始化后的ResFormer50作为特征提取主干网络, 注意力头数设置为4, 前馈比率 $\kappa$ 设置为2.0。输入图像的尺寸均调整为 $384 \times 192$ , 并使用随机翻转、裁剪和擦除进行数据扩充。训练阶段共80个轮次, 采用权重衰减为 $5 \times 10^{-4}$ 的Adam优化器, 学习率热身策略在前10轮将学习率由 $3.5 \times 10^{-6}$ 线性增加至 $3.5 \times 10^{-4}$ 后保持不变, 在第20轮、第40轮和第60轮



时学习率分别降低至当前学习率的0.1倍。波长 $\lambda$ 和纵横比 $\gamma$ 分别设置为20和0.5, 超参数 $\beta$ 设置为0.5。对于LTCC和PRCC数据集, 本文分别在标准和换衣设置下评估该算法的性能, 对于DeepChange数据集, 仅使用标准设置进行评估。具体而言, 标准设置的测试集中既包含服装一致样本, 也包含服装变换样本, 而换衣设置的测试集中仅涉及服装变换样本。

### 3.3 对比实验结果分析

将本文方法与几种最先进的方法进行对比, 以证明本文所提出的T<sup>3</sup>FRNet的优越性。表2中报告了LTCC和PRCC数据集上的实验结果, 表3和表4中分别报告了Celeb-reID和DeepChange数据集上的实验结果, 表5则展示了本文方法在服装一致的Market-1501数据集上的表现, 其中“ske”, “bs”, “ga”和“sil”分别表示行人轮廓、身体形状、人体步态和人体语义分割, “服装标签”表示是否使用真实服装标签。

#### 3.3.1 LTCC和PRCC

如表2所示, 相比于依赖辅助模态和服装标签的方法, 如FDGAN<sup>[23]</sup>, BMDB<sup>[6]</sup>, 本文方法的实

验效果更好, 说明基于服装标签进行特征解缠的效率不高, 辅助模态所提供的特征不稳定进而影响模型的性能, 而TA模块能够充分利用行人图像的细粒度纹理信息, 而ResFormer50网络能够更好地保留局部感知和全局关系。与Liu等人<sup>[24]</sup>所提出的聚类关系探索模块相比, 本文所提出的AFR策略能够在不依赖显式监督的前提下, 通过细粒度级别的对抗性扰动和选择性重构, 优化换衣样本的聚类分布。

#### 3.3.2 Celeb-reID

Celeb-reID是一个更大、更具挑战性的数据集, 它是由不受控制的街道快照组合而成, 平均每个人70%以上的图像显示的是不同服装, 并且不包含任何服装标签。如表3所示, 先进方法都取得了相对较差的性能, 并且由于缺少服装标签, 一些方法中未能报告基于该数据集的实验结果。然而, 在不依赖于辅助模态的情况下, 本文方法在Rank-1和mAP指标上实现了64.6%和18.4%的卓越性能, 这要归功于AFR策略。

#### 3.3.3 DeepChange

DeepChange数据集的规模远大于之前的基准测

表 1 5个常用数据集的基本情况

| 数据集         | 摄像头 | 数据类型  | 训练集(ID/图像) | 测试集(ID/图像) |           |
|-------------|-----|-------|------------|------------|-----------|
|             |     |       |            | 查询集        | 图库集       |
| LTCC        | 12  | SC/CC | 77/9576    | 75/493     | 75/7050   |
| PRCC        | 3   | SC/CC | 150/17896  | 71/3543    | 71/3384   |
| Celeb-reID  | -   | SC/CC | 632/20208  | 420/2972   | 420/11006 |
| DeepChange  | 17  | CC    | 450/75083  | 521/17527  | 521/62956 |
| Market-1501 | 6   | SC    | 751/12936  | 750/3368   | 750/19732 |

注: SC和CC分别表示服装一致和服装变换两种模式

表 2 本文方法与其他最新方法在LTCC和PRCC数据集上的实验结果(%)

| 方法                         | 模态     | 服装标签 | LTCC        |             |             |             | PRCC         |             |             |             |
|----------------------------|--------|------|-------------|-------------|-------------|-------------|--------------|-------------|-------------|-------------|
|                            |        |      | 标准          |             | 服装变换        |             | 标准           |             | 服装变换        |             |
|                            |        |      | Rank-1      | mAP         | Rank-1      | mAP         | Rank-1       | mAP         | Rank-1      | mAP         |
| CAL <sup>[7]</sup>         | RGB    | Yes  | 74.2        | 40.8        | 40.1        | 18.0        | 100.0        | 99.8        | 55.2        | 55.8        |
| AIM <sup>[8]</sup>         | RGB    | Yes  | 76.3        | 41.1        | 40.6        | 19.1        | 100.0        | 99.9        | 57.9        | 58.3        |
| FDGAN <sup>[23]</sup>      | RGB    | Yes  | 73.4        | 36.9        | 32.9        | 15.4        | 100.0        | 99.7        | 58.3        | 58.6        |
| GI-ReID <sup>[4]</sup>     | RGB+ga | No   | 63.2        | 29.4        | 23.7        | 10.4        | -            | -           | 33.3        | -           |
| BMDB <sup>[6]</sup>        | RGB+bs | No   | 74.3        | 39.5        | 41.8        | 17.9        | 99.7         | 97.9        | 56.6        | 53.9        |
| FIRE <sup>[2,12]</sup>     | RGB    | No   | 75.9        | 39.9        | 44.6        | 19.1        | 100.0        | 99.5        | 65.0        | 63.1        |
| TAPFN <sup>[13]</sup>      | RGB    | No   | 71.9        | 34.7        | 40.1        | 17.4        | 99.8         | 98.1        | 69.1        | 68.7        |
| CSSC <sup>[11]</sup>       | RGB    | No   | 78.1        | 40.2        | 43.6        | 18.6        | 100.0        | 99.1        | 65.5        | 63.0        |
| MBUNet <sup>[9]</sup>      | RGB    | No   | 67.6        | 34.8        | 40.3        | 15.0        | 99.8         | 99.6        | 68.7        | 65.2        |
| ACID <sup>[10]</sup>       | RGB    | No   | 65.1        | 30.6        | 29.1        | 14.5        | 99.1         | 99.0        | 55.4        | 66.1        |
| AFL <sup>[24]</sup>        | RGB    | No   | 74.4        | 39.1        | 42.1        | 18.4        | 100.0        | 99.7        | 57.4        | 56.5        |
| T <sup>3</sup> FRNet(本文方法) | RGB    | No   | <b>79.8</b> | <b>41.3</b> | <b>45.6</b> | <b>19.8</b> | <b>100.0</b> | <b>99.9</b> | <b>70.6</b> | <b>69.1</b> |

试,尤其是测试图库样本的数量,反映了现实场景的复杂性和难度。如表4所示,本文方法的性能优于其他现有方法。与SCNet<sup>[25]</sup>需要借助人体语义分割不同,本文方法中TA模块与AFR策略的配合可以打破辅助模态特征准确性的局限性,兼顾模型细粒度特征表达能力与鲁棒性,JP-Loss帮助模型对细粒度特征进行约束并进行自适应调控,增强泛化能力。

表 3 本文方法与其他最新方法在Celeb-reID数据集上的实验结果(%)

| 方法                         | 模态      | Rank-1      | mAP         |
|----------------------------|---------|-------------|-------------|
| MBUNet <sup>[9]</sup>      | RGB     | 55.5        | 12.8        |
| ACID <sup>[10]</sup>       | RGB     | 52.5        | 11.4        |
| CSSC <sup>[11]</sup>       | RGB     | 64.5        | 17.3        |
| FIRE <sup>2[12]</sup>      | RGB     | 64.0        | 18.2        |
| TAPFN <sup>[13]</sup>      | RGB     | 61.4        | 16.9        |
| SCNet <sup>[25]</sup>      | RGB+sil | 62.8        | 17.5        |
| T <sup>3</sup> FRNet(本文方法) | RGB     | <b>64.6</b> | <b>18.4</b> |

### 3.3.4 Market-1501

虽然Market-1501数据集中没有服装的变化,但是图像包含了行人姿态、摄像视角、物体遮挡等其他变化。本文通过TA模块有效提取图像中隐藏的局部纹理信息,并通过AFR策略进行细粒度级别的对抗性扰动与选择性重构,增强细粒度特征表达。如表5所示,本文方法实现的性能明显优于先进的竞争对手,实现了96.2%的Rank-1和89.3%的mAP。这些结果显著表明,具有鲁棒性的细粒度特征也可以有效地提高模型对标准行人重识别数据集的识别能力。

### 3.4 消融实验结果分析

为了检验本文方法中各模块的有效性,在服装变换设置下,基于LTCC和PRCC数据集进行了如表6所示的消融实验,使用ResNet50主干网络作为基线,通过加入AFR策略,模型进行细粒度级别的对抗性扰动与选择性重构,显著提升了对服装变换、局部细节扰动的鲁棒性和泛化能力,在LTCC

表 4 本文方法与其他最新方法在DeepChange数据集上的实验结果(%)

| 方法                         | 模态      | 服装标签 | Rank-1      | mAP         |
|----------------------------|---------|------|-------------|-------------|
| CAL <sup>[7]</sup>         | RGB     | Yes  | 54.0        | 19.0        |
| FIRE <sup>2[12]</sup>      | RGB     | No   | 57.9        | 20.0        |
| ACD-Net <sup>[5]</sup>     | RGB+ske | No   | 56.8        | 20.6        |
| SCNet <sup>[25]</sup>      | RGB+sil | No   | 53.5        | 18.7        |
| T <sup>3</sup> FRNet(本文方法) | RGB     | No   | <b>58.0</b> | <b>20.8</b> |

表 5 本文方法与其他最新方法在Market-1501数据集上的比较(%)

| 方法                         | 模态     | 服装标签 | Rank-1      | mAP         |
|----------------------------|--------|------|-------------|-------------|
| CAL <sup>[7]</sup>         | RGB    | Yes  | 94.7        | 87.5        |
| FDGAN <sup>[23]</sup>      | RGB    | Yes  | 95.4        | 87.0        |
| GI-ReID <sup>[4]</sup>     | RGB+ga | No   | 95.6        | 88.9        |
| CSSC <sup>[11]</sup>       | RGB    | No   | 95.3        | 87.6        |
| FIRE <sup>2[12]</sup>      | RGB    | No   | 95.4        | 87.7        |
| AFL <sup>[24]</sup>        | RGB    | No   | 95.5        | 88.8        |
| T <sup>3</sup> FRNet(本文方法) | RGB    | No   | <b>96.2</b> | <b>89.3</b> |

表 6 LTCC和PRCC数据集上的消融实验(%)

| AFR | TA | JP-Loss | ResFormer50 | AHP | LTCC   |      | PRCC   |      |
|-----|----|---------|-------------|-----|--------|------|--------|------|
|     |    |         |             |     | Rank-1 | mAP  | Rank-1 | mAP  |
| -   | -  | -       | -           | -   | 28.8   | 11.5 | 40.2   | 36.2 |
| √   | -  | -       | -           | -   | 40.1   | 17.9 | 58.3   | 56.0 |
| √   | √  | -       | -           | -   | 40.6   | 18.8 | 65.2   | 62.2 |
| √   | √  | √       | -           | -   | 41.5   | 19.3 | 67.6   | 62.5 |
| √   | √  | √       | √           | -   | 41.8   | 19.2 | 69.5   | 67.5 |
| √   | √  | √       | √           | √   | 45.6   | 19.8 | 70.6   | 69.1 |




和PRCC数据集上Rank-1/mAP分别提高了11.3%/6.4%和18.1%/19.8%。TA模块的加入能够辅助AFR策略对局部纹理信息进行提取,增强细粒度表达,实现了PRCC数据集上6.9%和6.2%的Rank-1和mAP增长。JP-Loss进一步辅助AFR策略和TA模块实现细粒度自适应调控和纹理特征身份聚类。在使用ResFormer50网络对ResNet50网络进行替换之后,模型在局部细粒度特征的基础上进行空间关系建模,更好地补充了局部感受野限制。AHP模块的加入平衡了模型对细粒度纹理与全局稳定性的需求,兼顾特征表达能力与鲁棒性。在完整使用本文方法,即AFR策略、TA模块、JP-Loss、ResFormer50网络及AHP模块全部选用时模型达到了最佳实验效果,Rank-1/mAP在LTCC和PRCC数据集上分别达到了45.6%/19.8%和70.6%/69.1%。

### 3.5 Transformer注意力机制嵌入位置效果分析

为了研究Transformer注意力机制的嵌入位置对模型的影响,在服装变换设置下,基于LTCC和PRCC数据集分别进行了相关实验。如表7所示,与stage1相比,注意力机制嵌入stage2后性能提升,模型能够利用较强的语义表达能力和丰富的空间结构信息,更好地进行局部结构感知和全局建模。然而,当注意力机制嵌入stage3和stage4后时,性能迅速下降。这是因为随着输出分辨率的降低,结构信息损失较大,对局部区域的敏感度下降,融入注意力机制后效能较差,甚至可能造成特征冗余,进而导致模型性能下降。根据上述分析,默认将注意力机制融入stage2之后构成ResFormer50网络。

表7 Transformer注意力机制嵌入位置研究结果(%)

| 嵌入位置   | LTCC        |             | PRCC        |             |
|--------|-------------|-------------|-------------|-------------|
|        | Rank-1      | mAP         | Rank-1      | mAP         |
| stage1 | 45.3        | 19.4        | 69.8        | 69.0        |
| stage2 | <b>45.6</b> | <b>19.8</b> | <b>70.6</b> | <b>69.1</b> |
| stage3 | 43.1        | 19.2        | 68.9        | 67.3        |
| stage4 | 41.6        | 19.2        | 62.0        | 61.1        |



### 3.6 超参数取值分析

在服装变换设置下,基于LTCC和PRCC数据集研究公式(18)中 $\beta$ 值对性能的影响, $\beta$ 的取值区间为0到1,取值间隔为0.1,实验结果如图5所示。当 $\beta$ 取值0.5时,纹理特征损失能够兼顾全局纹理一致性与局部细粒度区分性,有效缓解不同人服装纹理相似导致的识别混淆问题,提升CC Re-ID的鲁棒性和精度。

### 3.7 可视化结果分析

为了更加直观地展示性能,图6展示了不同模型的可视化结果。图6(a)中的4行图像从上到下依次为输入的原始图像、基线、除去Transformer注意力机制以及本文方法生成的热力图。对比可以发现,本文方法相比基线能够更好关注图像中的关键区域。另外,当Transformer注意力机制被去除后,模型提取关键特征的能力明显下降。该实验直观地证明了本文方法优秀的特征提取能力以及Transformer注意力机制的重要性。图6(b)展示了在换衣场景下基线模型与T<sup>3</sup>FRNet的前10名排名检索结果,绿色和红色框中的图像分别表示正例和负例结果,T<sup>3</sup>FRNet展现出比基线模型更好的稳定性和准确性。

### 3.8 计算复杂度与效率分析

最后,我们从FLOPs、训练和推理时间3个维度分析了T<sup>3</sup>FRNet的时间复杂性,以进一步说明其在实际部署中的潜力。实验结果表明,T<sup>3</sup>FRNet的FLOPs为8.9G,显著低于ACD-Net<sup>[5]</sup>的13.7G和SCNet<sup>[25]</sup>的10.2G,而这两种方法在表4中的表现都不如T<sup>3</sup>FRNet。在时间成本方面,T<sup>3</sup>FRNet在DeepChange数据集上的训练耗时约9.6h,而在相同硬件条件下,ACD-Net<sup>[5]</sup>需约21.8h,SCNet<sup>[25]</sup>需约14.2h。更为重要的是,在推理过程中,T<sup>3</sup>FRNet可以在不影响细粒度特征表示学习的前提下省略AFR策略,从而进一步降低存储和计算开销。综上所述,T<sup>3</sup>FRNet在性能与效率之间取得了良好平衡。




图5 参数 $\beta$ 不同取值下的模型性能对比




图6 不同模型的可视化结果图

## 4 结束语

本文提出了一种融合三重感知细粒度重构的换衣行人重识别方法,由ResFormer50主干网络、细粒度纹理感知模块、自适应混合池化模块、自适应细粒度重构策略以及联合感知损失构成。其中ResFormer50网络融合了卷积神经网络与Transformer网络结构的优点,在局部特征的基础上进行空间关系建模,兼顾效率与表现。细粒度纹理感知模块和自适应混合池化模块分别对纹理特征和全局特征进行深层次细粒度挖掘,从而达到整体表征一致性与服装变化泛化性并重的效果。而自适应细粒度重构策略通过细粒度级别的对抗性扰动与选择性重构,显著提升模型对服装变换、局部细节扰动的鲁棒性和泛化能力。此外,联合感知损失的加入进一步帮助模型学习鲁棒的细粒度身份特征。大量实验验证了本文方法在换衣行人重识别任务中的有效性和优越性。后续工作将研究如何进一步简化网络模型的复杂度,寻求兼顾高准确率与低延迟的方法。

## 参考文献

- [1] 程德强, 姬广凯, 张皓翔, 等. 基于多粒度融合和跨尺度感知的跨模态行人重识别[J]. 通信学报, 2025, 46(1): 108–123. doi: [10.11959/j.issn.1000-436x.2025019](https://doi.org/10.11959/j.issn.1000-436x.2025019).  
CHENG Deqiang, JI Guangkai, ZHANG Haoxiang, et al. Cross-modality person re-identification based on multi-granularity fusion and cross-scale perception[J]. *Journal on Communications*, 2025, 46(1): 108–123. doi: [10.11959/j.issn.1000-436x.2025019](https://doi.org/10.11959/j.issn.1000-436x.2025019).
- [2] 庄建军, 庄宇辰. 一种结构化双注意力混合通道增强的跨模态行人重识别方法[J]. 电子与信息学报, 2024, 46(2): 518–526. doi: [10.11999/JEIT230614](https://doi.org/10.11999/JEIT230614).

ZHUANG Jianjun and ZHUANG Yuchen. A cross-modal person re-identification method based on hybrid channel augmentation with structured dual attention[J]. *Journal of Electronics & Information Technology*, 2024, 46(2): 518–526. doi: [10.11999/JEIT230614](https://doi.org/10.11999/JEIT230614).

- [3] 张鹏, 张晓林, 包永堂, 等. 换装行人重识别研究进展[J]. 中国图象图形学报, 2023, 28(5): 1242–1264. doi: [10.11834/jig.220702](https://doi.org/10.11834/jig.220702).
- [4] ZHANG Peng, ZHANG Xiaolin, BAO Yongtang, et al. Cloth-changing person re-identification: A summary[J]. *Journal of Image and Graphics*, 2023, 28(5): 1242–1264. doi: [10.11834/jig.220702](https://doi.org/10.11834/jig.220702).
- [5] JIN Xin, HE Tianyu, ZHENG Kecheng, et al. Cloth-changing person re-identification from a single image with gait prediction and regularization[C]. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, New Orleans, USA, 2022: 14258–14267. doi: [10.1109/CVPR52688.2022.01388](https://doi.org/10.1109/CVPR52688.2022.01388).
- [6] GE Yiyuan, YU Mingxin, CHEN Zhihao, et al. Attention-enhanced controllable disentanglement for cloth-changing person re-identification[J]. *The Visual Computer*, 2025, 41(8): 5609–5624. doi: [10.1007/s00371-024-03741-4](https://doi.org/10.1007/s00371-024-03741-4).
- [7] LIU Xuan, HAN Hua, XU Kaiyu, et al. Cloth-changing person re-identification based on the backtracking mechanism[J]. *IEEE Access*, 2025, 13: 27527–27536. doi: [10.1109/ACCESS.2025.3538976](https://doi.org/10.1109/ACCESS.2025.3538976).
- [8] GU Xinqian, CHANG Hong, MA Bingpeng, et al. Clothes-changing person re-identification with RGB modality only[C]. *Proceedings of the 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, New Orleans, USA, 2022: 1060–1069. doi: [10.1109/CVPR52688.2022.00113](https://doi.org/10.1109/CVPR52688.2022.00113).

- [8] YANG Zhengwei, LIN Meng, ZHONG Xian, *et al.* Good is bad: Causality inspired cloth-debiasing for cloth-changing person re-identification[C]. Proceedings of the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition, Vancouver, Canada, 2023: 1472–1481. doi: [10.1109/CVPR52729.2023.00148](https://doi.org/10.1109/CVPR52729.2023.00148).
- [9] ZHANG Guoqing, LIU Jie, CHEN Yuhao, *et al.* Multi-biometric unified network for cloth-changing person re-identification[J]. *IEEE Transactions on Image Processing*, 2023, 32: 4555–4566. doi: [10.1109/TIP.2023.3279673](https://doi.org/10.1109/TIP.2023.3279673).
- [10] YANG Zhengwei, ZHONG Xian, ZHONG Zhun, *et al.* Win-win by competition: Auxiliary-free cloth-changing person re-identification[J]. *IEEE Transactions on Image Processing*, 2023, 32: 2985–2999. doi: [10.1109/TIP.2023.3277389](https://doi.org/10.1109/TIP.2023.3277389).
- [11] WANG Qizao, QIAN Xuelin, LI Bin, *et al.* Content and salient semantics collaboration for cloth-changing person re-identification[C]. Proceedings of the 2025 IEEE International Conference on Acoustics, Speech and Signal Processing, Hyderabad, India, 2025: 1–5. doi: [10.1109/ICASSP49660.2025.10890451](https://doi.org/10.1109/ICASSP49660.2025.10890451).
- [12] WANG Qizao, QIAN Xuelin, LI Bin, *et al.* Exploring fine-grained representation and recombination for cloth-changing person re-identification[J]. *IEEE Transactions on Information Forensics and Security*, 2024, 19: 6280–6292. doi: [10.1109/TIFS.2024.3414667](https://doi.org/10.1109/TIFS.2024.3414667).
- [13] ZHANG Guoqing, ZHOU Jieqiong, ZHENG Yuhui, *et al.* Adaptive transformer with pyramid fusion for cloth-changing person re-identification[J]. *Pattern Recognition*, 2025, 163: 111443. doi: [10.1016/j.patcog.2025.111443](https://doi.org/10.1016/j.patcog.2025.111443).
- [14] HE Kaiming, ZHANG Xiangyu, REN Shaoqing, *et al.* Deep residual learning for image recognition[C]. Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, USA, 2016: 770–778. doi: [10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
- [15] LUO Hao, GU Youzhi, LIAO Xingyu, *et al.* Bag of tricks and a strong baseline for deep person re-identification[C]. Proceedings of the 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops, Long Beach, USA, 2019: 1487–1495. doi: [10.1109/CVPRW.2019.00190](https://doi.org/10.1109/CVPRW.2019.00190).
- [16] CHEN Weihua, CHEN Xiaotang, ZHANG Jianguo, *et al.* Beyond triplet loss: A deep quadruplet network for person re-identification[C]. Proceedings of the 2017 IEEE Conference on Computer Vision and Pattern Recognition, Honolulu, USA, 2017: 1320–1329. doi: [10.1109/CVPR.2017.145](https://doi.org/10.1109/CVPR.2017.145).
- [17] QIAN Xuelin, WANG Wenxuan, ZHANG Li, *et al.* Long-term cloth-changing person re-identification[C]. Proceedings of the 15th Asian Conference on Computer Vision, Kyoto, Japan, 2020: 71–88. doi: [10.1007/978-3-030-69535-4\\_5](https://doi.org/10.1007/978-3-030-69535-4_5).
- [18] YANG Qize, WU Ancong, and ZHENG Weishi. Person re-identification by contour sketch under moderate clothing change[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2021, 43(6): 2029–2046. doi: [10.1109/TPAMI.2019.2960509](https://doi.org/10.1109/TPAMI.2019.2960509).
- [19] HUANG Yan, XU Jingsong, WU Qiang, *et al.* Beyond scalar neuron: Adopting vector-neuron capsules for long-term person re-identification[J]. *IEEE Transactions on Circuits and Systems for Video Technology*, 2020, 30(10): 3459–3471. doi: [10.1109/TCSVT.2019.2948093](https://doi.org/10.1109/TCSVT.2019.2948093).
- [20] XU Peng and ZHU Xiatian. DeepChange: A long-term person re-identification benchmark with clothes change[C]. Proceedings of the 2023 IEEE/CVF International Conference on Computer Vision, Paris, France, 2023: 11162–11171. doi: [10.1109/ICCV51070.2023.01028](https://doi.org/10.1109/ICCV51070.2023.01028).
- [21] ZHENG Liang, SHEN Liyue, TIAN Lu, *et al.* Scalable person re-identification: A benchmark[C]. Proceedings of the 2015 IEEE International Conference on Computer Vision, Santiago, Chile, 2015: 1116–1124. doi: [10.1109/ICCV.2015.133](https://doi.org/10.1109/ICCV.2015.133).
- [22] KRIZHEVSKY A, SUTSKEVER I, and HINTON G E. ImageNet classification with deep convolutional neural networks[J]. *Communications of the ACM*, 2017, 60(6): 84–90. doi: [10.1145/3065386](https://doi.org/10.1145/3065386).
- [23] CHAN P P K, HU Xiaoman, SONG Haorui, *et al.* Learning disentangled features for person re-identification under clothes changing[J]. *ACM Transactions on Multimedia Computing, Communications and Applications*, 2023, 19(6): 1–21. doi: [10.1145/3584359](https://doi.org/10.1145/3584359).
- [24] LIU Yuxuan, GE Hongwei, WANG Zhen, *et al.* Clothes-changing person re-identification via universal framework with association and forgetting learning[J]. *IEEE Transactions on Multimedia*, 2024, 26: 4294–4307. doi: [10.1109/TMM.2023.3321498](https://doi.org/10.1109/TMM.2023.3321498).
- [25] GUO Peini, LIU Hong, WU Jianbing, *et al.* Semantic-aware consistency network for cloth-changing person re-identification[C]. Proceedings of the 31st ACM International Conference on Multimedia, Ottawa, Canada, 2023: 8730–8739. doi: [10.1145/3581783.3612416](https://doi.org/10.1145/3581783.3612416).

庄建军：男，教授，研究方向为视频信号的智能处理。

王楠：女，硕士生，研究方向为计算机视觉、行人重识别。

责任编辑：陈倩



# T<sup>3</sup>FRNet: A Cloth-Changing Person Re-identification Via Texture-aware Transformer Tuning Fine-grained Reconstruction Method

ZHUANG Jianjun    WANG Nan

(School of Electronic and Information Engineering, Nanjing University of Information Science and Technology,  
Nanjing 210044, China)

## Abstract:

**Objective** Compared with conventional person re-identification, Cloth-Changing Person Re-Identification (CC Re-ID) requires moving beyond reliance on the temporal stability of appearance features and instead demands models with stronger robustness and generalization to meet real-world application requirements. Existing deep feature representation methods leverage salient regions or attribute information to obtain discriminative features and mitigate the effect of clothing variations; however, their performance often degrades under changing environments. To address the challenges of effective feature extraction and limited training samples in CC Re-ID tasks, a Texture-Aware Transformer Tuning Fine-Grained Reconstruction Network (T<sup>3</sup>FRNet) is proposed. The method aims to exploit fine-grained information in person images, enhance the robustness of feature learning, and reduce the adverse effect of clothing changes on recognition performance, thereby alleviating performance bottlenecks under scene variations.

**Methods** To compensate for the limitations of local receptive fields, a Transformer-based attention mechanism is integrated into a ResNet50 backbone, forming a hybrid architecture referred to as ResFormer50. This design enables spatial relationship modeling on top of local features and improves perceptual capacity for feature extraction while maintaining a balance between efficiency and performance. A fine-grained Texture-Aware (TA) module concatenates processed texture features with deep semantic features, improving recognition capability under clothing variations. An Adaptive Hybrid Pooling (AHP) module performs channel-wise autonomous aggregation, allowing deeper mining of feature representations and balancing global representation consistency with robustness to clothing changes. An Adaptive Fine-Grained Reconstruction (AFR) strategy introduces adversarial perturbations and selective reconstruction at the fine-grained level. Without explicit supervision, this strategy enhances robustness and generalization against clothing changes and local detail perturbations. In addition, a Joint Perception Loss (JP-Loss) is constructed by integrating fine-grained identity robustness loss, texture feature loss, identity classification loss, and triplet loss. This composite loss jointly supervises the learning of robust fine-grained identity features under cloth-changing conditions.

**Results and Discussions** Extensive evaluations are conducted on LTCC, PRCC, Celeb-reID, and the large-scale DeepChange dataset (Table 1). Under cloth-changing scenarios, the proposed method achieves Rank-1/mAP scores of 45.6%/19.8% on LTCC, 70.6%/69.1% on PRCC (Table 2), 64.6%/18.4% on Celeb-reID (Table 3), and 58.0%/20.8% on DeepChange (Table 4), outperforming existing state-of-the-art approaches. The TA module effectively captures latent local texture details and, when combined with the AFR strategy, enables fine-grained adversarial perturbation and selective reconstruction. This improves fine-grained feature representation and allows the method to achieve 96.2% Rank-1 and 89.3% mAP on the clothing-consistent Market-1501 dataset (Table 5). The JP-Loss further supports the TA module and AFR strategy by enabling fine-grained adaptive regulation and clustering of texture-sensitive identity features (Table 6). When the Transformer-based attention mechanism is inserted after stage 2 of ResNet50, improved local structural perception and global context modeling are obtained with only a slight increase in computational overhead (Table 7). Setting the  $\beta$  parameter to 0.5 (Fig. 5) enables effective balancing of global texture consistency and local fine-grained discriminability. Visualization results on PRCC (Fig. 6) and top-10 retrieval comparisons (Fig. 7) provide intuitive evidence of improved stability and accuracy in cloth-changing scenarios.

**Conclusions** A CC Re-ID method based on T<sup>3</sup>FRNet is proposed, consisting of the ResFormer50 backbone, TA module, AHP module, AFR strategy, and JP-Loss. Experimental results on four cloth-changing benchmarks and one clothing-consistent dataset confirm the effectiveness of the proposed approach. Under long-term



scenarios, Rank-1/mAP improvements of 16.8%/8.3% on LTCC and 30.4%/32.9% on PRCC are achieved. The ResFormer50 backbone supports spatial relationship modeling over local fine-grained features, while the TA module and AFR strategy enhance feature expressiveness. The AHP module balances sensitivity to local textures and stability of global features, and JP-Loss strengthens adaptive regulation of fine-grained representations. Future work will focus on simplifying the architecture to reduce computational complexity and latency while maintaining high recognition accuracy.

**Key words:** Person re-identification; Cloth-changing; Texture-aware; Transformer; Fine-grained reconstruction

