



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目： 基于 ICL-YOLOv11 的防眩板缺失检测算法研究与应用
作者： 文浩，杨江涛，邬琦，王梓睿，武盛
网络首发日期： 2025-09-28
引用格式： 文浩，杨江涛，邬琦，王梓睿，武盛. 基于 ICL-YOLOv11 的防眩板缺失检测算法研究与应用[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20250928.0915.004>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于 ICL-YOLOv11 的防眩板缺失检测算法研究与应用

文浩^{1,2,3}, 杨江涛^{1,2,3}, 邬琦⁴⁺, 王梓睿^{1,2,3}, 武盛^{1,2,3}

1.太原科技大学 电子信息工程学院, 太原 030024

2.太原科技大学 先进控制与装备智能化山西省重点实验室, 太原 030024

3.太原科技大学 山西省运动健康智能装备技术创新中心, 太原 030024

4.太原工业学院 计算机工程系, 太原 030008

+ 通信作者 E-mail: wuqi6567@163.com

摘要：针对现有高速公路巡检防眩板缺失检测处于初步阶段，且在检测任务中存在目标在复杂的道路背景下识别困难，密集排列目标定位要求较高，缺失为“非实体缺失”等问题，且需要满足实时检测的要求。提出基于改进 YOLOv11n 的 ICL-YOLOv11 算法。首先，构建融合倒置残差模块（Inverted Residual Mobile Block, IRMB）和级联组注意力机制（Cascaded Group Attention, CGA）的 ICGA 模块，通过嵌入 C3K2 结构增强特征融合能力；其次，设计细节增强轻量级共享卷积检测头（Detail Enhanced Lightweight Shared Convolution Detection Head, DE-LSCD），采用参数共享架构与细节增强卷积提升对防眩板细节的特征表征能力，通过群归一化（GN）策略优化模型参数规模；最后，通过采用 Inner-DIoU 损失函数，在保持检测精度的同时显著提升收敛速度与定位精确度。同时提出基于边界框中心点像素距离的自适应动态阈值检测方法。实验表明：改进后的 ICL-YOLOv11 算法相较于原 YOLOv11n 模型，召回率提升 15.5%，平均精度均值（mAP50%）提高 8.5%，模型参数量减少 10.2%。

关键词：防眩板缺失检测；YOLOv11n；ICGA；Inner-DIoU；自适应阈值检测

文献标志码：A 中图分类号：TP391 doi: 10.3778/j.issn.1002-8331.2504-0350

Research and Application of a Blind Spot Detection Algorithm Based on ICL-YOLOv11

WEN Hao^{1,2,3}, YANG Jiangtao^{1,2,3}, WU Qi⁴⁺, WANG Zirui^{1,2,3}, WU Sheng^{1,2,3}

1. School of Electronics Information Engineering, Taiyuan University of Science & Technology, Taiyuan 030024 China

2. Shanxi Key Laboratory of Advanced Control and Equipment Intelligence, Taiyuan University of Science & Technology, Taiyuan 030024 China

3. Shanxi Province Sports and Health Intelligent Equipment Technology Innovation Center, Taiyuan University of Science & Technology, Taiyuan 030024 China

4. Computer Engineering Department, Taiyuan Institute of Technology, Taiyuan 030008 China

基金项目：国家自然科学基金青年基金(61905172)，山西省基础研究计划面上项目(202303021211169)，山西省科技创新人才团队(202304051001035)，山西省科技合作交流专项(202204041101030)，山西省科技成果转化引导专项(202304021301044)。

作者简介：文浩(1999—)，男，硕士研究生，研究方向为仿生导航与信息系统、目标检测；杨江涛(1988—)，男，博士，副教授，研究方向为仿生导航与信息系统、目标检测；邬琦(1989—)，女，硕士，太原工业学院 计算机工程系，助教，研究方向为计算机仿真与图形图像处理；王梓睿(2001—)，女，硕士研究生，研究方向为仿生导航与信息系统、目标检测；武盛(2000—)，男，硕士研究生，研究方向为仿生导航与信息系统、目标检测。

Abstract: In view of the fact that the detection of the missing anti-glare plate of the existing highway inspection is in the preliminary stage, and there are problems in the detection task, such as the difficulty in identifying the target in the complex road background, the high requirements for the positioning of densely arranged targets, and the lack is "non-physical missing", and it is necessary to meet the requirements of real-time detection. The method develops an Inverted Residual Mobile Block (IRMB) and Cascaded Group Attention (ICGA) module with embedded C3K2 structure to enhance feature fusion. A Detail-Enhanced Lightweight Shared Convolution Detection Head (DE-LSCD) employs parameter-sharing architecture and detail-enhancing convolution to optimize feature representation efficiency, while group normalization reduces parameter quantity. The Inner-DIoU loss function replaces CIoU to accelerate convergence and improve localization accuracy without compromising detection performance. An adaptive dynamic threshold detection method based on bounding box center distance is introduced. Experiments show that the improved ICL-YOLOv11 algorithm has a 15.5% increase in recall rate and an 8.5% increase in mean average precision (mAP50%) compared to the original YOLOv11n model, with a 10.2% reduction in model parameter count.

Key words: anti-glare board missing detection; YOLOv11n; ICGA; Inner-DIoU; adaptive threshold detection

随着交通运输业的快速发展,高速公路的广泛建设,交通安全防护设施的管理与维护就变得尤为重要。防眩板作为减少对驾驶员视觉干扰、保证驾驶员眼睛不受强光照射,提高驾驶安全性的关键设施,在高速公路的交通安全保障中起着不可或缺的作用。然而,防眩板受到环境因素的影响发生损坏或缺失,给交通安全带来极大的安全隐患。传统人工巡检虽然能识别出损坏情况,但由于巡检范围广,人工成本高,逐渐暴露出诸多问题。因此,高效、准确地检测防眩板的缺失在交通设施管理和维护中有着重要意义。

近年来,计算机视觉与深度学习技术得到广泛的应用,尤其在道路交通监控、交通设施检测等领域。基于深度学习的目标检测模型可分为两大类:二阶段检测算法,将检测问题划分为两个阶段,先产生候选区域,然后进行区域分类,如 R-CNN^[1]、Fast R-CNN^[2]、Faster R-CNN^[3,4]等,二阶段算法计算复杂,不能保证实时性的要求;单阶段检测算法,不需要生成候选区域,其检测速度快但准确度降低,如 YOLO^[5-9]、SSD^[10]算法。综上所述,在实时检测方面单阶段算法更能满足工业需求。

近年来,YOLO 作为一种被广泛使用的检测模型,

在道路场景中的检测也得到了广泛应用,具有良好的检测效果。因此,基于 YOLO 算法的改进也成为众多学者的重要研究课题。针对检测防眩板缺失的方法研究处于初步阶段。Yuan^[11]等人采用像素级深度语义分割模型 PointRend 进行防眩板检测,提出基于图像的一维投影映射和相邻防眩板距离一致性判断防眩板是否缺失,但其需要对防眩板形状进行估计,因而影响检测精度。Feng^[12]等人将检测头与自适应空间特征模块结合提高多尺度特征融合能力,并提出了跨阶段分瓶颈转换器模块,提升了模型的泛化能力,但该模型在检测精度和参数量上仍有很大的改进空间。Lv^[13]等人提出一种多尺度融合特征金字塔网络,加强浅层和深层信息融合,提升了检测精度和实时性,但增加了模型的参数量。Su^[14]等人引入坐标注意力与全局注意力机制,且添加 1×1 卷积和身份连接到 3×3 卷积,提升了模型对遮挡目标的检测能力,但同时增加了模型的计算复杂度。Ren^[15]等人采用动态头部框架统一目标检测头部和注意力机制,且在 SPPF 层嵌入坐标注意力机制,提升了头部的检测能力,抑制了环境对模型检测的干扰,但由于引入注意力机制导致模型的计算复杂度增加,检测速度下降。Wang^[16]等人引入 Bi-level

Routing Attention, 增强了模型特征提取能力, 且在特征融合阶段采用三向特征金字塔网络, 提高了算法的准确性, 但由于引入注意力导致模型的参数量与计算复杂度增加。郭^[17]等人对特征图进行上采样操作, 提升了小目标检测识别精度, 但由于增加检测层导致检测速度下降。谢^[18]等人设计 AOD 去雾子网络和五天图像生成子网络的循环去雾双子网络, 提升了模型在雾天条件下的检测准确率与检测速度, 但由于增加去雾算法导致模型参数量增加。朱^[19]等人使用 SPDConv 模块减少细粒度信息丢失, 且引入 EMA 注意力机制, 抑制了背景环境的干扰, 增加了模型对道路小目标的检测能力, 但对于卡车的检测精度仍然不高。廖^[20]等人设计双向与自适应尺度融合特征金字塔网络结构, 提出 OR-RepN4 模块, 增强了对小目标特征的学习能力, 但同时引入了大量参数使得模型参数量增加。董^[21]等人设计了增强加权多分支特征融合网络, 并且融合卷积门控线性单元与卷积加法自注意力, 提升了模型对小尺度目标的检测能力, 但由于浅层特征图的尺寸较大, 使得模型计算量增加。宋^[22]等人引入 BiFormer 注意力机制以及 MobileNetV3 网络结构, 增强模型聚焦能力并且降低模型参数量, 且设计改进金字塔结构, 提升了细节保留能力, 虽然模型显著提升了精度, 但是增加了网络的计算复杂度。上述研究虽然在改进 YOLO 检测任务上做出了贡献, 但在模型检测精度上仍有很大的改进空间。

相比一般检测任务, 目前对于高速公路防眩板缺失检测任务的研究较少。其检测任务中存在诸多问题, 检测场景会发生光照变化、绿化植被以及对向车辆等复杂背景干扰; 不同车道检测使得目标尺寸大小存在变化, 其小目标检测易受噪声干扰。判定预期安装点位上目标的“非实体性缺失”状态, 需要较高的定位精度以区分相邻板和识别缺失。因此提出 ICL-YOLOv11 算法解决基于车载摄像头视角检测防眩板时存在的特征信息捕捉困难、误检漏检以及准确率低的难题, 并提出了一种检测防眩板缺失的新方法。具

体如下:

(1) 融合新注意力机制模块改进主干网络: 将倒置残差块与级联群体注意力机制融合, 形成 ICGA 模块以改进 C3K2 模块。通过级联注意力头逐步融合目标特征, 减少复杂背景干扰, 提升计算效率与特征融合能力。

(2) 优化检测头并引入新损失函数: 设计细节增强轻量化共享卷积检测头, 借助细节增强卷积挖掘目标关键信息, 利用共享卷积聚合信息, 增强对目标局部细节特征的关注, 提高检测头的细节捕获能力与检测精度。同时引入 Inner-DIoU 损失函数辅助边界框损失计算, 助力模型快速收敛和精确定位, 为防眩板缺失检测奠定基础。

(3) 提出动态阈值自适应检测方法: 基于前 5 帧数据累加相邻目标像素距离, 构建累加阈值基准, 并求取平均值, 通过比对后续帧中相邻目标距离与该平均值, 判断防眩板是否缺失的自适应检测方法, 解决不同车道检测时像素距离差异导致的错误。

1 ICL-YOLOv11

针对防眩板缺失检测任务中对防眩板的检测中检测精度不足的问题, 提出了一种增强检测精度的网络架构, 如图 1 所示。由于在检测任务中, YOLOv11n 主干网络针对动态检测以及复杂的道路环境下的特征提取能力存在不足, 导致模型容易出现漏检, 或者出现难以区分与背景相似的目标, 因此提出了 C3K2-ICGA 模块, 在不增加额外计算量的情况下增加检测深度以提升模型的检测精度; 并且提出一种 DE-LSGD 的检测头模型, 提升检测头定位和分类性能以及增强特征细节提取; 最后选择 Inner-DIoU 损失函数, 提升模型的收敛速度与定位的精确度。这些改进使得模型在不影响模型参数的情况下显著提升了模型的检测精度, 适用于基于车载视角下的防眩板检测任务中。




图1 ICL-YOLOv11 网络结构图

Fig.1 ICL-YOLOv11n network structure diagram

1.1 C3K2-ICGA

为了提高 YOLOv11n 的主干网络性能,尤其在高速公路复杂环境情况下,提出一种创新的 C3K2-ICGA 模块来解决原始模块的局限性。C3K2 模块虽然有较好的特征融合和上下文利用能力,但其依赖大卷积核扩展感受也的策略导致计算成本激增,且 IRMB 模块中的自注意力机制在远距离交替检测时存在资源浪费,在检测防眩板时会产生误检漏检等情况,影响检测的准确性。因此提出一种适用于移动设备的 C3K2-ICGA 模块,增强了局部特征提取能力和网络的计算效率,在不增加额外计算量的同时增加网络深度,提

升模型检测精度。C3K2-ICGA 将输入分为两部分处理输入特征,一部分直接传递,另一部分经过多个 I-Bottleneck 或 C3K 模块处理,最后对拼接结果再次卷积。其中 I-Bottleneck 中首先对输入数据进行通道数调整,通过卷积提取跨通道特征信息,其次通过注意力机制 CGA 进行特征分组处理和级联式信息融合,在保留通道数相同的情况下对数据进行提取,通过深度可分离卷积操作,减少计算量的同时提取局部特征,最后将 3×3 深度可分离卷积的输出与级联组注意力的输出相加,融合不同路径的特征信息,然后进行残差连接输出最终特征。其网络结构图如图 2 所示。




图2 C3K2-ICGA 网络结构图

Fig.2 C3K2-ICGA network structure diagram

1.2 ICGA 模块

在检测防眩板的过程中, 由于在车载摄像头中进行检测, 所以能够以轻量化模型实现高精度实时检测成为主流趋势。受 WU^[23]提出的 IRMB 模块启发, 其融合轻量级 CNN 与基于注意力的模型结构, 整合倒置残差块(IRB)与 Transformer^{[24][24]}有效组件, 提出 I-Bottleneck 结构, 其核心在于提出的 ICGA 模块在无额外计算开销下优化特征表示, 增强通道特征选择性。通过引入元移动区块, 调整扩展比例并采用高效算子, 实现模型模块化设计; 同时结合深度可分离卷积(DWConv)捕捉局部特征, 增强远距离信息处理能力, 提升网络效率与灵活性。针对轻量级设计导致的精度不足问题, 通过将 IRMB 的自注意力替换为 CGA^[25]注意力机制, 形成 ICGA 注意力机制, 提升模型的网络深度和检测精度。具体实现过程为: 首先生成查询(Q)和键(K)组件, 利用扩张卷积生成值(V)强化注意力效果; 再借助 DWConv 建模局部特征, 经挤压卷积恢复通道数, 最终将处理结果与输入相加。其网络结构图如图 3 所示。

ICGA 模块使用扩展窗口注意力机制模拟转换器的动态全局建模能力, 提高了防眩板检测准确性。其公式如下所示:

$$X' = \text{Lower}(X) \quad (1)$$

$$X_{QK} = \text{Conv}_Q(X') \cdot \text{Conv}_K(X')^T \cdot X' \quad (2)$$

$$X_V = \text{Conv}_V(X_{QK}) \quad (3)$$

$$X_e = \text{Up}(X_V) \quad (4)$$

其中 $X \in \mathbb{R}^{B \times C \times H \times W}$ 为输入特征映射; $X' \in \mathbb{R}^{(B \times \alpha^2) \times C \times \frac{H}{\alpha} \times \frac{W}{\alpha}}$, $X_V \in \mathbb{R}^{(B \times \alpha^2) \times \lambda C \times \frac{H}{\alpha} \times \frac{W}{\alpha}}$ 是输入中间特征映射; Q 、 K 、 V 分别表示查询、键和值操作; Lower 表示将 X 的宽度和高度减少 $1/\alpha$ 。最后使用 Up 操作变换 X_V 得到 $X_e \in \mathbb{R}^{B \times \lambda C \times H \times W}$ 。ICGA 使用深度卷积(DW-Conv)学习目标局部特征相互作用, 并表示为:

$$Y = \text{Conv}(\text{DW-Conv}(X_e) + X_e) + X \quad (5)$$

其中 Y 为输出特征映射。

CGA 注意力模块是通过特征分组处理和级联式信息融合, 解决了多头自注意力注意头冗余导致的计算效率低下的问题。其通过将输入特征通道均分给多个注意力头, 每个头独立处理不同特征子集以实现分组特征拆分, 各个注意力头在计算中使用较小的通道维度, 可以在不引入其他参数的条件下增加网络深度, 然后每个头的输出会级联到下一个头的输入中, 通过逐步融合增强特征表达能力的同时避免参数冗余。其分头处理机制可以高效的完成防眩板的检测任务, 在背景复杂的高速公路条件下有效的抑制背景环境对检

测任务的影响。CGA 注意力机制计算公式如下所示：

$$Attention(Q, K, V) = SoftMax\left(\frac{Q_i K_i^T}{\sqrt{d_k}} + B\right) V_i \quad (6)$$

$$X'_{ij} = Attention(X_{ij} W_{ij}^Q, X_{ij} W_{ij}^K, X_{ij} W_{ij}^V) \quad (7)$$

$$X'_{ij} = Concat(X'_{ij})_{j=1:h} W_i^P \quad (8)$$

$$X''_{ij} = X_{ij} + X'_{i(j-1)}, 2 \leq j \leq h \quad (9)$$

式中 j 为输入特征空间的第 j 个分割量, X_{ij} 通过 W_{ij} 被划分为不同的子空间 $W_{ij}^Q, W_{ij}^K, W_{ij}^V$, 通过自注意力得

到输出 X'_{ij} , 且所有头的输出特征通过线性层将连接后的输出特征投射回与输入相同维度。自注意力中 d 为缩放系数, B 为可训练偏置作相对位置编码。最后, 将每个注意力头的结果添加到下一个输入特征, 以级联的方式计算注意力分数, 增加了网络的深度且不引入额外参数。




图3 ICGA 网络结构图

Fig.3 ICGA network structure diagram

1.3 DE-LSCD 检测头

在防眩板检测任务中, 由于在不同车道线检测到的防眩板大小不一致, 会发生变化; 原始检测头之间缺乏信息交互, 可能会导致部分信息丢失。为解决此问题, 本文提出一种细节增强轻量级共享卷积检测头 DE-LSCD。图 4 为 DE-LSCD 的网络结构图。该网络采用 GroupNorm 替代 BatchNorm, 有效提升检测头的定位与分类性能, 增强模型鲁棒性。在检测头部分, 通过细节增强卷积 (DEConv) [26] 将先验信息融入普通卷积层, 提升网络表征与泛化能力, 并利用重参数化技术将 DEConv 转换为普通卷积, 实现特征细节增强, 同时避免增加额外参数与计算量。以 P3 层为例, 从 P3 层提取的特征经过 1 个 DEConv 调整通道, 再通过共享卷积进行深度特征提取, 随后分离为定位与分类分支。针对防眩板尺寸不一的问题, 在定位分支采用 Scale 操作对共享参数进行不同程度缩放, 有效解决尺度难题。其中, DEConv 卷积由 5 个并行工作卷积构

成, 分别采用了中心差分卷积(CDC)、角差分卷积(ADC)、水平差分卷积(HDC)和垂直差分卷积(VDC)计算图像中的差异, 进而提升模型的图像特征的细节提取能力。DEConv 利用重参数化技术可以以与普通卷积相同的计算成本得到输出 F 。公式如下所示:

$$F' = DEConv(F) = \sum_{i=1}^5 F * K_i = F * \left(\sum_{i=1}^5 K_i \right) = F * K_{cvt} \quad (10)$$

其中, $DEConv(\cdot)$ 表示 DEConv 的运算; K_i 为 VC、DC、ADC、HDC 和 CDC 的核; K_{cvt} 表示将并行卷积组合在一起的转换核; $*$ 表示卷积操作。分组归一化(GN)与批量归一化(BN)相比能保持较低的错误率, 其将输入通道分成多个组, 并在组内进行卷积, 提高了模型的计算效率。计算组内均值与方差的公式为:

$$\mu = \frac{1}{\left(\frac{C}{G}\right)HW} \sum_{c=g\left(\frac{C}{G}\right)}^{(g+1)\left(\frac{C}{G}\right)-1} \sum_{h=1}^H \sum_{w=1}^W x \quad (11)$$

$$\sigma^2 = \frac{1}{\left(\frac{C}{G}\right)HW} \sum_{c=g(\frac{C}{G})}^{(g+1)(\frac{C}{G})-1} \sum_{h=1}^H \sum_{w=1}^W (x - \mu)^2 \quad (12)$$

式中 x 为第 n 个样本在 c 个通道、第 h 行、第 w 列的特征值; C 是通道数, H 和 W 为特征图的高度和宽度, 将 C 个通道分成 G 个组, 每组有 C/G 个通道; $(C/G)HW$ 表示当前组内所有元素个数, 用于计算均值与方差时的归一化因子; g 为当前组的索引从 0 开

始, 用于定位通道范围; $(g+1)$ 作用是为了正确计算当前组的通道边界, $g(C/G)$ 为起始通道索引, $(g+1)(C/G)-1$ 为结束通道索引。然后对每个组的特征进行归一化, 公式如下:

$$\hat{x} = \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}} \quad (13)$$

式中 ε 为一个很小的常数, 通常取 10^{-5} 。




图4 DE-LSCD 网络结构图

Fig.4 network structure diagram

1.4 Inner-DIoU

在 YOLOv11 中用 CIoU 作为回归损失函数, CIoU^[27]考虑了纵横比、重叠面积以及中心点距离, 但在车载视角检测防眩板时进行自我调整和泛化能力不足, 且后续对防眩板缺失检测分析时依赖于检测框的精度。为解决这一问题, 本文引入一种可以快速收敛和精确定位的 Inner-DIoU 损失函数。Inner-DIoU 改进检测任务中边界框回归的准确性, 引入辅助边界框来计算损失函数。DIoU^[28]在基础 IoU 上增添了一个惩罚项, 提供了对重叠区域更加精确的评估; 与 CIoU 相比 DIoU 减少了边界框纵横比的计算, 减少了计算过程中的计算开销; 与 GIoU^[29]相比, GIoU 在预测矩形框与标注矩形框内部时会退化为 IoU 无法确定预测矩形框具体坐标, 因此这里本文选用 DIoU 作为基础损失函数, 用 Inner-IoU^[30]对 DIoU 进行优化形成 Inner-DIoU 损失函数, 通过缩放因子比计算损失的辅助边框的尺度大小, 使得边界框加速收敛, 以实现检测精度的提升。DIoU 的计算公式为:

$$DIoU = IoU - \frac{\rho^2(b, b^{gt})}{c^2} \quad (14)$$

其中 $\rho^2(b, b^{gt})$ 表示识别框与中心距离的欧式距离; c^2 表示识别框与预测框最小外接矩形的对角线长

度的平方。

Inner-IoU 计算公式为:

$$IoU^{inner} = \frac{inter}{union} \quad (15)$$

$$union = (w^{gt} \cdot h^{gt}) \cdot ratio^2 + (w \cdot h) \cdot ratio^2 - inter \quad (16)$$

$$inter = [\min(b_r^{gt}, b_r) - \max(b_l^{gt}, b_l)] \cdot [\min(b_b^{gt}, b_b) - \max(b_t^{gt}, b_t)] \quad (17)$$

$$b_l^{gt} = x_c^{gt} - \frac{w^{gt} \cdot ratio}{2} \quad (18)$$

$$b_r^{gt} = x_c^{gt} + \frac{w^{gt} \cdot ratio}{2} \quad (19)$$

$$b_t^{gt} = y_c^{gt} - \frac{h^{gt} \cdot ratio}{2} \quad (20)$$

$$b_b^{gt} = y_c^{gt} + \frac{h^{gt} \cdot ratio}{2} \quad (21)$$

$$b_l = x_c - \frac{w \cdot ratio}{2} \quad (22)$$

$$b_r = x_c + \frac{w \cdot ratio}{2} \quad (23)$$

$$b_t = y_c - \frac{h \cdot ratio}{2} \quad (24)$$

$$b_b = y_c + \frac{h \cdot ratio}{2} \quad (25)$$

Inner 引入 ratio 尺度因子, 通过指定 ratio 值, 根

据真实框和预测框的参数计算出辅助边框参数。其中 (x_c^{gt}, y_c^{gt}) 代表目标框的中心点； (x_c, y_c) 为预测框的中心点； w 和 h 分别代表预测框的宽度和高度； w^{gt} 和 h^{gt} 表示目标框的宽度和高度； b^{gt} 表示真实框的上下边界； b 表示预测框的边界。当 $ratio < 1$ 时，生成更小的辅助框，此时辅助框的 IoU 绝对值更大，加速高精度样本的收敛；当 $ratio > 1$ 时，生成更大的辅助框，扩大有效回归范围帮助模型快速定位目标。结合 Inner 与 DIoU 的损失函数可定义为：

$$L_{Inner-DIoU} = 1 - IoU^{Inner} + \frac{\rho^2(b, b^{gt})}{c^2} \quad (26)$$

1.5 防眩板缺失检测方法

针对高速公路防眩板缺失检测需求，提出一种基

于自适应阈值的实时检测方法。通过 ICL-YOLOv11 目标检测模型实现防眩板定位，结合几何特征分析与动态阈值计算构建检测系统。首先，基于车载巡检视角特性，限定左侧 1/3 图像区域作为 ROI^[31] 并选取前三个检测目标；其次，建立目标中心距计算模型，利用前 5 帧视频数据构建相邻防眩板距离的累积阈值基准；最后，实施动态阈值比对机制，当实时检测距离超过基准阈值时触发缺失预警，并生成可视化标识。该方法通过自适应阈值优化解决了多车道场景下的距离偏差问题，计算相邻目标中心距离公式为：

$$d_{i,j} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2} \quad (27)$$

其中 $d_{i,j}$ 为第 i 与第 j 检测框间的距离， x_i 为第 i 个检测框中心点 x 坐标， y_i 为第 i 个检测框中心点 y 坐标。防眩板缺失检测情况如图 5 所示。



图 5 防眩板缺失检测图

Fig.5 Anti-glare plate missing detection chart

2 实验与分析

2.1 数据集与数据标注

实验数据为高速公路实拍自建数据集，防眩板检测的训练集为 1200 张图像，验证集为 150 张图像，测试集为 150 张图像，数据集按照 8: 1: 1 的比例分割成训

练集，验证集和测试集。由于数据集较少，对数据集进行数据增强，改变图像的曝光度和饱和度，以增强检测的精度与鲁棒性数据增强效果如图 6 所示。同时文中提出在数据标注时采用预标注的方法对数据进行标注，首先人工标注 150 张图像并进行训练，其次用训练权重对其余数据进行推理标注，既减轻人工工作量又提高了标注的准确性，减轻了对人工标注的依赖。




图 6 数据增强对比图

Fig.6 Data Enhancement Comparison Chart

2.2 实验环境和设置

实验环境配置：实验的操作系统为 Windows11，深度学习框架由 PyTorch 构建，YOLOv11n 为基础网络模型。实验条件如表 1 所示。

表 1 环境配置表

Table 1 Environment configuration able

Name	Configuration
Operation	Windows11
GPU	NVIDIA GeForce RTX 4060
CPU	Intel Core i7-13700H
PyTorch	2.3.1+cu121
Python	3.12.5

该实验平台可以支撑多数深度学习任务如本文中的防眩板检测任务。训练中的参数设置为 300epoch、Batch Size 设置为 16、初始学习率为 0.01，且为了防止模型出现过拟合状况设置随机种子 Seed 为 1、实验中同时使用 SGD 优化器用于训练优化。

2.3 评价指标

为了评价本次检测任务中性能，本研究利用精度 (P)、召回率(R)、平均精度 (mAP) 的指标大小衡量模型。公式如下所示：

$$P = \frac{TP}{TP + FP} \quad (28)$$

$$R = \frac{TP}{TP + FN} \quad (29)$$

$$AP = \int_0^1 P(R) dR = \sum_{k=1}^N P(k) \Delta R(k) \quad (30)$$

表 2 C3K2 模块结果对比表

Table 2 C3K2 Module results comparison table

Module	Methods	Params	GFLOPs	P%	R%	mAP50%	FPS 帧/s
C3K2	+IEMA	2550651	6.3	81.2	70.4	77.3	51.0
	+IRMB	2615115	6.4	83.4	68.6	77.2	76.3
	+CGA	2683335	6.5	81.3	68.5	77.2	51.8
	+ICGA	2444283	6.3	84.7	70.9	77.5	79.3

2.4.2 检测头比较实验

DE-LSCD 通过细节增强卷积与参数共享机制在检测精度与效率间实现显著平衡。为了验证在移动检测任务中 DE-LSCD 模块的有效性，选取了主流检测头 LSCD 与 LADH 进行比较。

$$mAP = \frac{1}{n} \sum_{k=1}^{k=n} AP_k \quad (31)$$

其中 P 反映模型正确检测到的对象占预测对象的比例即模型的准确率，R 反映正确检测到的对象占总数的比例即模型的召回率。TP 代表正确识别的阳性样本的数量、FP 代表错误识别的阳性样本的数量、FN 代表错误识别的阴性样本的数量。mAP 表示所有类的平均精度之和除以类的总数，反映了模型检测的准确性。此外，根据模型的参数数量和浮点运算 (GFLOPs) 来反映模型的复杂度。

2.4 实验结果分析

2.4.1 主干网络比较实验

为验证面向防眩板动态检测的改进的 ICGA 注意力机制的有效性，本研究在 YOLOv11n 的主干网络 C3K2 模块中分别集成 IEMA、IRMB、CGA 及 ICGA 进行对比实验。

表 2 为 C3K2 模块的定量分析结果，实验结果表明，ICGA 通过分组特征拆分和级联信息融合减少了计算量的同时综合提升了模型的准确率和召回率。在准确率上略有提升，较次优模型提升 1.3 个百分点，在召回率上模型提升有限，较次优模型仅提升 0.5 个百分点。在推理速度方面，C3K2-ICGA 的 FPS 较次优模型提高 3 帧/s。在参数量与计算复杂度方面，均低于集成其他模块，证明 C3K2-ICGA 在高速公路巡检任务中具备更加卓越的性能。

表 3 的实验结果表明，在准确率方面，与次优模型持平，但在 mAP50% 上略有提升，提升了 0.8 个百分点。在召回率上，较次优模型提升了 4.6 个百分点。在计算复杂度上略高于其余模型，但在参数量上略低于其他模型。在推理速度方面，较次优模型提升了 2.1 帧/s。以

上实验结果证明了,融入细节增强卷积的轻量级共享卷积头在高速公路巡检任务中的平衡性与有效性。

表 3 检测头结果对比表

Table 3 Comparison table of test head results

Models	Methods	Params	GFLOPs	P%	R%	mAP50%	FPS 帧/s
Head	LSCD	2420492	5.6	83.2	72.0	78.5	78.5
	LADH	2281547	5.2	82.7	69.0	76.9	76.9
	DE-LSCD	2260300	6.0	83.2	76.6	79.3	80.6

2.4.3 损失函数比较实验

为了验证 Inner-DIoU 在防眩板检测任务中的有效性,本节选取 Clou、DIoU 和 GIoU 损失函数进行对比实验。如表 4 所示,在召回率方面提升较为明显,较次优模型提升 4.6 个百分点。在 mAP50%上较次优模型提升 3.3 个百分点。在准确率与推理速度方面没

有大幅落后,mAP(50-95)%略低于 Clou,在实际工程应用中,召回率是防止发生漏检的重要指标,其更关注于目标是否存在。综合考虑,满足在高速巡检任务中对防眩板检测的需求。实验结果表明,对于车载防眩板检测系统,虽然在准确率与推理速度上略有欠缺,但其高召回率与高精度可作为后处理算法的补偿,防止缺失检测的漏检情况。

表 4 损失函数结果对比表

Table 4 Comparison table of loss function results

Models	Params	GFLOPs	P%	R%	mAP50%	mAP (50-95) %	FPS 帧/s
Clou	2582347	6.3	85.4	66.3	74.9	43.5	81.9
DIoU	2582347	6.3	84.3	67.2	75.7	41.4	83.4
GIoU	2582347	6.3	84.7	66.4	73.0	39.8	58.9
Inner-DIoU	2582347	6.3	83.7	71.8	79.0	42.7	76.0

2.4.4 模型对比实验

为了证明提出的 ICL-YOLOv11 模型在防眩板目标检测任务中的优越性,进行了一系列的对比试验。在相同的实验设置中进行了定量比较,使用参数数量(Params)、浮点运算(GFLOPs)、准确率(P)、召回率(R)和平均准确率(mAP50)等性能指标对改进模型进行评估。将 ICL-YOLOv11 与 YOLOv8n、YOLOv9t、YOLOv10n、RT-DETR 和 YOLOv11n 进行对比。

如表 5 所示,实验结果表明 ICL-YOLOv11 在各种关键性能上取得了显著的提升。具体而言:ICL-YOLOv11 获得 84.9%的准确率、76.6%的召回率、81.3%的 mAP50%和 84.1 帧/s 的推理速度,较次优模型 YOLOv11n 分别提升 0.6 个百分点、10.3 个百分点、6.4 个百分点和 2.2 帧/s。与相同规模的模型相比,ICL-YOLOv11 表现出更高的检测精度与推理速度。这主要得益于 ICGA 通过特征分组处理和级联式信息融合,解决了多头自注意力注意头冗余导致的计算效率低下的问题,同时,在检测头中引入细节增强卷积提升细

节特征提取以及轻量化的共享检测头,使得模型的参数量得到有效的控制。

相较于 YOLOv8-n 其 mAP50%和 mAP(50-95)%分别提升了 8.7 个百分点和 2.1 百分点,召回率提升 10.7 个百分点,同时在推理速度方面提升了 18.3 帧/s,且在参数量上减少 22%。对比 YOLOv9-t,ICL-YOLOv11 在 mAP50%上提升 7.9 个百分点,虽在参数量上有所增加,但在推理速度方面 ICL-YOLOv11 呈显著优势提升了 65.7 帧/s。此外与 YOLOv10n 相比,ICL-YOLOv11 的 mAP50%与召回率分别提升 8.0 个百分点与 11.0 个百分点,且在推理速度上增加了 10.6 帧/s,进一步体现了模型设计的高效性。与 RT-DETR 相比,ICL-YOLOv11 各方面呈显著优势,由于 RT-DETR 的模型参数量较多计算复杂度较高,导致其不适用于高速巡检任务当中。在参数量与推理速度相差不大的情况下,ICL-YOLOv11 相较于 YOLOv11n 在 mAP50%和召回率上分别提升 6.4 个百分点和 10.3 个百分点,同时在计算复杂度上减少 23.8%。因此,ICL-YOLOv11

的设计在参数量 $mAP(50-95)\%$ 上略有劣势, 但其在其余方面都呈现显著优势。考虑到实际应用中对检测精度与实时性的需求, ICL-YOLOv11 能在保持高精度的

同时, 仍能保持较低参数量与较快的推理速度。这种性能特性使其适用于需要实时检测的高速公路巡检任务中。

表 5 对比实验结果表

Table 5 Comparative experimental results table

Models	Params	GFLOPs	P%	R%	mAP50%	mAP(50-95) %	FPS 帧/s
YOLOv8-n	3005843	8.1	84.1	65.9	72.6	42.3	65.8
YOLOv9-t	2005587	7.8	84.4	66.4	73.4	41.1	18.4
YOLOv10-n	2694806	8.2	84.0	65.6	73.3	45.2	73.5
RT-DETR	31985795	103.4	82.2	71.0	71.2	32.0	42.9
YOLOv11-n	2582347	6.3	84.3	66.3	74.9	41.4	81.9
ICL-YOLOv11	2317948	4.8	84.9	76.6	81.3	44.4	84.1

2.5 消融实验

为了验证改进策略的有效性, 设计并完成消融实验, 实验结果如表 6 所示。每组实验均在相同实验配置环境下进行。

从表 6 中可以看出, 使用 YOLOv11n 作为基准模型, 通过协同融合 ICGA、DE-LSCD、Inner-DIoU 三项核心创新, 实现了在精度、效率和鲁棒性上的显著提升。Model 0 为改进的基础模型 YOLOv11n 检测效果, 根据 Model 1 和 Model 2 可以看出, 单独引入 IRMB 和 CGA 模块导致 P 降低且参数量略有增长, 增加了计算复杂度, 但是在 R 和 mAP50 上略有增加。Model 3 是将 ICGA 模块引入基础模型中的结果, 模型的参数量减少, P 略有增长, R 增长了 4.6 个百分点, 在 mAP50 上增加了 2.6 个百分点, 但在推理速度上略有减少, 这表明将 ICGA 融入 C3K2 模块中增加模型的

特征提取能力使其在检测精度上得到提升, 但在原来基础上的计算复杂度与参数量略有增加。在上述基础上, 将基础模型的检测头替换为 DE-LSCD 检测头形成 Model 4, 进一步减少了参数量减少计算复杂度, 虽然在 P 上有降低, 但是在 R 和 mAP50% 上都发生了显著的增长, 分别增长了 7.1 个百分点和 5.5 个百分点, 这得益于对检测头的轻量化设计与引入细节增强卷积, 提升了模型的表征能力。最后, 引入 Inner-DIoU 损失函数后, 优化了边界框的筛选策略, 进一步提升了目标定位精度, 与 Model 4 相比, 使其在 P、R、mAP50 上分别增长了 2.6、3.6 和 0.9 个百分点。实验结果表明, 改进的算法能在提升精度和推理速度的同时降低模型参数量与复杂度, 适用于高速公路防眩板缺失巡检任务中。

表 6 消融实验结果表

Table 6 Table of ablation experiment results

Models	ICGA	IRMB	CGA	DE-LSCD	Inner-DIoU	Params	GFLOPs	P%	R%	mAP50%	FPS 帧/s
0						2582347	6.3	84.3	66.3	74.9	81.9
1			√			2683335	6.5	81.3	68.5	77.2	51.8
2		√				2615115	6.4	83.4	68.6	77.2	76.3
3	√					2444283	6.3	84.7	70.9	77.5	79.3
4	√			√		2317948	4.8	82.3	73.4	80.4	79.4
5	√			√	√	2317948	4.8	84.9	76.6	81.3	84.1

2.6 对比实验

为证明所提算法相较于其他算法的有效性，将所提算法在 KITTI 公开数据集上与主流的其他算法进行对比实验，结果如表 7 所示。本文所提算法在 KITTI 公开数据集上有良好的表现，相较于

YOLOv11n 模型，在 mAP50%和召回率上分别提升了 5.7 个百分点和 8.6 个百分点，且在其他性能上均优于其他算法。因此 ICL-YOLOv11 在提高模型精度的同时提升了模型检测速度，适用于高速公路防眩板缺失巡检任务中。

表 7 KITTI 数据集对比试验结果表

Table 7 Table of results of comparative experiments on the KITTI dataset

Models	P%	R%	mAP50%	FPS/帧/s
Faster R-CNN	70.1	65.6	63.4	13.4
SSD	65.6	60.5	59.1	50.2
YOLOv8n	81.4	63.7	70.1	65.5
YOLOv9t	81.9	60.3	71.8	17.7
YOLOv10n	81.2	60.4	71.1	72.3
RT-DETR	79.4	66.3	68.5	43.0
YOLOv11n	82.6	63.5	72.6	80.6
ICL-YOLOv11	83.7	72.1	78.3	84.0

2.7 训练曲线及可视化结果对比

为了更直观的观察改进算法对 YOLOv11n 目标检测的增强效果，图 7、图 8、图 9 与图 10 综合展示了 YOLOv11 和逐步改进算法在训练过程中 mAP50、mAP50-95、训练损失、验证损失、热力图和预测对比

的结果。从对比曲线中可以看出，改进算法在检测精度上的优势与其较快的收敛速度。由热力图可得改进算法更加专注于防眩板目标的检测。由预测对比图可得改进模型的检测精度逐步上升，体现了其检测性能的优势。




图 7 mAP50 和 mAP50-95 对比曲线图

Fig.7 Comparison curves of mAP50 and mAP50-95




图 8 损失函数对比曲线图

Fig.8 Loss function comparison curve plot




图 9 模型热力图

Fig.9 Model heat map




图 10 预测结果对比图

Fig.10 Comparison chart of forecast results

其中, Model 0 为 YOLOv11n 模型; Model 1 为在 YOLOv11n 主干网络上增加 CGA 模块的模型; Model 2 为在 YOLOv11n 主干网络上增加 IRMB 模块的模型; Model 3 为在 YOLOv11n 主干网络增加 ICGA 模块的模型; Model 4 为在 YOLOv11n 增加 ICGA 模块与 DE-LSCD 模块的模型; Model 5 为在 YOLOv11n 增加 ICGA 模块与 DE-LSCD 模块, 且引入 Inner-DIoU 损失函数的模型。

3 结论

本文介绍了一种基于 YOLOv11n 的改进算法, 为检测防眩板缺失提供检测基础。该算法集成了多个精细化模块, 提升了对防眩板检测的准确性。为了增强各个层的特征信息提取能力, 该算法通过在主干网络中引入 ICGA 注意力机制, 完成对 C3K2 模块的改进。此外, 用更加轻量化且高效的检测头 DE-

LSCD 替换原来的检测头以提升对检测目标的准确度。最终用 Inner-DIoU 损失函数代替 YOLOv11n 的 CIoU 损失函数, 该函数可以快速收敛和精确定位, 增强了回归性能且更加适合于本次缺失任务的检测, 提升了整体算法性能。且提出基于像素距离的动态阈值自适应检测防眩板缺失的方法。与 YOLOv11n 相比, ICL-YOLOv11 的 P、R、mAP50 和 mAP50-95 分别达到了 84.9%、76.6%、81.3% 和 44.4%, 比原来 YOLOv11n 分别提高了 0.6 个百分点、10.3 个百分点、6.4 个百分点和 3.0 个百分点。在计算参数方面, 改进算法参数量少于原 YOLOv11n 模型的参数量, 减轻了模型的计算复杂度。在推理速度方面达到了 84.1 帧/s。证实了 ICL-YOLOv11 算法在检测防眩板缺失方面的有效性和实用性。接下来将通过模型蒸馏和剪枝技术减少不重要的权重, 旨在保证模型精度的条件下进一步增强模型检测能力, 继续改进检

测方法,提升防眩板缺失检测能力防止错检,漏检。

参考文献

- [1] FERNANDEZ-CARROBLES M M, DENIZ O, MAROTO F. Gun and knife detection based on faster R-CNN for video surveillance[C]//Iberian conference on pattern recognition and image analysis. Cham: Springer International Publishing, 2019: 441-452.
- [2] GIRSHICK R. Fast r-cnn [C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
- [3] LI W. Analysis of object detection performance based on Faster R-CNN [C]//Journal of Physics: Conference Series. IOP Publishing, 2021, 1827(1): 012085.
- [4] XU X, ZHAO M, SHI P, et al. Crack detection and comparison study based on faster R-CNN and mask R-CNN[J]. Sensors, 2022, 22(3): 1215.
- [5] YANG J T, TIAN Z C, WEN H, et al. Robust Orientation Method Based on an Atmospheric Polarization Model for Hazy Weather[J]. IEEE Internet of Things Journal, 2024, DOI 10.1109/JIOT.2024.3521943.
- [6] KIM J-H, KIM N, PARK Y W, WON C S. Object detection and classification based on YOLO-V5 with improved maritime dataset[J]. Journal of Marine Science and Engineering, 2022, 10(3): 377.
- [7] LI C, LI L, JIANG H, et al. YOLOv6: A single-stage object detection framework for industrial applications[J]. arXiv preprint arXiv:2209.02976, 2022.
- [8] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023:7464-7475.
- [9] REDMON J, DIVVALA S, GIRSHICK R, FARHADI A. You only look once: Unified real-time object detection[C]//Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2016:779-788.
- [10] LIU W, ANGUELOV D, ERHAN D. Ssd: Single shot multibox detector[C]//Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part I 14. Springer International Publishing, 2016: 21-37.
- [11] DONG Y, ZHANG Y, HOU Y, et al. Damage recognition of road auxiliary facilities based on deep convolution network for segmentation and image region correction[J]. Advances in Civil Engineering, 2022, 2022(1): 5995999.
- [12] FENG J, YI C. Lightweight detection network for arbitrary-oriented vehicles in UAV imagery via global attentive relation and multi-path fusion[J]. Drones, 2022, 6(5): 108.
- [13] LV Z, WANG R, WANG Y, et al. Road scene multi-object detection algorithm based on CMS-YOLO[J]. IEEE Access, 2023, 11: 121190-121201.
- [14] SU J, Wang F, Zhuang W. An Improved YOLOv7 Tiny Algorithm for Vehicle and Pedestrian Detection with Occlusion in Autonomous Driving[J]. Chinese Journal of Electronics, 2025, 34(1): 282-294.
- [15] Ren H, Jing F, Li S. DCW-YOLO: road object detection algorithms for autonomous driving[J]. IEEE Access, 2024: 1-1.
- [16] Wang Q, Wang Q L. BT-YOLO11: Automatic Driving Road Target Detection in Complex Scenarios[J]. IEEE Access, 2025, 13: 72364-72374.
- [17] 郭君斌,于琳,于传强.改进 YOLOv5s 算法在交通标志检测识别中的应用[J].国防科技大学学报, 2024, 46(06): 123-130.
- GUO J B, YU L, YU C Q. Application of improved YOLOv5s algorithm in traffic sign detection and recognition[J]. Journal of National University of Defense Technology, 2024, 46(06): 123-130.
- [18] 谢祖华,李海涛,胡建文.基于 YOLOv7 的雾天实时目标检测方法[J/OL].电子测量技术, 1-10 [2025-06-16]. <http://kns.cnki.net/kcms/detail/11.2175.TN.20250425.1219.024.html>.
- XIE Z H, LI H T, HU J W. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors[J/OL]. Electronic measurement technology, 1-10 [2025-06-16]. <http://kns.cnki.net/kcms/detail/11.2175.TN.20250425.1219.024.html>.
- [19] 朱彦,张月霞.SEP-YOLO: 基于 YOLOv8 改进的道路目标检测算法[J/OL].计算机应用与软件, 1-8 [2025-06-16]. <http://kns.cnki.net/kcms/detail/31.1260.tp.20240829.1140.002.html>.
- ZHU Y, ZHANG Y X. SEP-YOLO: ROAD OBJECT DETECTION ALGORITHM IMPROVED BASED ON YOLOV8[J/OL]. Computer Applications and Software, 1-8 [2025-06-16]. <http://kns.cnki.net/kcms/detail/31.1260.tp.20240829.1140.002.html>.
- [20] 廖炎华,万学俊,赵周洲,等.RO-YOLOv9 车辆行人检测算法[J].计算机工程与应用, 2025, 61(11): 144-155.
- LIAO Y H, WAN X J, ZHAO Z Z, et al. RO-YOLOv9 Vehicle and Pedestrian Detection Algorithm[J]. Computer Engineering and Applications, 2025, 61(11): 144-155.
- [21] 董一兵,曾辉,李建科,等.DPRT-YOLO:智能网联汽车复杂驾驶环境实时目标检测器[J/OL].计算机工程与应用, 1-19 [2025-06-

- 16].<http://kns.cnki.net/kcms/detail/11.2127.TP.20250317.1012.002.html>.
DONG Y B, ZENG H, LI J K, et al. DPRT-YOLO: A Real-time Object Detector for Intelligent and Connected Vehicles in Complex Driving Environments[J/OL]. Computer Engineering and Applications, 1-19 [2025-06-16].<http://kns.cnki.net/kcms/detail/11.2127.TP.20250317.1012.002.html>.
- [22] 宋晓茹,王嘉乐,刘通,等.改进 YOLOv11 的复杂场景下交通车辆检测方法[J/OL].激光杂志, 1-9 [2025-06-16].
<http://kns.cnki.net/kcms/detail/50.1085.TN.20250523.1108.012.html>.
SONG X R, WANG J L, LIU T, et al. Improved YOLOv11 traffic vehicle detection method in complex scenarios[J/OL]. Laser Journal, 1-9 [2025-06-16].
<http://kns.cnki.net/kcms/detail/50.1085.TN.20250523.1108.012.html>.
- [23] WU J. Plant Disease Inspection Based on YOLOv9-iRMB[J]. Advances in Engineering Technology Research, 2025, 13(1): 904-904.
- [24] PARMAR N, VASWANI A, USZKOREIT J, et al. Image transformer[C]//International conference on machine learning. PMLR, 2018: 4055-4064.
- [25] CAI H, LI J, HU M, et al. Efficientvit: Lightweight multi-scale attention for high-resolution dense prediction[C]//proceedings of the IEEE/CVF international conference on computer vision. 2023: 17302-17313.
- [26] CHEN Z, HE Z, LU Z-M. DEA-Net: Single image dehazing based on detail-enhanced convolution and content-guided attention[J]. IEEE Transactions on Image Processing, 2024, 33: 1002-1015.
- [27] GAO J, CHEN Y, WEI Y, LI J. Detection of specific building in remote sensing images using a novel YOLO-S-CIOU model. Case: Gas station identification[J]. Sensors, 2021, 21(4): 1375.
- [28] LI S J, LIU Y X, LI M, DING L. DF-YOLO: Highly accurate transmission line foreign object detection algorithm[J]. IEEE Access, 2023, 11: 108398-108406.
- [29] ZHENG Z, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 12993-13000.
- [30] ZHANG H, XU C, ZHANG S. Inner-IoU: More effective intersection over union loss with auxiliary bounding box[J]. arXiv preprint arXiv: 2311.02877,2023.
- [31] DING J, XUE N, LONG Y, et al. Learning RoI transformer for oriented object detection in aerial images[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 2849-2858.