



东南大学学报(自然科学版)
Journal of Southeast University(Natural Science Edition)
ISSN 1001-0505,CN 32-1178/N

《东南大学学报(自然科学版)》网络首发论文

题目: 基于 YOLOv11n 的桥梁水下结构病害轻量化快速目标检测模型
作者: 赵井卫, 沈涵, 侯士通, 赵鹏程, 吴刚
收稿日期: 2025-09-11
网络首发日期: 2025-11-26
引用格式: 赵井卫, 沈涵, 侯士通, 赵鹏程, 吴刚. 基于 YOLOv11n 的桥梁水下结构病害轻量化快速目标检测模型[J/OL]. 东南大学学报(自然科学版).
<https://link.cnki.net/urlid/32.1178.N.20251126.1241.004>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

基于 YOLOv11n 的桥梁水下结构病害轻量化快速目标检测模型

赵井卫^{1, 2}, 沈涵^{1, 2}, 侯士通^{1, 2}, 赵鹏程^{1, 2}, 吴刚^{1, 2}

(1. 东南大学土木工程学院, 南京 211189; 2. 东南大学智慧建造与运维国家地方联合工程研究中心, 南京 211189)

摘要: 为实现桥梁水下结构病害的高效检测, 提出了一种轻量化快速目标检测模型 CF-YOLOv11n。引入上下文感知局部增强注意力机制, 通过双分支结构将全局语义与局部细节信息相融合, 利用深度卷积来减少冗余计算, 提升推理速度。通过频域调制前馈网络, 对特征进行局部窗口频域滤波, 实现多尺度特征建模与背景干扰抑制, 从而提升检测精度。结果表明, CF-YOLOv11n 在实桥数据集下的 mAP_{50:95} 达到 45.50%, 相较于基线模型提升了 2.46%; 推理速度为 66.13 帧/s, 为基线模型的 2.25 倍。相对于基线模型, 所提模型能够更好地捕捉多尺度信息, 加快推理过程, 并兼顾精度与速度, 在实际桥梁水下环境的实时检测任务中展现出更优的工程应用价值。

关键词: 桥梁水下结构; 目标检测; 注意力机制; 前馈神经网络 (FNN); 频域特征建模
中图分类号: U446.2

Lightweight and fast object detection model for bridge underwater defects based on YOLOv11n

Zhao Jingwei^{1, 2}, Shen Han^{1, 2}, Hou Shitong^{1, 2}, Zhao Pengcheng^{1, 2}, Wu Gang^{1, 2}

(1. School of Materials Science and Engineering, Southeast University, Nanjing 211189, China;
2. National and Local Joint Engineering Research Center for Smart Construction and Operation and Maintenance, Southeast University, Nanjing 211189, China)

Abstract: To achieve efficient detection of bridge underwater defects, a lightweight and fast object detection model CF-YOLOv11n was proposed. A context-aware local enhancement attention mechanism with a dual-branch structure was introduced to fuse global semantic and local detail information, while depth-wise convolution was used to reduce the redundant computation and improve the inference speed. A frequency-modulation feed-forward network performs local-window frequency domain filtering to realize multi-scale feature modeling and suppress background interference, thereby improving the detection accuracy. The results show that the mAP_{0.5:0.95} (mean average precision at intersection over union thresholds from 0.5 to 0.95) of CF-YOLOv11n on a real bridge dataset reaches 45.50%, which is 2.46% higher than that of the baseline. The inference speed is 66.13 frame/s, which is 2.25 times faster than that of the baseline. Compared with the baseline model, the proposed model can capture multi-scale information more effectively, accelerate the inference process, and balance accuracy and speed, demonstrating stronger engineering application value in real-time detection tasks within actual underwater bridge environments.

收稿日期: 2025-09-11

作者简介: 赵井卫 (1981—), 男, 博士生; 侯士通 (通信作者), 男, 博士, 副教授, 101013197@seu.edu.cn.

基金项目: 国家自然科学基金青年基金资助项目 (52208306); 江苏省自然科学基金青年基金资助项目 (BK20220849)。

Key words: bridge underwater structure; object detection; attention mechanism; feedforward neural network (FNN); frequency domain feature modeling

桥梁作为国家基础设施的重要枢纽之一，是维系社会生产和人民生活的生命线工程^[1-2]，其下部结构是承载上部荷载、传递外力的关键载体，直接决定桥梁整体安全性能与服役寿命^[3]。相较于上部结构，桥梁水下结构长期抵御水流冲刷、泥沙磨蚀等多重作用，易产生混凝土剥落、露筋、骨料露出等表观病害^[4]。然而，桥梁水下结构因处于独特复杂环境，其病害往往易被忽视^[5-7]。因此，实现桥梁水下结构表观病害的高效、精准检测，已成为保障桥梁全生命周期安全的核心需求。

当前，桥梁水下结构检测主要依靠专业人员进行潜水探摸作业，存在高危、费时等缺点^[8-11]，同时，光源、水质等因素往往会对图像识别的准确率产生不利影响^[12]。随着深度学习技术的发展，基于卷积神经网络的目标检测算法已逐步被应用到桥梁水下结构检测任务中^[13-15]。骆剑彬等^[16]开展了基于 Fast R-CNN 模型的多类型病害分类识别与区域定位研究，对数据增强后的水下桩墩声呐图像进行训练和识别，但声呐成本较高，难以推广应用^[17]。Jiang 等^[18]提出了一种将像素级图像融合增强算法与 YOLOv3 算法相结合的目标检测模型，为水下桩基表面缺陷的检测提供了方法和技术支持，但数据集样本较少，且模型收敛速度较慢，难以实现工程应用中的病害实时检测和快速反馈。Li 等^[19]通过对 YOLOv4 模型的主干网络进行轻量化改进，将模型尺寸减至原来的 1/5，检测速度提升 178%，但识别精度有所下降。现有桥梁水下结构病害目标检测模型难以兼顾精度、速度与轻量化水平。

桥梁水下结构病害图像的获取主要依赖人工下水，自动化程度低，存在高风险与低效率等问题。相比之下，水下机器人能够在复杂环境中高效采集病害图像，减少人工成本并提升作业安全性。文献[20]将水下机器人与轻量级神经网络相结合，使用水下机器人采集水下隧洞淤积图像，并基于 MobileNetv3 模型进行训练测试。Zhang 等^[21]将优化的 MobileNet-Detection 模型用于水下检测机器人中，并集成了新型的 HiLo 注意力模块，降低了水下检查操作的风险和劳动强度。然而，现有研究在检测精度与实用性方面仍存在不足。

现有桥梁水下结构病害检测方法难以平衡精度与效率，且依赖人工，在低光照、高浊度等复杂水下环境下，无法兼顾检测实时性与精确性。基于此，本文基于 YOLOv11n 模型，提出了一种轻量化快速检测模型 CF-YOLOv11n，结合上下文感知局部增强注意力机制与可调频的前馈网络，实现特征提取的高效融合与推理速度的显著提升。在保持低复杂度和快速推理的同时，提升检测精度，为桥梁水下结构病害的快速智能检测提供了新的技术路线。

1 YOLOv11n 基准模型

YOLOv11n 是在 YOLOv8 基础上改进的单阶段目标检测模型，延续了骨干、颈部与检测头的三段式架构，并在特征提取与计算效率上进行了进一步优化^[22-23]。骨干网络引入了 C2PSA 模块，通过嵌入部分空间注意力机制，显著增强了空间特征的建模能力。在颈部结构中采用 C3K2 模块替代原有的 C2f 模块，通过通道分离与双卷积设计，提升特征复用效率与计算性能。C2PSA 模块在 C2 结构中引入部分空间注意力（partial spatial attention, PSA）模块，堆叠 n 次，将特征图划分为多个区域并分配独立权重，从而增强模型对关键区域的关注能力（见图 1(a)）。C3K2 模块则在传统 CSP 基础上进行改进，通过通道分离和可变卷积核设计，提升特征复用能力与计算效率（见图 1(b)）。




图 1 模块结构示意图

Fig. 1 Structural diagrams of modules

2 基于 YOLOv11n 改进的模型结构

2.1 CF-YOLO11 模型结构


桥梁水下结构病害检测要求模型在水下机器人（ROV）有限的计算资源下实现高帧率的实时推理，且要克服因水下恶劣成像条件对病害特征精准检测的干扰。因此，本文对传统 YOLOv11n 模型中的 C3K2 模块与 C2PSA 模块进行针对性优化，提出了一种轻量化快速目标检测模型 CF-YOLOv11n，使其在保障精度的前提下实现高效快速检测。

首先，在 C3K2 模块的瓶颈层引入上下文感知局部增强注意力机制^[24]（context-aware local enhancement attention, CloAttention），在经典 Transformer 网络的基础上，利用深度卷积（depth-wise convolution, DWconv）提取局部表示，并部署上下文感知权重来增强局部特


征，极大降低了网络的冗余计算，提升模型的检测效率。同时，针对原始 C2PSA 模块在尺度建模方面的不足以及对复杂背景下目标特征抑制不充分的问题，对前馈网络（feed-forward network, FFN）模块进行改进，在 PSA 模块中引入频域调制前馈网络，有效提升多尺度特征融合与上下文建模能力，抑制非必要背景信息干扰，从而进一步提高检测精度。

2.2 基于上下文感知局部增强机制改进的 C3K2 模块

桥梁水下实时巡检任务对检测模型的推理速度要求较高。传统 YOLOv11n 模型中的 C3K2 模块虽已进行优化，但在部署于水下机器人等内存带宽和功耗受限的边缘设备时，其计算结构仍存在进一步优化的空间。引入 Transformer 等全局建模结构虽然可以提升精度，但计算复杂度较高，水下机器人的算力资源有限，难以满足实时性需求。因此，本文对传统 C3K2 模块进行改进，以保证轻量化和精度的同时加快推理速度。如图 1(b)所示，YOLOv11n 模型中的 C3K2 模块由多个 C3K 模块和瓶颈层堆叠构成，同时，在 C3K 模块内部，瓶颈层为基本特征提取单元。基于这一层级关系，本文首先在瓶颈层中引入上下文感知局部增强注意力机制，得到改进后的瓶颈层（见图 2(a)）；其次，将改进后的瓶颈层替换原 C3K 模块中的传统瓶颈层，形成改进的 C-C3K 模块（见图 2(b)）；然后，将改进后的瓶颈层和 C-C3K 模块嵌入 C3K2 模块中，得到新的 C-C3K2 模块。C-C3K2 模块通过共享权重机制与上下文感知权重设计的协同作用，实现上下文感知局部增强，减少了冗余计算，提升了推理效率与速度。



(a) 基于上下文感知局部增强注意力机制改进的瓶颈层



(b) C-C3K 模块

图 2 C-C3K2 模块示意图

Fig. 2 Schematic diagram of C-C3K2 modules




图 3 上下文感知局部增强注意力机制网络结构示意图

Fig. 3 Schematic diagram of network architecture of context-aware local enhancement attention mechanism

有效融合全局语义与局部细节并突破传统注意力机制的计算瓶颈,上下文感知局部增强注意力机制采用并行的双分支结构(见图3)。在图像处理中,低频分量通常对应于全局且平滑的结构信息,高频分量则代表图像的局部细节、边缘和纹理信息。在上下文感知局部增强注意力机制中,设置低频分支,用于全局语义信息建模。该分支通过带下采样的标准注意力模块对输入特征进行处理,输入特征的查询、键和值特征图分别为 Q_g 、 K_g 和 V_g 。首先,利用池化算子 $\text{Pool}(\cdot)$,对键、值特征进行下采样。在平滑特征图的同时,有效滤除高频噪声和细节,从而提取出代表全局语义的低频概要信息。然后,对查询、下采样后的键和值执行标准注意力计算,即

$$\mathbf{x}_g = \text{Attn}\left(\mathbf{Q}_g, \text{Pool}(\mathbf{K}_g), \text{Pool}(\mathbf{V}_g)\right) \quad (1)$$

式中, $\mathbf{x}_g$ 为全局分支输出特征图; $\text{Attn}(\cdot)$ 为标准自注意力算子。

为克服传统 Transformer 网络中对于高频信息处理不足的问题，在另一个分支中引入注意力风格卷积算子（attention style convolution operator, AttnConv），获取高频局部信息。首先，将输入特征 X_{in} 通过 3 组互不共享参数的全连接映射，分别投影得到查询 Q 、键 K 和值 V ，即

$$Q = FC_Q(X_{in}) \quad (2)$$

$$K = FC_K(X_{in}) \quad (3)$$

$$V = FC_V(X_{in}) \quad (4)$$

式中， $FC_Q(\cdot)$ 、 $FC_K(\cdot)$ 、 $FC_V(\cdot)$ 为三组独立的全连接层的线性映射。

然后，利用共享权重，对 V 进行局部特征聚合处理，根据处理后的 V 、 Q 和 K ，执行基于上下文感知的局部增强操作。局部特征聚合处理通过深度卷积算子 $DWconv(\cdot)$ 来实现，即

$$v_s = DWconv(V) \quad (5)$$

式中， v_s 表示经过局部聚合的值特征图。

2.2.1 基于上下文感知局部增强注意力机制

区别于经典的局部自注意力机制，基于上下文感知的局部增强方法首先分别对查询和键特征进行局部信息聚合，以引入空间局部性建模能力。令局部聚合后的查询和键特征分别为 q_1 和 k_1 ，则

$$q_1 = DWconv(Q) \quad (6)$$

$$k_1 = DWconv(K) \quad (7)$$

然后，计算 q_1 和 k_1 的 Hadamard 积，将乘积结果通过一个全连接层（fully connected layer, FC），进行非线性转换，加强非线性注意力匹配关系，并对结果进行归一化处理。中间注意力权重为

$$a_t = FC\left(\text{Swish}(FC(q_1 \odot k_1))\right) \quad (8)$$

式中， $FC(\cdot)$ 为全连接层的线性映射； $\text{Swish}(\cdot)$ 为 Swish 非线性激活函数； $\odot$ 为 Hadamard 积。

归一化后的注意力权重为

$$a = \text{Tanh}\left(\frac{a_t}{\sqrt{d}}\right) \quad (9)$$

式中， $\text{Tanh}(\cdot)$ 为双曲正切激活函数； d 为特征维度。

高频局部增强特征图为

$$x_1 = a \odot v_s \quad (10)$$

在权重生成过程中使用了 Tanh 、 Swish 两个非线性激活函数，相较于常规的线性或单一激活建模方式，能够增强权重映射的非线性表达能力，生成的上下文感知权重质量更高。同时，相对于传统卷积层， $DWconv(\cdot)$ 可减少大量乘加操作，提高计算效率，降低推理时间。

2.2.2 分支融合方法

在分别提取高频局部细节 $\mathbf{x}_l$ 和低频全局语义特征 $\mathbf{x}_g$ 后,采用通道维度拼接(concatenation, Concat),将二者进行融合。融合后的中间特征图可表示为

$$\mathbf{x}_t = \text{Concat}(\mathbf{x}_l, \mathbf{x}_g) \quad (11)$$

通过一个全连接层,对拼接后的特征进行跨通道信息交互与融合,生成的输出特征图为

$$\mathbf{x}_o = \text{FC}(\mathbf{x}_t) \quad (12)$$

通过通道维度拼接,将局部高频细节特征与全局低频语义特征融合,并借助全连接层实现跨通道信息交互,避免了复杂的卷积或注意力操作,提高了计算效率。

2.3 基于频域调制改进的 C2PSA 模块

为解决水下浑浊、光照不均等恶劣成像条件导致的检测精度下降问题,本文对 C2PSA 模块进行了针对性改进。水下图像中的悬浮颗粒、光线散射等通常表现为高频噪声,而混凝土剥落、露筋等病害的纹理细节则体现在特定的中低频信息中。原始 C2PSA 模块中的前馈网络主要在空间域内进行通道混合,缺乏对不同频率成分的显式建模能力,故难以有效区分水下图像中与频率相关的目标特征与背景噪声。基于此,本文在 PSA 模块的前馈结构中引入可调频的前馈网络(frequency-modulation feed-forward network, FMFFN)^[25],设计了 F-C2PSA 模块,以实现更精准的局部特征调制与增强。

如图 4 所示,传统 FFN 仅通过 1×1 卷积进行通道混合,缺乏对空间频率成分的区分和对特征频率信息的动态调整能力。FMFFN 通过引入局部窗口频域调制模块(window frequency modulation, WFM),利用频率调制机制,动态调整特征的频率信息,从而提高特征表示的质量和模型的适应性。首先,输入特征 $\mathbf{x}$ 经过一个标准的 2 层 1×1 卷积结构 $\text{Conv}_{1 \times 1}(\cdot)$ 及 GELU 激活函数进行通道变换。中间特征可表示为

$$\mathbf{x}_f = \text{Conv}_{1 \times 1}(\text{GELU}(\text{Conv}_{1 \times 1}(\mathbf{x}))) \quad (13)$$

式中, $\text{GELU}(\cdot)$ 为高斯误差线性单元激活函数。

然后,利用 WFM 模块,将特征图分为非重叠的 4×4 局部窗口,并对每个窗口沿空间维度(4, 4)进行二维实数快速傅里叶变换。通过引入一个可学习的复数权重 W (初始为单位复数,不改变原始信号),对频域系数进行逐元素调制。频域调制后的特征可表示为


$$\mathbf{x}_m = \mathcal{F}[(\mathcal{B}(\mathbf{x}_f)) \odot W] \quad (14)$$

式中, $\mathcal{B}(\cdot)$ 为窗口划分算子; $\mathcal{F}(\cdot)$ 表示二维快速傅里叶变换。最后,通过逆快速傅里叶变换(Inverse Fast Fourier Transform, IFFT)将信号还原至空间域,并重组为原始格式:


$$\mathbf{x}_o = \mathcal{B}^{-1}[(\mathcal{F}^{-1}(\mathbf{x}_m))] \quad (15)$$

式中, $\mathcal{B}^{-1}(\cdot)$ 为重组算子; $\mathcal{F}^{-1}(\cdot)$ 表示二维快速傅里叶逆变换。

通过在传统 FFN 后嵌入一个可学习的局部频域调制模块,实现空间域与频域的协同建模。这种“先通道混合、再频率调制”的双阶段设计,不仅保留了 FFN 的非线性表达能力,还赋予网络对图像多尺度频率特征的精细调控能力。



(a)常规 PSA 模块



(b)可调频前馈网络模块

图 4 基于可调频前馈网络改进的 PSA 模块网络结构

Fig. 4 Network architectures of improved PSA module based on frequency-modulated feed-forward network

3 试验与分析

3.1 数据制备与试验参数配置

为验证本文模型在实际工程场景中的有效性,桥梁水下结构病害数据集由水下机器人在实桥水下环境中采集,以提高检测效率与安全性。实桥位于江苏省某市内,为单幅多柱式桥墩结构,全长 33.36m,桥宽 25.5m。通过水下机器人搭载的便携式多参数水质传感器 S60-M,对环境参数进行同步记录。采集图像时水体浊度在 15~108 NTU 之间动态变化,其中大部分数据采集于浊度高于 40NTU 的环境中。桥梁水下机器人通过贴近水下桥墩结构来进行图像采集,相机与桥梁结构的拍摄距离为 0.1~0.2m。在采集的图像中,选取典型混凝土病害,并将其划分为露筋、剥落和骨料露出 3 类(见图 5)。最终共获得 1038 张病害图像,按照 7:2:1 的比例划分为训练集(828 张)、验证集(105 张)和测试集(105 张)。数据集中各

类病害样本数量见表 1。模型训练过程中，采用在线数据增强策略，包括随机水平翻转、尺度缩放、颜色扰动及混合增强等操作，进一步扩充了样本的多样性。所有图像统一缩放至 640×640 像素，以满足模型输入需求。




图 5 现场作业及典型病害示例

Fig. 5 On-site operation and typical defect examples

表 1 数据集中各类病害样本数量

Table 1 Number of samples for each type of defect in the dataset

病害种类	训练集	验证集	测试集
露筋	153	18	16
剥落	292	45	73
骨料露出	5288	704	666

试验基于 PyTorch 框架实现。硬件环境包括 Nvidia GeForce RTX3090 显卡 (24GB 显存) 和 Intel Xeon Gold 5215 处理器。软件环境为 Python 3.10、PyTorch 2.2.2 及 CUDA 12.1。在训练参数方面，批尺寸设为 32，训练轮数为 300，优化器选用 SGD，初始学习率为 0.01，动量为 0.937，权重衰减系数为 5×10^{-4} ，并采用余弦退火策略动态调整学习率。为提高效率，将数据加载线程数设置为 4，并启用混合精度训练。

3.2 评价指标

本文使用精确度、召回率、平均精度等作为评价指标，对模型检测效果进行评价。精确度表示模型正确预测的样本数量占全部预测为真的样本数量的比例；召回率表示模型检出为真的样本数量占全部真样本数量的比例。本文采用平均精度 (mean average precision, mAP) 来衡量模型在所有目标类别上的平均检测精度。预测框的真伪由其与真实框的交并比 (intersection over union, IoU) 决定：当预测框与真实框的 IoU 大于设定阈值时，判定为正样本；否则，判定为负样本。令 IoU 阈值为 0.5 时计算得到的 mAP 为 mAP₅₀，用于表征模型的整体检测精度。同时，将 0.50~0.95 范围内、间隔为 0.05 的 10 个不同 IoU 阈值下的平均精度均值记为 mAP_{50:95}，以更严格地衡量模型的边界框定位与回归能力。

使用参数量表征模型复杂度，即模型中所有可训练参数的数量。模型复杂度过高时，容易出现过拟合现象，复杂度过低则可能导致欠拟合，因此，参数量能够直观反映模型轻量化程度与泛化能力。利用理论计算量 GFLOPs 来表征模型的计算复杂度，即模型处理单张图像所需执行的 1×10^9 次浮点运算数。该指标与具体硬件无关，能够从理论上衡量模型的计算开销和轻量化程度。GFLOPs 越小，通常表示模型在结构上越高效。

使用 FPS 来表征模型的推理速度，即单位时间内能够处理的图像帧数。使用推理时间表征模型处理单张图像的平均耗时，以 ms 为单位，能够直观地体现模型的计算效率。推理时间越短，表示模型在工程应用中的响应速度越快。

3.3 消融试验

为验证 CF-YOLOv11n 模型的优越性，以 YOLOv11n 为基准模型，构建了引入 C-C3K2 模块的 YOLOv11n-C-C3K2 模型和引入 F-C2PSA 模块的 YOLOv11n-F-C2PSA 模型。在相同试验条件下，对这 4 种模型进行全面评估。

图 6 展示了训练过程中 4 种模型的损失与平均精度变化曲线。由图可知，各模型的损失总体呈下降趋势，mAP 指标逐步上升并趋于稳定。CF-YOLOv11n 模型的收敛速度最快，最终损失最低，且精度最高，表现出更优的训练稳定性与泛化能力。因此，所提模块能够有效提升模型的特征提取能力和检测性能。




图 6 训练过程中不同模型的损失与平均精度变化曲线

Fig. 6 Loss and mean average precision curves of different models during training

消融试验结果见表 2。由表可知，各模块带来了不同的性能增益。相较于基准模型，YOLOv11n-C-C3K2 模型的推理速度提升了 23.5%，推理速度达到 36.20 帧/s。基准模型的 GFLOPs 为 6.3，该模型虽然仅增加至 6.4，但实际推理速度更快，表明所采用的 DWconv 模块能有效加速特征提取，从而提升了实际运行效率。YOLOv11n-F-C2PSA 模型在检测精度上表现最优，mAP50:95 平均值达到 45.55%，并且针对露筋病害的检测效果明显提升，对露筋病害检测的 mAP50:95 达到 62.29%，说明频域调制可以有效增强模型对病害特征的识别效果。

CF-YOLOv11n 模型融合了 YOLOv11n-C-C3K2 模型和 YOLOv11n-F-C2PSA 模型的改进策略，实现了速度与精度的协同优化。其推理速度提升至 66.13 帧/s，为基线模型的 2.25 倍。同时，该模型针对 3 类病害的 mAP50:95 平均值为 45.50%，与精度最优模型基本持平，相较于基线模型提升了 2.46%；对剥落病害检测的 mAP50 达到 63.10%，为所有模型中的最高值。CF-YOLOv11n 模型融合了 C-C3K2 模块的加速能力与 F-C2PSA 模块的精度增强能力，以极小的参数数量和计算复杂度为代价，实现了推理速度的大幅提升，同时兼顾了高检测精度，体现了模型在速度与精度上的平衡。

表 2 消融试验结果

Table 2 Results of ablation experiments

模型名称	GFLOPs	参数量 /10 ⁶	mAP50/%				mAP50:95/%				FPS /(帧·s ⁻¹)	推理 时间 /ms
			露筋	剥落	骨料 露出	平均 值	露筋	剥落	骨料 露出	平均 值		
YOLOv11n	6.3	2.58	80.83	61.61	77.81	73.42	55.34	34.08	39.70	43.04	29.33	34.10
YOLOv11n- C-C3K2	6.4	2.64	80.01	50.58	73.76	68.12	47.72	29.47	38.29	38.49	36.20	27.62
YOLOv11n- F-C2PSA	6.3	2.59	85.46	61.69	76.84	74.66	62.29	36.61	37.75	45.55	30.47	32.82
CF- YOLOv11n	6.4	2.64	84.23	63.10	75.61	74.31	58.57	38.21	39.70	45.50	66.13	15.12

3.4 对比试验

为验证 CF-YOLOv11n 模型的有效性，将其与主流轻量化检测框架 YOLO 系列模型、RT-DETR 模型、SSD 模型和 Faster-RCNN 模型进行对比试验，结果见表 3。试验在相同的数据集、硬件平台和输入分辨率条件下进行，以确保结果的公平性和可比性。由表可知，RT-DETR 模型推理速度最快，但参数量较大、精度较低。SSD 模型虽结构轻量，但检测精度和速度均不理想。Faster-RCNN 模型虽推理速度较快，但精度整体低于 YOLO 系列模型，且参数量较大。CF-YOLOv11n 模型在保持较低参数量的同时，mAP50 和 mAP50:95 分别达到 74.31% 和 45.50%，检测精度优于其他模型，推理速度和帧率也表现出较好的实时性，实现了检测精度与推理效率之间的平衡，从而验证了 CF-YOLOv11n 模型的优越性。

表 3 对比试验结果

Table 3 Results of comparative experiments

模型名称	参数量 /10 ⁶	mAP50/ %	mAP50:95/%	FPS/(帧·s ⁻¹)	推理时间/ ms
RT-DETR	4.96	39.81	16.51	91.33	10.95
SSD	1.96	33.53	17.93	26.09	38.33
Faster-RCNN	3.23	62.35	35.04	68.54	14.57
YOLOv5	2.18	71.23	40.77	39.14	25.55
YOLOv6	4.16	69.56	40.14	36.51	27.39
YOLOv8	2.68	73.94	43.76	33.49	38.86
YOLOv10	2.27	71.98	39.41	31.52	31.72
CF-YOLOv11n	2.64	74.31	45.50	66.13	15.12

对比试验的可视化结果见图 7。图中，浅蓝色框为剥落病害，深蓝色框为露筋病害，白色框为骨料露出病害。由图可知，RT-DETR 模型与 SSD 模型在复杂纹理和细微病害区域中存在明显漏检现象，尤其对剥落与细小露筋区域响应不足。YOLOv5 模型与 YOLOv10 模型

虽能识别主要病害，但检测框定位偏移，且在边缘区易出现误检。YOLOv8 模型具有较高的灵敏度，但部分噪声纹理被误判为骨料露出，导致置信度分布波动较大。CF-YOLOv11n 模型在 3 类病害检测任务中均能给出更准确的检测框，具有更高的预测置信度，漏检与误检现象更少。该模型借助 C-C3K2 模块与 F-C2PSA 模块，增强了特征融合能力与空间注意力分配效果，在复杂光照条件及表面纹理干扰较强的情况下仍能保持稳定的特征判别性能。综合来看，CF-YOLOv11n 模型不仅在检测结果上更贴近真实边界，误检、漏检现象也较少，置信度较高，展现出更强的鲁棒性与泛化能力。




图 7 对比试验的可视化结果

Fig. 7 Visualization results of comparative experiments

3 类病害检测中不同模型的检测精度存在显著差异（见表 4）。传统的 RT-DETR 模型、SSD 模型和 Faster-RCNN 模型在复杂纹理和小目标的识别任务中检测精度有限，精确度和召回率较低；尤其是 SSD 模型，在露筋与剥落病害中 $mAP_{50:95}$ 仅为 5%~12%，说明其特

征表达能力不足。YOLO 系列模型整体性能优于前面 3 种模型，检测精度和召回率均显著提升。CF-YOLOv11n 模型在精度与泛化性能上表现最优，在露筋与骨料露出病害中，精确度分别为 84.98%和 79.01%，mAP50:95 分别为 58.57%和 45.50%，CF-YOLOv11n 模型在保持轻量化结构的同时，检测精度与稳定性显著提升，充分验证了 CF-YOLOv11n 模型在桥梁水下结构病害检测任务中的有效性与鲁棒性。

表 4 3 类病害检测中不同模型的检测精度
Table 4 Detection accuracy of different models in the detection of three types of diseases %

模型名称	病害类别	精确度	召回率	mAP50	mAP50:95
RT-DETR	露筋	27.05	75.00	37.65	11.47
	剥落	27.04	23.29	19.20	8.71
	骨料露出	59.32	63.29	62.57	29.35
SSD	露筋	29.24	06.25	8.22	5.43
	剥落	52.61	19.18	22.29	12.44
	骨料露出	69.34	68.47	70.06	35.93
Faster-RCNN	露筋	67.68	75.00	61.68	37.73
	剥落	66.83	44.16	52.81	30.47
	骨料露出	76.16	66.22	72.57	36.92
YOLOv5	露筋	82.15	81.25	86.38	56.64
	剥落	59.63	54.79	51.55	28.17
	骨料露出	68.53	76.88	75.76	37.50
YOLOv6	露筋	72.34	75.00	80.13	50.07
	剥落	82.60	45.51	52.34	31.68
	骨料露出	76.09	70.26	76.20	38.66
YOLOv8	露筋	86.19	81.25	87.09	57.32
	剥落	80.28	53.42	62.43	36.72
	骨料露出	76.82	68.62	72.30	37.23
YOLOv10	露筋	74.17	75.00	76.91	44.83
	剥落	76.90	60.27	62.07	33.22
	骨料露出	77.99	69.16	76.97	40.19
CF-YOLOv11n	露筋	84.98	81.25	84.23	58.57
	剥落	74.17	49.32	63.10	38.21
	骨料露出	79.01	68.17	75.61	45.50

4 结论

(1) 本文通过在瓶颈层引入上下文感知局部增强注意力机制，构建了一种 C-C3K2 模块，并结合 DWconv 模块，加速了特征提取。试验结果表明，C-C3K2 模块显著提升了基准模型的推理效率，推理速度达到 36.20 帧/s，较基线模型提升 23.4%，有效满足了桥梁水下结构实时巡检对高帧率检测的需求。

(2) 通过在 PSA 模块中引入可调频的前馈网络，构建了 F-C2PSA 模块，实现了对全局语义依赖与局部频率特征的协同建模。F-C2PSA 模块在局部窗口内执行可学习的频域滤

波,显著增强了对钢筋裸露等关键病害的细节响应能力。试验结果显示,该模块将露筋病害下的 mAP50 提升至 85.46%, mAP50:95 达到 62.29%,检测精度显著优于基线模型,实现了精细化病害检测。

(3) 构建了基于 YOLOv11n 的病害检测模型 CF-YOLOv11n。该模型兼具高效推理与高精度检测的优势,推理速度高达 66.13 帧/s,同时多类病害上的平均精度均表现优越,尤其在剥落等复杂纹理病害上表现最优。试验结果表明,CF-YOLOv11n 模型能够在水下低光照、高模糊的复杂环境中实现快速、准确、鲁棒的病害识别,为桥梁水下结构的安全评估与智能巡检提供了强有力的技术支持。

参考文献 (References)

- [1] 朱尧于, 李佳欢, 朱力, 等. 基于视觉增强的桥梁检测算法及技术[J]. 东南大学学报(自然科学版), 2024, 54(4): 902-910.
- Zhu Y Y, Li J H, Zhu L, et al. Visual enhancement-based bridge detection algorithm and technique[J]. *Journal of Southeast University (Natural Science Edition)*, 2024, 54(4): 902-910. (in Chinese)
- [2] 倪有豪, 陆欢, 季超, 等. 基于语义分割的桥梁锈蚀病害识别对比分析[J]. 东南大学学报(自然科学版), 2023, 53(2): 201-209.
- Ni Y H, Lu H, Ji C, et al. Comparative analysis on bridge corrosion damage detection based on semantic segmentation[J]. *Journal of Southeast University (Natural Science Edition)*, 2023, 53(2): 201-209. (in Chinese)
- [3] 杨东辉, 孙家正, 伊廷华, 等. 可考虑温致位移时滞的大跨桥梁支座劣化预警技术[J]. 东南大学学报(自然科学版), 2024, 54(2): 268-274.
- Yang D H, Sun J Z, Yi T H, et al. Early warning technology of long-span bridge bearing deterioration considering time lag effects of thermal-induced displacement[J]. *Journal of Southeast University (Natural Science Edition)*, 2024, 54(2): 268-274. (in Chinese)
- [4] Wang Z J, Wang K, Han Q Q, et al. Crack imaging of underwater concrete components using interfacial waves and transducer array[J]. *Mechanical Systems and Signal Processing*, 2025, 224: 111998.
- [5] Hou S T, Wang Y X, Wu G, et al. Advanced image stitching method and evaluation for underwater structure inspection utilizing planar array cameras[J]. *Advances in Structural Engineering*, 2025, 28(1): 104-121.
- [6] 熊文, 张学峰, 唐平波, 等. 基于上部结构振动响应的杭州湾大桥桥塔冲刷状态分析[J]. 东南大学学报(自然科学版), 2018, 48(5): 871-877.
- Xiong W, Zhang X F, Tang P B, et al. Scour condition analysis on pylons of Hangzhou Bay Bridge by tracing dynamic behaviors of superstructures[J]. *Journal of Southeast University (Natural Science Edition)*, 2018, 48(5): 871-877. (in Chinese)
- [7] Wu T, Hou S T, Wu Z S, et al. Underwater bridge pier morphology measurement method via refraction correction and multi-camera calibration[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2025, 40(16): 2324-2350.
- [8] Hou S T, Shen H, Wu T, et al. Underwater surface defect recognition of bridges based on fusion of semantic segmentation and three-dimensional point cloud[J]. *Journal of Bridge Engineering*, 2025, 30: 04024101.
- [9] Hou S T, Wang Y X, Wu T, et al. Rapid array images stitching for underwater structures based on camera integrated calibration with multi-scale detectable features pattern[J]. *Developments in the Built Environment*, 2025, 22: 100649.
- [10] 杨才千, 李帅, 王博昆, 等. 基于动态阈值的混凝土裂缝高抗噪提取及识别方法[J]. 东南大学学报(自然科学版), 2021, 51(6): 967-972.

- Yang C Q, Li S, Wang B K, et al. High anti-noise extraction and identification method for concrete cracks based on dynamic threshold[J]. *Journal of Southeast University (Natural Science Edition)*, 2021, 51(6): 967-972. (in Chinese)
- [11] 崔弥达, 王超, 陈金桥, 等. 基于 ROS 及 YOLOv3 的混凝土桥梁裂缝实时检测系统[J]. 东南大学学报(自然科学版), 2023, 53(1): 61-66.
- Cui M D, Wang C, Chen J Q, et al. Real-time concrete bridge cracks detection system based on ROS and YOLOv3[J]. *Journal of Southeast University (Natural Science Edition)*, 2023, 53(1): 61-66. (in Chinese)
- [12] Zhao W J, Liu Y Y, Zhang J W, et al. Automatic pixel-level crack detection and evaluation of concrete structures using deep learning[J]. *Structural Control and Health Monitoring*, 2022, 29(8): e2981.
- [13] Hou S T, Jiao D, Dong B, et al. Underwater inspection of bridge substructures using sonar and deep convolutional network[J]. *Advanced Engineering Informatics*, 2022, 52: 101545.
- [14] Sun W H, Hou S T, Wu G, et al. Two-step rapid inspection of underwater concrete bridge structures combining sonar, camera, and deep learning[J]. *Computer-Aided Civil and Infrastructure Engineering*, 2025, 40(18): 2650-2670.
- [15] Sun W H, Hou S T, Wu G, et al. Turbid image tackling framework towards underwater concrete bridge detection based on distance control and deep learning[J]. *Advanced Engineering Informatics*, 2024, 62: 102723.
- [16] 骆剑彬, 姜绍飞, 沈圣, 等. 基于声呐成像的水下桩墩表面病害深度学习与智能检测[J]. 土木工程学报, 2021, 54(7): 90-100.
- Luo J B, Jiang S F, Shen S, et al. Deep learning and intelligent detection of apparent defects on underwater foundations of bridges with sonar imaging[J]. *China Civil Engineering Journal*, 2021, 54(7): 90-100. (in Chinese)
- [17] 吉同元, 章定文, 毛志远, 等. 基于水面校准和圆柱特征分割的水下桩基尺寸检测方法[J]. 东南大学学报(自然科学版), 2022, 52(6): 1071-1080.
- Ji T Y, Zhang D W, Mao Z Y, et al. Underwater pile foundation size detection method based on water surface calibration and cylindrical feature segmentation[J]. *Journal of Southeast University (Natural Science Edition)*, 2022, 52(6): 1071-1080. (in Chinese)
- [18] Jiang S F, Wang W, Su Z H, et al. Automatic detection of surface defects on underwater pile-pier of bridges based on image fusion and deep learning[J]. *Structural Control and Health Monitoring*, 2023, 2023: 8429099.
- [19] Li X F, Sun H M, Song T Y, et al. A method of underwater bridge structure damage detection method based on a lightweight deep convolutional network[J]. *IET Image Processing*, 2022, 16(14): 3893-3909.
- [20] Wu X B, Li J J. Deep learning-based siltation image recognition of water conveyance tunnels using underwater robot[J]. *Journal of Civil Structural Health Monitoring*, 2024, 14(3): 801-816.
- [21] Zhang B W, Jiang J J, Gao X J, et al. Detection of defects in underwater concrete structures: Integrating compact robotic systems with an edge detection model[J]. *Ocean Engineering*, 2025, 321: 120390.
- [22] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas, NV, USA, 2016: 779-788.
- [23] Redmon J, Farhadi A. YOLO9000: Better, Faster, Stronger[EB/OL]. (2016-12-25)[2025-07-20]. <https://arxiv.org/pdf/1612.08242>.
- [24] Fan Q, Huang H, Guan J, et al. Rethinking local perception in lightweight vision transformer[EB/OL]. (2023-03-31)[2025-07-20]. <https://arxiv.org/pdf/2303.17803>.
- [25] Li H, Li S, Dai W, et al. Frequency-aware transformer for learned image compression[EB/OL]. (2023-10-25)[2025-07-20]. <https://arxiv.org/pdf/2310.16387>.