

分类号：TP391.4 学校代号：10150
UDC：004.8 学 号：20223384

大连交通大学
专业硕士学位论文

基于改进 YOLOv11n 的路面裂缝和坑
洞检测算法研究

Research on the detection algorithm for
pavement cracks and pits based on improved
YOLOv11n

学 生 姓 名：	张林烽
校内导师及职称：	欧晓英 讲师
行业产业导师及职称：	段彦斌 高级工程师
专 业 名 称：	交通运输
研 究 方 向：	交通安全
论 文 类 型：	技术研究类
培 养 类 型：	全日制专业学位硕士
论文答辩日期：	2025 年 6 月 11 日
学位授予单位：	大连交通大学

摘 要

目前,我国的路面裂缝和坑洞检测方式仍以人工检测为主。人工检测的方法存在效率低、影响正常交通、工作强度大、耗时和不安全等问题。为了解决路面裂缝和坑洞检测中遇到的复杂背景干扰导致检测精度较低,以及路面裂缝和坑洞存在多尺度的特点导致识别难度较高的问题;本文结合 YOLOv11n(you only look once version 11)物体检测模型高效轻量、适用于实时检测的特点,对 YOLOv11n 模型进行改进。首先,考虑到细小裂缝和坑洞容易发生漏检的情况,本文将 BiFPN 加权双向特征金字塔网络与 MCA 多模态交叉注意力机制相结合,提出一种新的 BMFPN 结构以替换原网络结构中的 Concat 层,以优化模型对于细小裂缝和坑洞的检测能力,提高路面裂缝和坑洞检测的召回率,同时强化模型的多尺度特征融合能力,提高模型对路面裂缝与坑洞的检测性能。其次,考虑到路面裂缝和坑洞检测易受到其他与裂缝和坑洞的特征相似的背景干扰,导致误判或漏判,本文设计一种 SMC3K2 模块以替换原网络结构中的 C3K2 模块,以实现 Neck 层的自适应注意力增强以及特征选择性提升,使模型可以精准聚焦于目标区域的关键特征,同时保留 C3K2 模块的跨层特征融合能力和计算效率,在保持模型轻量化和高效计算的同时,提升模型对路面裂缝和坑洞的检测精度和鲁棒性。本文改进的 YOLOv11n 路面裂缝和坑洞算法在实验数据集上较基准模型精度提升 4.3%、召回率提升 7.3%、平均精度提升 10.5%,F1 提升 6.1%,充分验证了模型的有效性。改进后的路面裂缝和坑洞检测模型对智能路面裂缝和坑洞检测研究提供了新的算法依据。

关键词: 路面裂缝和坑洞检测; YOLOv11; 特征处理; 注意力机制; 双向特征金字塔网络

Abstract

At present, the detection methods of pavement cracks and potholes in China are still mainly manual detection. The manual detection method has problems such as low efficiency, affecting normal traffic, high work intensity, time-consuming and unsafe. In order to solve the problem of low detection accuracy caused by complex background interference encountered in the detection of pavement cracks and potholes, and the difficulty of identification of pavement cracks and potholes due to the multi-scale characteristics. Combined with the characteristics of the YOLOv11n (you only look once version 11) object detection model, which is efficient, lightweight, and suitable for real-time detection, this thesis improves the YOLOv11n model. Firstly, considering that small cracks and potholes are prone to missed detection, this thesis combines the BiFPN weighted bidirectional feature pyramid network with the MCA multimodal cross-attention mechanism, and proposes a new BMFPN structure to replace the Concat layer in the original network structure, so as to optimize the detection ability of the model for small cracks and potholes, improve the recall rate of pavement crack and pothole detection, and strengthen the multi-scale feature fusion ability of the model, and improve the detection performance of the model for pavement cracks and potholes. Secondly, considering that pavement crack and pothole detection is susceptible to other background interference similar to the characteristics of cracks and potholes, resulting in misjudgment or missed judgment, this thesis designs an SMC3K2 module to replace the C3K2 module in the original network structure, so as to realize the adaptive attention enhancement and feature selectivity improvement of the Neck layer, so that the model can accurately focus on the key features of the target region, while retaining the cross-layer feature fusion ability and computational efficiency of the C3K2 module, while maintaining the lightweight and efficient calculation of the model. Improve the detection accuracy and robustness of the model for pavement cracks and potholes. Compared with the benchmark model, the improved YOLOv11n pavement crack and pothole algorithm in this thesis improves the accuracy by 4.3%, the recall rate by 7.3%, the average accuracy by 10.5%, and the F1 algorithm by 6.1% on the experimental dataset, which fully verifies the effectiveness of the model. The improved pavement crack and pothole detection model provides a new algorithm basis for the research of intelligent pavement crack and pothole detection.

Key Words: Pavement cracks and pit detection; YOLOv11; feature processing; attention mechanism; Bidirectional feature pyramid network

目 录

第一章 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.2.1 基于传统图像识别的路面裂缝和坑洞检测	2
1.2.2 基于深度学习的路面裂缝和坑洞检测	4
1.3 现有检测方法存在的问题及不足	10
1.4 论文主要研究内容及技术路线	11
1.4.1 论文主要研究内容.....	11
1.4.2 技术路线.....	12
本章小结.....	13
第二章 理论基础	14
2.1 深度学习概述.....	14
2.2 卷积神经网络.....	14
2.2.1 卷积层.....	15
2.2.2 激活函数.....	17
2.2.3 池化层.....	21
2.2.4 全连接层	23
2.2.5 采样方式.....	24
2.3 单阶段目标检测算法.....	30
2.3.1 经典算法.....	30
2.3.2 YOLO 系列算法.....	33
2.3.3 YOLOv11 算法	37
本章小结.....	38
第三章 基于改进 YOLOv11n 算法的路面裂缝和坑洞检测	39
3.1 路面裂缝和坑洞检测模型选择及边缘设备部署可行性分析	39
3.2 考虑多尺度融合的路面裂缝和坑洞检测	40
3.2.1 双向特征金字塔网络.....	40
3.2.2 MCA 多模态交叉注意力机制	42
3.2.3 设计 BMFPN 模块	42
3.3 考虑背景抑制与模型轻量化的路面裂缝和坑洞检测	45
3.3.1 C3K2 模块	45
3.3.2 SimAM 注意力模块.....	48
3.3.3 设计 SMC3K2 模块	48
本章小结.....	50

第四章 改进 YOLOv11 目标检测算法的实验结果与分析51

4.1 路面裂缝和坑洞数据集.....51

4.1.1 自制数据集.....51

4.1.2 RDD2022 数据集52

4.2 实验环境与参数配置.....53

4.3 实验评价指标.....54

4.4 实验结果.....56

4.4.1 模型训练.....56

4.4.2 实验结果.....56

4.4.3 检测效果可视化.....59

4.4.4 改进点消融实验.....62

4.4.5 对比实验.....62

本章小结.....63

结论与展望.....64

参考文献.....65

第一章 绪论

1.1 研究背景及意义

在现代交通体系中，道路基础设施作为经济发展和社会运转的动脉，其重要性不言而喻。随着交通流量的持续攀升，特别是重型车辆的频繁往来，路面承受着日益严峻的压力。这种长期且高强度的荷载作用，不可避免地导致路面出现各种病害，其中裂缝和坑洞是最为常见且危害较大的两种形式。

路面裂缝和坑洞若不及时处理易造成以下危害：

（1）结构破坏：水沿裂缝和坑洞下渗，会降低沥青粘附性，使沥青混合料强度降低，还会冲刷基层细料，导致唧浆，使沥青面层下陷、裂缝两侧破碎，加速路面大面积损坏；水泥路面裂缝和坑洞会使雨水进入基层或土层，在车辆作用下形成板下脱空，导致水泥砼路面大面积断裂破碎。

（2）影响行车安全与舒适性：裂缝和坑洞使路面平整度下降，车辆行驶产生颠簸、跳动，降低行车舒适性；同时破坏路面表面纹理，使抗滑性能下降，潮湿或结冰时，车辆制动距离增加，易引发交通事故。

（3）缩短路面使用寿命：裂缝和坑洞是早期病害，会随路龄增长加重，未经处理会不断扩展恶化，加速路面损坏进程，缩短使用寿命。

（4）影响美观：裂缝和坑洞破坏路面整体性和连续性，影响道路整体形象和景观效果。

传统的路面裂缝和坑洞检测方法，诸如人工目视检测、基于图像处理的半自动检测等，存在诸多局限性。人工检测高度依赖检测人员的经验与主观判断，不仅效率低下，而且在面对长距离、大面积的路面检测任务时，极易出现疏漏。基于图像处理的半自动检测方法虽在一定程度上提高了检测效率，但在复杂路面环境下，如光照不均、路面材质多样、存在杂物干扰等情况下，检测精度难以保证。

交通运输部在《“十四五”公路养护管理发展纲要》文件中提出，借助数字化技术带动公路维护和管理的革新和进步，加快公路技术状况检测监测及养护装备研发，提高道路检测和养护的自动化程度。通过实施人工智能自动巡检技术，促进公路养护的智慧化进程。着重开展公路设施养护的评估、预测和决策分析方法的研究，重点发展相关分析算法与模型^[1]。

深度学习技术近年来取得了突破性进展，在图像识别、目标检测等领域展现出卓越的性能。其强大的特征学习能力和对复杂数据的处理能力，为解决路面裂缝和坑洞检测

难题提供了新的契机。通过构建深度神经网络模型，能够自动从大量的路面图像数据中学习裂缝和坑洞的特征，从而实现对裂缝的精准检测与分类，及时准确地检测出路面裂缝和坑洞，使道路管理部门提前采取维护措施，避免裂缝进一步扩展导致路面塌陷等严重病害，有效降低交通事故的发生风险，保障行车安全。通过早期发现裂缝和坑洞并进行修复，能够阻止水分、空气等侵蚀性介质通过裂缝渗透到路面结构内部，减少对路面结构层的损害，延长道路的使用寿命，降低道路全生命周期的维护成本。

随着我国的交通基础设施迅速发展，深度学习技术的应用为交通基础设施的智能化提供了关键支撑，有助于构建全面、实时、精准的道路病害监测与管理体系，实现道路养护工作的科学化、智能化决策，促进交通行业的可持续发展。

1.2 国内外研究现状

目前，在路面裂缝和坑洞识别任务研究中主要分为传统的图像识别方法和基于深度学习的图像识别方法。传统图像处理识别中特征提取主要依赖于人工对特征进行提取，进而对原始特征进行重构和表达，将最终重构好的特征进行提取。深度学习方法则是对计算机模型进行训练，使其能自主完成对任务目标的识别和分类。近年来，随着人工智能和计算机视觉领域的发展，基于深度学习的路面裂缝和坑洞检测已成为研究的热点。基于深度学习的目标检测模型主要分为两类^[2]。一类是单阶段，如 RetinaNet^[3]、SSD 系列^[4]、YOLO 系列^[5-9]、EfficientDet^[10]、DETR^[11]等；另一类是两阶段，包括 R-CNN^[12]、Faster R-CNN^[13]、Mask RCNN^[14]等。

1.2.1 基于传统图像识别的路面裂缝和坑洞检测

对于采集到的路面裂缝和坑洞图像，由于受光影和表面污浊的影响，需要采用图像增强和降噪的预处理方法对采集到的路面图像进行预处理。目前常用的图像增强方法有差影法、直方图均衡化、模糊理论增强运算等。对图像饱和度、亮度等参数进行调整增强后，需要对图像降噪，即降低甚至消除图像的噪点，使图像更加纯净，便于后续裂缝识别与提取^[15]。

王墨川^[16]等提出基于曲率滤波和 N-P 准则的路面裂缝识别方法，通过曲率滤波算法保留裂缝信息，应用 N-P 准则实现裂缝检测。李鹏^[17]等结合聚类分析和区域生长算法，提出了 K-means 聚类路面分割算法，根据图像灰度像素特征进行裂缝目标聚类，融合裂缝几何纹理特征将聚类中心值作为种子点区域生长，经过形态学滤波优化处理完成精确分割。Safaei^[18]等提出了基于图像块的图像处理方法，将局部阈值技术应用于每个图像块，并根据图像块像素的空间分布检测出有裂缝的图像块，并且方法不限于路面纹理类型，具有较好的泛化性。

König J^[19]等人提出了优化的编码器-解码器优化方法,由于多种技术的组合,可以使分割裂缝的能力得到提高。史英英^[20]采取基于对比度增强和高斯滤波对图像像素增强的方法进行预处理来保障计算机分析结果。基于均值滤波算法进行降噪处理,采用 Prewitt 算子分割法和 Otsu 阈值分割算法对图像进行分割处理,得出明确边缘定位和图像去噪效果的路面裂缝图像。孙向鹏^[21]基于均值滤波算法进行降噪处理,采用 Prewitt 算子和迭代阈值分割算法对图像进行分割处理,得到路面裂缝准确的边缘定位及图像去噪效果图。肖钟捷^[22]等为提升基于数字图像处理技术的高速公路路面裂缝自动检测识别技术的识别速度及识别率,对采集到的路面裂缝图像,通过均衡化处理增强路面裂缝图像,提出一种自适应的快速去噪方法可提升识别速度;对经过图像预处理的裂缝图像,采用大津阈值分割法提取出图像中的裂缝,并在此基础上施加适当的形态学方法加以修正。

贾迪^[23]等提出一种道路影像裂缝鲁棒识别方法。首先对图像进行分块,采用改进的 CV 模型对分块影像进行预处理,获得初步的分割结果。其次,通过裂缝在分块区域中占据较小的面积比;裂缝在影像中呈现的连续性较差;裂缝的宽度与长度比值较小;同一段裂缝的走向基本一致 4 个特点识别线阵列 CCD 道路影像的裂缝。然后,采用椭圆拟合的方法计算初步分割区域的方向,并以此为基础将这些区域分为 4 类。在每个分类中,分别计算各区域内的质心位置,建立质心间的矢量表,设计递归算法计算其共线性,获得裂缝检测结果,并以此为基础构造活动模型的初始距离矩阵,通过在原图中迭代求解更为精确的裂缝区域。

张玉雪^[24]等提出了一种基于稀疏表示和多特征融合的路面裂缝检测改进算法。该算法首先以图像子块为单位,提取对裂缝识别有效的统计、纹理和形状特征。然后,分别在各个特征矩阵下利用稀疏表示分类方法实现对裂缝子块的识别,再融合不同特征下的识别结果,设计综合识别分类器进行子块检测。最后,在识别出的裂缝子块上,采用基于视觉显著性的像素级检测方法精确提取裂缝细节。

传统图像识别中每个方法都是针对据体特定的情况,所以泛化能力和鲁棒性较差。通过对比分析基于传统图像处理和基于深度学习的两种方法,发现深度学习方法在路面裂缝和坑洞识别场景下具有更好的性能表现。使用高清相机对道面裂缝进行图像采集是现在较为常用的方法,传统的图像识别在道面病害目标分割,例如在边缘检测算法中可能会出现图像分割较差的情况。基于上述情况,采用基于深度学习算法对路面裂缝和坑洞进行识别是另一种较好地解决办法^[25]。

1.2.2 基于深度学习的路面裂缝和坑洞检测

杨泽^[26]等人针对目前路面裂缝检测方法在复杂环境下识别率较低、鲁棒性较差的问题,提出一种改进网络 CBAM—Res—Ghost—Net 对路面裂缝实现有效分类。在卷积神经网络中引入 Ghost 模块和改进残差模块,加入卷积注意力,避免梯度消失和过拟合现象,实现对路面裂缝的准确判断;在此基础上,提出一种改进网络 Self—Attention—UNet 对路面裂缝区域进行高精度分割,引入自注意力机制增强模型裂缝特征提取能力,提高分割精度。

瞿中,李明^[27]针对复杂背景下路面裂缝检测困难的问题,提出一种基于混合扩张卷积和空间—通道注意力机制的路面裂缝检测算法。基于改进的 U—Net 网络,在编码阶段,使用空间—通道注意力机制增强裂缝特征,抑制非裂缝特征;在网络中间部分,使用混合扩张卷积实现在不增加额外模块的前提下增大网络的感受野;在解码阶段,融合多层次和多尺度特征使最终预测结果更接近路面真实情况。

王丹等人^[28]针对已有路面裂缝检测算法对细小特征提取不够完善,并且未考虑到全局信息的问题,提出一种具有全局信息的多尺度全卷积神经网络路面裂缝检测算法。该算法融合了 3 个具有不同空洞卷积率的单尺度空洞卷积,构成多尺度空洞卷积,在不丢失分辨率的情况下扩展感知范围,减少参数计算量。利用反卷积层融合深层信息与浅层信息来扩充图像细节。最后将网络与一个条件随机场实现端到端的连接以计算损失值,优化处理结果。算法可有效避免特征丢失,实现多尺度裂缝感知,并对全局像素信息进行传递。

陈涵深等人^[29]提出了一种 U 型结构的卷积神经网络 UCrackNet。首先在跳跃连接中加入 Dropout 层来提高网络的泛化能力;其次,针对上采样中容易产生边缘轮廓失真的问题,采用池化索引对图像边界特征进行高保真恢复;最后,为了更好地提取局部细节和全局上下文信息,采用不同扩张系数的空洞卷积密集连接来实现感受野的均衡,同时嵌入多层输出融合来进一步提升模型的检测精度。

王安政等人^[30]针对路面裂缝检测任务中面临的阴影遮挡、背景复杂等干扰造成的裂缝检测不完整的问题,提出一种基于位置信息和注意力机制的路面裂缝检测模型 (PA-TransUNet)。首先,通过混合编码器接收输入图像,提取裂缝特征信息,引入查询项、键、值的位置信息,提升编码器 Transformer 中自注意力机制捕获裂缝形状和补偿特征信息丢失的能力。然后,输入裂缝特征到解码器进行上采样,设计一种基于注意力门控的解码模块 (AGDM),AGDM 通过抑制非裂缝区域来加强对裂缝区域的学习,提高裂缝检测的准确性和完整性。

张明星等人^[31]针对基础 U-Net 对路面裂缝分割效果不强, 裂缝轮廓分割精细度不够、难以识别狭窄裂缝、分割精度低等问题, 提出一种改进 U-Net 的路面裂缝分割方法。使用改进的 ResNet50 作为主干网络提取路面裂缝特征, 设计了基于注意力机制的特征融合模块改进 U-Net 的跳跃连接, 在解码部分添加特征细化头得到改进的模型, 提升了模型性能和泛化性。徐康等人^[32]针对目前沥青路面裂缝检测存在的识别率低和细微裂缝在复杂背景下难以检测的问题, 提出了基于改进 Faster-RCNN 的裂缝检测方法, 将 ResNet50 与 Faster-RCNN 结合, 提高了模型的检测精度。

李鹏程等人^[33]提出一种基于改进 MobileNet-SSD 的路面裂缝图像检测算法。该检测算法在之前采用轻量化卷积神经网络 MobileNet 的 SSD 算法基础上设计一种基于感受野提升的检测模块。将深度可分离卷积融合后的特征信息输入到感受野提升模块中, 提升感受野范围增强特征信息提取。引入批量归一化算法(Batch Normalization, BN) 提升算法的稳定性, 提高网络泛化能力。

祝一帆等人^[34]针对复杂背景下的裂缝分割能力差且效率不高的问题, 提出了一种基于编码器-解码器结构的新改进型网络结构 Crack U-Net, 为提高路面裂缝检测的模型泛化性以及检测精度, Crack U-Net 用密集连接结构增强了基于编码器-解码器的网络 U-Net 模型, 在以往结构的基础上提高了网络各层特征信息利用率, 增强了模型的鲁棒性; 此外, Crack U-Net 使用由残差块和 mini-U 组成的 Crack U-block 作为网络的基础卷积模块, 相比传统双层卷积层, Crack U-block 可以提取出更丰富的裂缝特征; 最后, 在 Crack U-Net 的下采样节点中使用了空洞卷积替代传统卷积核, 以充分捕获图像边缘的裂缝特征。曹锦纲等人^[35]提出了一种基于注意力机制的裂缝检测网络(attention-based crack networks, ACNet)。该网络采用编码器-解码器网络构架, 编码器采用 ResNet34 为骨干网, 提取路面裂缝特征; 在编码器和解码器间加入基于注意力机制的特征模块(attention-based feature module, AFM), 以利用全局信息和增加对检测不同尺度裂缝的鲁棒性, 更好地提取裂缝特征和定位裂缝位置; 在解码阶段也引入注意力机制, 设计了基于注意力机制的解码模块(attention-based decoder module, ADM), 实现对裂缝的准确定位。

赵志宏等人^[36]针对现有深度学习路面裂缝检测方法提取裂缝特征不完整导致精度低以及实时性不足的问题, 提出一种融合注意力机制与 GhostUNet 的路面裂缝检测方法。该方法由编码器和解码器组成, 将 U-Net 中的常规卷积改进为 Ghost 卷积, 减少模型参数量; 在编码和解码部分, 为了提高对裂缝特征的提取能力, 引入 ECA 注意力机制和残差连接, ECA 注意力模块可以过滤不相关的特征信息, 利用残差连接可以避免网络退化现象。段中兴等人^[37]针对裂缝的多态性和噪声干扰等问题, 提出一种结合有效多

尺度特征融合结构和级联优化的裂缝检测方法。首先构建有效的多尺度特征融合提取结构,增强对不同尺度裂缝特征的提取效果;然后针对编码器-解码器对于特征信息的关注重点,分别引入空间和通道注意力机制抑制背景噪声干扰,增强裂缝特征表达;最后对不同层级解码特征进行联合优化学习,强化对低层级特征信息的利用,提升裂缝分割纹路的连贯性。

夏淑芳等人^[38]针对深层特征图中裂缝细节信息易丢失的问题,提出一种融合注意力机制与深层特征优化策略的网络模型。该模型以 VGG-16 作为主干网络,在中高层卷积后引入一种轻量级的置换注意力机制,以提高网络对裂缝特征的敏感性;为了进一步增强对裂缝特征的捕捉能力,在每个阶段的侧边输出中嵌入相应的注意力模块;提出一种空间可分离金字塔模块并设计了一种注意力融合模块,用以优化深层特征图,还原更多的裂缝细节。侧网络通过在多个层次上融合低层和高层特征,辅助生成最终的预测图像。

苏天成等人^[39]针对深度学习模型应用在道路裂缝检测时,存在裂缝提取不完整及检测速度慢等问题,提出了一种基于 ResNet34 骨干网络并结合通道注意力和空间注意力机制对特征图进行多级特征融合学习的算法。提出的算法由特征提取网络、多级特征融合模块构成,能够生成清晰准确的裂缝分割图像。其中,特征提取网络提取三原色(RGB)图像的分层级特征,多级特征融合模块学习 ResNet34 分层级特征信息,且各层的输出采用分层监督方式引导网络快速训练。

翟军治等人^[40]针对路面裂缝检测不完整和分割出现断裂的问题,提出了一种多尺度特征增强的路面裂缝检测网络 MFENet,实现端到端的路面裂缝图像检测、分类和分割处理;设计了多尺度注意力特征增强模块,建立了网络模型的上层多尺度特征通道与底层特征通道权重系数之间的映射关系,以提升有效通道的特征输出;基于路面裂缝的坐标信息和像素语义信息在物理位置上的相关性,设计了多语义特征关联模块,实现不同语义信息之间的特征融合增强,并通过特征维度转换实现对路面裂缝图像的前景特征过滤;提出了一种针对深度特征强度进行量化评估的方法,用于提升模型提取特征能力的可解释性。

谢永华等人^[41]针对路面裂缝检测中裂缝漏检和定位不准的问题,提出一个结合注意力特征融合的可端到端训练的路面裂缝检测网络。该网络基于 Resnet-50 结构设计,在特征融合部分添加注意力特征融合模块,通过注意力掩码学习,动态调整浅层特征与深层特征融合权重,突出有用信息,解决裂缝漏检问题;在编码器部分,改进浅层特征与深层特征的选取方式,提升特征融合效果和检测精度。尹学辉等人^[42]针对现有基于深度学习的检测方法因过度下采样导致裂缝像素信息丢失的问题,提出一种基于渐进式上下文交互和注意力机制的混凝土裂缝检测网络。首先,以优化的 UNet++为主干,采用非

对称卷积块来增强特征提取能力；其次，引入渐进式上下文交互机制（PCIM）以高效捕捉与融合相邻特征图的多尺度特征；再次，在特征增强阶段，用注意力组合（AC）方式提高特征表达能力；最后，在特征融合阶段，使用多语义注意力动态融合模块（MADFM），以增强细节恢复和保留效果。

王保宪等人^[43]针对路面复杂背景的干扰易造成路面裂缝检测算法易产生虚警和漏检的问题，提出一种基于语义特征增强学习的路面裂缝病害检测方法。该算法以 Unet++ 网络为裂缝检测的主框架，其通过融合更多的底层特征信息来提升裂缝病害检测的精度。在 Unet++ 网络层间特征融合的基础上，根据不同卷积层的特征图属性，进一步差异性地引入视觉注意力计算模块，有效抑制背景杂波的干扰，减少虚警率。利用空洞卷积操作分别从 2 方面改进网络模型的训练过程：应用空洞卷积代替传统的池化操作，通过网络的自动学习剔除无关紧要的特征信息，加强网络对细微裂缝特征的学习能力；在网络上采样前，建立空洞卷积金字塔池化层，通过增加对裂缝特征的尺度多样性计算，保证网络模型在不同拍摄距离下裂缝病害检测的适用性。

两阶段模型通过候选区域生成和精确定位实现较高的检测精度，但其计算量大、推理速度慢，不适合部署在实体平台。相较之下，单阶段模型通过直接回归生成检测框，具有更高的推理速度和帧率^[44]。因此单阶段模型更适合应用于路面裂缝检测任务当中。

郝巨鸣等人^[45]针对目前公路路面裂缝种类和尺度多样导致路面病害检测困难的问题，提出一种基于 GhostNet 的轻量化无人机图像裂缝检测方法检测不同种类路面裂缝。引入轻量级 GhostNet 中的 Ghost 模块优化 YOLOv4 主干特征提取网络，得到轻量化模型 YOLOv4-Light，以降低模型复杂度，并提高裂缝检测速度；在模型预测输出端融合高效通道注意力（ECA）机制，从而进一步增强裂缝特征提取能力，提高裂缝检测精度。

龚芳媛等人^[46]针对使用 YOLOv5 模型检测路面裂缝未能充分考虑裂缝尺度差异大、目标小的特性以及与背景不易区分等因素导致检测精度低的问题，提出了一种基于改进 YOLOv5 的路面裂缝检测算法。首先，引入 SwinTransformer 模块到 YOLOv5 模型中，提升网络全局特征提取能力。其次，在主干网后增加膨胀卷积模块，旨在特征融合前提取主干网全局特征信息。最后，通过加入注意力机制模块来增强模型对检测目标的关注度并削弱背景干扰因素的影响。

沈思远等人^[47]针对传统的路面裂缝检测方式耗时耗力、成本高、主观性强等问题，提出了一种基于 YOLOv5 的路面裂缝检测模型 YOLOv5-Crack。首先在主干部分处引入坐标注意力机制并优化成 CA-plus 结构以提高裂缝特征关注度；其次提出一种全新的特征融合网络 ESPP，降低部分计算量的同时提升特征融合能力；然后，在颈部网络中使用重影混洗卷积替代传统卷积，尽可能保持通道语义信息的同时降低计算成本；最后，

整体引入 SIOU 损失函数提升回归精度。孙建诚等人^[48]针对现有算法检测含光影斑驳、车道线等复杂背景下路面裂缝图像效果不佳的问题,提出一种基于 YOLOv5 裂缝检测改进算法 YOLOv5-GG。首先,添加坐标注意力(coordinate attention, CA)模块,将背景噪声隐化,从而使模型针对性地聚焦于有用特征;其次,将原网络中的 Conv 模块替换为 GhostConv,降低网络的复杂度。

景峰等人^[49]针对路面裂缝自动化检测中存在裂缝漏检和定位不准的问题,提出一种路面裂缝实时检测模型 CrackNet。基于 YOLOv5 结构设计,在特征融合网络插入融合注意力模块,重点关注特定通道和空间位置裂缝信息,有效解决部分裂缝漏检问题。李金涛等人^[50]针对路面小缺陷检测准确率低、漏检率和误检率高且均匀分布缺陷类型数据集难以采集的问题,提出一种基于 YOLOv5s 的 TAS-YOLO 改进网络模型方法。在预测结果阶段采用特定任务的上下文解耦头,通过分离分类和定位任务,增强定位检测框的精度并通过 FPN 结构将 5 个尺度的特征图输入解耦头进行预测,增强小目标的多尺度特征信息。刘宏利等人^[51]基于 YOLOv8 提出了一种轻量化裂缝检测模型。首先使用改进后的轻量化 Ghost 模块与 Conv 和 C2F 结合,依靠更少的卷积核生成更高精度的特征图;随后在颈部引入跨尺度特征融合模块,在 Concat 模块前添加额外的 Conv,将不同尺度的特征进行融合,提高对信息捕捉能力的同时降低冗余计算;最后在主干网络添加级联组注意力机制,将特征分成不同区域并分配不同权重,进一步提升对小目标的检测能力。

高明星等人^[52]提出一种基于双金字塔网络的航拍图像路面裂缝检测方法。使用改进 MobileNetv3_small 编码特征,轻量化网络;在跳跃连接时,设计了一种阶梯式的特征引导方式,结合混合域注意力机制组成 3 个不同尺度的特征金字塔融合网络,高效传递多尺度上下文特征;最后在网络深层设计并行尺度感知金字塔融合模块传递更多细节编码特征。此外,通过权重修正优化了 focal 损失和 dice 损失联合约束的效果,提高网络训练时对类别不平衡数据的处理能力。白锋等人^[53]针对当前道路巡检智能化程度不足以及效率低等问题,在 YOLOv8s 的基础上针对无人机航拍场景提出改进模型 AC-YOLO,在主干网络引入动态大卷积核注意力机制 LSK-attention 来扩展模型的感受野,提高对路面裂缝范围检测的准确性。其次在颈部结构设计多尺度特征融合策略,融入 BiFPN 网络,改善对细小裂缝的检测。

钟伟^[54]先在 YOLOv8 的颈部添加了特征聚焦扩散金字塔网络 Focusing Diffusion Pyramid Network(FDPN),通过定制的特征聚焦模块与特征扩散机制,能让每个尺度的特征都具有详细的上下文信息。

周秀珊等人^[55]通过在 YOLOv11 的骨干网络的 C2PSA 层后增加细粒度分类注意力机制,将 C3k2 模块替换为 VoV-GSCSP 模块,此外,在 P2 层使用轻量级的 VoV-GSCSP 模块进行特征融合策略。在不降低检测速度和不损失模型轻量化程度的情况下提高了模型的检测精度。

李禹萱等人^[56]针对路面裂缝检测过程中易受到路面阴影、杂草、泥土等干扰因素的影响,导致基于路面图像的自动化检测变得更加困难的问题,提出一种基于 Swin-Transformer 主干网络的农村道路裂缝检测模型。针对模型在裂缝特征提取过程中受到周围干扰物影响导致识别精度降低的问题,设计一种自适应的混合注意力机制模块 CAS,该模块能够在空间和通道两个维度上调整裂缝的权重,提高检测模型的抗干扰能力;针对多个裂缝在同一图像上尺寸差异较大导致识别困难的问题,改进了一种带注意力机制的多尺度目标检测头 AHead,该检测头可以自适应调整网络感受野,实现多尺度的裂缝检测。

杨杰等人^[57]针对现有路面损伤检测模型中存在识别精确度低和计算量大的问题,提出一种结合 Transformer 和 SimAM 的轻量化路面损伤检测算法。在 Transformer 模型中引入 COT 模块加强特征提取性能,其可以利用特征图的上下文信息构建自注意力机制,有效捕获路面损伤图像的上下文信息,加强信息表征能力。融入 SimAM 注意力机制调节特征,增强模型在复杂场景下的特征表达能力,抑制无关特征的干扰。

隆涛等人^[58]针对较复杂背景下路面裂缝检测以及裂缝图像自身像素类别不平衡的问题,提出了一种基于注意力机制和可变形卷积的路面裂缝检测网络,该网络基于编码-解码结构进行构建。为了解决较为复杂背景裂缝检测困难的问题,首先,由可变形卷积提升网络对不同形状裂缝线性特征的学习能力;其次,使用密集连接机制强化特征信息;然后,在解码阶段采用转置卷积和桥接方式与编码阶段特征逐步融合,并结合多级特征融合的思想,提高网络的检测精度;最后,引入注意力模块(SimAM),在不增加网络参数的前提下,更加关注目标特征的提取,抑制背景特征。

刘向举等人^[59]提出了一种基于 SimAM 注意力机制的 DCN-YOLOv5 水下目标检测方法,采用 YOLOv5 所使用的双向金字塔网络(BiFPN, Bi-directional Feature Pyramid Network)在多个尺度上提取和融合特征信息,从而提高目标辨别的准确度;针对水下目标的外观、形状变化问题,将 C3 模块中的 CBS 模块结合可变形卷积(DCN, Deformable Convolution Network),提出 DBS 模块并组成 D3 模块替换部分 C3 模块,以适应水下目标的外观、形状变化;同时,融入加权注意力机制(SimAM),自适应地调节模型的关注度,进一步在复杂场景下增强特征表达能力;考虑目标边界模糊,为改善目标定位精度,采用 WIoU(Wise-IoU) 损失函数来替换交叉熵损失,能够更好地适应不同目标类型和

尺寸的特点,提高算法鲁棒性。单飞等人^[60]针对道路路面病害数据多模态和识别准确率低的问题,提出了一种基于自适应注意力机制 simAM 改进 YOLOv8 的路面多病害识别算法,采用 simAM 模块进一步调整不同尺度的特征图的权重,实现对目标的检测改善。

张刚等人^[61]针对目前已有目标检测算法在路面坑洼养护应用较少,且存在检测模型参数量较大、小目标容易漏检的问题提出一种改进的 YOLOv5 的算法。在主干(Backbone)层采用轻量化卷积 GhostConv 代替原有的标准卷积,减少模型参数;在颈部(Neck)层加入卷积 GSConv 和改进的注意力机制 GSECA 以及改进的双向融合模型 BiFPN-m,增强特征信息提取与融合能力;将损失函数替换为 EIOULoss,提高小目标的检测精度。任金霞等人^[62]提出一种基于 ECA 和 BiFPN 改进 YOLOv5s 的 PCB 缺陷检测方法。首先,在主干网络的 C3 中引入 ECA 注意力机制,使模型更加关注小目标的特征信息,保证模型检测效果;其次,引入加权双向特征金字塔网络(bidirectional feature pyramid network, BiFPN),让模型能够更快速地开展多尺度特征融合;最后,使用 SIOU Loss 替换 CIOU Loss,进一步提升模型的稳定性。

刘丽丽等人^[63]提出一种基于 BiFPN 和注意力机制改进的 YOLOv5s 模型。通过集成双向特征金字塔网络(BiFPN)和引入 CBAM 注意力机制,优化了模型对小目标的识别能力。侯涛等人^[64]提出一种改进 YOLOv7-tiny 的轻量级道路缺陷检测算法。首先,利用多尺度特征提取模块构建主干网络,增强提取多尺度特征的能力;其次,颈部网络引用轻量颈部设计范式以降低所提算法的整体计算复杂度,提升特征表达性能,并采用改进的双向特征金字塔(BiFPN)特征融合结构,自适应控制不同尺度特征图之间的融合程度;然后,引入坐标注意力,捕捉细节特征信息;最后,采用 Mish 激活函数,使算法具有更好的泛化能力,同时利用 k-means 算法重聚类先验框,使其更符合道路缺陷目标分布特点,从而提高网络收敛速度与检测精度。

王启涵等人^[65]针对现阶段道路裂缝检测算法中准确度低、效率低的问题,提出了一种基于 YOLOv7-Tiny 的轻量型道路裂缝检测算法 YOLOv7-TPSF。结合特征融合网络 BiFusion Neck 与加权特征金字塔 BiFPN 的优点,提出了新的特征融合模块 Bi-FusFPN,减少网络计算量,强化多尺度特征的融合能力,并在输出端添加无参注意力机制 SimAM,进一步提高各类目标的检测能力。

1.3 现有检测方法存在的问题及不足

通过对国内外研究现状的分析,可以发现,路面裂缝和坑洞检测的相关研究虽然取得了很大进展,仍有以下问题需要解决。

(1) 在进行路面检测中，多是检测单一目标，但是在路面损害中这两类目标常常一起出现。

(2) 路面裂缝和坑洞在拍摄的照片部分为较小的目标，提高对于小目标的检测准确率有助于提升算法整体的效果。

(3) 路面裂缝和坑洞具有多尺度特征，应考虑多尺度特征融合以提高裂缝和坑洞检测精度。

(4) 现有研究少有考虑多尺度特征融合与引入注意力机制导致的模型参数量增加和计算效率下降的问题。

1.4 论文主要研究内容及技术路线

1.4.1 论文主要研究内容

为了提升路面裂缝和坑洞检测模型的性能，本文提出一种基于改进 YOLOv11n 的路面裂缝和坑洞检测算法。主要改进内容如下：

(1) 对 YOLOv11n 颈部网络进行优化，将 BiFPN 与 MCA 融合设计出一种新的 BMFPN 结构，并替换原颈部网络的 Concat 层，通过动态优化多尺度特征处理，以更好地保留细粒度特征，增强目标区分和上下文感知能力并抑制背景干扰，同时保持轻量化和高效计算，提升检测精度和模型鲁棒性。

(2) 为了解决 C3K2 模块存在的缺乏对关键特征的选择性的问题，将 SimAM 与 C3K2 融合，提出一种 SMC3K2 模块，以增强对不同尺度路面裂缝和坑洞特征的提取能力。利用局部空间特征的自适应调节，增强 C3K2 模块的信息选择性。使得模型可以精准聚焦于目标区域的关键特征。同时保留 C3K2 模块的跨层特征融合能力和计算效率。通过增强特征表示能力，提高模型对路面裂缝和坑洞的检测效果。

论文结构安排如下：

第一章：绪论。首先，交代路面裂缝检测的背景及意义。其次，对国内外学者对于路面裂缝和坑洞检测技术的研究现状进行介绍。最后，对本文主要研究内容及结构安排进行阐述。

第二章：理论基础。首先介绍有关深度学习的基础理论。其次介绍卷积神经网络的概念、组成、原理以及网络结构。最后介绍深度学习的经典目标检测算法--RetinaNet 算法、SSD 算法以及 YOLO 系列算法，其中重点介绍本文的基础网络模型 YOLOv11。

第三章：YOLOv11n 算法改进。为了提升路面裂缝和坑洞检测模型的性能，满足其在实际应用中的需求，考虑路面裂缝和坑洞检测任务中因场景复杂以及检测目标多样化易对检测效果造成影响，基于 BiFPN、MCA 和 SimAM 对 YOLOv11n 模型进行改进。

本章详细介绍 BMFPN 结构和 SMC3k2 模块的核心思想,以及实现对 YOLOv11n 模型改进的理论方法。

第四章:实验结果与分析。为了验证模型改进可行性与改进效果,设计进行对比实验与消融实验。本章首先交代了实验数据集、环境与参数配置以及实验评价指标。其次先后进行 BMFPN 与 SMC2f 的消融实验,接着进行改进 YOLOv11n 模型与经典物体检测模型的对比试验,最后对实验结果进行量化、分析和可视化展示。通过实验验证了改进方法的可行性以及模型在路面裂缝和坑洞检测任务中的有效性。

第五章:结论。对论文的主要研究内容与研究结果进行归纳总结,并对未来的研究发展进行展望。

1.4.2 技术路线

本文技术路线图如下。




图 1.1 技术路线图

Fig. 1.1 Technology roadmap

本章小结

本章交代了路面裂缝和坑洞检测的背景与意义；整理了目前国内外相关研究的现状；介绍了道路裂缝和坑洞检测研究面临的问题；明确了本文的研究思路，研究内容与研究方法；展示了研究的技术路线与论文的结构安排。

第二章 理论基础

2.1 深度学习概述

深度学习是机器学习的一个分支领域，它是一种基于对数据进行表征学习的方法。深度学习通过构建具有多个层次的神经网络模型，让计算机自动从大量数据中学习特征和模式，以实现数据的分类、预测、生成等任务。这些神经网络由许多神经元组成，神经元之间通过连接权重传递信息，通过调整这些权重来优化模型的性能。近年来，随着计算能力的大幅提升，尤其是图形处理单元（GPU）在计算中的应用，以及大规模数据集的出现和算法的创新，深度学习迎来了爆发式增长，在图像识别、语音识别、自然语言处理等领域取得了突破性的成果。

深度学习模型通常包含多个层次，如输入层、隐藏层和输出层。输入层接收原始数据，输出层给出模型的预测结果，隐藏层则负责对数据进行特征提取和变换。隐藏层的数量和结构决定了模型的复杂度和表达能力。深度学习的学习过程通常如下：

（1）数据准备：收集和整理大量的标注或未标注数据，对数据进行清洗、预处理和划分，通常将数据分为训练集、验证集和测试集。训练集用于训练模型，验证集用于调整模型的超参数，测试集用于评估模型的性能。

（2）模型训练：使用训练数据对深度学习模型进行训练，通过反向传播算法计算损失函数关于模型参数的梯度，然后利用梯度下降等优化算法更新参数，使得损失函数逐渐减小。在训练过程中，还会使用一些技巧，如学习率调整、正则化、Dropout 等，以防止模型过拟合，提高模型的泛化能力。

（3）模型评估：使用测试集对训练好的模型进行评估，计算模型在测试集上的准确率、召回率、均方误差等指标，以衡量模型的性能。如果模型性能不满足要求，可以调整模型结构、超参数或增加数据量，重新进行训练和评估。

随着 AI 大模型技术的不断发展，深度学习在计算机视觉和自然语言领域均取得了长足进步。在计算机视觉领域，包括图像识别、目标检测、图像分割、人脸识别、视频分析等在内的技术应用均有突破。

2.2 卷积神经网络

卷积神经网络（Convolutional Neural Network，简称 CNN）是一种专门为处理具有网格结构数据（如图像、音频）而设计的深度学习模型，在图像识别、物体检测、图像分割和语音识别等领域均有应用。




图 2.1 卷积神经网络结构

Fig. 2.1 Convolutional neural network structure

CNN 的工作原理基于局部感知、权值共享和池化等思想。局部感知意味着网络中的神经元只需要关注输入数据的局部区域，而不是整个输入，这符合图像等数据的局部相关性特点，使得网络能够更有效地提取局部特征。权值共享是指卷积核在整个输入数据上滑动时，其权重是固定不变的，这大大减少了模型的参数数量，降低了模型的复杂度，同时也提高了模型的泛化能力。池化操作则进一步对特征进行压缩和选择，保留最具代表性的特征。CNN 能够自动提取数据的特征，无需人工设计特征工程，这使得它在处理复杂的图像和语音数据时具有很大的优势。同时，由于其权值共享和局部感知的特性，CNN 对数据的平移、旋转等变换具有一定的不变性，能够更好地适应实际应用中的各种变化。

在计算机视觉领域，CNN 被广泛应用于图像分类、目标检测、图像分割等任务。例如，在图像分类中，CNN 可以将图像准确地分类为不同的类别，如识别动物、植物、交通工具等；在目标检测中，它能够定位图像中的多个目标，并识别出它们的类别和位置；在图像分割中，CNN 可以将图像中的不同物体或区域进行精确的分割。在语音识别领域，CNN 也被用于对语音信号进行特征提取和分类，实现语音到文字的转换等功能。总之，CNN 作为一种强大的深度学习模型，以其独特的结构和工作原理，在众多领域中发挥着重要作用，推动了人工智能技术的不断发展和进步。

卷积神经网络结构一般包括卷积层、激活函数、池化层和全连接层。

2.2.1 卷积层

卷积层 (Convolutional Layer) 是卷积神经网络的核心组成部分，卷积层通过卷积核在输入数据上滑动，进行卷积操作来提取特征。卷积核是一个具有固定大小的权重矩

阵，它在输入数据的每个位置上进行加权求和，从而生成新的特征图。以图像为例，卷积核在图像上从左到右、从上到下逐像素滑动，每次滑动都与对应位置的图像像素进行乘法和加法运算，将结果作为输出特征图上对应位置的值。

这样，卷积核就可以捕捉到图像中的局部特征，如边缘、角点等。不同的卷积核可以捕捉到不同类型的特征，例如，一些卷积核可能对水平边缘敏感，而另一些则对垂直边缘或纹理更敏感。随着卷积层的堆叠，网络可以逐渐提取出更高级、更抽象的特征。在卷积操作中，同一个卷积核在整个输入数据上共享权重。这大大减少了模型的参数数量，降低了计算量和过拟合的风险。因为无论卷积核在输入的哪个位置，它都以相同的方式提取特征，所以只需要学习一组卷积核的参数即可。每个输出特征图上的元素只与输入数据中的一个局部区域相连，而不是与整个输入数据相连。这种稀疏连接方式使得网络能够专注于局部特征，同时也减少了参数数量和计算量。




图 2.2 卷积原理图

Fig. 2.2 Convolution schematic diagram

卷积层相关参数如下：

(1) 卷积核大小：通常为奇数，如 3×3 、 5×5 等。较小的卷积核可以捕捉到更精细的局部特征，而较大的卷积核可以覆盖更大的区域，捕捉到更宏观的特征。

(2) 步幅 (Stride)：指卷积核在滑动时每次移动的步数。步幅为 1 表示卷积核每次移动一个像素，步幅为 2 则表示每次移动两个像素，以此类推。较大的步幅可以减少输出特征图的尺寸，提高计算效率，但可能会丢失一些细节信息。

(3) 填充 (Padding)：为了保持输入数据的尺寸或控制输出特征图的尺寸，在输入数据的边缘添加额外的行和列。常见的填充方式有“Same”填充和“Valid”填充。“Same”填充会在输入数据的边缘填充适量的 0，使得输出特征图的尺寸与输入数据相同；“Valid”

填充则不进行任何填充，卷积核只在输入数据内部进行滑动，因此输出特征图的尺寸会小于输入数据。

卷积操作计算过程如下：

假设输入数据是一个大小为 $H \times W \times C$ 的三维张量，其中 H 表示高度， W 表示宽度， C 表示通道数（例如，对于彩色图像， $C=3$ ，分别对应红、绿、蓝三个通道）。卷积核的大小为 $K \times K \times C$ ，其中 K 是卷积核的边长， C 与输入数据的通道数相同，以确保能够对每个通道进行卷积操作。对于输入数据中的每个位置 (i, j) ，卷积核与以 (i, j) 为中心的大小为 $K \times K \times C$ 的局部区域进行对应元素相乘并求和，得到输出特征图上对应位置的值。具体计算公式为：

$$O_{i,j} = \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} \sum_{c=0}^{C-1} I_{i+m,j+n,c} \times W_{m,n,c} \quad (2.1)$$

其中， $O_{i,j}$ 是输出特征图在位置 (i, j) 的值， $I_{i+m,j+n,c}$ 是输入数据在位置 $(i+m, j+n, c)$ 的值， $W_{m,n,c}$ 是卷积核在位置 (m, n, c) 的权重。如果考虑步幅 s 和填充 p ，则输出特征图的尺寸计算公式为：

$$H_{out} = \frac{H + 2p - K}{s} + 1, W_{out} = \frac{W + 2p - K}{s} + 1 \quad (2.2)$$

2.2.2 激活函数

激活函数是 CNN 中输入和输出之间的关系，它为神经网络引入了非线性因素，使得网络能够学习和表示复杂的函数关系。以下是 CNN 中几种常见的激活函数：

(1) Sigmoid 函数

$$\text{数学表达式: } f(x) = \frac{1}{1 + e^{-x}} \quad (2.3)$$

其值域在 $(0, 1)$ 之间，函数图像是一条平滑的曲线，在 $x=0$ 处取值为 0.5 ，当 x 趋于正无穷时， $f(x)$ 趋近于 1 ；当 x 趋于负无穷时， $f(x)$ 趋近于 0 。Sigmoid 能够将任意实数映射到 $(0, 1)$ 区间，这对于表示概率或进行二分类任务非常有用。例如，在图像分类中，可以将输出通过 Sigmoid 函数转化为属于某一类别的概率。但同时，Sigmoid 函数存在梯度消失问题，当 x 绝对值较大时，函数的导数趋近于 0 ，这会导致在反向传播过程中，梯度难以传递，使得网络训练速度变慢，甚至无法收敛。此外，其输出不是以 0 为中心的，这可能会导致神经元的输出始终为正或始终为负，从而影响网络的学习能力。




图 2.3 Sigmoid 函数图像

Fig. 2.3 Sigmoid function image

(2) Tanh 函数（双曲正切函数）

数学表达式: $f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$ (2.4)




图 2.4 Tanh 函数图像

Fig. 2.4 Tanh function image

其值域在 $(-1,1)$ 之间,是一个奇函数,关于原点对称,在 $x=0$ 处取值为 0 。与 Sigmoid 函数相比, Tanh 函数的输出是以 0 为中心的,这使得它在一些情况下能够更好地收敛。在处理一些需要考虑正负值的问题时,如情感分析中的积极和消极情感, Tanh 函数更合适。同 Sigmoid 函数一样, Tanh 函数也存在梯度消失问题,当 x 绝对值较大时,导数趋近于 0 ,导致训练困难。

(3) ReLU 函数 (修正线性单元)

$$\text{数学表达式: } f(x) = \max(0, x) \quad (2.5)$$




图 2.5 ReLU 函数图像

Fig. 2.5 ReLU function image

即当 $x>0$ 时, $f(x)=x$; 当 $x\leq 0$ 时, $f(x)=0$ 。在 $x>0$ 时, 函数是线性的, 斜率为 1 , 在 $x=0$ 处不可导, 但在实际应用中可以通过一些技巧来处理。ReLU 函数有效地解决了梯度消失问题, 因为当 $x>0$ 时, 其导数恒为 1 , 使得梯度能够在反向传播中顺利传递, 大大加快了网络的训练速度。同时, ReLU 函数计算简单, 减少了计算量。但是 ReLU

函数存在神经元死亡问题，当输入小于 0 时，神经元的输出恒为 0，在训练过程中，如果某些神经元的权重更新不当，可能导致这些神经元永远不会被激活，即死亡。

(4) Leaky ReLU 函数

$$\begin{aligned} \text{数学表达式: } f(x) &= x, x > 0 \\ f(x) &= \alpha x, x \leq 0 \end{aligned} \quad (2.6)$$

其中 α 是一个较小的常数，通常取 0.01 左右。与 ReLU 函数类似，但在 $x \leq 0$ 时，不再是恒为 0，而是有一个较小的斜率 α ，这使得当输入为负数时，神经元也能有一定的激活程度。解决了 ReLU 函数中神经元死亡的问题，因为即使输入为负数，神经元也不会完全失去活性，能够更好地保持信息的传递。同时，它也继承了 ReLU 函数计算简单和能够加快训练速度的优点。虽然在一定程度上缓解了神经元死亡问题，但 α 的取值需要进行调优，如果取值不合适，可能会影响模型的性能。




图 2.6 Leaky ReLU 函数图像

Fig. 2.6 Leaky ReLU Function graph

(5) ELU 函数（指数线性单元）

$$\begin{aligned} \text{数学表达式: } f(x) &= x, x > 0 \\ f(x) &= \alpha(e^x - 1), x \leq 0 \end{aligned} \quad (2.7)$$




图 2.7 ELU 函数图像

Fig. 2.7 ELU function image

其中 α 是一个超参数，通常取 1。在 $x > 0$ 时与 ReLU 函数相同，在 $x \leq 0$ 时，函数是一个指数形式，能够将输出拉向 $-\alpha$ ，使得输出的均值更接近 0，有助于加快收敛。输出均值接近 0，这有利于减少梯度消失问题，并且在 $x \leq 0$ 时，函数是平滑的，不存在 ReLU 函数在 $x=0$ 处的不连续问题，使得模型的训练更加稳定。但是计算相对复杂，因为涉及到指数运算，这会增加一定的计算量。

在实际应用中，选择合适的激活函数对于 CNN 模型的性能至关重要。通常需要根据具体的任务和数据特点进行尝试和调优，以找到最适合的激活函数。同时，也可以通过组合不同的激活函数或对激活函数进行改进来进一步提高模型的性能。

2.2.3 池化层

池化层（Pooling Layer）通常位于卷积层之后，主要用于对数据进行下采样，以减少数据的维度，同时保留数据的重要特征。池化操作可以看作是一种数据增强方式，它对局部区域的特征进行聚合，使得模型对输入数据的微小变化具有更强的鲁棒性，减少了模型对噪声的敏感性，从而在一定程度上防止过拟合。

随着卷积层的不断堆叠，数据的维度会逐渐增加，计算量也会越来越大。池化层通过对特征图进行下采样，减少了数据的空间维度，从而降低了模型的计算量和存储量，提高了模型的运行效率。池化层在降低维度的同时，能够保留图像中的主要特征。通过

选择合适的池化方式，可以提取出对分类或其他任务有用的特征，如图像中的边缘、纹理等信息。




图 2.8 池化原理图

Fig. 2.8 Pooling schematic diagram

池化层相关参数如下：

(1) 池化窗口大小：决定了每次池化操作所涉及的区域大小。常见的池化窗口大小有 2×3 、 3×3 等。较大的池化窗口会导致更多的信息丢失，但能更大程度地降低数据维度；较小的池化窗口则能保留更多的细节信息，但降低维度的效果相对较弱。

(2) 步长 (Stride)：表示池化窗口在特征图上移动的步幅。如果步长等于池化窗口大小，那么池化操作不会有重叠区域；如果步长小于池化窗口大小，则会有重叠区域，这样可以更精细地对特征图进行采样，但也会增加计算量。通常情况下，步长与池化窗口大小相等，以提高计算效率。

常见的池化方法有：

(1) 最大池化 (Max Pooling)：在一个给定的池化窗口内，选择最大值作为该窗口的输出。例如，对于一个 2×2 的池化窗口，它会在该 2×2 的区域内选择最大的像素值作为输出。最大池化能够很好地保留图像中的纹理和边缘等特征，因为这些特征通常对应着图像中的高强度区域，更容易被选择为最大值。

(2) 平均池化 (Average Pooling)：计算池化窗口内所有元素的平均值作为输出。与最大池化不同，平均池化更注重对区域内整体特征的提取，它会对池化窗口内的所有像素值进行平均，能够在一定程度上平滑图像，减少噪声的影响。

(3) 全局平均池化 (Global Average Pooling)：将整个特征图的平均值作为输出。它是平均池化的一种特殊形式，通常用于网络的最后一层，将特征图压缩成一个固定长度的向量，作为分类器的输入。全局平均池化可以有效地减少模型的参数数量，避免过拟合，同时也具有较好的可解释性。

池化操作过程：以最大池化为例，假设输入的特征图是一个 4×4 的矩阵，池化窗口大小为 2×2 ，步长为 2。首先，从特征图的左上角开始，取一个 2×2 的窗口，在这个窗口内选择最大值作为输出，然后将窗口按照步长向右移动 2 个单位，再取一个新的 2×2 窗口，重复上述操作，直到遍历整个特征图。最终得到的输出特征图维度将变为 2×2 ，实现了对输入特征图的下采样。

池化层作为卷积神经网络中的重要组成部分，通过对特征图进行下采样，有效地降低了数据维度，提高了模型的运行效率和鲁棒性，同时保留了对任务有用的特征信息，为后续的分类或其他任务提供了更好的输入。

2.2.4 全连接层

全连接层（Fully Connected Layer）通常位于神经网络的末端，在经过卷积层、池化层等对图像数据进行特征提取和处理后，全连接层负责将提取到的特征进行整合，并进行最终的分类或回归任务。




图 2.9 全连接原理图

Fig. 2.9 Full connection schematic

全连接层中的神经元与上一层的所有神经元都有连接，这意味着该层的每个神经元都接收来自上一层所有神经元的输出作为输入。例如，若上一层有 n 个神经元，全连接层中有 m 个神经元，那么就会有 $n \times m$ 条连接边，每条边都对应一个权重参数。计算过程：对于全连接层中的每个神经元，它会将上一层传来的输入信号进行加权求和，再加上一个偏置项，然后通过激活函数进行非线性变换，得到该神经元的输出。具体计算公式为：

$$y = f(\sum_{i=1}^n w_i x_i + b) \quad (2.8)$$

其中 x_i 是上一层第 i 个神经元的输出, w_i 是对应的权重, b 是偏置项, f 是激活函数, y 是当前神经元的输出。

经过前面的卷积层和池化层, 图像的局部特征被提取出来, 但这些特征还比较分散。全连接层将这些局部特征进行整合, 形成一个全局的特征表示, 然后根据这个特征表示进行分类或其他预测任务。图像分类任务中, 全连接层可以将提取到的各种图像特征组合起来, 判断图像属于不同类别的概率。

全连接层包含了大量的权重参数, 这些参数在模型训练过程中通过反向传播算法进行优化。通过不断调整权重和偏置, 使得模型能够最小化损失函数, 从而提高模型的准确性和泛化能力。具有很强的拟合能力, 可以学习到输入特征之间的复杂关系, 能够对各种类型的数据进行有效的分类和回归。在处理具有明确分类边界的问题时, 全连接层能够通过调整权重来准确地划分不同类别。

全连接层在卷积神经网络中起着至关重要的作用, 它将前面提取到的特征进行整合和分类, 是实现各种计算机视觉任务的关键步骤。具有很强的拟合能力, 可以学习到输入特征之间的复杂关系, 能够对各种类型的数据进行有效的分类和回归。在处理具有明确分类边界的问题时, 全连接层能够通过调整权重来准确地划分不同类别。

2.2.5 采样方式

在卷积神经网络 (Convolutional Neural Network, CNN) 里, 采样是很关键的操作, 它能缩减特征图的尺寸, 降低计算量, 还能增强特征的鲁棒性。常见的采样方式有下采样和上采样。

下采样也被叫做降采样, 作用是缩小特征图的尺寸, 同时提升感受野, 进而减少计算量和参数数量。常见的下采样方法有:

1. 最大池化

最大池化是在输入特征图上划分出不重叠的矩形区域, 即池化窗口。通常, 池化窗口的大小是固定的, 如 2×2 、 3×3 等。然后, 在每个池化窗口内选取最大值作为输出特征图中对应位置的值。例如, 对于一个 4×4 的输入特征图, 使用 2×2 的池化窗口进行最大池化操作, 会将输入特征图划分为 4 个不重叠的 2×2 区域, 分别在每个区域中取最大值, 得到一个 2×2 的输出特征图。

通过最大池化操作能够提取特征图中的关键信息, 将最具代表性的特征保留下来, 例如图像中的边缘、角点等显著特征。因为这些特征往往对应着较大的数值, 通过最大池化可以强化它们在特征图中的表现。同时, 最大池化的采样方法对特征的位置变化具

有一定的容忍度。即使特征在池化窗口内有小幅度的位移，只要其数值仍然是窗口内的最大值，就不会影响池化结果。这使得模型对输入数据的微小变化不那么敏感，提高了模型的鲁棒性。通过减少特征图的尺寸，降低了后续神经网络层的输入维度，从而减少了计算量和模型的参数数量。这有助于提高模型的训练速度，减少过拟合的风险。




图 2.10 最大池化操作

Fig. 2.10 Maximum pooling operation

然而，由于只保留了池化窗口内的最大值，其他像素的信息被丢弃，这可能导致一些细节信息的丢失。如果池化窗口过大或池化操作过于频繁，可能会对模型的性能产生一定的影响，尤其是对于一些需要精细细节信息的任务，如图像分割中的边界识别等。

在图像分类任务中，最大池化常用于提取图像的整体特征，帮助模型快速定位图像中的关键信息，如物体的轮廓、颜色等，从而提高分类的准确性。例如，在识别手写数字的任务中，最大池化可以帮助模型更好地捕捉数字的形状特征，即使数字在图像中的位置有微小变化，也能准确识别。

在目标检测算法中，最大池化可以用于对特征图进行下采样，减少计算量的同时，保留目标的关键特征，有助于快速定位目标物体在图像中的位置。在 YOLO 系列目标检测算法中，就广泛使用了最大池化操作来提取图像的特征，提高目标检测的速度和精度。

2. 平均池化

平均池化同样是在输入特征图上划分出固定大小的池化窗口，通常为正方形或矩形，如 2×2 、 3×3 等。与最大池化不同的是，它是计算每个池化窗口内所有元素的平均值，并将该平均值作为输出特征图中对应位置的值。例如，对于一个 4×4 的输入特征图，

使用 2×2 的池化窗口进行平均池化操作，会将输入特征图划分为 4 个不重叠的 2×2 区域，分别计算每个区域内元素的平均值，得到一个 2×2 的输出特征图。



图 2.11 平均池化操作

Fig. 2.11 Average pooling operation

平均池化考虑了池化窗口内所有元素的信息，能够更全面地反映区域内的特征均值，对于一些需要保留整体特征分布的任务较为适用。例如在图像风格迁移中，平均池化可以帮助保留图像的整体颜色和纹理信息，使得生成的图像在风格上更接近原始图像。

由于是取平均值，平均池化可以对特征图起到平滑作用，减少数据中的噪声和局部波动。这有助于提高模型的稳定性，降低模型对局部细节变化的敏感性，使模型更关注整体的特征趋势。

与最大池化类似，平均池化也会导致一定程度的信息丢失。因为它将池化窗口内的所有元素进行平均，可能会模糊掉一些具有代表性的局部特征，尤其是当这些特征的数值差异较大时。例如，在处理具有明显边缘或纹理细节的图像时，平均池化可能会使这些细节变得不那么清晰。如果池化窗口内存在一些对识别任务非常关键的高值特征，但被其他低值特征平均后，可能会削弱这些关键特征的表达能力，影响模型对重要特征的捕捉。

3. 步长卷积

常规卷积操作是在输入数据上以固定的卷积核大小进行滑动，每次滑动一个像素位置来计算卷积结果。而步长卷积则在滑动卷积核时，按照指定的步长值移动。例如，当步长为 1 时，卷积核每次移动一个像素；当步长为 2 时，卷积核每次在水平和垂直方向

上移动两个像素，以此类推。这样，在相同大小的输入数据上，使用步长大于 1 的卷积操作可以减少输出特征图的尺寸，实现下采样的效果。

其计算过程如下：

假设输入是一个 $H \times W$ 的特征图，卷积核大小为 $K \times K$ ，步长为 S 。在进行步长卷积时，从图像的左上角开始，将卷积核与图像对应位置的元素相乘并求和，得到输出特征图的第一个元素。然后，按照步长 S 在水平方向上移动卷积核，再次进行乘法和求和操作，得到输出特征图的下一个元素。当卷积核在水平方向移动到图像边缘后，再按照步长 S 在垂直方向上移动一行，继续进行卷积操作，直到覆盖整个图像。输出特征图的大小可以通过式 2.9（向下取整）来计算高度，式 2.10（向下取整）来计算宽度。

$$\frac{H-K}{S}+1 \quad (2.9)$$

$$\frac{W-K}{S}+1 \quad (2.10)$$

通过减少卷积核在输入数据上的滑动次数，步长卷积可以显著降低计算量。例如，当步长为 2 时，卷积核只需要在每隔一个像素的位置上进行计算，相比步长为 1 的情况，计算量大约减少为原来的四分之一。这对于处理大规模图像数据或在计算资源有限的设备上运行模型非常有帮助，可以提高模型的训练和推理速度。步长卷积能够在提取特征的同时实现下采样，减少输出特征图的尺寸。这有助于减少模型中的参数数量，降低模型的复杂度，从而在一定程度上避免过拟合。同时，下采样后的特征图仍然保留了输入数据的主要特征信息，能够有效地压缩数据，便于后续的处理和分析。

与池化操作类似，步长卷积在实现下采样的过程中会丢失一些细节信息。由于卷积核以较大的步长滑动，可能会错过一些局部的细微特征，尤其是当步长较大时，这种信息丢失可能会更加明显。这可能对一些需要精确捕捉细节的任务，如高精度图像分割、超分辨率重建等产生一定的影响。步长卷积会改变卷积核的感受野大小和形状。感受野是指卷积神经网络中某个神经元在输入图像上所对应的区域。步长越大，感受野增长得越快，但感受野内的信息也会变得更加稀疏。这可能导致模型对输入数据的局部信息整合能力发生变化，需要在模型设计和调参过程中加以考虑。

上采样也称为升采样，其目的是增大特征图的尺寸，常用于恢复图像的空间分辨率，在图像分割、图像生成等任务中应用广泛。常见的上采样方法有：

1. 双线性插值

双线性插值上采样的核心原理是在原始数据的基础上，通过双线性插值算法计算出新增采样点的值，从而实现数据的上采样。具体来说，对于给定的一幅低分辨率图像，

要将其放大到指定的高分辨率尺寸，需要在原始图像的每个像素周围通过双线性插值生成多个新的像素点。其假设是在一个二维平面上，待插值点的像素值是其周围四个相邻像素点的加权平均值，权重由该点与四个相邻像素点的距离决定。

假设原始低分辨率图像的尺寸为 $M \times N$ ，要将其放大到 $m \times n$ 的尺寸 ($m > M, n > N$)。首先建立原始图像与目标图像之间的坐标映射关系。对于目标图像中的任意一点 (x, y) ，其在原始图像中的对应坐标 (x', y') 可以通过以下公式计算：

$$x' = x \times \frac{M-1}{m-1} \quad (2.11)$$

$$y' = y \times \frac{N-1}{n-1} \quad (2.12)$$

这一步是为了确定目标图像中的点在原始图像中的相对位置。找到相邻像素点：根据 $((x', y'))$ 确定其在原始图像中相邻的四个像素点。假设 (x', y') 位于原始图像中 (i, j) 、 $(i+1, j)$ 、 $(i, j+1)$ 、 $(i+1, j+1)$ 这四个像素点所构成的矩形内，其中 $i = x'$ （向下取整）， $j = y'$ （向下取整）。计算 (x', y') 与这四个相邻像素点在 x 和 y 方向上的距离权重。在 x 方向上，权重 $t = x' - i$ ；在 y 方向上，权重 $s = y' - j$ 。根据双线性插值公式计算目标图像中 (x, y) 点的像素值 $f(x, y)$ ，公式如下：

$$f(x, y) = (1-s)[(1-t)f(i, j) + tf(i+1, j)] + s[(1-t)f(i, j+1) + tf(i+1, j+1)] \quad (2.13)$$

其中 $f(i, j)$ 、 $f(i+1, j)$ 、 $f(i, j+1)$ 和 $f(i+1, j+1)$ 分别是原始图像中四个相邻像素点的像素值。相比简单的最近邻上采样方法，双线性插值上采样能够生成更平滑的图像，有效减少了锯齿和块状效应，视觉效果更好。它在数学上具有线性精度，对于具有一定连续性和线性变化的数据能够提供较为准确的插值结果。

然而，因为对于目标图像中的每个像素都需要进行多次乘法和加法运算。在处理一些具有复杂纹理或细节的图像时，可能会出现模糊现象，因为双线性插值本质上是一种加权平均方法，会在一定程度上平滑掉图像的细节。

2. 反卷积

反卷积也被称为转置卷积，是一种在深度学习中广泛用于图像上采样和特征图尺寸恢复的技术。反卷积实际上是卷积的一种逆操作，但并非严格意义上的数学逆运算。在普通卷积中，通过卷积核在输入特征图上滑动进行加权求和，从而得到尺寸缩小的输出特征图。而反卷积则是通过一种特殊的运算，将输入特征图的尺寸扩大，以实现上采样的目的。具体来说，反卷积是在一个更大的网格上进行卷积核的滑动操作，在滑动过程中，根据卷积核的权重对相应位置进行赋值和累加，从而生成尺寸更大的输出特征图。可以将其理解为将输入特征图中的每个元素“扩展”成一个更大的区域，然后通过卷积

核的作用进行加权组合，以恢复出更高分辨率的特征图。计算步骤假设输入特征图的尺寸为 $(W \times H \times C)$ ，（ W 为宽度， H 为高度， C 为通道数），卷积核大小为 $(k \times k)$ ，步长为 s ，填充为 p 。初始化输出特征图：首先根据输入特征图的尺寸、卷积核大小、步长和填充来计算输出特征图的尺寸。输出特征图的宽度：

$$W_{\text{out}} = (W - 1) \times s - 2p + k \quad (2.14)$$

输出特征图的高度为：

$$H_{\text{out}} = (H - 1) \times s - 2p + k \quad (2.15)$$

然后创建一个大小为 $W_{\text{out}} \times H_{\text{out}} \times C$ 的输出特征图，初始值通常设为 0。对于输入特征图中的每个元素，将其对应的卷积核在输出特征图上进行滑动放置。放置的位置根据步长和填充来确定。在放置卷积核的过程中，将卷积核中的权重与输出特征图对应位置的元素进行相乘，并累加到输出特征图的相应位置上。具体来说，对于输入特征图中坐标为 (i, j) 的元素，其对应的卷积核在输出特征图上的放置位置为 $(s \times i - p, s \times j - p)$ 到 $(s \times i - p + k - 1, s \times j - p + k - 1)$ 。将卷积核与这个区域内的输出特征图元素进行乘法和累加操作。对输入特征图中的每个元素都执行上述步骤，直到所有元素都处理完毕，最终得到上采样后的输出特征图。

反卷积上采样能够在学习过程中自动学习到上采样的参数，相比于一些传统的上采样方法（如双线性插值），它可以更好地适应不同的图像特征和任务需求，生成更符合语义和结构的上采样结果。在处理具有复杂结构和语义信息的图像时，反卷积能够利用其学习能力，保留更多的细节和特征信息，减少上采样过程中的信息丢失和失真。

反卷积操作在计算过程中会引入一些“棋盘效应”，即输出特征图中会出现一些棋盘状的伪影。这是由于反卷积过程中对输入特征图的元素进行扩展和卷积操作时，某些位置的权重更新不均匀导致的。此外，反卷积的计算量相对较大，尤其是在处理高分辨率图像或深度神经网络中的大量特征图时，会增加模型的训练和推理时间。

3.最近邻插值

最近邻插值是一种较为简单的图像上采样技术，该方法基于最近邻的原理，将目标像素值设为距离该像素最近的源像素值。对于图像中的每个待插值点，在原始图像中找到距离它最近的像素点，然后将该最近像素点的灰度值或其他属性值赋给待插值点。可以将其理解为在原始图像的像素网格上，为每个新的上采样点找到离它最近的“邻居”像素，并复制该“邻居”的属性来确定新点的属性。计算步骤对于给定的原始图像和上采样的目标尺寸，首先确定原始图像和目标图像中像素点的坐标对应关系。例如，若原始图像大小为 $M \times N$ ，要将其放大到 $M' \times N'$ ，则计算坐标的映射关系，通常是根

(x', y') ，通过坐标映射公式找到其在原始图像中对应的坐标 (x, y) 。由于上采样时坐标可能不是整数，需要找到距离 (x, y) 最近的整数坐标点 (x_0, y_0) ，这个点就是 (x', y') 的最近邻点。将原始图像中最近邻点 (x_0, y_0) 的像素值赋给目标图像中的点 (x', y') 。重复这个过程，直到目标图像中的所有像素点都被赋值，从而完成上采样过程。

由于最近邻插值法计算量很小，算法简单，运算速度快，所以在一些对实时性要求较高的场景，如实时视频处理、游戏中的图形渲染等任务中，能够快速完成图像的上采样任务，满足实时性需求，且不会改变原始图像中像素的取值；对于一些离散数据或分类数据的图像，如二值图像、土地利用类型图等，能保持原始的类别信息不被改变。

但是，由于最近邻插值法仅使用离待测采样点最近的像素的灰度值作为该采样点的灰度值，没有考虑其他相邻像素点的影响，因而重新采样后图像质量损失较大，会产生明显的马赛克和锯齿现象，尤其是在图像的边缘和细节部分。插值精度不高，对于一些需要高精度处理的图像任务，如医学图像分析、卫星图像测绘等，可能无法满足要求。

2.3 单阶段目标检测算法

2.3.1 经典算法

RetinaNet 算法是一种高效的单阶段目标检测算法，在目标检测领域具有重要地位。在目标检测中，正负样本不均衡问题是影响模型性能的关键因素之一。传统的目标检测算法在处理大量负样本时，容易导致模型对负样本过度拟合，从而影响对正样本（即目标物体）的检测精度。RetinaNet 算法的提出主要是为了解决这一问题，通过设计新的损失函数和网络结构，提高模型对目标物体的检测能力。

RetinaNet 通常采用 ResNet 等经典的卷积神经网络作为骨干网络，其作用是对输入图像进行特征提取，得到具有丰富语义信息的特征图。例如，使用 ResNet-50 或 ResNet-101 等网络，可以有效地提取图像的底层和高层特征，为后续的目标检测提供基础。

在骨干网络的基础上，RetinaNet 采用 FPN 结构。FPN 的主要作用是融合不同尺度的特征信息，生成多尺度的特征金字塔。它通过自顶向下的路径和横向连接，将高层特征图的语义信息与低层特征图的细节信息相结合，使得模型能够在不同尺度的特征图上检测不同大小的目标物体。具体来说，FPN 从骨干网络的不同层中提取特征图，并通过上采样和融合操作，生成一系列具有不同分辨率和语义信息的特征图，形成特征金字塔。




图 2.12 ResNet 网络结构

Fig. 2.12 ResNet network structure

RetinaNet 有两个并行的检测头，分别用于分类和回归任务。分类头负责预测每个候选区域内物体的类别概率，回归头则负责预测物体的边界框坐标。这两个检测头都基于 FPN 生成的多尺度特征图进行操作，在每个特征图上的每个位置都预测多个不同大小和比例的边界框，即 **Anchor Boxes**。

RetinaNet 算法的核心创新点是焦点损失，它是一种针对类别不均衡问题的改进损失函数。传统的交叉熵损失在处理类别不均衡数据时，容易被大量的负样本主导，导致模型对正样本的关注不足。焦点损失通过在交叉熵损失函数的基础上，引入一个调制因子，来降低容易分类样本的权重，使得模型更加关注难分类的样本。具体来说，对于一个二分类问题，焦点损失的计算公式为：

$$FL(p_i) = -\alpha_i(1-p_i)^\gamma \log(p_i) \quad (2.16)$$

其中, p_i 是模型预测的概率, α_i 是平衡正负样本的权重因子, γ 是调制因子, 用于控制对容易分类样本的抑制程度。当 $\gamma=0$ 时, 焦点损失退化为传统的交叉熵损失。随着 γ 的增大, 容易分类样本的损失权重会逐渐降低, 模型会更加关注那些难以分类的样本。焦点损失有效地解决了目标检测中正负样本不均衡的问题, 使得模型在训练过程中能够更加专注于正样本和难分类的负样本, 从而提高了模型对目标物体的检测精度。通过调整 α 和 γ 的值, 可以根据不同的数据集和任务需求, 灵活地控制模型对正负样本的关注程度。

RetinaNet 算法通过 FPN 结构融合多尺度特征信息, 以及焦点损失函数解决正负样本不均衡问题, 在目标检测任务中取得了显著的性能提升, 为后续目标检测算法的发展提供了重要的借鉴和思路。

SDD (Single - Shot Object Detection) 系列算法是目标检测领域中的一类经典算法, 其核心思想旨在通过单次前向传播直接从图像中检测出目标物体, 同时预测物体的类别和位置, 属于单阶段目标检测算法。其设计理念是在保证检测精度的前提下, 尽可能提高检测速度, 以满足实时性要求较高的应用场景, 如视频监控、自动驾驶等。




图 2.13 VGG16 网络结构

Fig. 2.13 VGG16 network structure

SSD 算法以 VGG - 16 经典卷积神经网络作为基础骨干网络, 用于提取图像的特征。在骨干网络之后, 添加了多个不同尺度的卷积层来构建特征金字塔, 以适应不同大小目

标的检测。在每个尺度的特征图上，通过卷积操作同时预测目标的类别概率和边界框坐标。

算法核心组件：

(1) 多尺度特征图。SSD 利用不同层的特征图进行目标检测，这些特征图具有不同的分辨率和感受野。较浅层的特征图具有较高的分辨率，能够检测较小的目标；而较深层的特征图具有较大的感受野，适合检测较大的目标。通过这种多尺度特征融合的方式，SSD 能够有效地检测出各种大小的目标物体。

(2) 默认框 (Default Boxes)。也称为 Anchor Boxes，是 SSD 算法中的一个重要概念。在每个特征图的每个位置，都会预先定义一组不同大小和比例的默认框。这些默认框作为候选区域，模型通过调整默认框的位置和大小来匹配真实的目标物体。在训练过程中，根据默认框与真实标签的匹配情况来计算损失并更新模型参数。SSD 可以实现端到端检测，即直接将图像输入模型，经过一次前向传播即可得到检测结果，无需像两阶段目标检测算法那样先生成候选区域再进行分类和定位，大大提高了检测速度。

同时实现多尺度检测：通过构建特征金字塔和使用不同尺度的默认框，SSD 能够在多个尺度上对目标进行检测，对不同大小的目标具有较好的适应性。由于不需要复杂的候选区域生成和采样过程，SSD 的训练过程相对简单，收敛速度较快。

SDD 系列算法以其快速、高效的特点在目标检测领域占据重要地位，尤其是在实时性要求较高的应用场景中具有广泛的应用前景。尽管存在一些局限性，但随着技术的不断发展和改进，SDD 系列算法的性能也在不断提升，为目标检测技术的普及和应用提供了有力的支持。

2.3.2 YOLO 系列算法

YOLO (You Only Look Once) 系列算法是一系列用于目标检测的深度学习算法，具有速度快、精度高的特点，在计算机视觉领域得到了广泛应用。

YOLOv1 算法将输入图像划分为 $s \times s$ 的网格，每个网格负责检测中心落在该网格内的目标。对于每个网格，预测 B 个边界框以及这些边界框属于不同类别的概率。网络结构采用了类似 VGG 的卷积神经网络结构，由卷积层和全连接层组成。先通过卷积层提取图像特征，然后将特征图展平后连接全连接层进行目标类别和边界框的预测。

优点：将目标检测任务转化为一个回归问题，大大提高了检测速度，可以实现实时检测。而且它在训练和推理过程中只需要对图像进行一次处理，不像传统方法需要对图像进行大量的区域提议和特征提取操作。

缺点：由于每个网格只能预测 B 个边界框，对于密集分布的小目标检测效果不佳。同时，它对目标的空间信息编码能力有限，导致定位精度不高。

YOLOv2 改进措施：引入了批量归一化（Batch Normalization）技术，加快了网络的收敛速度，减少了对数据增强的依赖。采用了高分辨率分类器，在训练前期使用高分辨率图像进行预训练，使网络能够更好地适应高分辨率输入。提出了锚框（Anchor Boxes）机制，通过在每个网格上设置多个不同大小和比例的锚框，提高了对不同大小和形状目标的检测能力。性能提升：通过这些改进，YOLOv2 的检测精度得到了显著提高，同时保持了较快的检测速度。在一些基准数据集上，其性能优于当时的其他目标检测算法。

YOLOv3 网络结构改进：使用了 Darknet-53 作为基础网络结构，该结构包含了 53 个卷积层，能够提取更丰富的图像特征。采用了多尺度预测机制，在不同尺度的特征图上进行目标检测，从而能够更好地检测不同大小的目标。具体来说，它在网络的不同层次上分别输出三个不同尺度的特征图，每个尺度的特征图负责检测不同大小范围的目标。损失函数优化：改进了损失函数，对边界框的预测采用了更合适的指标，如交并比（IoU）等，使得模型在训练过程中能够更准确地学习到目标的位置信息。同时，对于不同类别的预测，采用了二元交叉熵损失函数，提高了分类的准确性。性能表现：YOLOv3 在检测精度和速度上都取得了很好的平衡，能够在多种数据集上达到较高的检测准确率，并且在实时性要求较高的场景中也能表现出色，如视频监控、自动驾驶等领域。

YOLOv4 训练技巧改进：引入了一些新的训练技巧，如 Mosaic 数据增强，将四张图像拼接在一起进行训练，增加了数据的多样性，提高了模型的鲁棒性。还采用了 Self-Adversarial Training（SAT）技术，让模型在训练过程中自己生成对抗样本，进一步提高模型的泛化能力。网络结构优化：对网络结构进行了进一步优化，提出了 CSPDarknet53 结构，通过跨阶段局部连接和特征融合，减少了计算量，提高了模型的运行速度。同时，在检测头部分采用了 PANet 结构，加强了不同尺度特征图之间的信息传递，提高了小目标的检测性能。性能优势：YOLOv4 在保持实时性的同时，进一步提高了检测精度，在 COCO 等数据集上取得了当时领先的成绩，成为了目标检测领域的重要算法之一。

YOLOv5 特点：YOLOv5 是一个轻量级的目标检测算法，具有较高的灵活性和可扩展性。它的代码结构简洁，易于理解和修改，方便研究人员和开发者根据自己的需求进行定制和优化。模型改进：在模型设计上，YOLOv5 采用了一种新的网络结构，包括 CSPNet、Focus 结构等，进一步提高了模型的性能和效率。同时，它还引入了一些新的技术，如自适应锚框计算、自适应图片缩放等，使得模型能够更好地适应不同大小和比例的输入图像，提高了检测的准确性和稳定性。应用场景：由于其轻量级和高效性，

YOLOv5 在移动设备和嵌入式设备上也有很好的表现，能够满足一些对实时性和资源限制要求较高的应用场景，如手机摄像头的目标检测、无人机视觉等。

YOLOv1-YOLOv5 系列算法以其高效的检测速度和不断提升的检测精度，在目标检测领域占据了重要地位，并在多个实际应用场景中发挥着关键作用。随着技术的不断发展，YOLO 算法也在持续改进和优化，为计算机视觉领域的发展提供了强大的支持。

YOLOv6 网络结构：YOLOv6 采用了高效的网络架构设计，主要包括 Backbone、Neck 和 Head 三个部分。其 Backbone 基于 RepVGG 风格，在推理阶段可以将多分支结构转换为单分支结构，从而提高推理速度。Neck 部分采用了 CSP（Cross Stage Partial）结构，加强了特征融合和传递。Head 部分则采用了改进的 Anchor-free 检测头，提高了检测的精度和速度。

训练策略：使用了多种数据增强技术，如 Mosaic、RandomAffine 等，增加数据的多样性，提高模型的泛化能力。在训练过程中，还采用了 EMA（Exponential Moving Average）技术来平滑模型的参数更新，使模型更加稳定收敛。同时，针对不同的硬件平台，YOLOv6 进行了专门的优化，如对 GPU 进行了 CUDA kernel 优化，对 ARM 平台进行了 NEON 指令优化等，以提高模型在不同设备上的运行效率。

性能特点：YOLOv6 在保持较高检测精度的同时，具有出色的推理速度。在 COCO 数据集上进行评估，其精度和速度都达到了较好的平衡，尤其在移动端和边缘设备上表现优异，能够满足实时性要求较高的目标检测任务，如安防监控、自动驾驶等场景中的应用。

YOLOv7 网络结构改进：提出了一种新的扩展策略，通过对网络的深度和宽度进行合理扩展，在不增加过多计算量的情况下提高模型的性能。同时，引入了 ELAN（Efficient Layer Aggregation Network）结构，进一步加强了特征的融合和传递，使模型能够更好地利用不同层次的特征信息。

训练优化：采用了新的损失函数，如 CIoU-Loss（Complete Intersection over Union Loss），能够更准确地衡量预测框与真实框之间的距离和相似度，提高了模型的定位精度。此外，还提出了一种新的训练技巧，即 Label Assignment for Auxiliary Head（LA-AH），通过为辅助头提供更合理的标签分配，提高了模型的训练效率和稳定性。

性能优势：YOLOv7 在各种基准数据集上都取得了显著的性能提升，无论是在精度还是速度方面都优于之前的 YOLO 系列算法。尤其是在面对复杂场景和小目标检测时，YOLOv7 表现出了更强的鲁棒性和准确性，在工业界和学术界都引起了广泛关注。

YOLOv8 主要特点：YOLOv8 是 Ultralytics 公司在 YOLO 系列算法基础上开发的新一代目标检测模型，它具有更加灵活的架构和更强大的性能。该模型采用了一种称为

“Anchor-free”的检测机制，摒弃了传统的锚框设计，简化了检测流程，提高了检测效率。同时，YOLOv8 引入了一种新的特征金字塔结构，能够更好地融合不同尺度的特征信息，增强了对不同大小目标的检测能力。

模型性能：YOLOv8 在多个公开数据集上进行了评估，如 COCO、VOC 等，其检测精度和速度都达到了当前先进水平。在保持实时性的前提下，YOLOv8 能够准确地检测出图像中的各种目标，对于小目标、密集目标以及遮挡目标等都有较好的检测效果。此外，YOLOv8 还支持多种输出格式，方便与其他系统进行集成和对接，具有较高的实用性和扩展性。

应用领域：由于其出色的性能，YOLOv8 在计算机视觉的多个领域得到了广泛应用。在安防监控领域，能够实时检测出监控画面中的人员、车辆等目标，并进行行为分析和预警；在自动驾驶领域，可用于检测道路上的车辆、行人、交通标志等，为车辆的行驶决策提供依据；在工业检测领域，能够快速检测出产品中的缺陷和异常，提高生产质量和效率。

YOLOv9 创新点：YOLOv9 进一步改进了网络结构，采用了一种更高效特征提取模块，能够在更少的计算量下提取更丰富的特征。同时，引入了一种新的注意力机制，能够自适应地关注图像中的重要区域，提高目标检测的准确性。在训练方法上，YOLOv9 采用了一种多模态数据融合的策略，将图像数据与其他模态的数据（如激光雷达数据、毫米波雷达数据等）进行融合，充分利用不同模态数据的互补信息，提高模型对复杂场景的理解和检测能力。

YOLOv10 网络架构优化：YOLOv10 对网络架构进行了深度优化，提出了一种新的分层特征融合结构，能够更有效地融合不同层次的特征信息，增强模型对目标的多尺度感知能力。同时，对网络的卷积层和池化层进行了改进，采用了一些更高效的卷积操作和池化策略，减少了模型的参数数量和计算量，提高了模型的运行效率。

检测性能提升：在检测性能方面，YOLOv10 通过引入一些新的技术和方法，如改进的目标定位算法、更精准的分类器等，进一步提高了目标检测的精度和召回率。在各种基准测试中，YOLOv10 在不同类型的目标检测任务中都表现出色，尤其在对小目标和密集目标的检测上取得了明显的突破，能够更准确地识别和定位这些具有挑战性的目标。

应用拓展：YOLOv10 的高效性和高性能使其在多个领域得到了广泛的应用拓展。除了传统的计算机视觉领域，如安防监控、自动驾驶、图像识别等，还在一些新兴领域，如无人机巡检、机器人视觉导航、智能物流等方面展现出了巨大的应用潜力。它能够为

这些领域中的目标检测任务提供准确、快速的解决方案，推动相关技术的发展和场景的拓展。

随着 YOLO 系列算法的不断发展，从 YOLOv6 到 YOLOv10，它们在网络结构、训练策略、性能表现等方面都取得了显著的进步，不断推动着目标检测技术各个领域的应用和发展。

2.3.3 YOLOv11 算法

YOLOv11 是 Ultralytics YOLO 系列实时目标检测算法的最新版本，于 2024 年 9 月 30 日发布。对比以往的 YOLO 系列模型，YOLOv11 在速度，准确性和效率上都取得了显著提升，YOLOv11 具体网络结构如图 2.14 所示。




图 2.14 YOLOv11n 网络结构

Fig. 2.14 YOLOv11n network structure

模型经历了一系列架构改进，并专注于在不牺牲准确率的情况下提升检测效率。YOLOv11 提出了新的 C3K2 模块以替换原有的 C2F 模块，其核心思想保留了 C2F 的 BottleNeck 残差连接和特征拼接思想，通过对定义的不同空间通道的输入特征进行卷积和拼接。C3K2 模块通常将输入特征分为两部分，一部分通过普通卷积操作直接传递，另一部分在 True 和 False 两种参数设置下分别通过 2 个和 1 个 C3K2 模块（同原 C2F 模块），再将两部分特征进行拼接，在不影响检测速度的情况下强化了模型的特征提取能力。由于采用了不同大小的卷积核，C3K2 模块在处理复杂场景时具有更大优势。

此外，YOLOv11 模型新增了 C2PSA 注意力机制，进一步增强了特征提取能力，其融合了 PSA（Pyramid Squeeze Attention）注意力机制和 CSP（Cross Stage Partial）结构，C2PSA 模块继承了 CSP 的分段特征处理思想，特征经过一次 1×1 卷积后被分成两部分，一部分直接传递，另一部分经过 PSA 注意力模块处理，然后将两部分特征拼接，并经过另一个 1×1 卷积来恢复原始通道数。通过 SE（Squeeze-and-Excitation）注意力机制为特征通道加权，提升多层次特征处理能力。最后，通过 Softmax 生成的注意力权重应用到各个特征图上，从而实现通道逐点加权，提升对重要特征的关注度。

在颈部网络中，YOLOv11 采用 PAN-FPN 结构，该结构可以实现多尺度特征的融合和增强。通过上下双向路径结合，确保从输入图像中提取的不同层次特征图能有效地在检测过程中发挥作用。综上，YOLOv11 目前展现出了优秀的目标检测性能，展现了其在各种计算机视觉任务中的强大潜力。

本章小结

本章详细介绍了改进路面裂缝和坑洞检测模型的理论基础，包括深度学习相关概念、卷积神经网络结构与原理、经典单阶段物体检测模型（RetinaNet、SDD、YOLO 系列算法），其中重点阐述了本文的改进对象 YOLOv11 模型的优势。

第三章 基于改进 YOLOv11n 算法的路面裂缝和坑洞检测

3.1 路面裂缝和坑洞检测模型选择及边缘设备部署可行性分析

单阶段物体检测模型将目标检测任务视为一个回归问题，直接在一次前向传播中预测物体的类别和位置，无需像双阶段检测模型那样先进行区域建议再分类，大大减少了计算量和处理时间，能满足实时性要求较高的应用场景；且单阶段检测模型的架构相对简洁，没有复杂的区域建议网络和后续的精调过程，这使得模型的训练和部署更加容易，降低了开发成本和难度，也方便在资源受限的设备上运行，如移动设备、嵌入式设备等。




图 3.1 改进的 YOLOv11n 网络结构

Fig. 3.1 Improved YOLOv11n network structure

YOLOv11 作为 YOLO 系列的最新版本,延续了轻量级的设计思路,采用 CSP 结构、Ghost 模块等优化,参数量和计算量进一步降低,模型性能与边缘设备适配性较高;路面病害检测需要同时识别细小裂缝(像素级特征)和坑洞(区域特征),对多尺度检测能力要求高,因此改进后模型检测精度与实时性的平衡性较好;路面图像受水渍、油污、阴影、车辆遮挡、路面标识线等背景干扰严重,且需构建包含不同场景(城市道路/高速公路/乡村道路)的数据集以评估模型鲁棒性,论文在考虑数据特性与模型泛化性的基础上对模型进行改进,改进后模型在路面裂缝和坑洞检测的边缘化部署具有较大可行性。

物体检测的关键是特征提取,对于 YOLOv11 模型而言,由于其简单高效的结构,在处理大规模图像数据时能够快速进行推理,能够在短时间内处理大量的图像,适用于对大量数据进行快速检测和分析的场景,如大规模图像数据集的标注、视频流中的目标检测等。且因其可以很容易地与其他技术或模块相结合,进行功能扩展和性能提升,例如,可以结合双层特征金字塔网络来提高对不同尺度物体的特征提取能力;或者引入注意力机制来增强模型对关键区域的关注,因此在路面裂缝和坑洞检测任务上具有先天优势。

本文考虑路面裂缝和坑洞检测任务中因场景复杂对检测易造成影响,对 YOLOv11n 模型进行改进。首先在原模型颈部网络的连接层引入 BiFPN 双向特征金字塔网络与 MCA 注意力机制,在保留了 PAN-FPN 结构多尺度特征融合和增强的能力基础上,进一步提高了模型对底层目标特征信息的提取能力和细节保留能力,增强了模型对小目标的关注度,能够更好地避免对细小裂缝漏检情况和检测不准确情况的发生;其次通过将 SimAM 注意力机制与原模型的 C3K2 模块进行融合,使模型能够聚焦目标区域关键特征,同时对模型抑制背景干扰的能力进行强化,使改进模型能够在复杂路面检测环境下对路面裂缝和坑洞进行精准识别。

3.2 考虑多尺度融合的路面裂缝和坑洞检测

3.2.1 双向特征金字塔网络

BiFPN (Bidirectional Feature Pyramid Network) 即双向特征金字塔网络,是一种用于目标检测的特征融合网络结构,在目标检测任务中,不同尺度的特征图对于检测不同大小的目标具有不同的作用。传统的特征金字塔网络(FPN)在特征融合时主要是自顶向下的单向传递,这种方式可能无法充分利用底层特征的丰富细节信息和高层特征的语义信息。BiFPN 的提出旨在改进特征融合方式,以更有效地融合不同层次的特征,提高目标检测的精度,尤其是对小目标的检测性能。BiFPN 接收来自不同骨干网络层的多个输入特征图,这些特征图具有不同的分辨率和语义信息。通常包括从底层到高层的多个

尺度的特征图，例如在一些实现中，会使用骨干网络中不同阶段的输出作为输入，这些输入特征图为后续的特征融合提供了丰富的信息来源。

与传统 FPN 不同，BiFPN 引入了双向连接。在自顶向下的路径中，高层特征图经过上采样后与底层特征图进行融合，以将高层的语义信息传递到底层；同时，在自底向上的路径中，底层特征图经过下采样后与高层特征图进行融合，使得底层的细节信息能够传播到高层。这种双向连接的方式有助于在不同尺度的特征图之间更充分地交换信息，从而更好地融合不同层次的特征。

在特征融合过程中，BiFPN 使用了可学习的权重来对不同来源的特征进行加权求和。每个输入特征在融合时都有对应的权重，这些权重通过网络的训练自动学习得到，能够自适应地调整不同特征的重要性，从而更灵活地融合特征。

首先，高层特征图通过上采样操作调整到与底层特征图相同的分辨率，然后与底层特征图进行融合。融合后的特征既包含了高层特征的语义信息，又融入了底层特征的细节信息。接着，融合后的特征再通过下采样操作回到高层特征图的分辨率，与下一层的高层特征图进行融合，以此类推，在双向路径中不断进行特征的传递和融合，使得不同尺度的特征图能够充分交互信息。

在每次特征融合时，可学习的权重会根据训练数据自动调整。通过反向传播算法，网络根据检测任务的损失函数来优化权重，使得模型能够根据具体的任务需求，为不同的特征分配合适的权重，从而提高特征融合的效果。例如，对于检测小目标，模型可能会自动增加底层特征的权重，因为底层特征包含更多的细节信息，有助于检测小目标的轮廓和纹理；而对于大目标，高层特征的权重可能会相对较高，因为高层特征具有更强的语义信息，能够更好地识别大目标的类别和整体结构。

BiFPN 通过双向连接和加权特征融合，能够更全面地融合不同层次的特征，充分利用底层特征的细节和高层特征的语义，提高了特征的质量和丰富度，从而有助于提升目标检测的精度，特别是对小目标的检测效果有明显改善。

在实现高效特征融合的同时，BiFPN 的结构相对简洁，通过合理的设计减少了模型的参数数量和计算量，避免了过多的计算开销，使得模型在保持高性能的同时具有较好的实时性，能够适应不同的计算平台和应用场景。

BiFPN 具有良好的可扩展性，可以方便地与不同的骨干网络和检测头相结合，形成不同规模和性能的目标检测模型，以满足各种不同任务和数据集的需求。无论是在小型数据集上进行快速检测，还是在大型复杂数据集上追求高精度检测，都可以通过调整 BiFPN 的结构和参数来实现。

3.2.2 MCA 多模态交叉注意力机制

MCA 注意力机制即多模态交叉注意力 (Multi-modal Cross Attention) 机制, 是一种在多模态数据处理中广泛应用的技术。MCA 注意力机制旨在有效地融合来自不同模态 (如视觉、语言等) 的信息, 通过学习不同模态之间的相互关系, 动态地分配注意力权重, 从而突出对任务更为重要的信息。以图像和文本模态为例, 它可以帮助模型在处理图像时, 根据文本信息来聚焦于图像中的相关区域; 在处理文本时, 也能依据图像内容来更好地理解文本的语义。

在 MCA 中, 不同模态的数据会被分别映射为查询、键和值。例如, 对于图像模态, 图像的特征向量可以作为查询, 而文本模态中相应的特征向量可以作为键和值。通过计算查询与键之间的相似度, 来确定值的权重, 从而实现对不同模态信息的选择性关注。

注意力权重计算: 通常使用一些相似性度量函数来计算查询与键之间的相似度, 如点积、余弦相似度等。然后通过 softmax 函数将相似度转换为概率分布, 得到注意力权重。这些权重表示了不同模态信息对于当前任务的重要程度。

MCA 注意力机制能够有效地捕捉不同模态之间的语义关联, 促进模态间的信息流动和融合, 使模型对多模态数据的理解更加深入和全面。通过动态地分配注意力权重, 模型可以更加关注与任务相关的信息, 抑制无关信息的干扰, 从而提高在各种多模态任务上的性能表现。然而需要注意的是, 随着模态数量的增加和数据维度的增大, 计算注意力权重的复杂度也会显著提高, 可能导致模型训练和推理速度变慢, 需要消耗更多的计算资源; 此外, 不同模态的数据在特征空间和语义表示上存在差异, 如何准确地对齐和关联这些不同模态的信息是一个挑战。如果模态对齐不准确, 可能会影响注意力机制的效果, 进而降低模型的性能。

3.2.3 设计 BMFPN 模块

当前 YOLOv11n 使用的 PAN-FPN 结构可以实现多尺度特征的融合和增强。通过上下双向路径结合, 确保从输入图像中提取的不同层次特征图能有效地在检测过程中发挥作用。然而, 在特征融合过程中, 存在多次上、下采样过程中容易产生重复特征, 并增加了模型的计算开销的问题。已经引入了一些有效的轻量级网络模型, 如 BiFPN, 通过简化特征融合网络的结构减少计算开销。然而, BiFPN 仍存在上下文信息捕捉能力不足的问题, 这使得 BiFPN 容易受到背景噪声的干扰。同时 BiFPN 存在细粒度特征的选择性不强的问题。这在复杂背景的路面裂缝和坑洞检测任务中会导致特征表达不足。

在路面裂缝和坑洞检测任务中, 考虑到裂缝与坑洞具有多尺度特性, 且部分较小裂缝与坑洞易被漏检的问题, 本文对 YOLOv11n 颈部网络进行了优化。一种新的 BMFPN

结构被设计应用于 YOLOv11 中。该结构的核心思想是通过动态优化多尺度特征处理，增强目标区分和上下文感知能力，同时保持轻量化和高效计算，提升对路面裂缝检测精度和模型鲁棒性。

具体来说，BMFPN 实现步骤如图 3.2、图 3.3 所示：




图 3.2 FPN+PAN 原理

Fig. 3.2 FPN+PAN principle




图 3.3 BMFPN 原理

Fig. 3.3 BMFPN principle

BMFPN 对于只有一条输入路径的要素图，不进行其他处理。通常，这样的特征对特征工程的贡献很小。对于具有两个输入路径的特征图，如果特征图的大小相同，则从主干中的特征添加一个附加路径，并融合 PAN 中的特征。这样的处理方法不增加额外

的参数成本。**OR**：（通过将每个双向路径（自顶向下和自底向上）处理为一个特征网络层。并通过加权特征融合对不同特征进行差分融合，从而学习不同输入特征的重要性，以提高处理路径上更高层次的特征融合。）

此外，在传统的特征金字塔网络中，所有输入特征通常在没有区分的情况下等同对待。这意味着不同分辨率的特征被简单地相加在一起，而不考虑它们对输出特征的不同贡献。然而在 **BMFPN** 中，由于不同的输入特征具有不同的分辨率，它们通常对输出特征的贡献是不等的。为了优化使用不同的输入特征，**BMFPN** 实现了一种快速归一化方法，用于改进特征融合效果。为每个通道分配唯一的权重。其定义如式 3.1 所示。

$$c = \sum_i \frac{w_i}{\sum_j w_j + \varepsilon} I_i \quad (3.1)$$

这里， c 表示输出， I_i 是节点的输入， w_j 是输入节点的累积权重。这些权重是可学习的。为了保持数值稳定性，学习率被设置为 $e = 0.0001$ 的最小阈值。最后，将每个双向（顶部-底部和底部-顶部）路径视为一个单元，并多次重用该单元以改进混合。

以第 i 层为例，**BMFPN** 的两个融合特征公式如式 3.2、式 3.3 所示：

$$P_i^{td} = \text{Conv} \left(\frac{w_1 P_i^{in} + w_2 P_{i+1}^{in}}{w_1 + w_2 + \varepsilon} \right) \quad (3.2)$$

$$P_i^{out} = \text{Conv} \left(\frac{w_1 P_i^{in} + w_2 P_i^{td} + w_3 P_{i-1}^{out}}{w_1 + w_2 + w_3 + \varepsilon} \right) \quad (3.3)$$

为了进一步增强上下文信息的捕捉能力和特征选择性，**BMFPN** 结构还融合了 **MCA** 多模态交叉注意力机制：在路径上使用一个测量 $C \times H \times W$ 的特征张量 F 作为输入，并输出具有与 F 相同大小的经处理的特征张量 F' ，如图 3.4 所示




图 3.4 MCA 结构图

Fig. 3.4 MCA structure diagram

这个过程分为两个步骤，一个是协调注意的嵌入，另一个是协调注意的生成。首先，需要对输入向量 F 进行全局池化以获得全局特征信息。本结构将输入的图像沿着水平和

垂直两个空间方向的通道进行编码，同时对其进行全局池化操作，得到两个一维向量，即高度和重量两个方向的特征，为后期获取全局特征和保留坐标信息创造条件。将 F_1 作为卷积算子，因此在高度处第 c 个通道的编码可以通过式 3.4 来描述：

$$z_c^h(h) = F_1(f_c) = \frac{1}{W} \sum_{0 < n < W} f_c(h, n) \quad (3.4)$$

类似的，可以根据式 3.5 来定义第 c 个通道在权重 w 处的编码：

$$z_c^w(w) = F_1(f_c) = \frac{1}{H} \sum_{0 < m < H} f_c(m, w) \quad (3.5)$$

变换使注意力集中在沿着水平空间方向的长距离特征上，同时保留垂直空间方向上的坐标信息。然后将从全局感受野获得的两个特征图连接起来，并送入 1×1 卷积算子。本文将 F_2 作为 1×1 卷积算子，将 R 作为非线性激活函数，然后得到：

$$Z = R(F_2([z^h, z^w])) \quad (3.6)$$

在式 3.6 中， $[Z^h, Z^w]$ 表示拼接后特征张量， Z 是具有水平和垂直方向上的特征信息的中间特征图。然后将 Z 在水平和垂直方向上分成两个特征张量 Z^h 和 Z^w ，并使用两个 1×1 卷积算子将 Z^h 和 Z^w 分别变换成与输入特征图 F 在水平和垂直方向上大小相同的两个张量。它们被发送到 sigmoid 激活函数中，该函数可以表示为式 3.7，3.8。

$$y^h = \sigma(F_h(Z^h)) \quad (3.7)$$

$$y^w = \sigma(F_w(Z^w)) \quad (3.8)$$

σ 表示 sigmoid 函数。最后，我们在两个空间方向上连接这些特征张量，以获得通道特征的注意力权重，并将其视为输出特征图 F' 。整个计算可以用式 3.9 总结：

$$F'_c(n, m) = f_c(n, m) y_c^h(n) y_c^w(m) \quad (3.9)$$

这样，注意力模块不仅获得了通道信息，而且还考虑了位置信息，这使得模型能够更好地定位和检测对象，提高对于多尺度路面裂缝和坑洞的检测性能。

3.3 考虑背景抑制与模型轻量化的路面裂缝和坑洞检测

3.3.1 C3K2 模块

C3K2 模块是基于传统 C3 模块的改进设计，是带有 2 个卷积操作的加速版 CSP Bottleneck 模块，并且可以选择性地使用 C3K 块。它将输入特征分为两部分，一部分通过普通的卷积操作直接传递，另一部分则通过多个 C3K（当 C3K 参数设置为 True 时）或 Bottleneck 结构进行深度特征提取，最终两部分特征进行拼接，并通过 1×1 卷积进行融合。

C3K2 引入了多尺度的卷积核 C3K, K 为可调整的卷积核大小, 如 3x3、5x5 等。这种设计可以扩展感受野, 使模型能够捕捉更广泛的上下文信息, 尤其适合大物体检测或背景复杂的场景。

C3K2 模块在处理复杂场景时能显著提高特征提取的精度, 特别是在物体边界和复杂背景中的检测能力方面, 相比标准 C3 模块和 YOLOv8 的 C2F 模块, C3K2 在保持轻量化的同时, 有效提高了深层次特征提取能力, 通过更高效特征提取和融合方式, 提升了模型对各种目标的检测性能。




图 3.5 C3K2 结构图

Fig. 3.5 C3K2 structure diagram

C3K2 模块结构组成:

1. 输入特征分流

将输入的特征图分为两部分。一部分通过普通的卷积操作直接传递, 另一部分则进入后续的核心处理模块进行深度特征提取。

2. 核心处理模块

C3K 块 (可选): 当 C3K 参数设置为 True 时, 会采用 C3K 块。C3K 中的“K”代表可调整的卷积核大小, 例如可以是 3x3、5x5 等。这种可变卷积核的设计使得模型能够

扩展感受野，从而捕捉更广泛的上下文信息，对于大物体检测或者背景复杂的场景有很好的适应性。

Bottleneck 结构：在不使用 C3k 块时，会采用传统的 Bottleneck 结构。Bottleneck 结构通过 1×1 卷积先降低特征图的通道数，减少计算量，然后使用 3×3 卷积进行特征提取，最后再通过 1×1 卷积恢复通道数，以实现高效的特征提取。




图 3.6 Bottleneck 结构图

Fig. 3.6 Bottleneck structure diagram

3. 特征融合

经过不同处理路径的两部分特征会进行拼接操作，将不同层次和不同尺度的特征信息进行整合。拼接后的特征图会通过一个 1×1 卷积进行融合，进一步调整通道数，输出最终的特征图。

通过可变卷积核的 C3k 块以及 Bottleneck 结构的组合，能够提取不同尺度和层次的特征信息，对复杂场景下的目标有更好的感知能力，特别是在物体边界和复杂背景中的检测能力方面表现出色。在提高特征提取能力的同时，通过合理的通道调整和计算优化，保持了模型的轻量化，不会显著增加模型的计算量和参数量，有助于在不同硬件设备上实现高效推理。可以根据具体的任务需求和数据集特点，灵活调整是否使用 C3k 块以及卷积核的大小，以适应不同的检测场景。

3.3.2 SimAM 注意力模块

SimAM(Similarity - Aware Activation Module)相似性感知激活模块,是一个概念简单但对卷积神经网络非常有效的注意力模块。其设计灵感来自神经科学中的“空间抑制”理论。在神经科学中,信息丰富的神经元通常表现出与周围神经元不同的放电模式,激活神经元通常会抑制周围神经元,即空域抑制。SimAM 基于此提出通过优化能量函数来查找每个神经元的重要性,以让网络学习到更具区分性的神经元。能量函数与解析解:针对每个神经元定义能量函数,该函数通过比较一个目标神经元与其周围神经元的线性可分性,来衡量该神经元的“显著性”。理论上每个通道会有多个这样的能量函数,若用梯度下降算法求解计算开销大。但该能量函数的 w_i 和 b_i 都可以快速求得解析解,且可以在所有神经元上计算均值和方差,同一通道上的所有神经元都可以复用这个均值和方差,大大减少计算开销。最终每个位置的最小能量可通过特定公式得到,能量越低,神经元和周围神经元的区别越大,在视觉处理中也越重要,通过 $1/e \times t$ 来表示每个神经元的重要性。

不同于现有的仅在通道或空间维度上应用的注意力模块,SimAM 模块直接推断出特征图中的三维权重,结合空间和通道维度进行精确调整,提供了更细粒度的注意力机制,这种方法提高了网络在图像中捕捉相关区域的能力。SimAM 模块无需引入额外的参数,相比其他注意力模块(如 SE、CBAM),该模块通过优化能量函数直接计算权重,从而减少了结构调整和计算的复杂性,保持了模型的轻量化。

由于有能量函数的快速闭合解,简化了计算过程,并能够在少于 10 行代码中实现整个模块,使其适用于各种卷积神经网络,且计算效率高,能保持较快的推理速度。在多个数据集(如 CIFAR、ImageNet 等)上的实验结果表明,SimAM 在不同网络架构上表现非常接近甚至优于其他注意力模块,特别是在小型网络上具有竞争优势。同时,由于其无参数、轻量化和高效性的特点,非常适用于移动设备或边缘计算等对模型高效性有要求的场景。

3.3.3 设计 SMC3K2 模块

路面裂缝和坑洞检测任务中多存在外部干扰因素,如其他路面特征干扰:车辙、水渍、油污、杂物等会掩盖裂缝与坑洞,或者与裂缝和坑洞的特征相似,干扰检测算法的判断,导致误判或漏判,因此抑制背景干扰即成为了路面裂缝检测任务中的关键技术目标,然而注意力机制与多尺度特征融合的方法常会增大模型参数量,增加计算路径,不利于模型的轻量化与高效化,所以在保留模型轻量化与高效化优势的同时增强对任务目标的特征提取能力是路面裂缝和坑洞检测任务中的重难点。

注意力模块可以通过为特征图分配不同的权重来增强对关键区域的关注。在 Neck 层中，YOLOv11 的注意力机制通常在通道或空间维度中生成相应的 1-D 或 2-D 权重。例如 BAM 以及 CBAM。然而，在生成过程中，它们平等地对待每个通道或空间位置中的神经元。这种局限性限制了他们学习更多区分性线索的能力。同时，在 Neck 层中的 C3K2 模块采用部分特征跳过卷积的策略，在减少计算复杂度的同时，保留了较强的特征表达能力。然而，Neck 层中的 C3K2 模块还存在缺乏对关键特征的选择性的问题。这使得在处理复杂背景和细节信息时无法有效地区分目标和无关背景，导致检测精度受限。

因此，本文设计了一种 SMC3K2 模块，实现 Neck 层的自适应注意力增强以及特征选择性提升。SMC3K2 的核心思想是引入 SimAM 自适应注意力机制。它利用局部空间特征的自适应调节，增强 C3K2 模块的信息选择性。模型可以精准聚焦于目标区域的关键特征，并抑制背景干扰。同时，保留了 C3K2 模块的跨层特征融合能力和计算效率，如图 3.5 所示。




图 3.7 权重注意力模块结构图

Fig. 3.7 Weight Attention Module Structure Diagram

该结构是一个统一的权重注意力模块，可以在不需要额外参数的情况下导出特征图的 3-D 注意力权重。在视觉神经科学中，信息量最大的神经元通常表现出与周围神经元不同的放电模式，并且活跃的神经元倾向于抑制周围的神经元。受此启发，SMC3K2 模

块设计了一个能量函数来衡量神经元之间的线性可分性，从而识别重要的神经元。能量函数定义如下：

$$e_t(w_t, b_t, y, x_i) = \frac{1}{M-1} \sum_{i=1}^{M-1} (-1 - (cx_i + b_t))^2 + (1 - (w_t t + b_t))^2 + \lambda w_t^2 \quad (3.9)$$

其中 t 表示目标神经元， x_i 表示输入特征 $x \in R^{HWC}$ 的单个通道中的其他神经元， i 是空间维度上的索引， M 是神经元的数量。 w_t 和 b_t 是对变换的加权和偏置。随后通过计算变量 w_t 和 b_t 的封闭形式解，并将它们代入式 3.9，最小能量可以如下获得：

$$e_t^* = \frac{4(\hat{\sigma}^2 + \lambda)}{(t - \hat{\mu})^2 + 2\hat{\mu}^2 + 2\lambda} \quad (3.10)$$

式 3.10 中的表达式指示较小的能量值对应于神经元 t 与其他神经元之间的较大的线性可分性，这表示较高的重要性。根据注意力机制的定义，SMC3K2 模块可以表示如下：

$$\tilde{X} = \text{sigmoid}\left(\frac{1}{E}\right) \otimes X \quad (3.11)$$

其中， E 是在信道和空间维度上的所有能量函数 $e \in t$ 的分类函数。sigmoid 函数确保 E 中的较大值受到约束，从而不会影响每个神经元的相对重要性。我们将 SMC3K2 模块集成到 YOLOv11 模型的 Neck 部分，这有助于模型更好地关注目标，而无需引入额外的参数。

本章小结

本章重点介绍了改进 YOLOv11n 模型的原理与方法。考虑路面裂缝和坑洞存在的多尺度特点，以及检测中遇到的背景干扰的问题，本章基于 BiFPN 双层特征金字塔网络和 MCA 多尺度交叉注意力机制，设计一种新的 BMFPN 结构；并融合 SimAM 注意力机制与 YOLOv11 颈部网络的 C3K2 模块，设计一种新的 SMC3K2 结构，对 YOLOv11n 路面裂缝和坑洞检测模型进行了改进。

第四章 改进 YOLOv11 目标检测算法的实验结果与分析

为了验证改进的 YOLOv11n 路面裂缝检测模型的检测性能与改进方法的有效性,对模型进行基线实验、改进模块消融实验以及与经典目标检测算法的对比试验。通过实验可以得出改进后的模型相较于原模型在检测精度,召回率方面具有明显提升;设计的 BMFPN 结构与 SMC3K2 模块均对改进模型的性能提升起到显著作用;改进模型相较于 Faster-RCNN、SDD、YOLOv3、YOLOv5、YOLOv7 这些经典目标检测模型在检测效果上均有明显优势。

4.1 路面裂缝和坑洞数据集

4.1.1 自制数据集

研究通过实地相机拍摄的方法在大连市黄河路、西安路、西南路、沿河街、富国街、北港桥、黄河桥、星海湾大桥、春柳隧道、石门山隧道、白云隧道、莲花山隧道路段收集共计 2054 张路面裂缝和坑洞图片,通过 Labelme 软件对路面裂缝和坑洞进行标注,标签分别为 D00(纵向裂缝)、D10(横向裂缝)、D20(网状裂缝)和 D40(坑洼),形成路面裂缝和坑洞自制数据集。




图 4.1 路面裂缝标注图

Fig. 4.1 Pavement crack marking diagram

4.1.2 RDD2022 数据集

RDD2022 (Road Defect Detection 2022) [66]是一个用于道路瑕疵检测的多国家图像数据集,不同国家采用了不同的设备和方式来采集图像。印度、日本和捷克使用安装在车辆上的智能手机采集图像,其中日本和捷克采集的图像分辨率为 600×600 ,印度图像初始分辨率为 960×720 ,后调整为 720×720 。挪威使用安装在专用车辆挡风玻璃内的高分辨率相机采集数据,通过两个 Basler_ace 2040 gc 相机搭配 CMOS 传感器采集图像,并拼接成 3650×2044 的宽视角图像。美国的数据来自谷歌街景图像,分辨率为 640×640 。

中国的数据则通过两种方式采集,一是由摩托车上装置智能手机拍摄 (China_M),二是由无人机搭载摄像头拍摄 (China_D)。日本的数据来自七个地方政府所在区域,包括城市和多雪地区;印度的数据涵盖了当地道路、州际公路和国家公路,包括大都市地区和非大都市地区;捷克的大部分图像在奥洛穆茨、布拉格和布拉迪斯拉发的城市中采集,涵盖了不同等级的道路,还有一小部分来自高速公路;挪威的数据包括高速公路和县级公路,由挪威公共道路管理局和内陆郡政府负责采集;美国的数据来自加利福尼亚、马萨诸塞和纽约等多个地点的谷歌街景图像;中国的 China_Drone 图像取自南京的东吉大道,China_Motorbike 图像采集于东南大学九龙湖校区。

数据集共包含 47,420 张道路图像。图像标注有超过 55,000 个道路损坏实例,包含四种裂缝,分别是 D00 (纵向裂缝)、D10 (横向裂缝)、D20 (网状裂缝) 和 D40 (坑洞)。标注格式有 PAS_VOC 格式和 YOLO 格式,方便不同的目标检测框架使用。



图 4.2 纵向裂缝图

Fig. 4.2 Longitudinal cracks




图 4.3 横向裂缝

Fig.4.3 Cross-sectional cracks



图 4.4 网状裂缝图

Fig. 4.4 Mesh cracks



图 4.5 坑洞

Fig. 4.5 Pothole

为了验证模型的泛化性，实验使用路面裂缝和坑洞数据集共由两部分组成，一部分为 RDD-2022 Chine-Drone 部分中选出的 3000 张包含三种路面裂缝和坑洞的数据集，另一部分为自制数据集，最终得到共 5054 张数据集图片。将实验数据集以 7:2:1 的比例作为训练集，测试集和验证集，在本章进行 YOLOv11 基线实验和替换 BMFPN 的实验，以及替换 BMFPN 并融合 SMC3K2 的改进的 YOLOv11 实验。实验采用的道路裂缝和坑洞数据集中含有大量且复杂的路面裂缝及背景，为模型改进效果提供了可靠的数据支持。数据集数据如表 4.1。

表 4.1 路面裂缝和坑洞数据

Table 4.1 Pavement crack and pothole data

类别	图像（张）	裂缝和坑洞（个）
D00	2994	5978
D10	1684	3441
D20	982	1630
D40	563	1088

4.2 实验环境与参数配置

得益于 GPU 强大的并行处理能力与深度算力，深度学习模型的训练条件得到了优化，论文选择高性能的硬件配置为模型提供高效的运行平台。在 Linux 操作系统中，使

用 Intel Xeon CPU E5-2680 v3、配备 24 GB VRAM 的 NVIDIA GeForce RTX 4090 GPU、PyTorch 框架版本 1.7.0 和 Python 版本 3.8 进行了实验。实验硬件配置参数如下：

表 4.2 硬件配置表

Table 4.2 Hardware configuration table

名称	参数
操作系统	Linux
处理器	Intel Xeon CPU E5-2680 v3
显卡	NVIDIA GeForce RTX 4090
Python	3.8
PyTorch	1.7.0

为了得到优秀的检测效率和效果，论文结合实际路面裂缝检测任务与实验数据集，通过调整训练参数以确定实验参数配置。本研究实验参数设定如下：初始学习率（Learning Rate）0.01，迭代次数（Epoch）150，训练批次大小（batch Size）32，学习率权重衰减 0.0005，学习率动量（momentum）0.937，参数配置表见表 4.3。

表 4.3 参数配置表

Table 4.3 Parameter configuration table

参数	数值
运行迭代次数（Epoch）	150
初始学习率（Lr）	0.01
训练批次大小（batch Size）	32
学习率权重衰减	0.0005
学习率动量（momentum）	0.937

4.3 实验评价指标

在目标检测任务中，检测结果一般包含四种情况，分别为 TP（True Positive，真正例）、FP（False Positive，假正例）、TN（True Negative，真负例）和 FN（False Negative，假负例）。TP 指的是模型正确地预测了正确的检测目标，即检测结果与实际结果皆为正例；FP 指的是模型错误地预测了错误的检测目标，即实际结果为负例，但检测结果为正例；TN 表示的是模型正确地预测了错误的检测目标，即检测结果与实际结果皆为负例，TN 同 TP 一样，代表模型的预测是正确的；FN 则代表的是模型错误地预测了正

确的检测目标，即实际结果为正例，但检测结果为负例，同理，FN 与 FP 则是模型预测错误的两种结果。为了准确、清晰、直观地展示出改进后的 YOLOv11 模型的检测效果，

本文采用精确率（Precision, P）、召回率（Recall, R）、调和平均数（F1 Score）、平均精度均值（mean Average Precision, mAP）作为实验评价指标。

精确率 P 是真正例同真正例与假正例之和的比值，代表了检测目标在检测过程中被正确检测的比例， P 越高，则代表检测的正确率越高，当 $P=100\%$ 时，说明所有检测结果均正确。 P 的计算公式为：

$$P = \frac{TP}{TP + FP} \quad (4.1)$$

召回率 R 是真正例同真正例与假负例之和的比值。代表着模型准确预测检测目标，排除背景干扰的能力。当 $R=100\%$ 时，说明所有真正例全部被检测出来。 R 的计算公式为：

$$R = \frac{TP}{TP + FN} \quad (4.2)$$

调和平均数 $F1\ Score$ 是基于精确率 P 和召回率 R 的综合参数，能够作为模型检测准确性的评价指标， $F1\ Score$ 的计算公式如下：

$$F1 = \frac{2 * P * R}{P + R} \quad (4.3)$$

平均精度均值 AP 同样是基于精确率 P 和召回率 R 的综合参数，其数据是 P-R（Precision-Recall）曲线与横纵坐标轴围成的面积的值，可以作为衡量模型检测精度的评价指标， AP 的计算公式如下：

$$AP = \int_0^1 (P * R) dR \quad (4.4)$$

平均精度均值 mAP 是 AP 的平均值，可进一步辅助评价模型的检测精度， mAP 的计算公式如下：

$$mAP = \frac{\sum (AP)}{n} \quad (4.5)$$

4.4 实验结果

4.4.1 模型训练

在搭载好的实验平台和训练环境下对改进后的模型进行训练。损失函数通过计算模型预测结果与真实结果之间的差异，提供了一种量化评估模型性能的方式。较小的损失值表示模型的预测结果与真实结果更接近，说明模型的性能较好；反之，较大的损失值则意味着模型的预测误差较大，性能有待提高。改进模型损失函数曲线如图 4.6。




图 4.6 损失函数曲线

Fig. 4.6 Loss function curve

改进后的 YOLOv11n 模型在经历 140 轮迭代后损失值趋近于 0.002，说明改进模型的参数配置合理、检测结果损失值较小、检测真实性和准确性较好；在迭代过程中损失函数呈快速下降趋势，可见模型在训练过程中进行了有效学习与优化，训练效果理想。

4.4.2 实验结果

本文的 YOLOv11n 检测模型在路面裂缝检测任务上展现出了较好的检测性能，总体裂缝检测精确率为 58.3%、召回率为 51.3%、 $F1$ 为 0.546， mAP 为 54.6%；具体检测结果如表 4.4 所示。

表 4.4 路面裂缝和坑洞检测结果

Table 4.4 Pavement crack and pothole detection results

类别	精确率(%)	召回率(%)	F1 (%)	mAP (%)	mAP@0.5: 0.95 (%)
全部	58.3	51.3	0.546	54.6	29.2
D00	51.5	55.2	0.533	51.5	25.6
D10	62.4	56.4	0.592	59.7	28.9
D20	66.5	59.6	0.629	64.6	40.6
D40	52.9	34.0	0.414	42.4	21.5

混淆矩阵在评估分类模型性能方面具有重要作用，能够直观展示模型的预测性能，以矩阵形式将模型的预测结果与实际标签进行对比，清晰呈现每个类别的预测情况，包括正确预测和错误预测的数量。




图 4.7 混淆矩阵

Fig. 4.7 Confusion matrix

对于二分类问题，通过真阳性（TP）、假阴性（FN）、假阳性（FP）、真阴性（TN）四个指标来描述；对于多分类问题，矩阵的行表示实际类别，列表示预测类别，矩阵中的每个元素表示模型在对应类别上的预测结果，改进模型混淆矩阵如图 4.7。由图可知，模型对不同种类的裂缝预测准确性较高、置信度较高，模型总体预测性能较好。

PR 曲线即精确率 - 召回率曲线，在深度学习模型评估中能够直观展示精确率和召回率的权衡，PR 曲线中的每个点对应模型在某个特定决策阈值下的精确率和召回率，通过曲线可以直观地看到在不同阈值下，精确率和召回率的变化情况；PR 曲线可以清晰呈现模型对正类样本的处理能力，通过比较不同模型的 PR 曲线可以评估它们的性能优劣，如果一个模型的 PR 曲线完全包住另一个模型的曲线，那么可断言前者的性能优于后者；此外，还可以通过计算 PR 曲线下的面积即 AP 值来量化模型的性能， AP 值越大，说明模型性能越好，改进模型 PR 曲线如图 4.8。




图 4.8 PR 曲线

Fig. 4.8 PR curve

F1-score 曲线展示了在不同阈值下 $F1$ 分数的变化情况。通过观察曲线，能直观了解模型在不同决策阈值下的综合性能，本文改进模型 F1-score 曲线如图 4.9， $F1$ -score 最高分数为 0.546。




图 4.9 F1-score 曲线

Fig. 4.9 F1-score curve

4.4.3 检测效果可视化

图 4.10-4.13 为路面裂缝和坑洞检测模型检测效果可视化展示，左侧为原 YOLOv11n 模型检测效果图，右侧为本文改进的模型检测效果图。可以看出，对于不同角度下的路面裂缝和坑洞识别，改进后的模型展现出了理想的检测效果。面对不同种类的路面裂缝检测、不同的检测视角，复杂的背景干扰，改进后的模型均展现出了更强的检测能力。

如图 4.10，改进后的模型更为精确地检测了宽阔路面上的细小纵向裂缝，由此可见 BMFPN 模块成功弥补了 BiFPN 存在对细粒度特征的选择性不强的问题，提高了对于细小裂缝的检测精度。



图 4.10 纵向裂缝检测效果图

Fig. 4.10 Longitudinal crack detection effect diagram



图 4.11 横向裂缝检测效果图

Fig. 4.11 Horizontal crack detection effect diagram

如图 4.11，原模型对于航拍视角下的路面横向裂缝存在检测不完全的现象，而改进后的模型不仅完整识别了裂缝，有效减少了漏检的发生，并且精度也较原模型从 0.33 提高到 0.64。



图 4.12 网状裂缝检测效果图

Fig. 4.12 Mesh crack detection effect diagram

如图 4.12，原模型对于复杂的路面网状裂缝出现了错误检测的情况，将与网状裂缝相似的路肩识别成了任务目标，而改进后的模型在斑马线与网状裂缝交错并紧邻路肩的检测环境下排除背景干扰的能力明显提高，对于路肩旁的大面积路面网状裂缝识别效果更为理想，对于画面上方的细小路面龟裂也能完成准确检测，检测精度也较原模型从 0.44 提高到了 0.78。由此可见融合了 MCA 注意力机制的多尺度特征融合改进方法有效提升了模型对于不同尺度裂缝的检测能力，且改进的 SMC3K2 有效提高了模型聚焦目标区域关键特征，抑制背景干扰的能力。




图 4.13 坑洞检测效果图

Fig. 4.13 Pothole detection renderings

如图 4.13，原模型对于大背景下单一小目标的检测精度较低。相比之下，改进后的模型精确率提高了 0.13，能够在这种高挑战性的场景下，更为精确地检测出面积较小的路面坑洼，再次验证了创新模块对于模型完成路面裂缝和坑洼检测任务的显著贡献。

4.4.4 改进点消融实验

为验证不同改进模块对改进后模型性能的贡献,论文通过 PyTorch 搭建神将网络模型,在 RDD-2022Chine-Drone 数据集上进行训练,通过逐步添加模块的方法进行消融实验,实验记录了各阶段模型的精确率、召回率、F1 Score, mAP 等参数以量化各改进模块的改进效果。实验步骤如下:首先将 YOLOv11 主干网络中的 Concat 层替换为提出的 BMFPN 结构;然后将 C3k2 模块替换为提出的 SMC3k2 模块。消融实验结果见表 4.5。

表 4.5 消融实验数据表

Table 4.5 Ablation experiment data sheet

Baseline	BMFPN	SMC3K2	精确率(%)	召回率(%)	F1 (%)	mAP (%)	mAP@0.5: 0.95 (%)
√			54.0	44.0	48.5	44.1	21.1
√	√		57.9	50.9	54.2	52.8	28.4
√	√	√	58.3	51.3	54.6	54.6	29.2

实验结果表明,各改进模块均有效提升了模型的检测性能。将 Concat 层替换为 BMFPN 模块后,模型精确率提高了 3.6%、召回率提高了 6.9%、mAP 提高了 8.7%, mAP@0.5:0.95 提高了 7.3%,这表明 BMFPN 模块有效解决了 PAN-FPN 上下文信息捕捉能力不足,容易受到背景噪声干扰的问题。

用 SMC3K2 模块替换掉原 C3K2 模块时,模型精确率提高了 0.4%、召回率提高了 0.4%、mAP 增加了 1.8%, mAP@0.5:0.95 增加了 0.8%。这表明改进的 SMC3K2 模块不仅成功抑制了背景干扰。同时,保留了 C3K2 模块的跨层特征融合能力和计算效率,有效强化了模型的特征提取能力。

4.4.5 对比实验

为了验证本文改进的模型检测性能,进行改进 YOLOv11 模型与两阶段经典目标检测模型 Faster-CNN,单阶段经典目标检测模型 SDD 以及 YOLOv3、YOLOv5、YOLOv7、YOLOv9, RTMDet 的对比试验。表 4.6 展示了上述流行算法在路面裂缝和坑洞检测数据集上的检测结果。可以看出,改进后的算法在检测性能上位于前列。其精确率与召回率分别达到了 58.3%和 51.3%;F1 达到了 54.6%;mAP 和 mAP@0.5:0.95 分别达到了 54.6%和 29.2%,在各项指标上均优于 YOLOv7、YOLOv9 和 RTMDet 等算法。在精确率方面,改良后的模型相较于 RTMDet 提高了 3.4%;在召回率方面提高了 6.2%;而在 F1 和 mAP 方面则分别提升了 6.2%和 7.8%。

表 4.6 实对比验数据表
Table 4.6 Real comparison data table

模型	精确率 (%)	召回率 (%)	F1 (%)	mAP (%)	mAP@0.5: 0.95 (%)
Faster-RCNN	46.4	37.0	41.2	37.8	12.9
SSD	48.3	38.7	43.0	38.9	11.8
YOLOv3	49.4	40.7	44.6	40.3	19.0
YOLOv5	51.5	41.4	46.0	41.5	22.3
YOLOv7	53.1	42.5	47.2	42.8	21.2
YOLOv9	54.3	44.5	47.6	45.2	23.0
RTMDet	54.9	45.1	48.4	46.8	23.5
本文	58.3	51.3	54.6	54.6	29.2

论文提出的改进 YOLOv11n 路面裂缝检测模型在公开路面裂缝数据集上的表现相较于其它流行目标检测算法，表现出了明显的优势。实验进一步表明，改进的模型能够有效提升路面裂缝检测性能。

本章小结

为了验证本文改进的 YOLOv11n 路面裂缝和坑洞检测模型的检测性能与创新模块的贡献，在本章建立了路面裂缝和坑洞检测数据集，并在此数据集上进行了检测基线实验、改进点消融实验以及经典检测模型对比实验。实验结果表明，改进模型具有良好的训练效果和检测性能；各创新模块均有效提升了模型对于路面裂缝和坑洞的检测效果；改进模型相较于其他经典物体检测模型具有明显优势，具有良好的理论与应用价值。

结论与展望

在大力发展路面裂缝和坑洞检测模型的背景下,本文基于深度学习研究了路面裂缝和坑洞检测算法,对 YOLOv11n 模型提出优化改进方案,并设计实验验证了本文改进的路面裂缝和坑洞检测模型的检测性能。研究结果如下:

(1) 提出融合了 BiFPN 双向特征金字塔网络和 MCA 多模态交叉注意力机制的 BMFPN 模块,来替换 Concat 层。该模块通过动态优化多尺度特征处理,增强目标区分,细粒度特征提取和上下文感知能力,同时保持轻量化和高效计算,提升了模型检测精度和鲁棒性,提高了模型对于细小裂缝和坑洞的识别能力,以及对多尺度路面裂缝和坑洞的检测性能。

(2) 针对 C3k2 模块在目标特征提取中的不足,引入了 SimAM 注意力机制来改进 C3k2,设计出一种 SMC3k2 模块,该模块利用局部空间特征的自适应调节,增强 C3k2 模块的信息选择性。模型可以精准聚焦于目标区域的关键特征,并抑制背景干扰。同时,保留了 C3k2 模块的跨层特征融合能力和计算效率,提升了模型对于区域目标裂缝和坑洞的特征提取能力,以及抑制复杂背景干扰的能力。

(3) 改进的模型在路面裂缝和坑洞检测任务中显著提升了检测性能。在路面裂缝和坑洞数据集上的实验结果表明,改进后的模型在 mAP@0.5 指标上达到了 54.6%,优于大多主流模型,且精度显著高于 YOLOv11n,证明了该模型在路面裂缝和坑洞检测任务中的高效性。

论文在路面裂缝和坑洞检测模型改进研究中尚存在以下不足:

(1) 研究考虑了路面裂缝和坑洞的多尺度特征但没有考虑到多模态特征,在路面裂缝和坑洞检测精度上仍有上升空间。下一步研究将考虑路面裂缝和坑洞多模态特点,对模型进行进一步改进。

(2) 本文使用数据集基本为天气状况良好条件下路面裂缝和坑洞图像,而实际情况中经常会遇到复杂多变的天气环境,因此未来研究将收集和应用包括各种复杂天气条件下的路面裂缝和坑洞数据集对模型进行训练,以贴近各种实际情况,增强模型泛用性和鲁棒性。

未来,将继续优化模型结构,在控制模型参数量的同时,针对路面裂缝和坑洞多模态的特点并考虑实际天气影响,对模型进行进一步改进以提升模型检测性能,力求进一步实现模型轻量化、高效化、实用化。

参考文献

- [1] 宣以国. 基于改进 YOLO 算法的路面裂缝和坑洞损害检测研究[D]. 重庆: 重庆理工大学, 2024. DOI:10.27753/d.cnki.gcqgx.2024.000512.
- [2] 徐彦威, 李军, 董元方, 等. YOLO 系列目标检测算法综述[J]. 计算机科学与探索, 2024, 18(9): 2221-2238.
- [3] Ross T Y, Dollár G. Focal loss for dense object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 2980-2988.
- [4] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multi object detectors[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7464-7475.
- [5] Redmon J. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [6] Farhadi A, Redmon J. Yolov3: An incremental improvement[C]//Computer vision and pattern recognition. Berlin/Heidelberg, Germany: Springer, 2018, 1804: 1-6.
- [7] Ge Z. Yolox: Exceeding yolo series in 2021[J]. arXiv pre print arXiv:2107.08430, 2021.
- [8] Wang CY, Bochkovskiy A, Liao HYM.YOLOv7[J]: Trainable bag-of-freebies sets new state-of-the-art for real-time results of the IEEE international conference on computer vision,2017: 2961-2969.
- [9] Wang A, Chen H, Liu L, et al. Yolov10: Real-time end-to-end object detection[J]. arXiv preprint arXiv:2405.14458, 2024.
- [10] Tan M, Pang R, Le Q V. Efficientdet: Scalable and efficient object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 10781-10790.
- [11] CarionN,MassaF,SynnaeveG, et al. End-to-end object detection with transformers[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 213-229.
- [12] Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [13] Ren S. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. arXiv:1506.01497, 2015. arXiv preprint.
- [14] He K, Gkioxari G, Dollár P, et al. Mask r-cnn[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 2961-2969.
- [15] 黄瑾.路面裂缝检测识别方法研究综述与前景展望[J].黑龙江交通科技,2023,46(06):32-34.
- [16] 王墨川,何莉,胡成雪,等. 基于曲率滤波和 N-P 准则的路面裂缝识别方法 [J]. 计算机工程与科学,2022,44(10):1822-1831.
- [17] 李鹏,李强,马味敏,等. 基于 K-means 聚类的路面裂缝分割算法 [J]. 计算机工程与设计,2020,41(11):3143-3147.
- [18] SAFAEI N,SMADI O,MASOUD A,et al. An Automatic Image Processing Algorithm Based on Crack Pixel Density for Pavement Crack Detection and Classification [J]. International Journal of Pavement Research and Technology,2022,15(1):159-172.

- [19] KÖNIG J, JENKINS M D, MANNION M, et al. Optimized deep encoder-decoder methods for crack segmentation [J]. Digital Signal Processing, 2021, 108: 102907.
- [20] 史英英. 基于图像处理的路面裂缝识别技术研究 [J]. 四川水泥, 2022, (11): 203-205.
- [21] 孙向鹏. 基于图像处理的高速路面裂缝识别技术研究 [J]. 交通世界, 2022, (33): 86-88. DOI:10.16248/j.cnki.11-3723/u.2022.33.013.
- [22] 肖钟捷, 韩辉珍, 徐应明. 基于数字图像处理的路面裂缝识别关键技术研究 [J]. 吉林师范大学学报(自然科学版), 2022, 43(1): 116-120.
- [23] 贾迪, 宋伟东, 戴激光, 等. 面向线阵列 CCD 道路影像的裂缝识别 [J]. 中国图象图形学报, 2016, 21 (12): 1623-1633.
- [24] 张玉雪, 唐振民, 钱彬, 等. 基于稀疏表示和多特征融合的路面裂缝检测 [J]. 计算机科学, 2018, 45 (07): 271-277.
- [25] 张焱, 屈鑫, 良健, 等. 基于数字图像处理的路面裂缝识别技术 [C]// 中国公路学会, 中国航海学会, 中国铁道学会, 中国航空学会, 中国汽车工程学会. 2024 世界交通运输大会(WTC2024)论文集(公路工程). 长安大学公路学院; 西安西北民航项目管理有限公司, 2024: 484-489. DOI:10.26914/c.cnkihy.2024.010803.
- [26] 杨泽, 孙静宇. 复杂背景下的路面裂缝检测的关键技术 [J]. 计算机工程与设计, 2023, 5(44): 1519-1527.
- [27] 瞿中, 李明. 混合扩张卷积和注意力机制的路面裂缝检测 [J]. 计算机工程与设计, 2023, 8(44): 2425-2431.
- [28] 王丹, 李琦, 梁栋, 等. 基于多尺度全卷积与 CRF 的路面裂缝检测算法 [J]. 燕山大学学报, 2021, 4(45): 367-376.
- [29] 陈涵深, 姚明海, 瞿心昱. 基于 U 型全卷积神经网络的路面裂缝检测 [J]. 光电工程, 2020, 47 (12): 67-77.
- [30] 王安政, 党建武, 岳彪, 等. 基于位置信息和注意力机制的路面裂缝检测 [J]. 计算机工程, 2024, 50(4): 303-312.
- [31] 张明星, 徐健, 刘秀平, 等. 改进 U-Net 的路面裂缝检测方法 [J]. 计算机工程与应用, 2024, 24(60): 305-313.
- [32] 徐康, 马荣贵. 基于改进 Faster-RCNN 的沥青路面裂缝检测 [J]. 计算机系统应用, 2022, 7(31): 340-348.
- [33] 李鹏程, 孙立双, 谢志伟, 等. 基于改进 MobileNet-SSD 的路面裂缝图像检测算法 [J]. 激光杂志, 2022, 43(7): 123-127.
- [34] 祝一帆, 王海涛, 李可, 等. 一种高精度路面裂缝检测网络结构: Crack U-Net [J]. 计算机科学, 2022, 49 (01): 204-211.
- [35] 曹锦纲, 杨国田, 杨锡运. 基于注意力机制的深度学习路面裂缝检测 [J]. 计算机辅助设计与图形学学报, 2020, 32(8): 1324-1333.
- [36] 赵志宏, 郝子晔, 何朋. 融合注意力机制与 GhostUNet 的路面裂缝检测方法 [J]. 电子测量技术, 2023, 46(24): 164-171.

- [37] 段中兴,何宇超,张旭生,等.有效特征提取和级联优化的路面裂缝检测方法[J].计算机辅助设计与图形学学报,2024,36(12):2020-2028.
- [38] 夏淑芳,袁彬,瞿中.基于注意力机制和深层特征优化的混凝土路面裂缝检测[J].计算机科学,2024,51(11):198-204.
- [39] 苏天成,郑津津,张广强,等.融合多级特征与注意力机制的路面裂缝检测[J].传感器与微系统,2024,43(6):157-160.
- [40] 翟军治,孙朝云,裴莉莉,等.多尺度特征增强的路面裂缝检测方法[J].交通运输工程学报,2023,23(1):291-308.
- [41] 谢永华,厉涛,柏勇.结合注意力特征融合的路面裂缝检测[J].计算机工程与设计,2025,46(1):307-313.
- [42] 尹学辉,傅林琳,周尚波.渐进式上下文交互和注意力机制的混凝土路面裂缝检测网络[J/OL].计算机应用,1-12[2025-04-23]. <http://kns.cnki.net/kcms/detail/51.1307.TP.20250314.1257.002.html>.
- [43] 王保宪,白少雄,赵维刚.基于特征增强学习的路面裂缝病害视觉检测方法[J].铁道科学与工程学报,2022,19(7):1927-1935.
- [44] 李彬,李生林.改进YOLOv11n的无人机小目标检测算法[J].计算机工程与应用,2025,61(07):96-104.
- [45] 郝巨鸣,杨景玉,韩淑梅,等.引入Ghost模块和ECA的YOLOv4公路路面裂缝检测方法[J].计算机应用,2023,43(4):1284-1290.
- [46] 龚芳媛,方冰杰,程雪佼,等.基于改进YOLOv5的路面裂缝检测算法[J].大连理工大学学报,2024,64(3):314-322.
- [47] 沈思远,华蓓,黄汝维.改进YOLOv5的路面裂缝检测模型研究[J].电子测量技术,2023,46(21):132-142.
- [48] 孙建诚,杨舒涵,龚芳媛,等.基于改进YOLOv5的复杂背景下路面裂缝检测[J].中国科技论文,2023,18(7):779-785.
- [49] 景峰,刘晓捷,刘军,等.基于融合注意力和任务解耦的路面裂缝检测[J].计算机工程与设计,2023,44(5):1565-1571.
- [50] 李金涛,周兴林,尹雨飞,等.基于TAS-YOLO的道路表面缺陷检测[J].电子测量技术,2024,47(13):148-156.
- [51] 刘宏利,吕文涛,邵磊,等.基于改进YOLOv8的路面裂缝检测方法[J/OL].天津理工大学学报,1-9[2025-04-23]. <http://kns.cnki.net/kcms/detail/12.1374.N.20250107.1634.004.html>.
- [52] 高明星,蒋正发,张林,等.基于双金字塔网络的航拍图像路面裂缝检测方法[J].激光与光电子学进展,2024,61(22).
- [53] 白锋,马庆禄,赵敏.面向航拍路面裂缝检测的AC-YOLO[J].计算机工程与应用,2025,61(01):153-164.
- [54] 钟伟.基于改进YOLOv8的绝缘子故障诊断研究[J/OL].重庆工商大学学报(自然科学版),1-12[2025-04-23]. <http://kns.cnki.net/kcms/detail/50.1155.N.20241105.1023.002.html>.
- [55] 周秀珊,文露婷,介百飞,等.改进YOLOv11的水面膨化饲料颗粒图像实时检测算法[J].智慧农业(中英文),2024,6(06):155-167.

- [56] 李禹萱,宋伟东,孙尚宇,等.基于改进 Swin-Transformer 的农村路面裂缝检测算法[J].北京交通大学学报,2024,48(5):88-97.
- [57] 杨杰,蒋严宣,熊欣燕.结合 Transformer 和 SimAM 轻量化路面损伤检测算法[J].铁道科学与工程学报,2024,21(09):3911-3920.
- [58] 隆涛,董安国,刘来君.基于注意力机制和可变形卷积的路面裂缝检测 [J].计算机科学,2023,50 (S 1): 402-407.
- [59] 刘向举,刘洋,蒋社想.基于 SimAM 注意力机制的 DCN-YOLOv5 水下目标检测[J].重庆工商大学学报(自然科学版),2025,42(2):63-70.
- [60] 单飞,李辉,孙浩,等.基于改进 simAM-YOLOv8 的路面多病害识别方法 [J/OL].吉林大学学报(工学版),1-14[2025-04-23]. <https://doi.org/10.13229/j.cnki.jdxbgxb.20240586>.
- [61] 张刚,唐戡,杨小双,等.基于改进 YOLOv5 算法的道路坑洼检测方法[J].计算机工程与设计,2025,46(2):554-561.
- [62] 任金霞,吴吉林,王金荣.基于 ECA 和 BiFPN 改进 YOLOv5s 的 PCB 缺陷检测[J].机器视觉与检测,2024,11(8):78-83.
- [63] 刘丽丽,王智文,王亮,等.基于 BiFPN 和注意力机制改进 YOLOv5s 的车辆行人检测[J].现代电子技术,2025,48(3):174-180.
- [64] 侯涛,张田明,牛宏侠.基于改进 YOLOv7-tiny 的道路缺陷检测研究 [J/OL].北京邮电大学学报,1-7[2025-04-23]. <https://doi.org/10.13190/j.jbupt.2024-061>.
- [65] 王启涵,刘超.改进 YOLOv7-Tiny 的道路裂缝检测算法[J/OL]. 计算机工程与应用,1-10[2025-04-23].<http://kns.cnki.net/kcms/detail/11.2127.TP.20240912.1008.006.html>.
- [66] Ghosh, D. Arya, H. Maeda, S. K. D. Toshniwal, and Y. Sekimoto,“Rdd2022: A multi-national imagedatasetfordetection,”automatic2022.roaddamage[Online].