

引用格式:

麻海志, 刘拥民, 徐卓农, 邓伟豪. 农田环境中玉米叶片病害精准识别算法DBG-YOLO [J]. 湖南农业大学学报(自然科学版), 2025, 51(4): 107–116.

MA H Z, LIU Y M, XU Z N, DENG W H. DBG-YOLO algorithm for precise identification of corn leaf diseases in farmland environments[J]. Journal of Hunan Agricultural University(Natural Sciences), 2025, 51(4): 107–116.

投稿网址: <http://xb.hunau.edu.cn>



农田环境中玉米叶片病害精准识别算法DBG-YOLO

麻海志^{1,2}, 刘拥民^{1,2*}, 徐卓农^{2,3}, 邓伟豪^{1,2}

(1. 中南林业科技大学电子信息与物理学院, 湖南 长沙 410004; 2. 中南林业科技大学智慧林业云研究中心, 湖南 长沙 410004; 3. 中南林业科技大学计算机与数学学院, 湖南 长沙 410004)

摘要: 为有效地预防玉米病害, 精准地监测玉米的生长状态, 本研究提出了玉米叶片病害识别算法DBG-YOLO。该算法以YOLOv8框架为基础, 首先, 在骨干网络中使用动态卷积(DynamicConv)替换YOLOv8的骨干C2f模块卷积, 在不增加网络深度或宽度的情况下, 大大增强算法的表达能力; 其次, 在颈部网络中采用全局和局部信息自注意力机制(GLSA)用于捕捉输入特征的全局上下文信息, 同时保留局部细节特征; 然后, 在颈部网络的特征融合过程中引入双向特征金字塔网络(BiFPN)模块, 以减少算法的参数量, 提高算法对多尺度目标的感知能力, 从而更好地检测玉米叶片病害; 最后, 为了加快收敛速度, 在损失函数上引入指数移动平均数(EMA)来动态调整SlideLoss中的IoU阈值, 以增强其适应能力, 由此改善算法的鲁棒性, 同时减少误检和漏检, 进一步提升整体检测精度并加快算法的收敛。结果表明: 相较于YOLOv8n, DBG-YOLO算法的精确度、mAP@50分别提高了5.8个百分点和6.6个百分点, 同时算法的浮点计算数和帧率分别降低了11.5%和43.5%。综上所述, 本研究提出的算法全面提高了玉米叶片病害检测的准确性, 具备较高的鲁棒性, 可为玉米叶片病害检测模型在移动端检测设备的部署和应用提供参考。

关键词: 玉米叶片病害; YOLOv8; 动态卷积; 深度学习; 目标检测

中图分类号: S436.6; S511; TP391.41

文献标志码: A

文章编号: 1007-1032(2025)04-0107-10

DBG-YOLO algorithm for precise identification of corn leaf diseases in farmland environments

MA Haizhi^{1,2}, LIU Yongmin^{1,2*}, XU Zhuonong^{2,3}, DENG Weihao^{1,2}

(1. School of Electronic Information and Physics, Central South University of Forestry and Technology, Changsha, Hunan 410004, China; 2. Smart Forestry Cloud Research Center, Central South University of Forestry and Technology, Changsha, Hunan 410004, China; 3. School of Computer and Mathematics, Central South University of Forestry and Technology, Changsha, Hunan 410004, China)

Abstract: To effectively prevent corn diseases and monitor corn leaf growth, the DBG-YOLO detection algorithm was proposed. Based on YOLOv8, the C2f module in the backbone was replaced with DynamicConv, enhancing the model's capability without increasing its depth or width. In the neck network, the global-local self-attention(GLSA) mechanism was used to capture global context while retaining local details. The bidirectional feature pyramid network(BiFPN) module was introduced to reduce parameters and improve multi-scale feature fusion, thus enhancing the detection of corn leaf diseases. To accelerate convergence, the exponential moving average(EMA) was introduced to the IoU threshold in SlideLoss, improving robustness while reducing false detections and missed detectinos. The results showed that

收稿日期: 2024-09-11

修回日期: 2025-07-02

基金项目: 国家自然科学基金项目 (31870532); 长沙市科技计划项目(kq2402265)

作者简介: 麻海志(1999—), 男, 湖南凤凰人, 硕士研究生, 主要从事图像处理、人工智能研究, 1147335268@qq.com; *通信作者, 刘拥民, 博士, 教授, 主要从事深度学习、智慧农业研究, T20040550@csuft.edu.cn

compared with YOLOv8n, the precision and mAP@50 of the DBG-YOLO algorithm were increased by 5.8 percentage points and 6.6 percentage points, respectively. Meanwhile, the floating-point operations(FLOPs) and frame rate of the algorithm were reduced by 11.5% and 43.5%, respectively. In summary, the model proposed in this study comprehensively improves the accuracy of corn leaf disease detection and has good robustness, providing a reference for the deployment and application of corn leaf disease detection model in mobile detection devices.

Keywords: corn leaf diseases; YOLOv8; DynamicConv; deep learning; object detection

玉米是全球粮食供应的重要农作物之一^[1],但玉米叶片病害却是限制其增产增收的主要因素。一旦玉米病害发生,将严重影响其产量,尤其是在未能及时防治的情况下,可能对农业经济造成重大影响^[2]。因此,在玉米生长早期阶段,及时识别并检测叶片病害对保障玉米的产量和质量至关重要。近年来,深度学习技术广泛应用于农业场景下的玉米叶片病害检测中。根据检测阶段的不同,目标检测算法主要分为两大类。一类是以R-CNN^[3]、Fast R-CNN^[4]和Faster R-CNN^[5]为代表的两阶段检测算法。这类算法以高精度著称,但由于检测过程包含多个步骤,计算量较大,且耗时长。另一类是单阶段检测算法,代表性算法包括YOLO^[6]系列(如YOLOv3、YOLOv4)和SSD(single shot multibox detector)^[7]等。这类算法通过单一阶段同时完成目标定位和分类,具备速度快、实时性强的优点。例如,黄政等^[8]引入RepGhostNet、路由注意力来改进的YOLOv8n模型,用于检测梨树叶片病害,其精确率为90.1%。YASIN等^[9]利用带有批量归一化(batch normalization)模块的CNN进行番茄和玉米叶片病害检测,二者准确率分别为90.89%和92.21%。张鹏程等^[10]提出了一种改进的YOLOv7算法,通过引入GhostNetV2、PConv、D-LKA与CARAFE模块,算法精度达72.1%,参数量与计算量分别减少43.4%和37.0%,兼顾了检测效率与准确性。

虽然基于深度学习的玉米叶片多病害检测算法已经应用于实际,但其依旧存在以下不足:

1) 缺乏全局特征信息。现有玉米叶片病害识别

算法大多依赖于局部特征的提取,难以有效整合整体叶片的全局特征信息,导致其对分散、早期或微小病害的识别能力不足。

2) 抗干扰能力差。受田间环境中的光照、尺度变化、噪声等因素影响,现有算法在复杂环境下的鲁棒性和泛化能力较弱,识别效果下降。

3) 图像数据有限。大规模玉米病害图像数据难以获取,数据量不足限制了算法的训练效果和检测性能。

为此,本研究首先采用YOLOv8网络作为主干特征提取网络,并在原有骨干网络的C2f卷积中引入动态卷积DynamicConv;其次,在颈部网络中加入GLSA注意力机制和BiFPN特征融合模块,同时引入损失函数EMA-SlideLoss;最后,提出DBG-YOLO识别算法,并在玉米叶片病害数据集中对该算法进行训练,以期实现对玉米叶片多种病害的精准识别。

1 材料准备

1.1 数据集

1.1.1 数据集来源

本研究中所使用的玉米叶片病害图像数据集来源于Kaggle网站上的Corn or Maize Leaf Disease Dataset公开数据集。此数据集包含了灰斑病图像1 278张、枯萎病图像1 275张、草地贪夜蛾幼虫病图像1 200张、草地贪夜蛾卵图像1 068张和锈病图像1 132张,部分图像如图1所示。



图1 玉米叶片病害图像示例

Fig.1 Example of images of corn leaf diseases

1.1.2 数据集预处理

为了进一步增强训练算法的泛化能力，本研究采用多种数据增强策略。这些方法包括旋转图像以模拟不同的拍摄角度、添加噪声以提高算法对图像质量变化的鲁棒性、裁剪叶片以及降低图像的亮度来模拟现实中可能出现的低亮度图像。通过这些增

强手段，算法能够更好地适应玉米田间环境的复杂性，提高在不同场景下的检测准确性。玉米叶片病害图像增强效果如图2所示。

为了对算法进行训练与评估，将数据集随机划分为训练集、验证集和测试集，每类病害的图像数量及图像标注总数如表1所示。

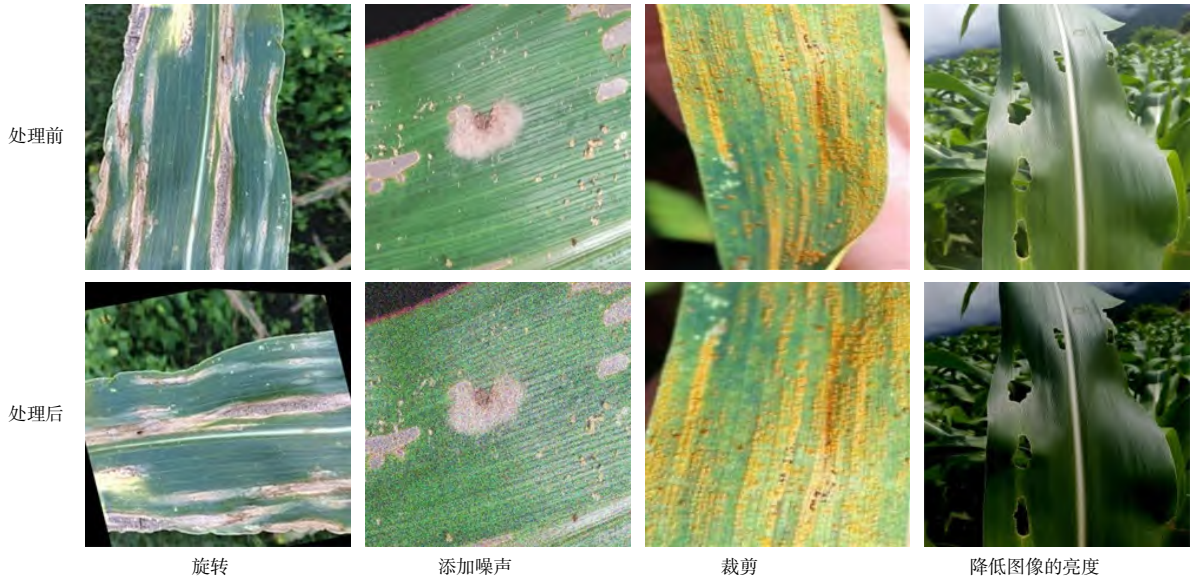


图2 玉米叶片病害图像增强效果

Fig.2 Images enhancement effects for corn leaf diseases

表1 玉米叶片病害数据集参数

| 病害类别 | 图像数量/张 | | | 图像标注 总数/个 |
|----------|--------|-----|-----|--------------|
| | 训练集 | 验证集 | 测试集 | |
| 锈病 | 821 | 132 | 179 | 7 991 |
| 灰斑病 | 910 | 173 | 195 | 4 665 |
| 枯萎病 | 1 010 | 132 | 133 | 4 706 |
| 草地贪夜蛾卵 | 859 | 101 | 108 | 3 070 |
| 草地贪夜蛾幼虫病 | 960 | 121 | 119 | 7 553 |

1.2 YOLOv8网络

在目标检测领域，YOLOv8是一种快速、精准的目标检测算法，具备出色的灵活性和稳定性。YOLOv8网络结构主要由骨干网络、颈部网络和头部网络3个部分组成^[11]，其网络结构如图3所示。

1) 骨干网络。这是YOLOv8的特征提取模块核心组件之一，主要用于提取输入图像中不同层次的特征。该模块通常包含多层卷积层、池化层、激活函数等，用于对输入图像的信息进行抽象化处理。具体而言，特征提取模块通过一系列的卷积操作，

逐级提取具备低级特征(如边缘、纹理)和高级语义特征(如目标的形状和类别)的特征图。YOLOv8在设计中采用了一些改进的卷积模块，以提高特征提取的效率和性能，在减少计算量的同时提升网络的表达能力。随后，特征提取模块输出的多尺度特征图会被传递到特征融合模块，用于进一步整合不同层次的特征。

2) 颈部网络。YOLOv8的颈部网络通常采用特征金字塔网络(FPN)与路径聚合网络(PANet)相结合的结构，通过上采样操作，将来自不同深度的特征图进行融合。FPN提供自底向上的特征传播通道，增强高层特征的细节表达；PANet则自顶向下聚合特征，提升算法对小目标的检测能力。

3) 头部网络。YOLOv8在头部网络中将分类任务和回归任务分离，采用了“解耦头”设计，将原本的耦合头改成目前主流的解耦头结构，并将Anchor Base换成Anchor-Free无锚框检测头，减少锚框预测数量，加速非最大抑制(non-maximum suppression)^[12]。

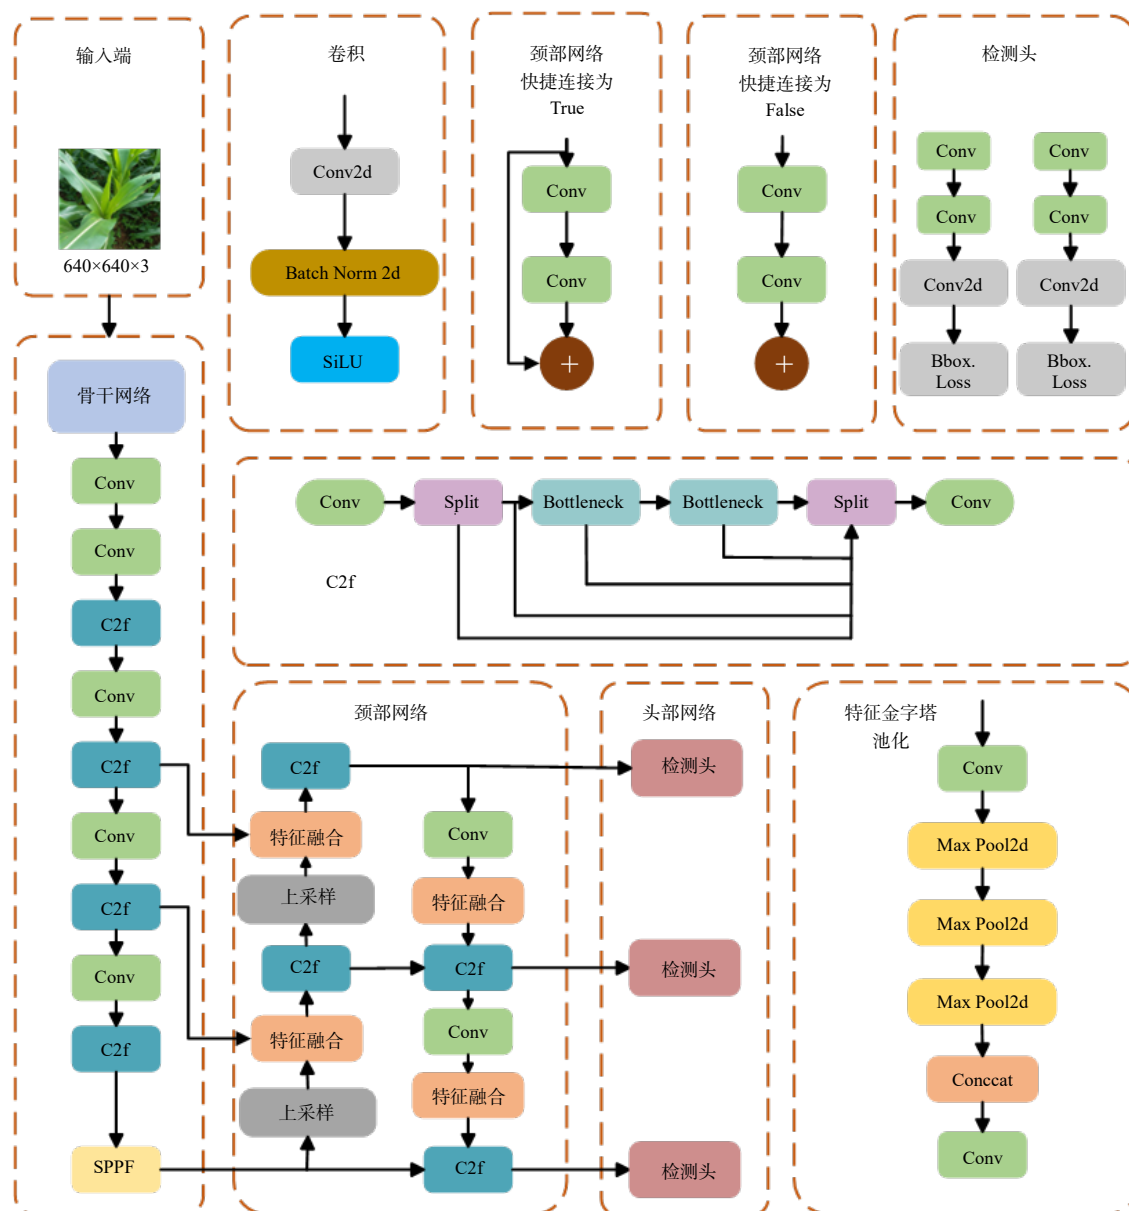


图3 YOLOv8网络结构示意图

Fig.3 Schematic diagram of YOLOv8 network structure

2 玉米叶片病害检测算法的改进

针对当前玉米病害检测算法中存在的计算速度慢、权重文件内存较大以及检测精度低等问题,本研究提出玉米叶片病害检测新算法DBG-YOLO。该算法以YOLOv8框架为基础,主要在以下4个方面进行功能优化和算法改进,以实现更高的检测精度和更低的计算成本。首先,为解决减少参数冗余问题,提升计算效率和特征提取的表达能力,将YOLOv8中C2f模块的卷积替换为动态卷积DynamicConv,通过共享参数或动态生成卷积核的方式^[13],能够在一定程度上减少参数冗余,同时卷积核可以根据输入特征的内容进行动态调整,增强

特征提取的多样性和表达能力。其次,为了进一步增强特征融合和上下文信息的提取能力,引入全局和局部的自注意力机制GLSA,使得网络能够更好地处理各种复杂的检测任务^[14]。相比之下,传统的自注意力机制(如标准的self-attention)主要集中在全局特征,而SE(squeeze-and-excitation)^[15]或CBAM(convolutional block attention module)^[16]等算法更多地关注局部特征。通过全局和局部自注意力的结合,算法可以更精确地捕获图像中的关键特征,提高目标检测的精度和鲁棒性。再次,为了优化多尺度特征的融合和利用,提升目标检测的精度和效率,引入BiFPN(bidirectional feature pyramid network,

双向特征金字塔网络),该网络简化了特征融合的路径,通过减少不必要的连接和操作,降低了计算复杂度^[17]。同时,通过优化特征融合的结构和计算路径,BiFPN 能够在提升检测性能的同时,保持较低的计算成本和参数量^[18]。最后,在损失函数上研究引入EMA-SlideLoss损失函数,聚焦于难以预测的

样本,减少误检和漏检,同时提高小目标检测的精度^[19]。改进后的DBG-YOLO网络结构如图4所示。该算法对YOLOv8的骨干网络和颈部网络进行了优化,前者加入了更高效的卷积模块,后者则加入了注意力机制和特征融合机制。

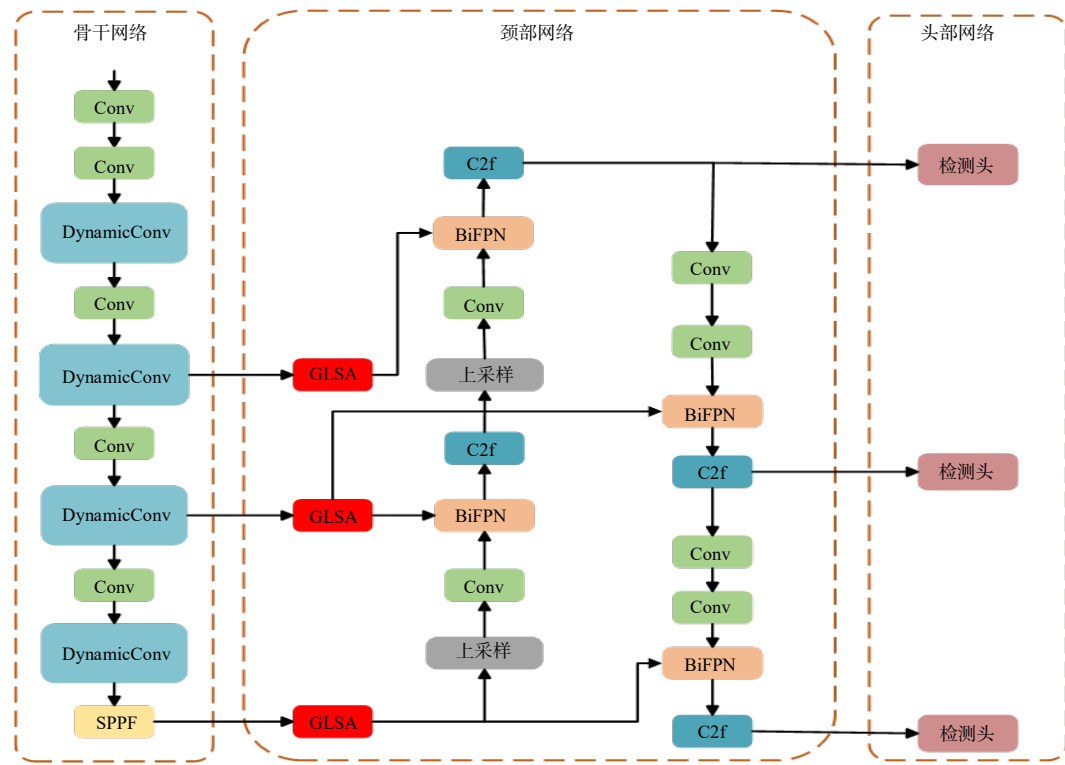


图4 改进后的DBG-YOLO算法结构示意图

Fig.4 Structural diagram of improved DBG-YOLO algorithm

3 试验与结果分析

3.1 试验环境和参数配置

本试验在64位操作系统ubuntu 20.04下进行, GPU为RTX 2080 Ti,显存为12 GB,主机内存为50 GB,编程语言为Python 3.8.10,使用CUDA v11.8对GPU进行加速,基于深度学习框架Pytorch 2.0.0进行训练。训练参数设置如表2所示。

表2 训练参数设置

| Table 2 Training parameters settings | | | |
|--------------------------------------|---------|----------|---------|
| 参数 | 数值 | 参数 | 数值(型号) |
| 训练轮次 | 200 | 优化器 | SGD |
| 早停耐心值/轮次 | 30 | 权重衰减 | 0.000 5 |
| 批次 | 16 | 动量 | 0.937 |
| 图像分辨率/(像素×像素) | 640×640 | 学习率热身动量 | 0.8 |
| 线程数 | 8 | 优化轮次 | 10 |
| 学习率 | 0.5 | 下调耐心值/轮次 | 5 |

3.2 评价指标

本文旨在评估算法的性能并验证新方法的有效性。为此,选取多项评价指标来全面衡量算法的表现,包括准确率 P 、召回率 R 、平均精度均值(A_{mAP})、权重文件内存、算法参数量、计算量等。这些指标有助于精准分析算法的轻量化程度和实时性能。

$$P = \frac{N_{TP}}{N_{TP} + N_{FP}} \tag{1}$$

$$R = \frac{N_{TP}}{N_{TP} + N_{FN}} \tag{2}$$

$$f_1 = \frac{2PR}{P + R} \tag{3}$$

$$F_1 = \sum (f_1/n) \tag{4}$$

$$P_{AP} = \int_0^1 P(R) dR \tag{5}$$

$$A_{mAP} = \frac{1}{m} \sum_{i=1}^m (P_{AP})_i \tag{6}$$

式中： N_{TP} 表示被正确检测到的正样本(即标注的病害目标)数量； N_{FP} 表示被误检测为正样本的负样本(即无关的背景)数量； N_{FN} 表示未被正确检测为正样本的正样本数量； P_{AP} 表示平均准确率； f_1 是单个类别的F1分数(变量用 F_1 表示)； P 为准确率； R 为召回率； n 为病害类别的数量； m 为玉米叶片病害类别的总数。

3.3 试验结果与分析

3.3.1 不同卷积方法对比结果

为了验证Dynamic卷积的优势,选取了YOLOv8-Conv、GroupConv、WTConv、DySnakeConv、DEConv和DynamicConv 6种主流卷积方法进行对比实验,结果如表3所示。

表3 不同卷积方法性能对比

| 主流卷积方法 | 平均精度/% | | | | | 参数量/ (10 ⁶ 个) | 浮点计算数/ GFLOPs | 帧率/ (帧·s ⁻¹) | 平均精度 均值/% |
|-------------|--------|------|------|----------|--------|-----------------------------|------------------|-----------------------------|--------------|
| | 锈病 | 灰斑病 | 枯萎病 | 草地贪夜蛾幼虫病 | 草地贪夜蛾卵 | | | | |
| YOLOv8-Conv | 78.4 | 72.6 | 88.1 | 81.0 | 90.3 | 3.1 | 8.7 | 309.8 | 82.1 |
| GroupConv | 76.6 | 70.3 | 84.2 | 76.2 | 88.2 | 2.2 | 6.2 | 258.3 | 79.1 |
| WTConv | 77.2 | 70.5 | 86.7 | 77.3 | 88.9 | 2.6 | 7.3 | 138.8 | 80.2 |
| DySnakeConv | 79.3 | 73.2 | 83.2 | 82.5 | 89.8 | 3.8 | 9.6 | 172.3 | 81.6 |
| DEConv | 78.4 | 70.7 | 84.1 | 81.4 | 90.0 | 3.6 | 7.5 | 215.6 | 80.7 |
| DynamicConv | 79.1 | 71.3 | 86.3 | 88.6 | 91.2 | 4.4 | 6.9 | 217.2 | 83.3 |

由表3可见：在平均精度均值方面，DynamicConv卷积表现最佳，达到了83.3%。在计算效率上，虽然DynamicConv的浮点计算数为6.9 GFLOPs，略高于GroupConv的浮点计算数，但仍保持在较低水平，低于DySnakeConv的9.6 GFLOPs。DynamicConv在提供高精度的同时，保持了相对较高的计算效率，适合在计算资源有限的环境中使用。在参数量方面，DynamicConv的参数量为4.4×10⁶个，虽然比一些轻量化卷积方法的略高，但仍处于可接受范围内。这种参数量的平衡使得DynamicConv能够在不增加算法复杂度的情况下，提供高质量的检测结果。在帧率方面，DynamicConv达到了217.2帧/s，高于DySnakeConv(172.3帧/s)和

WTConv(138.8帧/s)的帧率，显示出较好的实时性能。DynamicConv在保持高精度的同时，仍能提供足够的帧率，适合实时应用场景。综合来看，DynamicConv在多个方面展现出优势，通过平衡计算复杂度和参数量，提升了检测精度，同时保持了较高的计算效率和良好的实时性能。这使得DynamicConv较适宜于高精度检测的应用场景。

3.3.2 不同注意力机制对比试验分析结果

为了验证本研究中GLSA注意力机制的有效性，在颈部网络相同的位置分别加入CA(coord attention)、CBAM(convolutional block attention module)、SimAM(simple attention mechanism)注意力机制进行对比，结果如表4所示。

表4 不同注意力机制性能对比

| 注意力机制 | 平均精度/% | | | | | 参数量/ (10 ⁶ 个) | 浮点计算数/ GFLOPs | 帧率/ (帧·s ⁻¹) | 平均精度 均值/% |
|-------|--------|------|------|----------|--------|-----------------------------|------------------|-----------------------------|--------------|
| | 锈病 | 灰斑病 | 枯萎病 | 草地贪夜蛾幼虫病 | 草地贪夜蛾卵 | | | | |
| None | 78.4 | 72.6 | 88.1 | 81.0 | 90.3 | 3.1 | 8.7 | 309.8 | 82.1 |
| CA | 73.9 | 76.2 | 81.3 | 84.0 | 89.1 | 3.0 | 8.1 | 308.1 | 80.9 |
| CBAM | 74.3 | 72.4 | 86.2 | 83.5 | 90.1 | 3.5 | 11.8 | 256.5 | 81.3 |
| SimAM | 77.4 | 75.6 | 89.3 | 78.2 | 91.5 | 3.1 | 8.2 | 339.5 | 82.4 |
| GLSA | 78.5 | 74.8 | 88.5 | 82.8 | 90.7 | 4.0 | 9.2 | 235.8 | 83.1 |

由表4可见：在所有注意力机制中，GLSA对各种病害检测的平均精度均较高，虽然其参数量和浮点计算数相较于其他注意力机制的稍高，但仍在合

理范围内。GLSA的浮点计算数为9.2 GFLOPs，略高于无注意力机制(None)的8.7 GFLOPs。虽然该算法显示出一定的计算开销，但能够通过更高的检测

精度弥补。在帧率上, GLSA的帧率为235.8帧/s, 低于无注意力机制和SimAM注意力机制的帧率, 这表明GLSA由于复杂度增加, 计算速度有所降低, 但仍保持在一个较高的水平。总体来说, GLSA能够有效提高算法的检测性能, 特别是在复杂的病害检测任务中, GLSA注意力机制能够帮助算法更好地关注关键区域, 提高整体检测的准确性。

3. 3. 3 不同算法对比试验分析

为验证本文所提的算法相较于当前主流目标检测算法的优势, 选取精确度、召回率、mAP@50(即

在IoU(交并比)阈值为50%的条件下计算的平均精度均值, 其核心是使用单一且较低的IoU阈值来评估检测性能)、mAP@50-95(即在IoU阈值为50%~95%、步长为0.05的区间内所计算的平均精度的均值)、浮点计算数、参数量指标进行评估, 试验结果如表5所示。由表5可见: 二阶段目标检测算法Faster R-CNN虽然在精确度和召回率上表现不错, 但其浮点计算数和参数量较高, 因此, 不适合用于轻量化实时检测任务。

表5 不同算法性能对比

| Table 5 Performance comparison of different algorithms | | | | | | |
|--|-------|-------|----------|-------------|---------------|-------------------------|
| 网络 | 精确度/% | 召回率/% | mAP@50/% | mAP@50-95/% | 浮点计算数/ GFLOPs | 参数量/(10 ⁶ 个) |
| Faster R-CNN | 69.2 | 59.3 | 68.5 | 54.6 | 239.3 | 41.4 |
| YOLOv5s | 75.8 | 68.6 | 77.9 | 51.7 | 7.1 | 2.5 |
| YOLOv7-tiny | 77.3 | 70.6 | 79.4 | 54.6 | 13.0 | 6.0 |
| YOLOv8n | 79.5 | 72.6 | 82.1 | 56.1 | 8.7 | 3.1 |
| YOLOv8s | 80.8 | 76.7 | 84.1 | 60.3 | 28.7 | 11.1 |
| YOLOv10n | 73.7 | 69.5 | 77.7 | 51.5 | 6.5 | 2.3 |
| DBG-YOLO | 85.3 | 80.1 | 88.7 | 63.3 | 7.7 | 3.7 |

在单阶段算法中, YOLOv8n凭借较低的参数量和较小的算法内存, 在精确度、召回率、mAP等指标上均优于YOLOv5s、YOLOv7-tiny、和YOLOv10n的; YOLOv8s的精确度和召回率高于YOLOv8n的, 但它的参数量和浮点计算数却是YOLOv8n的数倍。与之相比, YOLOv10n的参数量和算法内存虽然较小, 但在性能上并未体现出显著优势。

改进后的DBG-YOLO算法虽然引入了额外的模块, 略微增加了计算量, 但其精确度和召回率得到大幅度提升, mAP@50和mAP@50-95均高于YOLOv8系列算法的, 同时浮点计算数和参数量也

得到了有效控制, 证明了改进方法的有效性。由此可见, 新提出的DBG-YOLO算法在多个关键指标上均展现出优越性, 特别是在保持高检测性能的同时, 还具备较好的实时性和轻量化特性。

3. 3. 4 消融试验

为验证本研究所提算法各改进模块的有效性, 以原始算法YOLOv8n为基础算法, 并以 F_1 、mAP@50、帧率、浮点计算数、参数量作为评价指标, 通过多个改进模块的不同组合方式进行消融试验, 消融试验结果如表6所示。

表6 消融实验数据表

| Table 6 Results of ablation experiment | | | | | | | | |
|--|-------|------|---------------|----------|----------|-------------------------|-------------------------|---------------|
| DynamicConv | BiFPN | GLSA | EMA-SlideLoss | F_1 /% | mAP@50/% | 帧率/(帧·s ⁻¹) | 参数量/(10 ⁶ 个) | 浮点计算数/ GFLOPs |
| × | × | × | × | 76.1 | 82.1 | 309.8 | 3.1 | 8.7 |
| √ | × | × | × | 77.2 | 83.3 | 217.2 | 4.4 | 6.9 |
| × | √ | × | × | 80.0 | 86.4 | 268.5 | 1.9 | 7.1 |
| × | × | √ | × | 77.0 | 83.1 | 219.5 | 4.0 | 9.2 |
| √ | √ | × | × | 78.0 | 84.4 | 202.7 | 2.7 | 6.4 |
| √ | × | √ | × | 80.0 | 86.9 | 176.1 | 4.7 | 8.5 |
| × | √ | √ | × | 81.1 | 86.6 | 177.8 | 2.1 | 7.6 |
| √ | √ | √ | × | 82.1 | 87.8 | 159.5 | 3.7 | 7.7 |
| √ | √ | √ | √ | 83.0 | 88.7 | 174.9 | 3.7 | 7.7 |

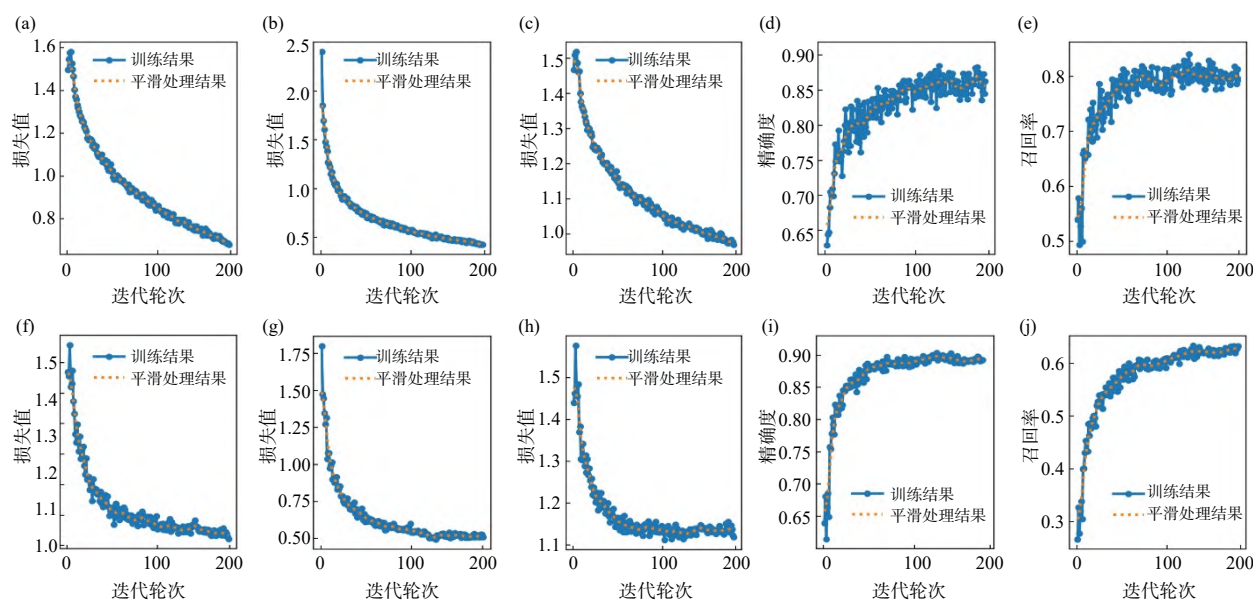
注: “×”表示YOLOv8n没有添加该模块; “√”表示YOLOv8n添加该模块; YOLOv8n+DynamicConv+BiFPN+GLSA+EMA-SlideLoss即为DBG-YOLO。

在不同的组合下,对每个模块的性能提升效果分别进行单独和联合验证。由表6可见:随着DynamicConv、BiFPN、GLSA和EMA-SlideLoss这4个关键改进模块的引入,算法检测性能($mAP@50$ 和 F_1)均有所提升。例如,DynamicConv和BiFPN的引入均显著提升了算法的 mAP 和 F_1 ,尤其是BiFPN的加入使 $mAP@50$ 相较于YOLOv8n提升了4.3个百分点, F_1 提高了3.9个百分点,表明这些模块能够有效捕捉叶片上不同大小、形状和位置的病害特征,特别是微小病害的检测能力有显著提升。当进一步加入GLSA和EMA-SlideLoss时,检测精度继续提升, $mAP@50$ 达到88.7%, F_1 达到83.0%。

EMA-SlideLoss通过动态调整损失权重,显著提高了检测算法对不同玉米叶片病害的鲁棒性,这表明其在处理难以预测的样本、减少误检和漏检等方面表现尤为出色。虽然添加了更多模块会增加参数量和计算量,但这些增加对帧率(FPS)的影响仍在可接受范围内。例如,启用DynamicConv、BiFPN、GLSA和EMA-SlideLoss后,参数量增加至 3.7×10^6 个,浮点数为7.7 GFLOPs,算法性能大幅提升的同时,仍保持了较高的处理速度。

3.3.5 DBG-YOLO改进算法的训练结果

改进后的DBG-YOLO算法训练过程如图5所示。



(a) 训练集边界框回归损失曲线; (b) 训练集分类损失曲线; (c) 训练集分布焦点损失曲线; (d) 训练集精确度曲线; (e) 训练集召回率曲线; (f) 验证集边界框回归损失曲线; (g) 验证集分类损失曲线; (h) 验证集分布焦点损失曲线; (i) 验证集精确度曲线; (j) 验证集召回率曲线

图5 DBG-YOLO训练过程

Fig.5 Training process of DBG-YOLO

由图5可见:随着训练轮次的增加,算法的各类损失(如边界框回归损失和分类损失)显著下降,说明算法的收敛效果较好,泛化能力增强。同时,精确度和召回率稳步提升,分别达到85.3%和80.1%, $mAP@50$ 和 $mAP@50-95$ 也逐步提升(分别为88.7%和63.3%),表明算法检测性能得到改善。

3.3.6 算法验证

通过对不同玉米叶片病害的图像进行检测,验证改进后算法的有效性,结果如图6所示。由图6可见:在多病害检测场景中,YOLOv8n在检测多个病害类型时也表现出一定的不足之处,特别是在复杂

背景下(例如植被覆盖和多种病斑共存的场景),容易出现漏检或低置信度的检测框。YOLOv5s在单病害检测中表现相对较好,能够识别出大多数的病斑。然而,它在多病害场景中的表现并不理想。例如,在一些复杂背景下,它的检测框偏大,且少数检测结果置信度不高。

在多病害共存的检测中,YOLOv5s与YOLOv8n均出现了漏检和置信度不高的情况。特别是对于小目标病害的检测,二者的置信度往往偏低,导致结果不够稳定。在单病害检测中,DBG-YOLO能够准确识别出更多病害,且检测框更加精确,置信度高。在复杂背景和多病害共存场景(图中间列和右列)

中,DBG-YOLO显著减少了漏检和误检的现象。它能够检测出更多的小病斑和叠加病斑,同时保持较

高的置信度,这表明它在复杂场景中具备更强的鲁棒性和更高的检测精度。

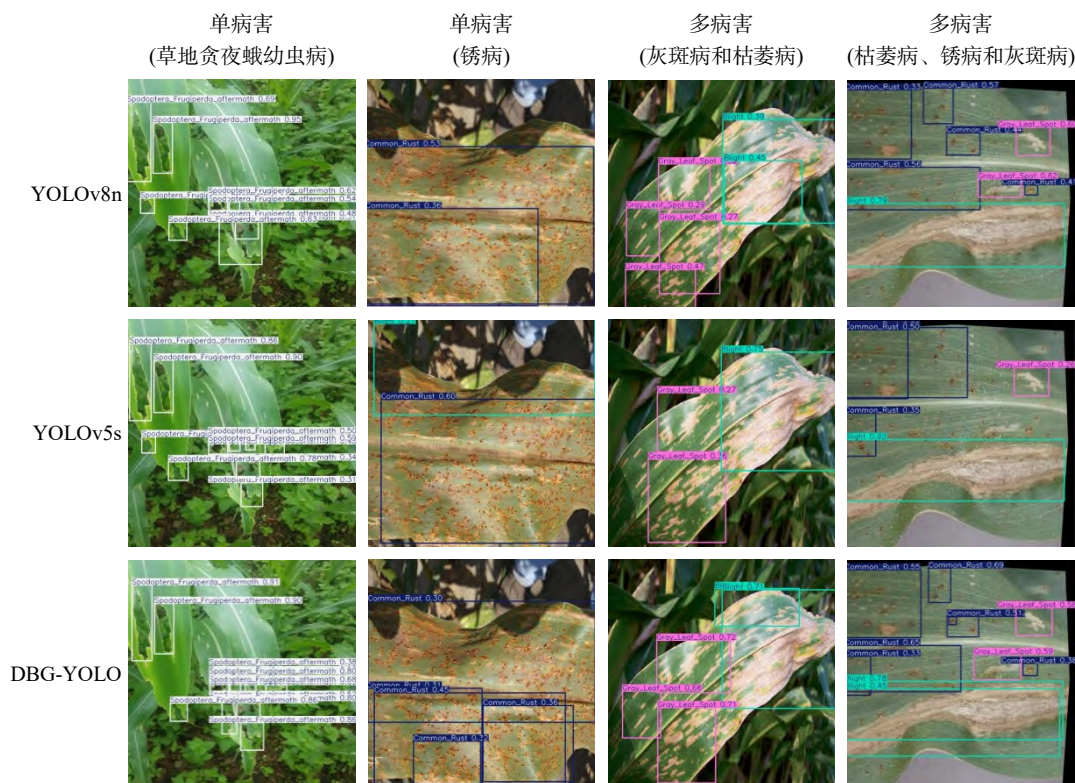


图6 不同算法对玉米叶片病害图像识别效果

Fig.6 Recognition performance of different models on corn leaf disease images

4 结论

1) DynamicConv 卷积模块的检测精度为 83.3%, 优于其他模块(如C2fConv和GroupConv)的检测精度, 同时保持较低的计算量和参数量。这说明在不增加复杂度的情况下, 该模块提高了算法的特征提取能力和检测性能。

2) GLSA(global-local self-attention)注意力机制在提升检测精度(mAP@50为83.1%)方面表现最好, 尤其在处理复杂病害时效果较好, 同时计算开销较小。它有效结合了全局和局部信息, 增强了算法的适应性和精度。

3) 改进后的DBG-YOLO算法在精确度(85.3%)、召回率(80.1%)和mAP指标上均优于其他算法(如YOLOv8n和Faster R-CNN)的, 同时计算效率更高。

4) 通过对YOLOv8的卷积模块、注意力机制和整体架构进行多重改进, 新的玉米叶片病害检测算法DBG-YOLO提升了检测精度和效率, 降低了计算复杂度和参数量。这些改进为该算法的实际应用提供了更具竞争力的解决方案, 特别是在资源有限的

移动端设备部署中有望取得较好的检测效果。

参考文献:

- [1] AICH S, STAVNESS I. Leaf counting with deep convolutional and deconvolutional networks[C]//2017 IEEE International Conference on Computer Vision Workshops (ICCVW). Venice, Italy: IEEE, 2017: 2080–2089.
- [2] LIU Y L, CEN C J, CHE Y P, et al. Detection of maize tassels from UAV RGB imagery with Faster R-CNN[J]. Remote Sensing, 2020, 12(2): 338.
- [3] DONG C, ZHANG K, XIE Z Y, et al. An improved cascade RCNN detection method for key components and defects of transmission lines[J]. IET Generation, Transmission & Distribution, 2023, 17(19): 4277–4292.
- [4] WANG X L, SHRIVASTAVA A, GUPTA A. A-fast-RCNN: hard positive generation via adversary for object detection[C]//2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Honolulu, USA: IEEE, 2017: 3039–3048.
- [5] LIU R, YU Z H, MO D L, et al. An improved faster-RCNN algorithm for object detection in remote sensing images[C]//2020 39th Chinese Control Conference (CCC). Shenyang, China: IEEE, 2020: 7188–7192.

- [6] JIANG P Y, ERGU D, LIU F Y, et al. A review of YOLO algorithm developments[J]. *Procedia Computer Science*, 2022, 199: 1066–1073.
- [7] ZHAI S P, SHANG D R, WANG S H, et al. DF-SSD: an improved SSD object detection algorithm based on DenseNet and feature fusion[J]. *IEEE Access*, 2020, 8: 24344–24357.
- [8] 黄政, 张涛, 孔万仔, 等. 基于YOLOv8n的梨树叶片病害检测模型[J]. *湖南农业大学学报(自然科学版)*, 2025, 51(2): 113–121.
- [9] YASIN A, FATIMA R. On the image-based detection of tomato and corn leaves diseases: an in-depth comparative experiments [EB/OL]. (2023–12–14). <https://arxiv.org/abs/2312.08659>.
- [10] 张鹏程, 矫桂娥, 毕卓. 基于YOLOv7的轻量化农田害虫检测算法[J]. *湖南农业大学学报(自然科学版)*, 2025, 51(2): 103–112.
- [11] 孙丰刚, 王云露, 兰鹏, 等. 基于改进YOLOv5s和迁移学习的苹果果实病害识别方法[J]. *农业工程学报*, 2022, 38(11): 171–179.
- [12] BODLA N, SINGH B, CHELLAPPA R, et al. Soft-NMS: improving object detection with one line code[C]// *Proceedings of the IEEE International Conference on Computer Vision*. Venice, Italy: IEEE, 2017: 5561–5569.
- [13] HAN K, WANG Y H, GUO J Y, et al. ParameterNet: parameters are all you need for large-scale visual pretraining of mobile networks[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, USA: IEEE, 2024: 15751–15761.
- [14] TANG F L, XU Z X, HUANG Q M, et al. DuAT: dual-aggregation transformer network for medical image segmentation[C]// *Pattern Recognition and Computer Vision*. Singapore: Springer, 2023: 343–356.
- [15] JIN X, XIE Y P, WEI X S, et al. Delving deep into spatial pooling for squeeze-and-excitation networks[J]. *Pattern Recognition*, 2022, 121: 108159.
- [16] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module[C]// *Computer Vision-ECCV 2018*. Cham, Germany: Springer, 2018: 3–19.
- [17] CHEN J, MAI H S, LUO L B, et al. Effective feature fusion network in BIFPN for small object detection[C]// *2021 IEEE International Conference on Image Processing (ICIP)*. Anchorage, USA: IEEE, 2021: 699–703.
- [18] 马燕婷, 赵红东, 阎超, 等. 改进YOLOv5网络的带钢表面缺陷检测方法[J]. *电子测量与仪器学报*, 2022(8): 150–157.
- [19] ZHANG Y F, REN W Q, ZHANG Z, et al. Focal and efficient IOU loss for accurate bounding box regression[J]. *Neurocomputing*, 2022, 506: 146–157.

责任编辑: 伍锦花

英文编辑: 张承平