

基于动态时空子图卷积网络的电机轴承故障声纹识别方法^{*}

熊丽萍¹, 吕辉^{2,3}, 周建安⁴

(1 河南工业和信息化职业学院, 焦作 454000;

2 河南理工大学电气工程与自动化学院, 焦作 454000;

3 河南理工大学光电传感与智能测控河南省工程实验室, 焦作 454000;

4 比亚迪汽车工业有限公司汽车工程研究院, 深圳 518118)

摘要:针对现有基于声纹识别的故障诊断方法因捕捉信号时空耦合关系困难以及动态调整构建图的能力不足导致的适应性和性能不佳问题,提出一种面向非接触电机轴承故障诊断的动态时空子图卷积网络。首先,设计一个边动态图卷积网络,通过优化边的权重自适应学习声纹信号之间的空间相关性,克服传统 k 近邻图对超参数敏感的问题;其次,将扩张因果卷积与交叉自注意力结合,构建一个时间特征融合模块,用于捕捉信号内部重要的长期依赖信息,突出信号之间的时间关系;最后,通过融合多信号时空信息来增强声纹故障特征的判别表示,实现图级故障诊断。在实际三相异步电机测试平台上的实验结果表明,所提DSTSGCN在仅有1个训练样本的情况下实现了99.72%的准确率,优于其他7种基于声纹信号的故障诊断方法。

关键词:电机轴承;声纹识别;故障诊断;图卷积网络

中图分类号:TM307;TP391.5 **文献标志码:**B **文章编号:**1671-3133(2025)11-0124-12

DOI:10.16731/j.cnki.1671-3133.2025.11.017

Dynamic spatial-temporal subgraph convolutional network and its application in voiceprint-based asynchronous motor bearing fault diagnosis method

XIONG Liping¹, LÜ Hui^{2,3}, ZHOU Jianan⁴

(1 Henan College of Industry & Information Technology, Jiaozuo 454000, China;

2 School of Electrical Engineering and Automation, Henan Polytechnic University, Jiaozuo 454000, China;

3 Henan Provincial Engineering Laboratory of Optoelectronic Sensing and Intelligent Measurement and Control, Henan Polytechnic University, Jiaozuo 454000, China;

4 Automotive Engineering Research Institute, BYD Automotive Industry Co., Ltd., Shenzhen 518118, China)

Abstract: A Dynamic Spatial-Temporal Sub Graph Convolutional Network (DSTSGCN) was proposed to address limitations in existing voiceprint-based fault diagnosis methods, including poor adaptability and insufficient dynamic graph construction capabilities caused by difficulties in capturing spatial-temporal coupling relationships. Firstly, a edge-level dynamic graph convolutional network was designed, where spatial correlations between voiceprint signals were adaptively learned through optimization of edge weights, and the sensitivity of traditional k -nearest neighbor graphs to hyperparameters was effectively mitigated. Secondly, dilated causal convolution was integrated with cross self-attention mechanisms, and a temporal feature fusion module was constructed to capture critical long-term dependency information within signals, thereby highlighting temporal relationships between signals. Finally, discriminative representations of fault features were enhanced through multi-signal spatial-temporal information fusion, enabling graph-level fault diagnosis. Experimental validation was conducted on a three-phase asynchronous motor test platform. Results demonstrated that the proposed DSTSGCN achieved 99.72 % accuracy with only one training sample, outperforming seven comparative voiceprint-based diagnostic methods.

^{*} 河南省科技攻关项目(232102210171);河南省高等学校重点科研计划项目(24B120002)

Keywords: motor bearing; voiceprint recognition; fault diagnosis; graph convolutional network

0 引言

旋转机械在工业领域是不可或缺的动力传输设备,承担着重要的制造任务^[1]。作为旋转机械的核心组件,电机能够提供稳定的动力输出,具有高效、可靠和灵活控制的优势。然而,由于复杂的机械结构和恶劣的工作条件,在长时间运行中电机及其部件容易发生多种类型故障,不仅会影响电机的控制性能,甚至会导致整个系统失效^[2]。

在所有故障类型中,超过40%的电机故障是由轴承故障引起的^[3],因此,及时诊断故障类型并确定故障位置对于工业系统的稳定运行具有重要意义。

轴承故障通常伴随着明显的周期性振动,因此通常使用振动信号进行数据驱动的故障诊断。近年来,基于振动信号的故障诊断方法在变速、负载变化、强噪声和样本稀缺等方面取得了出色的表现^[4-7]。然而,在实际场景中,振动传感器对安装位置和精度有着严格要求,采集过程受机械设备表面的影响较大,例如油污、滑动和几何不规则性,这使得收集振动信号变得困难。此外,在高湿度、高温和高腐蚀等极端环境中,振动信号难以测量。鉴于此,基于振动的故障诊断方法在某些工业场景中可能存在局限性。

作为典型的非接触感知方法,基于声纹的方法由于覆盖范围广、后处理量大、成本低以及对极端环境的良好适应性等优势,逐渐被用于故障诊断任务^[8]。在基于声纹的故障诊断任务中,通常应用传统的信号处理方法分析声纹信号的统计特征,包括时域、频域以及混合时频域。

例如,文献[9]结合声纹特征和小波变换用于感应电机故障诊断。

文献[10]改进了频率调制小波变换以减少声纹信号中的谐波干扰,利用希尔伯特包络谱识别轴承故障。

文献[11]提出一种基于压缩感知信号处理的故障诊断框架,采用压缩感知技术直接从声纹信号中提取压缩特征,用于监测滚动轴承的工作状态。然而,上述传统声纹信号处理方法严重依赖于专家知识,且计算过程复杂。

近年来,基于深度学习的方法因其良好的特征提取能力,逐渐被应用于多种故障诊断问题。基于深度学习的声纹识别方法可以识别微小差异,处理声学模

式中的复杂非线性关系,从而提高声纹故障诊断的效率和适应性。

例如,文献[12]针对声纹信号中高度非平稳背景噪声的局限性,提出一种基于多层次注意力机制的递归去噪学习方法。

文献[13]采用变分模式分解和卷积神经网络(Convolutional Neural Networks, CNNs)去除高频噪声,并提取Mel频谱声纹特征以实现轴承故障诊断。

文献[14]设计了一个基于Transformer的轻量级轴承故障诊断框架,并将其部署在智能手机上,实现了边缘智能故障诊断。

文献[15]首次提出一种基于深度图卷积网络(Graph Convolutional Network, GCN)的声纹故障诊断方法,将图卷积、图粗化和图池化操作结合起来捕捉顶点之间的关系,从而提高分类准确性。

文献[16]提出了一种加权GCN用于轴向泵设备的声纹故障诊断。

文献[17]构建了一种特殊的图结构“超图”,提取其图结构特征作为GCN模型输入进行故障标签识别。

文献[18]设计了一种动态加权GCN方法,克服了原始信号中外部噪声的负面影响。

尽管上述研究在声纹信号故障诊断方面取得了显著的改进,但仍存在一些不足。首先,现有的声纹故障诊断方法缺乏有效的高级空间邻近关联建模能力,使得这些算法无法准确地捕捉信号间的空间依赖关系;其次,这些方法在分配特征网络权重时通常未考虑信号分布之间的时间相似性和相关性,导致无法捕捉声纹信号之间的重要时间关系;最后,当前基于GCN的故障诊断研究大多以 k 近邻图作为输入,通过调整 k 值的超参数来控制图结构复杂度,这种构建声纹图的方式缺乏动态调整并同时捕捉构建的声纹图复杂时空关系的能力,导致GCN的适应性和表达能力不佳。

为了解决上述挑战,本文面向电机轴承故障声纹识别,提出一种动态时空子图卷积网络(Dynamic Spatial-Temporal Subgraph Convolutional Network, DSTSGCN),该网络能够自适应地捕捉信号之间的空间-时间关系,并实现低消耗的图级故障诊断。与现有的声纹故障诊断方法相比,DSTSGCN基于滑动窗口分割和声纹信号的周期性,同时考虑了声纹信号的空间邻近相关性和时间相似性。

此外,为了提升不同空间依赖性信号的区分度,设计了一种边动态图卷积网络 (Edge-Level Dynamic GCN, ELDGCN),其核心动态边算法 (Dynamic Edge Algorithm, DEA) 可通过边权重的动态优化机制有效捕捉声纹信号间的高阶空间邻域关联;然后,结合交叉自注意力 (Cross-Self-Attention, CSA) 和扩张因果卷积 (Dilated Causal Convolution, DCCConv) 构建了一种时间特征融合模块 (Temporal Feature Fusion Module, TFFM),旨在强化信号间时序相似性关联,同步实现声纹图数据的高效融合与多尺度依赖关系捕获。采用真实三相异步电机平台收集的声纹电机轴承故障数据进行测试,验证所提方法的性能。

1 面向电机轴承故障诊断的动态时空子图卷积网络

所提故障诊断方法的整体流程如图 1 所示。

流程主要包括 5 个部分:1) 收集的声纹信号经过 Mel 频率倒谱 (频谱) 系数和串行化方法进行预处理;2) 采用最小二阶图分解策略构建声纹信号的原始输入子图;3) 使用 ELDGCN 优化子图结构,提取声纹信号之间的高级空间邻近特征;4) 将高级特征输入 TFFM,突出信号之间的时间相似性关联和多尺度时间特征融合;5) 将融合的深层特征输入 Sigmoid 函数进行监督训练,实现图级故障诊断。




图 1 所提故障诊断方法的整体流程

1.1 边动态图卷积网络

CNN 专注于信号内部特征提取,而忽略它们之间的潜在连接。然而,声纹信号之间存在复杂的潜在联系,如空间邻近关系以及时间序列上声纹特征的相似性,这些联系通常呈现非线性和非平稳特征。不同于 CNN,GCN 可以通过在图结构上的卷积操作自然地揭示声纹信号之间的复杂相互作用,其中节点和边分别表示信号和它们之间的关系。由于其能够捕获输入数据之间的额外信息,GCN 已经被广泛研究^[19-21]。

在基于声纹的故障诊断中,通过 GCN 聚合邻近信号的表示,可以有效地提取声纹信号之间的空间特征;因此,在图领域中可以提供更多的声纹故障信息,从而增强声纹故障诊断的准确性和鲁棒性。

对于一个给定的图 $G=(O,E,F,A)$, O 为图节点集合, E 为集合边, F 为特征矩阵, A 为邻接矩阵。

邻接矩阵 A 中的元素 $a_{i,j}$ 表示为:

$$a_{i,j} = \begin{cases} 1 & \text{if nodes } O_i \text{ and } O_j \text{ are connected} \\ 0 & \text{if nodes } O_i \text{ and } O_j \text{ are unconnected} \end{cases} \quad (1)$$

式中: i 和 j 为节点。

图卷积的特征提取过程可以表示为:

$$F' = \hat{D}^{-1/2} \hat{A} \hat{D}^{-1/2} F W + b \quad (2)$$

式中: F' 为圈卷积提取的特征; $\hat{D}$ 为 $\hat{A}$ 的对角度矩阵, $\hat{D} \in \mathbf{R}^{n \times n}$, $\hat{A}$ 为具有加性自环的邻接矩阵, $\hat{A} = A + I$, I 为单位矩阵; W 为可学习矩阵; b 为偏置。

基于 GCN 的故障诊断的主要挑战是如何定义节

点之间的关系,即边的构建。在各种构建边的方法中,基于 KNNG 构建静态网络图是一种广泛使用的技术。通过计算节点之间的欧氏距离,每个节点与其 k 个最近邻节点相连。然而,基于 KNNG 方法的诊断结果对 k 值的选择非常敏感,而且无法为不同的数据集确定最佳的 k 值,导致稳定性不足。这是因为过多的邻居会引入不相关的邻域特征,而较少的邻居则无法提供足够的信息。此外,对于给定节点,其 k 个邻居之间的边连接具有相同的优先级,因此适应性较差。为了优化构建图的质量,提出了 ELDGCN 以改善模型对不同数据的适应性,ELDGCN 结构如图 2 所示。




图2 ELDGCN 结构

ELDGCN 采用 DEA 构建,过程如式(3)~式(5)所示。通过学习边的重要性分布,构造一个节点相关矩阵 M 来捕获节点间关系。然后,自适应地分配边的权重,并动态更新邻接矩阵 A ,对图进行优化。

$$M_l = F_l F_l^T \quad (3)$$

$$\hat{A}_{l+1} = \text{Softmax}(M_l) \otimes \hat{A}_l \quad (4)$$

$$F_{l+1} = \hat{D}_{l+1}^{-1/2} \hat{A}_{l+1} \hat{D}_{l+1}^{-1/2} F_l W_{l+1} \quad (5)$$

式中: l 为网络层数; $\otimes$ 为元素级乘法。

通过 DEA 来自适应地提取关键的空间特征,有助于改善 GCN 对声纹信号的适应性。与基于 KNNG 的方法相比,节点之间边连接的优先级被重新分配,从而提高了 GCN 的表达能力和适应性。

1.2 时间特征融合模块

为了捕捉声纹信号中关键的长期依赖性,并有效突出它们之间的时间相关性,在 ELDGCN 之后添加一个 TFFM 以获取更多的时间特征细节。TFFM 的设计结合扩张因果卷积(Dilated Causal Convolution, DCCConv)和

CSA^[22-23],组成 CSA-DCCConv 模块的基础结构如图 3 所示。




图3 CSA-DCCConv 模块的基础结构

与通过链式结构捕获序列信息的循环神经网络相比,DCCConv 不依赖于先前计算就可以生成当前的输出,具有更高的计算效率。

DCCConv 通过调整扩张因子来改变卷积核的感受野以捕获更长的序列依赖关系,从而缓解了梯度消失问题。在多尺度时间特征提取阶段,TFFM 采用层级递进式融合策略,通过 3 组尺寸分别为 3×1 、 5×1 和 7×1 的 DCCConv 核对输入特征进行多尺度时序建模,还使用 1×1 的卷积核来结合全局节点信息,每组 DCCConv 输出的特征映射表示为 H_t^n 。随后,采用拼接操作将多尺度特征沿通道维度融合 $H_t^{\text{fusion}} = [H_t^1; H_t^2; H_t^3]$,形成包含局部细节与全局趋势的混合时序表征。具体而言,在时刻 t ,经多尺度 DCCConv 处理后,网络第 $l+1$ 层的时间特征表示 $H_{l+1}(t)$ 为:

$$H_{l+1}(t) = \text{CON}_{n=1}^3 \left(\sum_{k=0}^{K_n-1} W_n(k) \cdot H_l(t - d_n \cdot k) \right) \quad (6)$$

式中: n 为不同尺度的数量; K_n 为卷积核尺寸; W_n 为卷积核权重; d_n 为扩张率; $\text{CON}(\cdot)$ 为拼接操作。

在完成多尺度时间特征提取的基础上,构建 CSA 层进行特征选择和融合。将融合后的特征矩阵按节点对拆分为 H_1 和 H_2 ,分别通过可学习的权重矩阵 W^Q 、 W^K 、 W^V 生成查询(Q_1, Q_2)向量、键(K_1, K_2)向量和值向量(V_1, V_2)。通过跨节点注意力计算 H_1 和 H_2 ,实现节点间时序特征的交互增强。最终,将跨节点注意力输出 $\hat{H}_1$ 和 $\hat{H}_2$ 与原始特征进行连接,并通过

1×1 卷积压缩通道维度,形成兼具多尺度感知与时序依赖强化的融合特征,这个过程表示为:

$$\begin{cases} \mathbf{Q}_1 = \mathbf{H}_1 \mathbf{W}^{\mathbf{Q}_1} \\ \mathbf{K}_1 = \mathbf{H}_1 \mathbf{W}^{\mathbf{K}_1} \\ \mathbf{V}_1 = \mathbf{H}_1 \mathbf{W}^{\mathbf{V}_1} \end{cases} \quad (7)$$

$$\begin{cases} \mathbf{Q}_2 = \mathbf{H}_2 \mathbf{W}^{\mathbf{Q}_2} \\ \mathbf{K}_2 = \mathbf{H}_2 \mathbf{W}^{\mathbf{K}_2} \\ \mathbf{V}_2 = \mathbf{H}_2 \mathbf{W}^{\mathbf{V}_2} \end{cases} \quad (8)$$

$$\hat{\mathbf{H}}_1 = \text{Softmax} \left(\frac{\mathbf{Q}_2 \mathbf{K}_2^T}{\sqrt{d_k}} \right) \mathbf{V}_1 \quad (9)$$

$$\hat{\mathbf{H}}_2 = \text{Softmax} \left(\frac{\mathbf{Q}_1 \mathbf{K}_1^T}{\sqrt{d_k}} \right) \mathbf{V}_2 \quad (10)$$

式中: $\mathbf{Q}_1$ 、 $\mathbf{Q}_2$ 、 $\mathbf{K}_1$ 、 $\mathbf{K}_2$ 、 $\mathbf{V}_1$ 和 $\mathbf{V}_2$ 分别是查询向量、键向量和值向量; $\mathbf{H}$ 和 $\hat{\mathbf{H}}$ 为输入和输出矩阵; $\mathbf{W}^{\mathbf{Q}}$ 、 $\mathbf{W}^{\mathbf{K}}$ 、 $\mathbf{W}^{\mathbf{V}}$ 为对应于查询向量、键向量和值向量的可学习权重矩阵; d_k 为键向量 $\mathbf{K}$ 的维度。通过在时间序列中为更关键的时间步骤分配更高的权重,CSA-DCCConv 可以捕获节点内的长期依赖关系,使注意力权重与节点之间的关系密切相关,突出节点间的相关性。

与仅在单个节点内建立连接的自注意力相比,CSA 可以利用节点间上下文信息,聚焦于节点内关键的时间序列特征;因此,CSA 可以更有针对性地从一个节点中提取对另一个节点有用的信息,提高信息利用效率和模型的泛化能力。

本文通过 CSA 同时捕获节点间和节点内的依赖关系,通过融合时间交互作用,为声纹图数据捕获了更复杂和多尺度的依赖关系。

1.3 基于 DSTSGCN 的故障诊断框架

为了提高深度学习模型捕获声纹数据之间空间-时间特征的能力,提高电机轴承故障诊断的准确性,提出一种基于 DSTSGCN 的非接触电机轴承故障诊断框架,DSTSGCN 的结构如图 1b) 所示。

首先,将原始图分解为多个子图以降低输入复杂性,并使用 ELDGCN 层提取声纹信号的空间特征;其次,利用 TFFM 提取时间特征,通过全局平均池化和全局最大池化在节点之间进行特征融合,以获得图级全局信息;最后,采用具有 Sigmoid 激活函数的全连接层,获得节点间相似度得分,以进行分类。

通过 DSTSGCN 捕获声纹信号之间的空间-时间信息,提高故障诊断的性能。ELDGCN 和 TFFM 串联的顺序基于文献[24]和实际实验结果确定,通过在

TFFM 之前放置 ELDGCN,可以在 TFFM 进行时间融合之前提取和表示空间依赖关系,实现了更好的性能。DSTSGCN 的详细信息如下。

1) 输入: DSTSGCN 的输入是由声纹信号构建的图,包括节点和边。在 DSTSGCN 中,每个样本被视为一个节点。首先,使用 Mel 频率倒谱系数 (Mel Frequency Cepstral Coefficients, MFCC)^[25] 对样本进行预处理,以有效地提取轴承正常状态和故障状态之间的显著特征,MFCC 特征提取过程如图 1a) 所示。

然后执行最小二阶子图分解策略,对于一个样本 $\mathbf{X} \in \mathbf{R}^{L \times 1}$,其对应的 MFCC 特征为 $\mathbf{X}_{\text{MFCC}} \in \mathbf{R}^{N_{\text{MFCC}} \times T}$,其中 L 为样本长度, N_{MFCC} 为 MFCC 特征数量, T 为时间帧数量。按照时间帧序列化 $\mathbf{X}_{\text{MFCC}}$ 得到节点特征 $\mathbf{F} \in \mathbf{R}^{TN_{\text{MFCC}} \times 1}$ 。对于每个类别 C 中给定的 N 个样本数据,首先构建一个具有 $(CN)^2$ 个边的全连接有向图,然后原始图按节点分成 $CN(CN+1)/2$ 个二阶子图,最后对每个子图的邻接矩阵 $\mathbf{A} \in (0, 1]$ 进行随机初始化。DSTSGCN 的输入是多个最小二阶子图,显著降低了图的复杂性,有利于进行图级故障诊断。

2) 输出: DSTSGCN 的输出是介于 0~1 之间的得分因子 S ,用于衡量子图中节点之间的相似性。根据节点是否属于相同类别,将子图标记为相似 ($S=1$) 和不相似 ($S=0$)。将节点级多分类任务转化为图级回归任务,简化并提高了模型的泛化能力。

3) 训练和测试: DSTSGCN 的详细结构参数如表 1 所示。

表 1 DSTSGCN 的详细结构参数

模型	层	结构
DSTSGCN	GCN	64
	DEA	—
	GCN	32
	CSA-DCCConv	$64(3 \times 1, d=2) - 64(5 \times 1, d=2) - 64(7 \times 1, d=2)$

采用交叉熵损失函数和 Adam 模型优化器来训练所提出的 DSTSGCN。交叉熵损失函数 $L(S, y)$ 可以表示为:

$$L(S, y) = -[y \ln(S) + (1-y) \ln(1-S)] \quad (11)$$

式中: y 为标签,如果输入节点属于同一类, $y=1$,否则 $y=0$ 。

使用 dropout 策略和批量归一化来防止过拟合。图级故障诊断采用一次性测试,如图 1c) 所示。支持集与测试节点配对,形成用于输入的测试子图集,该集必须识别出测试节点属于的支持集类别。

2 实验与分析

为了充分验证所提出的 DSTSGCN 的有效性,本文建立了一个真实的三相异步电动机实验平台来收集故障数据。此外,所有实验和模型架构均使用了 Spektral 1.3 和 TensorFlow 2.6 实现。

2.1 实验平台与数据采集

三相异步电机实验平台如图 4 所示,实验平台由一台 2 200 W 的电机、10 种不同健康状态的 SKF 滚动轴承以及一个声纹传感器组成。声纹传感器为带有 VS1053 芯片的 STM32 微控制器,采样频率为 8 kHz。实验考虑了一个正常轴承(Normal Bearing, NB)和 9 种故障轴承,具体的故障类型包括外圈故障(Outer race Fault, OF)、内圈故障(Inner race Fault, IF)和滚珠故障(Ball Fault, BF)。每种类型的故障轴承分别具有 3 个损伤等级:H-0.5 mm、M-0.3 mm 和 L-0.1 mm。9 种轴承故障类型通过人为加工模拟实现,具体采用电火花加工法,在轴承的指定位置制造不同尺寸的凹槽或裂纹,以模拟实际运行中因磨损或冲击导致的渐进性缺陷。




图 4 三相异步电机实验平台

通过调整 DWZ-3 盘式涡流制动器和速度控制器,获得了由负载为 1 A、2 A 和转速为 20 Hz、40 Hz 组成的 3 种工作状态。表 2 所示为轴承声纹实验数据,其描述了 3 种不同工作条件下的最终数据集 A、数据集 B、数据集 C 的细节。

根据图 1a),收集到的声纹信号首先经过 MFCC 特征提取,对每个样本 X 进行预处理,采用滑动窗口法获得 10 种故障类型的 2 000 个样本,移动步长为 512,窗口长为 2 048。然后对分帧加窗后的每帧声纹数据进行快速傅里叶(FFT)变换,计算谱线能量,并通过 Mel 滤波组对谱线能量谱进行滤波,最后对每帧信

号进行离散余弦变换(DCT),获得声纹信号的 MFCC 序列化特征 X_{MFCC} ,并进行最大最小归一化:

$$X_{MFCC_{norm}} = \frac{X_{MFCC} - X_{MFCC_{min}}}{X_{MFCC_{max}} - X_{MFCC_{min}}} \tag{12}$$

式中: $X_{MFCC_{min}}$ 和 $X_{MFCC_{max}}$ 为 X_{MFCC} 的最大值和最小值; $X_{MFCC_{norm}}$ 为输入节点特征。

特征矩阵 $F \in \mathbf{R}^{2 \times 200}$,邻接矩阵 $A \in \mathbf{R}^{2 \times 2}$,MFCC 特征数量 $N_{MFCC} = 40$ 。

表 2 轴承声纹实验数据

标签	故障类别	数据集 A 负载/转速/ 样本量	数据集 B 负载/转速/ 样本量	数据集 C 负载/转速/ 样本量
0	BF-H	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
1	BF-M	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
2	BF-L	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
3	IF-H	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
4	IF-M	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
5	IF-L	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
6	OF-H	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
7	OF-M	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
8	OF-L	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200
9	NB	1 A/20 Hz/200	1 A/40 Hz/200	2 A/20 Hz/200

经过预处理,得到的信号预处理如图 5 所示。

从图 5 所示可知,经 MFCC 预处理后,信号的频谱特征可以压缩到更低维度,同时保留了关键的声学信息,减少了高频细节冗余,更有利于图节点对故障特征的提取。此外,DSTSGCN 的 TFFM 模块中的 CSA 利用节点间上下文信息,可以更有针对性地从一个节点中提取对另一个节点有用的信息。为了清晰地展示 CSA 对节点特征提取的有效性,图 6 所示为应用 CSA 后的特征热图。

从图 6 所示可知,CSA 在时频域表现出显著的高能量响应,模型能够更为有效地捕捉声纹信号的关键时频特征,说明其通过跨节点信息交互捕获了更丰富的上下文关联。

2.2 有限数据下的实验比较

2.2.1 对比方法

实验使用不同数量的训练样本来评估所提出的 DSTSGCN 的准确性。此外,还将所提 DSTSGCN 与其他基于声纹的模型进行了比较,分别为 DGCN^[15]、RDL^[26]、Mel-CNN^[13]、XACNN^[14]、POWG^[16]、ACMFDS^[27]、GAT^[28]、TCN^[29]、DeiT^[30] 和 Swin Transformer^[31]。对这些算法的参数进行微调,以达到最佳性




图5 信号预处理




图6 应用 CSA 后的特征热图

能,保证实验结果的可靠性。

DGCN^[15]利用输入特征矩阵 $F \in \mathbf{R}^{2048 \times 1}$ 和邻接矩阵 $A \in \mathbf{R}^{2048 \times 2048}$ 构建了来自单个声纹样本的静态图,

DGCN 包括 3 个图卷积块 (128-64-32) 和两个全连接层 (32-10), 每个图卷积块包含图卷积层、图粗化层和图池化层。

RDL^[26]对声纹信号进行预处理,提取 Mel 频谱特征 $F_{\text{Mel}} \in \mathbf{R}^{40 \times 9 \times 1}$, Mel 滤波器的数量为 40。RDL 基于注意力机制构建了一个多阶段噪声降低模块,以获得清晰的频谱,然后采用“拼接”方法将从多尺度卷积中提取的特征进行融合,以充分提取声纹信号中的故障信息。

Mel-CNN^[13]的输入端为 $F_{\text{Mel}} \in \mathbf{R}^{128 \times 65 \times 1}$, 然后使用 3 个二维卷积块 (32-64-128) 和 3 个全连接层 (1024-512-10) 进行特征提取。卷积块包含一个二维卷积层、批归一化层和全局最大池化层。

XACNN^[14]采用绝对值快速傅里叶变换,获得声纹信号上的频域特征 $F_{\text{AVFFT}} \in \mathbf{R}^{2048 \times 1}$ 。基于 Transformer 的 Inception 自注意力模块被设计用于优化故障诊断模型,并提高对噪声的鲁棒性。

考虑到传统基于 KNNG 的方法中边的冗余性, POWGCN^[16]引入了剪枝优化操作来增强输入图的质量。POWGCN 使用输入特征矩阵 $F \in \mathbf{R}^{n \times 64}$ 和邻接矩阵 $A \in \mathbf{R}^{n \times n}$ 构建声纹样本之间的静态图,其中 n 表示节点的数量。POWGCN 包括 3 个切比雪夫图卷积层 (128-64-32) 和两个全连接层 (32-10)。

ACMFDS^[27]对声纹信号进行预处理,提取 MFCC 特征 $F_{\text{MFCC}} \in \mathbf{R}^{200 \times 1}$ 。基于隐性马尔可夫模型设计了一种自动、非侵入式的状态监测系统,旨在在复杂的操作条件下实现基于声纹的故障诊断。

为了提高 GCN 的特征提取能力,GAT^[28]提出了一种具有自注意力机制的图注意力网络。为了比较结果的严谨性,GAT 的输入与 DSTSCGN 相同。GAT 包括两个图注意力层 (64-32) 和两个全连接层 (32-10)。

TCN^[29]是一种基于迁移学习的 Transformer 与 CNN 的混合模型,将信号分块输入 Transformer 提取全局特征,CNN 解码分类,通过源域预训练和目标域微调解决数据不足问题,有效解决了小样本旋转机械故障诊断问题。

DeiT^[30]是一种高效的 Transformer 网络,该模型通过蒸馏技术来减小 Transformer 网络规模,同时不牺牲模型性能。

Swin Transformer^[31]是 Transformer 的一种变体,该模型通过采用移位窗口自注意力机制和图像块合并技术,从而获得更高的计算效率。实验中 4 个阶段的多头自注意力层头数分别设置为 2、4、6 和 8。

2.2.2 对比实验

考虑到真实场景中有限数据的影响,为每种故障类型提取了1、2、3、10、20和30个样本作为训练集。此外,测试集由所有10种类型的500个样本组成,训练和测试样本没有重叠,采用一次性测试来评价所提

DSTSGCN 的有效性。

为避免结果的随机性,针对每个随机数据集重复进行5次训练和测试实验,比较实验的结果如图7a)所示,其对应的 Few-shot 学习曲线如图7b)所示。此外,表3所示为不同训练样本量下模型准确率比较。




图7 模型性能比较

表3 不同训练样本量下模型准确率比较

模型	不同训练样本量下模型准确率/%					
	1	2	3	10	20	30
DGCN ^[15]	65.36(±5.93)	64.17(±5.32)	68.89(±5.10)	80.76(±3.36)	81.70(±1.10)	82.05(±0.35)
RDL ^[26]	91.16(±1.32)	91.84(±1.80)	96.40(±0.04)	92.65(±3.24)	97.91(±0.05)	95.14(±1.21)
Mel-CNN ^[13]	96.97(±1.20)	89.61(±4.42)	96.01(±2.11)	98.06(±1.07)	100.00(±0.00)	100.00(±0.00)
XACNN ^[14]	75.80(±9.19)	69.73(±10.65)	74.72(±7.47)	79.27(±5.65)	81.55(±4.31)	85.60(±3.22)
POWGCN ^[16]	41.76(±15.82)	50.00(±12.32)	79.41(±9.34)	88.30(±3.12)	89.37(±1.22)	94.33(±0.39)
ACMFDS ^[27]	91.78(±1.81)	91.76(±1.21)	94.65(±1.10)	99.18(±0.80)	100.00(±0.00)	100.00(±0.00)
GAT ^[28]	71.22(±10.32)	71.98(±9.85)	73.71(±9.33)	85.96(±3.80)	97.37(±0.11)	100.00(±0.00)
TCN ^[29]	90.64(±3.75)	92.71(±3.14)	93.29(±2.67)	99.37(±0.29)	100.0(±0.00)	100.00(±0.00)
DeiT ^[30]	90.39(±4.68)	92.56(±3.82)	93.77(±2.56)	95.28(±1.53)	96.65(±1.27)	98.35(±1.08)
Swin Transformer ^[31]	86.45(±6.25)	89.87(±4.73)	90.04(±4.21)	92.56(±2.36)	93.98(±1.69)	96.17(±0.87)
DSTSGCN	99.27(±0.03)	100.00(±0.00)	100.00(±0.00)	100.00(±0.00)	100.00(±0.00)	100.00(±0.00)

从图7a)和表3所示可以看出,大多数模型的准确性对训练数据集的样本量非常敏感,在小样本场景下准确率不足。例如,仅有1个训练样本时,所提DSTSGCN平均准确率达到99.27%,比其他方法平均提高了22.96%,而对比方法中表现最优的Mel-CNN仅达到96.97%,准确率较低。这是因为深度学习模型容易出现过拟合现象,在小样本下缺乏鲁棒性。从图7b)所示也可以看出,DSTSGCN的准确率随训练样本量增加呈平滑上升趋势,且在样本量=1时已接近100%,显著优于其他模型。对比其他GCN方法,其学习曲线一直在高准确率值上平滑变化,表明模型能更高效地利用有限样本,具有强大的小样本泛化能力。而Mel-CNN等模型在样本量>10后性能才能逐渐达到饱和,说明其在小样本场景下的泛化能力受

限。此外,现有的基于图神经网络的方法(如DGCN、POWGCN、GAT)在有限数据下表现较差,这是由于这些方法中固定的边权重导致模型对故障信息提取不足和时间特征提取不足。TCN在样本量为1时准确率为90.64%,其准确率虽然随样本量增加快速收敛至100%,但其小样本稳定性显著低于DSTSGCN。而DeiT和Swin Transformer在样本量为30时准确率分别仅达98.35%和96.17%,较DSTSGCN存在明显性能差距且误差范围扩大了2~3倍。

综合比较结果,由于其学习重要故障信息的能力,所提DSTSGCN优于现有方法。为了进一步验证所提模型的性能,其 F_1 分数结果如表4所示。

从表4所示可知,DSTSGCN在所有类别的诊断结果中 F_1 分数均超过96%,且大部分诊断结果均达到

100 %, 这表明尽管样本量受限, 所提方法仍能准确地实现故障信息的分类和识别, 且能够在二阶子图的各种工况下取得较好的诊断性能, 验证了其在有限数据下的有效性和鲁棒性。

表 4 测试结果的 F_1 分数 (数据集 A/B/C)

故障类型	不同训练样本量下测试的 F_1 分数					
	1	2	3	10	20	30
BF-H	100/100/98.34	100/100/99.54	100/100/99.89	100/100/100	100/100/100	100/100/100
BF-M	100/99.87/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100
BF-L	99.69/100/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100
IF-H	99.65/100/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100
IF-M	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100
IF-L	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100
OF-H	99.19/100/98.78	100/100/99.12	100/100/100	100/100/100	100/100/100	100/100/100
OF-M	99.27/100/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100
OF-L	99.69/96.79/97.76	100/98.58/99.57	100/99.39/100	100/100/100	100/100/100	100/100/100
NB	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100	100/100/100

2.3 消融实验

为了进一步阐明 DEA 和 TFFM 在 DSTSGCN 中对小样本下故障诊断的贡献, 进行消融实验来验证所提出的 DEA 和 TFFM 的有效性。在消融实验中, 设置 4 种模型方案, 分别为 A: 从 ELDGCN 中移除 DEA; B: 移除 TFFM; C: 移除 DEA 和 TFFM; D: DSTSGCN。对这 4 种模型性能进行比较分析, 准确率结果如表 5 所示。

表 5 不同训练样本下消融实验各模型准确率比较

样本量	不同方案下的准确率/%			
	A	B	C	D
1	91.49	84.88	76.13	99.27
2	91.69	91.84	87.75	100.00
3	93.56	98.22	92.44	100.00
10	99.88	100.00	97.01	100.00
20	100.00	100.00	100.00	100.00
30	100.00	100.00	100.00	100.00
平均值	96.10	95.82	92.22	99.88

此外, 为直观地展示不同模型之间的性能差异, 将比较结果展示在图 8 中, 图 8 所示为消融实验中各方案在不同样本量时的准确率变化。

从表 5 所示可知, DEA 和 TFFM 的引入显著提高了模型的准确性, 尤其是在训练样本量较小的情况下。例如, 仅使用 1 个训练样本时, 所提 DSTSGCN 的准确率比方案 C 提高了 23.14 %。这是因为 DEA 能够动态优化子图的边, 使其在邻居较少的情况下具有高度适应性, 有利于小样本情况下的空间特征提取。与 DSTSGCN 相比, 方案 B 的性能平均降低了 4.06 %, 这证明了所提出的 TFFM 能够自适应地捕获和融合节点之间的长期依赖信息, 并有效提高 GCN 的时间特征提取能力。此外, 在样本量仅为 1 时, 方案 A 的准确

率比方案 B 提高了 6.61 %, 表明当样本量非常小时, TFFM 发挥着更为关键的作用, 而 DEA 的有效性随着样本量的增加而变得显著。这是因为随着样本量的增加, 时间特征提取遇到了瓶颈。此外, DSTSGCN 分解的子图中还包含更多的冗余边, 使得图的质量更加重要。图 9 所示为消融实验中各方案在样本量为 1 时的混淆矩阵。




图 8 消融实验中各方案在不同样本量时的准确率变化

从图 9 所示可以看出, 除 OH 和 OL 可能有一些误检外, DSTSGCN 对所有其他故障的识别准确率均达到 100 %。去除 DEA 和 TFFM 后, IH、IL、OL、OM 的误检率明显提高, OH 的准确率也有轻微下降。这一结果验证了所提方法在电机轴承故障诊断任务中的有效性, 其可以精准提取不同轴承状态的特征, 准确地对故障类型进行识别并分类。

2.4 图分解分析

基于图卷积网络 GCN 方法的诊断结果对输入图的复杂性高度敏感, 现有的图构建方法通常需要足够的节点来提供充足的信息以实现高精度诊断, 这会导




图9 消融实验中各方案在样本量为1时的混淆矩阵

致计算耗时较长。考虑到实际场景中小样本的局限性,本文采用最小二阶图分解策略来提高所提方法的计算效率,并将其与其他基于 GCN 的方法进行对比,不同的基于 GCN 模型实现最佳性能耗时比较结果如表 6 所示。

表 6 不同的基于 GCN 模型实现最佳性能耗时比较结果

时间	不同模型下的参数值			
	DGCN	POWGCN	GAT	DSTSGCN
训练时间/s	655	483	302	233
诊断时间/s	11.16	7.48	6.31	3.37

从表 6 所示可知,DSTSGCN 实现最佳性能所需时间仅为 233 s,相较于其他 3 种基于 GCN 的方法分别减少了 422、250、69 s,证明了该策略对提高训练效率的有效性。同时,在诊断运行时间方面,DSTSGCN 用时 3.37 s,远低于其他 3 种基于图卷积网络模型的运行时间,具有相对较高的故障诊断效率。

2.5 噪声鲁棒性验证

为验证所提方法在噪声环境下的鲁棒性,针对采集到的轴承故障数据进行了噪声鲁棒性实验。实验采用高斯白噪声模拟传感器电子噪声,按信噪比 (Signal to Noise Ratio, SNR) 设定为 -10、0、10、20 和 40 dB 这 5 个等级生成带噪测试数据集,并与几种故障诊断模型进行对比,噪声鲁棒性验证结果如图 10 所示。




图 10 噪声鲁棒性验证结果

DSTSGCN 在信噪比 SNR 为 20 和 40 dB 的噪声条件下表现良好,相较于 RDL、Mel-CMM、ACMFDS 和 GAT 在准确率上均表现出较高提升。随着噪声强度增加,局部相关特征不可避免地会引入噪声干扰,这使得 DSTSGCN 的性能受到负面影响。在 SNR 为 10 dB 的环境下,DSTSGCN 的准确率下降较为明显,且在强噪声场景 SNR 为 -10 dB 时,准确率不足 90 %,但仍

高于其他几种对比方法。尽管 DSTSGCN 的故障诊断能力会随噪声强度增加而减弱,导致精度逐渐下降,但是其故障诊断性能仍优于其他几种主流模型,且在弱噪声场景中性能受影响程度较低,具有较高的鲁棒性能。

3 结语

为解决非接触式电机轴承故障诊断中存在的时空特征捕捉能力不足、图结构动态调整机制缺失及小样本适应性差的问题,提出了一种基于动态时空子图卷积网络的故障诊断模型 DSTSGCN。

DSTSGCN 是一种图级故障诊断技术,以由原始声纹信号构造的子图作为输入,并输出子图中的节点间相似度得分。设计了一种 DEA 算法,并集成到 GCN 中,通过节点相关矩阵捕获节点间关系,以优化边的权重,自适应地提高了 GCN 的空间特征提取能力。此外,DSTSGCN 还基于声纹信号的长期依赖特性结合 DCCConv 和 CSA 构建了一个 TFFM 模块,用以同时捕获节点内部关键的多尺度长期关系,并突出子图中节点间的相关性。实验结果表明,在训练样本数量不同的条件下 DSTSGCN 的准确率均优于其他 7 种基于声纹的故障诊断模型,特别是在仅有 1 个训练样本时,所提方法准确率仍能达到 99.27%,且在 10 类故障诊断任务中,DSTSGCN 的 F_1 分数均超过 96%,且多数类别达到 100%,具有较高的稳定性和小样本鲁棒性。此外,通过图分解策略,模型训练耗时仅为 233 s,诊断耗时仅为 3.37 s,优于其他基于 GCN 的故障诊断方法,为工业实时监测提供了可行性。

DSTSGCN 在工业非接触式电机轴承故障诊断任务中具有高效、高精度优势。然而,TFFM 模块的计算复杂度随序列长度呈线性增长,对超长时序处理效率有待优化。此外,强噪声环境下的诊断精度下降较为明显,未来工作将专注于强噪声下的小样本故障诊断问题。

参考文献:

- [1] 童靳于,唐世钰,郑近德,等.基于自适应深度残差网络的旋转机械故障诊断方法[J].振动与冲击,2024,43(20):162-171.
- [2] 戴计生,丁荣军,付勇,等.基于谱估计和中心峭度的电机轴承故障诊断[J].铁道科学与工程学报,2024,21(10):4344-4356.
- [3] LIU Z,ZHANG L.Condition monitoring and fault diagnosis methods for large-scale wind turbine bearings[J].Measure-

ment,2020,149:107002.

- [4] 刘杰,谭玉涛,杨娜.强噪声下基于 ACYCBD-MTF-Mobile-ViT 的轴承故障诊断研究[J].振动与冲击,2024,43(24):34-47.
- [5] 强睿儒,赵小强.基于格拉姆角差场和生成对抗网络的小样本滚动轴承故障诊断方法[J].华南理工大学学报(自然科学版),2024,52(10):64-75.
- [6] ZHAO D,LIU S,DU H,et al.Deep branch attention network and extreme multi-scale entropy based single vibration signal-driven variable speed fault diagnosis scheme for rolling bearing[J].Advanced Engineering Informatics,2023,55:101844.
- [7] TANG J,ZHENG G,WEI C,et al.Signal-transformer:A robust and interpretable method for rotating machinery intelligent fault diagnosis under variable operating conditions[J].IEEE Transactions of Instrumentation and Measurement,2022,71:1-11.
- [8] 王寅杰,邓艾东,范永胜,等.基于改进 PNCC-SVM 的滚动轴承故障声纹识别方法[J].噪声与振动控制,2024,44(3):146-151,164.
- [9] AWADA E,AI-QAISI A,RADWAN E,et al.Motor fault detection using sound signature and wavelet transform[J].International Journal of Power Electronics and Drive Systems,2022,13(1):247-255.
- [10] ZHANG D,ENTEZAMI M,STEWART E,et al.Wayside acoustic detection of train bearings based on an enhanced spline-kernelled chirplet transform[J].Journal of Sound and Vibration,2020,480:115401.
- [11] LIU C,WU X,MAO J,et al.Acoustic emission signal processing for rolling bearing running state assessment using compressive sensing[J].Mechanical Systems and Signal Processing,2017,91:395-406.
- [12] YAO Y,GUI G,YANG S,et al.A recursive denoising learning for gear fault diagnosis based on acoustic signal in real industrial noise condition[J].IEEE Transactions of Instrumentation and Measurement,2021,70:1-15.
- [13] SHAN S,LIU J,WU S,et al.A motor bearing fault voiceprint recognition method based on mel-CNN model[J].Measurement,2023,207:112408.
- [14] FANG H,AN J,LIU H,et al.A lightweight transformer with strong robustness application in portable bearing fault diagnosis[J].IEEE Sensors Journal,2023,23(9):9649-9657.
- [15] ZHANG D,WTEWART E,ENTEZAMI M,et al.Intelligent acoustic-based fault diagnosis of roller bearings using a deep graph convolutional network[J].Measurement,2020,156:107585.
- [16] ZHANG X,JIANG L,WANG L,et al.A pruned-optimized weighted graph convolutional network for axial flow pump

- fault diagnosis with hydrophone signals[J].Advanced Engineering Informatics,2024,60:102365.
- [17] YANG C,ZHOU K,LIU J.SuperGraph: Spatial-temporal graph-based feature extraction for rotating machinery diagnosis[J].IEEE Transactions on Industrial Electronic,2022,69:4167-4176.
- [18] ZHANG X,HU Y,LIU J,et al.Robust rotating machinery diagnosis using a dynamic-weighted graph updating strategy[J].Measurement,2022,202:111895.
- [19] 吴志泽,陈盛,檀明,等.基于跨通道特征增强图卷积网络的骨架行为识别[J].模式识别与人工智能,2024,37(8):703-714.
- [20] 温楷儒,陈祝云,黄如意,等.基于可解释时空图卷积网络的多传感数据融合诊断方法[J].机械工程学报,2024,60(12):158-167.
- [21] 宁少慧,任永磊,武煜坤,等.基于图卷积网络的滚动轴承智能故障诊断[J].组合机床与自动化加工技术,2023(3):113-117.
- [22] 周蜀杰,曾园园,江昊.基于扩张因果卷积的城市客流量预测算法[J].武汉大学学报(工学版),2023,56(2):218-225.
- [23] CHEN C,FAN Q,PANDA R.CrossViT: Cross-attention multiscale vision transformer for image classification[C]//Proceedings of IEEE/CVF International Conference on Computer Vision. Montreal:IEEE Press,2021:357-366.
- [24] HU J,LIANG Y,FAN Z,et al.Graph neural processes for spatio-temporal extrapolation [C]//Proceedings of ACM SIGKDD Conference on Knowledge Discovery and Data Mining.Long Beach:ACM Press,2023:752-763.
- [25] ABDUL Z,AL-TALABANI A.Mel frequency cepstral coefficient and its applications: A review [J]. IEEE Access,2022,10:122136-122158.
- [26] YAO Y,GUI G,YANG S,et al. A recursive denoising learning for gear fault diagnosis based on acoustic signal in real industrial noise condition[J].IEEE Transactions of Instrumentation and Measurement,2021,70:1-15.
- [27] YU Z,WEI Y,NIU B,et alAutomatic condition monitoring and fault diagnosis system for power transformers based on voiceprint recognition[J].IEEE Transactions of Instrumentation and Measurement,2024,73:1-11.
- [28] 谢俊文,童靳于,郑近德,等.变转速极低标签率下旋转机械故障诊断的图注意力网络[J].振动与冲击,2024,43(19):242-248.
- [30] PEI X,ZHENG X,WU J.Rotating machinery fault diagnosis through a transformer convolution network subjected to transfer learning[J].IEEE Transactions on Instrumentation and Measurement,2021,70:2515611.
- [31] TOUVRON H,CORD M,DOUZE M,et al.Training data-efficient image transformers & distillation through attention [C]//Proceedings of International Conference on Machine Learning.[S.l.]:[s.n.],2021:10347-10357.
- [32] LIU Z,LIN Y,CAO Y,et al.Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of International Conference on Computer Vision.[S.l.]:[s.n.],2021:10347-10357.

作者简介:熊丽萍,硕士,讲师,主要研究方向为电气工程、控制工程及传感器技术。

吕辉,博士,副教授,主要研究方向为智能传感器。

E-mail:xiongliping1982@163.com

收稿日期:2025-03-31

(上接第93页)

- [13] HU J,YU M F.Meniscus-confined three-dimensional electrodeposition for direct writing of wire bonds[J].Science,2010,329(5989):313-316.
- [14] SEOL S K,KIM D,LEE S,et al.Electrodeposition-based 3D Printing of Metallic Microarchitectures with Controlled Internal Structures[J].Small,2015,11(32):3896-3902.
- [15] LIAO X,ZHUANG J,DENG Y,et al.A closed-loop constant deposition current control method based on MCED circuit model[J].AIP Advances,2020,10(4):045118.
- [16] CHEN Y L,WANG Y T,WANG Y Y,et al.Meniscus-confined electrodeposition of metallic microstructures with in-

process monitoring of surface qualities[J].Precision Engineering,2021,70:34-43.

作者简介:王鹏举,硕士研究生,主要研究方向为微细电化学加工。

李国栋,通信作者,副教授,主要研究方向为超精密特种加工。

E-mail:6220809029@stu.jiangnan.edu.cn;liguodong@jiangnan.edu.cn

收稿日期:2025-02-21