

基于双图卷积机制的数字孪生交通流预测

胡春华^{1,2,3}, 曾萼岚^{1,2}, 荣辉桂⁴

(1. 湖南工商大学人工智能与先进计算学院, 湖南长沙 410205; 2. 湘江实验室, 湖南长沙 410205; 3. 湖南工商大学长沙人工智能社会实验室, 湖南长沙 410205; 4. 湖南大学信息科学与工程学院, 湖南长沙 410082)

摘要: 城市数字化程度提升产生了大量数据,通过对交通流数据和天气数据的整合分析,能有效缓解各种天气状况下产生的城市交通拥堵。而现有交通流预测算法,未能充分考虑交通流中潜在的空间关系,且忽略了天气等外部因素造成的预测误差,极大地影响了预测的准确性。针对上述问题,本文提出了基于双图卷积机制的数字孪生交通流预测方法(Two-graph Convolution Mechanism-based Digital Twin Flow Prediction, TCM-DTFP)。该算法将交通流数据与天气特征相结合,构建了融合交通流特征与天气特征的增广矩阵,提出基于TCN(Temporal Convolutional Networks)的双图卷积机制,算法综合考虑了交通中时间相关性、空间相关性、与区域流量间的动态相互作用对交通流的影响,同时避免了复杂天气状况对交通流预测的影响,提高了算法的鲁棒性。最后基于TaxiBJ和PeMSD4真实数据集进行的大量实验表明了本文方法的有效性。

关键词: 交通数字孪生体;时空相关性;时间卷积网络;双图卷积机制;交通流预测

基金项目: 国家自然科学基金(No.72072053, No.91846301);国家重点研发计划(No.2021YFC3340403)

中图分类号: TP181

文献标识码: A

文章编号: 0372-2112(2025)01-0141-10

电子学报 URL: <http://www.ejournal.org.cn>

DOI: 10.12263/DZXB.20221308

Traffic Flow Prediction of Digital Twin Based on Two-Graph Convolution Mechanism

HU Chun-hua^{1,2,3}, ZENG E-lan^{1,2}, RONG Hui-gui⁴

(1. School of Artificial Intelligence and Advanced Computing, Changsha, Hunan 410205, China;

2. Xiangjiang Laboratory, Changsha, Hunan 410205, China;

3. Changsha Social Laboratory of Artificial Intelligence, Hunan University of Technology and Business, Changsha, Hunan 410205, China;

4. College of Information Science and Engineering, Hunan University, Changsha, Hunan 410082, China)

Abstract: The improvement of urban digitalization has generated a large amount of data. Through the integrated analysis of traffic flow data and weather data, urban traffic congestion caused by various weather conditions can be effectively alleviated. However, in the existing traffic flow prediction algorithms, the potential spatial relationship in the traffic flow has not been fully considered, and the prediction errors caused by external factors such as weather are ignored, which greatly affects the accuracy of the prediction. In response to the above problems, this paper proposes a digital twin traffic flow prediction method TCM-DTFP (Two-graph Convolution Mechanism-based Digital twin flow Prediction) based on the double-graph convolution mechanism. The algorithm builds an augmented matrix that integrates traffic flow features and weather features, adds weather features to traffic flow data, avoids the impact of complex weather conditions on traffic flow prediction, and improves the robustness of the algorithm; at the same time in order to improve the algorithm's ability to capture the spatial correlation of traffic flow, a two-graph convolution mechanism based on TCN (Temporal Convolutional Networks) is proposed to comprehensively consider the dynamic interaction between temporal correlation, spatial correlation and regional flow in traffic influence of flow. Finally, extensive experiments on two real datasets, TaxiBJ and PeMSD4, demonstrate the effectiveness of our method.

Key words: traffic digital twin; spatio-temporal correlation; temporal convolutional networks; two-graph convolution mechanism; traffic flow prediction

收稿日期:2022-11-16;修回日期:2023-09-13;责任编辑:王天慧

Foundation Item(s): National Natural Science Foundation of China (No.72072053, No.91846301); National Key Research and Development Program of China (No.2021YFC3340403)

1 引言

近年来,在“双碳目标”引领下,我国碳排放增长整体呈平稳态势,但交通碳排放量呈突出的上升趋势^[1]. 交通拥堵常常会导致碳排放量增加,构建人、车、路协同发展、路网通畅的智慧交通体系,已成为降低交通碳排放关键方式之一^[2],而数字孪生技术的蓬勃发展为智慧交通体系的构建提供了新思路^[3]. 随着城市数字化程度的不断提升,由道路、车辆、交通信号灯以及摄像头等元素构成的城市交通网络产生了大量交通数据,形成了数字孪生交通流^[4],为构建交通数字孪生体奠定了坚实基础.

然而,城市各区域功能的不同,导致发生交通拥堵的时段也有所不同^[5],同时,道路的空间相关性与天气等外部因素对交通流也有潜在影响^[6]. 现有的交通流预测算法多以交通流的时间相关性为主,再辅以空间相关性或城市各区域在不同时刻对彼此的相互影响以此获得预测结果,未充分考虑城市交通的时空特性和外部影响因素. 此外,据中国气象局统计的信息显示,复杂天气因素下更容易出现交通事故,而不同的天气状况将会形成具有不同特征的交通流变化规律^[7]. 已有的交通流预测算法,忽略了区域流量的动态相互作用与空间相关性的双重影响,以及天气等外部因素带来的干扰,导致了预测准确性不高、在恶劣天气下鲁棒性较弱的问题. 而数字孪生交通流预测算法作为交通数字孪生体的关键组成部分,相较于一般的交通流预测算法在鲁棒性和准确率等方面具有更高要求. 在此种情况下,如何精准且快速地分析大量数字孪生交通流数据,充分挖掘其中潜在的空间相关性并排除外部因素的干扰,将是一项具有挑战性的任务.

针对上述问题,本文提出了一种基于双图卷积机制的数字孪生交通流预测(Two-graph Convolution Mechanism-based Digital Twin Flow Prediction, TCM-DTFP)方法. 该方法通过构建基于时间卷积网络的双图卷积机制和融入天气因素的增广矩阵,在精确度量时间相关性的同时综合考虑空间因素和区域流量间的动态相互作用,并融合天气因素对交通流量或交通速度进行预测. 以此优化交通资源调度、缓解交通拥堵、助力交通数字孪生体建设. 最后基于真实数据集进行了大量实验,验证了本方法的准确性和有效性. 本文的主要贡献有如下3点:

(1)构建了时间卷积与双图卷积机制相融合的深度学习方法,在挖掘交通流的时间相关性的同时,综合

考虑区域流量的动态相互作用和地理空间上的静态关系,提升了算法对交通流空间特征的提取能力.

(2)以融合天气特征的增广矩阵为基础,将天气状况与交通流的特征融合,在进行预测过程中融入天气等外部因素对交通流的影响,提高了算法的鲁棒性.

(3)提供了一种精准且高效的交通流预测方法,并基于多个数据集和评价指标进行了充足实验,证明了该方法的有效性.

2 相关工作

随着智慧社会建设进程的加快,传感器广泛部署于城市的各个交通路段. 通过分析由传感器捕捉到的数字孪生交通流数据,城市管理者能够及时做出更科学、合理的交通调度和管理决策,从而缓解交通拥堵^[8]. 这不但极大地减轻了城市管理者的负担,也为交通数字孪生体的建设提供了有力支撑. 现有交通流预测算法主要可分为基于时间相关性和基于时空相关性两大类,本文将分别对这两类相关研究进行阐述.

2.1 基于时间相关性的交通流预测研究

该类算法主要是针对交通流中潜在的时间关系进行建模,以此挖掘交通流中潜在的时间相关性并进行预测. 如:张兴辉等人^[9]基于反向改进的灰狼算法来优化模型的超参数,并基于BP(Back Propagation)神经网络对未来的交通流进行预测. 此外,循环神经网络及其变体,如:长短期记忆网络和门控循环神经网络等也在该方面的研究中得到了广泛运用^[10,11]. Zhou等人^[12]提出了基于贝叶斯框架的变分图循环注意力网络,解决了传感器和交通序列不确定性导致的交通流预测准确率低的问题.

综上,基于时间相关性的交通流预测算法能解决交通流预测中潜在的不确定性等问题,但此类算法只考虑交通流中潜在的时间相关性,忽略了不同道路车流间存在的相互影响,研究视角较为单一. 空间相关性是交通流的另一潜在联系,其中研究最多的是静态空间相关性^[13],由于城市各个区域的功能不同,且居住区、工作区等不同区域发生拥堵的时间也不同,因此各个路段间还存在着一种动态的空间相关性^[14]. 仅考虑某路段交通流的时间关系,而忽略不同区域车流间干扰存在进行预测的算法,其交通流预测结果的准确性也将降低.

2.2 基于时空相关性的交通流预测研究

针对上述交通流预测算法不能较好捕捉空间相关性的问题,国内外学者近年来开展了广泛的研究,在考

考虑时间相关性的基础上,增强了算法对空间相关性的提取.基于时空相关性的交通流预测算法大致可以分为两类.

第一类是以静态空间相关性为主的交通流预测,此类研究通常基于交通网络的拓扑结构考虑其空间相关性,常以神经网络为主要手段.最初主要基于卷积神经网络来考虑交通流的空间相关性^[15].而随着图神经网络的发展,图神经网络及其变体在交通流预测领域得到了广泛的运用^[16,17],如:Guo等人^[18]考虑日、周、月三种时间间隔的交通序列,并融合城市道路的空间信息,提出了基于注意力的时空图卷积神经网络.

第二类是以区域流量的动态相互作用为主的交通流预测,其核心在于挖掘区域间潜在的动态空间相关性,此类研究于近两年受到了广泛关注.如:Yao等人^[19]将交通拓扑结构建模为一个随机游走的有向图,以此捕捉动态空间相关性,并以扩散卷积捕捉交通流的时间相关性.Han等人^[20]提出了一种动态图构建方法和动态图卷积模块,捕捉不同时间点下不同的相关关系,并融合多种辅助特征对交通流进行预测,但未考虑静态空间关系与天气因素带来的影响.Guo等人^[21]将城市划分为一个宏观图和微观图,分别捕捉宏观图和微观图的内部的相关关系,并利用深度transformer将宏观图和微观图融合,以此获得最终的预测结果.

仅考虑交通流自身的规律存在片面性,因此,近年来围绕天气状况等特殊因素对交通流影响的研究开始受到学者们的重视,即考虑天气的交通流预测.Koesdwiad等人^[22]通过对天气数据进行量化,并以决策融合的方式将其与交通流特征融合,以此消除天气对交通流的影响;陈如清等人^[23]通过奇异谱分析方法消除原始数据集中的噪声,并基于烟花差分进化混合算法增强的极限学习机对交通流进行预测;文献[24]在基于GRU(Gate Recurrent Unit)的交通流预测模型中融入天气、POI(Point Of Interest)等因素带来的影响以改进模型的预测效果.

综上所述,现有交通流预测算法存在如下不足:首先,多数研究都集中于空间相关性或区域流量动态相互作用对交通流的影响,忽略了上述两个方面对交通流的双重影响;其次,多数学者研究仅围绕交通流本身展开,将天气因素考虑其中的尚不多见.

本团队针对数字孪生交通流的缺失值补充等方面开展了深入研究,通过构建用于挖掘交通流中“动-静”双维空间相关性的双图卷积机制,结合城市的天气因素,本文提出了TCM-DTFP方法,以充分捕捉城市交通的时空特性和天气影响因素,提高预测的准确性和算法的鲁棒性.

3 TCM-DTFP模型

3.1 问题定义

本文交通流预测的目标旨在根据道路上的历史交通流数据和部分外部因素,预测未来一段时间内的交通流.在本文提及的方法中,交通流可以是交通流量或交通速度,外部因素则是一个通用概念,表示不受交通流影响但对交通流产生实际影响的因素,如天气、节假日等.在不失一般性的情况下,本节分别以交通流量和天气状况作为交通流数据和外部因素的特征对象,在实验中对交通流量和交通速度的预测性能进行了测试和比较.

定义1 交通流是描述交通状况的关键特征,本文以 $d_{i,t}$ 来表示第 i 个路段第 j 个时间点的交通流,以 $X_j = \{d_{1,j}, d_{2,j}, d_{3,j}, \dots, d_{n,j}\}$ 表示时间点 t 所有交通流的观测值,其中 $i = \{1, 2, 3, \dots, n\}$, n 为路段总数, $j = \{1, 2, 3, \dots, t\}$, t 为历史时间点个数.

定义2 天气和节假日等外部因素常常对交通有较大影响,但与交通流的变化规律无关,因此本文将诸如天气之类的因素作为一个特征与每个时间点各区域的检测值绑定,以 $w_{i,j}$ 来表示第 i 个路段第 j 个时间点的的外部特征,其中 i 与 j 的取值范围与定义1一致.

定义3 道路拓扑结构 G ,地理空间上的交通网络可以视为一个图 $G = (V, E)$,将城市中的各个不相交区域或道路作为节点,各个节点间的连接关系作为边.基于 G 与 E 可通过邻接矩阵 A 来表达图 G ,其为 $n \times n$ 的二维矩阵,元素值可记为 $a_{c,j}$,其中 c 与 j 表示节点 c 与节点 j 之间的连通性,其中 $c = \{1, 2, 3, \dots, n\}$, $j = \{1, 2, 3, \dots, n\}$. $a_{c,j}$ 的值为0、1两种,若节点间相互连通则为1,否则为0.

定义4 动态图 G_D ,由于城市存在居民区、办公区等不同的功能区域,因此在一天的不同时间点各区域交通流间的相互影响必然不同,由此本文构建了可学习的动态图 $G_D = (V, E^T)$,图 G_D 可由 t_{day} 个 $n \times n$ 的二维矩阵构成,其值为可学习参数,单个邻接矩阵记为 $A_{\text{day}}(T)$,其中 t_{day} 为一天的检测次数, $T = \{1, 2, 3, \dots, t_{\text{day}}\}$,图 G_D 整体为三维矩阵.

具体而言,本文的目标是训练一个模型Pre预测未来 N 个时间点的交通流量:

$$X_{t+1}, X_{t+2}, \dots, X_{t+N} = \text{Pre}(X_{t-\text{time}}, X_{t-\text{time}+1}, \dots, X_{t-1}) \quad (1)$$

其中,time表示输入序列的长度.

3.2 模型框架

本文针对空间相关性、区域流量的动态相互作用以及天气等外部因素对交通流的影响,以提高交通流

预测准确性为目标,构建了以交通流时空相关性为基础的TCM-DTFP模型.图1显示了TCM-DTFP模型的整体框架,模型分为两部分:

(1)融合天气因素的增广矩阵.将每个节点的流量特征与同时刻的天气特征绑定,构成一个融合天气特征的增广矩阵,并以历史上 t 个时间点的增广矩阵作为模型的输入.

(2)基于TCN的双图卷积机制.在将增广矩阵融合

为带有天气特征的流量后,首先通过TCN捕获各节点时间序列的特征;其次,由动态图卷积机制学习不同时间各节点间的动态相互作用,再由图卷积机制融入空间相关性带来的影响;最后,通过残差连接来平衡卷积结果与原数据间的权重.在多次卷积中通过跳跃连接记录不同卷积深度的特征,并通过全连接层将其融合获得最终结果.




图1 TCM-DTFP模型

3.3 融合天气因素的增广矩阵

描述天气状况的软数据通常需要进一步量化,因此本文在现有研究的基础上^[22],根据不同天气类型对交通流的影响程度,将天气划分为无影响(包括晴、多云、阴),弱影响(包括小雨、小雪),中等影响(包括中雨、中雪、雾、浮尘)和强影响(包括大雨、暴雨、大雪、雷暴、冻雨、沙尘暴等)四类,并对其量化如下:

$$w = \begin{cases} 1, & \text{无影响} \\ 2, & \text{弱影响} \\ 3, & \text{中等影响} \\ 4, & \text{强影响} \end{cases} \quad (2)$$

基于上述量化结果,以历史天气预报数据为参考,可以获得每个时间点对应的天气特征.由此,结合历史交通流数据,我们可以构建增广矩阵如下:

$$Z = \begin{bmatrix} (d_{1,1}, w_{1,1}) & (d_{2,1}, w_{2,1}) & \cdots & (d_{n,1}, w_{n,1}) \\ (d_{1,2}, w_{1,2}) & (d_{2,2}, w_{2,2}) & \cdots & (d_{n,2}, w_{n,2}) \\ \vdots & \vdots & \ddots & \vdots \\ (d_{1,t}, w_{1,t}) & (d_{2,t}, w_{2,t}) & \cdots & (d_{n,t}, w_{n,t}) \end{bmatrix} \quad (3)$$

其中, $d_{n,t}$ 和 $w_{n,t}$ 分别表示第 n 个路段第 t 个时间点对应的交通流量与天气状况.此外本文设定同一城市同一时间的天气状况一致,由此则有 $w_{1,t} = w_{2,t} = \cdots = w_{n,t}$.

通过对增广矩阵 Z 进行归一化,并施加卷积运算,即可将流量特征与天气特征相融合,获得最终输入模型的特征矩阵:

$$F = \begin{bmatrix} f_{1,1} & f_{2,1} & \cdots & f_{n,1} \\ f_{1,2} & f_{2,2} & \cdots & f_{n,2} \\ \vdots & \vdots & \ddots & \vdots \\ f_{1,t} & f_{2,t} & \cdots & f_{n,t} \end{bmatrix} \quad (4)$$

其中, $f_{n,t}$ 表示第 n 个地段第 t 个时间点的输入特征.

3.4 基于TCN的双图卷积机制

交通流与时间具有高度相关性,从历史流量中能够很好地发掘其变化规律.同时城市功能区存在着区域性差异,在不同时间点各区域间的动态相互作用有所不同.例如在工作日17~19点间,工作区流量迅速提升,其庞大的流量不仅会影响相邻道路的流量,甚至会对相距较远的居民区等区域也产生较大的影响.而地理位置上的空间关系也对交通流存在着巨大影响.由此,本文提出了基于TCN的双图卷积机制来解决上述问题,该机制主要分为两个部分:TCN和双图卷积机制.

本文基于TCN来捕获交通流中的时间相关性.通过设置不同大小的膨胀系数对输入序列进行多重卷积,同时以门控机制过滤数据中的噪声,由此本研究将单层TCN提取的隐含特征定义为

$$I_s = \sigma(W_{1,s} \star F_s) \circ \tanh(W_{2,s} \star F_s) \quad (5)$$

其中 $\star$ 表示扩散卷积; $\circ$ 表示矩阵的哈达玛积; σ 表示 sigmoid 函数, 也就是门控机制; $\tanh$ 表示激活函数; $W_{1,s}$ 表示第 s 层 TCN 对应的第 1 个卷积核的参数, 其中 $l = \{1, 2\}$. 此外, 本文对每层 TCN 的输出 I_s 进行记录, 用于表述不同卷积深度下的交通流特征.

一个时间点往后一段时间的流量特征, 往往能体现当前各区域流量间的潜在影响, 本文以动态图卷积机制来度量这种潜在关系. 由于每天的同一时间各区域间的动态相互作用是相似的, 我们仅以一天中的检测节点数构建可学习的动态图. 根据文章的 3.1 节可知动态图的空间复杂度为 $O(t_{\text{day}}nn)$, 当 t_{day} 不断变大时, 模型的空间复杂度会迅速上升, 为降低模型的空间复杂度, 本文基于 Tucker 分解^[25]将此三维矩阵进行拆分, 将原本的三维矩阵拆分成一个核张量和三个因子矩阵, 上述四个张量的维度都受动态图嵌入维度 e 的影响, 其中核张量的维度为 e^3 , 三个因子矩阵维度之和为 $et_{\text{day}} + 2en$, 而 e 为常数项, 由此可将模型的空间复杂度降低至 $O(e^3 + et_{\text{day}} + 2en) \approx O(t_{\text{day}} + n)$. 而原始的动态图 G_D 和 T 时刻的邻接矩阵 $A_{\text{day}}(T)$ 均可通过 Tucker 分解的逆运算获得. 综上, 动态图和一个时间点对应的邻接矩阵可以由式(5)和式(6)表示:

$$G_D = \sum_{p=1}^e \sum_{q=1}^e \sum_{r=1}^e g_{pqr} \alpha_{a,p} \beta_{b,q} \gamma_{c,r} \quad (6)$$

$$A_{\text{day}}(T) = \sum_{p=1}^e \sum_{q=1}^e \sum_{r=1}^e g_{pqr} \alpha_{T,p} \beta_{b,q} \gamma_{c,r} \quad (7)$$

其中, g_{pqr} 表示核张量; $\alpha_{a,p}$ 、 $\beta_{b,q}$ 、 $\gamma_{c,r}$ 分别表示三个因子矩阵中第 a 行第 p 列、第 b 行第 q 列和第 c 行第 r 列对应的值, 其中 $a, b, c = \{1, 2, 3, \dots, e\}$, $p, q, r = \{1, 2, 3, \dots, n\}$; $\alpha_{a,p}$ 包括所有时间段的隐含特征, 而 $\alpha_{T,p}$ 则表示 T 时刻对应的特征; e 表示动态图的嵌入维度. 因此单层动态图卷

积的结果可表示为

$$H_{D(s)} = A_{\text{day}}(T) I_s W_{D(s)} \quad (8)$$

其中, $W_{D(s)}$ 表示第 s 层动态图卷积的权重参数, $A_{\text{day}}(T)$ 表示 T 时刻动态图对应的邻接矩阵.

由上可知, 在动态图卷积过程中, 忽略了不随时间变化的地理空间因素对交通流的影响. 而基于拉普拉斯矩阵的图卷积通过邻接矩阵考虑道路的空间相关性, 能够很好地弥补这一缺陷, 本研究在动态图卷积的基础上施加一个图卷积构成双图卷积机制, 巧妙地平衡了两种情况对交通流的影响, 双图卷积机制可定义为

$$H_s = \hat{A} H_{D(s)} W_s = \hat{A} (A_{\text{day}}(T) I_s W_{D(s)}) W_s \quad (9)$$

其中, $\hat{A} = D^{1-1/2} A D^{1-1/2}$, 表示基于邻接矩阵 A 的拉普拉斯矩阵, W_s 表示第 s 层图卷积部分的可学习参数.

除上述内容外, 为减少特征提取后带来的损失, 本文在双图卷积机制之后设置了残差连接来缓解这一问题, 并对其结果进行归一化, 最后得经过处理后新的特征:

$$F_{s+1} = H_s + F_s \quad (10)$$

以上是单层 TCN+双图卷积机制的基本原理, 根据膨胀系数的变化, 多层 TCN+双图卷积机制如图 2 所示. 而随着膨胀系数的不断变化和卷积层数的不断增多, 不断记录每次运算的隐含特征, 最后通过两个全连接层即可得到最后的结果:

$$X_{t+1}, X_{t+2}, \dots, X_{t+N} = W_{\rho_2} \text{ReLU}(W_{\rho_1} \text{ReLU}(I_1 \| I_2 \| I_3 \dots \| I_s) + b_{\rho_1}) + b_{\rho_2} \quad (11)$$

其中, W_{ρ_2} 、 W_{ρ_1} 、 b_{ρ_1} 、 b_{ρ_2} 表示全连接层的权重和偏置; ReLU 表示激活函数; $\|$ 表示连接操作; $I_1, I_2, I_3, \dots, I_s$ 表示第 1, 2, 3, $\dots$, s 个 TCN 层记录的特征.

3.5 TCM-DTFP 模型

在 3.3 节和 3.4 节的基础上, 以历史交通流与天气特征所构成的增广矩阵、城市区域拓扑结构构成的邻




图 2 基于 TCN 的双图卷积机制

接矩阵为基础,输入基于TCN的双图卷积机制,最终得到下一阶段各区域的交通流量.具体如算法1所示.

算法1 TCM-DTFP模型

输入:城市区域拓扑结构、区域交通流量、城市气候

输出:城市各区域交通流量

1. 根据设置的序列长度 l 将区域交通流量信息和城市气候进行划分为数据序列
2. 利用卷积运算将各区域的交通流量与城市气候融合获得特征矩阵 F
3. 根据输入序列的时间点获取动态邻接矩阵 $A_{\text{day}}(T)$
4. FOR 时间卷积层 l_{tos}
5. 每个时间卷积层以上一层时间卷积的输出 F_i 为输入,初始为 F
6. 将特征 F_i 输入到TCN中,获得隐含特征 I_i 并记录
7. 将 h_i 作为动态图卷积的输入,采集动态空间关系并更新动态邻接矩阵
8. 基于拉普拉斯矩阵调节区域流量间的静态关系,获得特征矩阵 H_i
9. 建立残差连接并设置 LayerNorm 获得下一层的输入 F_{i+1}
10. END FOR
11. 将记录的特征 $I_1, I_2, I_3, \dots, I_s$, 进行连接,连接时保持序列总数不变
12. 利用全连接层获得交通流预测结果 $X_{t+1}, X_{t+2}, \dots, X_{t+N}$
13. END

表1 数据集信息统计表

数据集	时间片数	节点个数	监测间隔/min	时间跨度/月	天气状况
TaxiBJ	7 220	1 024	30	5	天晴、下雨、下雪等
PeMSD4	16 992	307	5	2	天晴、下雨

TaxiBJ数据集由微软城市计算发布,其中包括北京市区4个时间段的出租车流量数据和对应的天气数据,本文选取其中一段开展实验(2015/11/01—2016/04/10),将整个市区划分为不相交的 32×32 区域网格,每个出租车轨迹被映射到单独的区域,每30 min统计一次流量,以辆数据单位.

PeMSD4数据集由Caltrans系统收集,涵盖旧金山湾区2018年1月、2月的平均交通速度和交通流量,其天气数据根据旧金山湾区气象监测站点数据进行补充,每5 min整合一次数据,取该时段内各车辆交通速度的平均值,单位为 km/h.

为检测本算法的准确性,本文设置了平均绝对误差(Mean Absolute Error, MAE)和均方根误差(Root Mean Square Error, RMSE)和准确率(Accuracy)来度量模型效果,前两个指标代表预测误差,值越小越好,后一个指标代表预测准确性,值越大越好.其计算方式具体如下:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i| \quad (12)$$

3.6 时间复杂度分析

由于增广矩阵的构建可以在线下完成,本文提出的TCM-DTFP模型时耗主要由基于TCN的双图卷积机制产生.

基于TCN的双图卷积机制的时耗由TCN和双图卷积机制两部分组成,即 I_s 和 H_s 等值的计算.假设城市中道路数目为 n ,TCN及除双图卷积以外的卷积操作复杂度为 $O(7n) \approx O(n)$,而双图卷积机制主要包括动态图卷积和图卷积,动态图需要通过各个因子矩阵与核张量计算,复杂度为 $O(n^2)$,拉普拉斯矩阵的计算则可在线下完成,可不计算复杂度,由此,双图卷积机制复杂度为 $O(3n^2) \approx O(n^2)$. 综上,TCM-DTFP模型复杂度为TCN与双图卷积机制复杂度之和,即 $O(n + n^2) \approx O(n^2)$.

4 实验与分析

4.1 实验数据集和评价指标

本文在湘江实验室配备的前信闪电大数据系统上开展实验,相关硬件配置为Xeon双核e5CPU,512 GB内存,利用Python中的torch模块来编程实现TCM-DTFP算法.为验证模型有效性,本文使用TaxiBJ^[26]和PeMSD4^[19]两个通用数据集开展实验,这些数据集的信息如表1所示,其他的具体细节介绍如下.

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (13)$$

$$\text{Accuracy} = 1 - \frac{\|y_i - \hat{y}_i\|_F}{\|y_i\|_F} \quad (14)$$

4.2 对比算法

本文提出的基于双图卷积机制的数字孪生交通流预测算法,其核心在于提高交通流预测准确性,本研究将同近几年最新的交通流预测算法进行比较,对比算法大致可以分为以下几类:考虑静态空间关系的交通流预测算法、考虑天气等外部因素的交通流预测算法、基于传统深度学习方法考虑区域流量的动态相互作用的交通流预测算法、基于动态图卷积考虑区域流量的动态相互作用的交通流预测算法.

具体阐述如下. Temporal Graph Convolutional Network (T-GCN)^[27]:以图卷积网络为时间序列施加空间特征,再由门控单元捕获时间相关性,但未考虑天气对交通流的影响; attribute-Augmented Spatio-Temporal Graph Convolutional Network (AST-GCN)^[24]:在考虑交通流时空关系基础上,融合天气信息和POI信息对预测

结果进行调整; Diffusion Convolutional Recurrent Neural Network (DCRNN)^[19]; 将交通流建模为有向图的扩散过程, 并使用图的双向随机游走来捕捉空间相关性; Dynamic and Multifaceted Spatio-Temporal Graph Convolution Network (DMSTGCN)^[20]; 基于动态图卷积机制捕获不同时间点各区域动态相关性, 以此预测未来的流量。

4.3 实验分析

交通流预测的准确率是评估算法好坏的关键标准, 而输入数据量与预测时段长度对模型的预测效果都有影响, 输入数据量变化或者预测时段长度缩短都会导致预测准确率提升。为保证一致性, 本文比较了 TCM-DTFP 模型与其他算法在输入长度为 12 的数据序列时预测前三个时间点的各项指标。此外, 本文分别通过 TaxiBJ 和 PeMSD4 数据集对交通流量和交通速度两种交通流数据的预测情况都进行了测试。

由算法 1 可知, 本模型涉及多个参数, 其中隐含层个数为 64、批次为 16、学习率为 0.001、动态图嵌入维度

为 40, 迭代次数为 200, 实验过程中数据集按照 8:2 的比例划分为训练集和测试集。

在预测交通流量方面, 从表 2 可看出, TCM-DTFP 模型在各种情况下都能取得较好的结果, 这证明了本研究模型在交通流量预测方面的优越性。此外, T-GCN 预测效果相对较差, 这是其仅以邻接矩阵为输入序列施加相关性, 度量空间相关性不全面导致的。AST-GCN 在考虑空间关系的基础上融合了天气等外部因素带来的干扰, 预测的准确性得到了一定的提升。Diffusion Convolutional Recurrent Neural Network (DCRNN) 在预测未来第二的时间点的流量时效果优于 Dynamic and Multifaceted Spatio-Temporal Graph Convolution Network (DMSTGCN), 而其他情况下 DMSTGCN 效果更好, 这说明与随机游走的扩散卷积相比, 动态图卷积更能捕捉各区域间的动态相互作用。但上述研究在交通流空间相关性的度量方面均有缺陷。而本文在考虑了时空相关性和区域流量间的动态相互作用的同时, 添加了天气等多方面外部因素, 因此可获得更高的准确率。

表 2 TCM-DTFP 模型在交通流量预测方面对比结果

数据集		TaxiBJ				
对比算法		T-GCN	AST-GCN	DCRNN	DMSTGCN	TCM-DTFP
N=1	MAE	21.040 6	17.376 1	11.518 7	11.882 6	10.787 2
	RMSE	32.044 3	27.509 5	21.244 1	21.042 0	19.477 6
	Accuracy	0.782 8	0.813 6	0.861 3	0.862 6	0.871 5
N=2	MAE	23.162 4	20.157 1	13.797 8	14.291 7	12.568 1
	RMSE	36.348 6	32.139 3	25.889 1	25.905 4	23.304 8
	Accuracy	0.759 6	0.782 2	0.830 9	0.830 7	0.847 7
N=3	MAE	25.001 2	22.508 7	15.399 7	15.875 5	13.474 2
	RMSE	38.244 1	35.292 1	29.005 2	28.952 5	25.315 0
	Accuracy	0.740 6	0.761 3	0.810 4	0.810 7	0.834 5

在预测交通速度方面, 从表 3 可以看出, TCM-DTFP 模型在多数情况下均能取得较好的结果, 但与 DMSTGCN 的效果非常相近, 其原因是旧金山湾区 1 月、2 月份天气主要以晴天和阴天为主, 此种情况下天气因素的影响较小。即便如此, TCM-DTFP 模型依旧达到了与 DMSTGCN 相近甚至略优的效果, 这是因为本文提出的模型考虑了地理上的空间相关关系与区域间动态相互作用的双重作用, 对空间相关性的度量更为准确, 因此效果更好。

除模型的预测性能以外, TCM-DTFP 模型在训练和预测用时上也具有更优的效果, 与本研究的模型相比, DMSTGCN 时间复杂度为 $O(11n+6n^2) \approx O(n^2)$, 虽然与 TCM-DTFP 模型为一个数量级, 但随着 n 的增大, 其余常数项带来的影响也会变大, 因此在训练过程中本研究模型的时耗通常比 DMSTGCN 的时耗低一倍左右。而 T-GCN、AST-GCN 及 DCRNN 的时间复杂度分别为 $O(6n+$

$2n^2) \approx O(n^2)$ 、 $O(6n+6n^2) \approx O(n^2)$ 和 $O(5n+2n^2) \approx O(n^2)$, 与 TCM-DTFP 模型相近但预测准确度较差。在模型的实际运用过程中, 训练好的 TCM-DTFP 模型可以在 4 s 左右获得所有节点的预测结果, 能够满足实际运用的需求。

为验证融合“动-静”态空间关系的必要性本文基于 TCM-DTFP 模型进行了修改, 移除了 GCN(Graph Convolutional Network)以排除静态空间关系对交通流预测的影响, 记为 STCM-DTFP (Simplify Two-graph Convolution Mechanism-based Digital Twin Flow Prediction) 并基于 TaxiBJ 数据集进行实验, 于多项评价指标进行对比, 具体如表 4 所示。

由表 4 可知, 与 TCM-DTFP 模型相比, 移除 GCN 部分后, 模型的各项指标均有所下降, 且随着预测时间点向后推移模型效果下降得越多, 这说明仅考虑动态空间关系存在空间相关性捕捉不完整的问题, 而融合动-静态空间相关性后预测效果更好。

表3 TCM-DTFP模型在交通速度预测方面对比结果

数据集		PeMSD4				
对比算法		T-GCN	AST-GCN	DCRNN	DMSTGCN	TCM-DTFP
N=1	MAE	1.779 4	1.490 2	0.923 9	0.911 3	0.907 8
	RMSE	2.852 1	2.457 0	1.738 5	1.712 5	1.721 0
	Accuracy	0.955 6	0.962 2	0.972 4	0.973 0	0.973 2
N=2	MAE	1.904 6	1.652 4	1.201 3	1.180 3	1.169 2
	RMSE	3.130 2	2.720 9	2.442 1	2.406 3	2.370 1
	Accuracy	0.951 3	0.957 7	0.962 0	0.963 3	0.963 6
N=3	MAE	2.036 3	1.752 6	1.379 1	1.329 7	1.317 2
	RMSE	3.385 3	2.997 1	2.944 9	2.801 4	2.800 3
	Accuracy	0.947 3	0.952 9	0.954 2	0.955 9	0.956 2

表4 TCM-DTFP模型消融实验对比结果

数据集		TaxiBJ	
对比算法		STCM-DTFP	TCM-DTFP
N=1	MAE	11.869 4	10.787 2
	RMSE	20.834 6	19.477 6
	Accuracy	0.863 8	0.871 5
N=2	MAE	13.542 0	12.568 1
	RMSE	24.645 7	23.304 8
	Accuracy	0.838 9	0.847 7
N=3	MAE	14.597 6	13.474 2
	RMSE	27.023 2	25.315 0
	Accuracy	0.823 3	0.834 5

为进一步研究TCM-DTFP模型的预测效果,本文分别在TaxiBJ和PeMSD4数据集随机抽取了一个节点的交通流真实值与预测结果,其中TaxiBJ数据集随机抽取72 h、PeMSD4数据集随机抽取24 h进行可视化,由图3可以发现,预测曲线能较好地拟合真实曲线,说明TCM-DTFP模型具有较高的准确性。

此外,本文就算法预测效果的提升原因进行了分析。

在通过动态图卷积获取带有动态空间相关性的潜在特征 $\mathbf{H}_{D(s)}$ 后,本文以图卷积机制增强序列拓扑关系

导致的相互作用,提高被动态图卷积网络忽略但却客观存在的静态空间相关性在求解中的权重,得到了更为准确的潜在特征 $\mathbf{H}_s$ 。假设某序列的潜在特征可表示如下

$$f(x_t) = \beta(x_1, x_2, x_3, \dots, x_n) \quad (15)$$

其中, x_1, x_2 等表示各节点对应的序列, $f(x_t)$ 表示动态图卷积求解后得到的函数。尽管动态图卷积能根据反向传播不断捕捉序列间存在的动态空间关系,但输入序列通常包含较长时间内的交通流,其难以完整捕捉在短时间产生影响的静态空间相关性,而通过图卷积机制可以缓解这一问题。假设序列 x_t 与序列 x_1 等序列之间存在静态空间关系,则有

$$x_t = f(x_t) + \sigma(x_1, x_2, x_3, \dots, x_n) + b \quad (16)$$

其中, $\sigma(x_1, x_2, x_3, \dots, x_n)$ 表示各节点之间加强的权重 b 表示偏置,通过增大 x_1 等序列在求解 x_t 中所占的比重,可以保存对序列 x_t 存在的影响,从而提高特征质量。

此外,在输入交通流数据 $d_{i,j}$ 之前,本文通过天气因素 $w_{i,j}$ 对其进行重构,则有

$$f_{i,j} = d_{i,j} + \alpha_{i,j} w_{i,j} \quad (17)$$

其中, $f_{i,j}$ 表示重构后的数据; $\alpha_{i,j}$ 表示权重,用于在反向传播中学习天气因素在交通流数据中的重要程度。由




图3 预测值与真实值的对比曲线图

此,本研究将天气特征融入了交通流数据中,即对所有的交通流数据都进行了调整,进一步降低了噪声数据带来的影响。

综上,TCM-DTFP模型无论在交通流量还是交通速度预测方面都能取得优于现有算法的结果。本文通过提高模型特征的质量、保护特征的完整性和降低噪声的影响,提高了交通流预测的准确性和鲁棒性。

5 结论

高效精准地分析数字孪生交通流数据,在辅助城市管理进行决策、构建完善的交通数字孪生体等方面发挥着越来越重要的作用。本文在传统交通流预测算法的基础上,将近两年来受到关注的“动态空间相关性”引入模型,提出了一种综合考虑交通流“动-静”空间相关性的TCM-DTFP交通流预测算法。该方法在TCN和双图卷积机制的基础上,分析交通流潜在的时间关系,并根据不同起始时间的交通流施加“动-静”二维空间相关性,同时以增广矩阵融入天气等外部因素对交通流的影响,提高了交通流预测的准确性和算法的鲁棒性。所提算法在公开的TaxiBJ数据集和PeMSD4数据集上进行实验,结果表明,与DCRNN、DMSTGCN等近三年的主流算法相比,TCM-DTFP算法在MAE、RMSE及Accuracy指标上表现更优,尤其在天气情况较为复杂的条件下,TCM-DTFP算法与DMSTGCN算法相比在MAE、RMSE及Accuracy三项指标上的效果分别提升了6.35%、8.31%、2.93%,取得了令人满意的预测结果。而交通工具的多样化对交通流预测带来了挑战,同时对拥堵状况进行直接预测也成为当前的迫切需要,未来还可以从多种交通工具的综合预测^[28]、拥堵状况预测^[29]等维度继续深入研究。

参考文献

- [1] 董利苹, 曾静静, 曲建升, 等. 欧盟碳中和政策体系评述及启示[J]. 中国科学院院刊, 2021, 36(12): 1463-1470.
DONG L P, ZENG J J, QU J S, et al. Review of EU's carbon neutral policy system and its enlightenment[J]. Bulletin of Chinese Academy of Sciences, 2021, 36(12): 1463-1470. (in Chinese)
- [2] 李晓易, 谭晓雨, 吴睿, 等. 交通运输领域碳达峰、碳中和路径研究[J]. 中国工程科学, 2021, 23(6): 15-21.
Li X Y, Tan X Y, Wu R, et al. Paths for carbon peak and carbon neutrality in transport sector in China[J]. Strategic Study of CAE, 2021, 23(6): 15-21. (in Chinese)
- [3] TAO F, QI Q L. Make more digital twins[J]. Nature, 2019, 573(7775): 490-491.
- [4] HU C H, FAN W C, ZENG E L, et al. Digital twin-assisted real-time traffic data prediction method for 5G-enabled internet of vehicles[J]. IEEE Transactions on Industrial Informatics, 2022, 18(4): 2811-2819.
- [5] LI M Z, ZHU Z X. Spatial-temporal fusion graph neural networks for traffic flow forecasting[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(5): 4189-4196.
- [6] COOLS M, MOONS E, WETS G. Assessing the impact of weather on traffic intensity[J]. Weather, Climate, and Society, 2010, 2(1): 60-68.
- [7] AVILA A M, MEZIĆ I. Data-driven analysis and forecasting of highway traffic dynamics[J]. Nature Communications, 2020, 11(1): 2090.
- [8] LI Y, XIA S C, YANG Q Y, et al. Lifetime-priority-driven resource allocation for WNV-based internet of things[J]. IEEE Internet of Things Journal, 2021, 8(6): 4514-4525.
- [9] 张兴辉, 樊秀梅, 阿喜达, 等. 反向学习的灰狼算法优化及其在交通流预测中的应用[J]. 电子学报, 2021, 49(5): 879-886.
ZHANG X H, FAN X M, SHAN A, et al. Grey wolf optimization based on opposition learning and its application in traffic flow forecasting[J]. Acta Electronica Sinica, 2021, 49(5): 879-886. (in Chinese)
- [10] BELHADI A, DJENOURI Y, DJENOURI D, et al. A recurrent neural network for urban long-term traffic flow forecasting[J]. Applied Intelligence, 2020, 50(10): 3252-3265.
- [11] 戢晓峰, 戈艺澄. 基于深度学习的节假日高速公路交通流预测方法[J]. 系统仿真学报, 2020, 32(6): 1164-1171.
JI X F, GE Y C. Holiday highway traffic flow prediction method based on deep learning[J]. Journal of System Simulation, 2020, 32(6): 1164-1171. (in Chinese)
- [12] ZHOU F, YANG Q, ZHONG T, et al. Variational graph neural networks for road traffic prediction in intelligent transportation systems[J]. IEEE Transactions on Industrial Informatics, 2021, 17(4): 2802-2812.
- [13] GEROLIMINIS N, DAGANZO C F. Existence of urban-scale macroscopic fundamental diagrams: Some experimental findings[J]. Transportation Research Part B: Methodological, 2008, 42(9): 759-770.
- [14] LU B, GAN X Y, JIN H M, et al. Spatiotemporal adaptive gated graph convolution network for urban traffic flow forecasting[C]//Proceedings of the 29th ACM International Conference on Information & Knowledge Management. New York: ACM, 2020: 1025-1034.
- [15] ZHANG Y N, ZHOU Y H, LU H P, et al. Traffic network flow prediction using parallel training for deep convolutional neural networks on spark cloud[J]. IEEE Transactions on Industrial Informatics, 2020, 16(12): 7369-7380.
- [16] 冯宁, 郭晟楠, 宋超, 等. 面向交通流量预测的多组件时空图卷积网络[J]. 软件学报, 2019, 30(3): 759-769.

- FENG N, GUO S N, SONG C, et al. Multi-component spatial-temporal graph convolution networks for traffic flow forecasting[J]. Journal of Software, 2019, 30(3): 759-769. (in Chinese)
- [17] ZHANG Y X, WANG S Z, CHEN B, et al. TrafficGAN: Network-scale deep traffic prediction with generative adversarial nets[J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 22(1): 219-230.
- [18] GUO S N, LIN Y F, FENG N, et al. Attention based spatial-temporal graph convolutional networks for traffic flow forecasting[C]//Proceedings of the Thirty-Third AAAI Conference on Artificial Intelligence and Thirty-First Innovative Applications of Artificial Intelligence Conference and Ninth AAAI Symposium on Educational Advances in Artificial Intelligence. New York: ACM, 2019: 922-929.
- [19] YAO H X, WU F, KE J T, et al. Deep multi-view spatial-temporal network for taxi demand prediction[C]//Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence and Thirtieth Innovative Applications of Artificial Intelligence Conference and Eighth AAAI Symposium on Educational Advances in Artificial Intelligence. New York: ACM, 2018: 2588-2595.
- [20] HAN L Z, DU B W, SUN L L, et al. Dynamic and multi-faceted spatio-temporal deep learning for traffic speed forecasting[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery & Data Mining. New York: ACM, 2021: 547-555.
- [21] GUO K, HU Y L, SUN Y F, et al. Hierarchical graph convolution network for traffic forecasting[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(1): 151-159.
- [22] KOESDWIADY A, SOUA R, KARRAY F. Improving traffic flow prediction with weather information in connected cars: A deep learning approach[J]. IEEE Transactions on Vehicular Technology, 2016, 65(12): 9508-9517.
- [23] 陈如清, 李嘉春, 俞金寿. 基于 FWADE-ELM 的短时交通流预测方法[J]. 控制与决策, 2021, 36(4): 925-932.
- CHEN R Q, LI J C, YU J S. Short-term traffic flow forecasting based on hybrid FWADE-ELM[J]. Control and Decision, 2021, 36(4): 925-932. (in Chinese)
- [24] ZHU J W, WANG Q J, TAO C, et al. AST-GCN: Attribute-augmented spatiotemporal graph convolutional network for traffic forecasting[J]. IEEE Access, 2021, 9: 35973-35983.
- [25] TUCKER L R. Some mathematical notes on three-mode factor analysis[J]. Psychometrika, 1966, 31(3): 279-311.
- [26] ZHANG J B, ZHENG Y, QI D K, et al. Deep spatio-temporal residual networks for citywide crowd flows prediction [C]//Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence. New York: ACM, 2017: 1655-1661.
- [27] ZHAO L, SONG Y J, ZHANG C, et al. T-GCN: A temporal graph convolutional network for traffic prediction[J]. IEEE Transactions on Intelligent Transportation Systems, 2020, 21(9): 3848-3858.
- [28] ZHOU J H, DAI H N, WANG H, et al. Wide-attention and deep-composite model for traffic flow prediction in transportation cyber-physical systems[J]. IEEE Transactions on Industrial Informatics, 2021, 17(5): 3431-3440.
- [29] 周辉宇, 李瑞敏, 黄安强, 等. 基于时空关联规则挖掘的城市交通拥堵传导预测[J]. 系统工程理论与实践, 2022, 42(8): 2210-2224.
- ZHOU H Y, LI R M, HUANG A Q, et al. Forecasting urban traffic congestion conduction based on spatiotemporal association rule mining[J]. Systems Engineering-Theory & Practice, 2022, 42(8): 2210-2224. (in Chinese)


作者简介



胡春华 男, 1973 年生, 湖南娄底人. 2007 年在中南大学计算机专业获博士学位. 湖南工商大学二级教授、教育部新世纪人才. 主要研究方向为智能推荐、信息资源管理、智慧交通等.
E-mail: huch@hutb.edu.cn



荣辉桂 男, 1977 年生, 湖南株洲人. 2011 年在武汉大学获博士学位. 湖南大学信息科学与工程学院副教授、博士生导师. 主要研究方向为数据挖掘、自动驾驶等.
E-mail: ronghg@hnu.edu.cn



曾萼岚 男, 1998 年生, 湖南娄底人. 湖南工商大学管理科学与工程专业硕士. 主要研究方向为智慧交通、数字孪生.
E-mail: zengelan@163.com