



计算机科学与探索

Journal of Frontiers of Computer Science and Technology

ISSN 1673-9418, CN 11-5602/TP

《计算机科学与探索》网络首发论文

题目：基于改进低阶适应的开放词汇语音情感识别
作者：刘康伟，丁涵宇，高利剑，毛启容
网络首发日期：2025-11-19
引用格式：刘康伟，丁涵宇，高利剑，毛启容. 基于改进低阶适应的开放词汇语音情感识别[J/OL]. 计算机科学与探索.
<https://link.cnki.net/urlid/11.5602.tp.20251119.1015.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于改进低秩适应的开放词汇语音情感识别

刘康伟¹, 丁涵宇¹, 高利剑¹, 毛启容^{1,2+}

1. 江苏大学 计算机科学与通信工程学院 江苏 镇江 212013

2. 江苏省大数据泛在感知与智能农业应用工程研究中心, 江苏 镇江 212013

+ 通信作者 E-mail: Mao_qr@ujs.edu.cn

摘要: 音频大语言模型 (Audio Large Language Models, AudioLLMs) 的出现推动语音情感识别 (Speech Emotion Recognition, SER) 从简单的类别判别发展为深度情感理解, 旨在超越当前封闭集分类范式, 生成超出基本情感范畴的、多样的情感描述。这种区别于传统情感类别分类转而生情感描述的方法称之为开放词汇语音情感识别 (Open-Vocabulary Speech Emotion Recognition, OV-SER)。然而, 现有的开放词汇语音情感识别仍然处于起步阶段, 大多方法通过 AudioLLMs 推理或者微调来实现, 该类方法存在因低秩分解导致大模型表达能力受限的问题, 使其在开放词汇语音情感识别新任务上性能表现不佳。为此, 本文提出一种标签感知缩放的改进低秩适应方法 (Label-Aware Scaling LoRA, LoRA-LAS), 通过引入情感标签驱动的非线性映射, 缓解低秩约束对模型表征能力的限制。具体而言, 本文首先利用提示模板引导 AudioLLMs 生成聚焦于语调、韵律等声学线索的音频描述; 随后, 将该描述与文本内容及指令共同输入大语言模型 (Large Language Model, LLM), 再使用我们设计的 LoRA-LAS 微调方法进行参数高效微调。得益于标签感知机制, LoRA-LAS 能够动态感知更新, 可以更有效地适配开放词汇情感识别任务。此外, 基于 LLM 的生成式情感分析能够更全面地刻画真实世界中复杂、混合的情感状态, 克服传统封闭集分类的局限性。本文在 MER-Caption Plus、OV-MERD、MELD、IEMOCAP 和 CMU-MOSI 等多个数据集上进行了实验。结果表明, 所提方法在开放词汇与传统类别型情感识别任务上均优于现有方法。

关键词: 音频大语言模型; 语音情感识别; 大语言模型; 低秩适应; 开放词汇

文献标志码: A **中图分类号:** TP183;TP391.42

Open-Vocabulary Speech Emotion Recognition Based on Improved Low-Rank Adaptation

LIU Kangwei¹, DING Hanyu¹, GAO Lijian¹, MAO Qirong^{1,2+}

1. School of Computer Science and Communication Engineering, Jiangsu University, Zhenjiang, Jiangsu 212013, China

2. Jiangsu Engineering Research Center of Big Data Ubiquitous Perception and Intelligent Agriculture Applications, Zhenjiang, Jiangsu 212013, China

Abstract: The emergence of Audio Large Language Models (AudioLLMs) has propelled Speech Emotion Recognition (SER) from simple categorical discrimination toward profound emotional understanding, aiming to transcend current closed-set classification paradigms by generating diverse emotional descriptions beyond basic emotion categories. This

基金项目: 国家自然科学基金 (62176106); 国家自然科学基金 (62576155)。

This work was supported by the National Natural Science Foundation of China (62176106), and the National Natural Science Foundation of China (62576155).

approach, which shifts from traditional emotion category classification to generating emotional descriptions, is termed Open-Vocabulary Speech Emotion Recognition (OV-SER). However, existing OV-SER methodologies remain in their nascent stage, with most approaches relying on AudioLLM inference or fine-tuning. These methods suffer from limited expressive capabilities of large models due to low-rank decomposition constraints, resulting in suboptimal performance on this emerging task. To address this limitation, this paper proposes an enhanced Low-Rank Adaptation method with Label-Aware Scaling (LoRA-LAS), which introduces emotion label-driven nonlinear mapping to mitigate the representational constraints imposed by low-rank adaptation. Specifically, we first employ prompt templates to guide AudioLLMs in generating audio descriptions that focus on acoustic cues such as intonation and prosody. Subsequently, these descriptions, together with textual content and instructions, are jointly fed into a Large Language Model (LLM), followed by parameter-efficient fine-tuning using our designed LoRA-LAS method. Benefiting from its label-aware mechanism, LoRA-LAS can dynamically perceive and adapt to updates, enabling more effective adaptation to open-vocabulary emotion recognition tasks. Furthermore, LLM-based generative emotion analysis comprehensively captures complex, mixed emotional states in real-world scenarios, overcoming the limitations inherent in traditional closed-set classification. Experiments were conducted on multiple datasets, including MER-Caption Plus, OV-MERD, MELD, IEMOCAP, and CMU-MOSI. The results demonstrate that the proposed method outperforms existing approaches in both open-vocabulary and traditional category-based emotion recognition tasks.

Key words: Audio Large Language Model; Speech Emotion Recognition; Large Language Model; Low-Rank Adaptation; Open-Vocabulary

情感蕴含着人类的意图,代表着人类对某一事物的真实感受。真实世界中,情感能够以不同形式,通过人类的各种行为得以传达。近年来,随着人机交互需求的持续增长,语音情感识别(Speech Emotion Recognition, SER)受到了越来越多的关注^[1-3]。语音情感识别已经广泛应用于自然人机交互^[4]、疾病诊断^[5]、疲劳检测^[6]、公共安全^[7]等多个领域。

传统方法主要依赖于判别模型,这些方法将人类情感映射到预定义的情感分类体系中最有可能的类别。其中应用最广泛的分类体系源于 Ekman 的理论^[8],该理论将人类情感分为六个基本类别:悲伤、快乐、恐惧、愤怒、惊讶与厌恶。然而,此类分类框架在建模人类情感状态时存在明显局限。例如,特定文化背景下的表达习惯及个体间情感表达方式的差异,使得情感表现具有高度复杂性。此外,人类的情感丰富多样,仅基于当前封闭集的分类范式难以充分捕捉现实场景中情感表达的丰富性与细微差异。同时,传统的情感分类体系通过将离散的标签(如愤怒或惊讶)强加于同时存在的微妙情感状态上,过度简化了情感表达的连续性。

大语言模型(Large Language Models, LLMs)的发展使情感理解得以超越传统判别方法,转向更具生成性的建模范式^[9]。这一转变使得模型能够用自然语言描述复杂且同时存在的情感状态。凭借庞大的词汇

量与语义理解能力,LLMs 能够生成超出基本情感范畴的多样化、描述性情感标签,为情感理解提供了新的契机。近期提出的 AffectGPT^[10]首次构建了一个大规模的情感描述数据集 MER-Caption Plus,该数据集采用了模型主导、人工辅助的标注策略。同时其提出的 AffectGPT 模型通过预融合操作增强了对情感的理解能力。此外,该工作还为这项情感理解新任务构建了全面的评估基准。

然而,此类方法在采用低秩适应(Low-Rank Adaptation, LoRA)^[11]进行微调时,在低秩条件下表现出性能下降的问题。尽管提升秩值可在一定程度上缓解该问题,但性能增益有限,且会显著增加计算成本^[10]。进一步分析表明,模型表达能力受限的根本原因在于过低的秩值限制了大语言模型的表达能力。

现阶段,开放词汇语音情感识别的主流方案仍为传统 LoRA 微调,但该方案未充分考虑线性低秩假设对模型表征能力造成的限制。为解决如上问题,本文提出一种引入标签感知缩放(Label-Aware Scaling, LAS)机制的非线性 LoRA 方法——LoRA-LAS。

本文的主要贡献如下:

(1) 面向开放词汇语音情感识别任务,构建了一套基于音频大语言模型与通用大语言模型协同的端到端推理与微调架构。

(2) 针对 LoRA 在开放词汇情感识别中的局限

性,设计了一种标签感知的非线性映射函数 (LAS),通过将情感标签语义动态注入低秩更新路径,在几乎不增加可训练参数的前提下,显著增强了模型的语义分辨与跨任务泛化能力。

(3)在 MER-Caption Plus、OV-MERD、MELD、IEMOCAP 和 CMU-MOSI 等多个异构情感识别数据集上进行了系统实验,验证了所提方法在开放词汇与传统类别任务上的优越性与泛化能力。

1 基于改进低阶适应的开放词汇语音情感识别

本文所提方法的整体框架如图 1 所示:第一部分中,音频大语言模型仅在指令提示下执行推理,不进行参数更新;第二部分则需对模型进行参数高效微调 (Parameter-Efficient Fine-Tuning, PEFT)。

1.1 音频描述生成

传统深度学习方法在语音情感识别中通常采用“预训练特征提取 + 任务模型训练”的两阶段范式:首先利用 VGGish^[12]、HuBERT^[13]等预训练模型提取音频的声学特征,经降维等预处理后,输入 CNN、RNN 或 Transformer 等结构进行情感分类^[14-18]。这种范式存在两大局限:训练过程高度依赖预训练模型提取的声学特征,但这些模型的预训练目标与情感识别任务存在本质差异。无法显式分离语音内容与情感信息,导致内容相关特征对情感分类形成干扰;其次,训练数据需要预先定义情感标签集合(如“愤怒”“喜悦”),难以涵盖现实场景中的复杂情感表达。因此本文使用 LLM 生成的音频描述文本,替代传统的声学特征向量。具体来说,本文设计提示词 Q_a 以优化 AudioLLM 的推理过程,使得 AudioLLM 推理的过程中更关注于音频的韵律、语调、能量变化等,同时最大化的输出音频可能蕴含的情感信息。整个过程无需训练。最终可以生成一段针对该语音的描述文本 R 。

1.2 LoRA-LAS 微调方法

在得到音频描述 R 的前提下,我们进一步给定指令 Q_r ,对于指令 Q_r 和文本内容 X_t 以及音频描述 R ,通过预定义模板拼接为提示 P ,并借助 LLM 的分词器(tokenizer)与嵌入层(embedding layer)映射为对应的词元(Token)向量表示。将上述向量拼接后输入大语言模型的解码器。模型的优化目标是在给定音频描述文本

R 和文本内容 X_t 以及指令 Q_r 的条件下,最大化目标回复 R_{emo} 的条件概率:

$$\max P(R_{emo} | R, X_t, Q_r) \quad (1)$$

当前,大语言模型的参数高效微调主要采用 LoRA 方法。其核心思想是冻结 LLM 的预训练参数,仅在关键模块(如自注意力机制的查询(Q)、键(K)、值(V)投影层及前馈网络的线性层)中插入低秩适配模块。

在 LoRA 中,目标是使用更少的参数来拟合最优的 ΔW_i ,低秩分解可以表示为 $\Delta W_i \in \mathbb{R}^{d \times k}$,公式如下:

$$\Delta W_i = B_i \times A_i \quad (2)$$

其中 $B_i \in \mathbb{R}^{d \times r}$ 且 $A_i \in \mathbb{R}^{r \times k}$ 用于将可训练参数的维度从 d 降至 r ,然后再升回到 k 。由于通常会设置 $r \ll \min\{d, k\}$,因此拟合 ΔW_i 的参数数量远少于全量微调中的参数数量。该策略将可训练参数规模压缩至全量微调的 1% - 5%,显著降低内存占用与计算开销,同时有效保留模型的预训练知识。

然而,LoRA 的本质在于假设任务相关的参数扰动具有低秩结构。这一线性低秩假设与情感语义空间的高维非线性特性之间存在根本性矛盾,尤其在开放词汇语音情感识别任务中表现得尤为突出。该任务中的情感类别数量极多,通常服从幂律分布,呈现出显著的长尾特性。导致情感特征在语义空间中分布高度非线性且存在复杂的耦合关系。

近期多项研究提出了多种 LoRA 改进方案。如 LoRA+^[19]通过动态调整缩放因子 α 和秩值 r ,提升不同层的适配灵活性;DoRA^[20]将权重更新解耦为方向(direction)与幅值(magnitude)两个分量,分别优化以增强模型的表达能力;PiSSA^[21]则利用主成分分析对低秩矩阵进行语义感知初始化,加速收敛的同时可以提升性能。然而,上述方法均采用任务无关的通用优化策略,未能显式建模情感标签的语义特性。在开放词汇情感识别中,情感标签不仅数量庞大,且呈现显著的长尾分布与非均匀语义距离,使得通用缩放或初始化机制难以区分“愤怒”与“懊悔”等细粒度情感的语义强度差异。

在此背景下,将高维非线性情感语义结构强行压缩至低维低秩子空间,本质上是以牺牲模型表征能力为代价换取参数效率,易使模型陷入次优解,难以充分捕捉情感语义的复杂结构。




图1 开放词汇情感识别整体框架图

Fig.1 Overall Framework Diagram of Open-Vocabulary Emotion Recognition

为缓解这一矛盾,本文提出在 LoRA 框架中引入非线性映射机制。通过在低秩更新路径中嵌入一种由情感标签驱动的非线性变换,能够更精细地建模情感特征间的高阶交互与非线性偏移,从而突破传统 LoRA 的线性表征局限。

具体而言,本文对原始 LoRA 结构进行扩展,使其具备捕捉非线性情感语义的能力。相应的,可以将公式(2)重新表示为:

$$\Delta W_i = f(B_i \times A_i) \quad (3)$$

其中 $f(\cdot)$ 是指轻量额外可训练参数的非线性函数。

在开放词汇语音情感识别任务中,情感标签不仅是分类目标,更是动态调控模型行为的元信息。传统参数高效微调方法将所有标签视为平等实体,其静态适配策略严重忽视了情感语义的两个核心特性:类别间语义距离的非均匀性和由分布长尾性导致的信号强度差异。

此外,在非线性变换函数设计中,尽管存在多种兼具良好导数性质与合理值域的激活函数,但研究指出^[22],传统激活函数并不适用于 LoRA,相当一部分

激活函数会在变换过程中产生不合理映射。因此,所设计的非线性函数 $f(\cdot)$ 需在保持参数高效性的同时,融入非线性特性。

综合上述考虑,本文设计了一个具有标签感知缩放机制(Label-Aware Scaling, LAS)的非线性映射函数,其通过将情感标签的语义信息显式注入非线性映射函数,实现对低秩更新项的动态调控。本文将采用该函数的 LoRA 变体称为 LoRA-LAS。

具体而言,在训练阶段,给定样本的真实情感标签集合 $Y = \{y_1, y_2, \dots, y_k\}$,利用 AffectGPT^[10]提供的预训练情感词嵌入,获取每个标签的语义向量 $e_{y_i} \in \mathbb{R}^d$,并聚合为上下文向量 $c = \text{Mean}(\{e_{y_i}\})$ 。该向量 c 蕴含了当前样本的情感语义强度与类别分布特性。LAS 函数定义如下:

$$f(x) = x + \text{LeakyReLU}(x) \odot A \cdot \sin(\omega \cdot (x \odot s)) \quad (4)$$

其中, $\sin(\cdot)$ 为正弦函数, $\odot$ 表示哈达玛积,LeakyReLU 为改进的ReLU激活函数,解决了原本存在的梯度消失问题, A, ω 均为超参数,用于控制映射变换强度。 $s \in \mathbb{R}^r$ 由标签上下文动态生成:

$$s = \sigma(c \cdot W_s) \quad (5)$$

其中 W_s 为一个轻量可训练投影矩阵。该设计使得 LAS 函数能够根据情感标签语义自适应地调节低秩更新项 x 中各维度的激活强度。图 2 展示了不同超参数下 LAS。

1.3 开放词汇情感识别

本文的任务为开放词汇下的情感识别,超越了基本的情感类别。但也正因为这种特性,需要对预测后的结果进行一定处理才能用于评估计算,我们仿照 AffectGPT^[10]的工作,对其进行消除同义词影响以得到最终用于评估的情感标签。

具体来说,采用一套三级分组策略来缓解同义词的影响:

第一级:将不同形式的情感词映射到其基本形式。如将“happier”和“happiness”映射为“happy”。此函数表示为 $F_{11}(\cdot)$

第二级:将同义词映射到统一标签。如将“happy”和“joyful”映射为“happy”。此映射函数表示为 $F_{12}(\cdot)$

第三级:借助情感轮提供自然分组信息(核心情感显示在内圈,更细微的标签在外圈)的特性,将第 w 扇区外圈的情感标签映射到对应的内圈标签。考虑到多种情感轮的划分方法,我们使用 K 个较为权威的情感轮。因此这样的映射函数可以表示为 $F_{13}^{wk}(\cdot)$, $k \in [1, K]$ 。

基于此,上述三级分组策略可以总结为:

$$G_{wk}(\cdot) = F_{13}^{wk}(F_{12}(F_{11}(\cdot))) \quad (6)$$

其中, $k \in [1, K]$, K 为选择的情感轮个数。

通过上述策略,本文实现了端到端的开放词汇语音情感识别,能够更准确地刻画真实世界中丰富且细腻的情感表达。




图 2 不同超参数下的 LAS 函数

Fig.2 LAS Function under Different Hyperparameters

2 实验设置与分析

2.1 数据集介绍

为了验证所提方法的性能,本文采用了 MER-Caption plus^[10]和 OV-MERD^[23]数据集。二者均为开放

词汇情感数据集:前者包含 1972 种情感类别,后者则包含 236 种。这两个数据集均为描述性情感数据集,均采用模型与人工协同的标注策略。其中, MER-Caption Plus 采用模型主导、人工辅助的策略,而 OV-

MERD 则采用人工主导、模型辅助的标注策略。

表 1 情感描述数据集

Table 1 Emotion Description Dataset

	数据集	样本数量	情感数量	标注方式
Description Dataset	MER-Caption plus	31327	1972	Model-led+ Human-assisted
	OV-MERD	332	236	Human-led+ Model-assisted
Categorical Dataset	IEMOCAP	6433	6	Human
	MELD	13708	7	Human
	MER2023,	5030	6	Human

两种数据集的相关信息如表 1 所示。在本文中,我们在 MER-Caption Plus 上训练模型,并在 OV-MERD 上评估我们模型的性能。

为全面验证所提方法在不同情感分析场景下的适用性,除上述开放词汇情感数据集外,本文还引入三个主流的传统类别型情感数据集: MER2023^[24], IEMOCAP^[25]和 MELD^[26],以评估其在封闭类别设定下的性能,从而验证方法的通用性与鲁棒性。上述数据集的详细信息汇总于表 1。

2.2 评估指标

仿照之前的工作,我们使用准确率 Precision 来评估正确预测标签的数量,使用召回率 Recall 来评估是否覆盖所有真实标签。此外,我们计算两个指标的调和均值 WF,由于 WF 同时考虑了准确性和完整性,我们将其作为主要指标, Precision 和 Recall 作为次要指标,其计算公式如下。

$$Precision = \frac{TP}{TP + FP} \quad (7)$$

$$Recall = \frac{TP}{TP + FN} \quad (8)$$

$$WF = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (9)$$

其中, TP 表示实际为正类且被模型正确预测为正类的样本数量; FP 表示实际为负类但被模型错误预测为正类的样本数量。 FN 表示实际为正类但被模型错误预测为负类的样本数量。

此外,为了在传统数据集上评估本文所提出的方法,本文引入了一种新的评估指标: 命中率 (HiT)。当真实标签 y_i 属于模型输出标签集合 $\hat{Y}_i$ 时,命中率记为 1, 否则记为 0。由于 $\hat{Y}_i$ 为自由形式的情感描述文本,因此需要使用公式 (6) 将其映射至归一化的情感

基础集合 Y 。HiT 的计算公式如下:

$$HiT = \frac{1}{N} \sum_{i=1}^N \mathbb{I}[G_{wk}(y_i) \in G_{wk}(\hat{Y}_i)] \quad (10)$$

其中, N 为样本总数, y_i 表示第 i 个样本的真实情感标签, $\hat{Y}_i$ 为模型生成的情感描述标签集合, $G_{wk}(\cdot)$ 为第 1.3 节所述的三级归一化函数,用于将原始标签映射至统一的基础情感空间; $\mathbb{I}[\cdot]$ 为指示函数,当条件成立时取值为 1, 否则为 0。

因此,本文采用命中率 (HiT) 作为评估指标,以衡量模型输出是否至少覆盖了真实的基础情感标签。

2.3 实验设置

本文基于 PyTorch 框架实现。音频描述生成采用 SALMONN^[27]模型,大语言模型采用 Qwen2.5-7B^[28]。训练过程中冻结 LLM 的全部权重,仅对额外的 LoRA-LAS 模块进行微调。所有的模型均基于 PyTorch 实现,并在配备 48 GB 显存的 NVIDIA Tesla A40 GPU 上完成训练与推理。LAS 模块中的两项超参数分别设置为 $A = 2 \times 10^{-4}$ 和 $\omega = 1 \times 10^4$ 。

为便于复现与使用所提方法,本文已在 GitHub 上开源相关实现代码。

2.4 开放词汇数据集上的实验分析

本文在上述评估基准上,与当前最先进方法 AffectGPT^[10]以及包括 (SALMONN^[27]、Qwen-Audio^[29]、SECap^[30]) 在内的主流语音大模型进行了一系列对比实验,实验结果表明,本文所提方法性能更优。

表 2 给出了本文方法与上述方法的实验结果对比。由此可见,本文提出的 LoRA-LAS 在不同秩配置下

均体现出稳定的性能优势。尤其值得关注的是，即便在极低秩（ $r = 4$ ）设置下，其性能已超过原始 AffectGPT 在更高秩（ $r = 8$ ）时的表现。考虑到 LoRA 的可训练参数量与秩 r 大致呈线性关系，这意味着 LoRA-LAS 仅用约一半的可训练参数，就能实现更强

的情感建模能力。这一结果印证了方法设计时的核心思路，即传统 LoRA 的线性低秩更新，难以充分捕捉开放词汇情感语义的非线性特征，而通过引入标签感知的非线性映射（LAS），可在有限参数预算下，更高效地激活大语言模型中已有的情感知识。

表 2 不同模型方法结果对比
Table 2 Comparison of Different Models

模型	模态	Precision	Recall	WF
SECap	A T	54.52	39.37	45.72
Qwen-Audio	A T	52.44	41.43	46.29
SALMONN	A T	50.20	45.92	47.96
AffectGPT($r=8$)	A T	56.02	63.55	59.55
AffectGPT($r=16$)	A T	58.48	65.59	61.83
AffectGPT+ (LoRA+) ($r=8$)	A T	56.55	64.30	60.15
AffectGPT+DoRA($r=8$)	A T	57.12	65.10	60.92
AffectGPT+PiSSA($r=8$)	A T	57.02	64.92	60.70
AffectGPT+LoRA-LAS($r=4$)	A T	56.78	65.28	60.73
AffectGPT+LoRA-LAS($r=8$)	A T	57.21	65.49	61.07
AffectGPT+LoRA-LAS($r=16$)	A T	60.03	66.27	63.00

在与 LoRA+、DoRA、PiSSA 等近期 LoRA 改进方法的对比中，LoRA-LAS 在相同秩条件下始终表现更优。这说明，动态缩放、方向解耦或语义初始化等通用适配增强策略，虽能提升模型灵活性，但如果缺乏对情感标签语义特性的显式建模，仍难以充分释放低秩空间的表达潜力。相比之下，LAS 通过将情感标签的语义上下文动态融入非线性变换，实现了对低秩更新路径的精细调控，从而在不明显增加参数量的前提下，有效缓解了低秩约束与情感语义复杂性之间的矛盾。

与此同时，随着秩的提升，LoRA-LAS 的性能持续提升，表明该方法不仅适用于参数受限场景，还具备良好的可扩展性。这进一步支撑了我们的观点：非线性并非对低秩结构的破坏，而是对其表达能力的增强。通过合理设计的非线性函数，可以让模型在保持

参数高效性的同时，同时具备更强的语义分辨能力。

此外，我们对模型输出进行了深入的研究分析。如图 3 所示，我们观察到，为 LoRA 方法引入 LAS 非线性函数映射后，不但输出的情感描述内容更加丰富，生成的序列长度有所提升。而且还会充分发掘 LLM 中的词汇，生成更加细微、微妙的情感描述。



图 3 开放词汇情感描述词云图
Fig.3 Open-Vocabulary Emotional Description Word Cloud

表 3 不同微调方法在多情感基准上的性能对比
Table 3 Performance of Different Fine-tuning Methods Across Multiple Affective Benchmarks

数据集	MELD (HIT)	IEMOCAP (HIT)	CMU-MOSI (WF)	OV-MERD (WF)
AffectGPT($r=8$)	56.27	60.14	81.11	59.55

数据集	MELD (HIT)	IEMOCAP (HIT)	CMU-MOSI (WF)	OV-MERD (WF)
AffectGPT+DoRA($r=8$)	58.44	60.88	81.30	60.70
AffectGPT+LoRA-LAS($r=8$)	60.76	61.21	81.97	61.07

2.5 传统类别数据集上的实验分析

为验证所提方法的泛化能力, 本文在多个异构情感识别基准上进行了评估, 涵盖对话情感 (MELD、IEMOCAP)、多标签情感分析 (CMU-MOSI) 以及开放词汇语音情感识别 (OV-MERD)。如表 3 所示, 在所有数据集上, AffectGPT+LoRA-LAS ($r=8$) 均取得一致的性能提升, 表明该方法不仅适用于开放词汇设定, 也能有效迁移至传统封闭类别任务。

实验结果表明, 尽管这些任务在任务构成、标签体系和语境复杂度上差异显著, LoRA-LAS 仍能稳定带来性能提升。这就表明, 标签感知的非线性适配机制并非仅适合于特定数据分布, 而是通过动态建模情感语义结构, 提升了模型对不同情感表达形式的适应能力。尤其在 MELD 这类高噪声、多说话人的对话场景中, LoRA-LAS 相比 DoRA 和原始 AffectGPT 的提升幅度更为突出, 这体现出它在复杂语境下对细粒度情感线索更强的捕捉能力。

表 4 不同秩数下的训练参数量

Table 4 Number of Training Parameters under Different Ranks

秩数	可训练参数量	WF
4	10,092,544	60.73
8	20,185,088	61.07 ($\Delta 0.34$)
16	40,370,176	63.00 ($\Delta 1.93$)

2.6 训练参数量分析

表 4 展示了在 OVMERD 数据集上不同秩 (r) 设置下的可训练参数量以及性能表现。可见, 随着秩的增大, 可训练参数量显著增加, 对 GPU 计算资源与显存造成较大压力。相比之下, 本文提出的 LoRA-LAS 在低秩条件下仍能保持优异性能, 展现出更强的参数效率与适应能力。

3 结束语

本文面向开放词汇语音情感识别这一新兴任务,

提出了一种改进的低秩适配方法 LoRA-LAS。该方法通过引入标签感知缩放 (LAS) 非线性映射机制, 在不显著增加参数量的前提下, 有效缓解了传统 LoRA 因线性低秩假设导致的表达能力受限问题。实验结果表明, LoRA-LAS 在 MER-Caption Plus 和 OV-MERD 数据集上均取得了优于现有方法的性能, 尤其在低秩配置下优势显著, 验证了其在参数效率与模型表达能力之间的良好平衡。尽管如此, 当前方法仍存在一定局限, LAS 函数采用 LeakyReLU 与正弦调制相结合的固定形式, 其结构和超参数 (振幅 A 与频率 ω) 的选择主要依赖经验调优, 缺乏自适应调整能力。其次, 标签感知目前仅作为非线性映射的输入, 尚未与低秩矩阵 A 和 B 的学习过程进行深度耦合, 可能限制了语义先验对参数更新方向的引导作用。未来, 我们将探索情感上下文向量前置于低秩矩阵生成阶段, 通过门控机制实现更紧密的语义与参数的协同优化。此外, 后续计划将 LoRA-LAS 推广至其他生成式任务 (如细粒度视频描述等), 进一步验证其泛化能力。

总体而言, 本文不仅为开放词汇语音情感识别提供了高效可行的微调方案, 也为大模型在低秩约束下如何融合任务语义先验提供了新思路, 有望推动参数高效微调方法在垂直领域语义理解中的深入应用。

参考文献:

- [1] FAHAD M S, RANJAN A, YADAV J, et al. A survey of speech emotion recognition in natural environment[J]. Digital signal processing, 2021, 110: 102951.
- [2] LI S, XING X, FAN W, et al. Spatiotemporal and frequential cascaded attention networks for speech emotion recognition[J]. Neurocomputing, 2021, 448: 238-248.
- [3] XU X, LI D, ZHOU Y, et al. Multi-type features separating fusion learning for speech emotion recognition[J]. Applied Soft Computing, 2022, 130: 109648.
- [4] ALNUAIM A A, ZAKARIAH M, SHUKLA P K, et al. Human-computer interaction for recognizing speech emotions using multilayer perceptron classifier[J]. Journal of Healthcare Engineering, 2022, 2022(1): 6005446.
- [5] GONG B, LI Q, ZHAO Y, et al. Auditory emotion recognition deficits in schizophrenia: a systematic review and

- meta-analysis[J]. *Asian Journal of Psychiatry*, 2021, 65: 102820.
- [6] GAO X, MA K, YANG H, et al. A rapid, non-invasive method for fatigue detection based on voice information[J]. *Frontiers in Cell and Developmental Biology*, 2022, 10: 994001.
- [7] MARGHESCU B, TOMA Ş A, MOROGAN L, et al. Speech emotion recognition for emergency services[C]//2023 International Conference on Speech Technology and Human-Computer Dialogue (SpeD). Piscataway: IEEE, 2023: 105-110.
- [8] CADAYONA A M, CERILLA N M S, JURILLA D M M, et al. Emotional state classification: an additional step in emotion classification through face detection[C]//2019 IEEE 6th International Conference on Industrial Engineering and Applications (ICIEA). Piscataway: IEEE, 2019: 667-671.
- [9] LIANG Z, XU Y, HONG Y, et al. A survey of multimodal large language models[C]//Proceedings of the 3rd International Conference on Computer, Artificial Intelligence and Control Engineering. Piscataway: IEEE, 2024: 405-409.
- [10] LIAN Z, et al. AffectGPT: a new dataset, model, and benchmark for emotion understanding with multimodal large language models[C]//Proceedings of the 42nd International Conference on Machine Learning. Vienna: PMLR, 2024.
- [11] HU E J, SHEN Y, WALLIS P, et al. LoRA: low-rank adaptation of large language models[C]//Proceedings of the International Conference on Learning Representations (ICLR). Vienna: ICLR, 2022.
- [12] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[C]//3rd International Conference on Learning Representations (ICLR 2015). San Diego: Computational and Biological Learning Society, 2015.
- [13] HSU W N, BOLTE B, TSAI Y H H, et al. HuBERT: self-supervised speech representation learning by masked prediction of hidden units[J]. *IEEE/ACM transactions on audio, speech, and language processing*, 2021, 29: 3451-3460.
- [14] WANI T M, GUNAWAN T S, QADRI S A A, et al. A comprehensive review of speech emotion recognition systems[J]. *IEEE Access*, 2021, 9: 47795-47814.
- [15] PENG Z, LU Y, PAN S, et al. Efficient speech emotion recognition using multi-scale CNN and attention[C]//2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Piscataway: IEEE, 2021: 3020-3024.
- [16] NEDIYANCHATH A, PARAMASIVAM P, YENIGALLA P. Multi-head attention for speech emotion recognition with auxiliary learning of gender recognition[C]//2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Piscataway: IEEE, 2020: 7179-7183.
- [17] ANDO A, MASUMURA R, SATO H, et al. Speech emotion recognition based on listener adaptive models[C]//2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Piscataway: IEEE, 2021: 6274-6278.
- [18] TIWARI U, SONI M, CHAKRABORTY R, et al. Multi-conditioning and data augmentation using generative noise model for speech emotion recognition in noisy conditions[C]//2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Piscataway: IEEE, 2020: 7194-7198.
- [19] HAYOU S, GHOSH N, YU B. LoRA+: efficient low-rank adaptation of large models[C]//Proceedings of the 41st International Conference on Machine Learning. Vienna: PMLR, 2024: 17783-17806.
- [20] LIU S Y, WANG C Y, YIN H, et al. DORA: weight-decomposed low-rank adaptation[C]//Proceedings of the 41st International Conference on Machine Learning. Vienna: PMLR, 2024.
- [21] MENG F, WANG Z, ZHANG M. PISSA: principal singular values and singular vectors adaptation of large language models[C]//Advances in Neural Information Processing Systems. Red Hook: Curran Associates, 2024, 37: 121038-121072.
- [22] LI Y, SONG L, HOU H. LoRAN: improved low-rank adaptation by a non-linear transformation[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Stroudsburg: Association for Computational Linguistics, 2024: 3134-3143.
- [23] MA Z, ZHANG S, WEI L, et al. OVMR: open-vocabulary recognition with multi-modal references[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2024: 16571-16581.
- [24] LIAN Z, et al. MER 2023: multi-label learning, modality robustness, and semi-supervised learning[C]//Proceedings of the 31st ACM International Conference on Multimedia. New York: ACM, 2023.
- [25] BUSSO C, et al. IEMOCAP: interactive emotional dyadic motion capture database[J]. *Language Resources and Evaluation*, 2008, 42(4): 335-359.
- [26] PORIA S, et al. MELD: a multimodal multi-party dataset for emotion recognition in conversations[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: Association for Computational Linguistics, 2019.
- [27] TANG C, YU W, SUN G, et al. SALMONN: towards generic hearing abilities for large language models[C]//The Twelfth International Conference on Learning Representations. Vienna: ICLR, 2024.
- [28] YANG A, YANG B, ZHANG B, et al. Qwen2.5 technical report[EB/OL].[2024-01-01].<https://arxiv.org/abs/2412.15115>.
- [29] CHU Y, XU J, ZHOU X, et al. Qwen-audio: advancing universal audio understanding via unified large-scale audio-



刘康伟 (2001—), 男, 江苏南通人, 硕士研究生, CCF 学生会员, 主要研究方向为语音情感识别、多模态融合等。

Liu Kangwei, born in 2001, M.S. candidate, CCF student member. His research interests include speech emotion recognition, multi-modal fusion, etc.



丁涵宇 (2001—), 男, 江苏常州人, 硕士研究生, 主要研究方向为语音信号处理、语音关键词检测等。

DING Hanyu, born in 2001, M.S. candidate. His research interests include speech signal processing, spoken keyword spotting, etc.



高利剑 (1993—), 男, 江西瑞昌人, 博士, 讲师, CCF 会员, 主要研究方向为智能音频信号处理、声音事件检测等。

Gao Lijian, born in 1993, Ph.D., lecturer CCF member. His research interests include intelligent audio signal processing, sound event detection, etc.



毛启蓉 (1975—), 女, 四川泸州人, 博士, 教授, 博士生导师, CCF 杰出会员, 主要研究方向为多媒体与智能信息处理、情感计算等。

Mao Qirong, born in 1975, Ph.D., professor, Ph.D. supervisor, CCF distinguished member. Her research interests include multimedia and intelligent information processing, affective computing, etc.

language models[EB/OL]. [2023-01-01]. <https://arxiv.org/abs/2311.07919>.

- [30] XU Y, CHEN H, YU J, et al. SECAP: speech emotion captioning with large language model[C]//Proceedings of the AAAI Conference on Artificial Intelligence. Palo Alto: AAAI Press, 2024, 38(17): 19323-19331.