

基于递归门控卷积和上下文注意力的煤块检测算法^{*}

高凯,董立红,邓凡

(西安科技大学 计算机科学与技术学院, 陕西 西安 710600)

摘要:针对煤矿带式输送机上煤块检测因光照不均存在的漏检与误检问题,提出一种基于门控卷积和上下文注意力机制的改进YOLOv5煤块检测算法。首先,将主干网络中残差模块替换为递归门控卷积模块,通过逐步融合特征信息,提取高阶语义特征,增强模型的特征提取能力。其次,在特征融合结构中加入GCA注意力机制,将全局上下文信息融入坐标注意力模块中,加强感兴趣区域的全局表示,增强多尺度特征融合能力,提高模型对煤块边缘特征的敏感度。最后,采用SIoU损失函数,加速网络模型的收敛。试验结果表明,改进的算法在自建煤块数据集上平均精度均值达到92.8%,召回率达到85.9%,检测速度达到38帧/s。既提高了检测精度,又满足了检测的实时性。

关键词:带式运输;煤块检测;目标检测;注意力机制;YOLOv5

中图分类号:TD528+.1 **文献标识码:**A

文章编号:1005-2763(2023)06-0183-08

0 引言

煤炭是国家的支柱能源,各行各业都离不开煤炭的支撑。在矿山运煤环节,皮带作为主要的工具之一,经常遭受到不同程度的损伤,甚至造成撕裂。其中,煤块的掉落是损伤皮带的潜在因素。随着皮带更换次数的增加,企业经济损失也随之增加。因此,通过视频监控及时有效地实现煤块检测,提高视频智能预警能力^[1],是保证皮带输送机高效运行的重要措施之一。

传统的皮带上煤块检测方法受复杂场景的限制,且响应时间长。随着人工智能和深度学习的发展,基于深度学习的煤块检测方法得到广泛的应用。目前,目标检测算法主要分为一阶段目标检测算法和两阶段目标检测算法。

(1) 两阶段目标检测算法如:Faster R-CNN^[2]

和Mask-RCNN^[3]等。这类算法检测精度较高,但检测速度较慢,无法满足工业检测实时性的要求。

(2) 一阶段检测算法如YOLOv4^[4]、YOLOv5^[5]和YOLOv7^[6]等。一阶段目标检测算法检测精度低于两阶段目标检测算法,但是一阶段检测速度优于两阶段算法,可以有效平衡精度与速度。但是由于皮带上煤块相互重叠、密集和边缘特征不突出,容易引起漏检和误检,使得煤块的检测精度低。

针对以上问题,本文提出一种基于改进YOLOv5s的煤块检测算法。

(1) 在主干网络中将残差模块替换为递归门控卷积模块^[7],该模块在考虑局部建模的基础上,提升了远程和高阶空间交互的建模能力,捕获全局和局部信息的自适应融合,增强了对目标的表达能力。

(2) 构建全局上下文坐标注意力模块,将上下文信息嵌入坐标注意力(Coordinate Attention)^[8]机制,加强感兴趣区域的表示及定位能力,从而增强不同尺度特征融合能力,提高模型对目标边缘特征的敏感度。

(3) 采用SIoU^[9]损失函数,减少检测过程中样本重叠的现象,加速模型收敛,进一步提高煤块的定位精度。

1 相关工作

1.1 皮带上目标检测

传统方法是通过诸如颜色、纹理等提取煤块特征,并且该方法需要人工设计特征,张渤等^[10]通过对图像进行预处理、灰度化、阈值分割,提取运动煤块进行标记,实现了大块煤检测。然而,在复杂的煤矿场景下该方法鲁棒性差,很难满足实际工作需要。

基于深度学习的方法逐渐成为主流方法。杜京

^{*} 收稿日期:2022-09-07

基金项目:陕西省自然科学基金基础研究计划项目(2019JLM-11);陕西省教育厅科研计划专项项目(8146119003);陕西省自然科学基金项目(2018JQ5095)。

作者简介:高凯(1996—),男,陕西宝鸡人,硕士研究生,研究领域为深度学习与机器视觉,E-mail:gaokai0907@163.com。




图2 GNGCA-YOLOv5 网络结构

GNGCA-YOLOv5 网络模型通过引入递归门控卷积模块重新构建 C3 模块,通过相邻元素间的交互信息,逐步捕获高阶语义信息,增强特征提取能力,提高模型的检测精度。同时构建了具有位置信息和上下文信息的注意力模块 GCA,将 GCA 模块添加到信息聚合后,能更好关注全局上下文的通道信息和坐标位置信息,扩大了网络的全局感知范围,并在 GCA 中引入深度可分离卷积,使参数量降低,检测速度提高,更高效地聚焦目标位置。

3.1 递归门控卷积模块

YOLOv5 目标检测算法采用集成残差模块的 CSP 结构进行特征提取,但是残差模块无法充分融合多尺度特征信息,缺乏高阶远程建模能力,对煤块重叠检测问题不能有效解决。因此,引入递归门控卷积模块,它可以通过相邻特征间的信息交互,逐步获取目标的高阶特征,提高较小目标检测能力。

由递归门控卷积模块构建的 C3GN 模块如图 3 所示。C3GN 模块采用 CSP 结构构成,首先通过一个卷积层后分别采用两个分支提取特征,其中一个分支采用卷积操作,另一个分支采用递归门控卷积模块逐块提取特征,然后将两个分支提取特征合并,最后再由一个卷积层输出特征图。

递归门控卷积模块(GnBlock)由递归门控卷积层归一化(Layer Norm)和全连接层(MLP)构成。主要的部分是递归门控卷积(g^n Conv),首先经过一个独立卷积层通道数调整为输入通道 C 的 2 倍,指定阶数 k 划分为不同通道数的块,如式(1)所示。并得到一组特征投影 $p_0^{H \times W \times C_0}, q_0^{H \times W \times C_0}, \dots, q_k^{H \times W \times C_k}$,如式(2)所示。

$$C_k = C // 2^k (k \in 0, \dots, n-1) \quad (1)$$

$$[p_0^{H \times W \times C_0}, q_0^{H \times W \times C_0}, \dots, q_{n-1}^{H \times W \times C_{n-1}}] =$$

$$\varphi(x) \in R^{H \times W \times (C_0 + \sum_{0 \leq k \leq n-1} C_k)} \quad (2)$$

式中, C_k 代表 k 个通道数维度大小; $x \in R^{H \times W \times C}$ 是输入特征; H, W 代表输入图像高度和宽度; C 代表通道数; $\varphi(\cdot)$ 代表卷积操作。

将 q_k 整体通过一个独立的 7×7 深度分离卷积后乘以一个独立的缩放系数 α 。再与每一块 q_0 的特征与前一块 p_k 的特征进行逐元素相乘,实现当前特征与相邻特征的交互,最终得到输出特征 p_{k+1} 。最后通过 1×1 卷积,保持通道数不变,如式 3 所示。

$$p_{k+1} = f_k(q_k) \otimes c_k(p_k) / \alpha \quad (k = 0, 1, \dots, n-1; \alpha = 1) \quad (3)$$

式中, f_k 代表一组深度卷积操作; $\otimes$ 代表逐元素相乘; c_k 代表卷积操作。缩放系数用于模型的稳定训练。

通过这种相邻特征交互的方式,加强了相邻块间信息的沟通。逐步细化局部特征,进而增加了高阶空间的语义信息,增强了模型的特征提取和表达能力。




图3 C3GN 模块

3.2 GCA 注意力模块

在煤块检测中,煤块的边缘特征差异不明显。因此,为了增强对煤块目标的检测能力和定位能力,在原始 CA 注意力模块中构建全局平均池化分支获取全局上下文信息,在较少增加计算量的前提下,有效减少不必要的信息,加强突出感兴趣区域的特征表达。凸显边缘特征,增强煤块的检测能力。

特征融合阶段主要获取丰富的空间细节和语义信息来提高特征利用率,底层特征由于卷积操作不可避免会丢失一些有效信息,削弱最终的尺度特征表示。GCA 注意力模块结构不仅能够捕获跨通道的位置信息,还能聚合各种特征语义信息,如图 4 所示。

GCA 模块采用原始坐标注意力分支、上下文分支和残差分支。CA 分支分别利用两个一维平均池化沿着水平和垂直方向对输入的特征图提取特征,提取两个空间上的权重信息,如式(4)、式(5)所示。

$$z_c^h(h) = \frac{1}{W} \sum_{i=0}^{W-1} x_c(h, i) \quad (4)$$

$$z_c^w(w) = \frac{1}{H} \sum_{j=0}^{H-1} x_c(j, w) \quad (5)$$

式中, z^h, z^w 代表垂直方向和水平方向的特征图。




图4 GCA模块

随后将垂直和水平方向的特征聚合为两个独立的方向感知特征映射,如式(6)所示。

$$F_1 = \sigma(c^{1 \times 1}(\sigma(c^{1 \times 1}([z^h; z^w]))) \quad (6)$$

式中, F_1 代表 CA 注意力权重特征图; σ 代表 Sigmoid 激活函数。

式(6)表明,每个注意力图都包含了输入特征图沿空间方向的远程依赖关系,并保存沿着另一个空间方向的精确位置信息,使得网络能更好、更准确地获取感兴趣区域。

上下文分支对于输入特征图先使用 3×3 深度卷积学习上下文不同通道的重要性,在深度卷积输出后通过 1×1 卷积捕获上下文通道间信息关系,再使用全局平均池化操作获取全局上下文信息,增强模型对通道间的敏感性,如式(7)所示。

$$F_2 = \text{AvgPool}(\delta(c^{1 \times 1}(\delta(c^{3 \times 3}(x)))) \quad (7)$$

式中, F_2 是上下文分支的特征图; δ 代表 Gelu 激活函数; $c^{1 \times 1}, c^{3 \times 3}$ 分别代表卷积核为 1 和卷积核为 3 的卷积; $\text{AvgPool}(\cdot)$ 代表全局平均池化操作。

同时将特征图变换到和 x 输入相同的通道数。采用 Gelu 激活函数和批归一化层(BatchNorm)增强网络的非线性能力。

将 CA 分支和上下文信息分支采用矩阵相乘的

方法求得最终的注意力权重矩阵。

最后,将残差分支原特征图 x 与得到的特征图相加,以减少细节信息的损失,从而实现模型对目标的识别和定位目标,如式(8)所示。

$$y = x + F_1 \times F_2 \quad (8)$$

式中, y 是输出特征图。

3.3 损失函数

IoU^[23] 损失可以更准确地预测边界盒回归的局部化,在 YOLO 系列最常用的是 CIoU^[24],随着研究的不断深入,IoU 的变体越来越多,如 DIoU^[25]、GIoU^[26]、EIoU^[27] 和最新的 SIoU。SIoU 考虑真实框和检测框的角度关联性,重新定义相关损失函数。SIoU 的相关计算公式如下:

$$L_{\text{SIoU}} = 1 - I(A, B) + \frac{\Delta + \Omega}{2} \quad (9)$$

$$\Lambda = 1 - 2 \times \sin^2\left(\arcsin\left(\frac{U_h}{d}\right) - \frac{\pi}{4}\right) = \cos\left(2 \times \left(\arcsin\left(\frac{U_h}{d}\right) - \frac{\pi}{4}\right)\right) \quad (10)$$

$$\Delta = \sum_{t=x,y} (1 - e^{-\gamma \rho_t}) = 2 - e^{-\gamma \left(\frac{b_{c_x}^{\text{gt}} - b_{c_x}}{c_w}\right)^2} - e^{-\gamma \left(\frac{b_{c_y}^{\text{gt}} - b_{c_y}}{c_h}\right)^2} \quad (11)$$

$$\frac{U_h}{d} = \sin(\omega) \quad (12)$$

$$d = \sqrt{(b_{c_x}^{\text{gt}} - b_{c_x})^2 + (b_{c_y}^{\text{gt}} - b_{c_y})^2} \quad (13)$$

$$U_h = \max(b_{c_y}^{\text{gt}}, b_{c_y}) - \min(b_{c_y}^{\text{gt}}, b_{c_y}) \quad (14)$$

$$\Omega = \sum_{t=x,y} (1 - e^{-W_t})^\theta = (1 - e^{-W_w})^\theta + (1 - e^{-W_h})^\theta \quad (15)$$

式中, L_{SIoU} 为 SIoU 的损失值; $W_w = \frac{|w - w^{\text{gt}}|}{\max(w, w^{\text{gt}})}$,

$W_h = \frac{|h - h^{\text{gt}}|}{\max(h, h^{\text{gt}})}$, (w, h) 和 $(w^{\text{gt}}, h^{\text{gt}})$ 分别为预测框和真实框的宽和高; Λ 代表角度损失; Δ 代表距离损失; Ω 代表形状损失; 参数 A 和参数 B 分别代表真实框区域面积和预测框区域面积; $I(A, B)$ 为预测框 B 和真实框 A 的交并比; U_h 为真实框和预测框中心点的高度差; d 为真实框和预测框中心点的距离; $(b_{c_x}^{\text{gt}}, b_{c_y}^{\text{gt}})$ 为真实框中心坐标; (b_{c_x}, b_{c_y}) 为预测框中心坐标; ω 代表真实框中心的坐标与预测框角中心点坐标之间的角度; (c_w, c_h) 为真实框和预测框最小外接矩形的宽和高; θ 是形状损失权重。

4 试验结果与分析

4.1 试验环境与数据

试验运行环境为 Ubuntu16.04, CPU 为 Intel

(R) Xeon(R) Gold 6330, GPU 为 NVIDIA GeForce RTX 3090, 利用 cuda11.3, pytorch 版本1.11.0深度学习框架实现。超参数设置如下:学习率为 0.01, 动量参数为 0.937, 权重衰减因子为 0.0005, 批处理大小为 64, 图片分辨率为 640×640 , 训练周期为 100 次。模型在训练时均采用颜色增强、随机反转和马赛克数据增强方法来增强模型的鲁棒性, 以防止过拟合。

选择煤矿带式输送机上煤块作为研究对象, 试验数据集来源于真实的煤矿作业监控视频片段, 采样间隔 1 s, 共采集 6859 张图像。训练集共 5555 个样本、验证集共 618 个样本、测试集共 686 个样本, 整个数据集涵盖了不同大小的煤块。

4.2 评价指标

为了验证改进后的 YOLOv5s 性能, 使用精度、召回率、AP@0.5 和帧速率作为验证指标。精度 $U_{\text{precision}}$ 计算为正确预测的正样本数与预测为正样本的样本数的比例。计算公式如式(16)所示:

$$U_{\text{precision}} = \frac{TP}{TP + FP} \quad (16)$$

召回率 U_{recall} 计算为正确预测的所有目标的比例。计算公式如式(17)所示:

$$U_{\text{recall}} = \frac{TP}{TP + FN} \quad (17)$$

式中, TP 表示被正确分类的正例数; FP 表示被错误分类的正例数; FN 表示被正确分类的负例数。

AP@0.5 的计算公式如式(18)所示:

$$AP@0.5 = \int_0^1 P(R) dR \quad (18)$$

式中, AP@0.5 是指 IoU 设置为 0.5 时类别的平均准确率。

4.3 不同模块有效性试验

在试验过程中均保持相同的超参数, 试验中以分辨率为 640×640 的图像作为图像的输入。本文在自建煤块数据集上分别进行试验, 以验证模块的有效性。结果见表 1。

表 1 不同模块有效性试验

算法	平均精度均值/%	帧速率/(帧/s)
YOLOv5s	90.3	59
+GnBlock	91.4	42
+GCA	91.2	41
+SIoU	90.7	58
+GnBlock+GCA	92.4	38
+GnBlock+GCA+SIoU	92.8	38

从表 1 可以看出:不同模块在 YOLOv5s 算法基础上平均精度均值都有不同程度的提升。

(1) 为了进一步加强尺度高阶空间特征信息表达能力, 本文在主干网络将原有算法中 C3 结构的残差模块替换为递归门控模块, 有效地捕获了空间高阶信息, 细化了局部信息。平均精度均值提升了 1.1 个百分点, 检测速度为 42 帧/s。

(2) 在考虑了上下文语义信息基础上, 加入 GCA 注意力模块, 平均精度均值提升了 0.9 个百分点, 检测速度保持不变, 表明该方法加强了多尺度特征图语义信息融合, 更关注于煤块特征, 削弱背景信息带来的干扰。能够提高煤块检测效果, 验证了 GCA 注意力的有效性。特征可视化结果如图 5、图 6 所示。

(3) 引入 SIoU 损失函数, 平均精度均值提升了 0.4 个百分点, 该损失函数在引入向量角度权重后, 减低了样本重叠间的误检, 有效提升了检测精度。




图 5 YOLOv5s 特征可视化




图 6 GNGCA-YOLOv5 特征可视化

4.4 模型检测性能对比

为了验证本文所提出算法在自建煤块数据集的检测效果, 所有方法都是在同等模型大小和参数量的情况下进行对比。对比原始 YOLOv5 模型和改进后的 YOLOv5 模型在相同训练条件下的损失曲线变化情况, 如图 7 所示。不同算法的平均精度均值如图 8 所示, 不同算法对比结果见表 2。




图7 loss 损失函数变化曲线




图8 模型性能对比曲线

从图7可以看出,改进后的YOLOv5模型的收敛速度和效果都优于原始YOLOv5s算法。改进后YOLOv5算法在0~30个训练周期下降得非常快,训练周期达到40个周期后,趋势缓慢平缓,直到模

型收敛,且模型未出现过拟合现象。

表2 模型性能对比试验结果

算法	参数量/ ($\times 10^6$)	召回率/ %	平均精度 均值/%	帧速率/ (帧/s)
YOLOv3-tiny	8.67	76.9	83.2	175
YOLOv4s	9.11	82.2	88.3	41
YOLO5s	7.05	81.1	90.3	58
YOLOx-s	8.04	84.0	91.4	47
YOLOv7-tiny	6.01	85.6	89.6	65
ours	7.74	85.9	92.8	38

由图8和表2可以看出,在自制煤块数据集下,输入分辨率为 640×640 。与YOLOv3-tiny、YOLOv4s、YOLOv5s、YOLOx-s和YOLOv7-tiny进行了对比。试验表明,与其他算法相比,本文所提出的方法在煤块检测中达到了92.8%的检测精度,召回率为85.9%,检测速度为38帧/s。较其他算法平均精度均值分别提升了9.6、4.5、2.5、1.4和3.2个百分点。召回率分别提高了9.0、3.7、4.8、1.9和0.3个百分点。在算法参数量相当的前提下,本文提出的方法虽然检测精度得到了较大提升,但在检测速度上有所下降,不过仍能满足工业检测的要求。

不同算法的检测结果如图9所示,YOLOv3-tiny算法误检和漏检情况较多,YOLOv5s算法检测出了大多数煤块,但本文所提出的方法对较小煤块目标也能有良好的检测,漏检和误检相对减少,并且置信度都得到了较高的提升。




图9 不同算法煤块检测结果

5 结论

在 YOLOv5s 模型的主干网络区域将残差模块替换递归门控卷积模块作为特征提取网络,解决了模型在多尺度特征提取时缺乏空间高阶特征的问题,捕获更细节的特征。将 GCA 注意力模块嵌入特征融合阶段,充分关注多尺度融合的特征信息,增强了模型对于全局信息的感知,提高了模型定位能力。采用 SIoU 损失计算,加快了算法的收敛速度。在自建煤块数据集上试验结果表明,与 YOLOv5s 检测器相比,GNGCA-YOLOv5 的平均精度均值比基线高 2.5 个百分点,比最新的 YOLOv7-tiny 高 3.2 个百分点,检测速度也满足工业要求。

在未来的工作中,仍需进一步提高模型以适应不同场景的复杂性,以及提升模型的泛化能力和检测速度。

参考文献(References):

- [1] 胡兴涛,朱涛,苏继敏,等.煤矿巷道智能化掘进感知关键技术[J].煤炭学报,2021,46(7):2123-2135.
- [2] REN S Q, HE K M, ROSS G, et al. Faster R-CNN: Towards real-time object detection with region proposal networks[J].IEEE transaction pattern analysis and machine intelligence, 2017,39(6):1137-1149
- [3] HE K M, GKIOXARI G, DOLLÁR P, et al. Mask R-CNN [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence,2020,42(2):386-397.
- [4] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. YOLOv4: Optimal speed and accuracy of object detection[J/OL].arXiv. [2020-04-23].<https://arxiv.org/abs/2004.10934>.
- [5] 郝帅,张旭,马旭,等.基于 CBAM-YOLOv5 的煤矿输送带异物检测[J].煤炭学报,2022,47(11):4147-4156.
- [6] WANG C Y, BOCHKOVSKIY A, LIAO H Y M. YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for realtime object detectors[J/OL].arXiv.[2022-07-06].<https://arxiv.org/abs/2207.02696>.
- [7] RAO Y M, ZHAO W L, TANG Y S, et al. HorNet: Efficient High-Order spatial interactions with recursive gated convolutions [J/OL]. arXiv. [2022-07-28]. <https://arxiv.org/abs/2207.14248>.
- [8] HOU Q B, ZHOU D Q, FENG J S. Coordinate attention for efficient mobile network design[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition,2021:13713-13722.
- [9] GEVORGYAN Z. SIoU Loss: More powerful learning for bounding box regression [J/OL]. arXiv. [2022-05-25]. <https://arxiv.org/abs/2205.12740>.
- [10] 张渤,谢金辰,张后斌.矿井下输送带大块物体检测[J].煤炭技术,2021,40(4):154-156.
- [11] 杜京义,郝乐,王悦阳,等.一种煤矿井下输煤大块物检测方法[J].工矿自动化,2020,46(5):63-68.
- [12] 吴守鹏,丁恩杰,俞啸.基于改进 FPN 的输送带异物识别方法[J].煤矿安全,2019,50(12):127-130.
- [13] 叶鸥,窦晓熠,付燕,等.融合轻量级网络和双重注意力机制的煤块检测方法[J].工矿自动化,2021,47(12):75-80.
- [14] 张旭辉,闫建星,张超,等.基于改进 YO-LOv5s+DeepSORT 的煤块行为异常识别[J].工矿自动化,2022,48(6):77-86+117.
- [15] 李若熙,吕潇,张元生,等.改进 YOLOv4 算法井下人员检测的研究[J].矿业研究与开发,2021,41(11):179-185.
- [16] 延晓宇,董立红,库向阳,等.改进的 FCOS 煤矿井下行人检测算法[J].矿业研究与开发,2022,42(4):160-165.
- [17] 郭永存,童佳乐,王爽.井下无人驾驶电机车行驶场景中多目标检测研究[J].工矿自动化,2022,48(6):56-63.
- [18] 桂方俊,李尧.基于 CBA-YOLO 模型的煤矸石检测[J].工矿自动化,2022,48(6):128-133.
- [19] 沈科,季亮,张袁浩,等.基于改进 YOLOv5s 模型的煤矸目标检测[J].工矿自化,2021,47(11):107-111+118.
- [20] HU J, SHEN L, SUN G. Squeeze-and-Excitation networks [C]//Proceedings of The IEEE Conference on Computer Vision and Pattern Recognition,2018:7132-7141.
- [21] WOO S, PARK J, LEE J Y, et al. CBAM: convolutional block attention module [C]//2018 ECCV Conference on Computer Vision,Berlin,2018,11211:3-19.
- [22] YAN Pengcheng, SUN Quansheng, YIN Nini, et al. Detection of coal and gangue based on improved YOLOv5.1 which embedded scSE module [J]. Measurement, 2022, 188,110630.
- [23] YU J H, JIANG Y N, WANG Z Y, et al. Unitbox: An advanced object detection network[C]// Proceedings of the 24th ACM international conference on Multimedia, 2016: 516-520.
- [24] ZHENG Z H, WANG P, REN D W, et al. Enhancing geometric factors in model learning and inference for object detection and instance segmentation[J].IEEE Transactions on Cybernetics,2022,52(8):8574-8586.
- [25] ZHENG Z H, WANG P, LIU W, et al. Distance-IoU loss: Faster and better learning for bounding box regression[C]// Proceedings of the AAAI Conference on Artificial Intelligence,2020,34(7):12993-13000.
- [26] REZATOFIGHI H, TSOI N, GWAK J Y, et al. Generalized intersection over union: A metric and a loss for bounding box regression[C]// Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2019:658-666.
- [27] ZHANG Y F, REN W Q, ZHANG Z, et al. Focal and Efficient IOU loss for accurate bounding box regression[J]. Neurocomputing,2022,506:146-157.

Coal Block Detection Algorithm Based on Recursive Gated Convolution and Contextual Attention*GAO Kai, DONG Lihong, DENG Fan*

(School of Computer Science and Technology, Xi'an University of Science and Technology, Xi'an, Shaanxi 710600, China)

Abstract: Aiming at the problem of missed detection and false detection of coal block detection on coal mine belt conveyor due to uneven illumination, an improved YOLOv5 coal block detection algorithm based on gated convolution and contextual attention mechanism was proposed. Firstly, the residual module in the backbone network was replaced with a recursive gated convolution module, and the feature extraction capability of the model was enhanced by gradually fusing feature information to extract high-order semantic features. Secondly, the GCA attention mechanism was added to the feature fusion structure, the global context information was integrated into the coordinate attention module, the global representation of the region of interest was strengthened, the multi-scale feature fusion ability was enhanced, and the model's sensitivity to coal edge features was improved. Finally, the SIOU loss function was adopted to accelerate the convergence of the network model. The experimental results show that the average precision of the improved algorithm on the self-built coal block data set reaches 92.8%, the recall rate reaches 85.9%, and the detection speed reaches 38 frames/s. It not only improves the detection accuracy, but also satisfies the real-time detection.

Key words: Belt conveyor, Coal block detection, Object detection, Attention mechanism, YOLOv5