

DOI:10.13827/j.cnki.kyyk.2025.05.018

改进 YOLOv8n 的矿井火灾检测算法^{*}

苗作华^{1,2}, 周浩¹, 王巧稚^{1,2}, 徐厚友³, 王梦婷³, 张立¹, 白宇宸¹

- (1. 武汉科技大学 资源与环境工程学院, 湖北 武汉 430081;
2. 冶金矿产资源高效利用与造块湖北省重点实验室, 湖北 武汉 430081;
3. 中钢武汉安环院绿世纪安全管理顾问有限公司, 湖北 武汉 430081)

摘要:针对传统火灾检测算法效率低且难以应用于资源有限的嵌入式设备等问题,提出一种改进 YOLOv8n 的火灾检测轻量化算法。首先,为大幅度减少模型参数量,将 YOLOv8n 模型中的 C2f 模块改为 C2fGhost 模块。其次,为防止模型轻量化后重要特征丢失,强化特征提取能力并降低图像中无关信息干扰,在 YOLOv8n 模型的 Backbone 部分加入 EMA 注意力机制。最后,为提升模型泛化能力,将 YOLOv8n 模型中的 CIoU 损失函数替换为 WIoU。试验结果表明,改进后模型的参数量下降 30.1%, mAP_{50-95} 提升了 0.6 个百分点,精确率仅下降了 0.2 个百分点。改进后的模型能够对矿井火灾进行实时高效检测,并且该检测算法对矿井安全管理具有参考价值。

关键词:改进 YOLOv8n; 注意力机制; 轻量化; 火灾检测; 矿山安全

中图分类号:TD75⁺2

文献标识码:A

文章编号:1005-2763(2025)05-0200-07

Mine Fire Detection Algorithm Based on Improved YOLOv8n

MIAO Zuohua^{1,2}, ZHOU Hao¹, WANG Qiaozhi^{1,2}, XU Houyou³, WANG Mengting³, ZHANG Li¹, BAI Yuchen¹

- (1. School of Resources and Environmental Engineering, Wuhan University of Science and Technology, Wuhan, Hubei 430081, China;
2. Hubei Key Laboratory of Efficient Utilization and Blocking of Metallurgical Mineral Resources, Wuhan, Hubei 430081, China;
3. Sinosteel Wuhan SEPRI Green Century Safety Management & Consultancy Co., Ltd., Wuhan, Hubei 430081, China)

Abstract: Aiming at the problems of low efficiency and difficulty in applying traditional fire detection algorithms to embedded devices with limited resources, a lightweight fire detection algorithm based on improved YOLOv8n was proposed. Firstly, in order to greatly reduce the number of model parameters, the C2f module in the YOLOv8n model was changed to the C2fGhost module. Secondly, in order to prevent the loss of important features after the lightweight of the model, strengthen the feature extraction ability and reduce the interference of irrelevant information in the image, the EMA attention mechanism was added to the Backbone part of the YOLOv8n model. Finally, in order to improve the generalization ability of the model, the CIoU loss function in the YOLOv8n model was replaced by WIoU. The experimental results show that the parameters of the improved model decrease by 30.1%, mAP_{50-95} increases by 0.6 percentage points, and the accuracy rate decreases by only 0.2 percentage points. The improved model can detect the underground fire in real time and efficiently, and the detection algorithm has reference value for mine safety management.

Key words: Improved YOLOv8n, Attention mechanism, Lightweight, Fire detection, Mine safety

0 引言

我国矿产资源埋藏较深,矿藏区域的地质结构较为复杂,开采难度较大,会引发各种重大安全事故,对作业人员的安全造成危害^[1-2]。而矿山火灾是矿山生产中的重大灾害之一,易造成人员伤亡、设备

损毁和资源损失。矿山井下因电器故障、矿工违规操作、可燃物堆积、安全监管不到位等问题都有可能引发火灾。火灾发生初期火势较小、面积不大,若能在早期发现并及时作出应对措施,可避免重大火灾事故的发生。因此,如何提升矿井火灾实时检测速度及精度意义重大。

^{*} 收稿日期:2024-07-16

基金项目:国家自然科学基金项目(41971237,41071242);教育部产学研合作协同育人项目资助项目(202102136008)

作者简介:苗作华(1974—),男,山东德州人,博士,教授,主要从事矿山安全等方面的研究工作。E-mail: miaozuohua@wust.edu.cn

通信作者:王巧稚(1983—),女,湖北荆门人,博士,副教授,主要从事智慧矿山等方面的研究工作。E-mail: wangqiaozhi@wust.edu.cn

随着卷积神经网络技术的发展,深度学习在图像识别方面发挥着重要作用,有许多研究者将深度学习用于火灾检测^[3-5]。冯路佳等^[6]基于卷积神经网络(Convolutional Neural Networks,CNN),通过在目标定位层利用改进的背景差分法以及更改部分卷积层卷积核大小,提出了运用卷积神经网络来增强对火灾烟雾的检测。张坚鑫等^[7]基于 Faster R-CNN,引入 FPN 特征金字塔网络,再结合像素注意力机制和通道注意力机制实现了火灾定位,取得了较好的检测效果。

二阶段目标检测算法精确率高,但模型检测速度较慢,无法实现火灾实时检测。因此要利用单阶段检测算法提高检测速度,实现实时检测^[8]。PINCOTT 等^[9]分别采用 Faster R-CNN Inception V2 和 SSD MobileNet V2 模型检测室内火灾,发现 SSD 模型检测速度快、资源利用率低,但检测精度明显低于 Faster R-CNN 模型。马庆禄等^[10]在 YOLOv5s 的基础上加入加权双向特征金字塔网络,并且增加了一个特征检测头,再用完全交并比替代距离交并比损失函数,提升了模型对火灾的检测效果。

矿井火灾检测不仅需要模型能否高效检测火焰,还需要考虑模型能否部署到资源有限的硬件设备上。因此,如何将轻量化网络用于火灾检测是下一步的研究方向。HAN 等^[11]提出了 GhostNet 轻量化网络,其主要思想是利用线性运算替代部分卷积运算生成每个特征图的重影特征图,使轻量化后的模块运算量明显减少。刘伟^[12]提出 YOLOv5-

Lite 模型检测停车场火灾,该模型在 YOLOv5s 的基础上进行剪枝和替换,大幅降低了模型的复杂度。

内蒙古某金矿实施矿山智能化管理,部署烟火检测、人员“三违”等检测算法,对矿山中 4 个矿井的摄像头进行部署,成功实现了安全生产的智能化监管,及时发现矿井安全风险,报警精准度达到 95%,安全管理效率提升了 60%。

结合火灾检测的国内外研究现状来看, YOLO^[13]算法无疑是目前综合检测速度和精度的最优方法之一。本文在 YOLOv8n^[14]算法模型的基础上,结合轻量化模块、注意力机制^[15-16]以及损失函数模块对原模型进行优化,使其在降低模型参数的同时提升检测准确率。

1 YOLOv8n 网络介绍

YOLOv8 分为 n 、 s 、 m 、 l 、 x 共 5 种尺寸大小不同的模型,本文所用模型 YOLOv8n 是 YOLOv8 中尺寸最小的模型。

图 1 为 YOLOv8n 的网络结构图,Backbone 部分采用 Conv、C2f 和 SPPF 模块将输入信息进行多尺度提取。Neck 部分采用 Conv、C2f、Concat 以及 Upsample 模块对 Backbone 部分采集的多尺度信息进行融合。Head 部分采用解耦合头增强模型泛化能力并且降低计算复杂度。

YOLOv8n 整体采用无锚框的思想进行目标检测,降低检测过程中的超参数数量,提升模型的泛化能力。




图 1 YOLOv8n 网络结构

Fig.1 YOLOv8n network structure

2 算法改进

传统模型参数量大、算法复杂,施工现场的硬件设备通常难以满足模型的部署要求。因此在保证检测准确率的同时,要精简算法模型。首先为实现模型轻量化,本文利用 C2fGhost 模块替换原模型中的

C2f 模块;其次为降低模型轻量化对检测效果的影响,在网络的 Backbone 部分加入 EMA 注意力机制;最后为提升模型精准度及泛化能力,引入 WIoU 损失函数。

2.1 C2fGhost 模块

传统的卷积神经网络使用大量卷积操作,导致

了极高的计算成本。为降低卷积操作的计算量并在最大程度上保留特征信息,Ghost 模块使用普通卷积生成基础特征图,再利用计算量更小的线性运算增强输入图像特征并增加通道数。

卷积运算中生成特征图的运算见式(1)。

$$Y=X * f+b \quad (1)$$

式中: $Y \in R^{h' \times w' \times c'}$ 为高、宽和通道数分别为 h' 、 w' 和 c' 的输出特征图; $X \in R^{h \times w \times c}$ 为高、宽和通道数分别为 h 、 w 和 c 的输入特征图; $*$ 为卷积运算; $f \in R^{c \times k \times k \times n}$ 为大小是 $k \times k$ 的卷积核; b 为偏置项。

卷积运算的运算量 C_1 见式(2)。

$$C_1 = nh'w'ckk \quad (2)$$

式中: C_1 为普通卷积运算的计算量; $k \times k$ 为卷积滤波器的大小。

在 Ghost 模块中,先利用卷积运算生成固有特征图,卷积核大小与普通卷积保持一致,卷积运算过程的计算量为 C_2 (见式(3))。再利用线性运算让每个固有特征图生成多个的重影特征图,线性运算过程的计算量为 C_3 (见式(4))。

$$C_2 = mh'w'ckk \quad (3)$$

$$C_3 = (s-1)mh'w'gg \quad (4)$$

式中: m 为卷积运算生成的特征图数; s 为线性运算生成的重影特征图数; $g \times g$ 为线性运算核的大小。

基于上述运算的结果得出普通卷积与 Ghost 模块的理论运算量 r_s 为:

$$r_s = \frac{C_1}{C_2 + C_3} = \frac{nh'w'ckk}{\frac{n}{s}h'w'ckk + (s-1)\frac{n}{s}h'w'gg} \approx s \quad (5)$$

由上式可知,普通卷积的计算量是 Ghost 模块的 s 倍。因此,将 C2f 模块替换成 C2fGhost 模块后,模型所需计算的参数量将会大幅降低。

利用 Ghost 模块构成 C2fGhost 模块,结构如图 2 所示。




图2 C2fGhost 模块

Fig.2 C2fGhost module

C2f 模块中的 Bottleneck 被替换为 Ghost-Bottleneck,这种改进能减少模型总体尺寸并保持网络的检测精度。

2.2 EMA 注意力机制

EMA 注意力机制通过修改坐标注意力 (Coordinate Attention, CA)^[17-19] 机制的顺序处理方法,得到了一种不降维的高效多尺度注意力机制。

对于任何给定的输入特征图,EMA 将在通道维度方向上将 X 划分为 G 个子特征,使所学习的注意力权重用于增强子特征中感兴趣区域的特征表示。

EMA 利用三条平行的线路分别提取特征图的注意力权重,具体结构如图 3 所示。




图3 EMA 注意力机制结构

Fig.3 Structure of the EMA attention mechanism

在两条并行的 1×1 分支中,首先对特征图的 X 、 Y 通道分别利用 1D 全局平均池化进行编码;其次将两组编码连接起来,使其共享一个 1×1 卷积层,但不会在 1×1 分支中降维,卷积完成后,将输出结果分解为两个向量,然后利用 Sigmoid 函数对这两个向量进行非线性映射,以此拟合出线性卷积操作所对应的 2D 二进制分布;最后将两个通道注意力图融合在一起,在 3×3 分支中利用 3×3 卷积核捕获特征图中的多尺度特征,进而扩大特征空间。

为实现更加丰富的特征聚合效果,EMA 在通道维度上针对跨空间信息的有效聚合,引入了一个 1×1 分支和一个 3×3 分支的输出信息。在 1×1 分支中利用 2D 全局平均池化对输出中的全局空间信息进行编码,最小分支的输出将直接转换为相应的维度形状,即: $R_1^{1 \times C // G} \times R_3^{C // G \times h \times w}$ 。2D 平均池化公式为:

$$z_c = \frac{1}{h \times w} \sum_i^h \sum_j^w x_c(i, j) \quad (6)$$

式中: z_c 为输出特征图上位置在 i, j 且在 c 通道上的值; $x_c(i, j)$ 为输入特征图上位置在 i, j 且在 c 通道上的值。

2D 平均池化的输出被用于 Sigmoid 函数拟合线性变换,每组内的输出特征图被计算为两个空间注意力权重的聚合,至此跨空间信息聚合部分完成。聚合完成后利用 Sigmoid 函数突出显示所有像素的上下文像素,最终使 EMA 输出与输入特征图的大小保持一致。

在 EMA 模块中利用卷积核并行结构,通过使用跨空间学习方法来处理短期和长期的依赖关系,使神经网络获得更好的泛化能力,显著增强特征表示能力。因此,在本文模型中加入 EMA 模块可以增强对火焰和烟雾的识别能力。

2.3 Wise-IoU 损失函数

YOLOv8 采用 CIoU 作为损失函数,CIoU Loss 由预测框和实际框的重叠面积、距离以及纵横比决定。但训练数据中低质量数据会加重关于几何因素的损失函数的惩罚,降低模型适用性。因此,WIoU 提出当锚框与目标框重合度较高时,削弱损失函数对几何度量的惩罚,减少对模型训练的干预,提升其泛化能力,并根据距离度量构建了距离注意力。WIoUv1 的计算公式如下:

$$L_{\text{WIoUv1}} = R_{\text{WIoU}} L_{\text{IoU}} \quad (7)$$

$$R_{\text{WIoU}} = \exp\left(\frac{(x - x_{\text{gt}})^2 + (y - y_{\text{gt}})^2}{(W_{\text{g}}^2 + H_{\text{g}}^2)^*}\right) \quad (8)$$

$$L_{\text{IoU}} = 1 - \text{IoU} \quad (9)$$

式中: L_{WIoUv1} 为 WIoUv1 损失函数; R_{WIoU} 为惩罚项; L_{IoU} 为交并比损失函数; x 为预测框中心横坐标; x_{gt} 为实际框中心横坐标; y 为预测框中心纵坐标; y_{gt} 为实际框中心纵坐标; W_{g} 为最小封闭箱的宽; H_{g} 为最小封闭箱的高; IoU 为预测框与实际框的交并比。

为使模型能够聚焦于困难示例,提升其分类性能,在 WIoUv1 的基础上构造了单调聚焦系数并引入交并比损失函数的均值作为标准化系数。WIoUv2 的计算公式如下:

$$L_{\text{WIoUv2}} = \left(\frac{L_{\text{IoU}}^*}{\bar{L}_{\text{IoU}}}\right)^{\gamma} L_{\text{WIoUv1}} \quad (10)$$

式中: L_{IoU}^* 为单调聚焦系数; $\bar{L}_{\text{IoU}}$ 为动量是 m 的滑动平均 IoU 值。

为防止低质量示例对模型训练产生较大影响,在 WIoUv1 的基础上引入了非单调聚焦系数 r 。WIoUv3 计算公式如下:

$$L_{\text{WIoUv3}} = r L_{\text{WIoUv1}} \quad (11)$$

$$r = \frac{\beta}{\delta \alpha^{\beta - \delta}} \quad (12)$$

$$\beta = \frac{L_{\text{IoU}}^*}{\bar{L}_{\text{IoU}}} \quad (13)$$

式中: L_{WIoUv3} 为 WIoUv3 的损失函数; r 为非单调聚焦系数; β 为离群度,用以描述锚框的质量; α, δ 均为超参数,具体数值可通过网格搜索法计算。

后续试验结果表明,WIoUv3 的试验效果较好,因此,本文采用 WIoUv3 作为损失函数。

基于上述改进,最终得到了改进 YOLOv8n 算法模型,其结构如图 4 所示。




图 4 改进 YOLOv8n 网络结构

Fig.4 Network structure of improved YOLOv8n

3 试验结果与分析

3.1 试验环境与配置

试验使用 PyTorch 深度学习框架,编译环境为 Python 3.10.4+PyTorch 2.0.1+CUDA 11.7,GPU 为 NVIDIA GeForce GTX 1660 Super。

训练模型时参数设定如下:输入数据大小为 640 px×640 px,初始学习率设置为 0.001,模型训练轮次设置为 400,样本批次大小设置为 8,amp 设置为 False,模型采用 GPU 训练。

试验数据集来自网络数据集 Fire_Detection,数据集中火焰与烟雾分别标识为 0 和 1。本文所用数据集中火焰与烟雾占比分别为 60%和 40%。将数据集按 8:1:1 比例划分后,训练集中有 5 657 张图片,而验证集和测试集总共包含 1 414 张图片。

3.2 评价指标

选用精确率(P)、召回率(R)、平均精度均值(mAP)作为模型的评价指标。

精确率(P)计算公式如下:

$$P = \frac{TP}{TP + FP} \quad (14)$$

式中: TP 为实际是烟雾或火焰且被识别为烟雾或

火焰的数量; FP 为实际是其他物体被误识别为烟雾或火焰的数量。

召回率(R) 计算公式如下:

$$R = \frac{TP}{TP + FN} \quad (15)$$

式中: FN 为实际是烟雾或火焰但没有被识别为烟雾或火焰的数量。

平均精度均值(mAP) 计算公式如下:

$$mAP = \sum_{i=1}^n \frac{AP_i}{n} \quad (16)$$

$$AP = \int_0^1 P dR \quad (17)$$

式中, AP 为单个类别的平均精确率。

此外,本文还通过参数量和浮点计算量来评价模型大小及计算量。

3.3 消融试验

为了验证本文改进模型对火灾检测的有效性,以 YOLOv8n 为基准模型,与 EMA 注意力机制模块、C2fGhost 轻量化模块以及 WIoU 损失函数的不同组合进行消融试验,并以精确率、召回率、 $mAP50$ 、 $mAP50-95$ 、参数量及浮点计算量作为评价标准。消融试验结果见表 1。

表 1 消融试验结果

Table 1 Results of ablation experiments

模型	精确率/%	召回率/%	$mAP50$ /%	$mAP50-95$ /%	参数量	浮点计算量/G
YOLOv8n	93.7	90.2	95.5	63.6	3 006 233	8.1
YOLOv8n+EMA	95.8	89.4	95.2	64.2	3 009 705	8.3
YOLOv8n+WIoU	94.2	91.7	96.2	64.7	3 006 233	8.2
YOLOv8n+C2fGhost	93.2	89.4	94.3	62.5	2 099 221	6.0
YOLOv8n+EMA+WIoU	94.6	91.3	95.6	65.1	3 009 705	8.3
YOLOv8n+EMA+C2fGhost	93.0	89.0	94.6	62.4	2 102 693	6.1
YOLOv8n+WIoU+C2fGhost	93.4	89.9	94.5	62.9	2 099 221	5.9
YOLOv8n+EMA+WIoU+C2fGhost	93.5	90.3	95.5	64.2	2 102 693	6.1

注:表中 $mAP50$ 表示预测框和实际边界框的交并比大于 50%的平均精确率均值; $mAP50-95$ 表示预测框和实际边界框的交并比在 50%~95%之间的平均精度均值。

由表 1 可知,加入 EMA 注意力机制后,模型的精确率提升 2.1 个百分点、 $mAP50-95$ 提升 0.6 个百分点,可知 EMA 注意力机制能有效提升模型特征提取能力;将损失函数替换为 WIoU 后,模型的召回率提升 1.5 个百分点, $mAP50$ 和 $mAP50-95$ 分别提升 0.7 和 1.1 个百分点,表明 WIoU 损失函数能有效提升模型的泛化能力;将 C2f 模块替换为 C2fGhost 模块后,模型参数量下降了 30.2%,浮点计算量减少了 25.9%,表明 C2fGhost 模块能有效地减少模型参数量及浮点计算量。

将 EMA 注意力机制与 WIoU 损失函数组合后,模型的精确率提升 0.9 个百分点、召回率提升 1.1 个百分点,表明该组合能有效提升模型检测效果,但模型参数量、浮点计算量较大;将 C2fGhost 模块与 EMA 注意力机制、WIoU 损失函数分别组合后,模型参数量、浮点计算量都有大幅度下降,但精确率、召回率、 mAP 等参数均有所下降,不能同时满足模型轻量化和提升模型检测效果的要求。

基于上述试验结果,将 EMA 注意力机制、C2fGhost 模块、WIoU 损失函数与 YOLOv8n 融合

后,模型参数量、浮点计算量分别降低 30.1%、24.7%, mAP_{50-95} 提升 0.6 个百分点。表明改进后的模型在保证良好检测效果的同时,可大幅度降低模型的参数量以及计算量。

3.4 模型检测应用对比

消融试验结果表明,本文提出模型在训练过程中表现较好,但还需在实际检测中与原模型进行对比。原模型(左)与改进后模型(右)的检测效果对比见图 5。



(a) 原模型检测结果

(b) 改进后检测结果

图 5 检测效果对比

Fig.5 Comparison of detection performance

由图 5 可知,在真实的矿井火焰检测中,改进后算法的检测精准度更高;原模型在检测时将消防员误测为火焰,而改进后的模型则没有发生误测;在烟火混合的情况下,改进后算法表现出更好的检测效果。

综上所述,改进后的算法更适用于矿井中烟雾与火焰的检测。

4 结论

(1) 针对矿井火灾检测实时性低、检测模型复杂度高等问题,本文提出了一种 YOLOv8n 改进算法。为实现模型轻量化,在网络中加入 C2fGhost 模块;为提升模型对火焰识别的准确率,在 Backbone 部分加入 EMA 注意力机制;为提升模型泛化能力,将 CIoU 替换为 WIoU。

(2) 消融试验结果表明,与原 YOLOv8n 模型相比,改进后模型的参数量下降 30.1%,浮点计算量下降 24.7%, mAP_{50-95} 提升 0.6 个百分点,满足矿井火灾实时检测的需求。

(3) 模型检测应用对比试验结果表明,改进后模型在实际应用中检测精确率更高、误检更少且更适用于实际情况下烟火混合等复杂情景检测。

(4) 未来工作中,在算法上应进一步提升模型精确率及召回率,降低漏检、误检的概率。此外,后续算法应更加注重对小目标火焰的检测,提高模型在火灾发生初期的检测效率。

参考文献(References):

- [1] 周亚博,吴斌杰,柏杨,等.深井“T”型巷道火灾的安全区域划分[J].工矿自动化,2023,49(12):130-138.
ZHOU Yabo, WU Binjie, BAI Yang, et al. Classification of safety zones for T-shaped roadway fire in deep coal mines [J]. Journal of Mine Automation, 2023, 49(12): 130-138.
- [2] 杨桦,范国良,唐志新,等.矿井火灾智能疏散模拟研究:以新疆某铜矿为例[J].矿业研究与开发,2021,41(2):155-160.
YANG Hua, FAN Guoliang, TANG Zhixin, et al. Study on intelligent evacuation simulation of mine fire: taking a copper mine in Xinjiang as an example [J]. Mining Research and Development, 2021, 41(2): 155-160.
- [3] 祝玉华,司艺艺,李智慧.基于深度学习的烟雾与火灾检测算法综述[J].计算机工程与应用,2022,58(23):1-11.
ZHU Yuhua, SI Yiyi, LI Zhihui. Overview of smoke and fire detection algorithms based on deep learning [J]. Computer Engineering and Applications, 2022, 58(23): 1-11.
- [4] 邵延华,张铎,楚红雨,等.基于深度学习的 YOLO 目标检测综述[J].电子与信息学报,2022,44(10):3697-3708.
SHAO Yanhua, ZHANG Duo, CHU Hongyu, et al. A review of YOLO object detection based on deep learning [J]. Journal of Electronics & Information Technology, 2022, 44(10): 3697-3708.
- [5] KHAN S, MUHAMMAD K, HUSSAIN T, et al. DeepSmoke: deep learning model for smoke detection and segmentation in outdoor environments [J]. Expert Systems with Application, 2021, 182(1): 115-125.
- [6] 冯路佳,王慧琴,王可,等.基于目标区域的卷积神经网络火灾烟雾识别[J].激光与光电子学进展,2020,57(16):75-83.
FENG Lujia, WANG Huiqin, WANG Ke, et al. Convolutional neural network fire smoke detection based on target region [J]. Laser & Optoelectronics Progress, 2020, 57(16): 75-83.
- [7] 张坚鑫,郭四稳,张国兰,等.基于多尺度特征融合的火灾检测模型[J].郑州大学学报(工学版),2021,42(5):13-18.
ZHANG Jianxin, GUO Siwen, ZHANG Guolan, et al. Fire detection model based on multi-scale feature fusion [J]. Journal of Zhengzhou University (Engineering Science), 2021, 42(5): 13-18.

- [8] 罗会兰,陈鸿坤.基于深度学习的目标检测研究综述[J].电子学报,2020,48(6):1230-1239.
LUO Huilan, CHEN Hongkun. Survey of object detection based on deep learning[J]. Acta Electronica Sinica, 2020, 48(6):1230-1239.
- [9] PINCOTT J, WENBIN P T, WEI S Y, et al. Indoor fire detection utilizing computer vision-based strategies [J]. Journal of Building Engineering, 2022, 61(1):54-81.
- [10] 马庆禄,孙泉,唐小垚,等.基于改进 YOLOv5s 算法的隧道初期火灾检测模型[J].中国安全科学学报,2023,33(10):214-223.
MA Qinglu, SUN Xiao, TANG Xiaoyao, et al. Optimization method for tunnel initial fire detection based on YOLOv5s algorithm [J]. China Safety Science Journal, 2023, 33(10):214-223.
- [11] HAN K, WANG Y H, TIAN Q, et al. GhostNet: more features from cheap operations [C]//Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition. Seattle, WA, USA.: Institute of Electrical and Electronics Engineers, 2020:1577-1586.
- [12] 刘伟.电动车停车场火灾目标跟踪系统[D].杭州:杭州电子科技大学,2023.
LIU Wei. Electric vehicle parking lot fire target tracking system[D]. Hangzhou: Hangzhou Dianzi University, 2023.
- [13] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, Aerada: Institute of Electrical and Electronics Engineers, 2016:779-788.
- [14] 李松,史涛,井方科.改进 YOLOv8 的道路损伤检测算法[J].计算机工程与应用,2023,59(23):165-174.
LI Song, SHI Tao, JING Fangke. Improved road damage detection algorithm of YOLOv8[J]. Computer Engineering and Applications, 2023, 59(23):165-174.
- [15] 皇甫晓瑛,钱惠敏,黄敏.结合注意力机制的深度神经网络综述[J].计算机与现代化,2023(2):40-49.
HUANGFU Xiaoying, QIAN Huimin, HUANG Min. A review of deep neural networks combined with attention mechanism [J]. Computer and Modernization, 2023 (2): 40-49.
- [16] 杨锋,丁之桐,邢蒙蒙,等.深度学习的目标检测算法改进综述[J].计算机工程与应用,2023,59(11):1-15.
YANG Feng, DING Zhitong, XING Mengmeng, et al. Review of object detection algorithm improvement in deep learning[J]. Computer Engineering and Applications, 2023, 59(11):1-15.
- [17] OUYANG D L, HE S, ZHAN J, et al. Efficient multi scale attention module with cross-spatial learning [C]//Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing, Rhodes Island: IEEE, 2023:1-5.
- [18] 王安静,袁巨龙,朱勇建,等.基于改进 YOLOv8s 的鼓形滚子表面缺陷检测算法[J].浙江大学学报(工学版),2024,58(2):370-380.
WANG Anjing, YUAN Julong, ZHU Yongjian, et al. Drum roller surface defect detection algorithm based on improved YOLOv8s [J]. Journal of Zhejiang University (Engineering Science), 2024, 58(2):370-380.
- [19] HOU Q, ZHOU D, FENG J. Coordinate attention for efficient mobile network design [C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition, 2021:13713-13722.